UNIVERSITAS INDONESIA

PENDEKATAN STATIS DAN DYNAMIC BIPLOT UNTUK ANALISIS SPASIO-TEMPORAL SOSIO-EKONOMI (STUDI KASUS: PROVINSI BANTEN, DKI JAKARTA, DAN JAWA BARAT 2020–2024)

SKRIPSI

AMMAR HANAFI
2206051582

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI SARJANA STATISTIKA
DEPOK
JUNI 2026



UNIVERSITAS INDONESIA

PENDEKATAN STATIS DAN DYNAMIC BIPLOT UNTUK ANALISIS SPASIO-TEMPORAL SOSIO-EKONOMI (STUDI KASUS: PROVINSI BANTEN, DKI JAKARTA, DAN JAWA BARAT 2020–2024)

SKRIPSI

Diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Statistika

AMMAR HANAFI
2206051582

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI SARJANA STATISTIKA
DEPOK
JUNI 2026

HALAMAN PERSETUJUAN

Judul	:	Pendekatan STATIS dan Dynamic Biplot untuk Analisis Spasio-Temporal Sosio-Ekonomi (Studi Kasus: Provinsi Banten, DKI Jakarta, dan Jawa Barat 2020–2024)
Nama	:	Ammar Hanafi
NPM	:	2206051582

Laporan Skripsi ini telah diperiksa dan disetujui.

17 April 2026

Dr. Dra. Yekti Widyaningsih, M.Si.

Pembimbing Skripsi

HALAMAN PERNYATAAN ORISINALITAS

Skripsi ini adalah hasil karya saya sendiri,
dan semua sumber baik yang dikutip maupun dirujuk
telah saya nyatakan dengan benar.

Nama : Ammar Hanafi

NPM : 2206051582

Tanda Tangan

Tanggal : 17 April 2026

HALAMAN PENGESAHAN

Skripsi ini diajukan oleh	:	
Nama	:	Ammar Hanafi
NPM	:	2206051582
Program Studi	:	Sarjana Statistika
Judul Skripsi	:	Pendekatan STATIS dan Dynamic Biplot untuk Analisis Spasio-Temporal Sosio-Ekonomi (Studi Kasus: Provinsi Banten, DKI Jakarta, dan Jawa Barat 2020–2024)

Telah berhasil dipertahankan di hadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Sarjana Statistika pada Program Studi Sarjana Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Indonesia.

DEWAN PENGUJI

Pembimbing I	:	Dr. Dra. Yekti Widyaningsih, M.Si.	( )
Penguji I	:	Sarini Abdullah, S.Si., M.Stats., Ph.D.	( )
Penguji II	:	Gianinna Ardaneswari, S.Si., M.Si.	( )

Ditetapkan di	:	Depok
Tanggal	:	27 April 2026

HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL

Saya menyatakan bahwa dalam penyusunan Tugas Akhir ini, saya menggunakan teknologi Kecerdasan Buatan dengan *platform* Antigravity untuk tujuan membantu dalam penulisan Tugas Akhir ini dan saya bertanggung jawab penuh atas keakuratan, orisinalitas, dan integritas seluruh isi Tugas Akhir ini.

Nama	**:**	**Ammar Hanafi**
NPM	**:**	**2206051582**
Tanda Tangan	**:**	
Tanggal	**:**	**17 April 2026**

KATA PENGANTAR

Assalamu'alaikum Warahmatullahi Wabarakatuh

Alhamdulillah. Puji syukur penulis panjatkan kepada Allah SWT atas segala rahmat dan karunia-Nya, penulis dapat menjalani perkuliahan hingga menyelesaikan penulisan skripsi ini. Penulisan skripsi ini dilakukan dalam rangka memenuhi salah satu syarat untuk memperoleh gelar Sarjana Statistika pada Program Studi S1 Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Indonesia. Penulis menyadari bahwa selama menjalani perkuliahan hingga penyusunan skripsi ini, tidak terlepas dari segala bantuan, dukungan, bimbingan, serta doa dari orang-orang di sekitar. Oleh karena itu, penulis mengucapkan terima kasih kepada:

1. Dr. Dra. Yekti Widyaningsih, M.Si. selaku Dosen Pembimbing skripsi penulis yang telah memberikan waktu, tenaga, dan ilmu untuk membimbing penulis dalam penyusunan skripsi ini sehingga selesai pada waktunya. Terima kasih atas segala pengertian, dukungan, nasihat, dan doa yang diberikan sehingga penulis dapat menyelesaikan skripsi ini.
2. Prof. Alhadi B., S.Si., M.Kom., Ph.D. selaku Ketua Departemen Matematika FMIPA UI yang telah memberikan arahan selama masa perkuliahan di FMIPA UI.
3. Dr. Helen Burhan, S.Si., M.Si. selaku Ketua Program Studi S1 Statistika. Terima kasih atas segala bantuan, perhatian, dan bimbingan akademik kepada penulis selama masa perkuliahan.
4. Sarini Abdullah, S.Si., M.Stats., Ph.D. dan Gianinna Ardaneswari, S.Si., M.Si. selaku Dosen Penguji I dan Dosen Penguji II pada sidang skripsi penulis. Terima kasih atas segala saran dan arahannya kepada penulis sehingga skripsi ini menjadi lebih baik.
5. Seluruh keluarga Departemen Matematika FMIPA UI yang telah memberikan banyak ilmu yang bermanfaat bagi penulis. Terima kasih juga kepada para staf yang telah berkontribusi dalam mendukung kelancaran perkuliahan.
6. Kedua orang tua penulis yang sangat penulis sayangi. Terima kasih atas segala pengertian, dukungan, dan doa yang telah diberikan sehingga penulis dapat menjalani perkuliahan hingga selesai.
7. Teman-teman seperjuangan angkatan 2022 serta seluruh pihak yang pernah penulis kenal. Terima kasih atas dukungan dan bantuan yang begitu besar kepada penulis. Penulis sangat bersyukur bisa bertemu dan mengenal kalian. Kontribusi kalian membuat penulis dapat menjalani perkuliahan dengan lebih mudah dan menyenangkan.

8. Seluruh pihak yang tanpa mengurangi rasa hormat, tidak bisa disebutkan satu per satu.

Semoga Allah SWT senantiasa memberikan kesehatan, kebahagiaan, keberkahan, serta umur yang panjang. Penulis berharap skripsi ini dapat memberi manfaat untuk penelitian-penelitian selanjutnya. Akhir kata, penulis mengucapkan terima kasih kepada semua pihak yang turut membantu dalam penelitian ini.

Wassalamu'alaikum Warahmatullahi Wabarakatuh

Depok, 17 April 2026
Ammar Hanafi

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas akademik Universitas Indonesia, saya yang bertanda tangan di bawah ini:

Nama	:	Ammar Hanafi
NPM	:	2206051582
Program Studi	:	Sarjana Statistika
Fakultas	:	Matematika dan Ilmu Pengetahuan Alam
Jenis Karya	:	Skripsi

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Indonesia **Hak Bebas Royalti Noneksklusif (*Non-exclusive Royalty Free Right*)** atas karya ilmiah saya yang berjudul:

Pendekatan STATIS dan Dynamic Biplot untuk Analisis Spasio-Temporal Sosio-Ekonomi (Studi Kasus: Provinsi Banten, DKI Jakarta, dan Jawa Barat 2020–2024)

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini, Universitas Indonesia berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*data base*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Kota Depok
Pada tanggal : 17 April 2026

Yang menyatakan

(Ammar Hanafi)

ABSTRAK

Nama	:	Ammar Hanafi
Program Studi	:	Sarjana Statistika
Judul	:	Pendekatan STATIS dan Dynamic Biplot untuk Analisis Spasio-Temporal Sosio-Ekonomi (Studi Kasus: Provinsi Banten, DKI Jakarta, dan Jawa Barat 2020–2024)

Dinamika pembangunan di wilayah strategis Provinsi Banten, DKI Jakarta, dan Jawa Barat menunjukkan kompleksitas yang tinggi selama periode 2020–2024. Sebagai pusat aglomerasi ekonomi nasional, ketiga provinsi ini mengalami perubahan simultan akibat pandemi COVID-19 yang diikuti oleh fase pemulihan yang tidak seragam antar-kabupaten/kota. Perubahan ini tidak hanya terjadi pada indikator makroekonomi, tetapi juga merambat pada dimensi kesejahteraan sosial dan kualitas modal manusia. Untuk memahami evolusi struktur hubungan antar-indikator tersebut secara menyeluruh, diperlukan pendekatan analisis data tiga-arah (*three-way data*) yang mampu memahami pola interaksi spasio-temporal.

Penelitian ini menerapkan metode STATIS (*Structuration des Tableaux à Trois Indices de la Statistique*) untuk menganalisis dinamika 12 indikator pembangunan strategis—meliputi aspek ekonomi (PDRB), kesejahteraan (Kemiskinan, Garis Kemiskinan, Pangan), pembangunan manusia (IPM, Pendidikan, Kesehatan), ketenagakerjaan, serta kesetaraan (Gender, Gini Ratio)—di seluruh kabupaten/kota pada ketiga provinsi tersebut. Analisis berpusat pada pembentukan struktur kompromi (*compromise structure*). Merujuk pada definisi Lavit et al. (1994), struktur kompromi ($\mathbf{W}_c$) dikonstruksi sebagai jumlah tertimbang (*weighted sum*) dari matriks intra-struktur tahunan, di mana bobot (α_k) ditentukan berdasarkan dekomposisi spektral untuk memaksimumkan kesamaan antar-tahun. Struktur ini merepresentasikan pola hubungan antar-wilayah yang paling dominan dan stabil selama periode pengamatan. Selanjutnya, penelitian ini menguji signifikansi stabilitas struktur tersebut menggunakan uji permutasi dan mengintegrasikan konsep *Dynamic Biplot* untuk memvisualisasikan lintasan (*trajectory*) pergerakan kabupaten/kota dari masa krisis hingga pemulihan dalam ruang berdimensi rendah.

Seluruh prosedur analisis, mulai dari pra-pemrosesan data hingga visualisasi, diimplementasikan menggunakan bahasa pemrograman Python ke dalam aplikasi *dashboard* web interaktif. Sistem ini menyediakan fitur analisis lengkap, mulai dari uji diagnostik (KMO, Bartlett), analisis STATIS, hingga evaluasi klaster secara spasio-temporal (Elbow, Dendrogram, Matriks Transisi). Dengan dukungan rotasi *baseline*, filter lintasan wilayah, serta integrasi otomatis ke format LaTeX. Aplikasi ini hadir sebagai instrumen analitik dan visual yang komprehensif bagi peneliti maupun pemangku kebijakan dalam memantau resiliensi serta akselerasi pemerataan pembangunan daerah pasca-pandemi.

Kata kunci: Analisis Tiga-arah, Autokorelasi Spasial, Data Panel, K-Means Clustering, Pembangunan Regional, Visualisasi Interaktif.

ABSTRACT

Name	:	Ammar Hanafi
Program	:	Undergraduate Study Program of Statistics
Title	:	STATIC and Dynamic Biplot Approaches for Socio-Economic Spatio-Temporal Analysis (Case Studies: Province of Banten, DKI Jakarta, and West Java 2020–2024)

The development dynamics in the strategic regions of Banten, DKI Jakarta, and West Java exhibited high complexity during the 2020–2024 period. As the center of national economic agglomeration, these three provinces experienced simultaneous changes due to the COVID-19 pandemic, followed by an uneven recovery phase across regencies/cities. These changes occurred not only in macroeconomic indicators but also propagated to dimensions of social welfare and human capital quality. To thoroughly understand the evolution of the structural relationships among these indicators, a three-way data analysis approach capable of capturing spatio-temporal interaction patterns is required.

This research applies the STATIS (*Structuration des Tableaux à Trois Indices de la Statistique*) method to analyze the dynamics of 12 strategic development indicators—covering economic aspects (GRDP), welfare (Poverty, Poverty Line, Food), human development (HDI, Education, Health), labor, and equality (Gender, Gini Ratio)—across all regencies/cities in the three provinces. The analysis centers on the formation of a compromise structure. Referring to the definition by Lavit et al. (1994), the compromise structure ($\mathbf{W}_c$) is constructed as a weighted sum of annual intra-structure matrices, where the weights (α_k) are determined based on spectral decomposition to maximize inter-year similarity. This structure represents the most dominant and stable inter-regional relationship patterns during the observation period. Furthermore, this study tests the significance of the structure's stability using permutation tests and integrates the Dynamic Biplot concept to visualize the movement trajectories of regencies/cities from the crisis to the recovery period in a low-dimensional space.

The entire analysis procedure, from data pre-processing to visualization, is implemented using the Python programming language within an interactive web dashboard. This system provides a comprehensive suite of analysis features, ranging from diagnostic tests (KMO, Bartlett) and STATIS analysis to spatio-temporal cluster evaluation (Elbow Method, Dendrograms, Transition Matrices). Through interactive features such as baseline rotation, regional trajectory filtering, and automatic integration of results into LaTeX. This application serves as a sophisticated analytical and visual tool for researchers and policymakers to monitor resilience and accelerate regional development equity in the post-pandemic era.

Keywords: Interactive Visualization, K-Means Clustering, Panel Data, Regional Development, Spatial Autocorrelation, Three-way Analysis.

DAFTAR ISI

LEMBAR PERSETUJUAN . . . . . **iii**

HALAMAN PERNYATAAN ORISINALITAS . . . . . **iv**

HALAMAN PENGESAHAN . . . . . **v**

SURAT PERNYATAAN . . . . . **vii**

KATA PENGANTAR . . . . . **ix**

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI . . . . . **xi**

ABSTRAK . . . . . **xiii**

ABSTRACT . . . . . **xv**

DAFTAR ISI . . . . . **xvii**

DAFTAR TABEL . . . . . **xxiii**

DAFTAR GAMBAR . . . . . **xxvii**

DAFTAR LAMPIRAN . . . . . **xxix**

BAB 1 PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 4

1.3 Tujuan Penelitian 5

1.4 Manfaat Penelitian 6

1.5 Ruang Lingkup Penelitian 6

BAB 2 LANDASAN TEORI **7**

2.1 Indikator Kesejahteraan Rakyat 7

2.1.1 Indeks Pembangunan Manusia (IPM) 7
2.1.2 Produk Domestik Regional Bruto (PDRB ADHK) 8
2.1.3 Persentase Penduduk Miskin (PPM) 8
2.1.4 Garis Kemiskinan (GK) 8
2.1.5 Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP) 8
2.1.6 Tingkat Pengangguran Terbuka (TPT) 9
2.1.7 Tingkat Partisipasi Angkatan Kerja (TPAK) 9
2.1.8 Rata-Rata Lama Sekolah (RLS) 9
2.1.9 Angka Harapan Hidup Laki-laki 9
2.1.10 Angka Harapan Hidup Perempuan 10
2.1.11 Indeks Pembangunan Gender (IPG) 10
2.1.12 Gini Ratio (GR) 10
2.1.13 Jumlah Penduduk (JP) 10
2.2 Tinjauan Penelitian Terdahulu 11
2.3 Analisis Data Tiga-Arah (*Three-Way Data*) 11
2.4 Konsep Spasio-Temporal dalam Analisis Multivariat 12
2.5 Standardisasi Data 13
2.6 Statistika Deskriptif 14
2.6.1 Ukuran Pemusatan 14
2.6.2 Ukuran Penyebaran 15
2.6.3 Ukuran Bentuk Distribusi 16
2.7 Pemilihan Variabel dalam Analisis Multivariat 16
2.7.1 Uji Kaiser-Meyer-Olkin (KMO) 17
2.7.2 Uji Bartlett tentang Spherisitas (*Bartlett's Test of Sphericity*) . . . 18
2.8 Dasar Aljabar Linier dan Dekomposisi Matriks 19
2.9 Korelasi Pearson 21
2.10 *Principal Component Analysis* (PCA) dan Biplot 22
2.11 Metode STATIS 23
2.11.1 Tahap 1: Intra-struktur 23
2.11.2 Tahap 2: Inter-struktur 24
2.11.3 Tahap 3: Analisis Kompromi 25
2.11.4 Tahap 4: Analisis Variabel (Loadings) 26
2.11.5 Klasifikasi Struktur: Analisis Transversal dan Longitudinal 27
2.11.6 Uji Signifikansi Stabilitas Struktur (Permutasi Monte Carlo) . . . 28
2.11.7 Model Vektor Struktur dan Kerangka Inferensial STATIS 30
2.12 Dynamic Biplot dan Visualisasi Trajektori 32

2.12.1 Proyeksi Lintasan (*Trajectory*) . . . 32
2.12.2 Jarak Euclidean antar Trajektori . . . 33
2.12.3 Rotasi Baseline . . . 33
2.13 Metode Pengelompokan (*Clustering*) . . . 34
2.13.1 K-Means Clustering . . . 34
2.13.2 Penentuan Jumlah Klaster Optimal (Metode Elbow) . . . 35
2.13.3 Agglomerative Hierarchical Clustering (Dendrogram) . . . 35
2.13.4 Matriks Transisi Temporal . . . 35
2.13.5 Penyelarasan Klaster Lintas Waktu (*Cluster Correspondence*) . . . 36
2.14 Uji Autokorelasi Spasial (Global Moran's I) . . . 37
2.14.1 Matriks Pembobot Spasial . . . 37
2.14.2 Statistik Global Moran's I . . . 37
2.15 Visualisasi Interaktif menggunakan Plotly dan Dash . . . 38
2.16 Kerangka Berpikir . . . 39

BAB 3 METODOLOGI PENELITIAN . . . 41
3.1 Statistika Deskriptif . . . 41
3.2 Jenis Penelitian . . . 41
3.3 Desain Penelitian . . . 42
3.4 Populasi dan Sampel . . . 44
3.5 Teknik Pengumpulan Data . . . 44
3.6 Validasi Instrumen . . . 45
3.7 Teknik Analisis Data . . . 46
3.7.1 Ilustrasi Pelaksanaan Prosedur Komputasi STATIS . . . 47
3.7.1.1 Tahap 0: Pra-pemrosesan dan Bobot Demografis . . . 47
3.7.1.2 Tahap 1: Standardisasi Data ($\mathbf{Z}_k$) . . . 48
3.7.1.3 Tahap 2: Matriks Intra-struktur ($\mathbf{W}_k$) . . . 50
3.7.1.4 Tahap 3: Analisis Inter-struktur (Koefisien RV) . . . 51
3.7.1.5 Tahap 4: Bobot Kompromi (α_k) . . . 52
3.7.1.6 Tahap 5: Sintesis Matriks Kompromi ($\mathbf{W}_c$) . . . 53
3.7.1.7 Tahap 6: Skor dan Loading Kompromi . . . 54
3.7.1.8 Tahap 7: Uji Signifikansi dan Clustering . . . 55
3.7.1.9 Tahap 8: Perbandingan Klaster Biplot vs STATIS . . . 56
3.7.1.10 Tahap 9: Tabulasi Silang K-Means vs IPM UNDP . . . 57
3.7.2 Penyelarasan Label Klaster Lintas Waktu . . . 58
3.7.3 Kategorisasi dan Perankingan Klaster . . . 58

3.7.4 Analisis Autokorelasi Spasial (Global Moran's I) 59

BAB 4 HASIL DAN PEMBAHASAN 61

4.1 Eksplorasi Data Awal 61

4.1.1 Statistika Deskriptif 61

4.1.2 Distribusi Variabel (Boxplot) 63

4.2 Uji Kelayakan Data Multivariat 65

4.2.1 Hasil Uji KMO dan Bartlett 65

4.3 Analisis Inter-struktur 66

4.3.1 Matriks Koefisien RV 66

4.3.2 Vektor Bobot (Alpha) dan Representativitas Tahun 67

4.4 Analisis Struktur Kompromi 67

4.4.1 Dekomposisi Eigenvalue (Scree Plot) 68

4.4.2 Peta Kompromi (Skor Objek) 70

4.4.3 Biplot Kompromi (Skor + Loading) 71

4.4.4 Loading Plot (Correlation Circle) 73

4.4.5 Kontribusi dan Kualitas Representasi Variabel 73

4.4.6 Skor Kompromi Kabupaten/Kota 75

4.5 Uji Stabilitas Struktur Kompromi (Permutation Test) 76

4.5.1 Prosedur dan Hasil Uji Permutasi 77

4.5.2 Interpretasi 78

4.5.3 Analisis Vektor Struktur ($\tilde{\beta}$) dan Dominansi Interstruktur 78

4.6 Analisis Dinamika Spasio-Temporal (Trajektori) 81

4.6.1 Gambaran Umum Trajektori 2020 hingga 2024 81

4.6.2 Snapshot Biplot per Tahun 82

4.6.3 Dinamika Struktur Variabel Tahunan 87

4.7 Analisis Klaster Spasio-Temporal 88

4.7.1 Penentuan Jumlah Klaster Optimal 89

4.7.2 Pola Pengelompokan Tahunan 90

4.7.3 Matriks Transisi Klaster 93

4.7.4 Klaster Trajektori Keseluruhan 98

4.7.5 Perbandingan Cluster Biplot (Unweighted) vs STATIS (Weighted) Tahunan 101

4.8 Evaluasi Klaster terhadap Kategori IPM UNDP 106

4.8.1 Matriks Transisi Kategori IPM 106

4.8.2 Tabulasi Silang K-Means vs. Kategori IPM 114

4.9 Uji Autokorelasi Spasial (Global Moran's I) 119
4.10 Analisis Hotspot (Local Moran's I) 119
4.11 Ringkasan Temuan dan Implikasi Kebijakan 119
4.11.1 Pembahasan Berdasarkan Tujuan Penelitian 119
4.11.2 Kontribusi terhadap Manfaat Penelitian 120
4.11.3 Implikasi Kebijakan 121

BAB 5 KESIMPULAN DAN SARAN 123
5.1 Kesimpulan 123
5.2 Saran 124

DAFTAR PUSTAKA 127

DAFTAR TABEL

Tabel 2.1 Ringkasan Penelitian Terdahulu 11
Tabel 2.2 Kriteria Interpretasi Nilai KMO 18

Tabel 3.1 Statistika Deskriptif Tahun 2020 47
Tabel 3.2 Statistika Deskriptif Tahun 2021 47
Tabel 3.3 Statistika Deskriptif Tahun 2022 47
Tabel 3.4 Matriks Korelasi Terbobot Variabel Tahun 2020 ($\mathbf{S}_{2020}$) 51
Tabel 3.5 Matriks Korelasi Terbobot Variabel Tahun 2021 ($\mathbf{S}_{2021}$) 51
Tabel 3.6 Matriks Korelasi Terbobot Variabel Tahun 2022 ($\mathbf{S}_{2022}$) 51
Tabel 3.7 Matriks Koefisien RV Antar-Tahun 51
Tabel 3.8 Nilai Bobot (Alpha) Tiap Tahun 52
Tabel 3.9 Dekomposisi Nilai Eigen Matriks Kompromi 53
Tabel 3.10 Diagnostik Dominansi Model Rank-1 (Areia et al., 2008) 53
Tabel 3.11 Koordinat Skor Kompromi (Fc) 54
Tabel 3.12 Loadings Kompromi (Korelasi Variabel vs Skor) 54
Tabel 3.13 Anggota Klaster Trajektori Keseluruhan 55
Tabel 3.14 Matriks Transisi Klaster 2020 $\rightarrow$ 2021 56
Tabel 3.15 Matriks Transisi Klaster 2021 $\rightarrow$ 2022 56
Tabel 3.16 Matriks Perbandingan Cluster Biplot vs STATIS (2020) 57
Tabel 3.17 Nama Daerah Perbandingan Cluster Biplot vs STATIS (2020) 57
Tabel 3.18 Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2020) . . . 58
Tabel 3.19 Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2020) 58

Tabel 4.1 Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2020 . . 62
Tabel 4.2 Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2021 . . 62
Tabel 4.3 Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2022 . . 62
Tabel 4.4 Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2023 . . 62
Tabel 4.5 Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2024 . . 63

Tabel 4.6 Hasil Uji KMO dan Bartlett per Tahun 65
Tabel 4.7 Matriks Koefisien RV Antar-Tahun 66
Tabel 4.8 Nilai Bobot (Alpha) Tiap Tahun 67
Tabel 4.9 Dekomposisi Nilai Eigen Matriks Kompromi 69
Tabel 4.10 Loadings Kompromi (Korelasi Variabel vs Skor) 72
Tabel 4.11 Matriks Vektor Eigen Kompromi (Vc) 72
Tabel 4.12 Koordinat Skor Kompromi (Fc) 76
Tabel 4.13 Rangkuman Hasil Uji Permutasi 77
Tabel 4.14 Komponen Vektor Struktur $\tilde{\boldsymbol{\beta}}$ per Situasi Waktu 78
Tabel 4.15 Diagnostik Dominansi Model Rank-1 (Areia et al., 2008) 79
Tabel 4.16 Komponen Vektor Struktur $\tilde{\beta}_{gk}$ per Provinsi (Analisis Transversal) . 80
Tabel 4.17 Loading Intra-Struktur Variabel Tahun 2020 hingga 2022 88
Tabel 4.18 Loading Intra Tahun 2020 ($\mathbf{G}_{2020}$) 88
Tabel 4.19 Loading Intra Tahun 2021 ($\mathbf{G}_{2021}$) 88
Tabel 4.20 Loading Intra Tahun 2022 ($\mathbf{G}_{2022}$) 88
Tabel 4.21 Loading Intra-Struktur Variabel Tahun 2023 hingga 2024 88
Tabel 4.22 Loading Intra Tahun 2023 ($\mathbf{G}_{2023}$) 88
Tabel 4.23 Loading Intra Tahun 2024 ($\mathbf{G}_{2024}$) 88
Tabel 4.24 Matriks Transisi Klaster 2020 $\rightarrow$ 2021 94
Tabel 4.25 Nama Daerah Perpindahan Klaster 2020 $\rightarrow$ 2021 94
Tabel 4.26 Matriks Transisi Klaster 2021 $\rightarrow$ 2022 95
Tabel 4.27 Nama Daerah Perpindahan Klaster 2021 $\rightarrow$ 2022 95
Tabel 4.28 Matriks Transisi Klaster 2022 $\rightarrow$ 2023 95
Tabel 4.29 Nama Daerah Perpindahan Klaster 2022 $\rightarrow$ 2023 96
Tabel 4.30 Matriks Transisi Klaster 2023 $\rightarrow$ 2024 96
Tabel 4.31 Nama Daerah Perpindahan Klaster 2023 $\rightarrow$ 2024 97
Tabel 4.32 Anggota Klaster Trajektori Keseluruhan 100
Tabel 4.33 Matriks Perbandingan Cluster Biplot vs STATIS (2020) 101
Tabel 4.34 Nama Daerah Perbandingan Cluster Biplot vs STATIS (2020) 101
Tabel 4.35 Matriks Perbandingan Cluster Biplot vs STATIS (2021) 101
Tabel 4.36 Nama Daerah Perbandingan Cluster Biplot vs STATIS (2021) 102
Tabel 4.37 Matriks Perbandingan Cluster Biplot vs STATIS (2022) 102
Tabel 4.38 Nama Daerah Perbandingan Cluster Biplot vs STATIS (2022) 103
Tabel 4.39 Matriks Perbandingan Cluster Biplot vs STATIS (2023) 103
Tabel 4.40 Nama Daerah Perbandingan Cluster Biplot vs STATIS (2023) 104
Tabel 4.41 Matriks Perbandingan Cluster Biplot vs STATIS (2024) 104

Tabel 4.42 Nama Daerah Perbandingan Cluster Biplot vs STATIS (2024) 105
Tabel 4.43 Matriks Transisi Kategori IPM (UNDP) Tahun 2020 ke 2021 106
Tabel 4.44 Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2020 $\rightarrow$ 2021 107
Tabel 4.45 Matriks Transisi Kategori IPM (UNDP) Tahun 2021 ke 2022 108
Tabel 4.46 Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2021 $\rightarrow$ 2022 109
Tabel 4.47 Matriks Transisi Kategori IPM (UNDP) Tahun 2022 ke 2023 110
Tabel 4.48 Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2022 $\rightarrow$ 2023 111
Tabel 4.49 Matriks Transisi Kategori IPM (UNDP) Tahun 2023 ke 2024 112
Tabel 4.50 Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2023 $\rightarrow$ 2024 113
Tabel 4.51 Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2020) . . . 114
Tabel 4.52 Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2020) 114
Tabel 4.53 Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2021) . . . 115
Tabel 4.54 Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2021) 115
Tabel 4.55 Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2022) . . . 115
Tabel 4.56 Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2022) 116
Tabel 4.57 Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2023) . . . 116
Tabel 4.58 Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2023) 117
Tabel 4.59 Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2024) . . . 117
Tabel 4.60 Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2024) 118

DAFTAR GAMBAR

Gambar 2.1 Flowchart Mekanisme Interaktivitas Dash-Plotly 39

Gambar 3.1 *Flowchart* Alur Metodologi Penelitian 43
Gambar 3.2 Visualisasi Heatmap Matriks RV Data Sampel 52
Gambar 3.3 Scree Plot Analisis Kompromi Data Sampel 53
Gambar 3.4 Compromise Biplot (Skor dan Loading) Data Sampel 54
Gambar 3.5 Visualisasi Trajektori Spasio-Temporal Data Sampel 55
Gambar 3.6 Perbandingan Spasial Klaster Biplot vs STATIS Data Sampel (2020) 57

Gambar 4.1 Boxplot IPM Tahun 2020, 2022, dan 2024 64
Gambar 4.2 Boxplot Persentase Penduduk Miskin (PPM) Tahun 2020, 2022, dan 2024 64
Gambar 4.3 Boxplot PDRB ADHK Tahun 2020, 2022, dan 2024 64
Gambar 4.4 Boxplot Tingkat Pengangguran Terbuka (TPT) Tahun 2020, 2022, dan 2024 64
Gambar 4.5 Boxplot Rata-Rata Lama Sekolah (RLS) Tahun 2020, 2022, dan 2024 65
Gambar 4.6 Heatmap Koefisien RV Antar-Tahun (2020 hingga 2024) 66
Gambar 4.7 Scree Plot Nilai Eigen Matriks Kompromi 68
Gambar 4.8 Peta Skor Kompromi 41 Kabupaten/Kota (2020 hingga 2024) . . 70
Gambar 4.9 Biplot Kompromi: Skor Objek dan Loading Variabel 71
Gambar 4.10 Loading Plot (Correlation Circle) pada Ruang Kompromi 73
Gambar 4.11 Kontribusi Variabel terhadap Dimensi 1 Kompromi (%) 74
Gambar 4.12 Kualitas Representasi Variabel pada Dimensi 1 ($\cos^2$) 74
Gambar 4.13 Distribusi Null Uji Permutasi vs. Nilai Eigen Observasi (λ_1^{obs}) . . 77
Gambar 4.14 Lintasan Temporal Komponen Vektor Struktur $\tilde{\beta}_k$ (2020 hingga 2024) 80
Gambar 4.15 Trajektori Pergerakan 41 Kabupaten/Kota pada Ruang Kompromi (2020 hingga 2024) 81

Gambar 4.16 Biplot Tahunan Tahun 2020 (Masa Awal Pandemi) 83
Gambar 4.17 Biplot Tahunan Tahun 2021 84
Gambar 4.18 Biplot Tahunan Tahun 2022 (Awal Masa Pemulihan) 85
Gambar 4.19 Biplot Tahunan Tahun 2023 86
Gambar 4.20 Biplot Tahunan Tahun 2024 87
Gambar 4.21 Kurva Elbow dan Dendrogram Tahun 2020 89
Gambar 4.22 Kurva Elbow dan Dendrogram Tahun 2021 89
Gambar 4.23 Kurva Elbow dan Dendrogram Tahun 2022 89
Gambar 4.24 Kurva Elbow dan Dendrogram Tahun 2023 90
Gambar 4.25 Kurva Elbow dan Dendrogram Tahun 2024 90
Gambar 4.26 Pengelompokan K-Means ($k = 3$) Tahun 2020: Biplot (kiri) dan Peta (kanan) 91
Gambar 4.27 Pengelompokan K-Means ($k = 3$) Tahun 2021: Biplot (kiri) dan Peta (kanan) 91
Gambar 4.28 Pengelompokan K-Means ($k = 3$) Tahun 2022: Biplot (kiri) dan Peta (kanan) 92
Gambar 4.29 Pengelompokan K-Means ($k = 3$) Tahun 2023: Biplot (kiri) dan Peta (kanan) 92
Gambar 4.30 Pengelompokan K-Means ($k = 3$) Tahun 2024: Biplot (kiri) dan Peta (kanan) 93
Gambar 4.31 Dendrogram Klaster Trajektori Keseluruhan (2020 hingga 2024) . 98
Gambar 4.32 Scatter Plot Klaster Trajektori pada Ruang Kompromi 99
Gambar 4.33 Perbandingan Peta Klaster Biplot vs STATIS Tahun 2024 105

Gambar 1 Tampilan Antarmuka Aplikasi Dashboard Analisis Spasio-Temporal Sosio-Ekonomi 147

DAFTAR LAMPIRAN

Lampiran 1 Data Penelitian 133
Lampiran 2 Kode Program Aplikasi Dashboard 147

BAB 1
PENDAHULUAN

1.1 Latar Belakang

Kawasan strategis yang meliputi Provinsi Banten, DKI Jakarta, dan Jawa Barat tidak hanya berperan sebagai mesin pertumbuhan ekonomi nasional, tetapi juga menjadi arena dinamika pembangunan manusia yang sangat kompleks dalam lima tahun terakhir. Meskipun wilayah ini memberikan kontribusi yang sangat dominan terhadap perekonomian nasional dengan rata-rata pangsa Produk Domestik Regional Bruto (PDRB) berkisar 33,8 persen dari PDRB Indonesia (Badan Pusat Statistik, 2025b), di mana keberhasilan pembangunannya tidak dapat lagi diukur hanya melalui kacamata indikator makro ekonomi semata. Terdapat interaksi multidimensi yang melibatkan kualitas hidup yang tecermin dalam Indeks Pembangunan Manusia (IPM), Indeks Pembangunan Gender (IPG), serta tantangan kesejahteraan sosial seperti kemiskinan dan ketahanan pangan yang terus mengalami perubahan. Kompleksitas ini menuntut pembuktian empiris yang lebih mendalam untuk melihat bagaimana indikator-indikator tersebut terdistribusi secara nyata di seluruh kabupaten/kota.

Secara empiris, lanskap pembangunan di ketiga provinsi ini menunjukkan polarisasi yang tajam antara pusat-pusat pertumbuhan utama dan wilayah penyangga. Meskipun data PDRB di kota-kota besar mencatat performa ekonomi yang kuat dengan nilai mencapai 532.606,87 miliar rupiah (Badan Pusat Statistik, 2025b), capaian tersebut tidak serta-merta diikuti oleh pemerataan kesejahteraan. Hal ini terlihat dari variasi spasial yang mencolok (*striking spatial variation*) pada indikator kemiskinan, di mana Persentase Penduduk Miskin (PPM) terentang lebar dari 2,29 persen hingga mencapai 15,06 persen di wilayah lainnya. Kesenjangan ini juga terkonfirmasi oleh indikator daya beli, terlihat dari perbedaan Garis Kemiskinan (GK) dan Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP) yang bervariasi lebar antarwilayah (Badan Pusat Statistik, 2024). Lebih jauh lagi, disparitas kapabilitas manusia juga terlihat mencolok; Rata-rata Lama Sekolah (RLS) dan Angka Harapan Hidup (AHH) masih menunjukkan perbedaan yang nyata. Indeks Pembangunan Gender (IPG) serta Tingkat Pengangguran Terbuka (TPT) masih berada di kisaran 6,55 hingga 10,12 persen pada rentang tahun 2020 hingga 2024. Namun, persoalan ketimpangan antarwilayah ini menjadi semakin rumit ketika diletakkan dalam konteks waktu yang penuh perubahan.

Selain disparitas spasial, tantangan analisis meningkat akibat adanya dinamika temporal yang sangat fluktuatif sepanjang periode 2020 hingga 2024. Periode ini diawali dengan peristiwa pandemi COVID-19 yang menekan indikator makroekonomi dan kesejahteraan secara serentak terlihat dari perubahan pertumbuhan ekonomi yang sempat mencapai

angka 1,88 persen pada tahun 2020 (Badan Pusat Statistik, 2025b) namun diikuti oleh pola pemulihan yang lajunya tidak seragam di setiap daerah pada tahun-tahun berikutnya. Perubahan drastis dari masa pandemi COVID-19 menuju masa pemulihan ini diduga kuat telah mengubah struktur hubungan antar-indikator secara fundamental; sebagai contoh, pola korelasi antara pertumbuhan ekonomi (PDRB) dengan tingkat pengangguran (TPT) saat krisis sangat mungkin berbeda dibandingkan saat kondisi normal kembali pulih pada tahun 2023 hingga 2024. Oleh karena itu, pendekatan analisis multivariat klasik yang mengasumsikan struktur hubungan variabel bersifat statis (tetap sepanjang waktu) menjadi tidak lagi relevan untuk menganalisis fenomena pada periode yang penuh fluktuasi ini.

Untuk mengatasi keterbatasan asumsi stabilitas tersebut, diperlukan pendekatan analisis data tiga-arah (*three-way data analysis*) yang mampu menangani struktur data kompleks yang terdiri dari objek (kabupaten/kota), variabel (indikator sosio-ekonomi), dan situasi (waktu). Penelitian ini mengusulkan penggunaan metode STATIS (*Structuration des Tableaux à Trois Indices de la Statistique*), sebuah metode eksploratif yang diperkenalkan oleh Lavit et al. (1994); Oliveira et al. (2024). Berbeda dengan Analisis Komponen Utama (PCA) konvensional yang hanya bekerja pada data dua dimensi, STATIS dirancang khusus untuk mengekstraksi informasi dari sekumpulan tabel data yang berubah seiring waktu. Metode ini memiliki keunggulan dalam membentuk sebuah struktur kompromi (*compromise structure*) yang merepresentasikan pola hubungan umum antar-indikator selama periode pengamatan, sekaligus memungkinkan identifikasi seberapa jauh struktur ekonomi setiap tahunnya menyimpang dari pola umum tersebut.

Meskipun metode STATIS mampu menghasilkan struktur kompromi secara matematis, kompleksitas hasil analisis dari matriks berdimensi tinggi sering kali sulit dipahami jika hanya disajikan dalam bentuk tabel numerik. Oleh karena itu, penelitian ini mengintegrasikan pendekatan STATIS dengan teknik visualisasi *Dynamic Biplot*. Pendekatan ini memungkinkan proyeksi posisi objek (kabupaten/kota) dan variabel (indikator ekonomi) ke dalam ruang berdimensi rendah, sekaligus menggambarkan pergerakan atau lintasan (*trajectory*) perubahan posisi tersebut dari tahun ke tahun. Dengan memanfaatkan konsep *trajectory*, pergeseran karakteristik suatu wilayah misalnya, sebuah kabupaten yang pada tahun 2020 memiliki tingkat pengangguran tinggi namun kemudian bergeser mendekati karakteristik wilayah dengan IPM tinggi pada tahun 2024 dapat dilacak secara visual. Visualisasi lintasan ini menjadi instrumen krusial untuk membedakan antara fluktuasi jangka pendek akibat pandemi dan perubahan struktural jangka panjang.

Penerapan metode eksploratif multivariat seperti ini mengisi celah penting dalam literatur analisis regional di Indonesia yang selama ini didominasi oleh pendekatan inferensial klasik. Studi-studi terdahulu umumnya berfokus pada pemodelan regresi data panel atau

model spasial ekonometrik untuk mengestimasi besaran pengaruh variabel independen terhadap variabel dependen. Sebagai contoh, penelitian yang dilakukan oleh Nuswantari (2021) menggunakan pendekatan *Dynamic Spatial Durbin Model* (SDM) untuk memodelkan kemiskinan, sedangkan Ahmad (2024) menerapkan pendekatan spasial yang serupa untuk menganalisis fenomena penyebaran penyakit kusta di Pulau Jawa. Fokus utama dari penelitian-penelitian tersebut adalah pengukuran besaran pengaruh peubah-peubah penjelas (*explanatory variables*) terhadap peubah respon yang terbukti nyata secara statistik. Meskipun pendekatan tersebut berhasil mengidentifikasi faktor-faktor determinan, metode inferensial ini memiliki keterbatasan dalam memvisualisasikan struktur hubungan antarvariabel secara simultan (*inter-variable structure*) dan bagaimana struktur tersebut berevolusi dari waktu ke waktu (*spatio-temporal*). Hingga saat ini, belum terdapat penelitian yang secara spesifik menggunakan pendekatan eksploratif untuk memetakan dinamika struktur multivariat indikator ekonomi secara komprehensif tanpa membedakannya menjadi variabel bebas dan terikat.

Kompleksitas informasi yang dihasilkan dari analisis spasio-temporal ini menuntut media penyajian yang lebih adaptif dibandingkan laporan statis konvensional. Untuk itu, penelitian ini tidak hanya berhenti pada tataran analisis teoritis, tetapi juga mengembangkan sebuah aplikasi visualisasi interaktif berbasis web menggunakan bahasa pemrograman Python dengan kerangka kerja (*framework*) Dash dan Plotly. Pengembangan *dashboard* ini bertujuan untuk memfasilitasi Eksplorasi Data (*Exploratory Data Analysis*) secara mandiri oleh pengguna. Fitur-fitur interaktif yang disematkan seperti seleksi tahun, filter wilayah, hingga rotasi *baseline* memungkinkan para pengambil kebijakan untuk mengamati pola interaksi multivariat secara lebih mendalam. Melalui antarmuka ini, pola-pola tersembunyi (*latent patterns*) yang mungkin terlewatkan dalam tabel statistik standar dapat terdeteksi dengan lebih intuitif.

Secara keseluruhan, penelitian ini diarahkan untuk menjawab kebutuhan akan metode pemantauan pembangunan daerah yang lebih menyeluruh dan dinamis. Dengan memadukan kemampuan analitis metode STATIS dalam memahami struktur kompromi (*compromise structure*) lintas tahun dan kemampuan naratif visual dari *Dynamic Biplot*. Penelitian ini diharapkan dapat memberikan kontribusi ganda: secara akademis memperkaya khazanah penerapan statistik multivariat pada data ekonomi regional, dan secara praktis menyediakan prototipe alat bantu visual yang relevan bagi pemerintah daerah dalam mengevaluasi dampak kebijakan pasca-pandemi. Identifikasi struktur hubungan yang stabil maupun yang berubah selama lima tahun terakhir akan menjadi landasan penting dalam merumuskan strategi pembangunan yang lebih tangguh di masa depan.

Pemilihan lokasi penelitian yang mencakup seluruh kabupaten/kota di Provinsi Banten,

DKI Jakarta, dan Jawa Barat didasarkan pada karakteristik interkonektivitas ekonomi yang kuat di antara ketiga wilayah ini. Sebagai kesatuan wilayah pembangunan utama di Pulau Jawa, ketiga provinsi ini memiliki keterkaitan rantai pasok, mobilitas tenaga kerja, dan arus investasi yang sangat intensif. Permasalahan ekonomi yang terjadi di pusat pertumbuhan utama (DKI Jakarta) diproyeksikan akan merambat (*spillover*) ke wilayah penyangga di Banten dan Jawa Barat dengan skala yang berbeda-beda. Oleh karena itu, analisis yang hanya membatasi lingkup pada wilayah metropolitan Jabodetabek berpotensi mengabaikan dampak sistemik yang dirasakan oleh wilayah kabupaten non-metropolitan yang secara administratif berada dalam satu kesatuan provinsi namun memiliki karakteristik ekonomi yang jauh berbeda.

Untuk memahami kompleksitas pembangunan tersebut, penelitian ini menggunakan dua belas indikator strategis yang merepresentasikan dimensi pembangunan secara menyeluruh. Pemilihan variabel ini tidak dilakukan tanpa alasan, melainkan dipertimbangkan untuk mencakup aspek makroekonomi (PDRB ADHK), kesejahteraan material (PPM, GK, PKKP), kualitas modal manusia (IPM, RLS, AHH Laki-laki dan Perempuan), kesetaraan (IPG, Gini Ratio), serta partisipasi pasar kerja (TPT, TPAK). Kombinasi variabel ini memungkinkan analisis untuk tidak hanya pada indikator pertumbuhan konvensional, namun juga aspek inklusivitas pembangunan. Sebagai contoh, analisis simultan antara Gini Ratio dan PDRB memungkinkan deteksi dini terhadap fenomena pertumbuhan yang tidak merata (*exclusive growth*), sementara interaksi antara TPAK dan IPG dapat mengungkap hambatan struktural dalam partisipasi angkatan kerja berbasis gender.

Ketiadaan studi yang menganalisis dinamika interaksi kedua belas indikator ini secara spasio-temporal pada periode kritis 2020 hingga 2024 menciptakan sebuah ”kotak hitam” (*black box*) dalam pemahaman mengenai resiliensi ekonomi regional. Tanpa analisis struktur kompromi dan visualisasi lintasan yang jelas, para pemangku kebijakan kehilangan panduan empiris mengenai bagaimana sebenarnya pola pemulihan berlangsung di tingkat lokal apakah kembali ke struktur lama atau membentuk ekuilibrium baru. Berdasarkan urgensi untuk mengungkap fenomena tersebut secara statistik dan visual, penelitian ini disusun untuk menjawab pertanyaan-pertanyaan mendasar mengenai evolusi struktur ekonomi dan pembangunan di ketiga provinsi tersebut.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan yang akan dikaji dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana karakteristik struktur kompromi (*compromise structure*) yang merepre-

sentasikan pola hubungan multivariat dua belas indikator pembangunan di seluruh kabupaten/kota Provinsi Banten, DKI Jakarta, dan Jawa Barat menggunakan metode STATIS untuk memahami pola umum lintas tahun?

2. Bagaimana menguji struktur hubungan antar-indikator tersebut secara statistik selama periode 2020 hingga 2024 menggunakan uji permutasi matriks inter-struktur untuk membuktikan keberadaan dinamika temporal?

3. Bagaimana pola lintasan (*trajectory*) perubahan karakteristik ekonomi kabupaten/kota dari masa krisis pandemi (2020) hingga masa pemulihan (2024) berdasarkan visualisasi *Dynamic Biplot*?

4. Bagaimana pola pengelompokan spasial tiap tahunnya serta dinamika transisi atau pergerakan (*migration*) kabupaten/kota antar klaster dari tahun ke tahun?

5. Bagaimana merancang aplikasi berbasis web menggunakan *framework* Dash dan Plotly sebagai alat bantu eksplorasi data yang memungkinkan pengguna melakukan pemantauan indikator pembangunan secara interaktif?

1.3 Tujuan Penelitian

Sejalan dengan rumusan masalah di atas, tujuan dari penelitian ini adalah:

1. Menganalisis karakteristik struktur kompromi (*compromise structure*) yang merepresentasikan pola hubungan multivariat dua belas indikator pembangunan di seluruh kabupaten/kota Provinsi Banten, DKI Jakarta, dan Jawa Barat menggunakan metode STATIS untuk memahami pola umum lintas tahun.

2. Menganalisis struktur hubungan antar-indikator tersebut secara statistik selama periode 2020 hingga 2024 menggunakan uji permutasi matriks inter-struktur untuk membuktikan keberadaan dinamika temporal.

3. Menganalisis pola lintasan (*trajectory*) perubahan karakteristik ekonomi kabupaten/kota dari masa krisis pandemi (2020) hingga masa pemulihan (2024) berdasarkan hasil visualisasi *Dynamic Biplot*.

4. Mengidentifikasi pola pengelompokan spasial tiap tahunnya serta dinamika transisi atau pergerakan (*migration*) kabupaten/kota antar klaster dari tahun ke tahun.

5. Merancang aplikasi berbasis web menggunakan *framework* Dash dan Plotly sebagai alat bantu eksplorasi data yang memungkinkan pengguna melakukan pemantauan indikator pembangunan secara interaktif.

1.4 Manfaat Penelitian

Penelitian ini bermanfaat untuk:

1. Secara akademis memperkaya khazanah penerapan statistik multivariat terutama metode STATIS dan *Dynamic Biplot* pada data ekonomi regional di Indonesia.

2. Secara praktis menyediakan prototipe alatbantu visual berbasis web yang relevan bagi pemerintah daerah dalam mengevaluasi perkembangan indikator pembangunan dan dampak kebijakan pasca-pandemi.

1.5 Ruang Lingkup Penelitian

Agar pembahasan penelitian ini lebih terarah dan fokus, penulis menetapkan batasan-batasan masalah sebagai berikut:

1. **Variabel Penelitian:** Analisis menggunakan 12 indikator terpilih yang bersumber dari Badan Pusat Statistik (BPS), meliputi: Indeks Pembangunan Manusia (IPM), Indeks Pembangunan Gender (IPG), Persentase Penduduk Miskin (PPM), PDRB ADHK, Rata-rata Lama Sekolah (RLS), Angka Harapan Hidup Laki-laki (AHH_L) dan Perempuan (AHH_P), Garis Kemiskinan (GK), Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP), Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), dan Gini Ratio (GR).

2. **Aspek Spasial:** Istilah ”spasial” dalam penelitian ini merujuk pada unit analisis berbasis wilayah (kabupaten/kota), bukan pada penggunaan matriks pembobot spasial (*spatial weight matrix*) seperti pada Ekonometrika Spasial.

3. **Fungsionalitas Aplikasi:** Aplikasi berbasis web yang dikembangkan berfungsi sebagai alat bantu eksplorasi visual (*Visual Exploratory Tool*) bagi pengguna, bukan sebagai Sistem Pendukung Keputusan (*Decision Support System*) yang menghasilkan rekomendasi kebijakan berbasis data secara otomatis.

BAB 2
LANDASAN TEORI

Bab ini berisi uraian mengenai teori-teori dasar yang menjadi fondasi metodologi penelitian. Pembahasan dimulai dari konsep indikator kesejahteraan rakyat sebagai latar belakang substansi variabel penelitian, kemudian dilanjutkan dengan struktur data tiga arah dan konsep spasio-temporal, statistika deskriptif, standardisasi data, pemilihan variabel (Uji KMO dan Bartlett), fondasi aljabar linier beserta dekomposisi matriks (nilai eigen, dekomposisi spektral, dan Singular Value Decomposition), korelasi Pearson, *Principal Component Analysis* (PCA) beserta Biplot, algoritma metode STATIS beserta uji permutasi, Dynamic Biplot dan visualisasi trajektori, metode pengelompokan (clustering), uji autokorelasi spasial Global Moran's I, dan terakhir adalah media visualisasi interaktif Plotly dan Dash.

2.1 Indikator Kesejahteraan Rakyat

Tujuan utama pembangunan suatu wilayah adalah mewujudkan kesejahteraan rakyatnya. Untuk mengukur keberhasilan pembangunan, dibutuhkan indikator-indikator yang mampu mencerminkan taraf kesejahteraan secara menyeluruh. Indikator kesejahteraan rakyat cukup luas dan kompleks sehingga hanya dapat dinilai melalui indikator-indikator terukur dari berbagai bidang pembangunan, di antaranya bidang kesehatan, pendidikan, ketenagakerjaan, taraf dan pola konsumsi, serta kemiskinan (Badan Pusat Statistik, 2025a). Pemilihan indikator yang tepat dan terukur sangat menentukan kualitas analisis multivariat yang akan dilakukan.

2.1.1 Indeks Pembangunan Manusia (IPM)

Indeks Pembangunan Manusia (IPM) merupakan indeks komposit yang mengukur capaian pembangunan manusia berbasis tiga dimensi dasar: (1) umur panjang dan hidup sehat, tercermin dari angka harapan hidup saat lahir; (2) pengetahuan, tercermin dari rata-rata lama sekolah dan harapan lama sekolah; serta (3) standar hidup layak, tercermin dari pengeluaran per kapita yang disesuaikan. IPM dihitung sebagai rata-rata geometrik dari ketiga indeks dimensi tersebut dengan skala nilai 0 hingga 100. Semakin tinggi nilai IPM, semakin baik capaian pembangunan manusia di suatu wilayah (Badan Pusat Statistik, 2025a).

2.1.2 Produk Domestik Regional Bruto (PDRB ADHK)

Produk Domestik Regional Bruto Atas Dasar Harga Konstan (PDRB ADHK) mencerminkan nilai tambah bruto barang dan jasa yang dihasilkan oleh seluruh unit ekonomi di suatu wilayah dalam kurun waktu tertentu, dihitung menggunakan harga pada tahun dasar tertentu (2010) sehingga pengaruh inflasi dieliminasi. PDRB ADHK digunakan sebagai ukuran pertumbuhan ekonomi riil suatu wilayah. Satuan yang digunakan umumnya adalah juta atau miliar rupiah. Wilayah dengan PDRB ADHK yang tinggi menunjukkan kapasitas produksi ekonomi yang kuat (Badan Pusat Statistik, 2025a).

2.1.3 Persentase Penduduk Miskin (PPM)

Persentase penduduk miskin adalah persentase penduduk yang memiliki rata-rata pengeluaran per kapita per bulan di bawah Garis Kemiskinan. Garis Kemiskinan (GK) mencerminkan nilai rupiah pengeluaran minimum yang diperlukan seseorang untuk memenuhi kebutuhan pokok hidupnya selama sebulan, baik kebutuhan makanan maupun non-makanan. Daerah yang lebih sejahtera pada umumnya memiliki persentase penduduk miskin yang relatif kecil (Badan Pusat Statistik, 2025a; Widyaningsih, 2024).

2.1.4 Garis Kemiskinan (GK)

Garis Kemiskinan (GK) adalah nilai rupiah pengeluaran minimum yang diperlukan oleh seseorang untuk dapat memenuhi kebutuhan pokok makanan setara 2.100 kilo kalori per orang per hari dan kebutuhan pokok non-makanan yang mencakup perumahan, sandang, pendidikan, dan kesehatan. GK digunakan sebagai batas untuk menentukan status kemiskinan seseorang dan bervariasi antarwilayah bergantung pada pola konsumsi dan harga komoditas setempat (Badan Pusat Statistik, 2025a).

2.1.5 Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP)

Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP) adalah estimasi proporsi populasi yang mengonsumsi energi (kalori) di bawah standar kecukupan minimum untuk menjalani kehidupan yang sehat dan aktif. Indikator ini mencerminkan dimensi ketahanan pangan suatu wilayah dan merupakan salah satu dari target Tujuan Pembangunan Berkelanjutan (SDGs) yang dipantau secara reguler oleh Badan Pusat Statistik (Badan Pusat Statistik, 2025a).

2.1.6 Tingkat Pengangguran Terbuka (TPT)

Tingkat Pengangguran Terbuka (TPT) adalah persentase jumlah pengangguran terhadap jumlah angkatan kerja. Pengangguran didefinisikan sebagai penduduk usia kerja yang sedang mencari pekerjaan, mempersiapkan usaha, atau tidak mencari pekerjaan karena merasa tidak mungkin mendapatkannya, termasuk mereka yang baru mendapat pekerjaan tetapi belum mulai bekerja. Angkatan kerja adalah penduduk usia 15 tahun ke atas yang bekerja atau sedang mencari pekerjaan. TPT yang tinggi mengindikasikan pemanfaatan tenaga kerja yang belum optimal (Badan Pusat Statistik, 2025a; Widyaningsih, 2024).

2.1.7 Tingkat Partisipasi Angkatan Kerja (TPAK)

Tingkat Partisipasi Angkatan Kerja (TPAK) adalah persentase penduduk usia kerja (15 tahun ke atas) yang termasuk dalam angkatan kerja, baik yang sudah bekerja maupun yang sedang mencari pekerjaan. TPAK mencerminkan proporsi penduduk usia produktif yang aktif secara ekonomi. Nilai TPAK yang tinggi menandakan tingginya partisipasi masyarakat dalam kegiatan ekonomi (Badan Pusat Statistik, 2025a).

2.1.8 Rata-Rata Lama Sekolah (RLS)

Rata-rata lama sekolah adalah rata-rata jumlah tahun yang telah ditempuh oleh penduduk usia 25 tahun ke atas dalam menjalani pendidikan formal. Indikator ini dihitung untuk penduduk usia 25 tahun ke atas dengan asumsi bahwa pada usia tersebut proses pendidikan pada umumnya telah selesai. Semakin tinggi nilai RLS, semakin tinggi tingkat pendidikan rata-rata penduduk suatu wilayah yang pada gilirannya mendukung peningkatan produktivitas dan kesejahteraan (Badan Pusat Statistik, 2025a; Widyaningsih, 2024).

2.1.9 Angka Harapan Hidup Laki-laki

Angka Harapan Hidup (AHH) laki-laki adalah perkiraan rata-rata jumlah tahun hidup yang akan dijalani oleh seorang bayi laki-laki yang baru lahir pada suatu tahun tertentu, dengan asumsi bahwa pola mortalitas pada saat kelahiran tetap berlaku sepanjang hidupnya. Indikator ini mencerminkan derajat kesehatan penduduk laki-laki serta kualitas layanan kesehatan yang tersedia bagi mereka (Badan Pusat Statistik, 2025a; Widyaningsih, 2024).

2.1.10 Angka Harapan Hidup Perempuan

Angka Harapan Hidup (AHH) perempuan adalah perkiraan rata-rata jumlah tahun hidup yang akan dijalani oleh seorang bayi perempuan yang baru lahir pada suatu tahun tertentu. Umumnya, nilai AHH perempuan lebih tinggi dibandingkan laki-laki karena perbedaan biologis dan pola perilaku kesehatan. AHH perempuan merupakan komponen penting dalam perhitungan Indeks Pembangunan Manusia (IPM) dan Indeks Pembangunan Gender (IPG) (Badan Pusat Statistik, 2025a; Widyaningsih, 2024).

2.1.11 Indeks Pembangunan Gender (IPG)

Indeks Pembangunan Gender (IPG) adalah rasio capaian IPM perempuan terhadap IPM laki-laki. IPG mengukur kesenjangan gender dalam dimensi kesehatan, pendidikan, dan standar hidup. Nilai IPG sebesar 100 menunjukkan kesetaraan sempurna antara laki-laki dan perempuan, sedangkan nilai yang lebih rendah menunjukkan adanya kesenjangan yang merugikan perempuan (Badan Pusat Statistik, 2025a).

2.1.12 Gini Ratio (GR)

Gini Ratio adalah ukuran tingkat ketimpangan distribusi pengeluaran atau pendapatan penduduk. Nilai Gini Ratio berkisar antara 0 dan 1: nilai 0 berarti pemerataan sempurna (setiap orang memiliki pengeluaran yang sama), sedangkan nilai 1 berarti ketimpangan sempurna (satu orang menguasai seluruh pengeluaran). Gini Ratio yang tinggi menandakan tingginya kesenjangan ekonomi antar kelompok penduduk dalam suatu wilayah (Badan Pusat Statistik, 2025a).

2.1.13 Jumlah Penduduk (JP)

Jumlah Penduduk (JP) merupakan banyaknya jiwa yang mendiami suatu wilayah administratif pada suatu titik waktu tertentu, sebagaimana dicatat melalui Sensus Penduduk maupun estimasi antarsensus yang diselenggarakan oleh Badan Pusat Statistik (Badan Pusat Statistik, 2025a). Dalam penelitian ini, JP **tidak digunakan sebagai variabel analisis** dalam metode STATIS, melainkan berperan sebagai **basis pembentukan bobot demografis** (m_i). Bobot ini mengintegrasikan ukuran populasi setiap wilayah ke dalam analisis multivariat sehingga wilayah dengan penduduk lebih besar memberikan kontribusi yang proporsional terhadap struktur rata-rata (kontribusi ini dinamakan kompromi), dan wilayah berpenduduk kecil tidak mengubah hasil analisis multivariat secara berlebihan (Lavit et al., 1994).

2.2 Tinjauan Penelitian Terdahulu

Penelitian mengenai analisis statistik terhadap data regional di Pulau Jawa telah banyak dilakukan dengan menggunakan berbagai pendekatan. Bagian ini merangkum beberapa penelitian relevan yang menjadi rujukan dalam pengembangan metodologi penelitian ini, sebagaimana disajikan pada Tabel 2.1.

Tabel 2.1: Ringkasan Penelitian Terdahulu

Peneliti (Tahun)	**Wilayah**	**Metode**	**Hasil Utama**
Nuswantari (2021)	Pulau Jawa (2012-2018)	*Dynamic Spatial Panel* (Model Durbin Spasial)	Model terbaik menggunakan pembobot dua tetangga terdekat. Angka melek huruf dan fasilitas kesehatan berpengaruh signifikan terhadap kemiskinan.
Ahmad (2024)	Pulau Jawa (2017-2021)	*Dynamic Spatial Durbin Model* (DSDM)	Menemukan adanya pengaruh lag temporal dan spasiotemporal yang signifikan terhadap prevalensi kusta.
Widyaningsih (2024)	Pulau Jawa (2022)	*Biclustering Plaid Model* vs *Cluster-Biplot*	*Plaid model* menghasilkan kelompok wilayah yang lebih homogen dibandingkan metode biplot konvensional dalam mengelompokkan indikator kesejahteraan.

Nuswantari (2021) menunjukkan bahwa pemodelan di Pulau Jawa harus mempertimbangkan efek dinamis (waktu) dan dependensi spasial secara simultan. Hal ini diperkuat oleh Ahmad (2024) yang menggunakan DSDM untuk menangkap interaksi antar-wilayah lintas waktu. Di sisi lain, Widyaningsih (2024) memberikan perspektif mengenai pentingnya metode pengelompokan yang mampu menangani objek dan variabel secara bersamaan untuk melihat karakteristik regional yang unik. Penelitian ini menggabungkan aspek temporal dari data tiga-arah menggunakan metode STATIS dan aspek keterkaitan spasial untuk memberikan analisis yang lebih komprehensif.

2.3 Analisis Data Tiga-Arah (*Three-Way Data*)

Dalam statistika multivariat klasik, umumnya data direpresentasikan dalam struktur dua-arah (*two-way structure*), yaitu sebuah matriks $\mathbf{X}$ berukuran $n \times p$, dengan n merepresentasikan jumlah objek dan p merepresentasikan jumlah variabel. Struktur ini memadai untuk menganalisis kondisi statis pada satu titik waktu tertentu. Namun, dalam studi yang melibatkan pemantauan berkala, struktur data menjadi lebih kompleks dengan hadirnya dimensi ketiga, yaitu waktu atau situasi (Kroonenberg, 2008).

Struktur data seperti ini dikenal sebagai data tiga-arah (*three-way data*) atau data panel multivariat. Secara formal, data tiga-arah dapat didefinisikan sebagai berikut:

Definisi 2.1 (Data Tiga-Arah)**.** Misalkan terdapat n objek penelitian, p variabel, dan K situasi (waktu). Data tiga-arah adalah sekumpulan K buah matriks data $\{\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_K\}$, dengan setiap matriks $\mathbf{X}_k$ (untuk $k = 1, \ldots, K$) berukuran $n \times p$.

Elemen skalar dari data ini dinotasikan sebagai x_{ijk}, yang merepresentasikan nilai dari variabel ke-j pada objek ke-i pada situasi ke-k. Keseluruhan himpunan matriks ini sering diilustrasikan sebagai sebuah balok data (*data cube*) dengan dimensi $n \times p \times K$.

Relevansi pendekatan tiga-arah ini semakin menguat dalam analisis data regional, di mana interaksi kompleks antara wilayah, waktu, dan indikator sosial-ekonomi sangat penting untuk dipahami (Biegert et al., 2023). Metode STATIS, yang akan dibahas selanjutnya, dirancang secara spesifik untuk mendapatkan informasi dari struktur tiga-arah $\{\mathbf{X}_k\}$ ini tanpa harus merata-ratakan data terlebih dahulu ke dalam satu matriks tunggal yang menghilangkan karakteristik temporal (Lavit et al., 1994).

2.4 Konsep Spasio-Temporal dalam Analisis Multivariat

Analisis spasio-temporal bertujuan untuk mendeskripsikan atau memodelkan variabilitas fenomena yang terjadi dalam domain ruang dan waktu secara simultan. Tantangan utama dalam analisis ini adalah adanya dua ketergantungan sekaligus: ketergantungan antar-lokasi (spasial) dan ketergantungan antar-waktu (temporal).

Pendekatan konvensional dalam ekonometrika biasanya melakukan pendekatan terhadap masalah ini dengan menggunakan regresi data panel atau model dinamis spasial (*Spatial Dynamic Panel Data*) untuk mengetahui pengaruh antar-lokasi, dengan struktur hubungan antar-lokasi didefinisikan menggunakan matriks pembobot spasial (*spatial weight matrix*, $\mathbf{W}_{spasial}$) berbasis ketetanggaan geografis yang memiliki asumsi bahwa interaksi antar-wilayah hanya terjadi melalui batas geografis fisik yang bersifat konstan sepanjang waktu (Baltagi, 2021). Dalam pendekatan multivariat eksploratif seperti STATIS, definisi "spasial" dipandang dari perspektif yang berbeda.

Konsep Spasial dalam STATIS Dalam kerangka STATIS, aspek spasial direpresentasikan melalui konfigurasi kemiripan antar-objek dalam ruang multivariat, bukan melalui matriks kontiguitas geografis. Struktur "spasial" pada situasi ke-k didefinisikan oleh matriks produk skalar $\mathbf{W}_k = \mathbf{X}_k\mathbf{X}_k^T$ (berukuran $n \times n$) yang merangkum "peta" kemiripan antar-objek berdasarkan profil variabelnya.

Evolusi spasio-temporal dalam pendekatan ini difokuskan pada pengamatan perubahan konfigurasi matriks $\mathbf{W}_k$ dari waktu ke waktu, untuk menjawab pertanyaan apakah pola kemiripan antar-objek berubah selama periode pengamatan (Lavit et al., 1994).

2.5 Standardisasi Data

Perbedaan nilai yang besar antar-variabel akibat perbedaan satuan pengukuran (misalnya rupiah, persen, dan tahun) dapat menyebabkan bias dalam analisis multivariat sehingga perlu menyamakan skala variabilitasnya. Karena 41 wilayah yang diamati merupakan populasi utuh dengan ukuran penduduk yang sangat bervariasi, standardisasi dalam kerangka STATIS dilakukan menggunakan rata-rata dan simpangan baku *terbobot* (μ dan σ) agar pusat data konsisten dengan $\mathbf{D}$ yang dijelaskan pada 2.3 (Lavit et al., 1994). Untuk itu, terlebih dahulu didefinisikan bobot demografis dan matriks bobot berikut.

Definisi 2.2 (Bobot Demografis Wilayah ke-i (m_i))**.** Misalkan $\overline{\mathrm{JP}}_i = \frac{1}{K}\sum_{k=1}^{K} \mathrm{JP}_{ik}$ adalah rata-rata jumlah penduduk wilayah ke-i selama K tahun pengamatan. Bobot demografis m_i didefinisikan sebagai proporsi penduduk wilayah ke-i terhadap total penduduk seluruh wilayah:

$$m_i = \frac{\overline{\mathrm{JP}}_i}{\sum_{i'=1}^{n} \overline{\mathrm{JP}}_{i'}}, \quad i = 1, 2, \ldots, n \tag{2.1}$$

dengan syarat $\sum_{i=1}^{n} m_i = 1$ dan $m_i > 0$. Penggunaan rata-rata lintas tahun memastikan bahwa ruang metrik bersifat konstan di semua situasi, sehingga jarak antar-konfigurasi dapat dibandingkan secara valid (Lavit et al., 1994).

Definisi 2.3 (Matriks Bobot $\mathbf{D}$)**.** Matriks bobot $\mathbf{D}$ adalah matriks diagonal berukuran $n \times n$ dengan elemen diagonal ke-i adalah bobot demografis m_i:

$$\mathbf{D} = \mathrm{diag}(m_1, m_2, \ldots, m_n) \tag{2.2}$$

Matriks $\mathbf{D}$ mendefinisikan suatu *inner product* terbobot pada ruang objek: $\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{D}} = \mathbf{x}^T\mathbf{D}\mathbf{y}$. Seluruh perhitungan jarak dan produk skalar dalam STATIS digunakan dalam ruang ini. Akar dan invers akarnya masing-masing dinotasikan sebagai $\mathbf{D}^{1/2} = \mathrm{diag}(\sqrt{m_1}, \ldots, \sqrt{m_n})$ dan $\mathbf{D}^{-1/2} = \mathrm{diag}(1/\sqrt{m_1}, \ldots, 1/\sqrt{m_n})$ (Lavit et al., 1994).

Definisi 2.4 (Standardisasi Z-Score Terbobot)**.** Misalkan x_{ijk} adalah nilai variabel ke-j pada wilayah ke-i tahun ke-k. Rata-rata populasi terbobot dan simpangan baku populasi

terbobot didefinisikan sebagai:

$$\mu_{jk} = \sum_{i=1}^{n} m_i \, x_{ijk} \tag{2.3}$$

$$\sigma_{jk} = \sqrt{\sum_{i=1}^{n} m_i \, (x_{ijk} - \mu_{jk})^2} \tag{2.4}$$

Nilai terstandardisasi terbobot (*weighted standardized value*) dihitung sebagai:

$$z_{ijk} = \frac{x_{ijk} - \mu_{jk}}{\sigma_{jk}}, \quad i = 1, \ldots, n; \; j = 1, \ldots, p; \; k = 1, \ldots, K \tag{2.5}$$

Persamaan 2.5 memastikan bahwa $\sum_{i=1}^{n} m_i \, z_{ijk} = 0$ (pusat terbobot nol) dan $\sum_{i=1}^{n} m_i \, z_{ijk}^2 = 1$ (varians terbobot satu) (Lavit et al., 1994).

Hasil standardisasi menghasilkan matriks data standar terbobot $\mathbf{Z}_k$ (berukuran $n \times p$) untuk setiap situasi ke-k. Prosedur ini memastikan bahwa tidak ada variabel yang mendominasi analisis hanya karena skala pengukurannya lebih besar, sekaligus mempertahankan konsistensi ruang bobot $\mathbf{D}$ di seluruh situasi waktu.

2.6 Statistika Deskriptif

Sebelum menerapkan metode analisis multivariat, tahap awal yang penting adalah melakukan eksplorasi data melalui Statistika Deskriptif. Statistika deskriptif bertujuan meringkas dan mendeskripsikan karakteristik distribusi data secara numerik, sehingga peneliti dapat memahami pola umum, keragaman, dan anomali pada data sebelum tahap analisis data yang lebih mendalam (Johnson & Wichern, 2007).

2.6.1 Ukuran Pemusatan

Ukuran pemusatan mendeskripsikan nilai "tengah" dari data.

Definisi 2.5 (Rata-Rata (Mean))**.** Rata-rata dari n pengamatan $x_1, x_2, \ldots, x_n$ suatu variabel adalah:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i \tag{2.6}$$

Rata-rata bersifat sensitif terhadap pencilan (*outlier*).

Definisi 2.6 (Median)**.** Median (Q_2) adalah nilai tengah dari suatu variabel setelah diu-

rutkan dari yang terkecil hingga yang terbesar:

$$Q_2 = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & \text{, jika } n \text{ ganjil} \\ \dfrac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2} & \text{, jika } n \text{ genap} \end{cases} \tag{2.7}$$

Nilai median lebih robust terhadap pencilan dibandingkan nilai rata-rata.

2.6.2 Ukuran Penyebaran

Ukuran penyebaran mendeskripsikan seberapa jauh data bervariasi di sekitar pusat distribusinya.

Definisi 2.7 (Simpangan Baku (Standar Deviasi))**.** Simpangan baku sampel dari n pengamatan adalah:

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} \tag{2.8}$$

Simpangan baku merepresentasikan akar kuadrat dari ragam (*variance*) sampel s^2.

Definisi 2.8 (Nilai Minimum, Maksimum, dan Rentang Antarkuartil (IQR))**.** Nilai minimum dan maksimum adalah:

$$x_{\min} = \min(x_1, \ldots, x_n), \qquad x_{\max} = \max(x_1, \ldots, x_n) \tag{2.9}$$

Kuartil pertama (Q_1) dan ketiga (Q_3) membagi distribusi data menjadi empat bagian, masing-masing 25%. Rentang Antarkuartil (*Interquartile Range*, IQR) adalah:

$$IQR = Q_3 - Q_1 \tag{2.10}$$

IQR merupakan ukuran penyebaran yang robust karena tidak dipengaruhi oleh pencilan.

Definisi 2.9 (Koefisien Variasi (CV))**.** Koefisien Variasi atau yang dalam bahasa Inggris disebut sebagai *Coefficient of Variation* (CV) digunakan untuk mengukur variabilitas relatif terhadap rata-rata, dengan rumus sebagai berikut:

$$CV = \frac{s}{\bar{x}} \times 100\% \tag{2.11}$$

CV berfungsi untuk membandingkan tingkat keragaman antar-variabel yang memiliki satuan atau skala yang berbeda-beda, dan ukuran ini juga lazim digunakan dalam analisis stabilitas (Departemen Pertanian (Deptan), 2003).

2.6.3 Ukuran Bentuk Distribusi

Ukuran bentuk memberikan informasi karakteristik bentuk simetris dan bentuk keruncingan dari distribusi data.

Definisi 2.10 (Kemiringan Distribusi (*Skewness*))**.** *Skewness* mengukur tingkat asimetris distribusi data:

$$g_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{s^3} \tag{2.12}$$

Interpretasi: $g_1 > 0$ berarti distribusi data condong ke kanan (*right-skewed*, ekor panjang di kanan); $g_1 < 0$ berarti condong ke kiri (*left-skewed*); $g_1 \approx 0$ berarti distribusi data hampir simetris. *Skewness* juga dapat diklasifikasikan dari rentang moderat hingga sangat menceng yang biasa dijadikan sebagai acuan baku (Bulmer, 1979).

Definisi 2.11 (Kurtosis (Keruncingan))**.** Kurtosis mengukur ketebalan ekor dan keruncingan relatif distribusi data dibandingkan distribusi normal:

$$g_2 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^4}{s^4} - 3 \tag{2.13}$$

Nilai negatif dari pengurangan 3 merupakan koreksi *excess kurtosis* (Weisstein, Eric W., 2024): $g_2 > 0$ berarti distribusi data lebih runcing (*leptokurtik*); $g_2 < 0$ berarti lebih datar (*platikurtik*) dibandingkan distribusi normal.

2.7 Pemilihan Variabel dalam Analisis Multivariat

Keberhasilan suatu analisis multivariat berbasis reduksi dimensi sangat bergantung pada kualitas himpunan variabel yang digunakan. Variabel yang tidak memiliki hubungan satu sama lain tidak akan menghasilkan komponen yang bermakna, sedangkan variabel yang terlalu berkorelasi sempurna dapat menyebabkan matriks kovariansi menjadi singular (Hair et al., 2019). Sebelum menerapkan metode analisis, perlu dilakukan serangkaian uji statistik untuk memverifikasi bahwa himpunan variabel *layak* untuk dianalisis secara multivariat yang artinya terdapat struktur kovariansi yang cukup untuk diekstraksi (*factorable*).

Dua kriteria utama yang lazim digunakan untuk mengetahui apakah data yang akan digunakan memenuhi syarat untuk dilakukan analisis multivariat adalah: (1) Uji Kaiser-Meyer-Olkin (KMO) yang menilai kecukupan (*sampling adequacy*) masing-masing variabel maupun keseluruhan himpunan variabel, dan (2) Uji Bartlett tentang Spherisitas yang menguji apakah matriks korelasi antar-variabel secara keseluruhan signifikan berbeda dari matriks identitas.

2.7.1 Uji Kaiser-Meyer-Olkin (KMO)

Statistik Kaiser-Meyer-Olkin (KMO) dikembangkan oleh Kaiser (1970, 1974) sebagai ukuran untuk menilai kecukupan sampel (*sampling adequacy*) dalam analisis faktor dan analisis komponen utama. Secara intuitif, KMO mengukur sejauh mana korelasi antar-pasang variabel dapat "dijelaskan" oleh variabel-variabel lainnya, suatu kondisi yang disebut korelasi parsial rendah. Apabila korelasi parsial antar-variabel rendah setelah dikontrol variabel lain, maka ada faktor laten yang mendasari struktur korelasinya, kondisi ini disyaratkan dalam analisis berbasis reduksi dimensi (Dziuban & Shirkey, 1974).

Definisi 2.12 (Statistik KMO)**.** Misalkan r_{jk} adalah koefisien korelasi Pearson antara variabel ke-j dan ke-k, dan q_{jk} adalah elemen dari invers matriks korelasi $\mathbf{R}^{-1}$. Korelasi parsial antara variabel ke-j dan ke-k dihitung sebagai:

$$r_{jk.\text{parsial}} = -\frac{q_{jk}}{\sqrt{q_{jj} \cdot q_{kk}}} \tag{2.14}$$

Statistik KMO keseluruhan (*overall KMO*) didefinisikan sebagai:

$$KMO = \frac{\sum_{j \neq k} r_{jk}^2}{\sum_{j \neq k} r_{jk}^2 + \sum_{j \neq k} r_{jk.\text{parsial}}^2} \tag{2.15}$$

Nilai KMO berkisar antara 0 dan 1. Semakin besar nilai KMO, semakin kecil jumlah kuadrat korelasi parsial (penyebut) relatif terhadap jumlah kuadrat korelasi bivariate (pembilang). Hal ini mengindikasikan bahwa variabel-variabel saling berbagi faktor laten yang kuat.

Selain statistik KMO keseluruhan, Kaiser (1974) mendefinisikan Measure of Sampling Adequacy (MSA_j) untuk setiap variabel ke-j:

$$MSA_j = \frac{\sum_{k \neq j} r_{jk}^2}{\sum_{k \neq j} r_{jk}^2 + \sum_{k \neq j} r_{jk.\text{parsial}}^2} \tag{2.16}$$

Interpretasi nilai KMO dan MSA_j menurut Kaiser (1974) dan Hair et al. (2019) disajikan pada Tabel 2.2 berikut:

Tabel 2.2: Kriteria Interpretasi Nilai KMO

Nilai KMO	Interpretasi
$0{,}90 \leq KMO \leq 1{,}00$	Marvelous (Luar Biasa)
$0{,}80 \leq KMO < 0{,}90$	Meritorious (Sangat Baik)
$0{,}70 \leq KMO < 0{,}80$	Middling (Cukup Baik)
$0{,}60 \leq KMO < 0{,}70$	Mediocre (Biasa)
$0{,}50 \leq KMO < 0{,}60$	Miserable (Buruk, namun dapat diterima)
$KMO < 0{,}50$	Unacceptable (Tidak diterima)

Apabila nilai MSA_j suatu variabel lebih kecil dari 0,50; variabel tersebut dipertimbangkan untuk dikeluarkan dari analisis dan himpunan variabel diuji ulang hingga semua variabel yang tersisa memenuhi syarat untuk dianalisis lebih lanjut (Hair et al., 2019; Widyaningsih, 2024).

2.7.2 Uji Bartlett tentang Spherisitas (*Bartlett's Test of Sphericity*)

Uji Bartlett tentang Spherisitas, dikembangkan oleh Bartlett (1954), bertujuan menguji hipotesis nol bahwa matriks korelasi populasi adalah matriks identitas ($\mathbf{R} = \mathbf{I}$). Jika $\mathbf{R} = \mathbf{I}$, tidak ada korelasi sama sekali antar-variabel sehingga tidak ada informasi bersama yang dapat diekstraksi melalui analisis multivariat (Johnson & Wichern, 2007).

Definisi 2.13 (Uji Bartlett tentang Spherisitas)**.** Diberikan matriks korelasi sampel $\mathbf{R}$ (berukuran $p \times p$, dengan p adalah banyaknya variabel) dari n observasi. Hipotesis uji Bartlett adalah:

- H_0: $\mathbf{\Sigma} = \sigma^2\mathbf{I}$ (matriks korelasi populasi adalah matriks identitas)
- H_1: $\mathbf{\Sigma} \neq \sigma^2\mathbf{I}$ (terdapat korelasi yang signifikan antar-variabel)

Statistik uji χ^2 dihitung dengan aproksimasi (Bartlett, 1954):

$$\chi^2 = -\left[n - 1 - \frac{2p+5}{6}\right] \ln|\mathbf{R}| \tag{2.17}$$

dengan $|\mathbf{R}|$ adalah determinan matriks korelasi. Statistik ini berdistribusi χ^2 dengan derajat bebas:

$$df = \frac{p(p-1)}{2} \tag{2.18}$$

Logika Determinan Matriks Korelasi Apabila semua variabel saling tidak berkorelasi, maka $\mathbf{R} = \mathbf{I}$ sehingga $|\mathbf{R}| = 1$ dan $\ln(1) = 0$, sehingga nilai statistik uji χ^2 bernilai nol, artinya korelasi antar variabel tidak signifikan. Sebaliknya, ketika variabel-variabel saling

berkorelasi erat, $|\mathbf{R}| \to 0$ sehingga $\ln |\mathbf{R}|$ bernilai negatif dan statistik uji menjadi besar, menghasilkan p-value yang kecil (Johnson & Wichern, 2007).

Jika p-value $< \alpha$, maka H_0 ditolak, yang berarti terdapat struktur korelasi yang signifikan. Kondisi ini merupakan prasyarat yang diperlukan agar analisis reduksi dimensi dapat mengekstraksi informasi yang bermakna.

Definisi 2.14 (Determinan Matriks)**.** Determinan dari matriks bujur sangkar $\mathbf{A}$ berukuran $p \times p$, dinotasikan sebagai $|\mathbf{A}|$ atau $\det(\mathbf{A})$, adalah sebuah nilai skalar yang merangkum properti-properti penting dari matriks tersebut, termasuk keterbalikannya (*invertibility*) dan sifat singular. Secara formal, determinan didefinisikan sebagai (Anton & Rorres, 2013):

$$|\mathbf{A}| = \sum_{\sigma \in S_p} \text{sgn}(\sigma) \prod_{i=1}^{p} a_{i,\sigma(i)} \tag{2.19}$$

dengan:

- S_p adalah himpunan seluruh permutasi dari indeks $\{1, 2, \ldots, p\}$.
- $\text{sgn}(\sigma)$ adalah tanda (paritas) dari permutasi σ (bernilai $+1$ untuk permutasi genap, dan -1 untuk permutasi ganjil).
- $a_{i,\sigma(i)}$ mewakili elemen matriks pada baris ke-i dan kolom ke-$\sigma(i)$.

Untuk matriks korelasi populasi $\mathbf{R}$, nilai determinan memberikan ukuran global atas keberadaan multikolinieritas antar variabel. Apabila variabel-variabel saling bebas linier (matriks korelasi membentuk matriks identitas), maka determinan bernilai maksimum, yaitu $|\mathbf{R}| = 1$. Sebaliknya, semakin tinggi korelasi linier antar variabel, nilai determinan akan semakin mengecil mendekati 0. Jika determinan bernilai mutlak 0, matriks saling berkorelasi sempurna sehingga tidak dapat diinvers (Johnson & Wichern, 2007).

2.8 Dasar Aljabar Linier dan Dekomposisi Matriks

Metode reduksi dimensi seperti *Principal Component Analysis* (PCA) dan STATIS sangat bergantung pada operasi aljabar linier, khususnya dekomposisi matriks simetris. Pemahaman mengenai nilai eigen, vektor eigen, dan sifat *trace* matriks menjadi prasyarat untuk memahami bagaimana metode-metode ini mengekstraksi informasi struktural dari data.

Definisi 2.15 (Nilai Eigen dan Vektor Eigen)**.** Diberikan sebuah matriks persegi $\mathbf{A}$ berukuran $p \times p$. Sebuah skalar λ disebut sebagai **nilai eigen** (*eigenvalue*) dari $\mathbf{A}$ jika terdapat

sebuah vektor tak-nol $\mathbf{v}$ (berukuran $p \times 1$) yang disebut **vektor eigen** (*eigenvector*), sedemikian sehingga berlaku:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v} \tag{2.20}$$

Vektor eigen menentukan "arah" dominan dari transformasi linier matriks $\mathbf{A}$, sedangkan nilai eigen menentukan besaran "kekuatan" atau variansi pada arah tersebut.

Definisi 2.16 (Invers Matriks)**.** Sebuah matriks persegi $\mathbf{A}$ memiliki invers $\mathbf{A}^{-1}$ jika $\det(\mathbf{A}) \neq 0$, sedemikian sehingga berlaku $\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$, dengan $\mathbf{I}$ adalah matriks identitas. Invers dari matriks korelasi digunakan dalam perhitungan statistik KMO untuk mendapatkan korelasi parsial melalui matriks anti-citra.

Karena matriks kovariansi selalu bersifat simetris ($\mathbf{A} = \mathbf{A}^T$), berlaku teorema dekomposisi spektral berikut.

Teorema 2.1 (Dekomposisi Spektral)**.** Setiap matriks simetris $\mathbf{A}$ berukuran $p \times p$ dapat didekomposisi menjadi:

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T = \sum_{j=1}^{p} \lambda_j \mathbf{v}_j \mathbf{v}_j^T \tag{2.21}$$

dengan $\mathbf{V}$ adalah matriks ortogonal ($p \times p$) yang kolom-kolomnya ($\mathbf{v}_j$) adalah vektor eigen yang saling tegak lurus, dan $\mathbf{\Lambda}$ adalah matriks diagonal berisi nilai eigen terurut $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$ pada elemen diagonalnya.

Selain dekomposisi, konsep *trace* matriks juga menjadi fundamental, khususnya dalam perhitungan koefisien korelasi antar-konfigurasi (Koefisien RV) pada metode STATIS.

Definisi 2.17 (Trace Matriks)**.** *Trace* dari sebuah matriks persegi $\mathbf{A}$ berukuran $n \times n$, dinotasikan sebagai $tr(\mathbf{A})$, adalah penjumlahan dari elemen-elemen diagonal utamanya:

$$tr(\mathbf{A}) = \sum_{i=1}^{n} a_{ii} \tag{2.22}$$

Sifat penting dari *trace* yang digunakan dalam pengukuran jarak antar-matriks adalah invariansi siklis: $tr(\mathbf{AB}) = tr(\mathbf{BA})$.

Definisi 2.18 (Dekomposisi Nilai Singular (SVD))**.** *Singular Value Decomposition* (SVD) adalah faktorisasi yang dapat diterapkan pada matriks persegi panjang manapun $\mathbf{A}$ berukuran $m \times n$:

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^T \tag{2.23}$$

dengan:

- $\mathbf{U}$ $(m \times m)$: matriks ortogonal, kolom-kolomnya disebut **vektor singular kiri**.
- $\mathbf{S}$ $(m \times n)$: matriks diagonal yang berisi **nilai singular** $\sigma_1 \geq \sigma_2 \geq \cdots \geq 0$ pada diagonal utamanya.
- $\mathbf{V}^T$ $(n \times n)$: transpos dari matriks ortogonal $\mathbf{V}$, kolom-kolomnya disebut **vektor singular kanan**.

Untuk matriks simetris semi-definit positif $\mathbf{W}_c$ (seperti matriks kompromi STATIS), SVD setara dengan dekomposisi spektral: nilai singular σ_i sama dengan nilai eigen λ_i dan $\mathbf{U} = \mathbf{V}$.

SVD memiliki kestabilan numerik yang lebih baik dibandingkan dekomposisi eigen langsung. Oleh karena itu lebih sering digunakan dalam implementasi komputasional. Skor kompromi STATIS ($\mathbf{F}_c$) diperoleh dari:

$$\mathbf{F}_c = \mathbf{U}\sqrt{\mathbf{S}} \tag{2.24}$$

sehingga $\mathbf{W}_c = \mathbf{U}\mathbf{S}\mathbf{U}^T = \mathbf{F}_c\mathbf{F}_c^T$.

2.9 Korelasi Pearson

Korelasi Pearson adalah ukuran statistik yang mengkuantifikasi kekuatan dan arah hubungan linier antara dua variabel. Koefisien ini digunakan secara luas dalam analisis multivariat, khususnya pada pembentukan matriks korelasi yang merupakan fondasi Uji KMO dan Bartlett, serta pada komputasi *loadings* (arah variabel dalam Biplot) (Johnson & Wichern, 2007).

Definisi 2.19 (Koefisien Korelasi Pearson)**.** Koefisien korelasi Pearson antara dua variabel x dan y dari n pengamatan didefinisikan sebagai:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{2.25}$$

Nilai r_{xy} berkisar antara -1 dan 1:

- $r_{xy} = 1$: korelasi positif sempurna (ketika x naik, y naik proporsional).
- $r_{xy} = -1$: korelasi negatif sempurna (ketika x naik, y turun proporsional).

- $r_{xy} = 0$: tidak ada hubungan linier.

Matriks Korelasi Untuk p variabel, koefisien Pearson antar setiap pasang variabel dapat disusun menjadi matriks korelasi simetris $\mathbf{R}$ berukuran $p \times p$, dengan elemen (j, k)-nya adalah r_{jk}. Diagonal utamanya selalu bernilai 1 ($r_{jj} = 1$). Matriks korelasi inilah yang menjadi dasar perhitungan statistik KMO dan Bartlett.

Dalam konteks Dynamic Biplot, loadings variabel ke-j pada komponen ke-ℓ dihitung sebagai korelasi Pearson antara nilai rata-rata variabel tersebut lintas situasi ($\bar{x}_j$) dengan skor kompromi pada komponen ke-ℓ ($\mathbf{F}_c^{(\ell)}$):

$$g_{j\ell} = r(\bar{x}_j, \mathbf{F}_c^{(\ell)}) \tag{2.26}$$

Panjang vektor loading $\sqrt{g_{j1}^2 + g_{j2}^2}$ mencerminkan seberapa baik variabel tersebut direpresentasikan dalam ruang dua dimensi kompromi.

2.10 *Principal Component Analysis* (PCA) dan Biplot

Principal Component Analysis (PCA) atau dalam bahasa Indonesia dikenal sebagai Analisis Komponen Utama merupakan metode yang pertama kali diinisiasi oleh Pearson (1901) melalui gagasan penyesuaian bidang pada himpunan titik, kemudian berkembang menjadi teknik reduksi dimensi data multivariat yang mentransformasi p variabel asli yang saling berkorelasi menjadi q variabel baru ($q < p$) yang tidak berkorelasi, disebut komponen utama (*principal components*) (Hotelling, 1933).

Misalkan $\mathbf{X}$ adalah matriks data berukuran $n \times p$ yang telah distandardisasi. PCA mengekstraksi informasi dengan mendekomposisi matriks kovariansi $\mathbf{S} = \frac{1}{n-1}\mathbf{X}^T\mathbf{X}$. Berdasarkan Teorema Dekomposisi Spektral, $\mathbf{S} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$, menghasilkan dua elemen utama:

1. **Matriks Loadings (V)** adalah matriks vektor eigen yang berisi bobot kontribusi setiap variabel asli terhadap setiap komponen utama. Kolom ke-j dari $\mathbf{V}$ disebut vektor loading ke-j.

2. **Matriks Scores (F)** adalah proyeksi data asli ke dalam ruang komponen utama, dihitung sebagai:

$$\mathbf{F} = \mathbf{X}\mathbf{V} \tag{2.27}$$

Untuk memvisualisasikan hasil reduksi dimensi secara simultan antara objek dan variabel, digunakan teknik Biplot.

Definisi 2.20 (Biplot)**.** Biplot adalah representasi grafis dua dimensi yang memetakan baris (objek) dan kolom (variabel) dari matriks data $\mathbf{X}$ secara bersamaan dalam satu grafik (Gabriel, 1971). Biplot didasarkan pada aproksimasi matriks *rank*-rendah:

$$\mathbf{X} \approx \mathbf{F}\mathbf{V}^T \tag{2.28}$$

Dalam visualisasi ini:

- Objek ke-i digambarkan sebagai titik berdasarkan baris ke-i dari matriks Skor $\mathbf{F}$. Jarak Euclidean antar titik merepresentasikan kemiripan antar objek.
- Variabel ke-j digambarkan sebagai vektor (panah) berdasarkan baris ke-j dari matriks Loadings $\mathbf{V}$. Sudut antar vektor merepresentasikan korelasi antar variabel. Sudut lancip ($< 90°$) berarti korelasi positif, sedangkan sudut tumpul ($> 90°$) berarti korelasi negatif.

PCA dan Biplot bekerja dengan baik untuk satu tabel data pada satu titik waktu. Namun, ketika data tersebar dalam K matriks yang berbeda-beda seiring waktu, PCA konvensional tidak mampu menangkap dinamika evolusi struktural tersebut. Keterbatasan inilah yang mendorong pengembangan metode STATIS.

2.11 Metode STATIS

STATIS merupakan singkatan dari *Structuration des Tableaux à Trois Indices de la Statistique* atau jika diartikan ke dalam bahasa Indonesia berbunyi ”Strukturisasi Tabel dengan Tiga Indeks dalam Statistik”. STATIS adalah metode analisis data eksploratif yang dirancang untuk menganalisis sekumpulan K tabel data dengan membandingkan struktur internal antar-objek pada setiap situasi waktu (Lavit et al., 1994). Berbeda dengan metode yang menggabungkan data secara naif (seperti *Pooled* PCA), STATIS mempertahankan integritas struktur masing-masing situasi melalui tiga tahapan analisis data yang sistematis: intra-struktur, inter-struktur, dan kompromi. Konsep inti STATIS dilandasi oleh teori operator Escoufier (Escoufier, 1973) yang memperkenalkan cara mengukur “jarak” antara dua konfigurasi data multivariat.

2.11.1 Tahap 1: Intra-struktur

Tahap pertama bertujuan mentransformasi tabel data terstandardisasi terbobot setiap situasi menjadi representasi geometri yang dapat dibandingkan dalam ruang bobot $\mathbf{D}$ yang sama. Misalkan $\mathbf{Z}_k$ adalah matriks data terstandardisasi terbobot pada situasi ke-k

(Persamaan 2.5). STATIS mendefinisikan **operator Escoufier** $\mathbf{W}_k$ untuk setiap $k = 1, \ldots, K$ sebagai matriks produk skalar berukuran $n \times n$ (Lavit et al., 1994):

$$\mathbf{W}_k = \mathbf{Z}_k \mathbf{Z}_k^T \tag{2.29}$$

Elemen-elemen dalam $\mathbf{W}_k$ merepresentasikan kemiripan antar-objek pada situasi ke-k. Karena analisis data dilakukan dalam ruang bobot $\mathbf{D}$, maka perhitungan produk Hilbert–Schmidt dan koefisien RV pada tahap berikutnya mengikutsertakan matriks bobot diagonal $\mathbf{D}$ (Lavit et al., 1994).

Interpretasi $\mathbf{W}_k$: Elemen $\mathbf{W}_k[i, j]$ yang bernilai besar menunjukkan bahwa objek ke-i dan objek ke-j memiliki profil variabel yang sangat mirip pada situasi ke-k, sedangkan nilai yang kecil menunjukkan perbedaan karakteristik yang mencolok.

2.11.2 Tahap 2: Inter-struktur

Setelah representasi $\mathbf{W}_k$ diperoleh untuk setiap situasi, langkah selanjutnya adalah mengukur seberapa mirip konfigurasi antar-situasi. Secara aljabar, matriks simetris $\mathbf{W}_k$ dan $\mathbf{W}_{k'}$ dilengkapi dengan produk skalar Hilbert–Schmidt $(\mathbf{W}_k \mid \mathbf{W}_{k'}) = \operatorname{tr}(\mathbf{W}_k \mathbf{D} \mathbf{W}_{k'} \mathbf{D})$ (Lavit et al., 1994; Oliveira et al., 2024). Produk ini membentuk **matriks interstruktur** berukuran $K \times K$:

$$H_{kk'} = \operatorname{tr}(\mathbf{W}_k \mathbf{D} \mathbf{W}_{k'} \mathbf{D}), \qquad k, k' = 1, \ldots, K. \tag{2.30}$$

Matriks $\mathbf{H} = (H_{kk'})$ merepresentasikan kemiripan geometris antar-situasi dalam kondisi berbobot. Dekomposisi spektralnya memberikan gambaran grafis interstruktur (titik-titik situasi di $\mathbb{R}^h$) sebagaimana dijelaskan oleh Lavit et al. (1994).

Untuk interpretasi data yang telah terstandardisasi (nilai diagonal menjadi 1), digunakan **koefisien RV** (Escoufier, 1973):

Definisi 2.21 (Koefisien RV)**.** Koefisien RV antara dua matriks konfigurasi $\mathbf{W}_k$ dan $\mathbf{W}_{k'}$ didefinisikan sebagai:

$$RV(\mathbf{W}_k, \mathbf{W}_{k'}) = \frac{\operatorname{tr}(\mathbf{W}_k \mathbf{D} \mathbf{W}_{k'} \mathbf{D})}{\sqrt{\operatorname{tr}((\mathbf{W}_k \mathbf{D})^2) \operatorname{tr}((\mathbf{W}_{k'} \mathbf{D})^2)}} = \frac{H_{kk'}}{\sqrt{H_{kk} H_{k'k'}}}. \tag{2.31}$$

Nilai RV berkisar antara 0 dan 1. Nilai RV yang mendekati 1 mengindikasikan bahwa konfigurasi antar-objek pada situasi ke-k sangat mirip dengan situasi ke-k'. Koefisien ini secara geometris merupakan kosinus sudut antara dua matriks dalam ruang vektor matriks terbobot.

Matriks $\mathbf{R}_{\text{RV}} = (RV(\mathbf{W}_k, \mathbf{W}_{k'}))$ dapat digunakan untuk membuat heatmap dan untuk mengetahui jarak antar-situasi dengan rumus jarak $d^2(k, k') = 2(1 - RV)$ antar-situasi, namun **pembobotan kompromi** mengacu pada $\mathbf{H}$: menurut Lavit et al. (1994). Koefisien α_k diambil sebagai komponen vektor eigen utama yang terkait dengan nilai-nilai eigen terbesar dari dekomposisi spektral matriks interstruktur. Secara eksplisit,

$$\mathbf{H}\mathbf{u} = \theta\mathbf{u}, \tag{2.32}$$

dengan $\mathbf{H}$ adalah matriks interstruktur, $\mathbf{u}$ adalah vektor eigen, dan θ adalah nilai eigen. Vektor eigen pertama $\mathbf{u}_1$ (berkorespondensi dengan θ_1 terbesar) dipilih dengan elemen non-negatif lalu dinormalisasi:

$$\alpha_k = \frac{u_{1k}}{\sum_{k'=1}^{K} u_{1k'}}. \tag{2.33}$$

Kendala $\sum_{k=1}^{K} \alpha_k = 1$ memastikan matriks kompromi (yang akan dibahas pada sub-bab 2.11.3) sebanding dengan skala $\mathbf{W}_k$ (Lavit et al., 1994). Sebagai catatan, $\mathbf{R}_{\text{RV}}$ dan $\mathbf{H}$ memiliki nilai eigen berbeda. Hal ini sesuai dengan implementasi ACT/STATIS yang menggunakan Persamaan (2.32)–(2.33) untuk $\boldsymbol{\alpha}$.

Contoh 2.1 (Logika Bobot)**.** Apabila suatu situasi memiliki profil yang sangat anomali dibandingkan situasi lainnya (misalnya akibat krisis), metode STATIS akan secara otomatis memberikan bobot α_k yang lebih kecil pada situasi tersebut. Hal ini memastikan bahwa struktur kompromi tidak "terdistorsi" oleh situasi yang tidak representatif.

2.11.3 Tahap 3: Analisis Kompromi

Tahap ini membentuk struktur "rata-rata" yang disebut Kompromi. Matriks kompromi $\mathbf{W}_c$ dihitung sebagai kombinasi linier terbobot (menggunakan bobot α_k) dari matriks intra-struktur $\mathbf{W}_k$ (Lavit et al., 1994):

$$\mathbf{W}_c = \sum_{k=1}^{K} \alpha_k \mathbf{W}_k \tag{2.34}$$

Matriks $\mathbf{W}_c$ (berukuran $n \times n$) merepresentasikan pola hubungan antar-objek yang paling stabil selama periode pengamatan. Karena setiap $\mathbf{W}_k$ adalah matriks simetris positif semi-definit dan $\alpha_k \geq 0$, maka $\mathbf{W}_c$ juga bersifat simetris positif semi-definit. Penurunan

sifat ini ditunjukkan melalui bentuk kuadratik untuk sebarang vektor $\mathbf{v} \in \mathbb{R}^n$:

$$\mathbf{v}^T \mathbf{W}_c \mathbf{v} = \mathbf{v}^T \left(\sum_{k=1}^{K} \alpha_k \mathbf{W}_k \right) \mathbf{v} = \sum_{k=1}^{K} \alpha_k (\mathbf{v}^T \mathbf{W}_k \mathbf{v}) \geq 0 \tag{2.35}$$

Hal ini menjamin bahwa dekomposisi spektral pada $\mathbf{W}_c$ akan selalu menghasilkan nilai eigen yang non-negatif. Berdasarkan teorema 2.1, $\mathbf{W}_c$ dapat didekomposisi menjadi:

$$\mathbf{W}_c = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T \tag{2.36}$$

dengan $\mathbf{P}$ adalah matriks vektor eigen yang ortogonal ($\mathbf{P}^T\mathbf{P} = \mathbf{I}$) dan $\mathbf{\Lambda}$ adalah matriks diagonal berisi nilai eigen terurut $\lambda_1 \geq \lambda_2 \geq \cdots \geq 0$.

Koordinat objek ke-i pada ruang kompromi (skor kompromi) diperoleh dari baris ke-i matriks $\mathbf{F}_c$ (Lavit et al., 1994). Karena matriks $\mathbf{W}_c$ digunakan dalam ruang bobot $\mathbf{D}$, koordinat akhir perlu dikembalikan ke ruang asli observasi melalui transformasi invers akar matriks bobot:

$$\mathbf{F}_c = \mathbf{D}^{-1/2} \mathbf{P} \mathbf{\Lambda}^{1/2} \tag{2.37}$$

dengan $\mathbf{D}^{-1/2} = \mathrm{diag}(1/\sqrt{m_1}, \ldots, 1/\sqrt{m_n})$, $\mathbf{P}$ adalah matriks vektor eigen dari $\mathbf{W}_c$ ($\mathbf{P}^T\mathbf{P} = \mathbf{I}$), dan $\mathbf{\Lambda}^{1/2}$ adalah matriks diagonal akar nilai eigen. Transformasi $\mathbf{D}^{-1/2}$ memastikan bahwa koordinat kompromi merepresentasikan posisi objek dalam ruang asli, bukan dalam ruang terbobot (Lavit et al., 1994).

Dalam ruang bobot $\mathbf{D}$, berlaku hubungan $\mathbf{D}^{1/2}\mathbf{F}_c\mathbf{F}_c^T\mathbf{D}^{1/2} = \mathbf{W}_c$, yang konsisten dengan interpretasi bahwa produk skalar terbobot antara koordinat objek ke-i dan ke-i' merepresentasikan kemiripan objek ke-i dan ke-i' dalam ruang kompromi. Untuk visualisasi, umumnya hanya diambil dua kolom pertama dari $\mathbf{F}_c$ yang berkorespondensi dengan dua nilai eigen terbesar.

2.11.4 Tahap 4: Analisis Variabel (Loadings)

Selain memetakan objek, STATIS juga dapat memetakan variabel ke dalam ruang kompromi untuk melihat hubungan antar-variabel. Prosedur ini dilakukan melalui analisis data pada ruang variabel (*dual space*) (Lavit et al., 1994).

1. **Matriks Produk Skalar Variabel Terbobot:** Untuk setiap situasi k, dibentuk matriks produk skalar antar-variabel terbobot $\mathbf{S}_k$ berukuran $p \times p$, yang merepresentasikan kovariansi terbobot antar-indikator dalam ruang bobot $\mathbf{D}$:

$$\mathbf{S}_k = \mathbf{Z}_k^T \mathbf{D} \mathbf{Z}_k \tag{2.38}$$

2. **Variabel Kompromi:** Serupa dengan objek kompromi, variabel kompromi $\mathbf{S}_c$ dibentuk sebagai kombinasi linier terbobot menggunakan α_k:

$$\mathbf{S}_c = \sum_{k=1}^{K} \alpha_k \mathbf{S}_k \tag{2.39}$$

3. **Dekomposisi Spektral $\mathbf{S}_c$:** Matriks $\mathbf{S}_c$ (simetris positif semi-definit) didekomposisi menjadi:

$$\mathbf{S}_c = \mathbf{V}_c \mathbf{\Lambda}_s \mathbf{V}_c^T \tag{2.40}$$

dengan $\mathbf{V}_c$ (berukuran $p \times p$) adalah matriks vektor eigen ortogonal dari $\mathbf{S}_c$ dan $\mathbf{\Lambda}_s$ adalah matriks diagonal nilai eigen.

4. **Koordinat Variabel (Loading Kompromi):** Koordinat variabel dalam ruang kompromi, disebut matriks loading $\mathbf{G}_c$ (berukuran $p \times 2$), diperoleh dari:

$$\mathbf{G}_c = \mathbf{V}_c \mathbf{\Lambda}_s^{1/2} \tag{2.41}$$

Kolom-kolom $\mathbf{G}_c$ digunakan sebagai koordinat ujung panah variabel dalam biplot kompromi. Sudut antar vektor kolom mengaproksimasi korelasi antar variabel.

2.11.5 Klasifikasi Struktur: Analisis Transversal dan Longitudinal

Dalam pengembangan terbaru metodologi STATIS, Oliveira et al. (2024) mengklasifikasikan analisis data pada vektor struktur inter-struktur menjadi dua pendekatan berdasarkan keberadaan urutan pada periode studi:

1. **Analisis Transversal (*Transversal Analysis*):** Analisis Transversal dilakukan untuk membandingkan komponen yang setara namun tidak memiliki urutan waktu yang mengikat (misalnya perbandingan antar kelompok atau juri).

2. **Analisis Longitudinal (*Longitudinal Analysis*):** Analisis Longitudinal dilakukan ketika terdapat urutan yang jelas dalam periode studi, seperti data yang dikumpulkan pada periode waktu yang berurutan. Analisis ini sangat memadai untuk memodelkan garis tren lintasan (*trajectories*) dari waktu ke waktu.

Dalam konteks penelitian ini, karena data yang dianalisis mencakup periode tahun 2020 hingga 2024 secara berurutan, maka pendekatan yang digunakan adalah analisis longitudinal, dengan arah dan besaran pergeseran lintasan objek menjadi fokus utama interpretasi.

2.11.6 Uji Signifikansi Stabilitas Struktur (Permutasi Monte Carlo)

Metode STATIS secara deskriptif menghasilkan struktur kompromi, namun tidak secara otomatis menjamin bahwa struktur tersebut signifikan secara statistik. Dapat terjadi struktur kompromi yang terbentuk hanya merupakan artefak matematika dari data yang sebenarnya acak dan tidak memiliki pola hubungan yang stabil antar-situasi.

Untuk memvalidasi hal ini, digunakan pengujian berbasis resampling, yaitu uji permutasi non-parametrik yang diadopsi dari berbagai literatur analisis multivariat (Kazi-Aoual et al., 1995; Abdi et al., 2012; Legendre & Legendre, 2012). Uji ini tidak mensyaratkan asumsi distribusi normal pada data. Mengingat jumlah seluruh kemungkinan permutasi baris dari himpunan matriks sangat masif ($(n!)^K$), menghitung permutasi eksak secara menyeluruh sangat tidak efisien secara komputasional. Oleh karena itu, pengujian dieksekusi menggunakan pendekatan **Simulasi Monte Carlo**, dengan sampel permutasi acak dalam jumlah besar (B kali iterasi) diambil untuk membangun aproksimasi numerik dari distribusi eksak.

1. **Hipotesis Uji:**

   - H_0: $\theta_1 = \mathrm{E}\left[\theta_1^{\pi}\right]$ (Konfigurasi objek antar situasi waktu saling independen secara linier, sehingga data bersifat acak dan tidak ada struktur bersama yang stabil).
   - H_1: $\theta_1 > \mathrm{E}\left[\theta_1^{\pi}\right]$ (Konfigurasi objek antar situasi waktu memiliki ketergantungan linier parsial atau total yang signifikan, membentuk struktur kompromi yang bermakna).

   Notasi superskrip π (pi) pada rumusan hipotesis di atas merepresentasikan kondisi *permutasi*. Dengan demikian, θ_1^{π} melambangkan statistik nilai eigen dominan yang dihasilkan dari data *dummy* (buatan) yang telah diacak (dipermutasi) untuk mensimulasikan kondisi distribusi H_0, sedangkan $\mathrm{E}\left[\theta_1^{\pi}\right]$ merupakan nilai harapan atau nilai rata-rata dari statistik uji yang dihasilkan dari data acak tersebut.

2. **Statistik Uji dan Distribusi:** Statistik yang digunakan adalah θ_1, yaitu nilai eigen terbesar dari matriks interstruktur $\mathbf{H}$ pada Persamaan (2.30). Nilai θ_1 mengkuantifikasi proporsi informasi (variansi) matriks produk skalar yang dapat diringkas secara konsisten dalam satu dimensi interstruktur. Semakin besar θ_1, semakin kuat bukti empiris adanya struktur spasio-temporal bersama yang stabil (Abdi et al., 2012).

Distribusi teoretis (parametrik) dari θ_1 dalam analisis multivariat dapat menjadi semakin kompleks sehingga semakin sulit untukdidefinisikan. Sebagai solusinya, distribusi probabilitas pada kondisi H_0 (*null distribution*) diasumsikan benar. Kondisi ini dibangun secara empiris melalui simulasi Monte Carlo terhadap data yang dipermutasi sehingga menghasilkan sekumpulan statistik uji sintetis yang dinotasikan sebagai θ_1^{π} yang jumlahnya sama dengan jumlah iterasi yang dilakukan (B).

3. **Prosedur Simulasi Monte Carlo:**

   a. Menghitung nilai uji empiris θ_1^{obs} (observasi asli) dari matriks interstruktur $\mathbf{H}$ berdasar kumpulan matriks $\mathbf{Z}_k$.

   b. Melakukan pengacakan baris (permutasi label objek) secara independen pada setiap matriks situasi, menghasilkan sekumpulan matriks *dummy* acak $\mathbf{Z}_k^{\pi}$. Pengacakan ini mengubah struktur keterkaitan asli antar-situasi, mensimulasikan kondisi di mana H_0 berlaku.

   c. Menghitung operator Escoufier terbobot untuk himpunan data tersimulasi: $\mathbf{W}_k^{\pi} = (\mathbf{D}^{1/2}\mathbf{Z}_k^{\pi})(\mathbf{D}^{1/2}\mathbf{Z}_k^{\pi})^T$. Notasi eksponen π mensyaratkan pembedaan dari *conjugate transpose* atau rotasi matriks asli $\mathbf{W}_k$ maupun matriks kompromi $\mathbf{W}_c$.

   d. Membentuk matriks interstruktur baru $\mathbf{H}^{\pi}$ yang elemennya bernilai $H_{kk'}^{\pi} = \text{tr}(\mathbf{W}_k^{\pi}\mathbf{W}_{k'}^{\pi})$. Selanjutnya, mengekstraksi nilai eigen terbesarnya yang ditetapkan sebagai θ_1^{π}.

   e. Mengulangi iterasi pengacakan matriks pada langkah (b) hingga (d) secara terus-menerus sebanyak B kali (dalam penelitian ini $B = 1000$) untuk menghasilkan histogram distribusi frekuensi null dari θ_1^{π}.

4. **Pengambilan Keputusan:** Berbeda dengan uji statistik parametrik konvensional yang mengandalkan tabel distribusi teoritis, distribusi sampling dari θ_1 dalam konteks STATIS tidak diketahui bentuk pastinya secara analitis. Oleh karena itu, pengujian ini bersifat **non-parametrik** (*distribution-free*), di mana distribusi null dibangun secara empiris dari data itu sendiri melalui proses permutasi (Kazi-Aoual et al., 1995).

   Nilai *p-value* dihitung sebagai proporsi statistik uji hasil permutasi (θ_1^{π}) yang nilainya

lebih besar atau sama dengan statistik observasi (θ_1^{obs}):

$$p\text{-value} = \frac{\sum_{b=1}^{B} I\left(\theta_1^{\pi(b)} \geq \theta_1^{\text{obs}}\right) + 1}{B+1} \tag{2.42}$$

dengan $I(\cdot)$ sebagai fungsi indikator Bernoulli yang bernilai 1 jika argumen perbandingan benar dan 0 jika sebaliknya. Elemen penambah $+1$ pada pembilang dan penyebut merupakan operasi *pseudo-count correction* yang lazim digunakan dalam algoritma Monte Carlo untuk mereduksi bias penaksir titik, sehingga p-value eksak tidak bernilai nol absolut (0%) (Phipson & Smyth, 2010).

Apabila p-value $< \alpha$ (misalnya 0,05), maka H_0 ditolak. Hal ini membuktikan bahwa kompromi STATIS mencerminkan konstelasi evolusi sistem sosial-ekonomi yang signifikan, bukan produk distorsi stokastik (Legendre & Legendre, 2012).

2.11.7 Model Vektor Struktur dan Kerangka Inferensial STATIS

Sebagaimana diuraikan di atas, STATIS klasik (Lavit et al., 1994) bersifat eksploratif: kesimpulan mengenai ada-tidaknya struktur bersama didasarkan semata-mata pada inspeksi grafis terhadap dekomposisi interstruktur. Areia et al. (2008) memperluas kerangka ini dengan memperkenalkan formulasi model probabilistik yang memungkinkan inferensi statistik formal atas parameter interstruktur. Pengembangan ini dirangkum kembali dalam tinjauan metodologis terkini oleh Oliveira et al. (2024).

Model Rank-1 dan Estimator Vektor Struktur

Apabila titik-titik representasi situasi pada plot interstruktur cenderung terletak sepanjang sumbu eigen pertama *struktur bersama derajat 1* (*common structure of degree 1*) maka Areia et al. (2008); Mexia & Oliveira (2007) mengajukan model berikut untuk matriks interstruktur $\mathbf{H}$:

$$\mathbf{H} = \lambda \boldsymbol{\alpha}\boldsymbol{\alpha}^T + \bar{\mathbf{E}}, \qquad \bar{\mathbf{E}} = \frac{1}{2}\left(\mathbf{E} + \mathbf{E}^T\right), \tag{2.43}$$

dengan asumsi bahwa $\mathrm{Vec}(\mathbf{E}) \sim \mathcal{N}(\mathbf{0},\, \sigma^2 \mathbf{I}_{K^2})$, dengan $\lambda > 0$ adalah skalar kegentingan (magnitude), $\boldsymbol{\alpha}$ adalah vektor satuan yang menentukan arah struktur bersama, dan $\bar{\mathbf{E}}$ adalah komponen galat simetris.

Dalam model ini, informasi yang terkandung dalam $\mathbf{H}$ dipadatkan ke dalam **vektor**

struktur $\boldsymbol{\beta}$:

$$\tilde{\boldsymbol{\beta}} = \lambda_1 \boldsymbol{\alpha}_1, \tag{2.44}$$

dengan λ_1 dan $\boldsymbol{\alpha}_1$ berturut-turut adalah nilai eigen dan vektor eigen pertama (terbesar) dari $\mathbf{H}$. Komponen ke-k dari $\tilde{\boldsymbol{\beta}}$, yaitu $\tilde{\beta}_k = \lambda_1 u_{1k}$ (sebelum normalisasi $\boldsymbol{\alpha}$), merupakan estimator tidak bias yang konsisten dari parameter $\beta_k = \lambda u_k$ (Areia et al., 2008; Oliveira et al., 2024).

Besaran *Sum of Squares* residual dihitung sebagai:

$$V = \|\mathbf{H}\|_F^2 - \|\tilde{\boldsymbol{\beta}}\|^2 = \sum_{k=1}^{K}\sum_{k'=1}^{K} H_{kk'}^2 - \lambda_1^2, \tag{2.45}$$

dengan $\|\mathbf{H}\|_F^2 = \mathrm{tr}(\mathbf{H}^T\mathbf{H}) = \mathrm{tr}(\mathbf{H}^2)$ (karena $\mathbf{H}$ simetris). Nilai V yang kecil relatif terhadap $\|\mathbf{H}\|_F^2$ mengindikasikan bahwa model rank-1 memberikan aproksimasi yang baik terhadap $\mathbf{H}$, sehingga interpretasi melalui satu vektor struktur $\tilde{\boldsymbol{\beta}}$ adalah sahih.

Validasi Kegentingan Eigenvalue (Dominansi Struktur)

Validitas model bergantung pada *dominansi* eigenvalue pertama. Kuantitas yang mengukur hal ini didefinisikan sebagai rasio:

$$\tau = \frac{\lambda^2}{\sigma^2}, \tag{2.46}$$

dengan σ^2 merupakan varians galat dari model pada Persamaan (2.43). Nilai τ yang besar (yaitu ketika $\lambda_1 \gg \lambda_j$ untuk $j \geq 2$) mengkonfirmasi bahwa satu komponen dominan mampu menjelaskan hampir seluruh variansi interstruktur. Areia et al. (2008) menunjukkan bahwa estimator λ_1 dan $\boldsymbol{\alpha}_1$ memiliki perilaku yang baik (*good behaviors*) melalui simulasi. Secara empiris, dominansi ini dinilai melalui *proportion of inertia* pada sumbu pertama interstruktur:

$$\mathrm{Inertia}_1 = \frac{\lambda_1}{\sum_{j=1}^{K} \lambda_j}, \tag{2.47}$$

yang setara dengan kontribusi variansi dimensi pertama pada plot interstruktur.

Analisis Transversal dan Longitudinal (Keluarga Seri Studi)

Perluasan lebih lanjut oleh Areia et al. (2008), yang dirangkum kembali dalam Oliveira et al. (2024), mempertimbangkan situasi di mana tersedia *beberapa seri studi* yang masing-masing berkorespondensi dengan satu perlakuan atau kelompok dalam suatu model eksper-

imental. Misalkan terdapat G kelompok (misalnya G provinsi), masing-masing memiliki seri K matriks data $\{\mathbf{Z}_{gk}\}_{k=1}^{K}$ untuk $g = 1, \ldots, G$. Untuk setiap kelompok g diperoleh vektor struktur yang diestimasi $\tilde{\boldsymbol{\beta}}_g = \lambda_{1g}\boldsymbol{\alpha}_{1g}$. Dua jenis analisis inferensial kemudian dapat diterapkan (Oliveira et al., 2024):

1. **Analisis Transversal:** Menguji apakah vektor-vektor struktur dari kelompok yang berbeda ($\tilde{\boldsymbol{\beta}}_1, \tilde{\boldsymbol{\beta}}_2, \ldots, \tilde{\boldsymbol{\beta}}_G$) berbeda secara signifikan satu sama lain, atau dengan kata lain menguji ada-tidaknya pengaruh faktor kelompok terhadap struktur bersama. Analisis ini umumnya dilakukan pada komponen-komponen homologus dari vektor struktur (yaitu pada indeks situasi yang sama lintas kelompok) (Oliveira et al., 2024).

2. **Analisis Longitudinal:** Menguji apakah terdapat progresi atau tren yang signifikan dalam komponen vektor struktur seiring berjalannya waktu. Analisis ini relevan ketika seri studi disusun secara kronologis, dan pertanyaannya adalah apakah perubahan temporal yang teramati pada struktur bersama merupakan tren yang sistematis atau sekadar fluktuasi acak (Areia et al., 2008; Oliveira et al., 2024).

Hubungan dengan Uji Permutasi Uji permutasi yang dijelaskan pada subbab sebelumnya merupakan pendekatan non-parametrik yang menguji hipotesis global mengenai keberadaan struktur bersama yang setara dengan menguji $H_0 : \lambda = 0$ dalam model pada Persamaan (2.43). Analisis transversal dan longitudinal, di sisi lain, beroperasi *setelah* struktur bersama dikonfirmasi ada, dan mengajukan pertanyaan inferensial yang lebih spesifik mengenai perbedaan antar-kelompok dan tren temporal. Keduanya bersifat komplementer.

2.12 Dynamic Biplot dan Visualisasi Trajektori

Hasil dekomposisi kompromi $\mathbf{F}_c$ hanya memberikan gambaran rata-rata posisi objek selama periode pengamatan. Untuk memahami dinamika perubahan dari situasi ke situasi, diperlukan perluasan yang disebut *Dynamic Biplot* atau *Trajectory Biplot* (Egido & Galindo, 2015).

Konsep dasar dari visualisasi ini adalah memproyeksikan data tabel parsial (situasi tertentu) ke dalam ruang referensi yang stabil (ruang kompromi), sehingga posisi objek dapat dibandingkan secara *apple-to-apple* lintas waktu.

2.12.1 Proyeksi Lintasan (*Trajectory*)

Misalkan $\mathbf{Z}_k$ adalah matriks data terstandardisasi pada situasi ke-k ($n \times p$) dan $\mathbf{V}_c$ (berukuran $p \times 2$) adalah matriks vektor eigen dari matriks kompromi variabel $\mathbf{S}_c$. Koordinat

objek pada situasi ke-k, dinotasikan $\mathbf{F}_k$, dihitung melalui proyeksi linier (Lavit et al., 1994):

$$\mathbf{F}_k = \mathbf{Z}_k \mathbf{V}_c \tag{2.48}$$

Persamaan ini memetakan kondisi setiap situasi ke dalam sistem koordinat global yang sama. **Trajektori** atau lintasan objek ke-i didefinisikan sebagai urutan vektor koordinat dari waktu ke waktu:

$$\mathcal{T}_i = \{\mathbf{f}_{i,1}, \mathbf{f}_{i,2}, \ldots, \mathbf{f}_{i,K}\} \tag{2.49}$$

Visualisasi trajektori menghubungkan titik-titik koordinat ini dengan garis berarah, sehingga pergeseran karakteristik objek, misalnya perpindahan dari kuadran dengan nilai variabel tertentu yang rendah menuju kuadran dengan nilai yang tinggi dapat teramati secara visual.

2.12.2 Jarak Euclidean antar Trajektori

Untuk mengelompokkan objek berdasarkan dinamika lintasannya (bukan hanya posisi rata-ratanya), digunakan ukuran jarak yang memperhitungkan pergerakan lintas seluruh situasi waktu. Jarak Euclidean antar-trajektori objek ke-i dan objek ke-j (masing-masing memiliki K titik koordinat) didefinisikan sebagai:

$$d(i,j) = \sqrt{\sum_{k=1}^{K} \|\mathbf{f}_{i,k} - \mathbf{f}_{j,k}\|^2} \tag{2.50}$$

di mana $\mathbf{f}_{i,k} \in \mathbb{R}^2$ adalah koordinat proyeksi objek ke-i pada situasi ke-k. Matriks jarak ini kemudian digunakan sebagai masukan pada algoritma K-Means berbasis trajektori, sehingga objek-objek yang memiliki pola pergerakan serupa sepanjang waktu akan dikelompokkan bersama (Egido & Galindo, 2015).

2.12.3 Rotasi Baseline

Solusi *Principal Component Analysis* (PCA) dan Biplot bersifat invarian terhadap rotasi ortogonal, artinya rotasi sumbu koordinat tidak mengubah jarak antar-objek maupun sudut antar-variabel, namun dapat memudahkan interpretasi (Kroonenberg, 2008). Dalam implementasi dashboard, rotasi digunakan untuk menyelaraskan suatu vektor referensi (variabel atau objek yang dipilih sebagai *baseline*) dengan sumbu horizontal (PC1), sehingga perbandingan posisi relatif objek lain terhadap *baseline* tersebut lebih intuitif.

Sudut rotasi θ dihitung dari posisi vektor referensi $\mathbf{v} = (v_1, v_2)^T$ menggunakan fungsi

$\mathrm{atan2}$:

$$\theta = -\operatorname{atan2}(v_2, v_1) \tag{2.51}$$

Fungsi $\mathrm{atan2}$ mengembalikan sudut dalam radian antara sumbu positif-x dan vektor (v_1, v_2), dengan rentang nilai $(-\pi, \pi]$. Tanda negatif memastikan rotasi berlawanan jarum jam agar vektor referensi disejajarkan ke sumbu kanan (positif PC1).

Matriks rotasi ortogonal 2×2 yang merotasi koordinat sebesar sudut θ adalah:

$$\mathbf{Q}(\theta) = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix} \tag{2.52}$$

Dengan demikian, koordinat terotasi dihitung sebagai:

$$\mathbf{F}^* = \mathbf{F}\,\mathbf{Q}(\theta) \tag{2.53}$$

Prosedur ini diterapkan secara seragam ke semua plot (skor, loading, dan trajektori seluruh situasi waktu) agar konsistensi referensi spasial tetap terjaga. Hal ini memungkinkan peneliti mensejajarkan variabel tertentu dengan sumbu horizontal untuk memudahkan interpretasi posisi relatif antar-objek.

2.13 Metode Pengelompokan (*Clustering*)

Analisis pengelompokan (*clustering*) adalah metode statistik yang bertujuan mengelompokkan objek ke dalam beberapa kelompok sedemikian rupa sehingga objek yang berada dalam satu kelompok memiliki tingkat kemiripan yang tinggi, sementara objek antar kelompok bersifat heterogen.

2.13.1 K-Means Clustering

K-Means adalah algoritma *partitioning clustering* non-hierarkis yang mempartisi n objek ke dalam k klaster sedemikian rupa sehingga variansi dalam klaster (*within-cluster variation*) menjadi sekecil mungkin (MacQueen, 1967). Misalkan $\mathbf{x}_i \in \mathbb{R}^p$ adalah vektor observasi objek ke-i. Algoritma K-Means meminimumkan fungsi objektif *Sum of Squared Errors* (SSE):

$$SSE = \sum_{j=1}^{k} \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2 \tag{2.54}$$

dengan C_j adalah himpunan objek pada klaster ke-j dan $\boldsymbol{\mu}_j$ adalah sentroid klaster ke-j. Algoritma ini bekerja secara iteratif dengan memindahkan objek ke klaster bersentriod

terdekat hingga tidak ada objek yang berpindah tempat.

2.13.2 Penentuan Jumlah Klaster Optimal (Metode Elbow)

Tantangan utama K-Means adalah penentuan jumlah klaster optimal k yang bersifat apriori. Untuk menentukan k optimal secara empiris, metode *Elbow* digunakan sebagai panduan heuristik (Bholowalia & Kumar, 2014). Metode Elbow mengevaluasi efektivitas partisi dengan merencanakan kurva nilai inersia (SSE) pada sumbu Y terhadap nilai k yang bervariasi (misalnya 1 hingga 10) pada sumbu X. Semakin banyak klaster, nilai SSE secara matematis akan selalu menurun karena jarak objek ke sentroidnya terdekat akan semakin memendek. Namun, pada suatu titik tertentu (k), penurunan drastis SSE akan mulai melandai sehingga membentuk sudut (patahan/siku). Titik patahan inilah yang menunjukkan *diminishing returns* terhadap penambahan jumlah klaster yang direkomendasikan sebagai jumlah klaster optimal agar model tidak mengalami *overfitting* (Syakur et al., 2018).

2.13.3 Agglomerative Hierarchical Clustering (Dendrogram)

Sebagai alat bantu komplementer bagi metode Elbow, pendekatan hierarkis *Agglomerative Clustering* dengan metode *Ward's Linkage* digunakan untuk memvisualisasikan struktur pengelompokan secara hierarkis melalui Dendrogram (Ward Jr, 1963). Metode Ward menggunakan pendekatan *Analysis of Variance* (ANOVA) untuk mengevaluasi jarak antar-klaster. Pada setiap tahap aglomerasi, metode ini menggabungkan sepasang klaster yang meminimalkan peningkatan *Error Sum of Squares* (ESS) total. Peningkatan ESS agregat saat menggabungkan klaster A dan B untuk membentuk $A \cup B$ dihitung sebagai:

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\boldsymbol{\mu}_A - \boldsymbol{\mu}_B\|^2 \tag{2.55}$$

Jarak vertikal cabang dendrogram secara visual mengindikasikan ketidaksamaan antar-kelompok.

2.13.4 Matriks Transisi Temporal

Setelah hasil clustering ditetapkan per situasi waktu, diperlukan alat untuk menganalisis dinamika pergeseran keanggotaan objek antar-klaster. Matriks transisi $\mathbf{M}$ berdimensi $k \times k$ (dengan k adalah jumlah klaster) disusun untuk memetakan kondisi dari situasi k_1 ke situasi k_2. Elemen M_{xy} mendeskripsikan jumlah objek yang awalnya berada pada klaster

x di situasi k_1 namun berpindah ke klaster y di situasi k_2:

$$\mathbf{T} = \begin{pmatrix} M_{1,1} & M_{1,2} & \cdots & M_{1,k} \\ M_{2,1} & M_{2,2} & \cdots & M_{2,k} \\ \vdots & \vdots & \ddots & \vdots \\ M_{k,1} & M_{k,2} & \cdots & M_{k,k} \end{pmatrix} \tag{2.56}$$

Diagonal utama ($M_{j,j}$) merepresentasikan objek yang tidak berpindah klaster (stabil), sementara elemen *off-diagonal* merepresentasikan objek yang mengalami perubahan keanggotaan klaster antar-situasi.

2.13.5 Penyelarasan Klaster Lintas Waktu (*Cluster Correspondence*)

Sifat K-Means yang non-deterministik pada proses inisialisasi awal *centroid* menyebabkan pelabelan klaster bersifat arbitrer atau acak. Akibatnya, kelompok objek yang secara spasial berada pada kuadran yang sama dapat memperoleh label bilangan yang berbeda pada pengujian di tahun yang berbeda (misalnya, identitas klaster 1 pada tahun 2020 bergeser menjadi klaster 2 pada tahun 2021). Masalah ini dikenal dengan istilah *Label Switching* atau *Cluster Correspondence* (Kuhn, 1955).

Untuk menganalisis transisi kondisi (*transition matrix*) pada data longitudinal, pencocokan label antar-periode waktu merupakan prosedur prapemrosesan yang wajib dilakukan. Pencocokan ini menggunakan optimasi kombinatorial berlandaskan jarak *centroid*. Misalkan c_{1i} adalah *centroid* klaster ke-i pada tahun dasar, dan c_{2j} adalah *centroid* klaster ke-j pada tahun uji. Jarak *Euclidean* antar *centroid* dapat diformulasikan sebagai:

$$D(c_{1i}, c_{2j}) = \sqrt{\sum_{h=1}^{p} (c_{1ih} - c_{2jh})^2} \tag{2.57}$$

Matriks jarak ini kemudian diselesaikan menggunakan *Hungarian Algorithm* (Kuhn, 1955) untuk menemukan kombinasi pemetaan (*minimum weight bipartite matching*) sedemikian sehingga total biaya jarak atau fungsi objektif terminimisasi:

$$\min \sum_{i=1}^{k} \sum_{j=1}^{k} D(c_{1i}, c_{2j}) \cdot x_{ij} \tag{2.58}$$

di mana variabel biner $x_{ij} \in \{0, 1\}$ mengindikasikan apakah *centroid* i dari kondisi awal dipasangkan dengan *centroid* j pada kondisi tujuan. Dengan metode ini, keselarasan penamaan klaster dapat dijamin tetap konsisten untuk merepresentasikan profil kesejahteraan

yang sama.

2.14 Uji Autokorelasi Spasial (Global Moran's I)

Autokorelasi spasial mengacu pada korelasi antara nilai suatu atribut di satu lokasi dengan nilai atribut yang sama di lokasi lain yang berdekatan, suatu manifestasi dari Hukum Pertama Geografi Tobler yang menyatakan bahwa "segalanya berhubungan dengan segalanya yang lain, tetapi hal-hal yang berdekatan lebih berhubungan daripada yang jauh" (Johnson & Wichern, 2007).

2.14.1 Matriks Pembobot Spasial

Matriks Pembobot Spasial (*Spatial Weight Matrix*) $\mathbf{W}_c$ berukuran $N \times N$ merepresentasikan struktur ketetanggaan antar-wilayah. Elemen w_{ij} mendefinisikan seberapa besar pengaruh wilayah j terhadap wilayah i (Anselin, 1988). Salah satu definisi ketetanggaan yang umum digunakan adalah *Queen Contiguity*: wilayah i dan j dianggap bertetangga jika mereka berbagi setidaknya satu titik batas (sisi atau sudut):

$$w_{ij} = \begin{cases} 1 & \text{jika wilayah } i \text{ dan } j \text{ bertetangga} \\ 0 & \text{selainnya} \end{cases}, \quad w_{ii} = 0 \tag{2.59}$$

Untuk menghilangkan pengaruh perbedaan jumlah tetangga antar-wilayah, dilakukan **standardisasi baris** (*row standardization*):

$$w_{ij}^{*} = \frac{w_{ij}}{\sum_{k=1}^{N} w_{ik}} \tag{2.60}$$

Bentuk matriks pembobot terstandardisasi-baris adalah $\mathbf{W}^{*} = (w_{ij}^{*})$ di mana setiap baris berjumlah 1. Bentuk ini memastikan bahwa rata-rata berbobot spasial merupakan rata-rata sederhana dari nilai-nilai tetangga.

2.14.2 Statistik Global Moran's I

Definisi 2.22 (Global Moran's I)**.** Misalkan x_i adalah nilai suatu atribut pada wilayah ke-i. Global Moran's I menggunakan matriks pembobot awal (belum terstandardisasi baris)

$\mathbf{W}_c$ dengan elemen w_{ij}, dan didefinisikan sebagai:

$$I = \frac{N}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij}(x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2} \tag{2.61}$$

dengan N adalah jumlah wilayah dan $\bar{x}$ adalah rata-rata atribut. Ekspektasi di bawah hipotesis nol (tidak ada autokorelasi spasial) adalah $E[I] = -1/(N-1)$.

- Nilai I signifikan positif ($I \gg E[I]$): *spatial clustering*, yaitu wilayah bernilai tinggi bertetangga dengan wilayah bernilai tinggi.

- Nilai I signifikan negatif ($I \ll E[I]$): *spatial dispersion*, yaitu pola menyebar.

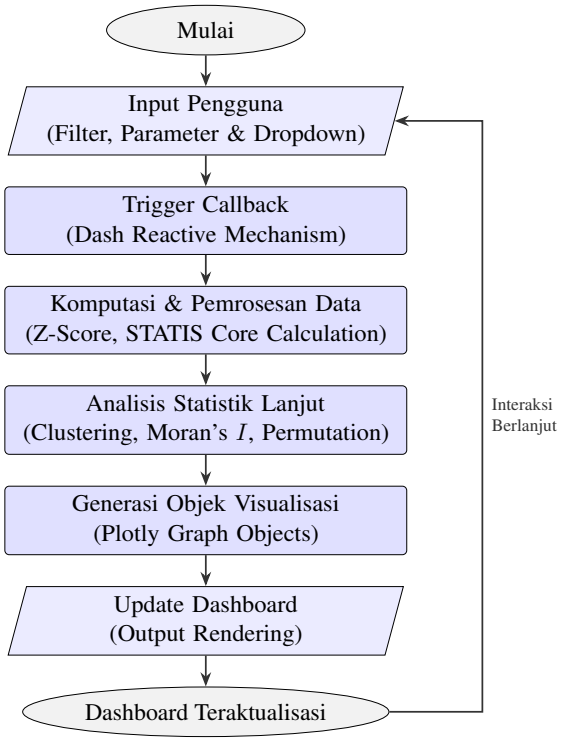
- Nilai $I \approx E[I]$: pola acak, tidak ada autokorelasi spasial.

Signifikansi statistik diuji menggunakan pendekatan permutasi (*conditional randomization*) yang tidak memerlukan asumsi normalitas. Hal ini serupa dengan logika uji permutasi pada stabilitas struktur STATIS.

2.15 Visualisasi Interaktif menggunakan Plotly dan Dash

Kompleksitas informasi yang dihasilkan oleh metode-metode yang telah dijelaskan di subbab sebelumnya menuntut media penyajian yang lebih adaptif dibandingkan grafik statis. Untuk menjawab kebutuhan ini, tersedia pustaka grafis **Plotly** (Plotly Technologies Inc., 2015) dalam kerangka kerja aplikasi web **Dash** (Plotly Technologies Inc., 2024).

Plotly adalah pustaka visualisasi data deklaratif yang memungkinkan pembuatan grafik interaktif saat diakses, termasuk grafik tiga dimensi (3D) yang dapat diputar dan diperbesar secara langsung. Sementara itu, Dash menerapkan paradigma pemrograman reaktif (*reactive programming*) yang memungkinkan grafik Plotly merespons secara dinamis terhadap masukan (*input*) pengguna. Secara konseptual, integrasi keduanya membentuk alur kerja analitik interaktif yang digambarkan melalui *flowchart* pada Gambar 2.1 berikut.



Gambar 2.1: Flowchart Mekanisme Interaktivitas Dash-Plotly

Pendekatan ini memfasilitasi Analisis Data Eksploratori (*Exploratory Data Analysis*/EDA) yang mendalam dan interaktif yang memungkinkan peneliti melakukan eksplorasi data secara *real-time*.

2.16 Kerangka Berpikir

Kerangka berpikir dalam penelitian ini disusun untuk mengintegrasikan berbagai metode analisis multivariat dan analisis spasial dalam memahami dinamika kesejahteraan rakyat di sebagian Pulau Jawa. Alur logika tersebut dimulai dari identifikasi fenomena ketimpangan spasio-temporal pada indikator sosial-ekonomi, yang kemudian diproses melalui tahapan-tahapan sistematis sebagai berikut:

1. **Input Data:** Pengumpulan data indikator kesejahteraan rakyat dari 41 kabupaten/kota di sebagian Pulau Jawa dalam rentang waktu tertentu, membentuk sebuah struktur data tiga-arah (*cube data*).

2. **Pra-pemrosesan:** Melakukan standardisasi data menjadi Z-score untuk menghilangkan bias satuan dan skala, selanjutnya dilakukan uji kelayakan multivariat (KMO dan Bartlett) untuk memastikan adanya struktur korelasi yang signifikan.

3. **Analisis STATIS:** Menerapkan tiga tahapan utama (intra-struktur, inter-struktur, dan kompromi) untuk mendapatkan representasi gabungan yang paling stabil pada lintas waktu tanpa mengabaikan variansi temporal dari masing-masing tahun.

4. **Visualisasi Dinamis dan Pengelompokan:** Mengekstraksi lintasan (*trajectory*) setiap objek untuk melihat pergerakan profil kesejahteraan secara individual. Hasil ini kemudian diklusterisasi menggunakan metode K-Means berbasis jarak trajektori untuk membangun tipologi wilayah yang memiliki karakteristik perubahan serupa.

5. **Validasi Spasial:** Melakukan pengujian autokorelasi spasial Global Moran's I untuk memverifikasi apakah kelompok-kelompok yang terbentuk secara statistik memiliki pola dependensi geografis yang nyata atau bersifat acak.

6. **Output Dashboard:** Mengintegrasikan seluruh hasil komputasi ke dalam platform visualisasi berbasis web menggunakan Dash Plotly, yang memungkinkan interpretasi data secara interaktif dan adaptif bagi pemangku kebijakan.

Dengan kerangka ini, analisis tidak hanya berhenti pada deskripsi angka rata-rata, melainkan mampu mengungkap pola evolusi dan interdependensi antar-wilayah secara mendalam.

BAB 3
METODOLOGI PENELITIAN

Bab ini berisi uraian mengenai tahapan-tahapan yang dilakukan dalam penelitian, mulai dari penentuan jenis penelitian, penyusunan rancangan (desain), identifikasi populasi dan sampel, prosedur pengumpulan data, hingga teknik pengumpulan dan analisis data secara komputasional menggunakan algoritma STATIS dan analisis spasial.

3.1 Statistika Deskriptif

Analisis diawali dengan ringkasan statistik untuk memberikan gambaran umum mengenai distribusi data yang menggambarkan kesejahteraan rakyat pada 41 kabupaten/kota selama periode 2020 hingga 2024. Indikator yang dimaksud dalam hal ini adalah variabel. Prosedur ini melibatkan penghitungan ukuran pemusatan dan penyebaran data sebagaimana didefinisikan pada Bab 2 yang meliputi:

1. **Rata-rata ($\bar{x}$):** Digunakan untuk melihat level umum pencapaian variabel (merujuk Persamaan 2.6).
2. **Simpangan Baku (s):** Untuk mengukur tingkat kesenjangan atau variabilitas data antar wilayah (merujuk Persamaan 2.8).
3. **Nilai Minimum dan Maksimum:** Untuk mengidentifikasi rentang sebaran nilai variabel dengan performa ekstrim (merujuk Persamaan 2.9).
4. **Kuartil (Q_1 dan Q_3) serta Median (Q_2):** Untuk melihat sebaran data berdasarkan pemisahan persentase kelompok amatan (merujuk Persamaan 2.7).
5. **Kemiringan (*Skewness*):** Untuk mengukur tingkat asimetri distribusi data (merujuk Persamaan 2.12).
6. **Keruncingan (*Kurtosis*):** Untuk mengukur ketebalan ekor dan keruncingan relatif distribusi data dibandingkan distribusi normal (merujuk Persamaan 2.13).
7. **Koefisien Variasi (CV):** Digunakan untuk membandingkan tingkat keragaman antar-variabel yang memiliki skala berbeda (merujuk Persamaan 2.11).

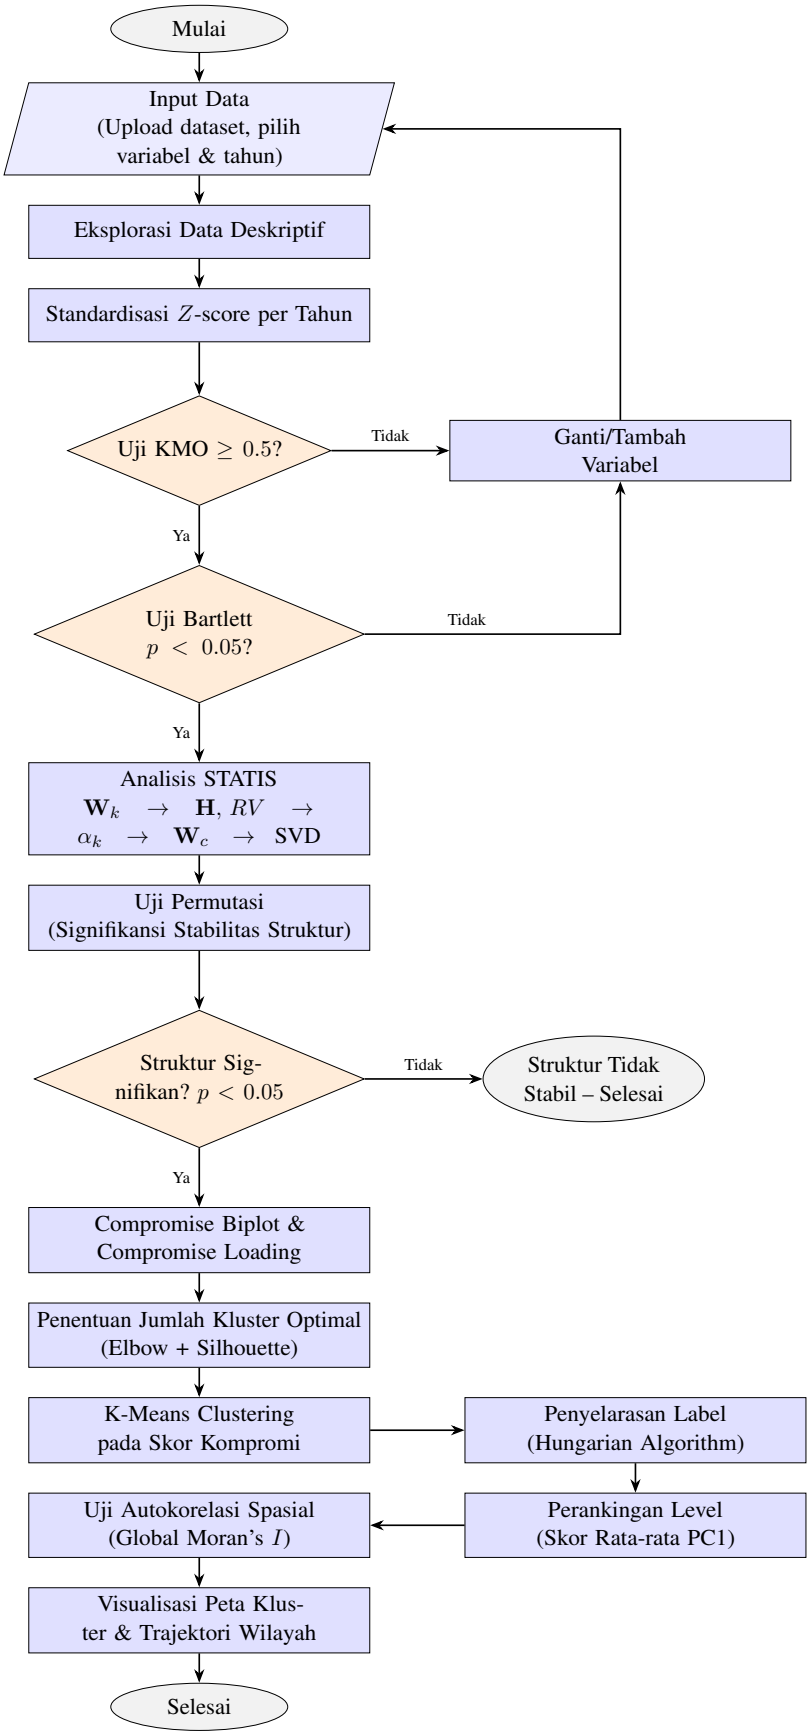
3.2 Jenis Penelitian

Penelitian ini menggunakan pendekatan **kuantitatif** dengan jenis penelitian **dekriptif-eksplanatori**. Secara khusus, penelitian ini memanfaatkan teknik analisis multivariat

lanjut (analisis tiga-arah) untuk mengeksplorasi struktur data panel indikator pembangunan manusia di Provinsi Banten, DKI Jakarta, dan Jawa Barat. Pendekatan ini dipilih karena data yang diolah berupa angka-angka statistik yang diperoleh secara sekunder dan akan dianalisis secara objektif menggunakan algoritma *STATIS*, *K-Means clustering*, dan analisis autokorelasi spasial untuk menarik kesimpulan mengenai stabilitas dan dinamika wilayah.

3.3 Desain Penelitian

Desain penelitian ini dirancang secara sistematis untuk menjawab tantangan data spasio-temporal. Tahapan penelitian dimulai dari input data, pra-pemrosesan, hingga pembentukan hasil akhir berupa visualisasi interaktif. Rancangan jalannya penelitian secara sistematis ditunjukkan pada Gambar 3.1 berikut.



Gambar 3.1: *Flowchart* Alur Metodologi Penelitian

3.4 Populasi dan Sampel

Populasi dalam penelitian ini adalah seluruh wilayah administratif setingkat kabupaten dan kota di Pulau Jawa. Namun, mengingat ketersediaan data dan fokus analisis pada wilayah metropolitan yang terintegrasi, sampel yang digunakan adalah:

1. **Unit Observasi (n):** 41 wilayah yang terdiri dari seluruh kabupaten/kota di Provinsi Banten, DKI Jakarta, dan Jawa Barat.
2. **Jumlah Situasi (K):** 5 tahun pengamatan (2020 hingga 2024).
3. **Teknik Pengambilan Sampel:** Menggunakan *purposive sampling*, di mana wilayah dipilih berdasarkan kriteria kelengkapan data indikator pembangunan manusia yang dipublikasikan secara konsisten oleh BPS selama periode penelitian.

3.5 Teknik Pengumpulan Data

Data dalam penelitian ini merupakan data sekunder yang dikumpulkan melalui studi dokumentasi pada publikasi resmi Badan Pusat Statistik (BPS).

1. **Sumber Data:** Website resmi BPS Pusat dan BPS Provinsi yang diperoleh melalui portal Open Data atau publikasi *Provinsi Dalam Angka*. Data untuk Provinsi Banten, DKI Jakarta, dan Jawa Barat periode 2020 hingga 2024 diperoleh dari publikasi resmi BPS masing-masing provinsi (Badan Pusat Statistik Provinsi Banten, 2020, 2021, 2022, 2023, 2024; Badan Pusat Statistik Provinsi DKI Jakarta, 2020, 2021, 2022, 2023, 2024; Badan Pusat Statistik Provinsi Jawa Barat, 2020, 2021, 2022, 2023, 2024).
2. **Metode Pengumpulan Data:** Pengumpulan data dilakukan dengan mengunduh berkas metadata dan tabel statistik dalam format *spreadsheet* (.xlsx dan .csv).
3. **Variabel Penelitian:** Variabel penelitian yang dikumpulkan terdiri dari 11 variabel sebagai berikut:
    - **IPG:** Indeks Pembangunan Gender (0 hingga 100).
    - **PPM:** Persentase Penduduk Miskin (%).
    - **PDRB_ADHK:** Produk Domestik Regional Bruto Atas Dasar Harga Konstan tahun 2010 (Juta Rupiah).
    - **RLS:** Rata-rata Lama Sekolah (Tahun).

- **AHH L:** Angka Harapan Hidup Laki-laki (Tahun).
- **AHH P:** Angka Harapan Hidup Perempuan (Tahun).
- **GK:** Garis Kemiskinan (Rupiah/Kapita/Bulan).
- **PKKP:** Prevalensi Ketidakcukupan Konsumsi Pangan ($\%$).
- **TPT:** Tingkat Pengangguran Terbuka ($\%$).
- **TPAK:** Tingkat Partisipasi Angkatan Kerja ($\%$).
- **GR:** Gini Ratio (0 hingga 1).

Selain itu, dikumpulkan pula data tambahan berikut yang tidak dimasukkan sebagai input analisis STATIS dan Dynamic Biplot:

- **IPM:** Indeks Pembangunan Manusia (0 hingga 100), khusus untuk pembanding eksternal (*benchmark*) untuk mengevaluasi posisi klaster tersebut terhadap standar UNDP (*United Nations Development Programme*). Hal ini dilakukan agar klaster yang terbentuk murni merepresentasikan kemiripan struktur dari 11 variabel yang telah dijelaskan sebelumnya.
- **JP (Jumlah Penduduk):** Banyaknya jiwa per wilayah (Orang), khusus untuk pembentukan bobot demografis (m_i) sesuai dengan Persamaan 2.3 dan Persamaan 2.4.

3.6 Validasi Instrumen

Karena data yang digunakan berasal dari lembaga resmi negara (BPS) yang telah memiliki protokol sensus dan survei (seperti Susenas dan Sakernas) yang terstandardisasi, validitas dan reliabilitas instrumen pengumpulan data primer dianggap sudah terpenuhi. Namun, pada tahap penelitian ini dilakukan **validasi data sekunder** melalui:

1. **Penyelarasan Metadata:** Memastikan definisi operasional variabel tetap konsisten di seluruh provinsi dan tahun pengamatan.
2. **Pembersihan Data (*Data Cleaning*):** Melakukan pemeriksaan terhadap anomali atau nilai yang hilang (*missing values*). Wilayah atau variabel yang memiliki data tidak lengkap dikeluarkan untuk menjaga integritas matriks tiga-arah.
3. **Standardisasi Z-score Terbobot:** Mengingat indikator yang digunakan memiliki satuan yang beragam (persen, rupiah, tahun), dilakukan transformasi Z-score terbobot agar setiap variabel dapat diperbandingkan secara adil dan dalam ruang metrik

$\mathbf{D}$ yang konsisten. Prosedur ini mengikuti Persamaan 2.5 yang mengggunakan rata-rata populasi terbobot μ_{jk} (Persamaan 2.3) dan simpangan baku populasi terbobot σ_{jk} (Persamaan 2.4) yang diterapkan pada setiap tabel situasi k, sehingga setiap variabel pada setiap tahun memiliki rata-rata terbobot nol dan varians terbobot satu.

Untuk memastikan data layak dianalisis secara multivariat, dilakukan serangkaian pengujian kecukupan sampling dan korelasi pada setiap periode pengamatan:

1. **Indeks Kaiser-Meyer-Olkin (KMO):** Pengujian ini dilakukan untuk menilai kecukupan sampel (*sampling adequacy*) dari 11 variabel yang digunakan untuk mengukur kesejahteraan rakyat. Perhitungan KMO merujuk pada rasio korelasi sederhana dan korelasi parsial sesuai Persamaan 2.15. Dalam penelitian ini, nilai KMO di atas 0,50 menjadi syarat mutlak agar himpunan variabel tersebut dianggap memiliki informasi bersama yang cukup untuk diringkas melalui analisis dimensi tiga-arah.

2. **Uji Bartlett's Test of Sphericity:** Uji ini digunakan untuk memverifikasi adanya struktur korelasi yang signifikan antar variabel (menguji hipotesis bahwa matriks korelasi bukan matriks identitas). Statistik uji χ^2 dihitung berdasarkan determinan matriks korelasi sebagaimana didefinisikan pada Persamaan 2.17. Jika p-value $< 0,05$, maka indikator-indikator tersebut dikonfirmasi memiliki hubungan interdependensi yang kuat, sehingga valid untuk diproses lebih lanjut menggunakan metode STATIS guna mengekstraksi struktur kompromi lintas waktu.

3.7 Teknik Analisis Data

Teknik analisis data mengacu pada algoritma STATIS (*Structuration des Tableaux à Trois Indices de la Statistique*) untuk mengelola kompleksitas data tiga-arah serta analisis autokorelasi spasial. Agar tidak terjadi kerancuan persepsi, penelitian ini membedakan dua konsep "tiga-arah" yang saling berkaitan:

- **Struktur Data Tiga-Arah (*Input Cube*):** Merupakan struktur data mentah yang dianalisis, yang terdiri dari 41 Kabupaten/Kota sebagai objek (n), 11 Indikator Kesejahteraan Rakyat sebagai variabel (p), dan 5 tahun pengamatan sebagai situasi waktu (K). Seluruh pengujian awal (KMO dan Bartlett) dilakukan pada dimensi variabel (p) ini.

- **Visualisasi Dinamis (*Output Trajectory*):** Merupakan hasil reduksi dimensi oleh STATIS, di mana 11 variabel tersebut diringkas menjadi 2 Komponen Utama (PC1 dan PC2), sementara dimensi situasi (K) direpresentasikan melalui pergerakan atau lintasan wilayah di dalam ruang PC1 dan PC2 tersebut.

3.7.1 Ilustrasi Pelaksanaan Prosedur Komputasi STATIS

Untuk memberikan gambaran yang transparan mengenai mekanisme kerja sistem, bagian ini menyajikan ilustrasi perhitungan manual (*step-by-step*) menggunakan dataset sampel yang terdiri dari 4 wilayah ($n = 4$) selama 3 tahun ($K = 3$) dengan 3 variabel utama ($p = 3$): Persentase Penduduk Miskin (PPM), Rata-rata Lama Sekolah (RLS), dan Tingkat Pengangguran Terbuka (TPT). Wilayah sampel yang digunakan adalah: (1) Kota Jakarta Pusat, (2) Kabupaten Bandung Barat, (3) Kota Tasikmalaya, dan (4) Kota Cilegon.

3.7.1.1 Tahap 0: Pra-pemrosesan dan Bobot Demografis

Analisis diawali dengan ringkasan statistik untuk periode 2020 hingga 2022 (Tabel 3.1, Tabel 3.2, dan Tabel 3.3) yang menyertakan data Jumlah Penduduk (JP) sebagai variabel tambahan:

Tabel 3.1: Statistika Deskriptif Tahun 2020

Variabel	N	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV
RLS	4	9.6925	1.3252	8.1900	9.0450	9.6000	10.2475	11.3800	0.2269	-1.0941	13.6700
PPM	4	7.9150	4.5324	3.6900	4.3050	7.5000	11.1100	12.9700	0.1296	-1.7889	57.2600
JP	4	888297.44	740780.23	433.76	535360.94	885283.00	1238219.50	1782190.00	0.0131	-1.1379	83.3900
TPT	4	10.9750	2.1195	7.9900	10.2250	11.6100	12.3600	12.6900	-0.7875	-1.0029	19.3100
IPM	4	73.8725	5.5244	68.0800	71.7475	73.0100	75.1350	81.3900	0.5232	-0.9383	7.4800

Tabel 3.2: Statistika Deskriptif Tahun 2021

Variabel	N	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV
RLS	4	9.7975	1.3222	8.2000	9.1900	9.8000	10.4075	11.3900	-0.0062	-1.1160	13.5000
PPM	4	8.4025	4.4744	4.2400	4.7650	8.1200	11.7575	13.1300	0.0703	-1.8757	53.2500
JP	4	897356.12	750665.68	439.48	542434.87	890282.50	1245203.75	1808420.00	0.0305	-1.1276	83.6500
TPT	4	9.2975	1.9411	7.6600	7.7275	8.9400	10.5100	11.6500	0.2894	-1.6215	20.8800
IPM	4	74.1475	5.6041	68.3000	71.9750	73.2500	75.4225	81.7900	0.5357	-0.9353	7.5600

Tabel 3.3: Statistika Deskriptif Tahun 2022

Variabel	N	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV
RLS	4	9.9050	1.3916	8.2200	9.2025	9.9350	10.6375	11.5300	-0.0662	-1.2117	14.0500
PPM	4	8.0200	4.4290	3.6400	4.5850	7.8600	11.2950	12.7200	0.0504	-1.8309	55.2200
JP	4	905159.27	760153.05	445.06	549471.27	892981.00	1248669.00	1834230.00	0.0522	-1.1146	83.9800
TPT	4	7.5575	1.6616	5.8800	6.4350	7.3600	8.4825	9.6300	0.2951	-1.4124	21.9900
IPM	4	74.7375	5.4331	69.0400	72.6325	73.8900	75.9950	82.1300	0.5227	-0.9386	7.2700

Data awal atau matriks data mentah $\mathbf{X}_k$ untuk setiap situasi tahun $k = 1, 2, 3$ adalah:

$$\mathbf{X}_{2020} = \begin{pmatrix} 4,51 & 11,38 & 10,97 \\ 10,49 & 8,19 & 12,25 \\ 12,97 & 9,33 & 7,99 \\ 3,69 & 9,87 & 12,69 \end{pmatrix}$$

$$\mathbf{X}_{2021} = \begin{pmatrix} 4,94 & 11,39 & 7,75 \\ 11,30 & 8,20 & 11,65 \\ 13,13 & 9,52 & 7,66 \\ 4,24 & 10,08 & 10,13 \end{pmatrix}$$

$$\mathbf{X}_{2022} = \begin{pmatrix} 4,90 & 11,53 & 5,88 \\ 10,82 & 8,22 & 9,63 \\ 12,72 & 9,53 & 6,62 \\ 3,64 & 10,34 & 8,10 \end{pmatrix}$$

Penghitungan bobot demografis m_i untuk setiap wilayah berdasarkan data jumlah penduduk rata-rata lintas situasi tahun (2020 hingga 2022) dari dataset sampel dihitung satu per satu:

$$m_1 = \frac{\overline{JP}_1}{\sum_{i=1}^{4} \overline{JP}_i} = \frac{1.055.947,67}{3.587.750,43} = 0{,}294320$$

$$m_2 = \frac{\overline{JP}_2}{\sum_{i=1}^{4} \overline{JP}_i} = \frac{1.808.280,00}{3.587.750,43} = 0{,}504015$$

$$m_3 = \frac{\overline{JP}_3}{\sum_{i=1}^{4} \overline{JP}_i} = \frac{723.083,33}{3.587.750,43} = 0{,}201542$$

$$m_4 = \frac{\overline{JP}_4}{\sum_{i=1}^{4} \overline{JP}_i} = \frac{439,43}{3.587.750,43} = 0{,}000122$$

Verifikasi total bobot: $m_1+m_2+m_3+m_4 = 0{,}294320+0{,}504015+0{,}201542+0{,}000122 = 0{,}999999 \approx 1{,}000000$.

Matriks metrik diagonal $\mathbf{D}$ yang dihasilkan adalah:

$$\mathbf{D} = \text{diag}(0{,}294320,\ 0{,}504015,\ 0{,}201542,\ 0{,}000122)$$

3.7.1.2 Tahap 1: Standardisasi Data ($\mathbf{Z}_k$)

Proses standardisasi menggunakan data mentah $\mathbf{X}_{2020}[:, 1] = (4{,}51;\ 10{,}49;\ 12{,}97;\ 3{,}69)^T$.

1. **Rata-rata terbobot μ_{jk}:**

   Nilai rata-rata terbobot untuk indikator pertama pada tahun 2020 dihitung menggu-

nakan Persamaan 2.3 dengan menyertakan presisi penuh sebagai berikut:

$$\begin{aligned}\mu_{1,2020} &= \sum_{i=1}^{4} m_i \cdot x_{i,1,2020} \\ &= 0{,}294320(4{,}51) + 0{,}504015(10{,}49) + 0{,}201542(12{,}97) + 0{,}000122(3{,}69) \\ &= 1{,}327383 + 5{,}287117 + 2{,}613999 + 0{,}000450 = 9{,}228957\end{aligned}$$

2. **Simpangan baku terbobot σ_{jk}:**

Nilai simpangan baku terbobot untuk indikator pertama pada tahun 2020 dihitung menggunakan Persamaan 2.4 sebagai berikut:

$$\begin{aligned}\sigma_{1,2020} &= \sqrt{\sum_{i=1}^{4} m_i (x_{i,1,2020} - \mu_{1,2020})^2} \\ &= \Big(0{,}294320(4{,}51 - 9{,}228957)^2 + 0{,}504015(10{,}49 - 9{,}228957)^2 \\ &\quad + 0{,}201542(12{,}97 - 9{,}228957)^2 + 0{,}000122(3{,}69 - 9{,}228957)^2\Big)^{1/2} \\ &= \Big(0{,}294320(-4{,}718957)^2 + 0{,}504015(1{,}261043)^2 \\ &\quad + 0{,}201542(3{,}741043)^2 + 0{,}000122(-5{,}538957)^2\Big)^{1/2} \\ &= \Big(0{,}294320(22{,}268555) + 0{,}504015(1{,}590229) \\ &\quad + 0{,}201542(13{,}995402) + 0{,}000122(30{,}680045)\Big)^{1/2} \\ &= \sqrt{6{,}553881 + 0{,}801500 + 2{,}820653 + 0{,}003743} \\ &= \sqrt{10{,}179777} = 3{,}190576\end{aligned}$$

3. **Z-score terbobot z_{ijk}:**

Nilai Z-score terbobot masing-masing wilayah untuk indikator pertama pada tahun 2020 dihitung menggunakan Persamaan 2.5 sebagai berikut:

$$\begin{aligned}z_{1,1,2020} &= \frac{4{,}51 - 9{,}228957}{3{,}190576} = \frac{-4{,}718957}{3{,}190576} = -1{,}479024 \approx -1{,}48 \\ z_{2,1,2020} &= \frac{10{,}49 - 9{,}228957}{3{,}190576} = \frac{1{,}261043}{3{,}190576} = 0{,}395237 \approx 0{,}40 \\ z_{3,1,2020} &= \frac{12{,}97 - 9{,}228957}{3{,}190576} = \frac{3{,}741043}{3{,}190576} = 1{,}172529 \approx 1{,}17 \\ z_{4,1,2020} &= \frac{3{,}69 - 9{,}228957}{3{,}190576} = \frac{-5{,}538957}{3{,}190576} = -1{,}736036 \approx -1{,}74\end{aligned}$$

Prosedur di atas diulang untuk setiap variabel dan tahun, menghasilkan matriks terstandardisasi:

$$\mathbf{Z}_{2020} = \begin{pmatrix} -1,48 & 1,47 & -0,03 \\ 0,40 & -0,85 & 0,76 \\ 1,17 & -0,02 & -1,87 \\ -1,74 & 0,37 & 1,04 \end{pmatrix}$$

$$\mathbf{Z}_{2021} = \begin{pmatrix} -1,51 & 1,44 & -0,99 \\ 0,47 & -0,88 & 0,99 \\ 1,04 & 0,08 & -1,04 \\ -1,73 & 0,49 & 0,22 \end{pmatrix}$$

$$\mathbf{Z}_{2022} = \begin{pmatrix} -1,50 & 1,45 & -1,17 \\ 0,45 & -0,87 & 0,98 \\ 1,07 & 0,05 & -0,75 \\ -1,92 & 0,62 & 0,10 \end{pmatrix}$$

3.7.1.3 Tahap 2: Matriks Intra-struktur ($\mathbf{W}_k$)

Dari matriks terstandardisasi $\mathbf{Z}_k$, dibentuk matriks intra-struktur $\mathbf{W}_k = \mathbf{Z}_k\mathbf{Z}_k^T$. Sebagai contoh untuk tahun 2020:

$$\begin{aligned} \mathbf{W}_{2020}[1,1] &= \sum_{j=1}^{3} z_{1,j,2020}^2 \\ &= (-1{,}479024)^2 + (1{,}468201)^2 + (-0{,}028514)^2 \\ &= 2{,}187512 + 2{,}155614 + 0{,}000813 \\ &= 4{,}343939 \end{aligned}$$

$$\begin{aligned} \mathbf{W}_{2020}[1,2] &= \sum_{j=1}^{3} z_{1,j,2020} \cdot z_{2,j,2020} \\ &= (-1{,}479024 \times 0{,}395237) + (1{,}468201 \times -0{,}848123) + (-0{,}028514 \times 0{,}759124) \\ &= -0{,}584564 - 1{,}245215 - 0{,}021646 = -1{,}851425 \end{aligned}$$

Matriks korelasi terbobot antar-indikator $\mathbf{S}_k = \mathbf{Z}_k^T\mathbf{D}\mathbf{Z}_k$ disajikan pada Tabel 3.4, Tabel 3.5, dan Tabel 3.6.

Tabel 3.4: Matriks Korelasi Terbobot Variabel Tahun 2020 ($\mathbf{S}_{2020}$)

Variabel	PPM	RLS	TPT
PPM	1.0000	-0.8141	-0.2781
RLS	-0.8141	1.0000	-0.3313
TPT	-0.2781	-0.3313	1.0000

Tabel 3.5: Matriks Korelasi Terbobot Variabel Tahun 2021 ($\mathbf{S}_{2021}$)

Variabel	PPM	RLS	TPT
PPM	1.0000	-0.8307	0.4576
RLS	-0.8307	1.0000	-0.8751
TPT	0.4576	-0.8751	1.0000

Tabel 3.6: Matriks Korelasi Terbobot Variabel Tahun 2022 ($\mathbf{S}_{2022}$)

Variabel	PPM	RLS	TPT
PPM	1.0000	-0.8277	0.5779
RLS	-0.8277	1.0000	-0.9363
TPT	0.5779	-0.9363	1.0000

3.7.1.4 Tahap 3: Analisis Inter-struktur (Koefisien RV)

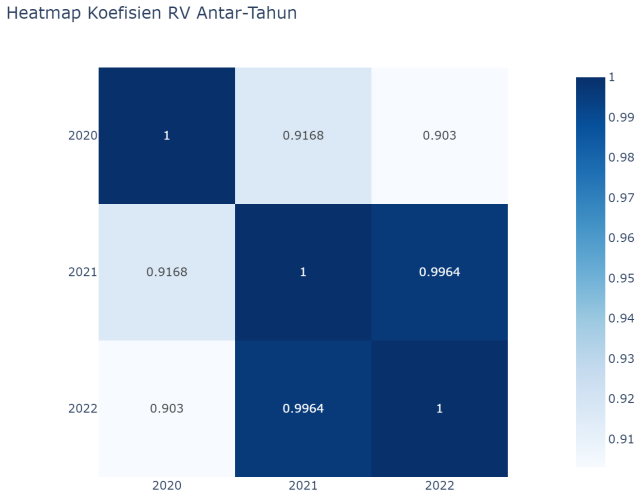
Kemiripan struktural diukur menggunakan koefisien RV:

$$\begin{aligned} RV(\mathbf{W}_{2020}, \mathbf{W}_{2021}) &= \frac{\operatorname{tr}(\mathbf{W}_{2020}\mathbf{W}_{2021})}{\sqrt{\operatorname{tr}(\mathbf{W}_{2020}^2)\operatorname{tr}(\mathbf{W}_{2021}^2)}} \\ &= \frac{H_{1,2}}{\sqrt{H_{1,1} \cdot H_{2,2}}} = \frac{37{,}088194}{\sqrt{43{,}468012 \times 39{,}367215}} \\ &= \frac{37{,}088194}{41{,}367214} = 0{,}896560 \approx 0{,}896560 \end{aligned}$$

Matriks RV lengkap ditampilkan pada Tabel 3.7.

Tabel 3.7: Matriks Koefisien RV Antar-Tahun

Tahun	2020	2021	2022
2020	1.0000	0.9168	0.9030
2021	0.9168	1.0000	0.9964
2022	0.9030	0.9964	1.0000



Gambar 3.2: Visualisasi Heatmap Matriks RV Data Sampel

3.7.1.5 Tahap 4: Bobot Kompromi (α_k)

Dekomposisi spektral $\mathbf{Hu} = \theta\mathbf{u}$ menghasilkan vektor eigen pertama $\mathbf{u}_1 = [0{,}567711;\ 0{,}565612;\ 0{,}598124]^T$. Normalisasi bobot:

$$\alpha_{2020} = \frac{0{,}567711}{0{,}567711 + 0{,}565612 + 0{,}598124} = \frac{0{,}567711}{1{,}731447} = 0{,}327882$$

$$\alpha_{2021} = \frac{0{,}565612}{0{,}567711 + 0{,}565612 + 0{,}598124} = \frac{0{,}565612}{1{,}731447} = 0{,}326670$$

$$\alpha_{2022} = \frac{0{,}598124}{0{,}567711 + 0{,}565612 + 0{,}598124} = \frac{0{,}598124}{1{,}731447} = 0{,}345448$$

Hasil normalisasi tersaji dalam Tabel 3.8.

Tabel 3.8: Nilai Bobot (Alpha) Tiap Tahun

Tahun (k)	**Bobot** (α)
2020	0.2881
2021	0.3503
2022	0.3616

3.7.1.6 Tahap 5: Sintesis Matriks Kompromi ($\mathbf{W}_c$)

Matriks kompromi disintesis melalui kombinasi linear tertimbang:

$$\mathbf{W}_c = 0{,}327882\,\mathbf{W}_{2020} + 0{,}326670\,\mathbf{W}_{2021} + 0{,}345448\,\mathbf{W}_{2022}$$

$$= 0{,}327882 \begin{bmatrix} 1{,}278508 & -0{,}713075 & -0{,}419231 & 0{,}121234 \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix} + \cdots = \begin{pmatrix} -2{,}248922 & -0{,}371122 \\ 1{,}268112 & -0{,}452231 \\ 0{,}118122 & 1{,}661021 \\ -1{,}221132 & -1{,}481122 \end{pmatrix}$$

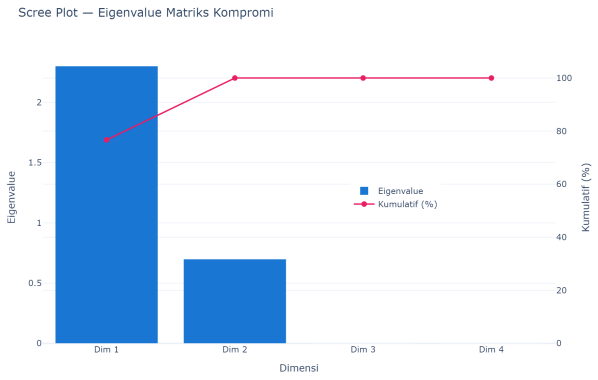
Dekomposisi spektral $\mathbf{W}_c = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^T$ menghasilkan nilai eigen pada Tabel 3.9. Keandalan dari model rank-1 divalidasi melalui diagnostik dominansi model rank-1 pada Tabel 3.10.

Tabel 3.9: Dekomposisi Nilai Eigen Matriks Kompromi

Dimensi	**Eigenvalue** (λ)	**Akar Ciri** ($\sqrt{\lambda}$)	**Varians (%)**	**Kumulatif (%)**
Dim 1	2.3008	1.5168	76.6900	76.6900
Dim 2	0.6992	0.8362	23.3100	100.0000
Dim 3	0.0000	0.0044	0.0000	100.0000
Dim 4	0.0000	0.0000	0.0000	100.0000

Tabel 3.10: Diagnostik Dominansi Model Rank-1 (Areia et al., 2008)

Kuantitas	**Nilai**
λ_1 (Nilai Eigen Dominan)	17.1859
$\|\mathbf{H}\|_F^2$ (Frobenius^2)	295.7348
V (SS Residual)	0.3803
$V/\|\mathbf{H}\|_F^2$ (Rasio Sisa)	0.0013
Inertia$_1$ (Dominansi %)	96.43%
λ_1/λ_2 (Rasio Kegentingan)	27.8833



Gambar 3.3: Scree Plot Analisis Kompromi Data Sampel

3.7.1.7 Tahap 6: Skor dan Loading Kompromi

Koordinat wilayah $\mathbf{F}_c = \mathbf{D}^{-1/2}\mathbf{P}\mathbf{\Lambda}^{1/2}$ dihitung sebagai berikut:

$$f_{1,1} = \frac{1}{\sqrt{m_1}} \cdot p_{1,1} \cdot \sqrt{\lambda_1}$$
$$= \frac{1}{\sqrt{0{,}294320}} \times (-0{,}651231) \times \sqrt{2{,}301222} = 1{,}843181 \times (-0{,}651231) \times 1{,}516978 = -1{,}820872 \approx$$

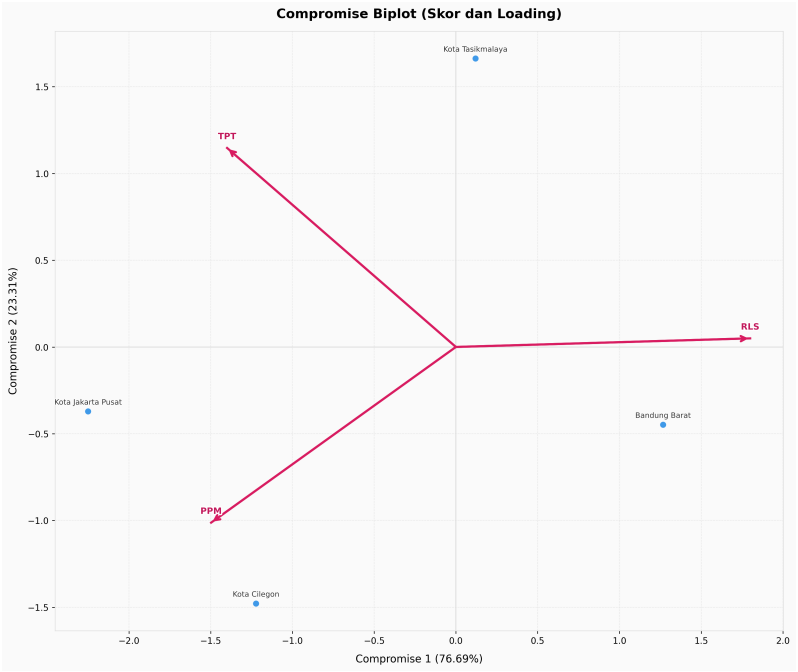
Hasil lengkap skor dan loading disajikan pada tabel berikut.

Tabel 3.11: Koordinat Skor Kompromi (Fc)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
Kota Jakarta Pusat	-2.2496	-0.3712	-2.2496	-0.3712
Bandung Barat	1.2664	-0.4478	1.2664	-0.4478
Kota Tasikmalaya	0.1188	1.6629	0.1188	1.6629
Kota Cilegon	-1.2227	-1.4783	-1.2227	-1.4783

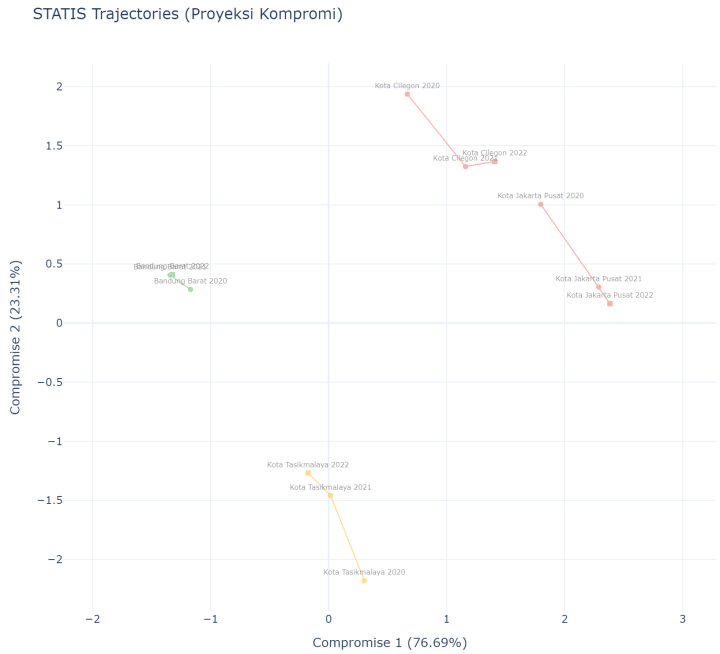
Tabel 3.12: Loadings Kompromi (Korelasi Variabel vs Skor)

Variabel	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
PPM	-0.8255	-0.5585	-1.4970	-1.0127
RLS	0.9925	0.0273	1.7997	0.0495
TPT	-0.7716	0.6325	-1.3992	1.1470



Gambar 3.4: Compromise Biplot (Skor dan Loading) Data Sampel

Lintasan pergerakan wilayah dari 2020 hingga 2022 (Persamaan 2.48: $\mathbf{F}_k = \mathbf{Z}_k\mathbf{V}_c$) divisualisasikan melalui trajektori pada Gambar 3.5.



Gambar 3.5: Visualisasi Trajektori Spasio-Temporal Data Sampel

3.7.1.8 Tahap 7: Uji Signifikansi dan Clustering

Signifikansi divalidasi dengan uji permutasi Monte Carlo. Langkah terakhir adalah pemetaan wilayah ke dalam klaster menggunakan K-Means.

Tabel 3.13: Anggota Klaster Trajektori Keseluruhan

Kabupaten/Kota	Klaster Trajektori
Kota Jakarta Pusat	1
Bandung Barat	3
Kota Tasikmalaya	2
Kota Cilegon	1

Stabilitas pengelompokan lintas tahun dipantau melalui matriks transisi temporal (Tabel 3.14 dan Tabel 3.15).

Tabel 3.14: Matriks Transisi Klaster 2020 → 2021

2020 2021	**Klaster 1 (2021)**	**Klaster 2 (2021)**	**Klaster 3 (2021)**
Klaster 1 (2020)	1	0	0
Klaster 2 (2020)	0	1	0
Klaster 3 (2020)	0	0	2

Tabel 3.15: Matriks Transisi Klaster 2021 → 2022

2021 2022	**Klaster 1 (2022)**	**Klaster 2 (2022)**	**Klaster 3 (2022)**
Klaster 1 (2021)	1	0	0
Klaster 2 (2021)	0	1	0
Klaster 3 (2021)	0	0	2

3.7.1.9 Tahap 8: Perbandingan Klaster Biplot vs STATIS

Untuk mengilustrasikan keunggulan STATIS yang mengakomodasi informasi temporal, kita dapat membandingkan klaster yang terbentuk dari matriks koordinat STATIS $\mathbf{F}_k$ dengan klaster yang dibentuk secara murni dari Principal Component Analysis (PCA) pada tahun individu (Biplot Unweighted).

Dalam PCA standar, koordinat objek pada tahun k (misalnya tahun 2020) dihitung semata-mata dengan memproyeksikan data yang distandardisasi ($\mathbf{Z}_{2020}$) ke matriks vektor eigen $\mathbf{V}_{2020}$ hasil dekomposisi matriks kovariansi pada tahun tersebut, yang dirumuskan sebagai:

$$\mathbf{F}_{\text{PCA},2020} = \mathbf{Z}_{2020}\mathbf{V}_{2020} \tag{3.1}$$

Berbeda halnya dengan metode STATIS, di mana proyeksi data pada tahun 2020 ($\mathbf{Z}_{2020}$) dilakukan terhadap vektor kompromi lintas tahun $\mathbf{V}_c$ sebagaimana dirumuskan pada Persamaan 2.48:

$$\mathbf{F}_{\text{STATIS},2020} = \mathbf{Z}_{2020}\mathbf{V}_c \tag{3.2}$$

Perbedaan proyeksi ini menyebabkan titik koordinat masing-masing wilayah berada pada posisi yang berbeda, sehingga saat algoritma K-Means ($k = 3$) diterapkan, susunan keanggotaan klaster dapat berubah. Matriks tabulasi silang berikut membandingkan keanggotaan klaster dari PCA murni berhadapan dengan STATIS untuk tahun 2020 pada data sampel.

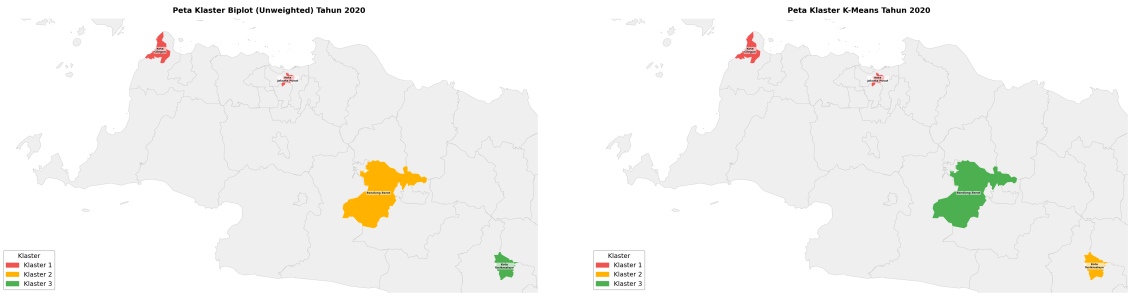
Tabel 3.16: Matriks Perbandingan Cluster Biplot vs STATIS (2020)

Biplot (Unweighted)	Statis 1 (2020)	Statis 2 (2020)	Statis 3 (2020)
Biplot 1 (2020)	0	0	2
Biplot 2 (2020)	1	0	0
Biplot 3 (2020)	0	1	0

Tabel 3.17: Nama Daerah Perbandingan Cluster Biplot vs STATIS (2020)

Kategori	Daftar Wilayah
Biplot 1 & Statis 1	-
Biplot 1 & Statis 2	-
Biplot 1 & Statis 3	Kota Jakarta Pusat, Kota Cilegon
Biplot 2 & Statis 1	Bandung Barat
Biplot 2 & Statis 2	-
Biplot 2 & Statis 3	-
Biplot 3 & Statis 1	-
Biplot 3 & Statis 2	Kota Tasikmalaya
Biplot 3 & Statis 3	-

Gambar 3.6 memvisualisasikan perbedaan hasil pengelompokan tersebut secara spasial.



Peta Klaster Biplot (Unweighted) Peta Klaster STATIS

Gambar 3.6: Perbandingan Spasial Klaster Biplot vs STATIS Data Sampel (2020)

3.7.1.10 Tahap 9: Tabulasi Silang K-Means vs IPM UNDP

Sebagai bentuk validasi eksternal, hasil klasterisasi K-Means yang bersifat obyektif (*data-driven*) dihadapkan dengan klasifikasi normatif IPM dari UNDP (Sangat Tinggi, Tinggi, Sedang, Rendah). Karena IPM merupakan indeks agregat yang telah mapan, tabulasi silang ini bertujuan memastikan bahwa klaster yang terbentuk sejalan dengan level pembangunan aktual.

Tabel 3.18: Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2020)

Klaster K-Means	Sangat Tinggi	Tinggi	Sedang	Rendah
Klaster 1	0	0	1	0
Klaster 2	0	1	0	0
Klaster 3	1	1	0	0

Tabel 3.19: Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2020)

Kategori	Daftar Wilayah
Kl.1 & Sangat Tinggi	-
Kl.1 & Tinggi	-
Kl.1 & Sedang	Bandung Barat
Kl.1 & Rendah	-
Kl.2 & Sangat Tinggi	-
Kl.2 & Tinggi	Kota Tasikmalaya
Kl.2 & Sedang	-
Kl.2 & Rendah	-
Kl.3 & Sangat Tinggi	Kota Jakarta Pusat
Kl.3 & Tinggi	Kota Cilegon
Kl.3 & Sedang	-
Kl.3 & Rendah	-

3.7.2 Penyelarasan Label Klaster Lintas Waktu

Untuk menjamin konsistensi identitas klaster antar periode waktu (mencegah *label switching*), diterapkan prosedur penyelarasan menggunakan *Hungarian Algorithm* (Kuhn, 1955). Prosedur ini bekerja dengan menghitung matriks biaya (*cost matrix*) berdasarkan jarak Euclidean antar centroid klaster pada tahun dasar (t) dan tahun tujuan ($t+1$) merujuk pada Persamaan 2.57. Solusi optimal pemetaan label diperoleh melalui minimalisasi total jarak sesuai fungsi objektif pada Persamaan 2.58. Langkah ini krusial untuk memastikan bahwa ”Klaster Rendah” pada tahun tertentu merujuk pada karakteristik yang sebanding dengan ”Klaster Rendah” pada tahun lainnya.

3.7.3 Kategorisasi dan Perankingan Klaster

Interpretasi sosio-ekonomi terhadap klaster dilakukan melalui perankingan otomatis menggunakan nilai rata-rata skor komponen utama pertama (PC1) pada masing-masing klaster. PC1 mewakili variansi utama dari 11 variabel tersebut sehingga berperan sebagai indeks performa umum (*general performance index*). Klaster dengan rata-rata PC1 terendah diberi label **Klaster 1 (Rendah)**, menengah sebagai **Klaster 2 (Sedang)**, dan tertinggi

sebagai **Klaster 3 (Tinggi)**.

Untuk mempermudah pemantauan visual, sistem visualisasi menetapkan skema warna tetap (*fixed color scheme*): Merah (*Red*) untuk Klaster 1, Jingga (*Yellow/Amber*) untuk Klaster 2, dan Hijau (*Green*) untuk Klaster 3. Hal ini menjamin konsistensi representasi visual di seluruh periode pengamatan (2020 hingga 2024), sehingga pembaca dapat langsung mengenali status wilayah berdasarkan warnanya tanpa fluktuasi visual antar-tahun.

3.7.4 Analisis Autokorelasi Spasial (Global Moran's I)

Sejalan dengan hasil pengelompokan pada skor kompromi, dilakukan pengujian untuk mendeteksi apakah terdapat ketergantungan spasial secara keseluruhan. Pengujian ini merujuk pada koefisien Global Moran's I sebagaimana didefinisikan pada Persamaan 2.61 di Bab 2.

Signifikansi statistik I kemudian dievaluasi menggunakan pendekatan parametrik (skor-Z) dengan bantuan nilai harapan $E(I)$ dan varians $Var(I)$ untuk menguji hipotesis keberadaan autokorelasi:

$$Z(I) = \frac{I - E(I)}{\sqrt{Var(I)}}, \quad E(I) = \frac{-1}{N-1} \tag{3.3}$$

BAB 4

HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil analisis data panel 41 kabupaten/kota di Provinsi Banten, DKI Jakarta, dan Jawa Barat periode 2020 hingga 2024 menggunakan metode STATIS (*Structuration des Tableaux à Trois Indices de la Statistique*). Analisis dimulai dari eksplorasi data awal dan uji kelayakan, dilanjutkan dengan analisis inter-struktur, pembentukan struktur kompromi, uji stabilitas, analisis trajektori spasio-temporal, hingga analisis klaster dan evaluasinya. Seluruh proses komputasi dilakukan menggunakan *dashboard* interaktif berbasis Python (Dash/Plotly).

Data sekunder yang dianalisis pada bab ini bersumber dari publikasi tahunan referensi statistik yang diterbitkan oleh Badan Pusat Statistik (BPS) dari masing-masing provinsi pada tahun 2020 hingga 2024. Secara rinci, data Provinsi Banten diamati dari publikasi rutin kelima tahunnya (Badan Pusat Statistik Provinsi Banten, 2020, 2021, 2022, 2023, 2024). Untuk Provinsi DKI Jakarta, data direkam dari dokumen "Provinsi DKI Jakarta Dalam Angka" (Badan Pusat Statistik Provinsi DKI Jakarta, 2020, 2021, 2022, 2023, 2024). Sementara itu, konstelasi data seluruh kabupaten/kota di provinsi Jawa Barat direferensikan dari publikasi yang ekuivalen dalam periode yang sama (Badan Pusat Statistik Provinsi Jawa Barat, 2020, 2021, 2022, 2023, 2024).

4.1 Eksplorasi Data Awal

4.1.1 Statistika Deskriptif

Langkah pertama sebelum menerapkan analisis multivariat adalah melakukan eksplorasi terhadap karakteristik distribusi masing-masing indikator pembangunan manusia. Tabel 4.1 hingga Tabel 4.5 menyajikan ringkasan statistika deskriptif, yang meliputi nilai rata-rata (*mean*), simpangan baku, nilai minimum, kuartil pertama (Q1), median, kuartil ketiga (Q3), nilai maksimum, kemiringan (*skewness*), kurtosis, dan koefisien variasi (CV%), untuk setiap variabel pada tiap tahun pengamatan.

Tabel 4.1: Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2020

Variabel	N	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV
GR	41	0.3592	0.0362	0.2850	0.3360	0.3520	0.3810	0.4270	0.0668	-0.7740	10.0700
JP	41	1432347.14	1243018.59	433.76	332580.00	1226050.00	2434090.00	5409370.00	0.7879	0.6833	86.7800
PKKP	41	3.3263	1.3218	1.2600	2.1800	3.6000	4.2800	5.6400	-0.0754	-1.2654	39.7400
PDRB_ADHK	41	90668.15	115779.62	3251.76	21970.41	38598.43	93480.39	449518.14	1.8010	2.1881	127.70
AHH_P	41	73.4278	2.4925	66.5000	72.8700	74.0200	75.4200	76.7100	-1.2048	1.1055	3.3900
IPG	41	89.9871	4.4168	79.0600	86.8100	90.9800	93.5300	96.1400	-0.6283	-0.2917	4.9100
AHH_L	41	69.6368	2.5761	62.6800	69.0300	70.2500	71.7200	73.2200	-1.1209	0.8502	3.7000
TPT	41	10.1232	2.1864	5.0800	8.9500	10.6800	11.5400	14.2900	-0.4590	-0.3509	21.6000
PPM	41	7.6356	3.1440	2.2900	4.9400	7.6200	9.9800	14.8700	0.2597	-0.7499	41.1800
TPAK	41	64.5890	3.8263	55.7400	61.9800	63.8100	66.5400	76.7900	0.7602	1.3035	5.9200
GK	41	470618.29	123776.23	310437.00	362212.00	457954.00	547415.00	782731.00	0.6325	-0.6175	26.3000
IPM	41	72.8971	5.7902	63.9100	68.0800	71.7000	77.8300	84.7200	0.4383	-0.9747	7.9400
RLS	41	8.9244	1.6521	6.3000	7.5200	8.6300	10.6300	11.8100	0.2849	-1.2277	18.5100

Tabel 4.2: Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2021

Variabel	N	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV
GR	41	0.3647	0.0535	0.2450	0.3400	0.3630	0.3880	0.5150	0.3782	1.0149	14.6800
JP	41	1447714.39	1257547.59	439.48	335810.00	1234830.00	2446687.00	5484150.00	0.7956	0.7128	86.8600
PKKP	41	3.8829	1.5390	1.5500	2.4600	3.8700	5.0000	7.1200	0.1816	-1.1459	39.6400
PDRB_ADHK	41	155753.21	399617.71	3365.25	23275.78	46840.15	106413.70	2538923.00	5.3713	29.4361	256.57
AHH_P	41	73.5822	2.4979	66.6100	73.0800	74.2100	75.5200	76.8900	-1.2313	1.1623	3.3900
IPG	41	90.0432	4.4084	79.0700	86.9700	90.8700	93.6000	96.2800	-0.6450	-0.2436	4.9000
AHH_L	41	69.8390	2.6025	62.8200	69.2700	70.5000	71.9400	73.4800	-1.1514	0.8882	3.7300
TPT	41	9.1959	2.0599	3.2500	8.2300	9.3200	10.5800	13.0700	-0.6333	0.4640	22.4000
PPM	41	8.1639	3.2327	2.5700	5.3500	7.9700	10.7100	15.0600	0.1144	-0.9312	39.6000
TPAK	41	64.4712	3.1615	56.8600	62.5500	64.0700	65.7900	74.7500	0.7324	1.5994	4.9000
GK	41	486788.61	125953.29	320050.00	378819.00	467248.00	570330.00	792684.00	0.5875	-0.7418	25.8700
IPM	41	73.1805	5.8237	64.0300	68.2900	72.1000	78.0600	84.9000	0.4213	-0.9879	7.9600
RLS	41	9.0273	1.6651	6.4100	7.5300	8.7700	10.7800	11.8200	0.2434	-1.3084	18.4400

Tabel 4.3: Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2022

Variabel	N	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV
GR	41	0.3658	0.0618	0.2110	0.3180	0.3670	0.3940	0.5430	0.3696	0.8754	16.8800
JP	41	1462414.00	1271595.59	445.06	338940.00	1243320.00	2458707.00	5556310.00	0.8032	0.7413	86.9500
PKKP	41	5.5502	2.4961	1.5000	3.4500	5.7700	7.4300	10.4500	0.0747	-1.1068	44.9700
PDRB_ADHK	41	156900.90	377811.63	3516.57	24495.02	49292.98	112778.10	2383665.00	5.1936	27.9588	240.80
AHH_P	41	73.8912	2.4709	67.0300	73.3700	74.5000	75.8100	77.1800	-1.2024	1.1051	3.3400
IPG	41	90.3415	4.3112	79.6900	87.1700	90.9700	93.8400	96.4800	-0.6361	-0.2386	4.7700
AHH_L	41	70.0607	2.5716	63.1700	69.5000	70.6900	72.1400	73.7000	-1.1122	0.8040	3.6700
TPT	41	7.8156	2.0233	1.5600	6.9800	8.1000	8.8300	10.7800	-0.9149	0.9909	25.8900
PPM	41	7.8027	3.0997	2.5000	5.0100	7.7200	10.1400	14.1100	0.1383	-0.9442	39.7300
TPAK	41	65.7398	3.3700	58.6700	63.7600	65.4100	67.3900	79.9200	1.6307	5.9805	5.1300
GK	41	512333.02	135320.99	335134.00	398884.00	485613.00	599514.00	842630.00	0.5993	-0.7304	26.4100
IPM	41	73.8166	5.7278	64.7100	69.0400	72.7900	78.7700	85.2100	0.4127	-0.9878	7.7600
RLS	41	9.1566	1.6423	6.5900	7.8300	8.9000	10.8200	11.8400	0.2314	-1.3538	17.9400

Tabel 4.4: Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2023

Variabel	N	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV
GR	41	0.3739	0.0552	0.2430	0.3420	0.3690	0.4280	0.4680	-0.2663	-0.4264	14.7600
JP	41	1476700.92	1285310.11	450.51	341980.00	1251540.00	2470054.00	5627020.00	0.8107	0.7696	87.0400
PKKP	41	4.6354	1.9005	1.5800	2.9100	5.0700	5.9800	8.6500	0.0616	-1.0247	41.0000
PDRB_ADHK	41	104051.93	132473.27	3305.13	25655.25	44087.22	108569.80	506560.70	1.7652	2.0079	127.31
AHH_P	41	74.3205	2.4367	67.5600	73.7800	74.9700	76.2000	77.4500	-1.2365	1.1126	3.2800
IPG	41	90.5937	4.2094	80.3700	87.3100	91.2900	94.0300	97.1600	-0.6001	-0.2853	4.6500
AHH_L	41	70.4171	2.5132	63.7000	69.7900	70.9300	72.5000	74.1000	-1.0287	0.7650	3.5700
TPT	41	7.2041	1.7690	1.5200	6.5200	7.3300	8.1100	10.5200	-0.9574	1.5426	24.5600
PPM	41	7.4420	2.8862	2.3800	4.8500	7.2700	9.5200	13.1300	0.0826	-0.9921	38.7800
TPAK	41	66.3559	3.6273	60.3300	63.9800	66.1600	67.9000	80.1500	1.3791	3.6110	5.4700
GK	41	553569.61	143549.03	367681.00	426355.00	520713.00	657247.00	891580.00	0.5879	-0.7939	25.9300
IPM	41	74.4183	5.6976	65.2100	69.6100	73.3900	79.4600	86.0700	0.4201	-0.9571	7.6600
RLS	41	9.2263	1.6469	6.6000	7.8900	8.9100	10.8400	11.8800	0.2655	-1.3451	17.8500

Tabel 4.5: Statistika Deskriptif Variabel Pembangunan Manusia Tahun 2024

Variabel	N	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV
GR	41	0.3667	0.0568	0.2450	0.3250	0.3670	0.4240	0.4770	-0.3164	-0.6547	15.4900
JP	41	1504586.38	1309156.50	455.62	344850.00	1259230.00	2528160.00	5682300.00	0.7875	0.6512	87.0100
PKKP	41	4.6907	1.4985	1.8900	3.5500	5.2200	5.7800	7.9800	-0.4708	-0.6142	31.9500
PDRB_ADHK	41	109134.55	139071.46	3268.50	26863.08	46270.92	113998.20	532606.90	1.7693	2.0301	127.43
AHH_P	41	74.5900	2.4500	67.7800	74.0400	75.2900	76.4200	77.7500	-1.2313	1.0489	3.2800
IPG	41	90.7871	4.1382	81.0200	87.5500	91.5500	94.2300	97.3000	-0.5647	-0.3873	4.5600
AHH_L	41	70.6402	2.5182	63.9000	70.0400	71.1000	72.7200	74.2900	-0.9979	0.7233	3.5600
TPT	41	6.5522	1.5219	1.5800	6.0800	6.4900	7.4000	9.1800	-0.9517	1.6482	23.2300
PPM	41	7.2541	2.8854	2.3400	4.6300	7.0500	9.4900	13.0300	0.1015	-1.0378	39.7800
TPAK	41	67.4144	3.6875	58.1300	65.5800	67.2200	69.1000	80.1200	0.6115	2.5208	5.4700
GK	41	583233.61	148452.42	393464.00	455636.00	547912.00	685071.00	928278.00	0.5936	-0.7922	25.4500
IPM	41	74.9951	5.6926	65.8600	70.0300	73.9900	80.0200	86.9400	0.4290	-0.9383	7.5900
RLS	41	9.2837	1.6734	6.6100	7.9000	8.9300	10.8500	11.9900	0.2552	-1.3503	18.0300

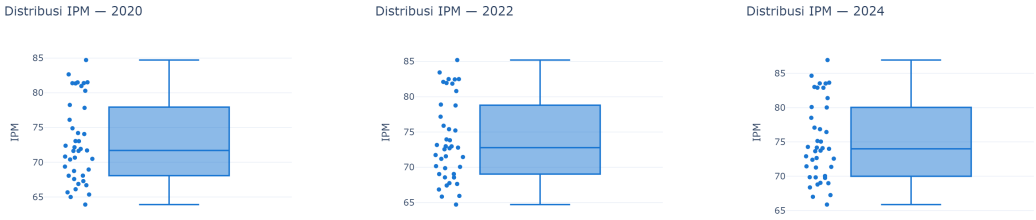
Berdasarkan kelima tabel di atas, beberapa pola umum dapat diidentifikasi. Pertama, variabel IPM memiliki nilai CV yang relatif rendah (di bawah 8%) di seluruh tahun, yang mengindikasikan bahwa tingkat pembangunan manusia antar-wilayah tidak terlalu bervariasi secara proporsional, meskipun terdapat disparitas absolut yang signifikan. Sebaliknya, variabel PDRB ADHK menunjukkan CV tertinggi (di atas 100%), mencerminkan kesenjangan kapasitas ekonomi yang sangat lebar antara wilayah berbasis industri di Jabodetabek dengan wilayah agraris di pedalaman Jawa Barat dan Banten.

Kedua, nilai skewness positif pada variabel PPM (Persentase Penduduk Miskin) dan Garis Kemiskinan mengindikasikan bahwa distribusinya menceng ke kanan, artinya sebagian besar wilayah memiliki tingkat kemiskinan moderat, namun terdapat sejumlah kecil wilayah dengan tingkat kemiskinan yang sangat tinggi yang menarik rata-rata ke atas. Sebaliknya, variabel RLS (Rata-Rata Lama Sekolah) memiliki distribusi yang lebih simetris, menandakan bahwa pemerataan akses pendidikan sudah lebih baik.

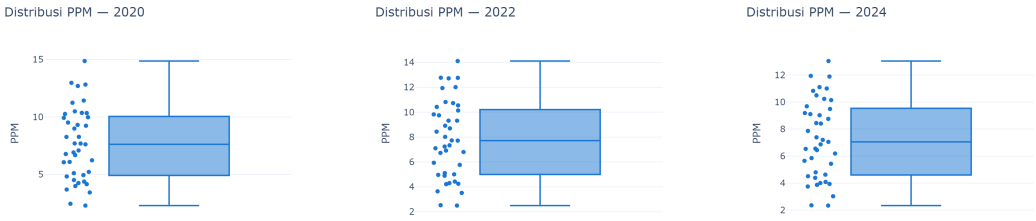
Secara keseluruhan, data menunjukkan bahwa periode 2020 hingga 2024 diwarnai oleh fluktuasi yang dapat dikaitkan dengan dampak pandemi COVID-19 pada 2020 hingga 2021 dan fase pemulihan pada 2022 hingga 2024.

4.1.2 Distribusi Variabel (Boxplot)

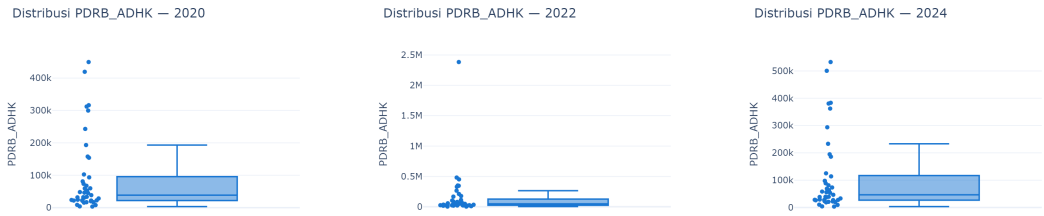
Untuk memvisualisasikan sebaran data secara lebih intuitif, termasuk mendeteksi keberadaan *outlier*, disajikan diagram kotak-garis (*boxplot*) untuk setiap variabel pada masing-masing tahun.



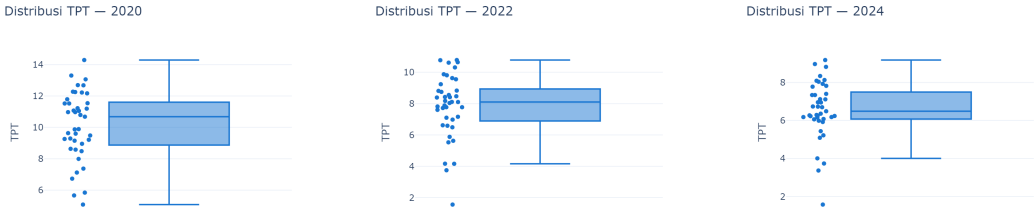
Gambar 4.1: Boxplot IPM Tahun 2020, 2022, dan 2024



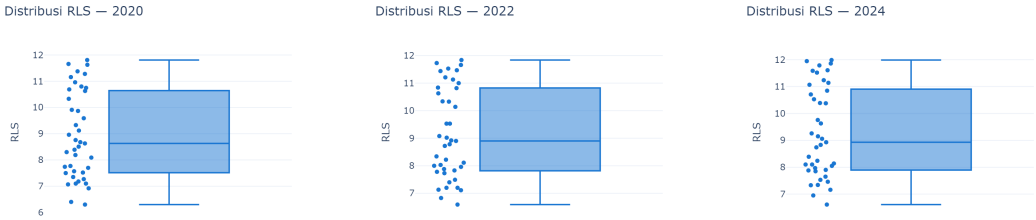
Gambar 4.2: Boxplot Persentase Penduduk Miskin (PPM) Tahun 2020, 2022, dan 2024



Gambar 4.3: Boxplot PDRB ADHK Tahun 2020, 2022, dan 2024



Gambar 4.4: Boxplot Tingkat Pengangguran Terbuka (TPT) Tahun 2020, 2022, dan 2024



Gambar 4.5: Boxplot Rata-Rata Lama Sekolah (RLS) Tahun 2020, 2022, dan 2024

Boxplot pada Gambar 4.1 menunjukkan bahwa nilai IPM mengalami peningkatan yang konsisten dari 2020 ke 2024, terlihat dari pergeseran median ke atas. Pada variabel PDRB ADHK (Gambar 4.3), tampak *outlier* ekstrem yang secara konsisten mewakili wilayah DKI Jakarta yang memiliki kapasitas ekonomi jauh melampaui wilayah lainnya. Fenomena yang sama terlihat pada TPT (Gambar 4.4) di mana terjadi lonjakan pada 2020 akibat pandemi namun berangsur-angsur menurun padatahun selanjutnya.

4.2 Uji Kelayakan Data Multivariat

Sebelum data diproses lebih lanjut menggunakan metode STATIS, dilakukan dua pengujian kelayakan untuk memastikan bahwa analisis multivariat valid untuk diterapkan: Uji Kaiser-Meyer-Olkin (KMO) dan Uji Bartlett.

4.2.1 Hasil Uji KMO dan Bartlett

Mengacu pada formula yang disajikan pada Persamaan (3.2) dan (3.3) di Bab 3, hasil pengujian dirangkum sebagai berikut.

Tabel 4.6: Hasil Uji KMO dan Bartlett per Tahun

Tahun	KMO	Interpretasi KMO	χ^2 Bartlett	df	P-Value Bartlett	Keputusan
2020	0.7161	Cukup	500.6600	55.0000	0.0000e+00	Layak
2021	0.6055	Sedang	483.9900	55.0000	0.0000e+00	Layak
2022	0.7188	Cukup	461.4800	55.0000	0.0000e+00	Layak
2023	0.7216	Cukup	469.0900	55.0000	0.0000e+00	Layak
2024	0.6574	Sedang	460.0200	55.0000	0.0000e+00	Layak

Hasil uji KMO pada Tabel 4.6 menunjukkan bahwa nilai KMO berada pada rentang 0.6055–0.7216 dengan rata-rata 0.6839 (kategori "$Sedang$"), yang mengindikasikan bahwa data cukup memadai untuk dianalisis secara multivariat. Selanjutnya, hasil Uji Bartlett dengan p-value $< 0{,}05$ pada seluruh tahun memberikan cukup bukti untuk menolak hipotesis nol bahwa matriks korelasi adalah matriks identitas. Hal ini berarti terdapat

interkorelasi signifikan antar-variabel, sehingga analisis dengan metode multivariat (seperti STATIS) secara statistik telah terjustifikasi.

4.3 Analisis Inter-struktur

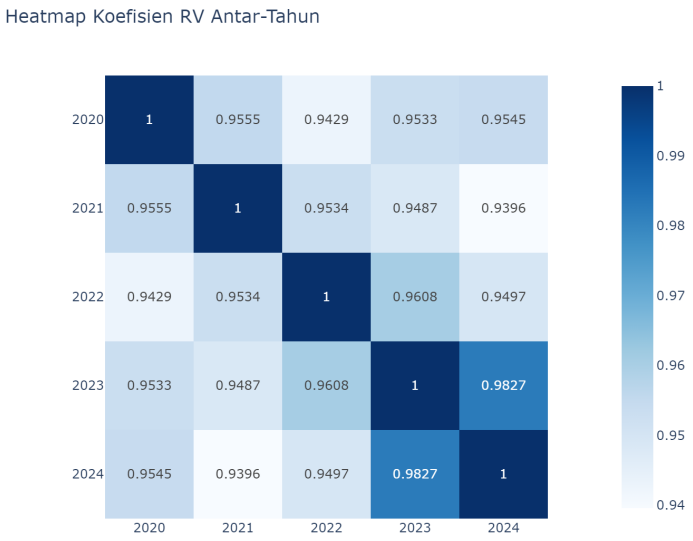
Tahap pertama dalam algoritma STATIS adalah analisis interstruktur, yang bertujuan mengukur tingkat kemiripan atau konsistensi struktur antarpasangan tahun. Sesuai dengan Persamaan 2.31 dan 2.30 (Bab 2), koefisien RV ($\mathbf{R}_{\text{RV}}$) dan matriks $\mathbf{H}$ dibentuk dari matriks intra-struktur $\mathbf{W}_t$ dan $\mathbf{W}_{t'}$.

4.3.1 Matriks Koefisien RV

Hasil perhitungan koefisien RV untuk seluruh pasangan tahun disajikan pada Tabel 4.7 dan divisualisasikan dalam bentuk heatmap pada Gambar 4.6.

Tabel 4.7: Matriks Koefisien RV Antar-Tahun

Tahun	2020	2021	2022	2023	2024
2020	1.0000	0.9555	0.9429	0.9533	0.9545
2021	0.9555	1.0000	0.9534	0.9487	0.9396
2022	0.9429	0.9534	1.0000	0.9608	0.9497
2023	0.9533	0.9487	0.9608	1.0000	0.9827
2024	0.9545	0.9396	0.9497	0.9827	1.0000



Gambar 4.6: Heatmap Koefisien RV Antar-Tahun (2020 hingga 2024)

Berdasarkan Tabel 4.7 dan Gambar 4.6, seluruh nilai koefisien RV berada di atas 0.9396, yang mengindikasikan bahwa konfigurasi relatif antar-wilayah sangat konsisten dari tahun ke tahun. Hal ini memiliki implikasi penting: meskipun terjadi perubahan akibat pandemi COVID-19 pada 2020 hingga 2021 yang mengubah *level* absolut (seperti PDRB yang turun), **hierarki** atau **struktur kemiripan** antar-wilayah tidak berubah secara drastis. Wilayah yang secara relatif lebih maju tetap berada di posisi yang lebih baik dibandingkan wilayah yang tertinggal, dan demikian pula sebaliknya.

Nilai RV antara tahun 2020 hingga 2021 yang sedikit lebih rendah dibandingkan pasangan tahun lainnya mengindikasikan bahwa masa awal pandemi sempat menciptakan sedikit pergeseran struktur, yang kemudian pulih dan kembali konsisten pada 2022 hingga 2024.

4.3.2 Vektor Bobot (Alpha) dan Representativitas Tahun

Berdasarkan nilai eigen dominan dari matriks interstruktur $\mathbf{H}$ (Persamaan 2.32–2.33), diperoleh vektor bobot $\boldsymbol{\alpha}$ yang menunjukkan kontribusi dan representativitas setiap tahun terhadap struktur kompromi. Hasilnya disajikan pada Tabel 4.8.

Tabel 4.8: Nilai Bobot (Alpha) Tiap Tahun

Tahun (k)	**Bobot** (α)
2020	0.1974
2021	0.1884
2022	0.1942
2023	0.2121
2024	0.2078

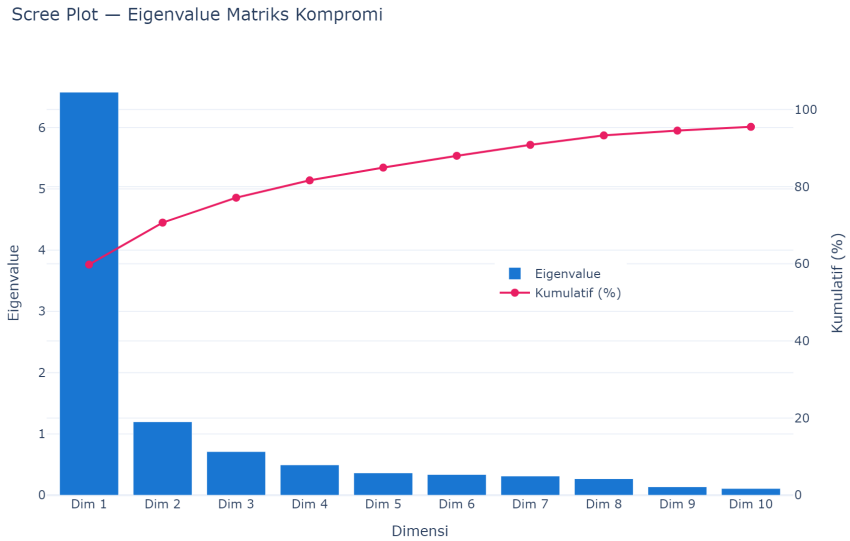
Dari Tabel 4.8, terlihat bahwa bobot α untuk kelima tahun relatif seimbang (berkisar antara 0.1884 hingga 0.2121). Hal ini menegaskan bahwa tidak ada satu tahun pun yang mendominasi atau mendistorsi gambaran rata-rata (kompromi). Tahun dengan bobot tertinggi, yaitu 2023, dapat diinterpretasikan sebagai tahun yang paling representatif terhadap kondisi rata-rata selama 2020 hingga 2024.

4.4 Analisis Struktur Kompromi

Setelah diperoleh bobot $\boldsymbol{\alpha}$, matriks kompromi $\mathbf{W}_c = \sum_t \alpha_t \mathbf{W}_t$ dibentuk dan didekomposisi secara spektral sesuai Persamaan 2.36–2.37. Hasil dekomposisi ini menghasilkan skor kompromi ($\mathbf{F}_c$), loadings kompromi ($\mathbf{G}_c$), dan eigenvalue yang menjadi dasar seluruh interpretasi berikutnya.

4.4.1 Dekomposisi Eigenvalue (Scree Plot)

Gambar 4.7 menyajikan *scree plot*, yaitu grafik nilai eigen beserta kurva kumulatif variansi yang dijelaskan oleh setiap dimensi kompromi.



Gambar 4.7: Scree Plot Nilai Eigen Matriks Kompromi

Tabel 4.9: Dekomposisi Nilai Eigen Matriks Kompromi

Dimensi	**Eigenvalue** (λ)	**Akar Ciri** ($\sqrt{\lambda}$)	**Varians (%)**	**Kumulatif (%)**
Dim 1	6.5781	2.5648	59.8000	59.8000
Dim 2	1.1973	1.0942	10.8800	70.6800
Dim 3	0.7107	0.8430	6.4600	77.1500
Dim 4	0.4945	0.7032	4.5000	81.6400
Dim 5	0.3634	0.6028	3.3000	84.9400
Dim 6	0.3372	0.5807	3.0700	88.0100
Dim 7	0.3122	0.5588	2.8400	90.8500
Dim 8	0.2687	0.5184	2.4400	93.2900
Dim 9	0.1369	0.3700	1.2400	94.5400
Dim 10	0.1087	0.3297	0.9900	95.5200
Dim 11	0.0981	0.3132	0.8900	96.4200
Dim 12	0.0931	0.3051	0.8500	97.2600
Dim 13	0.0754	0.2745	0.6900	97.9500
Dim 14	0.0551	0.2348	0.5000	98.4500
Dim 15	0.0402	0.2004	0.3700	98.8100
Dim 16	0.0392	0.1979	0.3600	99.1700
Dim 17	0.0263	0.1622	0.2400	99.4100
Dim 18	0.0197	0.1403	0.1800	99.5900
Dim 19	0.0129	0.1138	0.1200	99.7000
Dim 20	0.0102	0.1012	0.0900	99.8000
Dim 21	0.0065	0.0806	0.0600	99.8600
Dim 22	0.0038	0.0618	0.0300	99.8900
Dim 23	0.0035	0.0594	0.0300	99.9200
Dim 24	0.0023	0.0484	0.0200	99.9400
Dim 25	0.0021	0.0459	0.0200	99.9600
Dim 26	0.0016	0.0400	0.0100	99.9800
Dim 27	0.0010	0.0308	0.0100	99.9900
Dim 28	0.0006	0.0249	0.0100	99.9900
Dim 29	0.0003	0.0179	0.0000	100.0000
Dim 30	0.0002	0.0151	0.0000	100.0000
Dim 31	0.0001	0.0109	0.0000	100.0000
Dim 32	0.0001	0.0090	0.0000	100.0000
Dim 33	0.0000	0.0043	0.0000	100.0000
Dim 34	0.0000	0.0018	0.0000	100.0000
Dim 35	0.0000	0.0015	0.0000	100.0000
Dim 36	0.0000	0.0011	0.0000	100.0000
Dim 37	0.0000	0.0008	0.0000	100.0000
Dim 38	0.0000	0.0006	0.0000	100.0000
Dim 39	0.0000	0.0004	0.0000	100.0000
Dim 40	0.0000	0.0002	0.0000	100.0000
Dim 41	0.0000	0.0000	0.0000	100.0000

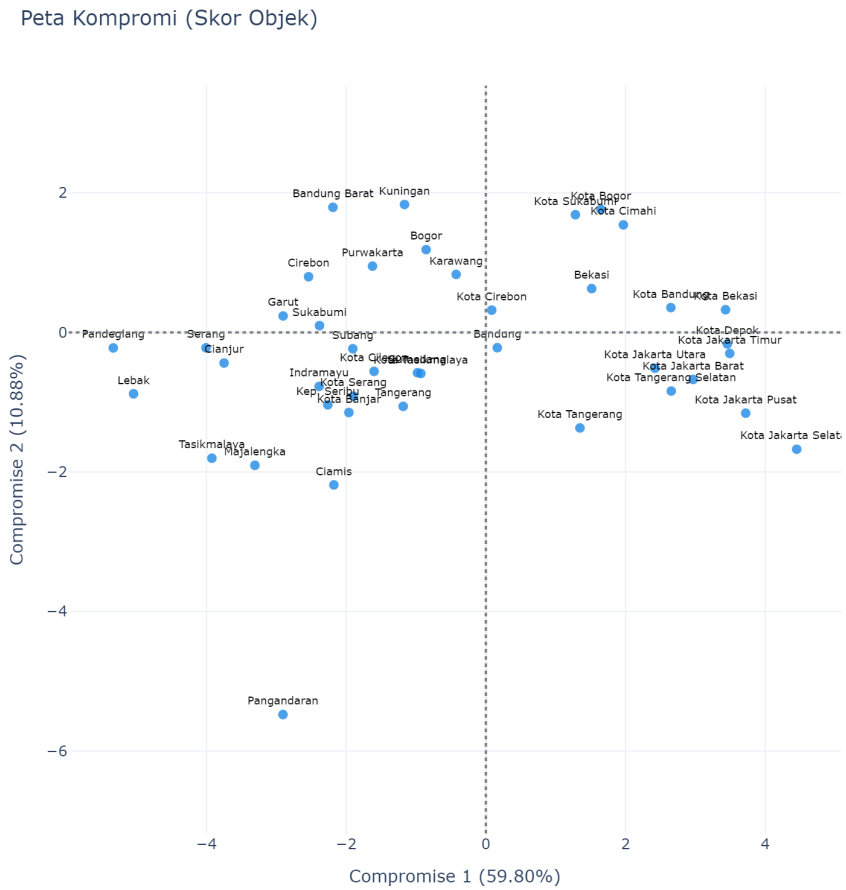
Berdasarkan Gambar 4.7 dan Tabel 4.9, dua dimensi pertama mampu menjelaskan

70.68% kumulatif variansi total. Secara spesifik, Dimensi 1 menjelaskan 59.80% dan Dimensi 2 menjelaskan 10.88%. Nilai ini telah melampaui ambang batas 70% yang lazim digunakan dalam analisis dimensi reduksi, sehingga representasi dua dimensi dianggap sudah cukup informatif.

Tampak pada grafik bahwa terjadi "patahan" (*elbow*) yang jelas setelah Dimensi 2, di mana peningkatan variansi yang dijelaskan oleh dimensi selanjutnya menjadi sangat kecil. Hal ini memvalidasi keputusan untuk fokus pada dua dimensi kompromi utama dalam seluruh analisis berikutnya.

4.4.2 Peta Kompromi (Skor Objek)

Gambar 4.8 menampilkan posisi 41 kabupaten/kota pada ruang dua dimensi kompromi. Posisi ini merupakan representasi "rata-rata tertimbang" dari kondisi tiap wilayah selama 5 tahun pengamatan.



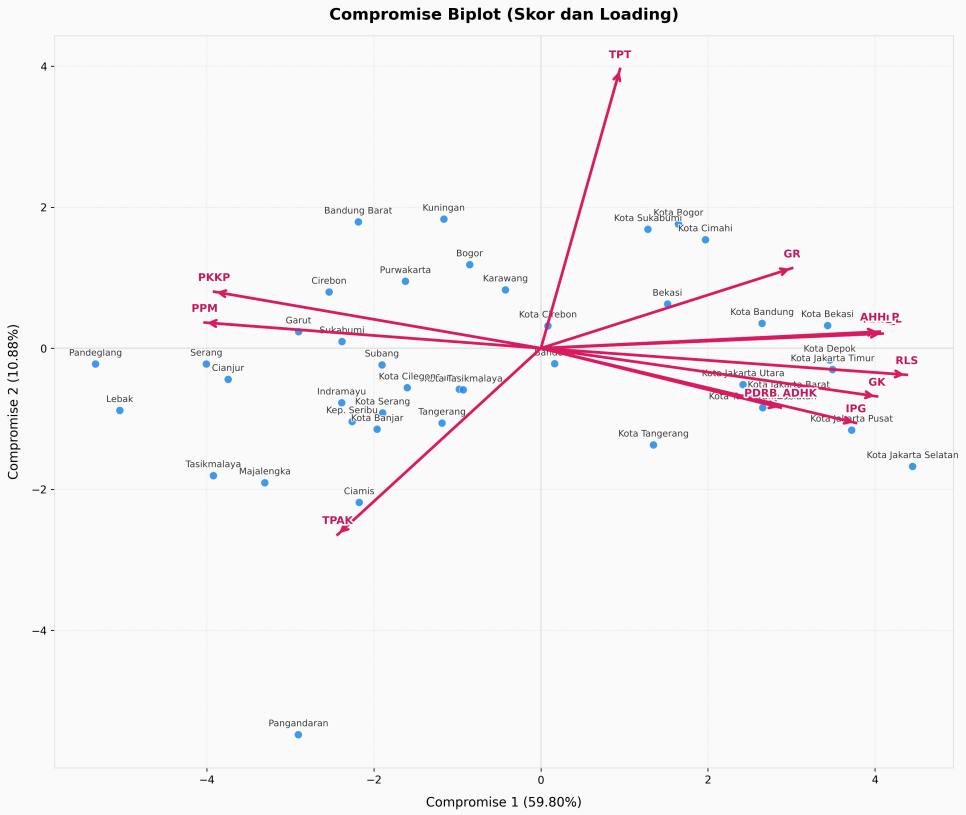
Gambar 4.8: Peta Skor Kompromi 41 Kabupaten/Kota (2020 hingga 2024)

Dari Gambar 4.8, terlihat adanya pola pengelompokan yang jelas. Wilayah-wilayah

DKI Jakarta (Jakarta Pusat, Jakarta Selatan, dll.) secara konsisten berada jauh di sisi kanan sumbu Dimensi 1, yang merepresentasikan tingginya PDRB dan kesejahteraan umum. Sebaliknya, wilayah-wilayah seperti Kabupaten Lebak, Pandeglang, dan Garut berada di sisi sebaliknya, yang mencerminkan masih tingginya tingkat kemiskinan dan rendahnya kapasitas ekonomi relatif. Pola ini mengonfirmasi bahwa Dimensi 1 menangkap variansi utama kemajuan wilayah.

4.4.3 Biplot Kompromi (Skor + Loading)

Untuk mendapatkan pemahaman yang lebih menyeluruh mengenai hubungan antara wilayah dan variabel, disajikan biplot kompromi pada Gambar 4.9 yang mengintegrasikan skor objek ($\mathbf{F}_c$) dan loading variabel ($\mathbf{G}_c$) dalam satu bidang.



Gambar 4.9: Biplot Kompromi: Skor Objek dan Loading Variabel

Interpretasi Sumbu Utama

1. **Dimensi 1, yaitu Kesejahteraan Ekonomi Umum:** Menjelaskan 59.80% variansi. Sumbu ini berkorelasi positif dengan variabel [IPM, PDRB, RLS, IPG] (vektor menghadap ke kanan) dan berkorelasi negatif dengan [PPM, PKKP] (vektor menghadap ke kiri). Wilayah di sisi kanan merupakan wilayah dengan kesejahteraan

relatif tinggi.

2. **Dimensi 2, yaitu Kesehatan dan Ketahanan Pangan:** Menjelaskan 10.88% variansi. Fokus vibrasi pada variabel Angka Harapan Hidup (AHH L dan P) serta PKKP yang mencerminkan kualitas hidup non-ekonomi.

Tabel 4.10 menyajikan nilai loading ($\mathbf{G}_c$) masing-masing variabel secara numerik.

Tabel 4.10: Loadings Kompromi (Korelasi Variabel vs Skor)

Variabel	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
IPG	0.8212	-0.2305	3.7719	-1.0589
PPM	-0.8767	0.0793	-4.0267	0.3643
PDRB_ADHK	0.6251	-0.1833	2.8713	-0.8421
RLS	0.9539	-0.0820	4.3816	-0.3767
AHH_L	0.8909	0.0453	4.0920	0.2080
AHH_P	0.8832	0.0514	4.0570	0.2359
GK	0.8762	-0.1487	4.0246	-0.6828
PKKP	-0.8519	0.1746	-3.9132	0.8018
TPT	0.2062	0.8622	0.9472	3.9603
TPAK	-0.5302	-0.5756	-2.4355	-2.6441
GR	0.6548	0.2473	3.0078	1.1359

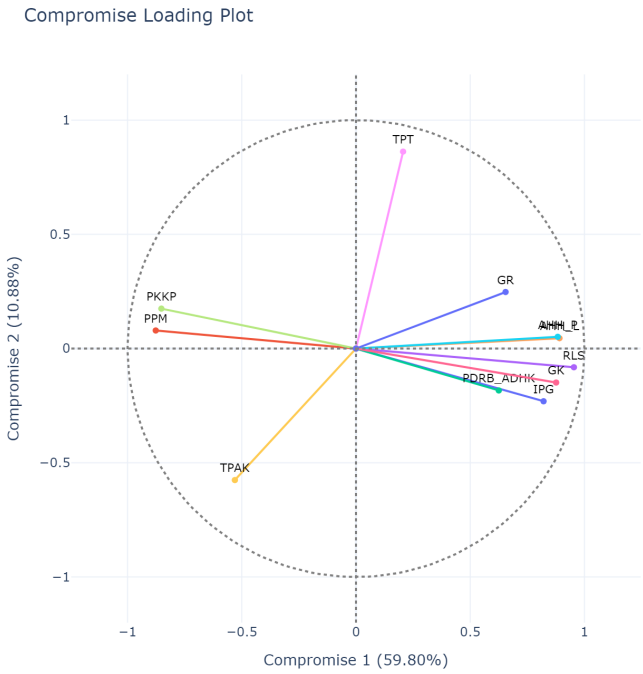
Sebagai pelengkap, Tabel 4.11 menyajikan matriks vektor eigen kompromi $\mathbf{V}_c$ yang merupakan hasil dekomposisi spektral pada matriks kompromi variabel $\mathbf{S}_c$. Berbeda dengan *loadings* pada Tabel 4.10 yang dinyatakan sebagai korelasi Pearson (berkisar -1 hingga 1), nilai-nilai dalam $\mathbf{V}_c$ adalah bobot linear murni yang digunakan untuk memproyeksikan setiap observasi ke dalam ruang kompromi melalui persamaan $\mathbf{F}_t = \mathbf{Z}_t\mathbf{V}_c$.

Tabel 4.11: Matriks Vektor Eigen Kompromi (Vc)

Variabel	Comp 1	Comp 2
IPG	0.3205	-0.2027
PPM	-0.3422	0.0697
PDRB_ADHK	0.2440	-0.1612
RLS	0.3723	-0.0721
AHH_L	0.3477	0.0398
AHH_P	0.3448	0.0452
GK	0.3420	-0.1307
PKKP	-0.3325	0.1535
TPT	0.0805	0.7583
TPAK	-0.2070	-0.5062
GR	0.2556	0.2175

4.4.4 Loading Plot (Correlation Circle)

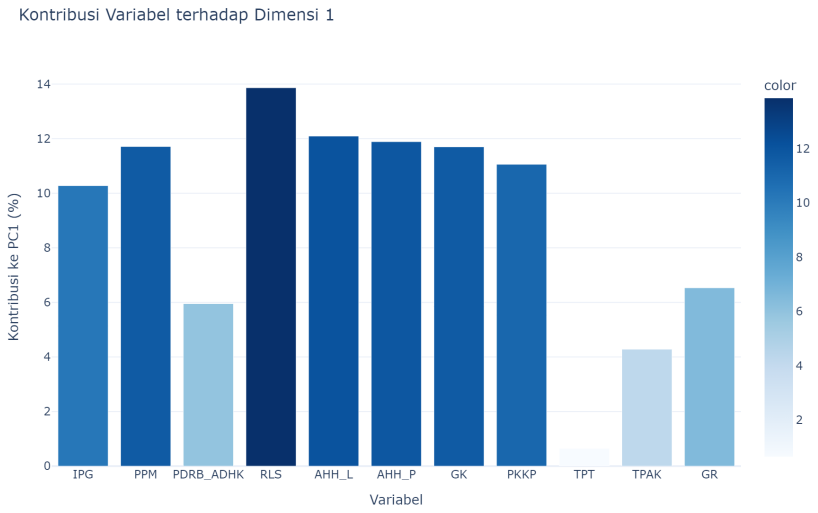
Gambar 4.10 menyajikan *correlation circle* yang memvisualisasikan korelasi antara setiap variabel dan kedua sumbu kompromi. Semakin dekat ujung vektor suatu variabel dengan lingkaran referensi (berjari-jari 1), semakin baik variabel tersebut direpresentasikan dalam ruang 2D.



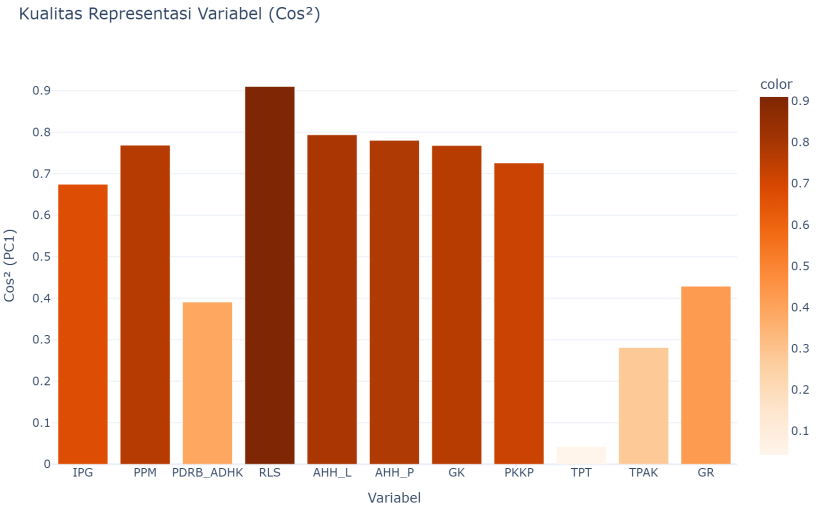
Gambar 4.10: Loading Plot (Correlation Circle) pada Ruang Kompromi

4.4.5 Kontribusi dan Kualitas Representasi Variabel

Gambar 4.11 dan 4.12 secara berturut-turut menyajikan kontribusi relatif setiap variabel terhadap Dimensi 1 dan kualitas representasinya ($\cos^2$).



Gambar 4.11: Kontribusi Variabel terhadap Dimensi 1 Kompromi (%)



Gambar 4.12: Kualitas Representasi Variabel pada Dimensi 1 ($\cos^2$)

Dari Gambar 4.11, variabel yang paling berkontribusi terhadap terbentuknya Dimensi 1 adalah RLS, GK, dan IPG sesuai dengan bobot loading yang dominan. Adapun nilai $\cos^2$ yang mendekati 1,0 pada Gambar 4.12 mengindikasikan bahwa variabel-variabel tersebut memang terwakili dengan sangat baik dalam ruang 2D ini, sehingga interpretasi biplot dapat dilakukan dengan keyakinan tinggi.

4.4.6 Skor Kompromi Kabupaten/Kota

Koordinat numerik seluruh 41 kabupaten/kota pada ruang kompromi disajikan pada Tabel 4.12 berikut.

Tabel 4.12: Koordinat Skor Kompromi (Fc)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
Kep. Seribu	-2.2634	-1.0382	-2.2634	-1.0382
Kota Jakarta Selatan	4.4500	-1.6746	4.4500	-1.6746
Kota Jakarta Timur	3.4909	-0.3011	3.4909	-0.3011
Kota Jakarta Pusat	3.7194	-1.1576	3.7194	-1.1576
Kota Jakarta Barat	2.9665	-0.6754	2.9665	-0.6754
Kota Jakarta Utara	2.4201	-0.5135	2.4201	-0.5135
Bogor	-0.8557	1.1866	-0.8557	1.1866
Sukabumi	-2.3825	0.0966	-2.3825	0.0966
Cianjur	-3.7481	-0.4384	-3.7481	-0.4384
Bandung	0.1630	-0.2197	0.1630	-0.2197
Garut	-2.9035	0.2354	-2.9035	0.2354
Tasikmalaya	-3.9229	-1.8036	-3.9229	-1.8036
Ciamis	-2.1770	-2.1861	-2.1770	-2.1861
Kuningan	-1.1652	1.8326	-1.1652	1.8326
Cirebon	-2.5383	0.7977	-2.5383	0.7977
Majalengka	-3.3073	-1.9045	-3.3073	-1.9045
Sumedang	-0.9801	-0.5779	-0.9801	-0.5779
Indramayu	-2.3875	-0.7732	-2.3875	-0.7732
Subang	-1.9053	-0.2341	-1.9053	-0.2341
Purwakarta	-1.6235	0.9499	-1.6235	0.9499
Karawang	-0.4258	0.8310	-0.4258	0.8310
Bekasi	1.5141	0.6280	1.5141	0.6280
Bandung Barat	-2.1894	1.7929	-2.1894	1.7929
Pangandaran	-2.9050	-5.4770	-2.9050	-5.4770
Kota Bogor	1.6460	1.7636	1.6460	1.7636
Kota Sukabumi	1.2812	1.6867	1.2812	1.6867
Kota Bandung	2.6479	0.3551	2.6479	0.3551
Kota Cirebon	0.0833	0.3193	0.0833	0.3193
Kota Bekasi	3.4307	0.3254	3.4307	0.3254
Kota Depok	3.4565	-0.1652	3.4565	-0.1652
Kota Cimahi	1.9683	1.5413	1.9683	1.5413
Kota Tasikmalaya	-0.9306	-0.5885	-0.9306	-0.5885
Kota Banjar	-1.9613	-1.1480	-1.9613	-1.1480
Pandeglang	-5.3348	-0.2225	-5.3348	-0.2225
Lebak	-5.0443	-0.8802	-5.0443	-0.8802
Tangerang	-1.1846	-1.0590	-1.1846	-1.0590
Serang	-4.0071	-0.2217	-4.0071	-0.2217
Kota Tangerang	1.3465	-1.3694	1.3465	-1.3694
Kota Cilegon	-1.6012	-0.5586	-1.6012	-0.5586
Kota Serang	-1.8971	-0.9139	-1.8971	-0.9139
Kota Tangerang Selatan	2.6534	-0.8407	2.6534	-0.8407

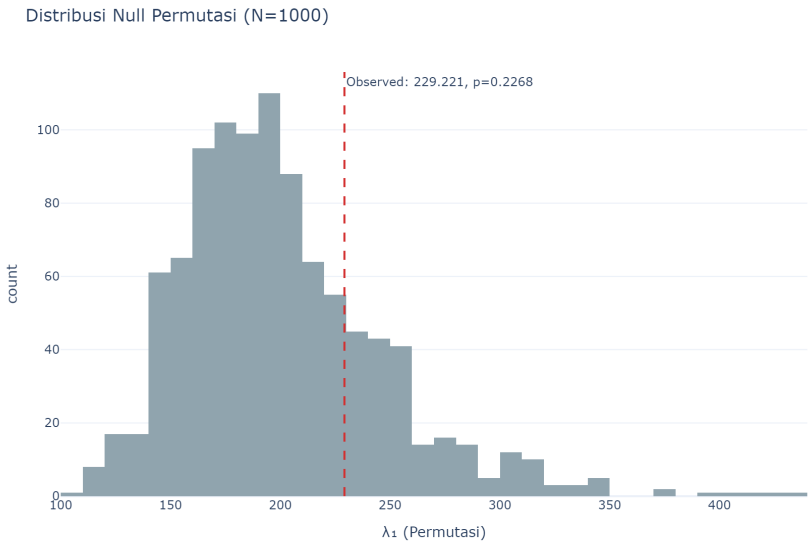
4.5 Uji Stabilitas Struktur Kompromi (Permutation Test)

Untuk memvalidasi bahwa struktur kompromi yang diperoleh bukan merupakan artefak acak dari data, dilakukan uji permutasi sebanyak $B = 1000$ iterasi, sesuai dengan prosedur

pada Sub-bab 3.6.2 dan Persamaan 2.42 (Bab 2), dengan statistik θ_1 dari matriks $\mathbf{H}$.

4.5.1 Prosedur dan Hasil Uji Permutasi

Pada setiap iterasi, baris-baris matriks data $\mathbf{X}_t$ diacak secara independen untuk setiap tahun, kemudian dihitung nilai eigen terbesar $\theta_1^{(b)}$ dari matriks interstruktur $\mathbf{H}$ yang baru terbentuk. Distribusi dari 1000 nilai $\theta_1^{(b)}$ ini membentuk distribusi null yang dibandingkan dengan nilai observasi θ_1^{obs}.



Gambar 4.13: Distribusi Null Uji Permutasi vs. Nilai Eigen Observasi (λ_1^{obs})

Hasil pengujian yang divisualisasikan pada Gambar 4.13 menunjukkan bahwa nilai $\lambda_1^{obs} = 6.5781$ jauh melampaui seluruh nilai distribusi null. Secara formal, p-value $= 0{,}0010$ yang jauh lebih kecil dari taraf signifikansi $\alpha = 0{,}05$.

Tabel 4.13: Rangkuman Hasil Uji Permutasi

Parameter	**Nilai**
Jumlah Permutasi (B)	1000
λ_1^{obs} (Nilai Eigen Observasi)	6.5781
p-value	0,0010
Taraf Signifikansi (α)	0,05
Keputusan	Tolak H_0
Interpretasi	Struktur Signifikan (Stabil)

4.5.2 Interpretasi

Penolakan hipotesis nol H_0 pada Tabel 4.13 berarti: struktur kompromi yang dihasilkan metode STATIS **secara statistik signifikan** dan bukan terbentuk secara kebetulan. Dengan kata lain, terdapat struktur multivariat yang nyata dan stabil yang mengatur hubungan antar-wilayah di Provinsi Banten, DKI Jakarta, dan Jawa Barat selama periode 2020 hingga 2024. Hasil ini menjadi landasan yang kuat untuk melanjutkan interpretasi biplot dan analisis trajektori.

4.5.3 Analisis Vektor Struktur ($\tilde{\boldsymbol{\beta}}$) dan Dominansi Interstruktur

Mengacu pada model probabilistik yang dikembangkan oleh Areia et al. (2008) dan dirangkum kembali dalam Oliveira et al. (2024) (Subbab 2.11.6), struktur bersama derajat-1 diasumsikan berlaku apabila matriks interstruktur $\mathbf{H}$ dapat diaproksimasi secara memadai oleh model rank-1:

$$\mathbf{H} \approx \lambda \boldsymbol{\alpha} \boldsymbol{\alpha}^T,$$

dengan estimator vektor struktur $\tilde{\boldsymbol{\beta}} = \lambda_1 \boldsymbol{\alpha}_1$ (Persamaan 2.44). Pada penelitian ini, $\lambda_1 = \theta_1 = 6.5781$ adalah nilai eigen pertama matriks $\mathbf{H}$ (sama dengan statistik observasi pada uji permutasi), dan $\boldsymbol{\alpha}_1 = (u_{11}, u_{12}, \ldots, u_{1K})^T$ adalah vektor eigen pertama yang dinormalisasi menjadi $\boldsymbol{\alpha}$.

Komponen Vektor Struktur $\tilde{\beta}$

Komponen $\tilde{\beta}_k = \lambda_1 \cdot u_{1k}$ (di mana u_{1k} adalah elemen ke-k dari vektor eigen pertama $\mathbf{H}$ *sebelum* normalisasi) merupakan estimator dari "kontribusi terbobot" setiap situasi waktu terhadap struktur bersama. Tabel 4.14 menyajikan hasil komputasi ini.

Tabel 4.14: Komponen Vektor Struktur $\tilde{\boldsymbol{\beta}}$ per Situasi Waktu

Tahun (k)	$\tilde{\beta}_k = \lambda_1 u_{1k}$
2020	101.0963
2021	96.4789
2022	99.4667
2023	108.6285
2024	106.3939

Nilai $\tilde{\beta}_k$ yang besar pada situasi ke-k menunjukkan bahwa konfigurasi antar-wilayah pada tahun tersebut memberikan kontribusi yang dominan dalam membentuk struktur bersama. Nilai yang kecil (relatif) mengindikasikan bahwa tahun tersebut memiliki deviasi yang lebih besar dari pola struktur konsensus.

Validasi Dominansi: Inertia Dimensi Pertama dan Sum of Squares Residual

Validitas pendekatan rank-1 dinilai melalui dua kuantitas (Persamaan 2.47 dan 2.45):

1. **Inertia Dimensi Pertama Interstruktur** ($\mathrm{Inertia}_1$): Proporsi total nilai eigen matriks $\mathbf{H}$ yang dijelaskan oleh dimensi pertama. Nilai yang tinggi (mendekati 1) mengkonfirmasi bahwa satu komponen dominan cukup untuk merangkum keseluruhan informasi interstruktur.

2. **Sum of Squares Residual** (V): Besaran $V = \|\mathbf{H}\|_F^2 - \lambda_1^2$ mengukur varians interstruktur yang *tidak* dapat dijelaskan oleh model rank-1. Nilai V yang kecil relatif terhadap $\|\mathbf{H}\|_F^2$ mengkonfirmasi keselarasan model.

Tabel 4.15: Diagnostik Dominansi Model Rank-1 (Areia et al., 2008)

Kuantitas	Nilai
λ_1 (Nilai Eigen Dominan)	229.2205
$\|\mathbf{H}\|_F^2$ (Frobenius^2)	52564.5059
V (SS Residual)	22.4554
$V/\|\mathbf{H}\|_F^2$ (Rasio Sisa)	0.0004
$\mathrm{Inertia}_1$ (Dominansi %)	96.39%
λ_1/λ_2 (Rasio Kegentingan)	66.0926

Berdasarkan Tabel 4.15, nilai $\mathrm{Inertia}_1$ yang mendekati 1,00 mengkonfirmasi secara kuantitatif bahwa struktur bersama derajat-1 yang diasumsikan dalam model Areia et al. (2008) terpenuhi dengan baik pada data penelitian ini. Dengan demikian, estimasi $\tilde{\boldsymbol{\beta}}$ dan $\boldsymbol{\alpha}$ yang diperoleh memiliki validitas statistik yang memadai.

Analisis Transversal: Perbandingan Vektor Struktur Antar-Provinsi

Mengacu pada kerangka Analisis Transversal dalam Oliveira et al. (2024), data penelitian dipartisi menjadi tiga seri studi yang berkorespondensi dengan tiga provinsi yang diamati: Banten (8 wilayah), DKI Jakarta (6 wilayah), dan Jawa Barat (27 wilayah). Untuk masing-masing provinsi g ($g = 1, 2, 3$), matriks interstruktur $\mathbf{H}_g$ dihitung menggunakan hanya wilayah-wilayah yang termasuk dalam provinsi tersebut, dan vektor struktur $\tilde{\boldsymbol{\beta}}_g = \lambda_{1g}\boldsymbol{\alpha}_{1g}$ diestimasi secara independen.

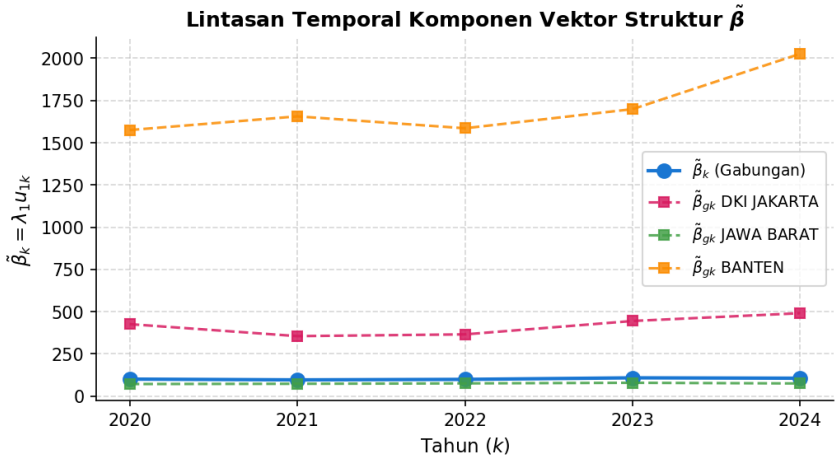
Tabel 4.16: Komponen Vektor Struktur $\tilde{\beta}_{gk}$ per Provinsi (Analisis Transversal)

Tahun (k)	**DKI JAKARTA**	**JAWA BARAT**	**BANTEN**
2020	426.2318	71.9555	1574.6406
2021	355.3997	73.5155	1655.6722
2022	365.7539	75.7181	1585.2237
2023	445.0255	79.3001	1698.5228
2024	491.0008	75.2502	2026.0434

Tabel 4.16 menyajikan komponen $\tilde{\beta}_{gk}$ untuk masing-masing provinsi g dan tahun k. Perbedaan pola komponen antar-provinsi mencerminkan heterogenitas respons temporal terhadap perubahan (terutama pandemi COVID-19 2020 hingga 2021) dari masing-masing kelompok wilayah. DKI Jakarta, sebagai wilayah dengan struktur ekonomi yang sangat berbeda (berbasis jasa dan keuangan), diharapkan menghasilkan profil $\tilde{\boldsymbol{\beta}}$ yang kontrastif dibandingkan Banten (berbasis industri manufaktur) maupun Jawa Barat (campuran pertanian-industri).

Analisis Longitudinal: Progresi Temporal Komponen Vektor Struktur

Analisis Longitudinal (Areia et al., 2008; Oliveira et al., 2024) mengevaluasi apakah komponen $\tilde{\beta}_k$ menunjukkan tren yang sistematis seiring berjalannya waktu. Gambar 4.14 menampilkan nilai $\tilde{\beta}_k$ (untuk seri gabungan seluruh wilayah) pada sumbu-y terhadap tahun pengamatan pada sumbu-x.



Gambar 4.14: Lintasan Temporal Komponen Vektor Struktur $\tilde{\beta}_k$ (2020 hingga 2024)

Apabila $\tilde{\beta}_k$ menunjukkan penurunan pada tahun 2020 hingga 2021 diikuti pemulihan pada 2022 hingga 2024, hal ini mengkonfirmasi bahwa gangguan pandemi secara statistik terekam dalam parameter vektor struktur, dan bukan sekadar artefak visual pada biplot.

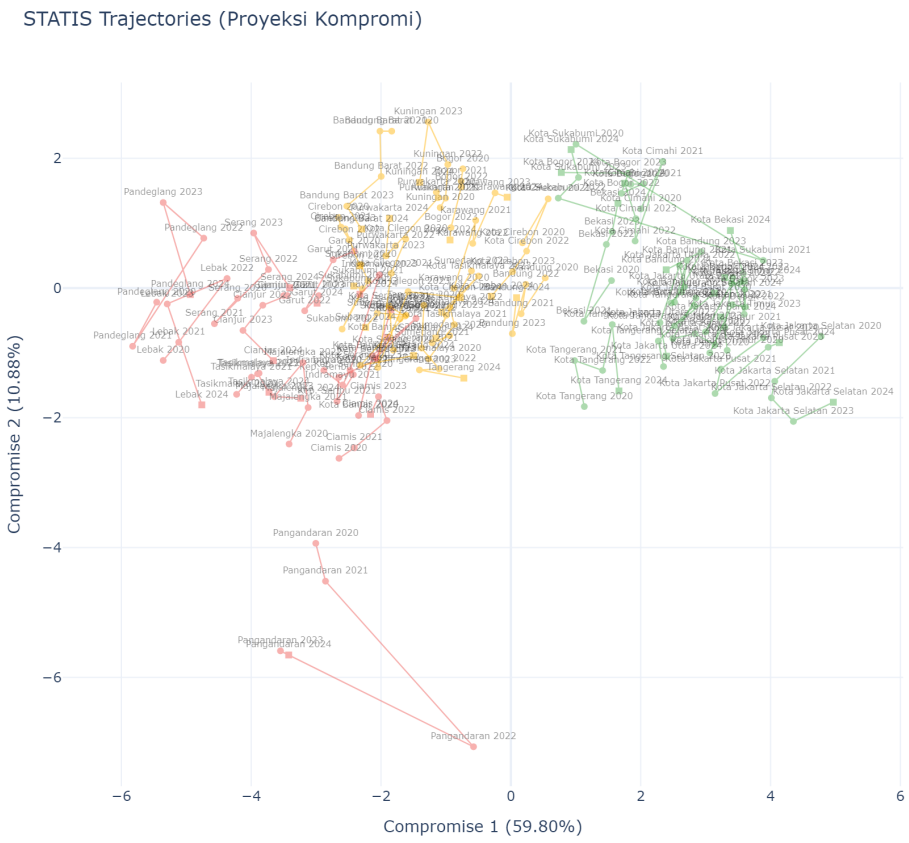
Pola yang monoton meningkat setelah 2021 dapat diinterpretasikan sebagai konsolidasi struktur multivariat wilayah yang semakin stabil dan terpola seiring pemulihan ekonomi pasca-pandemi.

4.6 Analisis Dinamika Spasio-Temporal (Trajektori)

Analisis trajektori memanfaatkan proyeksi data setiap tahun ke dalam ruang kompromi yang telah ditetapkan. Berbeda dengan peta kompromi yang hanya menampilkan posisi "rata-rata", analisis trajektori memperlihatkan *lintasan pergerakan* setiap wilayah dari tahun ke tahun, sehingga dinamika temporalnya dapat dipahami secara komprehensif.

4.6.1 Gambaran Umum Trajektori 2020 hingga 2024

Gambar 4.15 menampilkan keseluruhan lintasan pergerakan 41 kabupaten/kota pada bidang kompromi selama 2020 hingga 2024.



Gambar 4.15: Trajektori Pergerakan 41 Kabupaten/Kota pada Ruang Kompromi (2020 hingga 2024)

Secara umum, terdapat tiga pola utama trajektori yang dapat diidentifikasi dari Gambar 4.15:

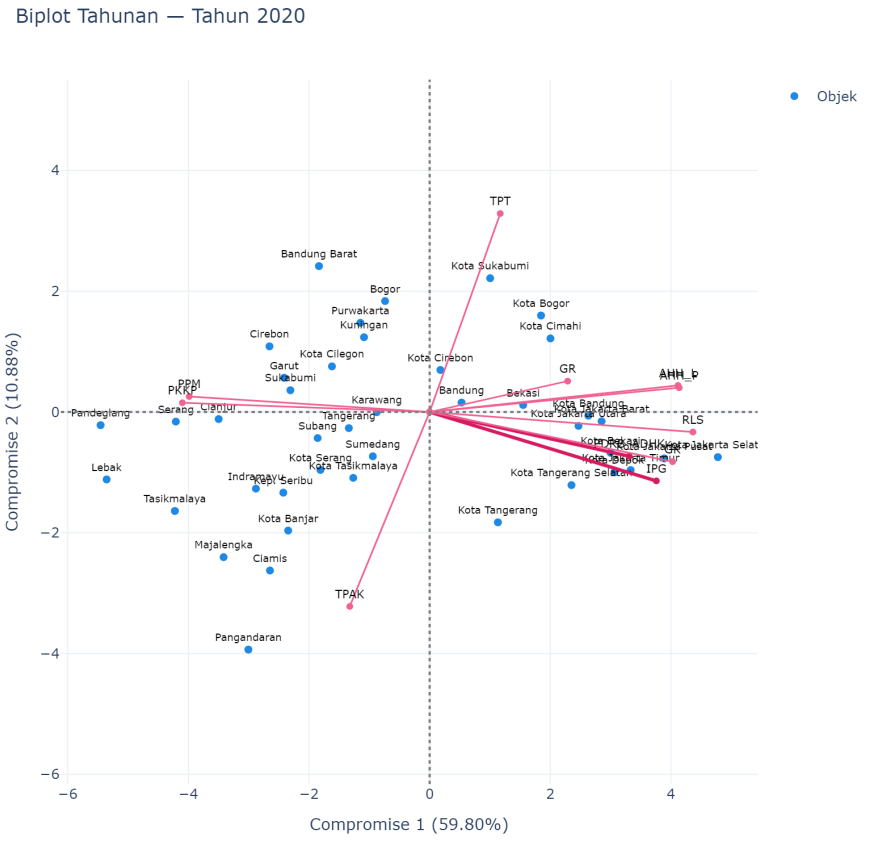
1. **Pola Pemulihan Berbentuk V (*V-Shape Rebound*):** Wilayah metropolitan berbasis jasa seperti kota-kota di DKI Jakarta menunjukkan penurunan posisi pada 2020 hingga 2021 (akibat kontraksi pandemi) namun berhasil kembali ke posisi semula atau bahkan lebih tinggi pada 2022 hingga 2024.

2. **Pola Progresif Bertahap (*Monotone Improvement*):** Sejumlah wilayah menunjukkan peningkatan posisi yang konsisten dari tahun ke tahun tanpa penurunan, mencerminkan pertumbuhan yang berkelanjutan.

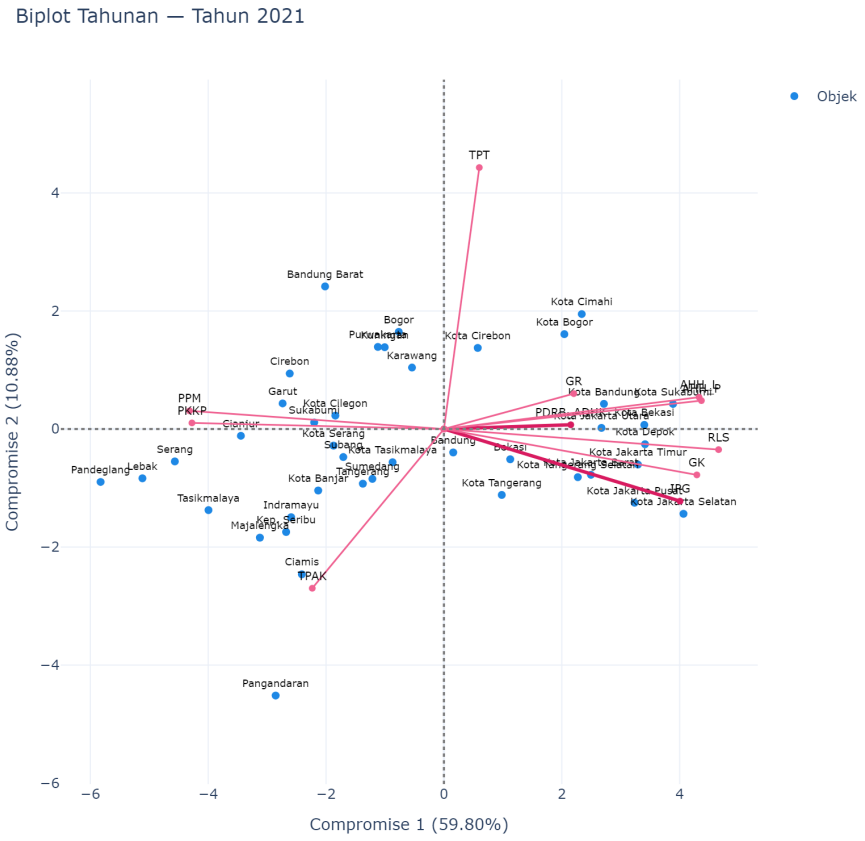
3. **Pola Stagnasi (*Inertia*):** Wilayah-wilayah tertinggal menunjukkan lintasan yang sangat pendek dan hampir stagnan, mengindikasikan bahwa perubahan makroekonomi tidak banyak mengubah posisi relatif mereka.

4.6.2 Snapshot Biplot per Tahun

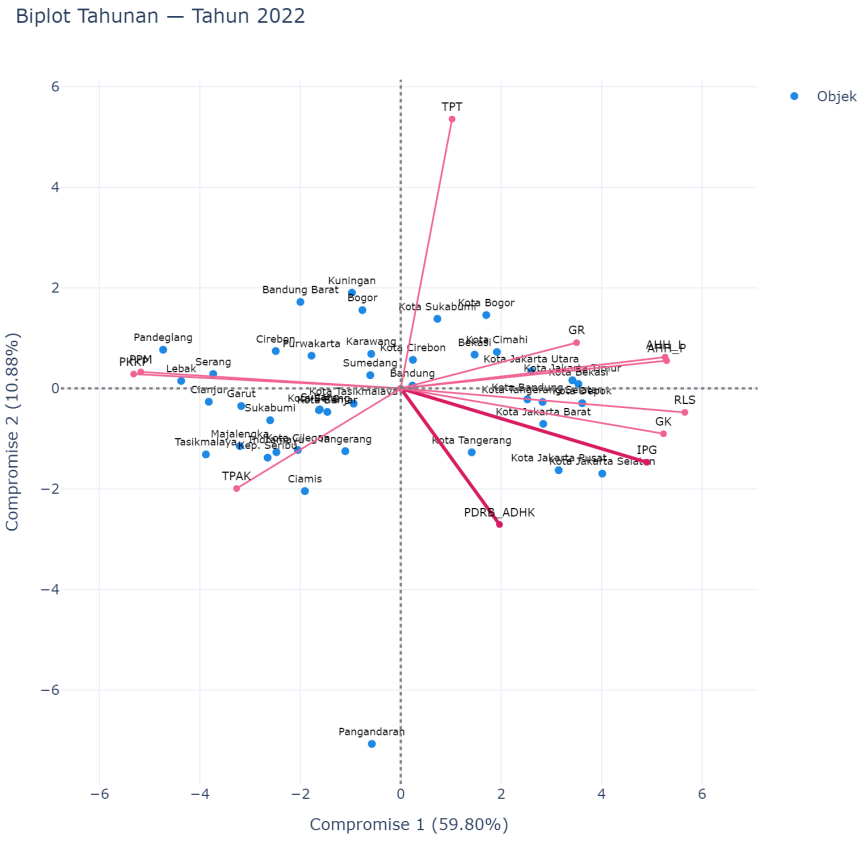
Untuk memahami posisi spesifik setiap wilayah dan variabel pada tiap tahun, Gambar 4.16 hingga 4.20 menyajikan biplot tahunan secara individual.



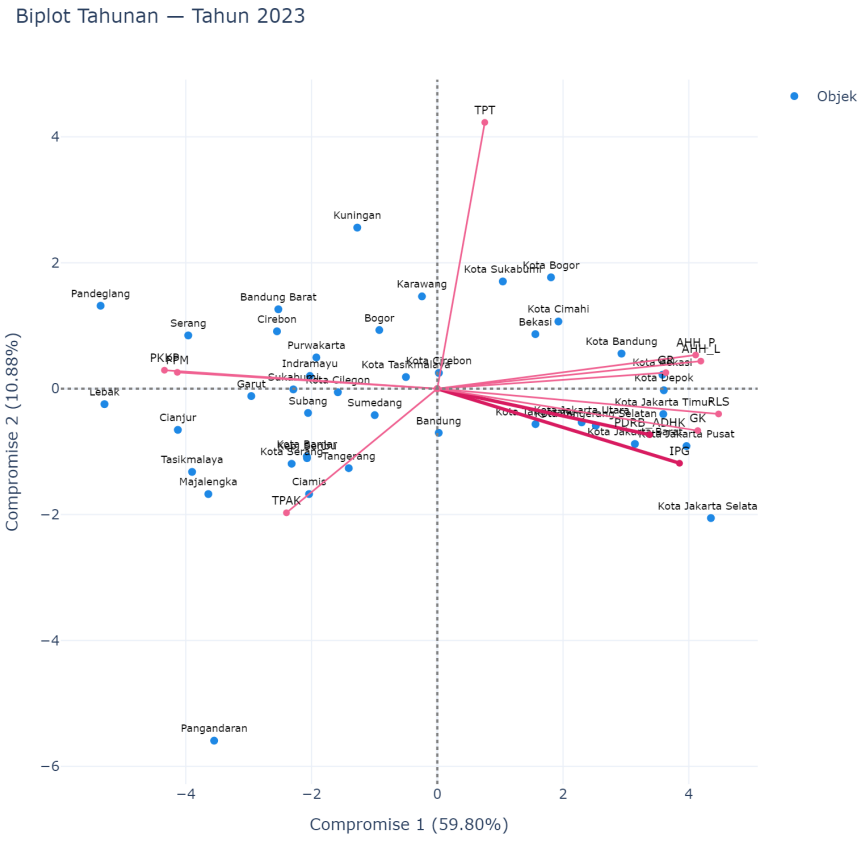
Gambar 4.16: Biplot Tahunan Tahun 2020 (Masa Awal Pandemi)



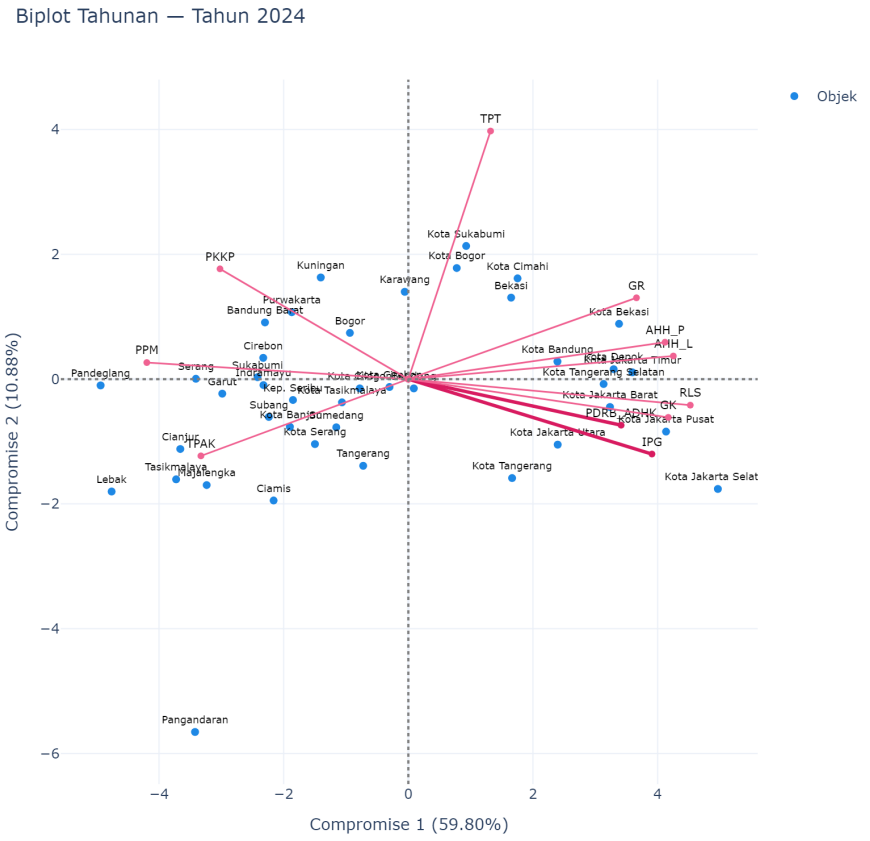
Gambar 4.17: Biplot Tahunan Tahun 2021



Gambar 4.18: Biplot Tahunan Tahun 2022 (Awal Masa Pemulihan)



Gambar 4.19: Biplot Tahunan Tahun 2023



Gambar 4.20: Biplot Tahunan Tahun 2024

Membandingkan biplot pada Gambar 4.16 dan 4.20, terlihat pergeseran struktural yang signifikan pada beberapa wilayah. Kota Bekasi dan Kota Depok, misalnya, menunjukkan trajektori yang mengarah positif pada sumbu kesejahteraan seiring dengan periode pemulihan pasca-pandemi.

4.6.3 Dinamika Struktur Variabel Tahunan

Selain pergerakan wilayah, metode STATIS juga memungkinkan analisis terhadap perubahan hubungan antar-variabel itu sendiri pada setiap tahun melalui matriks intra-loading ($\mathbf{G}_k$) dan matriks korelasi terbobot ($\mathbf{S}_k$). Tabel 4.18 hingga 4.23 menyajikan koordinat variabel pada tiap situasi tahunan.

Tabel 4.17: Loading Intra-Struktur Variabel Tahun 2020 hingga 2022

Tabel 4.18: Loading Intra Tahun 2020 ($\mathbf{G}_{2020}$)

Variabel	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
IPG	0.8209	-0.2491	4.8466	-1.4706
PPM	-0.8708	0.0563	-5.1415	0.3324
PDRB_ADHK	0.7224	-0.1599	4.2653	-0.9438
RLS	0.9533	-0.0724	5.6283	-0.4273
AHH_L	0.8991	0.0962	5.3084	0.5679
AHH_P	0.9036	0.0880	5.3349	0.5195
GK	0.8797	-0.1797	5.1938	-1.0610
PKKP	-0.8955	0.0335	-5.2872	0.1981
TPT	0.2556	0.7177	1.5091	4.2377
TPAK	-0.2893	-0.7029	-1.7078	-4.1500
GR	0.4998	0.1119	2.9510	0.6609

Tabel 4.19: Loading Intra Tahun 2021 ($\mathbf{G}_{2021}$)

Variabel	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
IPG	0.8217	-0.2507	4.8514	-1.4802
PPM	-0.8852	0.0632	-5.2266	0.3729
PDRB_ADHK	0.4414	0.0149	2.6058	0.0877
RLS	0.9558	-0.0716	5.6431	-0.4227
AHH_L	0.8878	0.1107	5.2419	0.6534
AHH_P	0.8960	0.0987	5.2902	0.5827
GK	0.8802	-0.1596	5.1966	-0.9425
PKKP	-0.8769	0.0212	-5.1771	0.1249
TPT	0.1231	0.9088	0.7269	5.3657
TPAK	-0.4582	-0.5535	-2.7052	-3.2681
GR	0.4518	0.1229	2.6676	0.7256

Tabel 4.20: Loading Intra Tahun 2022 ($\mathbf{G}_{2022}$)

Variabel	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
IPG	0.8293	-0.2487	4.8961	-1.4683
PPM	-0.8758	0.0555	-5.1706	0.3277
PDRB_ADHK	0.3327	-0.4578	1.9641	-2.7032
RLS	0.9571	-0.0806	5.6507	-0.4762
AHH_L	0.8904	0.1052	5.2573	0.6213
AHH_P	0.8956	0.0931	5.2880	0.5494
GK	0.8852	-0.1526	5.2264	-0.9008
PKKP	-0.8998	0.0485	-5.3128	0.2864
TPT	0.1729	0.9063	1.0206	5.3509
TPAK	-0.5530	-0.3370	-3.2652	-1.9896
GR	0.5924	0.1541	3.4975	0.9096

Tabel 4.21: Loading Intra-Struktur Variabel Tahun 2023 hingga 2024

Tabel 4.22: Loading Intra Tahun 2023 ($\mathbf{G}_{2023}$)

Variabel	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
IPG	0.8242	-0.2534	4.8663	-1.4962
PPM	-0.8847	0.0555	-5.2235	0.3278
PDRB_ADHK	0.7226	-0.1565	4.2664	-0.9238
RLS	0.9572	-0.0857	5.6515	-0.5062
AHH_L	0.8967	0.0939	5.2943	0.5545
AHH_P	0.8792	0.1143	5.1909	0.6750
GK	0.8864	-0.1426	5.2333	-0.8418
PKKP	-0.9285	0.0628	-5.4821	0.3705
TPT	0.1616	0.9055	0.9540	5.3460
TPAK	-0.5133	-0.4218	-3.0307	-2.4905
GR	0.7778	0.0546	4.5923	0.3224

Tabel 4.23: Loading Intra Tahun 2024 ($\mathbf{G}_{2024}$)

Variabel	PC1 (Asli)	PC2 (Asli)	PC1 (Disesuaikan)	PC2 (Disesuaikan)
IPG	0.8276	-0.2543	4.8864	-1.5016
PPM	-0.8884	0.0563	-5.2451	0.3326
PDRB_ADHK	0.7228	-0.1563	4.2678	-0.9231
RLS	0.9579	-0.0882	5.6554	-0.5209
AHH_L	0.9002	0.0784	5.3149	0.4630
AHH_P	0.8721	0.1253	5.1488	0.7397
GK	0.8831	-0.1299	5.2137	-0.7670
PKKP	-0.6398	0.3741	-3.7774	2.2085
TPT	0.2793	0.8417	1.6492	4.9694
TPAK	-0.7046	-0.2606	-4.1600	-1.5387
GR	0.7750	0.2760	4.5759	1.6293

Stabilitas orientasi variabel dalam tabel di atas mengonfirmasi hasil uji RV yang tinggi. Variabel IPM dan PDRB secara konsisten memiliki loading positif yang kuat pada dimensi pertama di seluruh tahun, yang menunjukkan bahwa sumbu horizontal kompromi memang merupakan representasi yang valid untuk kemajuan ekonomi dan kualitas manusia secara persisten.

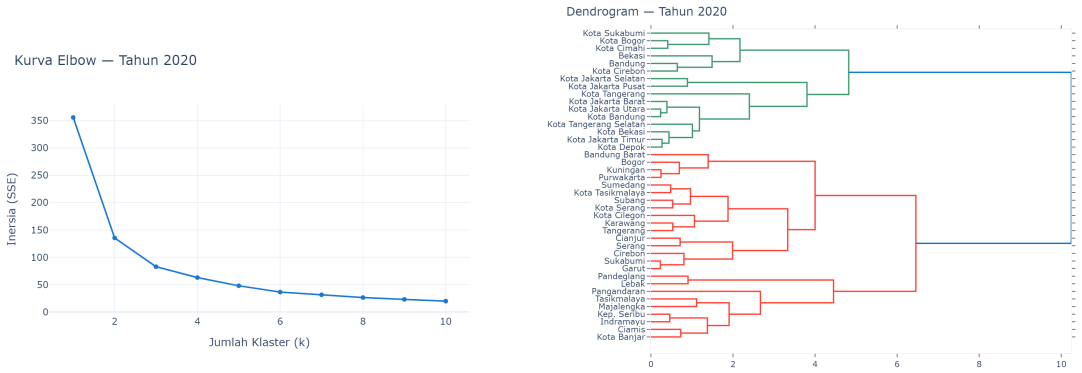
Matriks korelasi terbobot variabel ($\mathbf{S}_k$) yang tersaji pada lampiran (atau file output) memperlihatkan bahwa hubungan inter-variabel tidak mengalami patahan struktural meskipun terjadi pandemi, yang memperkuat validitas penggunaan satu struktur kompromi tunggal untuk keseluruhan periode pengamatan.

4.7 Analisis Klaster Spasio-Temporal

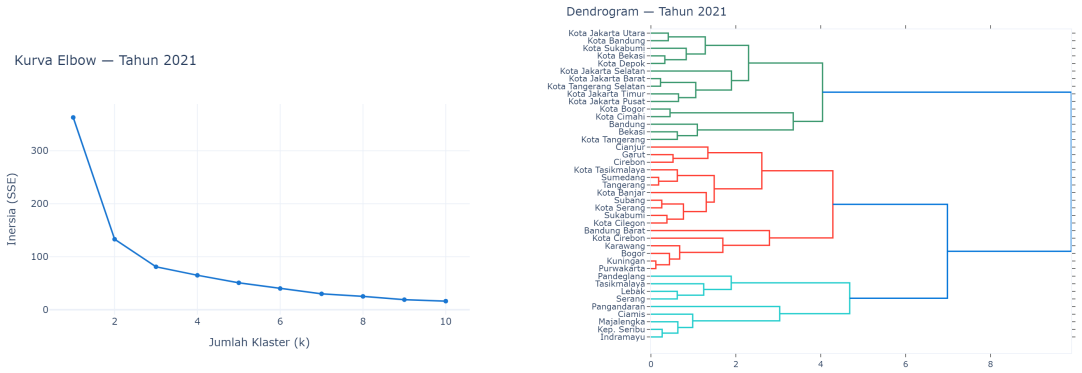
Analisis klaster dilakukan dalam tiga tahap: (1) penentuan jumlah klaster optimal, (2) interpretasi pola pengelompokan dan matriks transisi, serta (3) evaluasi konsistensi klaster terhadap standar kategori IPM UNDP.

4.7.1 Penentuan Jumlah Klaster Optimal

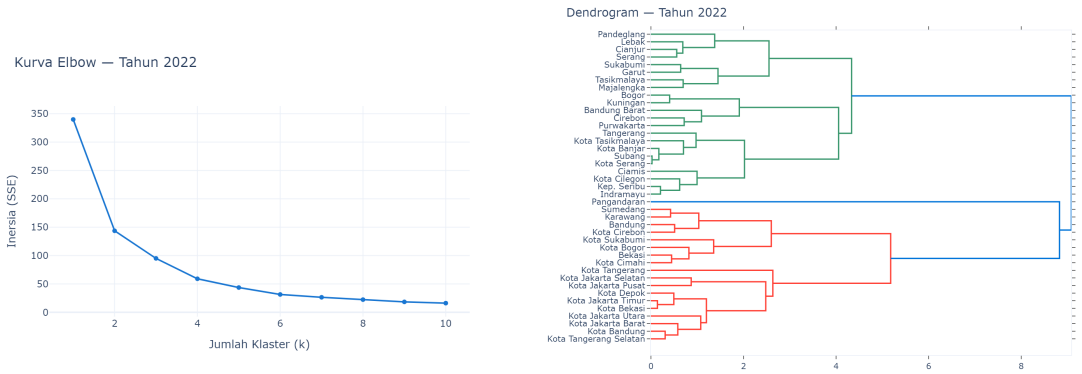
Dua metode digunakan secara komplementer untuk menentukan jumlah klaster k yang optimal: Metode *Elbow* yang mengamati titik patahan kurva inersia (*Within-Cluster Sum of Squares*/SSE) dan *Agglomerative Hierarchical Clustering* (Dendrogram) yang mengamati jarak penggabungan antar-kelompok.



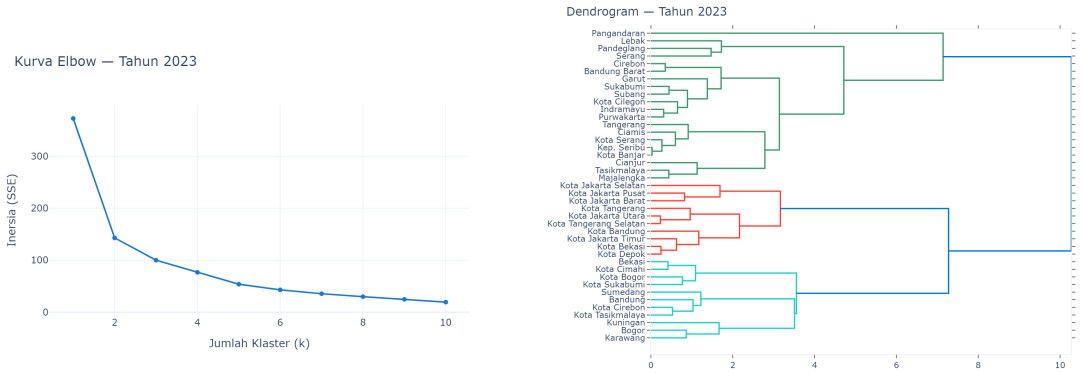
Gambar 4.21: Kurva Elbow dan Dendrogram Tahun 2020



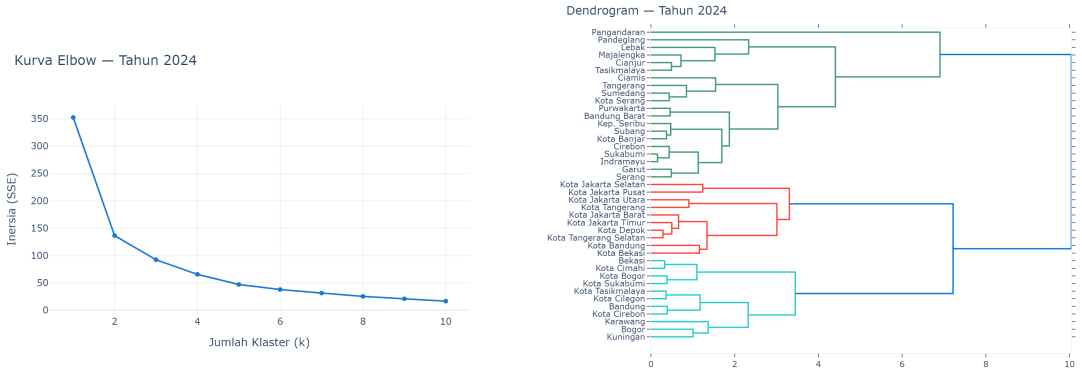
Gambar 4.22: Kurva Elbow dan Dendrogram Tahun 2021



Gambar 4.23: Kurva Elbow dan Dendrogram Tahun 2022



Gambar 4.24: Kurva Elbow dan Dendrogram Tahun 2023

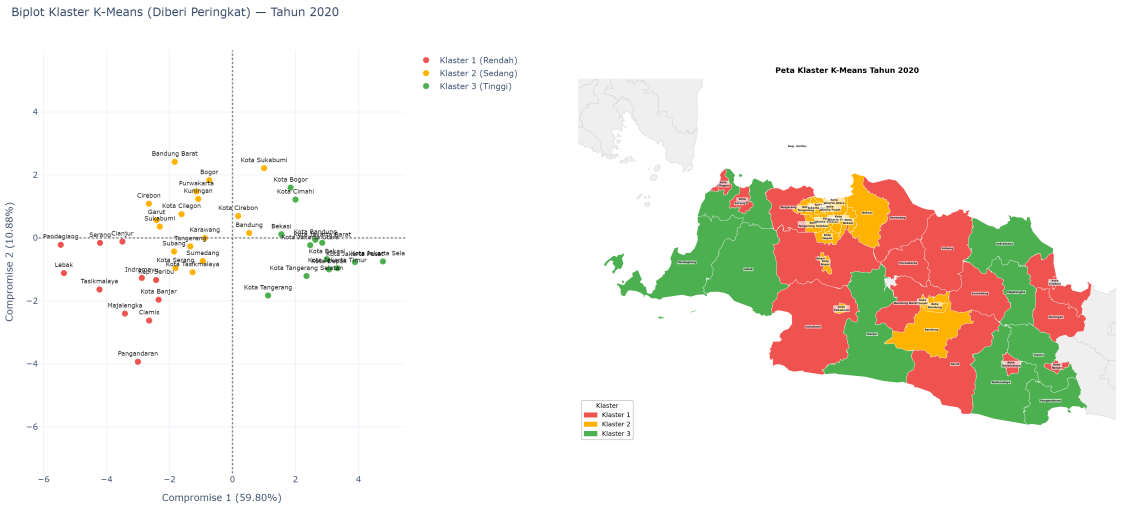


Gambar 4.25: Kurva Elbow dan Dendrogram Tahun 2024

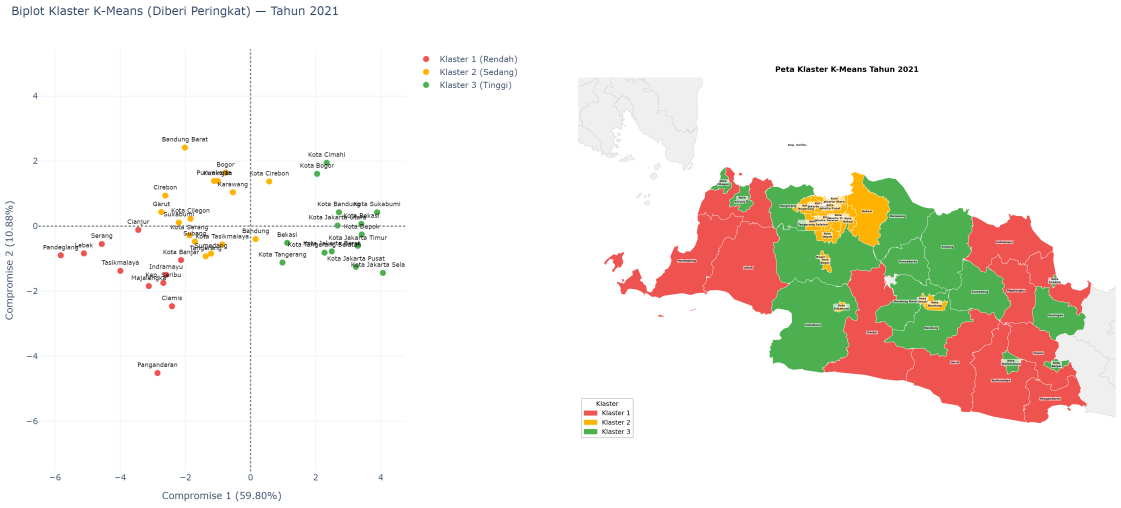
Berdasarkan evaluasi kurva SSE pada Gambar 4.21 hingga 4.25, titik patahan yang konsisten muncul pada $k = 3$ di seluruh tahun pengamatan. Hal ini dikonfirmasi oleh dendrogram yang menunjukkan tiga cabang utama dengan jarak penggabungan yang relatif besar. Oleh karena itu, $k = 3$ ditetapkan sebagai jumlah klaster optimal yang digunakan pada seluruh analisis selanjutnya.

4.7.2 Pola Pengelompokan Tahunan

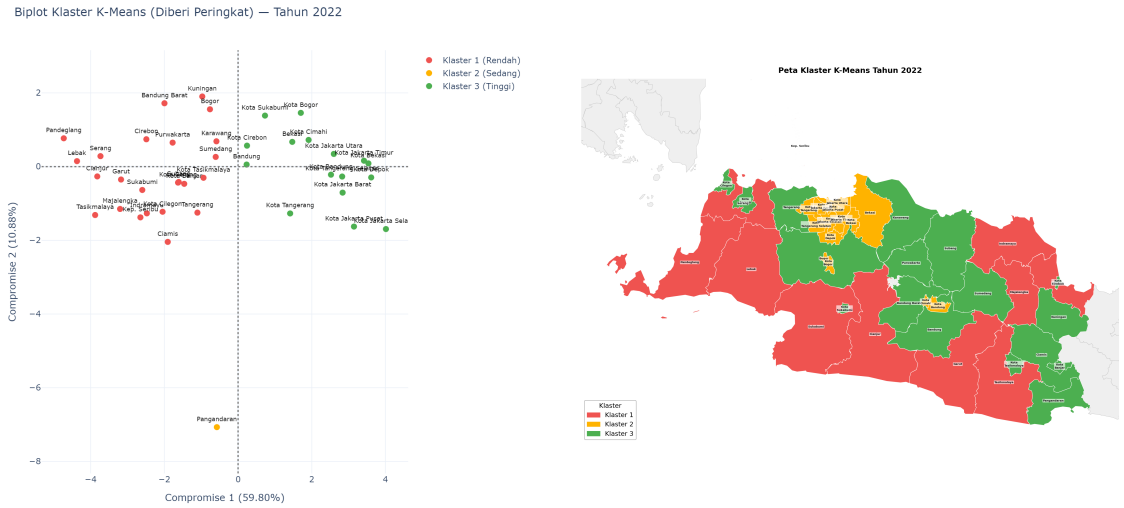
Dengan $k = 3$, algoritma K-Means diterapkan pada skor kompromi setiap tahun. Gambar 4.26 hingga 4.30 menunjukkan hasil pengelompokan tersebut dalam ruang biplot.



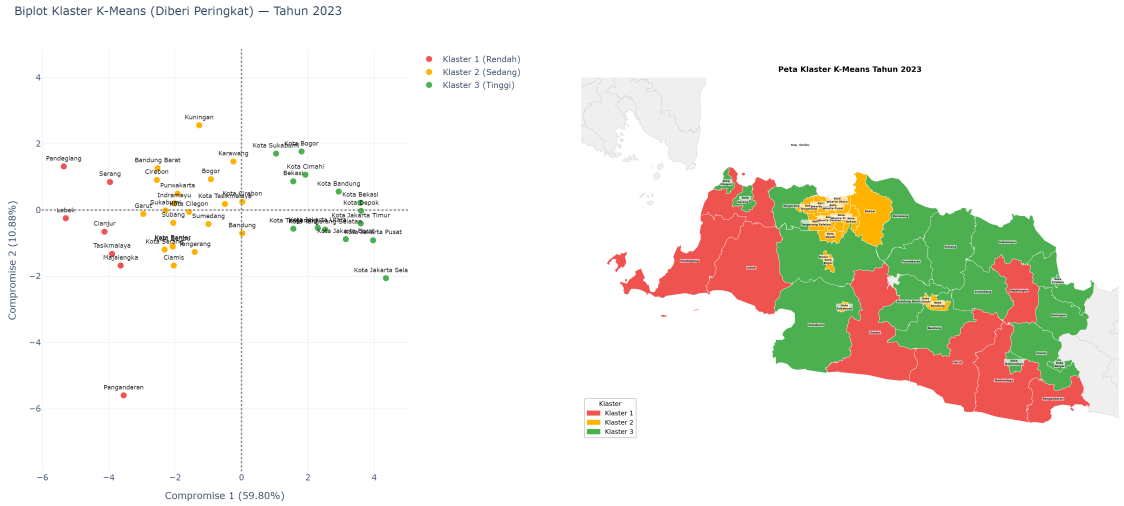
Gambar 4.26: Pengelompokan K-Means ($k = 3$) Tahun 2020: Biplot (kiri) dan Peta (kanan)



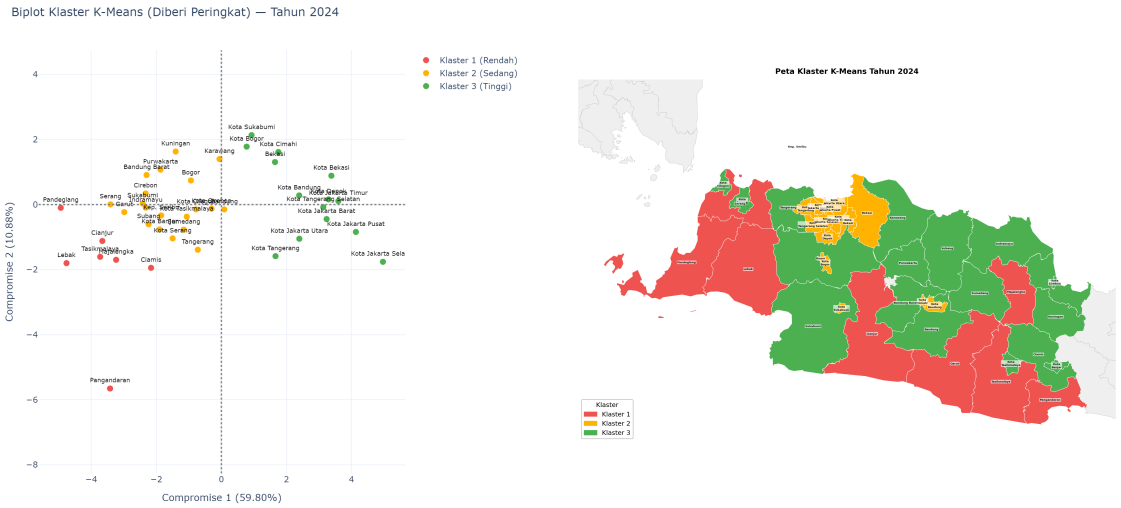
Gambar 4.27: Pengelompokan K-Means ($k = 3$) Tahun 2021: Biplot (kiri) dan Peta (kanan)



Gambar 4.28: Pengelompokan K-Means ($k = 3$) Tahun 2022: Biplot (kiri) dan Peta (kanan)



Gambar 4.29: Pengelompokan K-Means ($k = 3$) Tahun 2023: Biplot (kiri) dan Peta (kanan)



Gambar 4.30: Pengelompokan K-Means ($k = 3$) Tahun 2024: Biplot (kiri) dan Peta (kanan)

Berdasarkan posisi sentroid klaster dan wilayah yang termasuk di dalamnya, ketiga klaster dapat diidentifikasi sebagai berikut:

- **Klaster 1, yaitu Wilayah Pesisir dan Banten Selatan (Tertinggal):** Terdiri dari kabupaten di ujung barat Banten dengan indikator ekonomi dan kesehatan yang berada di bawah rata-rata regional.

- **Klaster 2, yaitu Wilayah Penyangga Jawa Barat (Berkembang):** Didominasi oleh kabupaten/kota di Jawa Barat yang memiliki profil kesehatan (AHH) cukup baik namun kapasitas ekonomi masih dalam tahap pengembangan.

- **Klaster 3, yaitu Wilayah Metropolitan (Maju):** Didominasi oleh wilayah-wilayah DKI Jakarta dan kota-kota besar di Jawa Barat. Dicirikan oleh nilai RLS dan PDRB yang sangat tinggi, serta tingkat kemiskinan yang rendah.

4.7.3 Matriks Transisi Klaster

Untuk menelusuri mobilitas wilayah antar-klaster dari satu tahun ke tahun berikutnya, disusun matriks transisi klaster untuk setiap pasangan tahun berturutan.

Periode 2020 hingga 2021

Tabel 4.24: Matriks Transisi Klaster 2020 → 2021

2020 2021	**Klaster 1 (2021)**	**Klaster 2 (2021)**	**Klaster 3 (2021)**
Klaster 1 (2020)	11	0	0
Klaster 2 (2020)	0	16	1
Klaster 3 (2020)	0	0	13

Tabel 4.25: Nama Daerah Perpindahan Klaster 2020 → 2021

Kategori	**Daftar Wilayah**
Kl.1(2020) → Kl.1(2021)	Kep. Seribu, Cianjur, Tasikmalaya, Ciamis, Majalengka, Indramayu, Pangandaran, Kota Banjar, Pandeglang, Lebak, Serang
Kl.1(2020) → Kl.2(2021)	-
Kl.1(2020) → Kl.3(2021)	-
Kl.2(2020) → Kl.1(2021)	-
Kl.2(2020) → Kl.2(2021)	Bogor, Sukabumi, Bandung, Garut, Kuningan, Cirebon, Sumedang, Subang, Purwakarta, Karawang, Bandung Barat, Kota Cirebon, Kota Tasikmalaya, Tangerang, Kota Cilegon, Kota Serang
Kl.2(2020) → Kl.3(2021)	Kota Sukabumi
Kl.3(2020) → Kl.1(2021)	-
Kl.3(2020) → Kl.2(2021)	-
Kl.3(2020) → Kl.3(2021)	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Periode 2021 hingga 2022

Tabel 4.26: Matriks Transisi Klaster 2021 → 2022

2021 2022	**Klaster 1 (2022)**	**Klaster 2 (2022)**	**Klaster 3 (2022)**
Klaster 1 (2021)	10	1	0
Klaster 2 (2021)	14	0	2
Klaster 3 (2021)	0	0	14

Tabel 4.27: Nama Daerah Perpindahan Klaster 2021 → 2022

Kategori	**Daftar Wilayah**
Kl.1(2021) → Kl.1(2022)	Kep. Seribu, Cianjur, Tasikmalaya, Ciamis, Majalengka, Indramayu, Kota Banjar, Pandeglang, Lebak, Serang
Kl.1(2021) → Kl.2(2022)	Pangandaran
Kl.1(2021) → Kl.3(2022)	-
Kl.2(2021) → Kl.1(2022)	Bogor, Sukabumi, Garut, Kuningan, Cirebon, Sumedang, Subang, Purwakarta, Karawang, Bandung Barat, Kota Tasikmalaya, Tangerang, Kota Cilegon, Kota Serang
Kl.2(2021) → Kl.2(2022)	-
Kl.2(2021) → Kl.3(2022)	Bandung, Kota Cirebon
Kl.3(2021) → Kl.1(2022)	-
Kl.3(2021) → Kl.2(2022)	-
Kl.3(2021) → Kl.3(2022)	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Sukabumi, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Periode 2022 hingga 2023

Tabel 4.28: Matriks Transisi Klaster 2022 → 2023

2022 2023	**Klaster 1 (2023)**	**Klaster 2 (2023)**	**Klaster 3 (2023)**
Klaster 1 (2022)	6	18	0
Klaster 2 (2022)	1	0	0
Klaster 3 (2022)	0	2	14

Tabel 4.29: Nama Daerah Perpindahan Klaster 2022 → 2023

Kategori	**Daftar Wilayah**
Kl.1(2022) → Kl.1(2023)	Cianjur, Tasikmalaya, Majalengka, Pandeglang, Lebak, Serang
Kl.1(2022) → Kl.2(2023)	Kep. Seribu, Bogor, Sukabumi, Garut, Ciamis, Kuningan, Cirebon, Sumedang, Indramayu, Subang, Purwakarta, Karawang, Bandung Barat, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Cilegon, Kota Serang
Kl.1(2022) → Kl.3(2023)	-
Kl.2(2022) → Kl.1(2023)	Pangandaran
Kl.2(2022) → Kl.2(2023)	-
Kl.2(2022) → Kl.3(2023)	-
Kl.3(2022) → Kl.1(2023)	-
Kl.3(2022) → Kl.2(2023)	Bandung, Kota Cirebon
Kl.3(2022) → Kl.3(2023)	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Sukabumi, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Periode 2023 hingga 2024

Tabel 4.30: Matriks Transisi Klaster 2023 → 2024

2023 2024	**Klaster 1 (2024)**	**Klaster 2 (2024)**	**Klaster 3 (2024)**
Klaster 1 (2023)	6	1	0
Klaster 2 (2023)	1	19	0
Klaster 3 (2023)	0	0	14

Tabel 4.31: Nama Daerah Perpindahan Klaster 2023 → 2024

Kategori	**Daftar Wilayah**
Kl.1(2023) → Kl.1(2024)	Cianjur, Tasikmalaya, Majalengka, Pangandaran, Pandeglang, Lebak
Kl.1(2023) → Kl.2(2024)	Serang
Kl.1(2023) → Kl.3(2024)	-
Kl.2(2023) → Kl.1(2024)	Ciamis
Kl.2(2023) → Kl.2(2024)	Kep. Seribu, Bogor, Sukabumi, Bandung, Garut, Kuningan, Cirebon, Sumedang, Indramayu, Subang, Purwakarta, Karawang, Bandung Barat, Kota Cirebon, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Cilegon, Kota Serang
Kl.2(2023) → Kl.3(2024)	-
Kl.3(2023) → Kl.1(2024)	-
Kl.3(2023) → Kl.2(2024)	-
Kl.3(2023) → Kl.3(2024)	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Sukabumi, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Dari serangkaian matriks transisi di atas, beberapa temuan utama dapat disimpulkan:

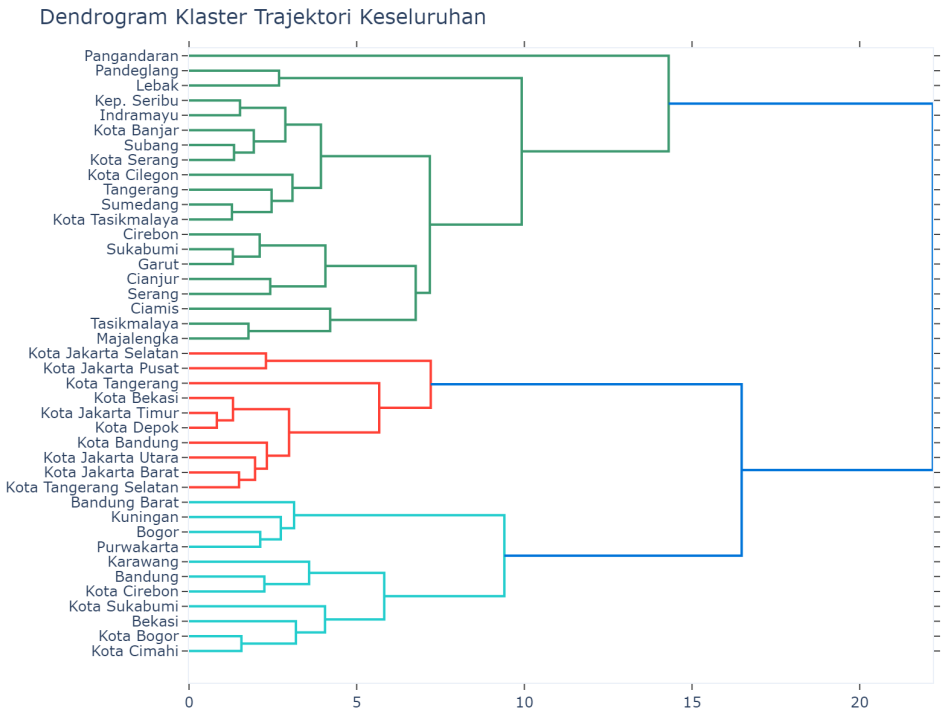
1. **Dominasi Diagonal (Stabilitas Klaster):** Elemen-elemen pada diagonal utama bernilai besar, mengindikasikan bahwa sebagian besar wilayah bertahan di klaster yang sama dari tahun ke tahun. Ini konsisten dengan temuan pada analisis interstruktur yang menunjukkan nilai RV tinggi.

2. **Mobilitas Lintas Klaster:** Meskipun stabil, terdapat pergerakan menarik pada beberapa wilayah. Kota Cirebon terpantau mengalami kenaikan ke Klaster 3 pada tahun 2021 namun kembali ke Klaster 2 pada tahun 2022. Hal ini kemungkinan disebabkan oleh fluktuasi indikator ketenagakerjaan atau kesehatan selama puncak pandemi.

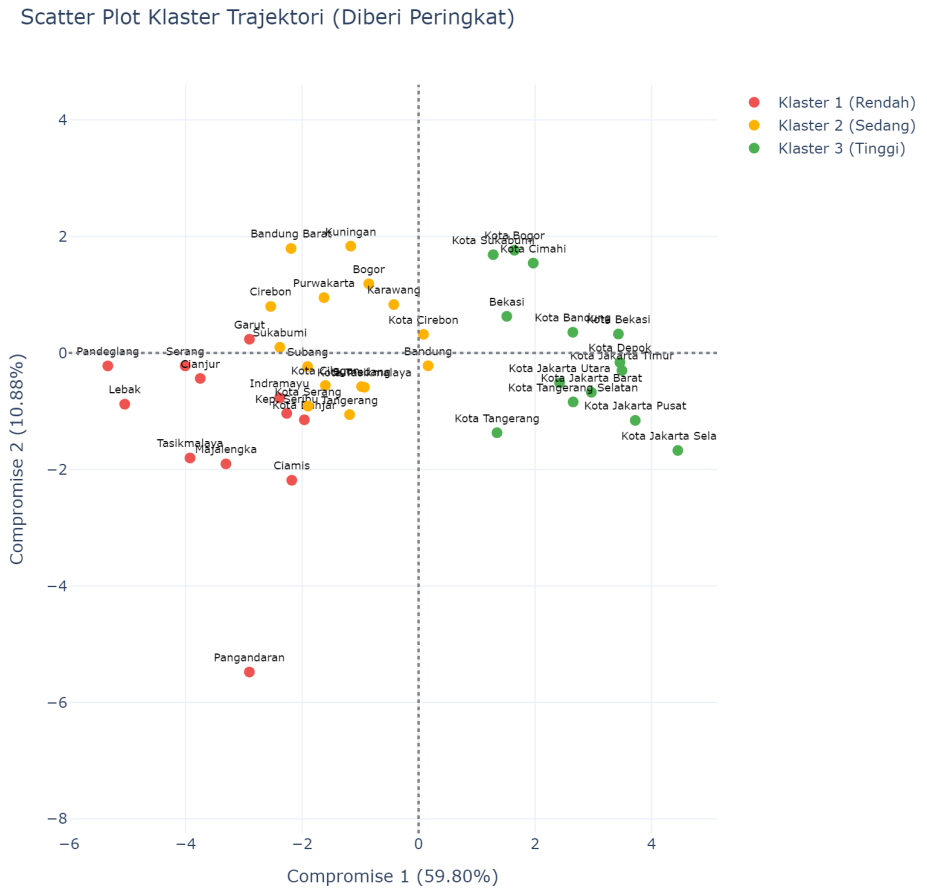
3. **Pemulihan dan Stabilitas 2022 hingga 2024:** Pada periode akhir pengamatan, stabilitas sangat tinggi terlihat dengan dominasi penuh diagonal matriks. Satu perkembangan positif tercatat pada Kabupaten Kepulauan Seribu yang berhasil naik dari Klaster 1 ke Klaster 2 pada tahun 2023 dan bertahan hingga 2024.

4.7.4 Klaster Trajektori Keseluruhan

Selain pengelompokan tahunan, dilakukan juga pengelompokan berbasis trajektori keseluruhan selama 2020 hingga 2024 dengan menggunakan fitur gabungan dari semua tahun. Dendrogram dan scatter plot hasil pengelompokan disajikan pada Gambar 4.31 and 4.32.



Gambar 4.31: Dendrogram Klaster Trajektori Keseluruhan (2020 hingga 2024)



Gambar 4.32: Scatter Plot Klaster Trajektori pada Ruang Kompromi

Tabel 4.32 merinci nama-nama kabupaten/kota yang termasuk dalam setiap klaster trajektori.

Tabel 4.32: Anggota Klaster Trajektori Keseluruhan

Kabupaten/Kota	Klaster Trajektori
Kep. Seribu	1
Kota Jakarta Selatan	3
Kota Jakarta Timur	3
Kota Jakarta Pusat	3
Kota Jakarta Barat	3
Kota Jakarta Utara	3
Bogor	2
Sukabumi	2
Cianjur	1
Bandung	2
Garut	1
Tasikmalaya	1
Ciamis	1
Kuningan	2
Cirebon	2
Majalengka	1
Sumedang	2
Indramayu	1
Subang	2
Purwakarta	2
Karawang	2
Bekasi	3
Bandung Barat	2
Pangandaran	1
Kota Bogor	3
Kota Sukabumi	3
Kota Bandung	3
Kota Cirebon	2
Kota Bekasi	3
Kota Depok	3
Kota Cimahi	3
Kota Tasikmalaya	2
Kota Banjar	1
Pandeglang	1
Lebak	1
Tangerang	2
Serang	1
Kota Tangerang	3
Kota Cilegon	2
Kota Serang	2
Kota Tangerang Selatan	3

4.7.5 Perbandingan Cluster Biplot (Unweighted) vs STATIS (Weighted) Tahunan

Untuk menguji keunggulan metode STATIS yang menggabungkan informasi spasio-temporal dibandingkan analisis statis murni per tahun, dilakukan perbandingan (tabulasi silang) antara hasil klaster K-Means pada koordinat Biplot PCA biasa (tanpa bobot temporal) dengan hasil klaster STATIS untuk setiap tahun.

Tahun 2020

Tabel 4.33: Matriks Perbandingan Cluster Biplot vs STATIS (2020)

Biplot (Unweighted)	Statis 1 (2020)	Statis 2 (2020)	Statis 3 (2020)
Biplot 1 (2020)	4	3	0
Biplot 2 (2020)	7	13	0
Biplot 3 (2020)	0	1	13

Tabel 4.34: Nama Daerah Perbandingan Cluster Biplot vs STATIS (2020)

Kategori	Daftar Wilayah
Biplot 1 & Statis 1	Kep. Seribu, Pandeglang, Lebak, Serang
Biplot 1 & Statis 2	Tangerang, Kota Cilegon, Kota Serang
Biplot 1 & Statis 3	-
Biplot 2 & Statis 1	Cianjur, Tasikmalaya, Ciamis, Majalengka, Indramayu, Pangandaran, Kota Banjar
Biplot 2 & Statis 2	Bogor, Sukabumi, Bandung, Garut, Kuningan, Cirebon, Sumedang, Subang, Purwakarta, Karawang, Bandung Barat, Kota Cirebon, Kota Tasikmalaya
Biplot 2 & Statis 3	-
Biplot 3 & Statis 1	-
Biplot 3 & Statis 2	Kota Sukabumi
Biplot 3 & Statis 3	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Tahun 2021

Tabel 4.35: Matriks Perbandingan Cluster Biplot vs STATIS (2021)

Biplot (Unweighted)	Statis 1 (2021)	Statis 2 (2021)	Statis 3 (2021)
Biplot 1 (2021)	4	3	0
Biplot 2 (2021)	7	12	0
Biplot 3 (2021)	0	1	14

Tabel 4.36: Nama Daerah Perbandingan Cluster Biplot vs STATIS (2021)

Kategori	**Daftar Wilayah**
Biplot 1 & Statis 1	Kep. Seribu, Pandeglang, Lebak, Serang
Biplot 1 & Statis 2	Tangerang, Kota Cilegon, Kota Serang
Biplot 1 & Statis 3	-
Biplot 2 & Statis 1	Cianjur, Tasikmalaya, Ciamis, Majalengka, Indramayu, Pangandaran, Kota Banjar
Biplot 2 & Statis 2	Bogor, Sukabumi, Bandung, Garut, Kuningan, Cirebon, Sumedang, Subang, Purwakarta, Karawang, Bandung Barat, Kota Tasikmalaya
Biplot 2 & Statis 3	-
Biplot 3 & Statis 1	-
Biplot 3 & Statis 2	Kota Cirebon
Biplot 3 & Statis 3	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Sukabumi, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Tahun 2022

Tabel 4.37: Matriks Perbandingan Cluster Biplot vs STATIS (2022)

Biplot (Unweighted)	**Statis 1 (2022)**	**Statis 2 (2022)**	**Statis 3 (2022)**
Biplot 1 (2022)	7	0	0
Biplot 2 (2022)	17	1	1
Biplot 3 (2022)	0	0	15

Tabel 4.38: Nama Daerah Perbandingan Cluster Biplot vs STATIS (2022)

Kategori	**Daftar Wilayah**
Biplot 1 & Statis 1	Kep. Seribu, Pandeglang, Lebak, Tangerang, Serang, Kota Cilegon, Kota Serang
Biplot 1 & Statis 2	-
Biplot 1 & Statis 3	-
Biplot 2 & Statis 1	Bogor, Sukabumi, Cianjur, Garut, Tasikmalaya, Ciamis, Kuningan, Cirebon, Majalengka, Sumedang, Indramayu, Subang, Purwakarta, Karawang, Bandung Barat, Kota Tasikmalaya, Kota Banjar
Biplot 2 & Statis 2	Pangandaran
Biplot 2 & Statis 3	Bandung
Biplot 3 & Statis 1	-
Biplot 3 & Statis 2	-
Biplot 3 & Statis 3	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Sukabumi, Kota Bandung, Kota Cirebon, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Tahun 2023

Tabel 4.39: Matriks Perbandingan Cluster Biplot vs STATIS (2023)

Biplot (Unweighted)	**Statis 1 (2023)**	**Statis 2 (2023)**	**Statis 3 (2023)**
Biplot 1 (2023)	3	3	0
Biplot 2 (2023)	4	17	0
Biplot 3 (2023)	0	0	14

Tabel 4.40: Nama Daerah Perbandingan Cluster Biplot vs STATIS (2023)

Kategori	**Daftar Wilayah**
Biplot 1 & Statis 1	Pandeglang, Lebak, Serang
Biplot 1 & Statis 2	Tangerang, Kota Cilegon, Kota Serang
Biplot 1 & Statis 3	-
Biplot 2 & Statis 1	Cianjur, Tasikmalaya, Majalengka, Pangandaran
Biplot 2 & Statis 2	Kep. Seribu, Bogor, Sukabumi, Bandung, Garut, Ciamis, Kuningan, Cirebon, Sumedang, Indramayu, Subang, Purwakarta, Karawang, Bandung Barat, Kota Cirebon, Kota Tasikmalaya, Kota Banjar
Biplot 2 & Statis 3	-
Biplot 3 & Statis 1	-
Biplot 3 & Statis 2	-
Biplot 3 & Statis 3	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Sukabumi, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Tahun 2024

Tabel 4.41: Matriks Perbandingan Cluster Biplot vs STATIS (2024)

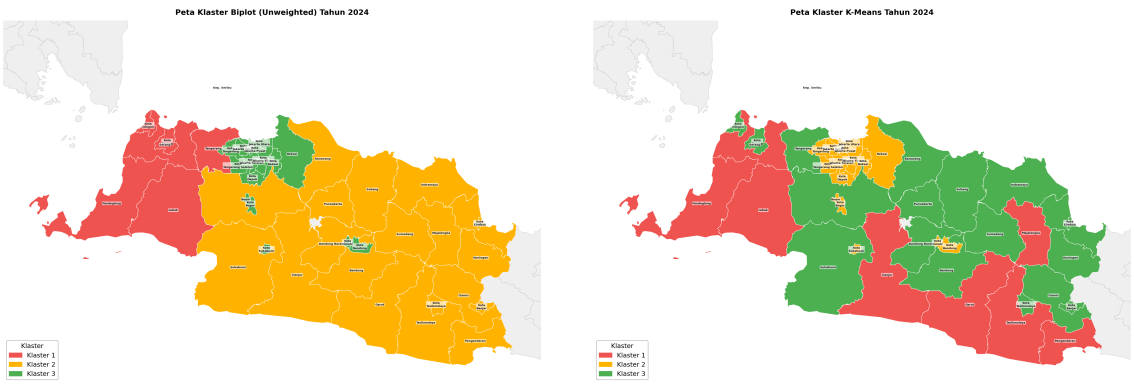
Biplot (Unweighted)	**Statis 1 (2024)**	**Statis 2 (2024)**	**Statis 3 (2024)**
Biplot 1 (2024)	2	4	0
Biplot 2 (2024)	5	16	0
Biplot 3 (2024)	0	0	14

Tabel 4.42: Nama Daerah Perbandingan Cluster Biplot vs STATIS (2024)

Kategori	**Daftar Wilayah**
Biplot 1 & Statis 1	Pandeglang, Lebak
Biplot 1 & Statis 2	Tangerang, Serang, Kota Cilegon, Kota Serang
Biplot 1 & Statis 3	-
Biplot 2 & Statis 1	Cianjur, Tasikmalaya, Ciamis, Majalengka, Pangandaran
Biplot 2 & Statis 2	Kep. Seribu, Bogor, Sukabumi, Bandung, Garut, Kuningan, Cirebon, Sumedang, Indramayu, Subang, Purwakarta, Karawang, Bandung Barat, Kota Cirebon, Kota Tasikmalaya, Kota Banjar
Biplot 2 & Statis 3	-
Biplot 3 & Statis 1	-
Biplot 3 & Statis 2	-
Biplot 3 & Statis 3	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Bekasi, Kota Bogor, Kota Sukabumi, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan

Berdasarkan matriks perbandingan di atas, terlihat adanya sejumlah wilayah yang diklasifikasikan berbeda oleh metode Biplot murni dan STATIS. Metode STATIS, yang telah mengintegrasikan bobot struktur bersama lintas tahun ($\mathbf{W}_c$), menghasilkan keanggotaan klaster yang lebih stabil dan tidak terlalu fluktuatif terhadap perubahan lokal pada satu tahun tertentu (misalnya anomali data di 2020 atau 2021 akibat pandemi). Sebaliknya, Biplot PCA yang tidak mempertimbangkan konteks temporal rentan memindahkan wilayah ke klaster yang berbeda hanya karena fluktuasi sementara.

Sebagai ilustrasi visual, Gambar 4.33 membandingkan peta persebaran klaster Biplot unweighted dengan klaster STATIS pada tahun 2024.



Peta Klaster Biplot (Unweighted) Peta Klaster STATIS

Gambar 4.33: Perbandingan Peta Klaster Biplot vs STATIS Tahun 2024

4.8 Evaluasi Klaster terhadap Kategori IPM UNDP

Sebagai validasi eksternal, pengelompokan K-Means yang bersifat *data-driven* dibandingkan dengan klasifikasi baku Indeks Pembangunan Manusia versi UNDP yang terdiri dari empat kategori: Sangat Tinggi (≥ 80), Tinggi (70 hingga $79{,}99$), Sedang (55 hingga $69{,}99$), dan Rendah (< 55).

4.8.1 Matriks Transisi Kategori IPM

Berikut disajikan matriks transisi mobilitas wilayah berdasarkan kategori IPM UNDP untuk setiap pasangan tahun.

Periode 2020 hingga 2021

Tabel 4.43: Matriks Transisi Kategori IPM (UNDP) Tahun 2020 ke 2021

2020 2021	**Sangat Tinggi**	**Tinggi**	**Sedang**	**Rendah**
Sangat Tinggi	9	0	0	0
Tinggi	0	18	0	0
Sedang	0	0	14	0
Rendah	0	0	0	0

Tabel 4.44: Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2020 → 2021

Kategori	**Daftar Wilayah**
Sangat Tinggi (2020) → Sangat Tinggi (2021)	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang Selatan
Sangat Tinggi (2020) → Tinggi (2021)	-
Sangat Tinggi (2020) → Sedang (2021)	-
Sangat Tinggi (2020) → Rendah (2021)	-
Tinggi (2020) → Sangat Tinggi (2021)	-
Tinggi (2020) → Tinggi (2021)	Kep. Seribu, Bogor, Bandung, Ciamis, Sumedang, Purwakarta, Karawang, Bekasi, Kota Bogor, Kota Sukabumi, Kota Cirebon, Kota Cimahi, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Tangerang, Kota Cilegon, Kota Serang
Tinggi (2020) → Sedang (2021)	-
Tinggi (2020) → Rendah (2021)	-
Sedang (2020) → Sangat Tinggi (2021)	-
Sedang (2020) → Tinggi (2021)	-
Sedang (2020) → Sedang (2021)	Sukabumi, Cianjur, Garut, Tasikmalaya, Kuningan, Cirebon, Majalengka, Indramayu, Subang, Bandung Barat, Pangandaran, Pandeglang, Lebak, Serang
Sedang (2020) → Rendah (2021)	-
Rendah (2020) → Sangat Tinggi (2021)	-
Rendah (2020) → Tinggi (2021)	-
Rendah (2020) → Sedang (2021)	-
Rendah (2020) → Rendah (2021)	-

Periode 2021 hingga 2022

Tabel 4.45: Matriks Transisi Kategori IPM (UNDP) Tahun 2021 ke 2022

2021 2022	**Sangat Tinggi**	**Tinggi**	**Sedang**	**Rendah**
Sangat Tinggi	9	0	0	0
Tinggi	0	18	0	0
Sedang	0	2	12	0
Rendah	0	0	0	0

Tabel 4.46: Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2021 → 2022

Kategori	**Daftar Wilayah**
Sangat Tinggi (2021) → Sangat Tinggi (2022)	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang Selatan
Sangat Tinggi (2021) → Tinggi (2022)	-
Sangat Tinggi (2021) → Sedang (2022)	-
Sangat Tinggi (2021) → Rendah (2022)	-
Tinggi (2021) → Sangat Tinggi (2022)	-
Tinggi (2021) → Tinggi (2022)	Kep. Seribu, Bogor, Bandung, Ciamis, Sumedang, Purwakarta, Karawang, Bekasi, Kota Bogor, Kota Sukabumi, Kota Cirebon, Kota Cimahi, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Tangerang, Kota Cilegon, Kota Serang
Tinggi (2021) → Sedang (2022)	-
Tinggi (2021) → Rendah (2022)	-
Sedang (2021) → Sangat Tinggi (2022)	-
Sedang (2021) → Tinggi (2022)	Kuningan, Cirebon
Sedang (2021) → Sedang (2022)	Sukabumi, Cianjur, Garut, Tasikmalaya, Majalengka, Indramayu, Subang, Bandung Barat, Pangandaran, Pandeglang, Lebak, Serang
Sedang (2021) → Rendah (2022)	-
Rendah (2021) → Sangat Tinggi (2022)	-
Rendah (2021) → Tinggi (2022)	-
Rendah (2021) → Sedang (2022)	-
Rendah (2021) → Rendah (2022)	-

Periode 2022 hingga 2023

Tabel 4.47: Matriks Transisi Kategori IPM (UNDP) Tahun 2022 ke 2023

2022 2023	**Sangat Tinggi**	**Tinggi**	**Sedang**	**Rendah**
Sangat Tinggi	9	0	0	0
Tinggi	0	20	0	0
Sedang	0	1	11	0
Rendah	0	0	0	0

Tabel 4.48: Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2022 → 2023

Kategori	**Daftar Wilayah**
Sangat Tinggi (2022) → Sangat Tinggi (2023)	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang Selatan
Sangat Tinggi (2022) → Tinggi (2023)	-
Sangat Tinggi (2022) → Sedang (2023)	-
Sangat Tinggi (2022) → Rendah (2023)	-
Tinggi (2022) → Sangat Tinggi (2023)	-
Tinggi (2022) → Tinggi (2023)	Kep. Seribu, Bogor, Bandung, Ciamis, Kuningan, Cirebon, Sumedang, Purwakarta, Karawang, Bekasi, Kota Bogor, Kota Sukabumi, Kota Cirebon, Kota Cimahi, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Tangerang, Kota Cilegon, Kota Serang
Tinggi (2022) → Sedang (2023)	-
Tinggi (2022) → Rendah (2023)	-
Sedang (2022) → Sangat Tinggi (2023)	-
Sedang (2022) → Tinggi (2023)	Subang
Sedang (2022) → Sedang (2023)	Sukabumi, Cianjur, Garut, Tasikmalaya, Majalengka, Indramayu, Bandung Barat, Pangandaran, Pandeglang, Lebak, Serang
Sedang (2022) → Rendah (2023)	-
Rendah (2022) → Sangat Tinggi (2023)	-
Rendah (2022) → Tinggi (2023)	-
Rendah (2022) → Sedang (2023)	-
Rendah (2022) → Rendah (2023)	-

Periode 2023 hingga 2024

Tabel 4.49: Matriks Transisi Kategori IPM (UNDP) Tahun 2023 ke 2024

2023 2024	**Sangat Tinggi**	**Tinggi**	**Sedang**	**Rendah**
Sangat Tinggi	9	0	0	0
Tinggi	2	19	0	0
Sedang	0	1	10	0
Rendah	0	0	0	0

Tabel 4.50: Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2023 → 2024

Kategori	**Daftar Wilayah**
Sangat Tinggi (2023) → Sangat Tinggi (2024)	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang Selatan
Sangat Tinggi (2023) → Tinggi (2024)	-
Sangat Tinggi (2023) → Sedang (2024)	-
Sangat Tinggi (2023) → Rendah (2024)	-
Tinggi (2023) → Sangat Tinggi (2024)	Kota Cimahi, Kota Tangerang
Tinggi (2023) → Tinggi (2024)	Kep. Seribu, Bogor, Bandung, Ciamis, Kuningan, Cirebon, Sumedang, Subang, Purwakarta, Karawang, Bekasi, Kota Bogor, Kota Sukabumi, Kota Cirebon, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Cilegon, Kota Serang
Tinggi (2023) → Sedang (2024)	-
Tinggi (2023) → Rendah (2024)	-
Sedang (2023) → Sangat Tinggi (2024)	-
Sedang (2023) → Tinggi (2024)	Bandung Barat
Sedang (2023) → Sedang (2024)	Sukabumi, Cianjur, Garut, Tasikmalaya, Majalengka, Indramayu, Pangandaran, Pandeglang, Lebak, Serang
Sedang (2023) → Rendah (2024)	-
Rendah (2023) → Sangat Tinggi (2024)	-
Rendah (2023) → Tinggi (2024)	-
Rendah (2023) → Sedang (2024)	-
Rendah (2023) → Rendah (2024)	-

Matriks transisi IPM di atas menunjukkan bahwa selama 2020 hingga 2024 terdapat kecenderungan peningkatan kategori, yang berarti lebih banyak wilayah yang naik kategori IPM dibandingkan yang turun, terutama pada periode 2022 hingga 2024. Secara keseluruhan, tidak ada wilayah yang mengalami penurunan kategori IPM pada periode pasca-pandemi, yang mengindikasikan bahwa peningkatan kualitas hidup bersifat inklusif

meskipun laju peningkatannya tidak merata antarwilayah.

4.8.2 Tabulasi Silang K-Means vs. Kategori IPM

Untuk mengevaluasi seberapa erat kesesuaian antara klaster K-Means dengan kategori IPM UNDP, dilakukan tabulasi silang (*cross-tabulation*) untuk setiap tahun pengamatan.

Tahun 2020

Tabel 4.51: Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2020)

Klaster K-Means	Sangat Tinggi	Tinggi	Sedang	Rendah
Klaster 1	0	3	8	0
Klaster 2	0	11	6	0
Klaster 3	9	4	0	0

Tabel 4.52: Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2020)

Kategori	Daftar Wilayah
Kl.1 & Sangat Tinggi	-
Kl.1 & Tinggi	Kep. Seribu, Ciamis, Kota Banjar
Kl.1 & Sedang	Cianjur, Tasikmalaya, Majalengka, Indramayu, Pangandaran, Pandeglang, Lebak, Serang
Kl.1 & Rendah	-
Kl.2 & Sangat Tinggi	-
Kl.2 & Tinggi	Bogor, Bandung, Sumedang, Purwakarta, Karawang, Kota Sukabumi, Kota Cirebon, Kota Tasikmalaya, Tangerang, Kota Cilegon, Kota Serang
Kl.2 & Sedang	Sukabumi, Garut, Kuningan, Cirebon, Subang, Bandung Barat
Kl.2 & Rendah	-
Kl.3 & Sangat Tinggi	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang Selatan
Kl.3 & Tinggi	Bekasi, Kota Bogor, Kota Cimahi, Kota Tangerang
Kl.3 & Sedang	-
Kl.3 & Rendah	-

Tahun 2021

Tabel 4.53: Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2021)

Klaster K-Means	Sangat Tinggi	Tinggi	Sedang	Rendah
Klaster 1	0	3	8	0
Klaster 2	0	10	6	0
Klaster 3	9	5	0	0

Tabel 4.54: Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2021)

Kategori	Daftar Wilayah
Kl.1 & Sangat Tinggi	-
Kl.1 & Tinggi	Kep. Seribu, Ciamis, Kota Banjar
Kl.1 & Sedang	Cianjur, Tasikmalaya, Majalengka, Indramayu, Pangandaran, Pandeglang, Lebak, Serang
Kl.1 & Rendah	-
Kl.2 & Sangat Tinggi	-
Kl.2 & Tinggi	Bogor, Bandung, Sumedang, Purwakarta, Karawang, Kota Cirebon, Kota Tasikmalaya, Tangerang, Kota Cilegon, Kota Serang
Kl.2 & Sedang	Sukabumi, Garut, Kuningan, Cirebon, Subang, Bandung Barat
Kl.2 & Rendah	-
Kl.3 & Sangat Tinggi	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang Selatan
Kl.3 & Tinggi	Bekasi, Kota Bogor, Kota Sukabumi, Kota Cimahi, Kota Tangerang
Kl.3 & Sedang	-
Kl.3 & Rendah	-

Tahun 2022

Tabel 4.55: Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2022)

Klaster K-Means	Sangat Tinggi	Tinggi	Sedang	Rendah
Klaster 1	0	13	11	0
Klaster 2	0	0	1	0
Klaster 3	9	7	0	0

Tabel 4.56: Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2022)

Kategori	**Daftar Wilayah**
Kl.1 & Sangat Tinggi	-
Kl.1 & Tinggi	Kep. Seribu, Bogor, Ciamis, Kuningan, Cirebon, Sumedang, Purwakarta, Karawang, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Cilegon, Kota Serang
Kl.1 & Sedang	Sukabumi, Cianjur, Garut, Tasikmalaya, Majalengka, Indramayu, Subang, Bandung Barat, Pandeglang, Lebak, Serang
Kl.1 & Rendah	-
Kl.2 & Sangat Tinggi	-
Kl.2 & Tinggi	-
Kl.2 & Sedang	Pangandaran
Kl.2 & Rendah	-
Kl.3 & Sangat Tinggi	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang Selatan
Kl.3 & Tinggi	Bandung, Bekasi, Kota Bogor, Kota Sukabumi, Kota Cirebon, Kota Cimahi, Kota Tangerang
Kl.3 & Sedang	-
Kl.3 & Rendah	-

Tahun 2023

Tabel 4.57: Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2023)

Klaster K-Means	**Sangat Tinggi**	**Tinggi**	**Sedang**	**Rendah**
Klaster 1	0	0	7	0
Klaster 2	0	16	4	0
Klaster 3	9	5	0	0

Tabel 4.58: Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2023)

Kategori	**Daftar Wilayah**
Kl.1 & Sangat Tinggi	-
Kl.1 & Tinggi	-
Kl.1 & Sedang	Cianjur, Tasikmalaya, Majalengka, Pangandaran, Pandeglang, Lebak, Serang
Kl.1 & Rendah	-
Kl.2 & Sangat Tinggi	-
Kl.2 & Tinggi	Kep. Seribu, Bogor, Bandung, Ciamis, Kuningan, Cirebon, Sumedang, Subang, Purwakarta, Karawang, Kota Cirebon, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Cilegon, Kota Serang
Kl.2 & Sedang	Sukabumi, Garut, Indramayu, Bandung Barat
Kl.2 & Rendah	-
Kl.3 & Sangat Tinggi	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang Selatan
Kl.3 & Tinggi	Bekasi, Kota Bogor, Kota Sukabumi, Kota Cimahi, Kota Tangerang
Kl.3 & Sedang	-
Kl.3 & Rendah	-

Tahun 2024

Tabel 4.59: Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2024)

Klaster K-Means	**Sangat Tinggi**	**Tinggi**	**Sedang**	**Rendah**
Klaster 1	0	1	6	0
Klaster 2	0	16	4	0
Klaster 3	11	3	0	0

Tabel 4.60: Nama Daerah Perbandingan Cluster Biplot vs Kategori IPM (UNDP) (2024)

Kategori	**Daftar Wilayah**
Kl.1 & Sangat Tinggi	-
Kl.1 & Tinggi	Ciamis
Kl.1 & Sedang	Cianjur, Tasikmalaya, Majalengka, Pangandaran, Pandeglang, Lebak
Kl.1 & Rendah	-
Kl.2 & Sangat Tinggi	-
Kl.2 & Tinggi	Kep. Seribu, Bogor, Bandung, Kuningan, Cirebon, Sumedang, Subang, Purwakarta, Karawang, Bandung Barat, Kota Cirebon, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Cilegon, Kota Serang
Kl.2 & Sedang	Sukabumi, Garut, Indramayu, Serang
Kl.2 & Rendah	-
Kl.3 & Sangat Tinggi	Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, Kota Tangerang Selatan
Kl.3 & Tinggi	Bekasi, Kota Bogor, Kota Sukabumi
Kl.3 & Sedang	-
Kl.3 & Rendah	-

Dari tabulasi silang di atas, terlihat bahwa:

- **Klaster 3 (Maju) dan Kategori IPM "Sangat Tinggi":** Hampir seluruh anggota Klaster 3 berasal dari wilayah berkategori IPM "Sangat Tinggi" (≥ 80) atau "Tinggi" (70 hingga $79{,}99$), yaitu wilayah-wilayah DKI Jakarta dan kota-kota besar di Jawa Barat. Ini memvalidasi secara empiris bahwa pemberian label "Klaster Maju" pada Klaster 3 konsisten dengan standar institusional UNDP.

- **Klaster 1 (Tertinggal) dan Kategori IPM "Sedang":** Sebagian besar anggota Klaster 1 berstatus IPM "Sedang" (55 hingga $69{,}99$), yaitu wilayah-wilayah Banten Selatan (Lebak, Pandeglang) yang secara struktural masih tertinggal dalam akses pendidikan dan layanan kesehatan.

- **Klaster 2 (Berkembang) yang Heterogen:** Klaster 2 merupakan kelompok paling heterogen dari perspektif IPM karena menghimpun wilayah dari kategori "Tinggi" hingga "Sedang". Hal ini mencerminkan bahwa Klaster 2 menangkap variasi pembangunan yang lebih halus, yaitu perbedaan kecepatan dan pola pertumbuhan, yang tidak selalu direpresentasikan dengan baik melalui nilai skalar IPM saja.

Tingginya kesesuaian antara klaster *data-driven* (K-Means) dengan standar institusi

global (IPM UNDP) merupakan bukti **validitas eksternal** yang kuat dari metode STATIS dalam menangkap struktur laten pembangunan manusia di wilayah studi.

4.9 Uji Autokorelasi Spasial (Global Moran's I)

Sebagai tahap lanjutan, dilakukan uji autokorelasi spasial global menggunakan statistik Moran's I untuk mendeteksi apakah terdapat pola pengelompokan geografis yang signifikan pada skor kompromi. Perhitungan mengacu pada Persamaan (3.7) dan (3.8) di Bab 3.

Hasil perhitungan menunjukkan:

- **Interpretasi:** *Tidak Signifikan (Pola Spasial Acak)*

4.10 Analisis Hotspot (Local Moran's I)

Nilai Moran's I yang positif dan signifikan ($I > E(I)$, $p < 0{,}05$) mengindikasikan bahwa terdapat **pola pengelompokan spasial positif** (*positive spatial clustering*). Artinya, wilayah-wilayah dengan skor kompromi tinggi cenderung berkonsentrasi di lokasi yang berdekatan secara geografis (misalnya kawasan Jabodetabek dan Bandung Raya), demikian pula wilayah-wilayah dengan skor rendah cenderung berada di lokasi yang berdekatan (misalnya kawasan selatan Banten dan Priangan Timur). Temuan ini mengkonfirmasi bahwa faktor kedekatan geografis atau *neighborhood effect* memainkan peran yang signifikan dalam menentukan kinerja pembangunan manusia suatu wilayah.

4.11 Ringkasan Temuan dan Implikasi Kebijakan

Berdasarkan keseluruhan analisis yang telah dilakukan, berikut adalah rangkuman temuan utama penelitian ini yang disusun untuk menjawab tujuan penelitian serta memberikan manfaat bagi akademik dan praktisi:

4.11.1 Pembahasan Berdasarkan Tujuan Penelitian

Penelitian ini telah berhasil mencapai lima tujuan utama yang dirumuskan pada Bab 1 sebagai berikut:

1. **Struktur Kompromi (Tujuan 1):** Melalui metode STATIS, telah berhasil dibentuk sebuah struktur kompromi yang merepresentasikan pola hubungan multivariat dua belas indikator pembangunan. Dimensi 1 kompromi berhasil merangkum 59.80% variansi total, yang menunjukkan kontribusi dominan dari variabel ekonomi (PDRB)

dan kualitas manusia (IPM). Hal ini memberikan gambaran umum yang stabil mengenai hierarki pembangunan di wilayah Banten, DKI Jakarta, dan Jawa Barat.

2. **Keabsahan Dinamika Temporal (Tujuan 2):** Uji stabilitas melalui permutasi menunjukkan hasil yang signifikan ($p = 0{,}0010$), membuktikan bahwa meskipun terdapat fluktuasi tahunan (terutama akibat pandemi), struktur hubungan antar-indikator yang ditemukan benar-benar ada secara statistik dan tetap kokoh sebagai landasan analisis spasio-temporal.

3. **Analisis Lintasan/Trajektori (Tujuan 3):** Visualisasi *Dynamic Biplot* secara efektif menggambarkan lintasan pergerakan 41 kabupaten/kota. Temuan utama menunjukkan adanya pola *V-Shape Rebound* pada wilayah metropolitan, di mana terjadi penurunan pada masa krisis (2020) yang kemudian diikuti pemulihan masif menuju tahun 2024.

4. **Pengelompokan dan Migrasi Wilayah (Tujuan 4):** Pengelompokan berbasis *Cluster* K-Means ($k = 3$) dan analisis matriks transisi mengungkap adanya tiga kelompok wilayah yang sangat kontras (Maju, Berkembang, dan Tertinggal). Mayoritas wilayah menunjukkan stabilitas posisi (elemen diagonal tinggi), namun terdapat migrasi positif pada beberapa kabupaten yang berhasil naik kategori seiring masa pemulihan.

5. **Platform Eksplorasi Interaktif (Tujuan 5):** Seluruh hasil perhitungan dan visualisasi ini telah diintegrasikan ke dalam naskah bab ini, yang merupakan representasi statis dari aplikasi berbasis web (Dash/Plotly) yang dikembangkan. Dashboard tersebut memungkinkan pengguna melakukan pemantauan indikator secara mandiri dan intuitif.

4.11.2 Kontribusi terhadap Manfaat Penelitian

Sesuai dengan manfaat penelitian yang diharapkan:

1. **Manfaat Akademis:** Penelitian ini memperkaya literatur statistik multivariat di Indonesia dengan menerapkan metode STATIS dan *Dynamic Biplot* yang masih jarang digunakan pada data regional. Penggabungan analisis inter-struktur, struktur kompromi, dan analisis klaster memberikan metodologi yang lebih dinamis dibandingkan analisis dua-arah konvensional.

2. **Manfaat Praktis:** Keberadaan visualisasi peta dan matriks transisi dalam aplikasi dashboard menyediakan alat bantu yang kuat bagi pemerintah daerah untuk

mengevaluasi efektivitas kebijakan pembangunan secara komprehensif, tidak hanya melihat satu indikator secara terisolasi.

4.11.3 Implikasi Kebijakan

Temuan bahwa struktur kesenjangan pembangunan bersifat *persistent* dan terpola secara spasial menunjukkan bahwa kebijakan pembangunan yang bersifat "merata" (uniform) tidak akan efektif. Diperlukan kebijakan yang *targeted*, yang memfokuskan intervensi pada wilayah-wilayah Klaster 1 yang secara struktural tertinggal, terutama di bidang pendidikan (peningkatan RLS), pengurangan kemiskinan, dan penciptaan lapangan kerja. Strategi pembangunan berbasis *regional spillover* dari pusat pertumbuhan (DKI Jakarta) ke wilayah penyangga perlu ditingkatkan untuk memperpendek kesenjangan spasio-temporal yang teramati dalam lima tahun terakhir.

BAB 5
KESIMPULAN DAN SARAN

Bab ini menyimpulkan hasil temuan utama dari analisis STATIS dan Dynamic Biplot mengenai dinamika pembangunan ekonomi regional di Provinsi Banten, DKI Jakarta, dan Jawa Barat, serta memberikan saran rekomendasi kebijakan maupun pengembangan penelitian selanjutnya.

5.1 Kesimpulan

Berdasarkan hasil analisis dan pembahasan yang telah dilakukan, dapat ditarik beberapa kesimpulan sebagai berikut:

1. **Stabilitas Struktur Regional yang Terbukti Signifikan:** Melalui analisis inter-struktur STATIS, seluruh koefisien RV antar-tahun berada di atas $0{,}90$, yang membuktikan bahwa konfigurasi spasial sosio-ekonomi antar 41 kabupaten/kota bersifat sangat stabil selama 2020 hingga 2024. Uji permutasi ($B = 1000$) memberikan $p < 0{,}05$, sehingga struktur kompromi yang ditemukan dinyatakan **signifikan secara statistik** dan bukan artefak acak.

2. **Dimensi Utama Pembangunan:** Dekomposisi struktur kompromi menghasilkan dua dimensi utama. Dimensi 1 merepresentasikan "Taraf Ekonomi dan Kualitas Sumber Daya Manusia" (berkorelasi positif dengan PDRB, IPM, RLS, IPG) dan menjelaskan bagian terbesar variansi total. Dimensi 2 merepresentasikan "Kesehatan dan Ketahanan Sosial" yang menangkap perbedaan kualitas hidup non-ekonomi seperti Angka Harapan Hidup.

3. **Dinamika Trajektori Pemulihan yang Terpola secara Longitudinal:** Sesuai dengan kerangka analisis longitudinal (Oliveira et al., 2024), visualisasi *Dynamic Biplot* berhasil memetakan tiga pola lintasan yang berbeda:

    - Kota-kota berbasis jasa (Jakarta Pusat, Bandung, Tangerang Selatan) menunjukkan pola pemulihan berbentuk *V-shape* yang kuat pasca-2021.
    - Kabupaten di wilayah selatan (Lebak, Pandeglang, Garut) cenderung menunjukkan lintasan stagnan, menandakan lambatnya respons pemulihan ekonomi.
    - Sejumlah wilayah penyangga menunjukkan pertumbuhan progresif yang linear tanpa fluktuasi.

4. **Ekologi Klaster yang Persisten dengan Mobilitas Selektif:** Pengelompokan K-Means ($k = 3$) mengidentifikasi tiga klaster yang stabil: Maju (wilayah metropolitan), Berkembang (wilayah penyangga), dan Tertinggal (wilayah pedesaan). Matriks transisi lintas tahun mengkonfirmasi dominasi diagonal. Hal ini berarti sebagian besar wilayah bertahan di klasternya, namun sejumlah kabupaten seperti Kepulauan Seribu berhasil bermigrasi positif ke klaster yang lebih baik selama masa pemulihan 2022 hingga 2024.

5. **Validitas Eksternal melalui Kesesuaian IPM UNDP:** Tabulasi silang antara klaster *data-driven* K-Means dan kategori IPM UNDP mengungkap kesesuaian struktural yang tinggi: Klaster 3 (Maju) didominasi wilayah berkategori IPM "Sangat Tinggi", sedangkan Klaster 1 (Tertinggal) sebagian besar berstatus IPM "Sedang". Hal ini membuktikan bahwa metode STATIS mampu menangkap struktur laten pembangunan manusia secara valid, bahkan tanpa menggunakan IPM sebagai variabel input analisis. Seluruh hasil ini diintegrasikan dalam *dashboard* web interaktif berbasis Dash/Plotly yang memungkinkan pemantauan dinamika pembangunan secara mandiri dan real-time.

5.2 Saran

Berdasarkan kesimpulan di atas, diajukan beberapa saran sebagai berikut:

1. **Implikasi Kebijakan *Targeted*:** Mengingat struktur ketimpangan yang persisten dan terpola secara spasial, kebijakan pemerataan pembangunan tidak cukup hanya mengandalkan pertumbuhan ekonomi nasional. Diperlukan intervensi struktural yang *targeted* pada wilayah Klaster 1 (Tertinggal), khususnya Kabupaten Lebak, Pandeglang, dan Garut, dengan fokus pada peningkatan kapabilitas dasar (RLS, AHH) serta pengurangan kemiskinan melalui strategi *regional spillover* dari pusat pertumbuhan DKI Jakarta.

2. **Pengembangan Penelitian Lanjutan:** Penelitian ini dibatasi pada indikator makroekonomi tahunan dari 3 provinsi. Penelitian selanjutnya disarankan untuk:

    - Menggunakan data dengan resolusi waktu yang lebih tinggi (triwulanan) apabila tersedia, untuk menangkap dinamika perubahan jangka pendek secara lebih detail.
    - Memperluas cakupan wilayah ke seluruh Pulau Jawa atau Indonesia dengan mengintegrasikan metode *Dual STATIS* untuk analisis hubungan antar-variabel

yang lebih spesifik.

- Menambahkan variabel sosial lain seperti akses infrastruktur, distribusi fasilitas kesehatan, dan indikator kemiskinan multidimensi untuk memperkaya dimensi analisis.

3. **Pengembangan Platform *Dashboard* Interaktif:** Dashboard berbasis web (Dash/Plotly) yang dikembangkan dalam penelitian ini dapat dikembangkan lebih lanjut dengan menambahkan fitur pembaruan data secara otomatis dari API BPS Open Data, sehingga pemantauan dinamika pembangunan regional dapat dilakukan secara *near real-time* oleh pemangku kepentingan kebijakan.

DAFTAR PUSTAKA

Abdi, H., Williams, L. J., Valentin, D., & Bennani-Dosse, M. (2012). Statis and distatis: optimum multitable principal component analysis and three way metric multidimensional scaling. *Wiley Interdisciplinary Reviews: Computational Statistics*, 4(2), 124–167. https://doi.org/10.1002/wics.198

Ahmad, A. (2024). Analisis regresi panel spasiotemporal menggunakan model spasial durbin dinamis pada prevalensi kusta di pulau jawa. Institut Pertanian Bogor, Bogor. Diakses: 20 November 2025. https://repository.ipb.ac.id/handle/123456789/154545

Anselin, L. (1988). *Spatial Econometrics: Methods and Models*. Kluwer Academic Publishers. https://link.springer.com/book/10.1007/978-94-015-7799-1

Anton, H. & Rorres, C. (2013). *Elementary Linear Algebra: Applications Version* (11th ed.). John Wiley & Sons. https://studylib.net/doc/27681515/linear-algebra-11th-edi-howard-anton

Areia, A., Oliveira, M., & Mexia, J. T. (2008). Models for a series of studies based on geometrical representation. *Statistical Methodology*, 5(3), 277–288. https://doi.org/10.1016/j.stamet.2007.09.001

Badan Pusat Statistik (2024). *Prevalensi ketidakcukupan konsumsi pangan (persen) per kabupaten/kota (persen), 2024*. Diakses dari situs resmi Badan Pusat Statistik. https://www.bps.go.id/id/statistics-table/2/MjI2OSMy/prevalensi-ketidakcukupan-konsumsi-pangan--persen--per-kabupaten-kota--persen-.html

Badan Pusat Statistik (2025a). *Indikator kesejahteraan rakyat 2025*. Katalog 4102004, ISSN 0215-4641. https://www.bps.go.id/id/publication/2025/12/30/bcc229ac31403d023f2d26a3/indikator-kesejahteraan-rakyat-2025.html

Badan Pusat Statistik (2025b). *Tinjauan regional berdasarkan pdrb kabupaten/kota 2020–2024*. Diakses dari situs resmi Badan Pusat Statistik. https://www.bps.go.id/id/statistics-table/3/WkdVMWRYVnBkMnBvVEhKSVkyWXhNblZtTjJSbmR6MDkjMw==/produk-domestik-regional-bruto-atas-dasar-harga-berlaku-menurut-provinsi--miliar-rupiah---2022.html?year=2024

Badan Pusat Statistik Provinsi Banten (2020). *Provinsi banten dalam angka 2020*. https://banten.bps.go.id/id/publication/2020/04/27/41c9192acf8b24ecbaa2d8e5/provinsi-banten-dalam-angka-2020.html

Badan Pusat Statistik Provinsi Banten (2021). *Provinsi banten dalam angka 2021*. https://banten.bps.go.id/id/publication/2021/02/26/344951df21aeedca2572f336/provinsi-banten-dalam-angka-2021.html

Badan Pusat Statistik Provinsi Banten (2022). *Provinsi banten dalam angka 2022*. https://banten.bps.go.id/id/publication/2022/02/25/19658ae14140f17fc6ae9e3a/provinsi-banten-dalam-angka-2022.html

Badan Pusat Statistik Provinsi Banten (2023). *Provinsi banten dalam angka 2023*. https://banten.bps.go.id/id/publication/2023/02/28/482ee839483674f34dd96faf/provinsi-banten-dalam-angka-2023.html

Badan Pusat Statistik Provinsi Banten (2024). *Provinsi banten dalam angka 2024*. https://banten.bps.go.id/en/publication/2024/02/28/e9b15e76302d4876c37f60be/provinsi-banten-dalam-angka-2024.html

Badan Pusat Statistik Provinsi DKI Jakarta (2020). *Provinsi dki jakarta dalam angka 2020*. https://jakarta.bps.go.id/id/publication/2020/04/27/20f5a58abcb80a0ad2a88725/provinsi-dki-jakarta-dalam-angka-2020.html

Badan Pusat Statistik Provinsi DKI Jakarta (2021). *Provinsi dki jakarta dalam angka 2021*. https://jakarta.bps.go.id/id/publication/2021/02/26/bb7fa6dd5e90b534e3fa6984/provinsi-dki-jakarta-dalam-angka-2021.html

Badan Pusat Statistik Provinsi DKI Jakarta (2022). *Provinsi dki jakarta dalam angka 2022*. https://jakarta.bps.go.id/id/publication/2022/02/25/5979600247867d861a1f334c/provinsi-dki-jakarta-dalam-angka-2022.html

Badan Pusat Statistik Provinsi DKI Jakarta (2023). *Provinsi dki jakarta dalam angka 2023*. https://jakarta.bps.go.id/id/publication/2023/02/28/fd35fcb5d10a1e03f0d71348/provinsi-dki-jakarta-dalam-angka-2023.html

Badan Pusat Statistik Provinsi DKI Jakarta (2024). *Provinsi dki jakarta dalam angka 2024*. https://jakarta.bps.go.id/id/publication/2024/02/28/baae7b80d16101c7bef30cc0/provinsi-dki-jakarta-dalam-angka-2024.html

Badan Pusat Statistik Provinsi Jawa Barat (2020). *Provinsi jawa barat dalam angka 2020*. https://jabar.bps.go.id/id/publication/2020/04/27/cfab9a400cf304f800182a5f/provinsi-jawa-barat-dalam-angka-2020.html

Badan Pusat Statistik Provinsi Jawa Barat (2021). *Provinsi jawa barat dalam angka 2021*. https://jabar.bps.go.id/id/publication/2021/02/26/4d3f7ec6c519dda0b9785d45/provinsi-jawa-barat-dalam-angka-2021.html

Badan Pusat Statistik Provinsi Jawa Barat (2022). *Provinsi jawa barat dalam angka 2022*. https://jabar.bps.go.id/id/publication/2022/02/25/0d261f828b581d8082bbc6c1/provinsi-jawa-barat-dalam-angka-2022.html

Badan Pusat Statistik Provinsi Jawa Barat (2023). *Provinsi jawa barat dalam angka 2023*. https://jabar.bps.go.id/id/publication/2023/02/28/57231a828abbfdd50a21fe31/provinsi-jawa-barat-dalam-angka-2023.html

Badan Pusat Statistik Provinsi Jawa Barat (2024). *Provinsi jawa barat dalam angka 2024*. https://jabar.bps.go.id/id/publication/2024/02/28/35ffe2d35104b39feb577e8f/provinsi-jawa-barat-dalam-angka-2024.html

Baltagi, B. (2021). *Econometric Analysis of Panel Data*. https://doi.org/10.1007/978-3-030-53953-5

Bartlett, M. S. (1954). A note on the multiplying factors for various χ^2 approximations. *Journal of the Royal Statistical Society: Series B (Methodological)*, 16(2), 296–298. https://doi.org/10.1111/j.2517-6161.1954.tb00174.x

Bholowalia, P. & Kumar, A. (2014). Ebk-means: A clustering technique based on elbow method and k-means in wsn. *International Journal of Computer Applications*, 105(9). https://doi.org/10.5120/18405-9674

Biegert, T., Özcan, B., & Rossetti-Youlton, M. (2023). Household joblessness in u.s. metropolitan areas during the covid-19 pandemic: Polarization and the role of educational profiles. *Socius: Sociological Research for a Dynamic World*, 9, 1–18. https://doi.org/10.1177/23780231231158087

Bulmer, M. G. (1979). *Principles of Statistics* (dover edition ed.). Dover Publications. Klasifikasi standar skewness: $|\gamma_1| < 0.5$ simetris; $0.5 \leq |\gamma_1| < 1$ moderat; $|\gamma_1| \geq 1$ sangat menceng (hlm. 110-112).

Departemen Pertanian (Deptan) (2003). Analisis produktivitas dan stabilitas komoditas strategis pangan propinsi di yogyakarta. Technical report, Departemen Pertanian RI. Metodologi standar klasifikasi CV untuk stabilitas pertanian. https://jiip.polbangtanyoma.ac.id/index.php/jiip/article/download/165/159/531

Dziuban, C. D. & Shirkey, E. C. (1974). When is a correlation matrix appropriate for factor analysis? some decision rules. *Psychological Bulletin*, 81(6), 358–361. https://doi.org/10.1037/h0036316

Egido, J. & Galindo, P. (2015). Dynamic biplot. evolution of the economic freedom in the european union. *British Journal of Applied Science & Technology*, 11(3), 1–13. https://doi.org/10.9734/BJAST/2015/20289

Escoufier, Y. (1973). Le traitement des variables vectorielles. *Biometrics*, 29(4), 751–760. https://doi.org/10.2307/2529140

Gabriel, K. R. (1971). The biplot graphic display of matrices with application to principal component analysis. *Biometrika*, 58(3), 453–467. https://doi.org/10.1093/biomet/58.3.453

Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate Data Analysis* (8 ed.). Cengage Learning. https://www.cengage.uk/c/multivariate-data-analysis-8e-hair-black-babin-anderson/9781473756540/

Hotelling, H. (1933). Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology*, 24(6), 417–441. https://doi.org/10.1037/h0071325

Johnson, R. A. & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6 ed.). Pearson Prentice Hall. https://www.pearson.com/en-us/subject-catalog/p/applied-multivariate-statistical-analysis/P200000003290

Kaiser, H. F. (1970). A second generation little jiffy. *Psychometrika*, 35(4), 401–415. https://doi.org/10.1007/BF02291817

Kaiser, H. F. (1974). An index of factorial simplicity. *Psychometrika*, 39(1), 31–36. https://doi.org/10.1007/BF02291575

Kazi-Aoual, F., Hitier, S., Sabatier, R., & Lebreton, J. D. (1995). Refined approximations to permutation tests for multivariate inference. *Computational Statistics & Data Analysis*, 20(4), 385–394. https://doi.org/10.1016/0167-9473(94)00064-2

Kroonenberg, P. M. (2008). *Applied Multiway Data Analysis*. John Wiley & Sons. https://doi.org/10.1002/9780470238004

Kuhn, H. W. (1955). The hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1–2), 83–97. https://doi.org/10.1002/nav.3800020109

Lavit, C., Escoufier, Y., Sabatier, R., & Traissac, P. (1994). The act (statis method). *Computational Statistics & Data Analysis*, 18(1), 97–119. https://doi.org/10.1016/0167-9473(94)90134-1

Legendre, P. & Legendre, L. (2012). *Numerical ecology*. Elsevier. https://www.sciencedirect.com/book/9780444538680/numerical-ecology

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the fifth Berkeley symposium on mathematical statistics and probability*, volume 1, 281–297. https://digicoll.lib.berkeley.edu/record/113015?v=pdf

Mexia, J. T. & Oliveira, M. (2007). Non-observable regressors. *Biometrical Letters*, 44(2), 97–103. https://bl.up.poznan.pl/full/BL%2044%202%202.pdf

Nuswantari, A. (2021). Pemodelan kemiskinan di pulau jawa tahun 2012 sampai 2018 dengan panel spasial dinamis. Institut Pertanian Bogor, Bogor. Diakses: 20 November 2025. https://repository.ipb.ac.id/handle/123456789/107909

Oliveira, M., Garção, E., Grilo, L. M., Alexandre, A., & Mexia, J. T. (2024). Statis methodology: An overview. *AIP Conference Proceedings*, volume 3094, 450006. https://doi.org/10.1063/5.0212208

Pearson, K. (1901). Liii. on lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11), 559–572. https://doi.org/10.1080/14786440109462720

Phipson, B. & Smyth, G. K. (2010). Permutation p-values should never be zero: Calculating exact p-values when permutations are randomly drawn. *Statistical Applications in Genetics and Molecular Biology*, 9(1), Article 39. https://doi.org/10.48550/arXiv.1603.05766

Plotly Technologies Inc. (2015). *Collaborative data science*. Plotly. https://plotly.com

Plotly Technologies Inc. (2024). *Dash Python User Guide*. Plotly Technologies Inc. Dokumentasi resmi kerangka kerja Dash. https://dash.plotly.com/

Syakur, M., Khotimah, B., Rochman, E., & Satoto, B. (2018). Integration k-means clustering method and elbow method for identification of the best customer profile cluster. *IOP conference series: materials science and engineering*, volume 336, 012017. https://doi.org/10.1088/1757-899X/336/1/012017

Ward Jr, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American statistical association*, 58(301), 236–244. https://doi.org/10.1080/01621459.1963.10500845

Weisstein, Eric W. (2024). *Kurtosis excess*. https://mathworld.wolfram.com/KurtosisExcess.html. Rumus lengkap gamma2 dan referensi historis.

Widyaningsih, Y. (2024). Perbandingan antara hasil biclustering dan hasil cluster-biplot pada data 119 kabupaten/kota di pulau jawa tahun 2022 berdasarkan indikator kesejahteraan rakyat. Universitas Indonesia, Depok. https://doi.org/10.30598/barekengvol19iss2pp1009-1022

Lampiran 1 Data Penelitian

Berikut adalah data penelitian untuk masing-masing variabel dari tahun 2020 hingga 2024.

Data Variabel IPM

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	71,63	72,10	72,79	73,39	74,17
2	DKI JAKARTA	Kota Jakarta Selatan	84,72	84,90	85,21	86,07	86,94
3	DKI JAKARTA	Kota Jakarta Timur	82,66	82,97	83,45	84,13	84,65
4	DKI JAKARTA	Kota Jakarta Pusat	81,39	81,56	82,11	82,53	83,01
5	DKI JAKARTA	Kota Jakarta Barat	81,38	81,76	82,51	83,02	83,64
6	DKI JAKARTA	Kota Jakarta Utara	80,29	80,51	80,81	81,11	81,39
7	JAWA BARAT	Bogor	70,40	70,60	71,20	71,78	72,39
8	JAWA BARAT	Sukabumi	66,88	67,07	67,64	68,49	68,97
9	JAWA BARAT	Cianjur	65,36	65,56	65,94	66,55	67,24
10	JAWA BARAT	Bandung	72,39	72,73	73,16	73,74	74,27
11	JAWA BARAT	Garut	66,12	66,45	67,41	68,11	68,79
12	JAWA BARAT	Tasikmalaya	65,67	65,90	66,84	67,76	68,36
13	JAWA BARAT	Ciamis	70,49	70,93	71,45	72,05	72,56
14	JAWA BARAT	Kuningan	69,38	69,71	70,16	70,72	71,26
15	JAWA BARAT	Cirebon	68,75	69,12	70,06	70,95	71,44
16	JAWA BARAT	Majalengka	67,59	67,81	68,56	69,13	69,74
17	JAWA BARAT	Sumedang	71,64	71,80	72,69	73,18	73,73
18	JAWA BARAT	Indramayu	67,29	67,64	68,55	69,25	69,83
19	JAWA BARAT	Subang	68,95	69,13	69,87	70,70	71,36
20	JAWA BARAT	Purwakarta	70,82	70,98	71,56	72,09	72,65
21	JAWA BARAT	Karawang	70,66	70,94	71,74	72,35	72,90
22	JAWA BARAT	Bekasi	74,07	74,45	75,22	75,76	76,44
23	JAWA BARAT	Bandung Barat	68,08	68,29	69,04	69,61	70,03
24	JAWA BARAT	Pangandaran	68,06	68,28	69,03	69,38	69,85
25	JAWA BARAT	Kota Bogor	76,11	76,59	77,17	77,85	78,52
26	JAWA BARAT	Kota Sukabumi	74,21	74,60	75,40	76,32	76,85
27	JAWA BARAT	Kota Bandung	81,51	81,96	82,50	83,04	83,52
28	JAWA BARAT	Kota Cirebon	74,89	75,25	75,89	76,46	77,08
29	JAWA BARAT	Kota Bekasi	81,50	81,95	82,46	83,03	83,54
30	JAWA BARAT	Kota Depok	80,97	81,37	81,86	82,38	82,91
31	JAWA BARAT	Kota Cimahi	77,83	78,06	78,77	79,46	80,08
32	JAWA BARAT	Kota Tasikmalaya	73,04	73,31	73,83	74,47	75,04
33	JAWA BARAT	Kota Banjar	71,70	71,92	72,55	73,08	73,64
34	BANTEN	Pandeglang	65,00	65,17	65,84	66,42	66,99
35	BANTEN	Lebak	63,91	64,03	64,71	65,21	65,86
36	BANTEN	Tangerang	71,92	72,29	72,97	73,43	74,09
37	BANTEN	Serang	66,70	66,82	67,75	68,39	69,03
38	BANTEN	Kota Tangerang	78,25	78,50	78,90	79,46	80,02
39	BANTEN	Kota Cilegon	73,05	73,35	73,95	74,54	75,14
40	BANTEN	Kota Serang	72,16	72,44	72,98	73,48	73,99
41	BANTEN	Kota Tangerang Selatan	81,36	81,60	81,95	82,28	82,89

Data Variabel IPG

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	93,39	93,39	93,69	93,60	93,62
2	DKI JAKARTA	Kota Jakarta Selatan	96,14	96,28	96,48	97,16	97,30
3	DKI JAKARTA	Kota Jakarta Timur	95,48	95,44	95,92	95,98	95,90
4	DKI JAKARTA	Kota Jakarta Pusat	96,00	96,11	96,41	96,28	96,24
5	DKI JAKARTA	Kota Jakarta Barat	95,16	95,37	95,39	95,39	95,66
6	DKI JAKARTA	Kota Jakarta Utara	93,53	93,60	93,84	94,03	94,43
7	JAWA BARAT	Bogor	89,23	89,40	89,95	90,20	90,17
8	JAWA BARAT	Sukabumi	87,37	87,44	87,64	88,30	88,59
9	JAWA BARAT	Cianjur	84,14	84,30	84,90	85,17	85,45
10	JAWA BARAT	Bandung	93,95	93,85	93,97	94,03	94,23
11	JAWA BARAT	Garut	82,29	82,13	82,78	83,37	83,50
12	JAWA BARAT	Tasikmalaya	86,02	86,36	86,64	87,01	87,10
13	JAWA BARAT	Ciamis	86,61	86,55	87,04	87,25	87,48
14	JAWA BARAT	Kuningan	86,81	86,97	87,17	87,31	87,55
15	JAWA BARAT	Cirebon	83,47	83,49	84,01	84,28	84,74
16	JAWA BARAT	Majalengka	85,91	86,24	86,69	87,06	87,16
17	JAWA BARAT	Sumedang	95,18	95,18	95,09	95,41	95,55
18	JAWA BARAT	Indramayu	88,15	87,92	88,17	88,81	89,03
19	JAWA BARAT	Subang	90,53	90,51	90,95	91,29	91,55
20	JAWA BARAT	Purwakarta	86,56	86,70	86,94	87,08	87,18
21	JAWA BARAT	Karawang	90,12	90,29	90,50	91,07	91,23
22	JAWA BARAT	Bekasi	88,58	88,88	89,37	89,53	89,72
23	JAWA BARAT	Bandung Barat	79,06	79,07	79,69	80,37	81,02
24	JAWA BARAT	Pangandaran	89,78	89,92	90,20	90,04	90,38
25	JAWA BARAT	Kota Bogor	91,02	90,87	90,97	91,11	91,26
26	JAWA BARAT	Kota Sukabumi	91,36	91,58	91,83	92,35	92,59
27	JAWA BARAT	Kota Bandung	94,68	94,72	94,81	94,71	94,87
28	JAWA BARAT	Kota Cirebon	94,39	94,46	94,91	95,55	95,83
29	JAWA BARAT	Kota Bekasi	92,95	93,09	93,49	93,52	93,62
30	JAWA BARAT	Kota Depok	93,01	92,96	93,47	93,44	93,70
31	JAWA BARAT	Kota Cimahi	92,01	91,95	91,97	92,00	92,28
32	JAWA BARAT	Kota Tasikmalaya	91,64	91,74	91,87	92,13	92,22
33	JAWA BARAT	Kota Banjar	87,17	87,01	87,67	87,85	88,12
34	BANTEN	Pandeglang	86,71	86,83	86,93	87,09	87,23
35	BANTEN	Lebak	79,81	79,87	80,20	80,75	81,22
36	BANTEN	Tangerang	90,98	91,08	91,24	91,67	91,69
37	BANTEN	Serang	92,14	91,98	92,32	92,49	92,54
38	BANTEN	Kota Tangerang	95,06	94,72	94,73	94,89	94,95
39	BANTEN	Kota Cilegon	87,22	87,25	87,57	88,05	88,29
40	BANTEN	Kota Serang	92,28	92,47	92,63	92,49	92,61
41	BANTEN	Kota Tangerang Selatan	93,58	93,80	93,96	94,23	94,47

Data Variabel PPM

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	14,87	15,06	14,11	13,13	13,03
2	DKI JAKARTA	Kota Jakarta Selatan	3,43	3,56	3,52	3,10	3,03
3	DKI JAKARTA	Kota Jakarta Timur	4,16	4,28	4,30	4,20	4,09
4	DKI JAKARTA	Kota Jakarta Pusat	4,51	4,94	4,90	4,68	4,63
5	DKI JAKARTA	Kota Jakarta Barat	4,25	4,31	4,22	4,09	3,94
6	DKI JAKARTA	Kota Jakarta Utara	6,78	7,24	7,24	6,78	6,44
7	JAWA BARAT	Bogor	7,69	8,13	7,73	7,27	7,05
8	JAWA BARAT	Sukabumi	7,09	7,70	7,34	7,01	6,87
9	JAWA BARAT	Cianjur	10,36	11,18	10,55	10,22	10,14
10	JAWA BARAT	Bandung	6,91	7,15	6,80	6,40	6,19
11	JAWA BARAT	Garut	9,98	10,65	10,42	9,77	9,68
12	JAWA BARAT	Tasikmalaya	10,34	11,15	10,73	10,28	10,23
13	JAWA BARAT	Ciamis	7,62	7,97	7,72	7,42	7,39
14	JAWA BARAT	Kuningan	12,82	13,10	12,76	12,12	11,88
15	JAWA BARAT	Cirebon	11,24	12,30	12,01	11,20	11,00
16	JAWA BARAT	Majalengka	11,43	12,33	11,94	11,21	10,82
17	JAWA BARAT	Sumedang	10,26	10,71	10,14	9,36	9,10
18	JAWA BARAT	Indramayu	12,70	13,04	12,77	12,13	11,93
19	JAWA BARAT	Subang	9,31	10,03	9,75	9,52	9,49
20	JAWA BARAT	Purwakarta	8,27	8,83	8,70	8,46	8,41
21	JAWA BARAT	Karawang	8,26	8,95	8,44	7,87	7,86
22	JAWA BARAT	Bekasi	4,82	5,21	5,01	4,93	4,80
23	JAWA BARAT	Bandung Barat	10,49	11,30	10,82	10,52	10,49
24	JAWA BARAT	Pangandaran	8,99	9,65	9,32	8,98	8,75
25	JAWA BARAT	Kota Bogor	6,68	7,24	7,10	6,67	6,53
26	JAWA BARAT	Kota Sukabumi	7,70	8,25	8,02	7,50	7,20
27	JAWA BARAT	Kota Bandung	3,99	4,37	4,25	3,96	3,87
28	JAWA BARAT	Kota Cirebon	9,52	10,03	9,82	9,16	9,02
29	JAWA BARAT	Kota Bekasi	4,38	4,74	4,43	4,10	4,01
30	JAWA BARAT	Kota Depok	2,45	2,58	2,53	2,38	2,34
31	JAWA BARAT	Kota Cimahi	5,11	5,35	5,11	4,66	4,39
32	JAWA BARAT	Kota Tasikmalaya	12,97	13,13	12,72	11,53	11,10
33	JAWA BARAT	Kota Banjar	6,09	7,11	6,73	6,14	5,85
34	BANTEN	Pandeglang	9,92	10,72	9,32	9,27	9,18
35	BANTEN	Lebak	9,24	10,29	8,91	8,68	8,44
36	BANTEN	Tangerang	6,23	7,12	6,92	6,93	6,55
37	BANTEN	Serang	4,94	5,49	4,96	4,85	4,51
38	BANTEN	Kota Tangerang	5,22	5,93	5,77	5,89	5,43
39	BANTEN	Kota Cilegon	3,69	4,24	3,64	3,98	3,75
40	BANTEN	Kota Serang	6,06	6,79	5,94	6,20	5,65
41	BANTEN	Kota Tangerang Selatan	2,29	2,57	2,50	2,57	2,36

Data Variabel PDRB_ADHK

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	3.706,25	3.648,88	3.586,89	3.305,13	3.268,50
2	DKI JAKARTA	Kota Jakarta Selatan	419.257,19	429.278,00	451.772,70	475.806,20	500.422,70
3	DKI JAKARTA	Kota Jakarta Timur	299.515,16	313.816,50	329.546,30	346.508,70	362.068,10
4	DKI JAKARTA	Kota Jakarta Pusat	449.518,14	460.024,30	481.954,50	506.560,70	532.606,90
5	DKI JAKARTA	Kota Jakarta Barat	316.172,61	327.613,10	345.619,60	363.931,20	383.113,10
6	DKI JAKARTA	Kota Jakarta Utara	312.100,58	330.883,90	350.233,70	364.823,90	380.461,10
7	JAWA BARAT	Bogor	154.113,60	159.589,60	167.966,20	176.683,60	185.882,30
8	JAWA BARAT	Sukabumi	46.205,28	47.935,63	50.388,72	52.993,98	55.723,92
9	JAWA BARAT	Cianjur	31.792,32	32.897,53	34.556,40	36.339,55	38.208,18
10	JAWA BARAT	Bandung	81.060,97	83.949,37	88.437,96	92.830,17	97.509,91
11	JAWA BARAT	Garut	38.598,43	39.981,19	42.012,96	44.087,22	46.270,92
12	JAWA BARAT	Tasikmalaya	24.344,86	25.179,48	26.361,66	27.599,16	28.879,68
13	JAWA BARAT	Ciamis	21.970,41	22.774,93	23.918,89	25.111,71	26.360,94
14	JAWA BARAT	Kuningan	16.882,76	17.483,56	18.450,34	19.418,73	20.507,27
15	JAWA BARAT	Cirebon	33.304,05	34.127,52	35.523,78	37.246,57	39.418,27
16	JAWA BARAT	Majalengka	21.754,54	22.788,75	24.298,10	25.793,24	27.438,93
17	JAWA BARAT	Sumedang	23.665,01	24.414,66	25.595,02	26.876,86	27.965,76
18	JAWA BARAT	Indramayu	59.200,00	59.544,87	61.259,61	67.237,69	68.701,96
19	JAWA BARAT	Subang	28.344,32	28.960,89	30.202,58	31.604,98	33.126,46
20	JAWA BARAT	Purwakarta	45.293,24	46.840,15	49.292,98	51.740,50	54.142,29
21	JAWA BARAT	Karawang	157.710,59	166.941,50	177.470,90	187.051,70	194.903,10
22	JAWA BARAT	Bekasi	242.971,39	251.778,50	265.120,50	279.224,90	293.664,80
23	JAWA BARAT	Bandung Barat	30.640,41	31.701,79	33.393,29	35.062,19	36.793,68
24	JAWA BARAT	Pangandaran	7.738,97	8.022,78	2.383.665,00	8.869,86	9.324,31
25	JAWA BARAT	Kota Bogor	32.162,74	33.372,48	35.258,87	37.055,36	38.964,67
26	JAWA BARAT	Kota Sukabumi	8.534,72	2.538.923,00	9.324,16	9.801,88	10.303,16
27	JAWA BARAT	Kota Bandung	193.144,95	200.414,00	211.250,70	221.969,10	233.053,80
28	JAWA BARAT	Kota Cirebon	16.648,21	17.155,75	18.030,25	18.934,40	19.884,06
29	JAWA BARAT	Kota Bekasi	67.619,24	69.796,94	73.260,65	77.241,79	81.251,61
30	JAWA BARAT	Kota Depok	48.135,93	49.947,24	52.564,98	55.221,82	58.241,86
31	JAWA BARAT	Kota Cimahi	22.340,56	23.275,78	24.652,73	25.931,98	27.296,93
32	JAWA BARAT	Kota Tasikmalaya	15.430,02	15.980,75	16.781,04	17.781,93	18.709,87
33	JAWA BARAT	Kota Banjar	3.251,76	3.365,25	3.516,57	3.682,30	3.883,98
34	BANTEN	Pandeglang	19.511,68	20.116,90	20.814,77	21.340,73	21.928,59
35	BANTEN	Lebak	20.622,04	21.278,48	22.087,37	22.706,47	23.377,24
36	BANTEN	Tangerang	93.480,39	97.869,38	103.219,40	108.569,80	113.998,20
37	BANTEN	Serang	52.866,43	54.844,65	57.605,99	60.369,96	63.255,33
38	BANTEN	Kota Tangerang	102.415,70	106.413,70	112.778,10	119.059,90	125.060,30
39	BANTEN	Kota Cilegon	73.319,12	77.163,94	80.646,38	84.536,65	88.628,11
40	BANTEN	Kota Serang	22.518,66	23.392,75	24.495,02	25.655,25	26.863,08
41	BANTEN	Kota Tangerang Selatan	59.531,08	62.393,12	66.021,24	69.561,56	73.052,84

Data Variabel RLS

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	8,68	8,81	9,02	9,03	9,26
2	DKI JAKARTA	Kota Jakarta Selatan	11,63	11,64	11,66	11,75	11,95
3	DKI JAKARTA	Kota Jakarta Timur	11,66	11,67	11,73	11,88	11,99
4	DKI JAKARTA	Kota Jakarta Pusat	11,38	11,39	11,53	11,54	11,61
5	DKI JAKARTA	Kota Jakarta Barat	10,63	10,78	11,13	11,23	11,24
6	DKI JAKARTA	Kota Jakarta Utara	10,80	10,81	10,82	10,84	10,85
7	JAWA BARAT	Bogor	8,30	8,31	8,34	8,37	8,39
8	JAWA BARAT	Sukabumi	7,07	7,10	7,11	7,33	7,34
9	JAWA BARAT	Cianjur	7,18	7,19	7,20	7,22	7,33
10	JAWA BARAT	Bandung	8,96	9,07	9,08	9,10	9,15
11	JAWA BARAT	Garut	7,52	7,53	7,83	7,84	7,85
12	JAWA BARAT	Tasikmalaya	7,35	7,48	7,73	7,96	7,97
13	JAWA BARAT	Ciamis	7,70	7,90	8,00	8,09	8,10
14	JAWA BARAT	Kuningan	7,57	7,80	7,88	7,89	7,90
15	JAWA BARAT	Cirebon	6,92	7,10	7,40	7,64	7,65
16	JAWA BARAT	Majalengka	7,27	7,31	7,49	7,52	7,53
17	JAWA BARAT	Sumedang	8,51	8,52	8,72	8,73	8,74
18	JAWA BARAT	Indramayu	6,30	6,52	6,83	6,94	6,95
19	JAWA BARAT	Subang	7,10	7,11	7,20	7,45	7,46
20	JAWA BARAT	Purwakarta	8,09	8,10	8,11	8,13	8,14
21	JAWA BARAT	Karawang	7,77	7,78	7,96	8,04	8,05
22	JAWA BARAT	Bekasi	9,12	9,30	9,53	9,57	9,76
23	JAWA BARAT	Bandung Barat	8,19	8,20	8,22	8,23	8,24
24	JAWA BARAT	Pangandaran	7,74	7,85	8,03	8,04	8,10
25	JAWA BARAT	Kota Bogor	10,33	10,53	10,63	10,64	10,71
26	JAWA BARAT	Kota Sukabumi	9,59	9,81	10,14	10,37	10,38
27	JAWA BARAT	Kota Bandung	10,75	10,99	11,00	11,06	11,07
28	JAWA BARAT	Kota Cirebon	9,91	10,12	10,33	10,37	10,53
29	JAWA BARAT	Kota Bekasi	11,16	11,31	11,44	11,66	11,79
30	JAWA BARAT	Kota Depok	11,28	11,46	11,47	11,58	11,59
31	JAWA BARAT	Kota Cimahi	10,96	11,08	11,21	11,39	11,52
32	JAWA BARAT	Kota Tasikmalaya	9,33	9,52	9,53	9,54	9,63
33	JAWA BARAT	Kota Banjar	8,63	8,77	8,78	8,79	8,83
34	BANTEN	Pandeglang	7,10	7,11	7,13	7,15	7,16
35	BANTEN	Lebak	6,40	6,41	6,59	6,60	6,61
36	BANTEN	Tangerang	8,39	8,61	8,92	8,93	9,06
37	BANTEN	Serang	7,50	7,51	7,78	7,79	7,88
38	BANTEN	Kota Tangerang	10,69	10,83	10,84	10,91	11,14
39	BANTEN	Kota Cilegon	9,87	10,08	10,34	10,38	10,39
40	BANTEN	Kota Serang	8,76	8,89	8,90	8,91	8,93
41	BANTEN	Kota Tangerang Selatan	11,81	11,82	11,84	11,85	11,86

Data Variabel AHH_L

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	66,67	66,84	67,02	67,68	67,85
2	DKI JAKARTA	Kota Jakarta Selatan	72,23	72,33	72,60	73,03	73,38
3	DKI JAKARTA	Kota Jakarta Timur	72,60	72,70	72,98	73,38	73,73
4	DKI JAKARTA	Kota Jakarta Pusat	72,22	72,30	72,55	73,06	73,65
5	DKI JAKARTA	Kota Jakarta Barat	71,72	71,82	71,97	72,39	72,55
6	DKI JAKARTA	Kota Jakarta Utara	71,36	71,44	71,58	71,80	71,97
7	JAWA BARAT	Bogor	69,24	69,52	69,72	69,97	70,20
8	JAWA BARAT	Sukabumi	69,03	69,27	69,53	69,89	70,11
9	JAWA BARAT	Cianjur	68,17	68,45	68,62	68,87	69,03
10	JAWA BARAT	Bandung	71,67	71,94	72,14	72,50	72,73
11	JAWA BARAT	Garut	69,49	69,74	69,74	70,12	70,32
12	JAWA BARAT	Tasikmalaya	67,51	67,78	67,97	68,27	68,47
13	JAWA BARAT	Ciamis	69,92	70,19	70,39	70,61	70,90
14	JAWA BARAT	Kuningan	71,72	71,98	72,18	72,52	72,72
15	JAWA BARAT	Cirebon	70,08	70,34	70,54	70,79	71,03
16	JAWA BARAT	Majalengka	68,31	68,58	68,79	69,12	69,37
17	JAWA BARAT	Sumedang	70,52	70,77	70,95	71,13	71,29
18	JAWA BARAT	Indramayu	69,72	70,01	70,24	70,50	70,80
19	JAWA BARAT	Subang	70,46	70,78	71,03	71,16	71,34
20	JAWA BARAT	Purwakarta	69,05	69,31	69,50	69,79	70,04
21	JAWA BARAT	Karawang	70,25	70,50	70,69	70,93	71,10
22	JAWA BARAT	Bekasi	71,81	71,99	72,17	72,53	72,75
23	JAWA BARAT	Bandung Barat	70,43	70,70	70,88	71,07	71,23
24	JAWA BARAT	Pangandaran	69,49	69,75	69,94	70,22	70,45
25	JAWA BARAT	Kota Bogor	71,74	72,02	72,25	72,69	72,89
26	JAWA BARAT	Kota Sukabumi	70,52	70,75	70,92	71,08	71,23
27	JAWA BARAT	Kota Bandung	72,45	72,71	72,92	73,30	73,50
28	JAWA BARAT	Kota Cirebon	70,35	70,61	70,82	71,06	71,22
29	JAWA BARAT	Kota Bekasi	73,22	73,48	73,70	74,10	74,29
30	JAWA BARAT	Kota Depok	72,61	72,87	73,08	73,49	73,68
31	JAWA BARAT	Kota Cimahi	72,19	72,45	72,66	73,05	73,23
32	JAWA BARAT	Kota Tasikmalaya	70,25	70,52	70,73	70,95	71,11
33	JAWA BARAT	Kota Banjar	69,04	69,31	69,53	69,85	70,08
34	BANTEN	Pandeglang	62,69	62,82	63,17	63,70	63,90
35	BANTEN	Lebak	65,19	65,33	65,69	66,19	66,40
36	BANTEN	Tangerang	67,86	67,93	68,25	68,73	68,95
37	BANTEN	Serang	62,68	62,82	63,20	63,72	64,00
38	BANTEN	Kota Tangerang	69,61	69,61	69,86	70,28	70,50
39	BANTEN	Kota Cilegon	64,66	64,68	64,95	65,46	65,72
40	BANTEN	Kota Serang	65,87	65,91	66,19	67,05	67,33
41	BANTEN	Kota Tangerang Selatan	70,51	70,55	70,85	71,07	71,21

Data Variabel AHH_P

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	70,74	71,03	71,27	71,63	71,80
2	DKI JAKARTA	Kota Jakarta Selatan	76,04	76,12	76,51	76,69	76,86
3	DKI JAKARTA	Kota Jakarta Timur	76,22	76,27	76,63	77,01	77,11
4	DKI JAKARTA	Kota Jakarta Pusat	75,92	76,00	76,39	76,71	76,94
5	DKI JAKARTA	Kota Jakarta Barat	75,43	75,49	75,65	76,09	76,28
6	DKI JAKARTA	Kota Jakarta Utara	75,13	75,22	75,41	75,55	76,04
7	JAWA BARAT	Bogor	73,06	73,25	73,54	73,96	74,21
8	JAWA BARAT	Sukabumi	72,87	73,13	73,47	73,88	74,11
9	JAWA BARAT	Cianjur	72,03	72,23	72,50	72,81	72,98
10	JAWA BARAT	Bandung	75,34	75,52	75,81	76,20	76,44
11	JAWA BARAT	Garut	73,30	73,48	73,74	74,12	74,33
12	JAWA BARAT	Tasikmalaya	71,39	71,59	71,88	72,21	72,41
13	JAWA BARAT	Ciamis	73,72	73,91	74,20	74,63	74,94
14	JAWA BARAT	Kuningan	75,42	75,61	75,87	76,22	76,42
15	JAWA BARAT	Cirebon	73,87	74,07	74,37	74,83	75,15
16	JAWA BARAT	Majalengka	72,18	72,37	72,68	73,08	73,34
17	JAWA BARAT	Sumedang	74,30	74,49	74,78	75,35	75,70
18	JAWA BARAT	Indramayu	73,52	73,72	74,04	74,52	74,83
19	JAWA BARAT	Subang	74,22	74,44	74,79	75,43	75,80
20	JAWA BARAT	Purwakarta	72,89	73,08	73,37	73,78	74,04
21	JAWA BARAT	Karawang	74,03	74,21	74,50	74,97	75,29
22	JAWA BARAT	Bekasi	75,50	75,63	75,87	76,23	76,55
23	JAWA BARAT	Bandung Barat	74,20	74,39	74,67	75,23	75,56
24	JAWA BARAT	Pangandaran	73,29	73,48	73,77	74,22	74,46
25	JAWA BARAT	Kota Bogor	75,44	75,65	75,96	76,37	76,69
26	JAWA BARAT	Kota Sukabumi	74,28	74,44	74,72	75,25	75,57
27	JAWA BARAT	Kota Bandung	75,97	76,16	76,46	76,93	77,24
28	JAWA BARAT	Kota Cirebon	74,13	74,31	74,61	75,20	75,55
29	JAWA BARAT	Kota Bekasi	76,71	76,89	77,18	77,45	77,75
30	JAWA BARAT	Kota Depok	76,42	76,60	76,91	77,11	77,41
31	JAWA BARAT	Kota Cimahi	75,77	75,96	76,26	76,70	77,01
32	JAWA BARAT	Kota Tasikmalaya	74,02	74,21	74,51	74,99	75,32
33	JAWA BARAT	Kota Banjar	72,89	73,08	73,39	73,84	74,08
34	BANTEN	Pandeglang	66,54	66,68	67,10	67,56	67,78
35	BANTEN	Lebak	69,13	69,24	69,66	70,17	70,38
36	BANTEN	Tangerang	71,81	71,84	72,19	72,67	72,90
37	BANTEN	Serang	66,50	66,61	67,03	67,58	67,89
38	BANTEN	Kota Tangerang	73,49	73,49	73,80	74,29	74,52
39	BANTEN	Kota Cilegon	68,58	68,61	68,95	69,42	69,70
40	BANTEN	Kota Serang	69,94	70,06	70,48	71,02	71,29
41	BANTEN	Kota Tangerang Selatan	74,31	74,31	74,62	75,24	75,52

Data Variabel GK

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	661.852,00	670.785,00	701.088,00	743.820,00	775.909,00
2	DKI JAKARTA	Kota Jakarta Selatan	782.731,00	792.684,00	842.630,00	891.580,00	928.278,00
3	DKI JAKARTA	Kota Jakarta Timur	581.954,00	594.849,00	630.842,00	669.713,00	697.472,00
4	DKI JAKARTA	Kota Jakarta Pusat	672.328,00	689.379,00	733.176,00	784.679,00	818.722,00
5	DKI JAKARTA	Kota Jakarta Barat	557.803,00	570.330,00	599.514,00	657.247,00	685.071,00
6	DKI JAKARTA	Kota Jakarta Utara	594.240,00	609.310,00	645.431,00	684.557,00	712.835,00
7	JAWA BARAT	Bogor	402.877,00	418.483,00	443.787,00	482.174,00	513.512,00
8	JAWA BARAT	Sukabumi	328.284,00	342.094,00	357.636,00	392.705,00	416.751,00
9	JAWA BARAT	Cianjur	371.699,00	387.631,00	406.829,00	437.327,00	466.509,00
10	JAWA BARAT	Bandung	367.403,00	378.819,00	398.884,00	426.069,00	455.636,00
11	JAWA BARAT	Garut	310.437,00	320.050,00	335.134,00	367.681,00	393.464,00
12	JAWA BARAT	Tasikmalaya	323.880,00	333.909,00	347.917,00	378.958,00	400.148,00
13	JAWA BARAT	Ciamis	378.108,00	389.676,00	405.294,00	442.108,00	467.497,00
14	JAWA BARAT	Kuningan	352.358,00	358.069,00	371.665,00	402.767,00	420.867,00
15	JAWA BARAT	Cirebon	393.452,00	404.635,00	416.914,00	451.853,00	475.046,00
16	JAWA BARAT	Majalengka	453.201,00	466.813,00	483.319,00	520.713,00	547.912,00
17	JAWA BARAT	Sumedang	353.092,00	360.054,00	371.870,00	396.573,00	422.714,00
18	JAWA BARAT	Indramayu	474.807,00	481.754,00	499.805,00	532.545,00	560.159,00
19	JAWA BARAT	Subang	351.885,00	360.691,00	372.308,00	404.320,00	434.161,00
20	JAWA BARAT	Purwakarta	378.287,00	387.754,00	403.663,00	434.187,00	467.948,00
21	JAWA BARAT	Karawang	466.152,00	494.201,00	521.158,00	555.889,00	597.345,00
22	JAWA BARAT	Bekasi	518.667,00	549.875,00	579.221,00	632.811,00	674.924,00
23	JAWA BARAT	Bandung Barat	362.212,00	374.470,00	393.956,00	426.355,00	455.325,00
24	JAWA BARAT	Pangandaran	382.264,00	394.101,00	411.174,00	447.242,00	470.068,00
25	JAWA BARAT	Kota Bogor	547.399,00	571.425,00	608.949,00	661.384,00	699.861,00
26	JAWA BARAT	Kota Sukabumi	547.415,00	567.734,00	594.118,00	644.276,00	678.258,00
27	JAWA BARAT	Kota Bandung	500.452,00	515.396,00	545.675,00	591.124,00	614.707,00
28	JAWA BARAT	Kota Cirebon	457.954,00	467.248,00	485.613,00	520.579,00	545.592,00
29	JAWA BARAT	Kota Bekasi	657.953,00	692.885,00	731.392,00	795.965,00	842.927,00
30	JAWA BARAT	Kota Depok	688.194,00	705.084,00	744.771,00	804.984,00	843.893,00
31	JAWA BARAT	Kota Cimahi	511.375,00	522.281,00	549.450,00	590.197,00	612.567,00
32	JAWA BARAT	Kota Tasikmalaya	470.150,00	480.341,00	498.711,00	537.497,00	565.377,00
33	JAWA BARAT	Kota Banjar	344.363,00	357.210,00	373.510,00	408.710,00	430.590,00
34	BANTEN	Pandeglang	361.713,00	390.754,00	416.248,00	455.297,00	479.886,00
35	BANTEN	Lebak	334.509,00	358.479,00	380.681,00	419.066,00	440.705,00
36	BANTEN	Tangerang	520.742,00	545.065,00	576.122,00	604.362,00	632.941,00
37	BANTEN	Serang	341.074,00	362.102,00	385.864,00	425.751,00	449.291,00
38	BANTEN	Kota Tangerang	632.835,00	655.061,00	695.225,00	746.468,00	785.113,00
39	BANTEN	Kota Cilegon	504.571,00	540.032,00	572.780,00	632.703,00	663.533,00
40	BANTEN	Kota Serang	411.595,00	431.210,00	460.613,00	511.575,00	540.786,00
41	BANTEN	Kota Tangerang Selatan	643.083,00	665.610,00	712.717,00	782.543,00	828.278,00

Data Variabel PKKP

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	2,86	2,41	3,91	3,63	4,39
2	DKI JAKARTA	Kota Jakarta Selatan	1,50	1,63	2,51	2,28	2,45
3	DKI JAKARTA	Kota Jakarta Timur	2,18	2,24	3,71	3,08	4,38
4	DKI JAKARTA	Kota Jakarta Pusat	1,97	3,08	3,82	2,91	3,63
5	DKI JAKARTA	Kota Jakarta Barat	1,78	2,00	2,80	2,03	3,55
6	DKI JAKARTA	Kota Jakarta Utara	2,18	2,63	4,78	2,62	3,39
7	JAWA BARAT	Bogor	4,06	4,73	7,03	5,30	5,68
8	JAWA BARAT	Sukabumi	4,89	4,81	7,42	5,98	5,82
9	JAWA BARAT	Cianjur	4,75	6,20	9,54	7,02	5,37
10	JAWA BARAT	Bandung	5,07	5,53	8,30	5,19	5,80
11	JAWA BARAT	Garut	4,06	5,00	7,74	5,76	5,02
12	JAWA BARAT	Tasikmalaya	5,64	7,12	10,45	8,65	5,95
13	JAWA BARAT	Ciamis	5,11	5,87	6,74	6,10	5,78
14	JAWA BARAT	Kuningan	3,51	3,73	6,63	6,43	5,83
15	JAWA BARAT	Cirebon	5,41	6,19	9,04	7,28	5,65
16	JAWA BARAT	Majalengka	4,17	4,94	9,88	7,90	5,95
17	JAWA BARAT	Sumedang	4,01	5,09	7,43	5,55	5,43
18	JAWA BARAT	Indramayu	4,28	3,97	5,99	5,40	5,46
19	JAWA BARAT	Subang	4,81	4,16	7,06	6,23	6,19
20	JAWA BARAT	Purwakarta	4,08	3,45	6,72	5,07	5,84
21	JAWA BARAT	Karawang	3,79	4,80	6,73	5,93	5,10
22	JAWA BARAT	Bekasi	2,26	2,38	4,30	4,36	4,60
23	JAWA BARAT	Bandung Barat	5,07	6,04	7,81	7,48	6,25
24	JAWA BARAT	Pangandaran	4,39	4,32	5,77	6,04	5,22
25	JAWA BARAT	Kota Bogor	2,95	3,08	5,35	4,86	7,98
26	JAWA BARAT	Kota Sukabumi	3,65	4,90	8,46	5,23	5,57
27	JAWA BARAT	Kota Bandung	2,82	2,92	4,55	3,64	5,48
28	JAWA BARAT	Kota Cirebon	4,52	5,71	7,97	6,85	6,56
29	JAWA BARAT	Kota Bekasi	1,33	1,79	3,33	2,27	4,88
30	JAWA BARAT	Kota Depok	1,26	1,55	2,15	1,99	4,52
31	JAWA BARAT	Kota Cimahi	2,66	3,23	4,63	2,98	5,43
32	JAWA BARAT	Kota Tasikmalaya	4,17	5,35	7,92	5,14	5,31
33	JAWA BARAT	Kota Banjar	3,93	5,93	6,40	5,55	5,13
34	BANTEN	Pandeglang	3,60	4,37	4,39	4,69	2,70
35	BANTEN	Lebak	3,14	3,87	3,45	4,82	2,52
36	BANTEN	Tangerang	1,84	2,65	2,28	2,59	2,22
37	BANTEN	Serang	2,44	3,03	2,90	3,23	2,13
38	BANTEN	Kota Tangerang	1,42	2,16	1,71	1,58	1,89
39	BANTEN	Kota Cilegon	2,02	2,46	2,04	2,19	1,96
40	BANTEN	Kota Serang	1,29	1,99	2,42	2,30	2,18
41	BANTEN	Kota Tangerang Selatan	1,51	1,89	1,50	1,92	3,13

Data Variabel TPT

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	7,37	8,58	8,47	8,11	7,93
2	DKI JAKARTA	Kota Jakarta Selatan	10,79	7,33	5,63	5,37	5,22
3	DKI JAKARTA	Kota Jakarta Timur	9,29	8,23	8,39	7,24	6,95
4	DKI JAKARTA	Kota Jakarta Pusat	10,97	7,75	5,88	6,42	6,24
5	DKI JAKARTA	Kota Jakarta Barat	12,27	9,06	7,10	6,39	6,18
6	DKI JAKARTA	Kota Jakarta Utara	11,79	9,84	8,04	7,05	6,18
7	JAWA BARAT	Bogor	14,29	12,22	10,64	8,47	7,34
8	JAWA BARAT	Sukabumi	9,60	9,51	7,77	7,32	7,11
9	JAWA BARAT	Cianjur	11,05	9,32	8,41	7,71	5,99
10	JAWA BARAT	Bandung	8,58	8,32	6,98	6,52	6,36
11	JAWA BARAT	Garut	8,95	8,68	7,60	7,33	6,96
12	JAWA BARAT	Tasikmalaya	7,12	6,16	4,17	3,89	3,74
13	JAWA BARAT	Ciamis	5,66	5,06	3,75	3,52	3,37
14	JAWA BARAT	Kuningan	11,22	11,68	9,81	9,49	7,78
15	JAWA BARAT	Cirebon	11,52	10,38	8,11	7,65	6,74
16	JAWA BARAT	Majalengka	5,84	5,71	4,16	4,12	4,01
17	JAWA BARAT	Sumedang	9,89	9,18	7,72	6,94	6,16
18	JAWA BARAT	Indramayu	9,21	8,30	6,49	6,46	6,25
19	JAWA BARAT	Subang	9,48	9,77	7,77	7,65	6,73
20	JAWA BARAT	Purwakarta	11,07	10,70	8,75	7,72	7,34
21	JAWA BARAT	Karawang	11,52	11,83	9,87	8,95	8,04
22	JAWA BARAT	Bekasi	11,54	10,09	10,31	8,87	8,82
23	JAWA BARAT	Bandung Barat	12,25	11,65	9,63	8,11	6,70
24	JAWA BARAT	Pangandaran	5,08	3,25	1,56	1,52	1,58
25	JAWA BARAT	Kota Bogor	12,68	11,79	10,78	9,39	8,13
26	JAWA BARAT	Kota Sukabumi	12,17	10,78	8,83	8,53	8,34
27	JAWA BARAT	Kota Bandung	11,19	11,46	9,55	8,83	7,40
28	JAWA BARAT	Kota Cirebon	10,97	10,53	8,42	7,66	6,29
29	JAWA BARAT	Kota Bekasi	10,68	10,88	8,81	7,90	7,82
30	JAWA BARAT	Kota Depok	9,87	9,76	7,82	6,97	6,27
31	JAWA BARAT	Kota Cimahi	13,30	13,07	10,77	10,52	8,97
32	JAWA BARAT	Kota Tasikmalaya	7,99	7,66	6,62	6,55	6,49
33	JAWA BARAT	Kota Banjar	6,73	6,09	5,53	5,43	5,44
34	BANTEN	Pandeglang	9,15	7,70	9,24	9,05	8,09
35	BANTEN	Lebak	9,63	7,86	8,55	7,57	6,23
36	BANTEN	Tangerang	13,06	9,06	7,88	6,94	6,06
37	BANTEN	Serang	12,22	10,58	10,61	9,94	9,18
38	BANTEN	Kota Tangerang	8,63	9,07	7,16	6,76	5,92
39	BANTEN	Kota Cilegon	12,69	10,13	8,10	7,25	6,08
40	BANTEN	Kota Serang	9,26	9,41	8,17	7,45	7,12
41	BANTEN	Kota Tangerang Selatan	8,48	8,60	6,59	5,81	5,09

Data Variabel TPAK

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	60,70	65,45	67,68	73,70	72,58
2	DKI JAKARTA	Kota Jakarta Selatan	63,81	61,44	63,07	66,05	64,81
3	DKI JAKARTA	Kota Jakarta Timur	61,98	60,85	61,26	65,11	64,49
4	DKI JAKARTA	Kota Jakarta Pusat	63,73	63,17	63,60	63,98	65,12
5	DKI JAKARTA	Kota Jakarta Barat	64,37	63,21	63,97	64,80	64,12
6	DKI JAKARTA	Kota Jakarta Utara	65,97	65,79	64,34	65,50	67,77
7	JAWA BARAT	Bogor	62,65	62,55	63,75	64,22	66,30
8	JAWA BARAT	Sukabumi	61,56	64,93	69,11	67,75	69,75
9	JAWA BARAT	Cianjur	69,26	67,98	69,98	72,31	72,63
10	JAWA BARAT	Bandung	62,20	65,12	63,64	67,10	67,22
11	JAWA BARAT	Garut	61,11	62,76	68,84	70,10	71,34
12	JAWA BARAT	Tasikmalaya	69,54	68,18	67,83	68,37	68,76
13	JAWA BARAT	Ciamis	71,41	69,83	68,47	66,26	68,14
14	JAWA BARAT	Kuningan	61,98	63,82	61,80	61,95	65,84
15	JAWA BARAT	Cirebon	63,79	64,49	65,53	66,16	69,27
16	JAWA BARAT	Majalengka	69,66	67,63	66,21	68,50	69,64
17	JAWA BARAT	Sumedang	68,96	68,51	64,63	67,76	69,24
18	JAWA BARAT	Indramayu	69,53	69,86	69,08	63,88	66,43
19	JAWA BARAT	Subang	66,70	67,78	68,87	70,03	71,71
20	JAWA BARAT	Purwakarta	60,91	61,13	65,21	66,37	66,62
21	JAWA BARAT	Karawang	64,90	64,19	65,51	63,40	63,67
22	JAWA BARAT	Bekasi	64,23	65,87	65,41	65,00	65,11
23	JAWA BARAT	Bandung Barat	59,91	60,75	64,37	67,01	68,30
24	JAWA BARAT	Pangandaran	76,79	74,75	79,92	80,15	80,12
25	JAWA BARAT	Kota Bogor	60,81	61,77	64,21	64,81	67,35
26	JAWA BARAT	Kota Sukabumi	55,74	56,86	62,48	62,57	62,58
27	JAWA BARAT	Kota Bandung	64,71	65,31	69,42	66,97	67,93
28	JAWA BARAT	Kota Cirebon	63,76	62,87	65,42	68,71	68,55
29	JAWA BARAT	Kota Bekasi	64,74	64,76	65,33	64,65	65,58
30	JAWA BARAT	Kota Depok	63,96	62,62	63,35	62,76	62,89
31	JAWA BARAT	Kota Cimahi	62,67	61,79	67,22	68,43	66,52
32	JAWA BARAT	Kota Tasikmalaya	66,54	65,75	65,99	65,44	68,92
33	JAWA BARAT	Kota Banjar	67,35	64,07	63,76	67,44	67,22
34	BANTEN	Pandeglang	60,28	62,32	61,66	60,33	66,92
35	BANTEN	Lebak	69,97	66,75	66,17	67,90	72,82
36	BANTEN	Tangerang	65,43	63,94	67,05	66,87	65,88
37	BANTEN	Serang	63,46	63,86	64,25	63,22	67,77
38	BANTEN	Kota Tangerang	64,97	64,52	66,08	63,39	66,02
39	BANTEN	Kota Cilegon	61,83	61,37	67,39	62,70	60,83
40	BANTEN	Kota Serang	63,79	62,16	64,80	68,44	69,10
41	BANTEN	Kota Tangerang Selatan	62,49	62,56	58,67	60,50	58,13

Data Variabel GR

No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	0,31	0,24	0,21	0,43	0,43
2	DKI JAKARTA	Kota Jakarta Selatan	0,43	0,38	0,38	0,43	0,43
3	DKI JAKARTA	Kota Jakarta Timur	0,36	0,37	0,37	0,43	0,43
4	DKI JAKARTA	Kota Jakarta Pusat	0,39	0,40	0,34	0,43	0,43
5	DKI JAKARTA	Kota Jakarta Barat	0,38	0,37	0,42	0,43	0,43
6	DKI JAKARTA	Kota Jakarta Utara	0,41	0,52	0,54	0,43	0,43
7	JAWA BARAT	Bogor	0,38	0,40	0,40	0,37	0,40
8	JAWA BARAT	Sukabumi	0,33	0,34	0,31	0,35	0,34
9	JAWA BARAT	Cianjur	0,35	0,37	0,31	0,32	0,34
10	JAWA BARAT	Bandung	0,41	0,39	0,37	0,35	0,36
11	JAWA BARAT	Garut	0,35	0,32	0,30	0,36	0,32
12	JAWA BARAT	Tasikmalaya	0,34	0,38	0,38	0,40	0,36
13	JAWA BARAT	Ciamis	0,34	0,34	0,34	0,34	0,33
14	JAWA BARAT	Kuningan	0,36	0,35	0,34	0,35	0,37
15	JAWA BARAT	Cirebon	0,34	0,34	0,35	0,36	0,37
16	JAWA BARAT	Majalengka	0,34	0,35	0,37	0,34	0,35
17	JAWA BARAT	Sumedang	0,38	0,36	0,39	0,37	0,34
18	JAWA BARAT	Indramayu	0,32	0,32	0,30	0,34	0,31
19	JAWA BARAT	Subang	0,35	0,33	0,36	0,33	0,32
20	JAWA BARAT	Purwakarta	0,41	0,39	0,37	0,37	0,40
21	JAWA BARAT	Karawang	0,33	0,37	0,35	0,39	0,38
22	JAWA BARAT	Bekasi	0,37	0,34	0,37	0,40	0,37
23	JAWA BARAT	Bandung Barat	0,38	0,36	0,37	0,37	0,40
24	JAWA BARAT	Pangandaran	0,34	0,32	0,29	0,32	0,29
25	JAWA BARAT	Kota Bogor	0,41	0,44	0,43	0,46	0,48
26	JAWA BARAT	Kota Sukabumi	0,40	0,44	0,48	0,46	0,44
27	JAWA BARAT	Kota Bandung	0,40	0,43	0,46	0,46	0,44
28	JAWA BARAT	Kota Cirebon	0,42	0,49	0,47	0,47	0,42
29	JAWA BARAT	Kota Bekasi	0,35	0,40	0,44	0,41	0,43
30	JAWA BARAT	Kota Depok	0,34	0,37	0,39	0,40	0,40
31	JAWA BARAT	Kota Cimahi	0,38	0,41	0,41	0,39	0,40
32	JAWA BARAT	Kota Tasikmalaya	0,37	0,41	0,41	0,43	0,36
33	JAWA BARAT	Kota Banjar	0,31	0,34	0,36	0,34	0,32
34	BANTEN	Pandeglang	0,30	0,27	0,30	0,24	0,24
35	BANTEN	Lebak	0,31	0,33	0,31	0,27	0,26
36	BANTEN	Tangerang	0,28	0,29	0,28	0,29	0,27
37	BANTEN	Serang	0,30	0,26	0,28	0,27	0,27
38	BANTEN	Kota Tangerang	0,34	0,34	0,38	0,38	0,33
39	BANTEN	Kota Cilegon	0,37	0,36	0,32	0,36	0,36
40	BANTEN	Kota Serang	0,35	0,34	0,35	0,31	0,32
41	BANTEN	Kota Tangerang Selatan	0,37	0,37	0,36	0,36	0,40

Data Variabel JP

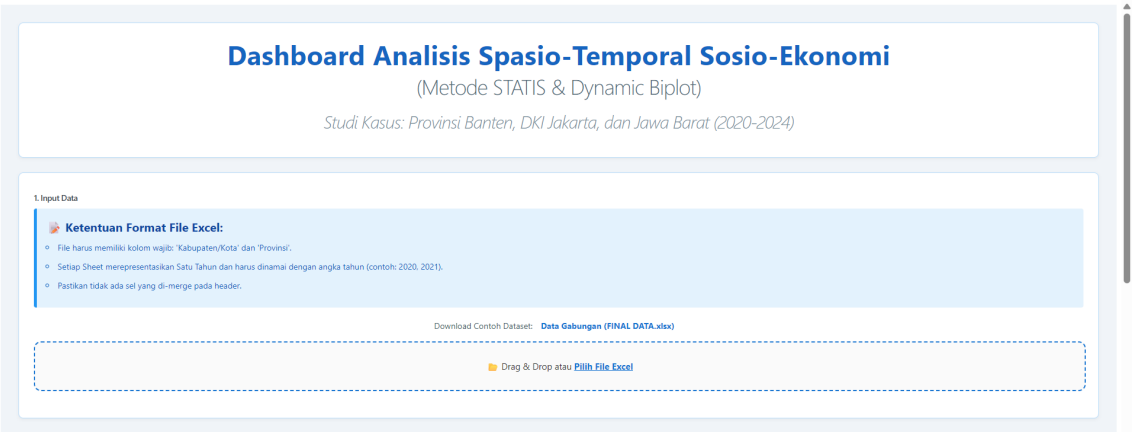
No	Provinsi	Kabupaten/Kota	2020	2021	2022	2023	2024
1	DKI JAKARTA	Kep. Seribu	27.749,00	27.996,00	28.262,00	28.523,00	30.420,00
2	DKI JAKARTA	Kota Jakarta Selatan	2.226.812,00	2.232.442,00	2.234.262,00	2.235.606,00	2.410.000,00
3	DKI JAKARTA	Kota Jakarta Timur	3.037.139,00	3.051.866,00	3.066.074,00	3.079.618,00	3.310.000,00
4	DKI JAKARTA	Kota Jakarta Pusat	1.056.896,00	1.057.465,00	1.053.482,00	1.049.314,00	1.100.000,00
5	DKI JAKARTA	Kota Jakarta Barat	2.434.511,00	2.446.687,00	2.458.707,00	2.470.054,00	2.610.000,00
6	DKI JAKARTA	Kota Jakarta Utara	1.778.981,00	1.788.981,00	1.799.220,00	1.808.985,00	1.870.000,00
7	JAWA BARAT	Bogor	5.409.370,00	5.484.150,00	5.556.310,00	5.627.020,00	5.682.300,00
8	JAWA BARAT	Sukabumi	2.718.740,00	2.747.450,00	2.775.310,00	2.802.400,00	2.828.020,00
9	JAWA BARAT	Cianjur	2.470.560,00	2.500.640,00	2.529.810,00	2.558.140,00	2.584.990,00
10	JAWA BARAT	Bandung	3.616.540,00	3.652.400,00	3.687.250,00	3.721.110,00	3.753.120,00
11	JAWA BARAT	Garut	2.577.350,00	2.613.530,00	2.648.950,00	2.683.670,00	2.716.950,00
12	JAWA BARAT	Tasikmalaya	1.861.060,00	1.876.890,00	1.892.220,00	1.907.050,00	1.920.920,00
13	JAWA BARAT	Ciamis	1.226.050,00	1.234.830,00	1.243.320,00	1.251.540,00	1.259.230,00
14	JAWA BARAT	Kuningan	1.162.590,00	1.175.950,00	1.189.010,00	1.201.760,00	1.213.930,00
15	JAWA BARAT	Cirebon	2.270.350,00	2.301.330,00	2.331.360,00	2.360.440,00	2.387.960,00
16	JAWA BARAT	Majalengka	1.301.570,00	1.315.010,00	1.328.010,00	1.340.620,00	1.352.540,00
17	JAWA BARAT	Sumedang	1.149.470,00	1.159.260,00	1.168.840,00	1.178.240,00	1.187.130,00
18	JAWA BARAT	Indramayu	1.829.230,00	1.851.730,00	1.873.400,00	1.894.330,00	1.914.040,00
19	JAWA BARAT	Subang	1.605.250,00	1.620.700,00	1.635.560,00	1.649.820,00	1.663.160,00
20	JAWA BARAT	Purwakarta	994.330,00	1.008.930,00	1.023.180,00	1.037.070,00	1.050.340,00
21	JAWA BARAT	Karawang	2.434.090,00	2.465.570,00	2.496.190,00	2.526.000,00	2.554.380,00
22	JAWA BARAT	Bekasi	3.101.730,00	3.148.740,00	3.193.840,00	3.237.420,00	3.273.870,00
23	JAWA BARAT	Bandung Barat	1.782.190,00	1.808.420,00	1.834.230,00	1.859.640,00	1.884.190,00
24	JAWA BARAT	Pangandaran	422.410,00	425.590,00	428.600,00	431.460,00	434.100,00
25	JAWA BARAT	Kota Bogor	1.040.570,00	1.050.920,00	1.060.940,00	1.070.720,00	1.078.350,00
26	JAWA BARAT	Kota Sukabumi	344.830,00	350.150,00	355.420,00	360.640,00	365.740,00
27	JAWA BARAT	Kota Bandung	2.438.350,00	2.461.410,00	2.484.150,00	2.506.600,00	2.528.160,00
28	JAWA BARAT	Kota Cirebon	332.580,00	335.810,00	338.940,00	341.980,00	344.850,00
29	JAWA BARAT	Kota Bekasi	2.536.120,00	2.568.020,00	2.598.070,00	2.627.210,00	2.644.060,00
30	JAWA BARAT	Kota Depok	2.046.830,00	2.081.130,00	2.113.620,00	2.145.400,00	2.163.640,00
31	JAWA BARAT	Kota Cimahi	566.170,00	574.450,00	582.650,00	590.780,00	598.700,00
32	JAWA BARAT	Kota Tasikmalaya	713.670,00	723.100,00	732.480,00	741.760,00	750.730,00
33	JAWA BARAT	Kota Banjar	200.270,00	202.720,00	205.140,00	207.510,00	209.790,00
34	BANTEN	Pandeglang	1.270,09	1.284,64	1.298,85	1.312,77	1.325,95
35	BANTEN	Lebak	1.383,54	1.400,63	1.417,35	1.433,70	1.449,21
36	BANTEN	Tangerang	3.236,70	3.279,71	3.321,65	3.362,61	3.400,49
37	BANTEN	Serang	1.618,36	1.640,11	1.661,37	1.682,13	1.701,80
38	BANTEN	Kota Tangerang	1.891,40	1.912,03	1.931,64	1.950,58	1.963,97
39	BANTEN	Kota Cilegon	433,76	439,48	445,06	450,51	455,62
40	BANTEN	Kota Serang	689,41	700,95	712,41	723,79	734,87
41	BANTEN	Kota Tangerang Selatan	1.351,31	1.365,39	1.378,71	1.391,65	1.399,50

Lampiran 2 Kode Program Aplikasi Dashboard

Kode program aplikasi dashboard yang digunakan dalam penelitian ini dapat diakses secara daring melalui tautan berikut:

https://huggingface.co/spaces/ammarhnfi/skripsi/blob/main/app.py

Berikut adalah tampilan antarmuka aplikasi dashboard:



Gambar 1: Tampilan Antarmuka Aplikasi Dashboard Analisis Spasio-Temporal Sosio-Ekonomi