BAB 1
PENDAHULUAN

1.1 Latar Belakang

Kawasan strategis yang meliputi Provinsi Banten, DKI Jakarta, dan Jawa Barat tidak hanya berperan sebagai mesin pertumbuhan ekonomi nasional, tetapi juga menjadi arena dinamika pembangunan manusia yang sangat kompleks dalam lima tahun terakhir. Meskipun wilayah ini memberikan kontribusi yang sangat dominan terhadap perekonomian nasional dengan rata-rata pangsa Produk Domestik Regional Bruto (PDRB) sekitar 33,8 persen dari PDRB Indonesia (**?**), di mana keberhasilan pembangunannya tidak dapat lagi diukur hanya melalui kacamata indikator makro ekonomi semata. Terdapat interaksi multidimensi yang melibatkan kualitas hidup yang tecermin dalam Indeks Pembangunan Manusia (IPM), Indeks Pembangunan Gender (IPG), serta tantangan kesejahteraan sosial seperti kemiskinan dan ketahanan pangan yang terus mengalami perubahan. Kompleksitas ini menuntut pembuktian empiris yang lebih mendalam untuk melihat bagaimana indikator-indikator tersebut terdistribusi secara nyata di seluruh kabupaten/kota.

Secara empiris, lanskap pembangunan di ketiga provinsi ini menunjukkan polarisasi yang tajam antara pusat-pusat pertumbuhan utama dan wilayah penyangga. Meskipun data PDRB di kota-kota besar mencatat performa ekonomi yang kuat dengan nilai mencapai 532.606,87 miliar rupiah (**?**), capaian tersebut tidak serta-merta diikuti oleh pemerataan kesejahteraan. Hal ini terlihat dari variasi spasial yang mencolok (*striking spatial variation*) pada indikator kemiskinan, di mana Persentase Penduduk Miskin (PPM) terentang lebar dari 2,29 persen hingga mencapai 15,06 persen di wilayah lainnya. Kesenjangan ini juga terkonfirmasi oleh indikator daya beli, terlihat dari perbedaan Garis Kemiskinan (GK) dan Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP) yang bervariasi lebar antarwilayah (**?**). Lebih jauh lagi, perbedaan kapabilitas manusia juga terlihat mencolok; Rata-rata Lama Sekolah (RLS) dan Angka Harapan Hidup (AHH) masih menunjukkan perbedaan yang nyata. Indeks Pembangunan Gender (IPG) serta Tingkat Pengangguran Terbuka (TPT) masih berada di kisaran 6,55 hingga 10,12 persen pada rentang tahun 2020 hingga 2024. Namun, persoalan ketimpangan antarwilayah ini menjadi semakin rumit ketika diletakkan dalam konteks waktu yang penuh perubahan.

Selain perbedaan wilayah, tantangan analisis meningkat akibat adanya dinamika temporal yang sangat fluktuatif sepanjang periode 2020 hingga 2024. Periode ini diawali dengan peristiwa pandemi COVID-19 yang menekan indikator makroekonomi dan kesejahteraan secara serentak terlihat dari perubahan pertumbuhan ekonomi yang sempat mencapai angka 1,88 persen pada tahun 2020 (**?**) namun diikuti oleh pola pemulihan yang

lajunya tidak seragam di setiap daerah pada tahun-tahun berikutnya. Perubahan drastis dari masa pandemi COVID-19 menuju masa pemulihan ini diduga kuat telah mengubah struktur hubungan antar-indikator secara fundamental; sebagai contoh, pola korelasi antara pertumbuhan ekonomi (PDRB) dengan tingkat pengangguran (TPT) saat krisis sangat mungkin berbeda dibandingkan saat kondisi normal kembali pulih pada tahun 2023 hingga 2024. Oleh karena itu, pendekatan analisis multivariat klasik yang mengasumsikan struktur hubungan indikator bersifat statis (tetap sepanjang waktu) menjadi tidak lagi relevan untuk menganalisis fenomena pada periode yang penuh fluktuasi ini.

Untuk mengatasi keterbatasan asumsi stabilitas tersebut, diperlukan pendekatan analisis data tiga-arah (*three-way data analysis*) yang mampu menangani struktur data kompleks yang terdiri dari objek (kabupaten/kota), indikator (indikator sosio-ekonomi), dan situasi (waktu). Penelitian ini mengusulkan penggunaan metode STATIS (*Structuration des Tableaux à Trois Indices de la Statistique*), sebuah metode eksploratif yang diperkenalkan oleh **??**. Berbeda dengan Analisis Komponen Utama (PCA) konvensional yang hanya bekerja pada data dua dimensi, STATIS dirancang khusus untuk mengekstraksi informasi dari sekumpulan tabel data yang berubah seiring waktu. Metode ini memiliki keunggulan dalam membentuk sebuah struktur kompromi (*compromise structure*) yang merepresentasikan pola hubungan umum antar-indikator selama periode pengamatan, sekaligus memungkinkan identifikasi seberapa jauh struktur ekonomi setiap tahunnya menyimpang dari pola umum tersebut.

Meskipun metode STATIS mampu menghasilkan struktur kompromi secara matematis, kompleksitas hasil analisis dari matriks berdimensi tinggi sering kali sulit dipahami jika hanya disajikan dalam bentuk tabel numerik. Oleh karena itu, penelitian ini mengintegrasikan pendekatan STATIS dengan teknik visualisasi *Dynamic Biplot*. Pendekatan ini memungkinkan proyeksi posisi objek (kabupaten/kota) dan indikator (indikator ekonomi) ke dalam ruang berdimensi rendah, sekaligus menggambarkan pergeseran atau lintasan (*trajectory*) perubahan posisi tersebut dari tahun ke tahun. Dengan memanfaatkan konsep *trajectory*, pergeseran karakteristik suatu wilayah misalnya, sebuah kabupaten yang pada tahun 2020 memiliki tingkat pengangguran tinggi namun kemudian bergeser mendekati karakteristik wilayah dengan IPM tinggi pada tahun 2024 dapat dilacak secara visual. Visualisasi lintasan ini menjadi instrumen penting untuk membedakan antara fluktuasi jangka pendek akibat pandemi dan perubahan struktural jangka panjang.

Penerapan metode eksploratif multivariat seperti ini mengisi celah penting dalam literatur analisis regional di Indonesia yang selama ini didominasi oleh pendekatan inferensial klasik. Studi-studi terdahulu umumnya berfokus pada pemodelan regresi data panel atau model spasial ekonometrik untuk mengestimasi besaran pengaruh indikator independen

terhadap indikator dependen. Sebagai contoh, penelitian yang dilakukan oleh **?** menggunakan pendekatan *Dynamic Spatial Durbin Model* (SDM) untuk memodelkan kemiskinan, sedangkan **?** menerapkan pendekatan spasial yang serupa untuk menganalisis fenomena penyebaran penyakit kusta di Pulau Jawa. Fokus utama dari penelitian-penelitian tersebut adalah pengukuran besaran pengaruh peubah-peubah penjelas (*explanatory variables*) terhadap peubah respon yang terbukti nyata secara statistik. Meskipun pendekatan tersebut berhasil mengidentifikasi faktor-faktor determinan, metode inferensial ini memiliki keterbatasan dalam memvisualisasikan struktur hubungan antarindikator secara simultan (*inter-variable structure*) dan bagaimana struktur tersebut berevolusi dari waktu ke waktu (*spatio-temporal*). Hingga saat ini, belum terdapat penelitian yang secara spesifik menggunakan pendekatan eksploratif untuk memetakan dinamika struktur multivariat indikator ekonomi secara komprehensif tanpa membedakannya menjadi indikator bebas dan terikat.

Kompleksitas informasi yang dihasilkan dari analisis spasio-temporal ini menuntut media penyajian yang lebih adaptif dibandingkan laporan statis konvensional. Untuk itu, penelitian ini tidak hanya berhenti pada tataran analisis teoritis, tetapi juga mengembangkan sebuah aplikasi visualisasi interaktif berbasis web menggunakan bahasa pemrograman Python dengan kerangka kerja (*framework*) Dash dan Plotly. Pengembangan *dashboard* ini bertujuan untuk memfasilitasi Eksplorasi Data (*Exploratory Data Analysis*) secara mandiri oleh pengguna. Fitur-fitur interaktif yang disematkan seperti seleksi tahun, filter wilayah, hingga rotasi *baseline* memungkinkan para pengambil kebijakan untuk mengamati pola interaksi multivariat secara lebih mendalam. Melalui antarmuka ini, pola-pola tersembunyi (*latent patterns*) yang mungkin terlewatkan dalam tabel statistik standar dapat terdeteksi dengan lebih intuitif.

Secara keseluruhan, penelitian ini diarahkan untuk menjawab kebutuhan akan metode pemantauan pembangunan daerah yang lebih menyeluruh dan dinamis. Dengan memadukan kemampuan analitis metode STATIS dalam memahami struktur kompromi (*compromise structure*) lintas tahun dan kemampuan naratif visual dari *Dynamic Biplot*. Penelitian ini diharapkan dapat memberikan kontribusi ganda: secara akademis memperkaya khazanah penerapan statistik multivariat pada data ekonomi regional, dan secara praktis menyediakan prototipe alat bantu visual yang relevan bagi pemerintah daerah dalam mengevaluasi dampak kebijakan pasca-pandemi. Identifikasi struktur hubungan yang stabil maupun yang berubah selama lima tahun terakhir akan menjadi landasan penting dalam merumuskan strategi pembangunan yang lebih tangguh di masa depan.

Pemilihan lokasi penelitian yang mencakup seluruh kabupaten/kota di Provinsi Banten, DKI Jakarta, dan Jawa Barat didasarkan pada karakteristik interkonektivitas ekonomi yang kuat di antara ketiga wilayah ini. Sebagai kesatuan wilayah pembangunan utama di Pulau

Jawa, ketiga provinsi ini memiliki keterkaitan rantai pasok, mobilitas tenaga kerja, dan arus investasi yang sangat intensif. Permasalahan ekonomi yang terjadi di pusat pertumbuhan utama (DKI Jakarta) diproyeksikan akan merambat (*spillover*) ke wilayah penyangga di Banten dan Jawa Barat dengan skala yang berbeda-beda. Oleh karena itu, analisis yang hanya membatasi lingkup pada wilayah metropolitan Jabodetabek berpotensi mengabaikan dampak sistemik yang dirasakan oleh wilayah kabupaten non-metropolitan yang secara administratif berada dalam satu kesatuan provinsi namun memiliki karakteristik ekonomi yang jauh berbeda.

Untuk memahami kompleksitas pembangunan tersebut, penelitian ini menggunakan dua belas indikator strategis yang merepresentasikan dimensi pembangunan secara menyeluruh. Pemilihan indikator ini tidak dilakukan tanpa alasan, melainkan dipertimbangkan untuk mencakup aspek makroekonomi (PDRB ADHK), kesejahteraan material (PPM, GK, PKKP), kualitas modal manusia (IPM, RLS, AHH Laki-laki dan Perempuan), kesetaraan (IPG, Gini Ratio), serta partisipasi pasar kerja (TPT, TPAK). Kombinasi indikator ini memungkinkan analisis untuk tidak hanya pada indikator pertumbuhan konvensional, namun juga aspek inklusivitas pembangunan. Sebagai contoh, analisis simultan antara Gini Ratio dan PDRB memungkinkan deteksi dini terhadap fenomena pertumbuhan yang tidak merata (*exclusive growth*), sementara interaksi antara TPAK dan IPG dapat mengungkap hambatan struktural dalam partisipasi angkatan kerja berbasis gender.

Ketiadaan studi yang menganalisis dinamika interaksi kedua belas indikator ini secara spasio-temporal pada periode kritis 2020 hingga 2024 menciptakan sebuah ”kotak hitam” (*black box*) dalam pemahaman mengenai resiliensi ekonomi regional. Tanpa analisis struktur kompromi dan visualisasi lintasan yang jelas, para pemangku kebijakan kehilangan panduan empiris mengenai bagaimana sebenarnya pola pemulihan berlangsung di tingkat lokal apakah kembali ke struktur lama atau membentuk ekuilibrium baru. Berdasarkan urgensi untuk mengungkap fenomena tersebut secara statistik dan visual, penelitian ini disusun untuk menjawab pertanyaan-pertanyaan mendasar mengenai evolusi struktur ekonomi dan pembangunan di ketiga provinsi tersebut.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan yang akan dikaji dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana karakteristik struktur kompromi (*compromise structure*) yang merepresentasikan pola hubungan multivariat sebelas indikator pembangunan di seluruh

kabupaten/kota Provinsi Banten, DKI Jakarta, dan Jawa Barat menggunakan metode STATIS untuk memahami pola umum lintas tahun?

2. Bagaimana menguji struktur hubungan antar-indikator tersebut secara statistik selama periode 2020 hingga 2024 menggunakan uji permutasi matriks inter-struktur untuk membuktikan keberadaan dinamika temporal?

3. Bagaimana pola lintasan (*trajectory*) perubahan karakteristik ekonomi kabupaten/kota dari masa krisis pandemi (2020) hingga masa pemulihan (2024) berdasarkan visualisasi *Dynamic Biplot*?

4. Bagaimana pola pengelompokan spasial tiap tahunnya serta dinamika transisi atau perubahan kabupaten/kota antar klaster dari tahun ke tahun?

5. Bagaimana merancang aplikasi berbasis web menggunakan *framework* Dash dan Plotly sebagai alat bantu eksplorasi data yang memungkinkan pengguna melakukan pemantauan indikator pembangunan secara interaktif?

1.3 Tujuan Penelitian

Sejalan dengan rumusan masalah di atas, tujuan dari penelitian ini adalah:

1. Menganalisis karakteristik struktur kompromi (*compromise structure*) yang merepresentasikan pola hubungan multivariat sebelas indikator pembangunan di seluruh kabupaten/kota Provinsi Banten, DKI Jakarta, dan Jawa Barat menggunakan metode STATIS untuk memahami pola umum lintas tahun.

2. Menganalisis struktur hubungan antar-indikator tersebut secara statistik selama periode 2020 hingga 2024 menggunakan uji permutasi matriks inter-struktur untuk membuktikan keberadaan dinamika temporal.

3. Menganalisis pola lintasan (*trajectory*) perubahan karakteristik ekonomi kabupaten/kota dari masa krisis pandemi (2020) hingga masa pemulihan (2024) berdasarkan hasil visualisasi *Dynamic Biplot*.

4. Mengidentifikasi pola pengelompokan spasial tiap tahunnya serta dinamika transisi atau perubahan kabupaten/kota antar klaster dari tahun ke tahun.

5. Merancang aplikasi berbasis web menggunakan *framework* Dash dan Plotly sebagai alat bantu eksplorasi data yang memungkinkan pengguna melakukan pemantauan indikator pembangunan secara interaktif.

1.4 Manfaat Penelitian

Penelitian ini bermanfaat untuk:

1. Secara akademis memperkaya khazanah penerapan statistik multivariat terutama metode STATIS dan *Dynamic Biplot* pada data ekonomi regional di Indonesia.

2. Secara praktis menyediakan prototipe alat bantu visual berbasis web yang relevan bagi pemerintah daerah dalam mengevaluasi perkembangan indikator pembangunan dan dampak kebijakan pasca-pandemi.

1.5 Ruang Lingkup Penelitian

Agar pembahasan penelitian ini lebih terarah dan fokus, penulis menetapkan batasan-batasan masalah sebagai berikut:

1. **Indikator Penelitian:** Analisis menggunakan 11 indikator terpilih yang bersumber dari Badan Pusat Statistik (BPS), meliputi: Indeks Pembangunan Gender (IPG), Persentase Penduduk Miskin (PPM), PDRB ADHK, Rata-rata Lama Sekolah (RLS), Angka Harapan Hidup Laki-laki (AHH_L) dan Perempuan (AHH_P), Garis Kemiskinan (GK), Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP), Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), dan Gini Ratio (GR) untuk periode 2020 hingga 2024.

2. **Aspek Spasial:** Istilah ”spasial” dalam penelitian ini merujuk pada unit analisis berbasis wilayah (kabupaten/kota), bukan pada penggunaan matriks pembobot spasial (*spatial weight matrix*) seperti pada Ekonometrika Spasial.

3. **Fungsionalitas Aplikasi:** Aplikasi berbasis web yang dikembangkan berfungsi sebagai alat bantu eksplorasi visual (*Visual Exploratory Tool*) bagi pengguna, bukan sebagai Sistem Pendukung Keputusan (*Decision Support System*) yang menghasilkan rekomendasi kebijakan berbasis data secara otomatis.

BAB 2
LANDASAN TEORI

Bab ini berisi uraian mengenai teori-teori dasar yang menjadi fondasi metodologi penelitian. Pembahasan dimulai dari konsep indikator kesejahteraan rakyat sebagai latar belakang substansi indikator penelitian, kemudian dilanjutkan dengan struktur data tiga arah dan konsep spasio-temporal, statistika deskriptif, standardisasi data, pemilihan indikator (Uji KMO dan Bartlett), fondasi aljabar linier beserta dekomposisi matriks (nilai eigen, dekomposisi spektral, dan Singular Value Decomposition), korelasi Pearson, *Principal Component Analysis* (PCA) beserta Biplot, algoritma metode STATIS beserta uji permutasi, Dynamic Biplot dan visualisasi trajektori, metode pengelompokan (clustering), uji autokorelasi spasial Global Moran's I, dan terakhir adalah media visualisasi interaktif Plotly dan Dash.

2.1 Indikator Kesejahteraan Rakyat

Tujuan utama pembangunan suatu wilayah adalah mewujudkan kesejahteraan rakyatnya. Untuk mengukur keberhasilan pembangunan, dibutuhkan indikator-indikator yang mampu mencerminkan taraf kesejahteraan secara menyeluruh. Indikator kesejahteraan rakyat cukup luas dan kompleks sehingga hanya dapat dinilai melalui indikator-indikator terukur dari berbagai bidang pembangunan, di antaranya bidang kesehatan, pendidikan, ketenagakerjaan, taraf dan pola konsumsi, serta kemiskinan (**?**). Pemilihan indikator yang tepat dan terukur sangat menentukan kualitas analisis multivariat yang akan dilakukan.

2.1.1 Indeks Pembangunan Manusia (IPM)

Indeks Pembangunan Manusia (IPM) merupakan indeks komposit yang mengukur capaian pembangunan manusia berbasis tiga dimensi dasar: (1) umur panjang dan hidup sehat, tercermin dari angka harapan hidup saat lahir; (2) pengetahuan, tercermin dari rata-rata lama sekolah dan harapan lama sekolah; serta (3) standar hidup layak, tercermin dari pengeluaran per kapita yang disesuaikan. IPM dihitung sebagai rata-rata geometrik dari ketiga indeks dimensi tersebut dengan skala nilai 0 hingga 100. Semakin tinggi nilai IPM, semakin baik capaian pembangunan manusia di suatu wilayah (**?**).

2.1.2 Produk Domestik Regional Bruto (PDRB ADHK)

Produk Domestik Regional Bruto Atas Dasar Harga Konstan (PDRB ADHK) mencerminkan nilai tambah bruto barang dan jasa yang dihasilkan oleh seluruh unit ekonomi di

suatu wilayah dalam kurun waktu tertentu, dihitung menggunakan harga pada tahun dasar tertentu (2010) sehingga pengaruh inflasi dieliminasi. PDRB ADHK digunakan sebagai ukuran pertumbuhan ekonomi riil suatu wilayah. Satuan yang digunakan umumnya adalah juta atau miliar rupiah. Wilayah dengan PDRB ADHK yang tinggi menunjukkan kapasitas produksi ekonomi yang kuat (**?**).

2.1.3 Persentase Penduduk Miskin (PPM)

Persentase penduduk miskin adalah persentase penduduk yang memiliki rata-rata pengeluaran per kapita per bulan di bawah Garis Kemiskinan. Garis Kemiskinan (GK) mencerminkan nilai rupiah pengeluaran minimum yang diperlukan seseorang untuk memenuhi kebutuhan pokok hidupnya selama sebulan, baik kebutuhan makanan maupun non-makanan. Daerah yang lebih sejahtera pada umumnya memiliki persentase penduduk miskin yang relatif kecil (**??**).

2.1.4 Garis Kemiskinan (GK)

Garis Kemiskinan (GK) adalah nilai rupiah pengeluaran minimum yang diperlukan oleh seseorang untuk dapat memenuhi kebutuhan pokok makanan setara 2.100 kilo kalori per orang per hari dan kebutuhan pokok non-makanan yang mencakup perumahan, sandang, pendidikan, dan kesehatan. GK digunakan sebagai batas untuk menentukan status kemiskinan seseorang dan bervariasi antarwilayah bergantung pada pola konsumsi dan harga komoditas setempat (**?**).

2.1.5 Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP)

Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP) adalah estimasi proporsi populasi yang mengonsumsi energi (kalori) di bawah standar kecukupan minimum untuk menjalani kehidupan yang sehat dan aktif. Indikator ini mencerminkan dimensi ketahanan pangan suatu wilayah dan merupakan salah satu dari target Tujuan Pembangunan Berkelanjutan (SDGs) yang dipantau secara reguler oleh Badan Pusat Statistik (**?**).

2.1.6 Tingkat Pengangguran Terbuka (TPT)

Tingkat Pengangguran Terbuka (TPT) adalah persentase jumlah pengangguran terhadap jumlah angkatan kerja. Pengangguran didefinisikan sebagai penduduk usia kerja yang sedang mencari pekerjaan, mempersiapkan usaha, atau tidak mencari pekerjaan karena merasa tidak mungkin mendapatkannya, termasuk mereka yang baru mendapat pekerjaan

tetapi belum mulai bekerja. Angkatan kerja adalah penduduk dengan usia lebih dari 15 tahun yang bekerja atau sedang mencari pekerjaan. TPT yang tinggi mengindikasikan pemanfaatan tenaga kerja yang belum optimal (**??**).

2.1.7 Tingkat Partisipasi Angkatan Kerja (TPAK)

Tingkat Partisipasi Angkatan Kerja (TPAK) adalah persentase penduduk usia kerja (lebih dari 15 tahun) yang termasuk dalam angkatan kerja, baik yang sudah bekerja maupun yang sedang mencari pekerjaan. TPAK mencerminkan proporsi penduduk usia produktif yang aktif secara ekonomi. Nilai TPAK yang tinggi menandakan tingginya partisipasi masyarakat dalam kegiatan ekonomi (**?**).

2.1.8 Rata-Rata Lama Sekolah (RLS)

Rata-rata lama sekolah adalah rata-rata jumlah tahun yang telah ditempuh oleh penduduk dengan usia lebih dari 25 tahun dalam menjalani pendidikan formal. Indikator ini dihitung untuk penduduk dengan usia lebih dari 25 tahun dengan asumsi bahwa pada usia tersebut proses pendidikan pada umumnya telah selesai. Semakin tinggi nilai RLS, semakin tinggi tingkat pendidikan rata-rata penduduk suatu wilayah yang pada gilirannya mendukung peningkatan produktivitas dan kesejahteraan (**??**).

2.1.9 Angka Harapan Hidup Laki-laki

Angka Harapan Hidup (AHH) laki-laki adalah perkiraan rata-rata jumlah tahun hidup yang akan dijalani oleh seorang bayi laki-laki yang baru lahir pada suatu tahun tertentu, dengan asumsi bahwa pola mortalitas pada saat kelahiran tetap berlaku sepanjang hidupnya. Indikator ini mencerminkan derajat kesehatan penduduk laki-laki serta kualitas layanan kesehatan yang tersedia bagi mereka (**??**).

2.1.10 Angka Harapan Hidup Perempuan

Angka Harapan Hidup (AHH) perempuan adalah perkiraan rata-rata jumlah tahun hidup yang akan dijalani oleh seorang bayi perempuan yang baru lahir pada suatu tahun tertentu. Umumnya, nilai AHH perempuan lebih tinggi dibandingkan laki-laki karena perbedaan biologis dan pola perilaku kesehatan. AHH perempuan merupakan komponen penting dalam penghitungan Indeks Pembangunan Manusia (IPM) dan Indeks Pembangunan Gender (IPG) (**??**).

2.1.11 Indeks Pembangunan Gender (IPG)

Indeks Pembangunan Gender (IPG) adalah rasio capaian IPM perempuan terhadap IPM laki-laki. IPG mengukur kesenjangan gender dalam dimensi kesehatan, pendidikan, dan standar hidup. Nilai IPG sebesar 100 menunjukkan kesetaraan sempurna antara laki-laki dan perempuan, sedangkan nilai yang lebih rendah menunjukkan adanya kesenjangan yang merugikan perempuan (**?**).

2.1.12 Gini Ratio (GR)

Gini Ratio adalah ukuran tingkat ketimpangan distribusi pengeluaran atau pendapatan penduduk. Nilai Gini Ratio berada di antara 0 dan 1: nilai 0 berarti pemerataan sempurna (setiap orang memiliki pengeluaran yang sama), sedangkan nilai 1 berarti ketimpangan sempurna (satu orang menguasai seluruh pengeluaran). Gini Ratio yang tinggi menandakan tingginya kesenjangan ekonomi antar kelompok penduduk dalam suatu wilayah (**?**).

2.1.13 Jumlah Penduduk (JP)

Jumlah Penduduk (JP) merupakan banyaknya jiwa yang mendiami suatu wilayah administratif pada suatu titik waktu tertentu, sebagaimana dicatat melalui Sensus Penduduk maupun estimasi antarsensus yang diselenggarakan oleh Badan Pusat Statistik (**?**). Dalam penelitian ini, JP **tidak digunakan sebagai indikator analisis** dalam metode STATIS, melainkan berperan sebagai **basis pembentukan bobot demografis** (m_i). Bobot ini mengintegrasikan ukuran populasi setiap wilayah ke dalam analisis multivariat sehingga wilayah dengan penduduk lebih besar memberikan kontribusi yang proporsional terhadap struktur rata-rata (kontribusi ini dinamakan kompromi), dan wilayah berpenduduk kecil tidak mengubah hasil analisis multivariat secara berlebihan (**?**).

2.2 Tinjauan Penelitian Terdahulu

Penelitian mengenai analisis statistik terhadap data regional di Pulau Jawa telah banyak dilakukan dengan menggunakan berbagai pendekatan. Bagian ini merangkum beberapa penelitian relevan yang menjadi rujukan dalam pengembangan metodologi penelitian ini, sebagaimana disajikan pada Tabel 2.1.

Tabel 2.1: Ringkasan Penelitian Terdahulu

Peneliti (Tahun)	Wilayah	Metode	Hasil Utama
?	Pulau Jawa (2012-2018)	*Dynamic Spatial Panel* (Model Durbin Spasial)	Model terbaik menggunakan pembobot dua tetangga terdekat. Angka melek huruf dan fasilitas kesehatan berpengaruh signifikan terhadap kemiskinan.
?	Pulau Jawa (2017-2021)	*Dynamic Spatial Durbin Model* (DSDM)	Menemukan adanya pengaruh lag temporal dan spasiotemporal yang signifikan terhadap prevalensi kusta.
?	Pulau Jawa (2022)	*Biclustering Plaid Model* vs *Cluster-Biplot*	*Plaid model* menghasilkan kelompok wilayah yang lebih homogen dibandingkan metode biplot konvensional dalam mengelompokkan indikator kesejahteraan.

? menunjukkan bahwa pemodelan di Pulau Jawa harus mempertimbangkan efek dinamis (waktu) dan dependensi spasial secara simultan. Hal ini diperkuat oleh **?** yang menggunakan DSDM untuk menangkap interaksi antar-wilayah lintas waktu. Di sisi lain, **?** memberikan perspektif mengenai pentingnya metode pengelompokan yang mampu menangani objek dan indikator secara bersamaan untuk melihat karakteristik regional yang unik. Penelitian ini menggabungkan aspek temporal dari data tiga-arah menggunakan metode STATIS dan aspek keterkaitan spasial untuk memberikan analisis yang lebih komprehensif.

2.3 Analisis Data Tiga-Arah (*Three-Way Data*)

Dalam statistika multivariat klasik, umumnya data direpresentasikan dalam struktur dua-arah (*two-way structure*), yaitu sebuah matriks $\mathbf{X}$ berukuran $n \times p$, dengan n merepresentasikan jumlah objek dan p merepresentasikan jumlah indikator. Struktur ini memadai untuk menganalisis kondisi statis pada satu titik waktu tertentu. Namun, dalam studi yang melibatkan pemantauan berkala, struktur data menjadi lebih kompleks dengan hadirnya dimensi ketiga, yaitu waktu atau situasi (**?**).

Struktur data seperti ini dikenal sebagai data tiga-arah (*three-way data*) atau data longitudinal multivariat. Secara formal, data tiga-arah dapat didefinisikan sebagai berikut:

Definisi 2.1 (Data Tiga-Arah)**.** Misalkan terdapat n objek penelitian, p indikator, dan K situasi (waktu). Data tiga-arah adalah sekumpulan K buah matriks data $\{\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_K\}$, dengan setiap matriks $\mathbf{X}_k$ (untuk $k = 1, \ldots, K$) berukuran $n \times p$.

Elemen skalar dari data ini dinotasikan sebagai x_{ijk}, yang merepresentasikan nilai dari indikator ke-j pada objek ke-i pada situasi ke-k. Keseluruhan himpunan matriks ini sering diilustrasikan sebagai sebuah balok data (*data cube*) dengan dimensi $n \times p \times K$.

Relevansi pendekatan tiga-arah ini semakin menguat dalam analisis data regional, di mana interaksi kompleks antara wilayah, waktu, dan indikator sosial-ekonomi sangat penting untuk dipahami (**?**). Metode STATIS, yang akan dibahas selanjutnya, dirancang secara spesifik untuk mendapatkan informasi dari struktur tiga-arah $\{\mathbf{X}_k\}$ ini tanpa harus merata-ratakan data terlebih dahulu ke dalam satu matriks tunggal yang menghilangkan karakteristik temporal (**?**).

2.4 Konsep Spasio-Temporal dalam Analisis Multivariat

Analisis spasio-temporal bertujuan untuk mendeskripsikan atau memodelkan variabilitas fenomena yang terjadi dalam domain ruang dan waktu secara simultan. Tantangan utama dalam analisis ini adalah adanya dua ketergantungan sekaligus: ketergantungan antar-lokasi (spasial) dan ketergantungan antar-waktu (temporal).

Pendekatan konvensional dalam ekonometrika biasanya melakukan pendekatan terhadap masalah ini dengan menggunakan regresi data panel atau model dinamis spasial (*Spatial Dynamic Panel Data*) untuk mengetahui pengaruh antar-lokasi, dengan struktur hubungan antar-lokasi didefinisikan menggunakan matriks pembobot spasial (*spatial weight matrix*, $\mathbf{W}_{spasial}$) berbasis ketetanggaan geografis yang memiliki asumsi bahwa interaksi antar-wilayah hanya terjadi melalui batas geografis fisik yang bersifat konstan sepanjang waktu (**?**). Dalam pendekatan multivariat eksploratif seperti STATIS, definisi "spasial" dipandang dari perspektif yang berbeda.

Konsep Spasial dalam STATIS Dalam kerangka STATIS, aspek spasial direpresentasikan melalui konfigurasi kemiripan antar-objek dalam ruang multivariat, bukan melalui matriks kontiguitas geografis. Struktur "spasial" pada situasi ke-k didefinisikan oleh matriks produk skalar $\mathbf{W}_k = \mathbf{X}_k\mathbf{X}_k^T$ (berukuran $n \times n$) yang merangkum "peta" kemiripan antar-objek berdasarkan profil indikatornya.

Evolusi spasio-temporal dalam pendekatan ini difokuskan pada pengamatan perubahan konfigurasi matriks $\mathbf{W}_k$ dari waktu ke waktu, untuk menjawab pertanyaan apakah pola kemiripan antar-objek berubah selama periode pengamatan (**?**).

2.5 Standardisasi Data

Perbedaan nilai yang besar antar-indikator akibat perbedaan satuan pengukuran (misalnya rupiah, persen, dan tahun) dapat menyebabkan bias dalam analisis multivariat sehingga perlu menyamakan skala variabilitasnya. Karena 41 wilayah yang diamati merupakan populasi utuh dengan ukuran penduduk yang sangat bervariasi, standardisasi dalam kerangka STATIS dilakukan menggunakan rata-rata dan simpangan baku *terbobot* (μ dan σ) agar pusat data konsisten dengan $\mathbf{D}$ yang dijelaskan pada 2.3 (**?**). Untuk itu, terlebih dahulu didefinisikan bobot demografis dan matriks bobot berikut menggunakan jumlah penduduk sebagai dasar pembobotan. Hal ini memastikan bahwa bobot yang digunakan dalam analisis STATIS mencerminkan proporsi populasi relatif dari setiap wilayah, sehingga hasil analisis lebih representatif terhadap kondisi demografis yang sebenarnya.

Definisi 2.2 (Bobot Demografis Wilayah ke-i (m_i))**.** Misalkan $\overline{\mathrm{JP}}_i = \frac{1}{K}\sum_{k=1}^{K} \mathrm{JP}_{ik}$ adalah rata-rata jumlah penduduk wilayah ke-i selama K tahun pengamatan. Bobot demografis m_i didefinisikan sebagai proporsi penduduk wilayah ke-i terhadap total penduduk seluruh wilayah:

$$m_i = \frac{\overline{\mathrm{JP}}_i}{\sum_{i'=1}^{n} \overline{\mathrm{JP}}_{i'}}, \quad i = 1, 2, \ldots, n \tag{2.1}$$

dengan syarat $\sum_{i=1}^{n} m_i = 1$ dan $m_i > 0$. Penggunaan rata-rata lintas tahun memastikan bahwa ruang terboboti bersifat konstan di semua situasi, sehingga jarak antar-konfigurasi dapat dibandingkan secara valid (**?**).

Definisi 2.3 (Matriks Bobot $\mathbf{D}$)**.** Matriks bobot $\mathbf{D}$ adalah matriks diagonal berukuran $n \times n$ dengan elemen diagonal ke-i adalah bobot demografis m_i:

$$\mathbf{D} = \mathrm{diag}(m_1, m_2, \ldots, m_n) \tag{2.2}$$

Matriks $\mathbf{D}$ mendefinisikan suatu *inner product* terbobot pada ruang objek: $\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{D}} = \mathbf{x}^T \mathbf{D} \mathbf{y}$. Seluruh penghitungan jarak dan produk skalar dalam STATIS digunakan dalam ruang ini. Akar dan invers akarnya masing-masing dinotasikan sebagai $\mathbf{D}^{1/2} = \mathrm{diag}(\sqrt{m_1}, \ldots, \sqrt{m_n})$ dan $\mathbf{D}^{-1/2} = \mathrm{diag}(1/\sqrt{m_1}, \ldots, 1/\sqrt{m_n})$ (**?**).

Definisi 2.4 (Standardisasi Z-Score Terbobot)**.** Misalkan x_{ijk} adalah nilai indikator ke-j pada wilayah ke-i tahun ke-k. Rata-rata populasi terbobot dan simpangan baku populasi

terbobot didefinisikan sebagai:

$$\mu_{jk} = \sum_{i=1}^{n} m_i \, x_{ijk} \tag{2.3}$$

$$\sigma_{jk} = \sqrt{\sum_{i=1}^{n} m_i \, (x_{ijk} - \mu_{jk})^2} \tag{2.4}$$

Nilai terstandardisasi terbobot (*weighted standardized value*) dihitung sebagai:

$$z_{ijk} = \frac{x_{ijk} - \mu_{jk}}{\sigma_{jk}}, \quad i = 1, \ldots, n; \; j = 1, \ldots, p; \; k = 1, \ldots, K \tag{2.5}$$

Persamaan 2.5 memastikan bahwa $\sum_{i=1}^{n} m_i \, z_{ijk} = 0$ (pusat terbobot nol) dan $\sum_{i=1}^{n} m_i \, z_{ijk}^2 = 1$ (varians terbobot satu) (**?**).

Hasil standardisasi menghasilkan matriks data standar terbobot $\mathbf{Z}_k$ (berukuran $n \times p$) untuk setiap situasi ke-k. Prosedur ini memastikan bahwa tidak ada indikator yang mendominasi analisis hanya karena skala pengukurannya lebih besar, sekaligus mempertahankan konsistensi ruang bobot $\mathbf{D}$ di seluruh situasi waktu.

2.6 Statistika Deskriptif

Sebelum menerapkan metode analisis multivariat, tahap awal yang penting adalah melakukan eksplorasi data melalui Statistika Deskriptif. Statistika deskriptif bertujuan meringkas dan mendeskripsikan karakteristik distribusi data secara numerik, sehingga peneliti dapat memahami pola umum, keragaman, dan anomali pada data sebelum tahap analisis data yang lebih mendalam (**?**).

2.6.1 Ukuran Pemusatan

Ukuran pemusatan mendeskripsikan nilai "tengah" dari data.

Definisi 2.5 (Rata-Rata (Mean))**.** Rata-rata dari n pengamatan $x_1, x_2, \ldots, x_n$ suatu indikator adalah:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i \tag{2.6}$$

Rata-rata bersifat sensitif terhadap pencilan (*outlier*).

Definisi 2.6 (Median)**.** Median (Q_2) adalah nilai tengah dari suatu indikator setelah diu-

rutkan dari yang terkecil hingga yang terbesar:

$$Q_2 = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & \text{, jika } n \text{ ganjil} \\ \dfrac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2} & \text{, jika } n \text{ genap} \end{cases} \tag{2.7}$$

Nilai median lebih robust terhadap pencilan dibandingkan nilai rata-rata.

2.6.2 Ukuran Penyebaran

Ukuran penyebaran mendeskripsikan seberapa jauh data bervariasi di sekitar pusat distribusinya.

Definisi 2.7 (Simpangan Baku (Standar Deviasi))**.** Simpangan baku populasi dari n pengamatan adalah:

$$s = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2} \tag{2.8}$$

Simpangan baku merepresentasikan akar kuadrat dari ragam (*variance*) populasi s^2. Karena penelitian ini mencakup seluruh wilayah kabupaten/kota di Pulau Jawa (populasi utuh), maka pembagi yang digunakan adalah n (**?**).

Definisi 2.8 (Nilai Minimum, Maksimum, dan Rentang Antarkuartil (IQR))**.** Nilai minimum dan maksimum adalah:

$$x_{\min} = \min(x_1, \ldots, x_n), \qquad x_{\max} = \max(x_1, \ldots, x_n) \tag{2.9}$$

Kuartil pertama (Q_1) dan ketiga (Q_3) membagi distribusi data menjadi empat bagian, masing-masing 25%. Rentang Antarkuartil (*Interquartile Range*, IQR) adalah:

$$IQR = Q_3 - Q_1 \tag{2.10}$$

IQR merupakan ukuran penyebaran yang robust karena tidak dipengaruhi oleh pencilan.

Definisi 2.9 (Koefisien Variasi (CV))**.** Koefisien Variasi atau yang dalam bahasa Inggris disebut sebagai *Coefficient of Variation* (CV) digunakan untuk mengukur variabilitas relatif terhadap rata-rata, dengan rumus sebagai berikut:

$$CV = \frac{s}{\bar{x}} \times 100\% \tag{2.11}$$

CV berfungsi untuk membandingkan tingkat keragaman antar-indikator yang memiliki

satuan atau skala yang berbeda-beda, dan ukuran ini juga lazim digunakan dalam analisis stabilitas (**?**).

2.6.3 Ukuran Bentuk Distribusi

Ukuran bentuk memberikan informasi karakteristik bentuk simetris dan bentuk keruncingan dari distribusi data.

Definisi 2.10 (Kemiringan Distribusi (*Skewness*))**.** *Skewness* mengukur tingkat asimetris distribusi data:

$$g_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{s^3} \tag{2.12}$$

Interpretasi: $g_1 > 0$ berarti distribusi data condong ke kanan (*right-skewed*, ekor panjang di kanan); $g_1 < 0$ berarti condong ke kiri (*left-skewed*); $g_1 \approx 0$ berarti distribusi data hampir simetris. *Skewness* juga dapat diklasifikasikan dari rentang moderat hingga sangat menceng yang biasa dijadikan sebagai acuan baku (**?**).

Definisi 2.11 (Kurtosis (Keruncingan))**.** Kurtosis mengukur ketebalan ekor dan keruncingan relatif distribusi data dibandingkan distribusi normal:

$$g_2 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^4}{s^4} - 3 \tag{2.13}$$

Nilai negatif dari pengurangan 3 merupakan koreksi *excess kurtosis* (**?**): $g_2 > 0$ berarti distribusi data lebih runcing (*leptokurtik*); $g_2 < 0$ berarti lebih datar (*platikurtik*) dibandingkan distribusi normal.

2.7 Pemilihan Indikator dalam Analisis Multivariat

Keberhasilan suatu analisis multivariat berbasis reduksi dimensi sangat bergantung pada kualitas himpunan indikator yang digunakan. Indikator yang tidak memiliki hubungan satu sama lain tidak akan menghasilkan komponen yang bermakna, sedangkan indikator yang terlalu berkorelasi sempurna dapat menyebabkan matriks kovariansi menjadi singular (**?**). Sebelum menerapkan metode analisis, perlu dilakukan serangkaian uji statistik untuk memverifikasi bahwa himpunan indikator *layak* untuk dianalisis secara multivariat yang artinya terdapat struktur kovariansi yang cukup untuk diekstraksi (*factorable*).

Dua kriteria utama yang lazim digunakan untuk mengetahui apakah data yang akan digunakan memenuhi syarat untuk dilakukan analisis multivariat adalah: (1) Uji Kaiser-Meyer-Olkin (KMO) yang menilai kecukupan (*sampling adequacy*) masing-masing indikator maupun keseluruhan himpunan indikator, dan (2) Uji Bartlett tentang Spherisitas yang

menguji apakah matriks korelasi antar-indikator secara keseluruhan berbeda signifikan dari matriks identitas.

2.7.1 Uji Kaiser-Meyer-Olkin (KMO)

Statistik Kaiser-Meyer-Olkin (KMO) dikembangkan oleh **??** sebagai ukuran untuk menilai kecukupan sampel (*sampling adequacy*) dalam analisis faktor dan analisis komponen utama. Secara intuitif, KMO mengukur sejauh mana korelasi antar-pasang indikator dapat "dijelaskan" oleh indikator-indikator lainnya, suatu kondisi yang disebut korelasi parsial rendah. Apabila korelasi parsial antar-indikator rendah setelah dikontrol indikator lain, maka ada faktor laten yang mendasari struktur korelasinya, kondisi ini disyaratkan dalam analisis berbasis reduksi dimensi (**?**).

Definisi 2.12 (Statistik KMO)**.** Misalkan r_{jk} adalah koefisien korelasi Pearson antara indikator ke-j dan ke-k, dan q_{jk} adalah elemen dari invers matriks korelasi $\mathbf{R}^{-1}$. Korelasi parsial antara indikator ke-j dan ke-k dihitung sebagai:

$$r_{jk.\text{parsial}} = -\frac{q_{jk}}{\sqrt{q_{jj} \cdot q_{kk}}} \tag{2.14}$$

Statistik KMO keseluruhan (*overall KMO*) didefinisikan sebagai:

$$KMO = \frac{\sum_{j \neq k} r_{jk}^2}{\sum_{j \neq k} r_{jk}^2 + \sum_{j \neq k} r_{jk.\text{parsial}}^2} \tag{2.15}$$

Nilai KMO berada di antara 0 dan 1. Semakin besar nilai KMO, semakin kecil jumlah kuadrat korelasi parsial (penyebut) relatif terhadap jumlah kuadrat korelasi bivariate (pembilang). Hal ini mengindikasikan bahwa indikator-indikator saling berbagi faktor laten yang kuat.

Selain statistik KMO keseluruhan, **?** mendefinisikan Measure of Sampling Adequacy (MSA_j) untuk setiap indikator ke-j:

$$MSA_j = \frac{\sum_{k \neq j} r_{jk}^2}{\sum_{k \neq j} r_{jk}^2 + \sum_{k \neq j} r_{jk.\text{parsial}}^2} \tag{2.16}$$

Interpretasi nilai KMO dan MSA_j menurut **?** dan **?** disajikan pada Tabel 2.2 berikut:

Tabel 2.2: Kriteria Interpretasi Nilai KMO

Nilai KMO (x)	Interpretasi
$0{,}90 \leq x \leq 1{,}00$	Marvelous (Luar Biasa)
$0{,}80 \leq x < 0{,}90$	Meritorious (Sangat Baik)
$0{,}70 \leq x < 0{,}80$	Middling (Cukup Baik)
$0{,}60 \leq x < 0{,}70$	Mediocre (Biasa)
$0{,}50 \leq x < 0{,}60$	Miserable (Buruk, namun dapat diterima)
$x < 0{,}50$	Unacceptable (Tidak diterima)

Apabila nilai MSA_j suatu indikator lebih kecil dari 0,50; indikator tersebut dipertimbangkan untuk dikeluarkan dari analisis dan himpunan indikator diuji ulang hingga semua indikator yang tersisa memenuhi syarat untuk dianalisis lebih lanjut (**??**).

2.7.2 Uji Bartlett tentang Spherisitas (*Bartlett's Test of Sphericity*)

Uji Bartlett tentang Spherisitas, dikembangkan oleh **?**, bertujuan menguji hipotesis nol bahwa matriks korelasi populasi adalah matriks identitas ($\mathbf{R} = \mathbf{I}$). Jika $\mathbf{R} = \mathbf{I}$, tidak ada korelasi sama sekali antar-indikator sehingga tidak ada informasi bersama yang dapat diekstraksi melalui analisis multivariat (**?**).

Definisi 2.13 (Uji Bartlett tentang Spherisitas)**.** Diberikan matriks korelasi sampel $\mathbf{R}$ (berukuran $p \times p$, dengan p adalah banyaknya indikator) dari n observasi. Hipotesis uji Bartlett adalah:

- H_0: $\boldsymbol{\Sigma} = \sigma^2\mathbf{I}$ (matriks korelasi populasi adalah matriks identitas)
- H_1: $\boldsymbol{\Sigma} \neq \sigma^2\mathbf{I}$ (terdapat korelasi yang signifikan antar-indikator)

Statistik uji χ^2 dihitung dengan aproksimasi (**?**):

$$\chi^2 = -\left[n - 1 - \frac{2p+5}{6}\right] \ln |\mathbf{R}| \tag{2.17}$$

dengan $|\mathbf{R}|$ adalah determinan matriks korelasi. Statistik ini berdistribusi χ^2 dengan derajat bebas:

$$df = \frac{p(p-1)}{2} \tag{2.18}$$

Logika Determinan Matriks Korelasi Apabila semua indikator saling tidak berkorelasi, maka $\mathbf{R} = \mathbf{I}$ sehingga $|\mathbf{R}| = 1$ dan $\ln(1) = 0$, sehingga nilai statistik uji χ^2 bernilai nol, artinya korelasi antar indikator tidak signifikan. Sebaliknya, ketika indikator-indikator saling berkorelasi erat, $|\mathbf{R}| \to 0$ sehingga $\ln |\mathbf{R}|$ bernilai negatif dan statistik uji menjadi besar, menghasilkan p-value yang kecil (**?**).

Jika p-value $< \alpha$, maka H_0 ditolak, yang berarti terdapat struktur korelasi yang signifikan. Kondisi ini merupakan prasyarat yang diperlukan agar analisis reduksi dimensi dapat mengekstraksi informasi yang bermakna.

Definisi 2.14 (Determinan Matriks)**.** Determinan dari matriks bujur sangkar $\mathbf{A}$ berukuran $p \times p$, dinotasikan sebagai $|\mathbf{A}|$ atau $\det(\mathbf{A})$, adalah sebuah nilai skalar yang merangkum properti-properti penting dari matriks tersebut, termasuk keterbalikannya (*invertibility*) dan sifat singular. Secara formal, determinan didefinisikan sebagai (**?**):

$$|\mathbf{A}| = \sum_{\sigma \in S_p} \text{sgn}(\sigma) \prod_{i=1}^{p} a_{i,\sigma(i)} \tag{2.19}$$

dengan:

- S_p adalah himpunan seluruh permutasi dari indeks $\{1, 2, \ldots, p\}$.
- $\text{sgn}(\sigma)$ adalah tanda (paritas) dari permutasi σ (bernilai $+1$ untuk permutasi genap, dan -1 untuk permutasi ganjil).
- $a_{i,\sigma(i)}$ mewakili elemen matriks pada baris ke-i dan kolom ke-$\sigma(i)$.

Untuk matriks korelasi populasi $\mathbf{R}$, nilai determinan memberikan ukuran global atas keberadaan multikolinieritas antar indikator. Apabila indikator-indikator saling bebas linier (matriks korelasi membentuk matriks identitas), maka determinan bernilai maksimum, yaitu $|\mathbf{R}| = 1$. Sebaliknya, semakin tinggi korelasi linier antar indikator, nilai determinan akan semakin mengecil mendekati 0. Jika determinan bernilai mutlak 0, matriks saling berkorelasi sempurna sehingga tidak dapat diinvers (**?**).

2.8 Dasar Aljabar Linier dan Dekomposisi Matriks

Metode reduksi dimensi seperti *Principal Component Analysis* (PCA) dan STATIS sangat bergantung pada operasi aljabar linier, khususnya dekomposisi matriks simetris. Pemahaman mengenai nilai eigen, vektor eigen, dan sifat *trace* matriks menjadi prasyarat untuk memahami bagaimana metode-metode ini mengekstraksi informasi struktural dari data.

Definisi 2.15 (Nilai Eigen dan Vektor Eigen)**.** Diberikan sebuah matriks persegi $\mathbf{A}$ berukuran $p \times p$. Sebuah skalar λ disebut sebagai **nilai eigen** (*eigenvalue*) dari $\mathbf{A}$ jika terdapat sebuah vektor tak-nol $\mathbf{v}$ (berukuran $p \times 1$) yang disebut **vektor eigen** (*eigenvector*), sedemikian sehingga berlaku:

$$\mathbf{A}\mathbf{v} = \lambda \mathbf{v} \tag{2.20}$$

Vektor eigen menentukan "arah" dominan dari transformasi linier matriks $\mathbf{A}$, sedangkan nilai eigen menentukan besaran "kekuatan" atau variansi pada arah tersebut.

Definisi 2.16 (Invers Matriks)**.** Sebuah matriks persegi $\mathbf{A}$ memiliki invers $\mathbf{A}^{-1}$ jika $\det(\mathbf{A}) \neq 0$, sedemikian sehingga berlaku $\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$, dengan $\mathbf{I}$ adalah matriks identitas. Invers dari matriks korelasi digunakan dalam penghitungan statistik KMO untuk mendapatkan korelasi parsial melalui matriks anti-citra.

Karena matriks kovariansi selalu bersifat simetris ($\mathbf{A} = \mathbf{A}^T$), berlaku teorema dekomposisi spektral berikut.

Teorema 2.1 (Dekomposisi Spektral)**.** Setiap matriks simetris $\mathbf{A}$ berukuran $p \times p$ dapat didekomposisi menjadi:

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T = \sum_{j=1}^{p} \lambda_j \mathbf{v}_j \mathbf{v}_j^T \tag{2.21}$$

dengan $\mathbf{V}$ adalah matriks ortogonal ($p \times p$) yang kolom-kolomnya ($\mathbf{v}_j$) adalah vektor eigen yang saling tegak lurus, dan $\mathbf{\Lambda}$ adalah matriks diagonal berisi nilai eigen terurut $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$ pada elemen diagonalnya.

Selain dekomposisi, konsep *trace* matriks juga menjadi fundamental, khususnya dalam penghitungan koefisien korelasi antar-konfigurasi (Koefisien RV) pada metode STATIS.

Definisi 2.17 (Trace Matriks)**.** *Trace* dari sebuah matriks persegi $\mathbf{A}$ berukuran $n \times n$, dinotasikan sebagai $tr(\mathbf{A})$, adalah penjumlahan dari elemen-elemen diagonal utamanya:

$$tr(\mathbf{A}) = \sum_{i=1}^{n} a_{ii} \tag{2.22}$$

Sifat penting dari *trace* yang digunakan dalam pengukuran jarak antar-matriks adalah invariansi siklis: $tr(\mathbf{AB}) = tr(\mathbf{BA})$.

Definisi 2.18 (Dekomposisi Nilai Singular (SVD))**.** *Singular Value Decomposition* (SVD) adalah faktorisasi yang dapat diterapkan pada matriks persegi panjang manapun $\mathbf{A}$ berukuran $m \times n$:

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^T \tag{2.23}$$

dengan:

- $\mathbf{U}$ ($m \times m$): matriks ortogonal, kolom-kolomnya disebut **vektor singular kiri**.
- $\mathbf{S}$ ($m \times n$): matriks diagonal yang berisi **nilai singular** $\sigma_1 \geq \sigma_2 \geq \cdots \geq 0$ pada diagonal utamanya.

- $\mathbf{V}^T$ $(n \times n)$: transpos dari matriks ortogonal $\mathbf{V}$, kolom-kolomnya disebut **vektor singular kanan**.

Untuk matriks simetris semi-definit positif $\mathbf{W}_c$ (seperti matriks kompromi STATIS), SVD setara dengan dekomposisi spektral: nilai singular σ_i sama dengan nilai eigen λ_i dan $\mathbf{U} = \mathbf{V}$.

Ekuivalensi SVD dan Eigendekomposisi untuk Matriks Simetris PSD Untuk matriks simetris semi-definit positif $\mathbf{A} = \mathbf{A}^T$ dengan $\mathbf{v}^T\mathbf{A}\mathbf{v} \geq 0$ untuk semua $\mathbf{v}$, berlaku identitas: jika $\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$ adalah dekomposisi spektral (dengan $\mathbf{\Lambda} = \mathrm{diag}(\lambda_1, \ldots, \lambda_n)$, $\lambda_i \geq 0$, dan $\mathbf{Q}$ ortogonal), maka $\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$ sudah merupakan SVD dengan $\mathbf{U} = \mathbf{V} = \mathbf{Q}$ dan $\mathbf{\Sigma} = \mathbf{\Lambda}$ (nilai singular = nilai eigen). Ini karena nilai singular suatu matriks didefinisikan sebagai akar kuadrat nilai eigen dari $\mathbf{A}^T\mathbf{A} = \mathbf{A}^2$; untuk matriks PSD, $\sqrt{\lambda_i(\mathbf{A}^2)} = \sqrt{\lambda_i^2} = \lambda_i = \sigma_i$. Akibatnya, dalam implementasi komputasional penelitian ini, `numpy.linalg.eigh` (eigendekomposisi untuk matriks Hermitian/simetris) dan `numpy.linalg.svd` menghasilkan hasil yang secara aljabar identik untuk $\mathbf{W}_c$.

SVD memiliki kestabilan numerik yang lebih baik dibandingkan dekomposisi eigen langsung untuk matriks nonsimetris. Untuk $\mathbf{W}_c$ yang simetris PSD, keduanya setara. Skor kompromi STATIS ($\mathbf{F}_c$) diperoleh dari:

$$\mathbf{F}_c = \mathbf{U}\sqrt{\mathbf{S}} \tag{2.24}$$

sehingga $\mathbf{W}_c = \mathbf{U}\mathbf{S}\mathbf{U}^T = \mathbf{F}_c\mathbf{F}_c^T$.

2.9 Korelasi Pearson

Korelasi Pearson adalah ukuran statistik yang mengkuantifikasi kekuatan dan arah hubungan linier antara dua indikator. Koefisien ini digunakan secara luas dalam analisis multivariat, khususnya pada pembentukan matriks korelasi yang merupakan fondasi Uji KMO dan Bartlett, serta pada komputasi *loadings* (arah indikator dalam Biplot) (**?**).

Definisi 2.19 (Koefisien Korelasi Pearson)**.** Koefisien korelasi Pearson antara dua indikator x dan y dari n pengamatan didefinisikan sebagai:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{2.25}$$

Nilai r_{xy} berada di antara -1 dan 1:

- $r_{xy} = 1$: korelasi positif sempurna (ketika x naik, y naik proporsional).
- $r_{xy} = -1$: korelasi negatif sempurna (ketika x naik, y turun proporsional).
- $r_{xy} = 0$: tidak ada hubungan linier.

Matriks Korelasi Untuk p indikator, koefisien Pearson antar setiap pasang indikator dapat disusun menjadi matriks korelasi simetris $\mathbf{R}$ berukuran $p \times p$, dengan elemen (j, k)-nya adalah r_{jk}. Diagonal utamanya selalu bernilai 1 ($r_{jj} = 1$). Matriks korelasi inilah yang menjadi dasar penghitungan statistik KMO dan Bartlett.

Dalam konteks Dynamic Biplot, loadings indikator ke-j pada komponen ke-ℓ dihitung sebagai korelasi Pearson antara nilai rata-rata indikator tersebut lintas situasi ($\bar{x}_j$) dengan skor kompromi pada komponen ke-ℓ ($\mathbf{F}_c^{(\ell)}$):

$$g_{j\ell} = r(\bar{x}_j, \mathbf{F}_c^{(\ell)}) \tag{2.26}$$

Panjang vektor loading $\sqrt{g_{j1}^2 + g_{j2}^2}$ mencerminkan seberapa baik indikator tersebut direpresentasikan dalam ruang dua dimensi kompromi.

2.10 *Principal Component Analysis* (PCA) dan Biplot

Principal Component Analysis (PCA) atau dalam bahasa Indonesia dikenal sebagai Analisis Komponen Utama merupakan metode yang pertama kali diinisiasi oleh **?** melalui gagasan penyesuaian bidang pada himpunan titik, kemudian berkembang menjadi teknik reduksi dimensi data multivariat yang mentransformasi p indikator asli yang saling berkorelasi menjadi q indikator baru ($q < p$) yang tidak berkorelasi, disebut komponen utama (*principal components*) (**?**).

Misalkan $\mathbf{X}$ adalah matriks data berukuran $n \times p$ yang telah distandardisasi. PCA mengekstraksi informasi dengan mendekomposisi matriks kovariansi $\mathbf{S} = \frac{1}{n-1}\mathbf{X}^T\mathbf{X}$. Berdasarkan Teorema Dekomposisi Spektral, $\mathbf{S} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$, menghasilkan dua elemen utama:

1. **Matriks Loadings (G)** adalah matriks vektor eigen yang berisi bobot kontribusi setiap indikator asli terhadap setiap komponen utama. Kolom ke-j dari $\mathbf{V}$ disebut vektor loading ke-j.

2. **Matriks Scores (F)** adalah proyeksi data asli ke dalam ruang komponen utama, dihitung sebagai:

$$\mathbf{F} = \mathbf{XV} \tag{2.27}$$

Untuk memvisualisasikan hasil reduksi dimensi secara simultan antara objek dan indikator, digunakan teknik Biplot.

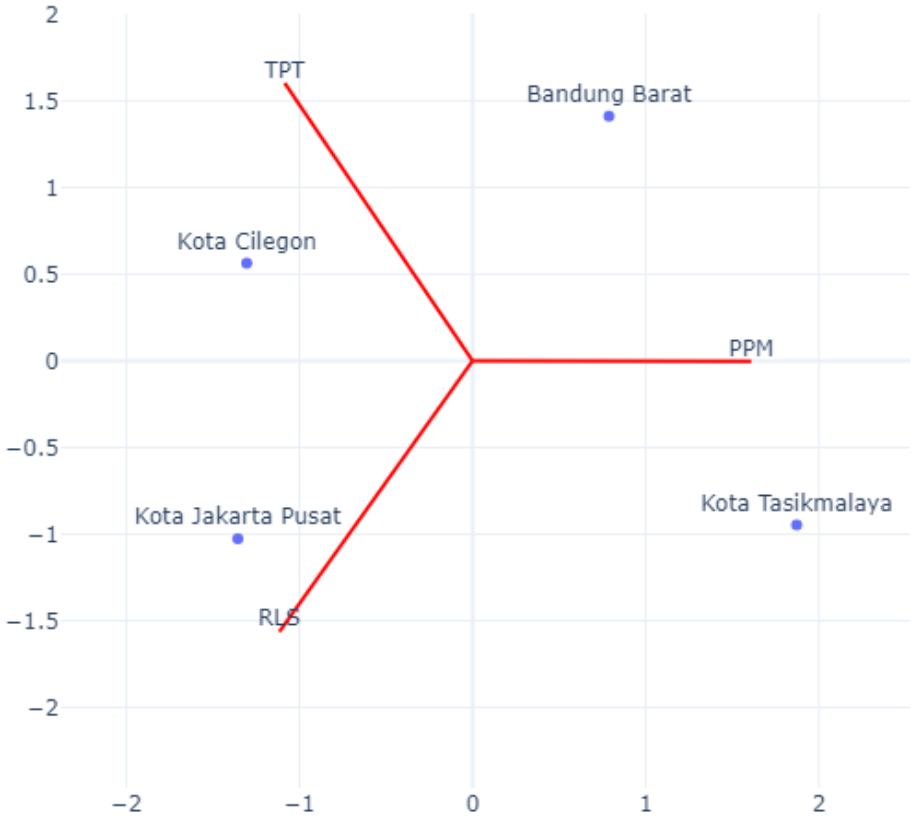
Definisi 2.20 (Biplot)**.** Biplot adalah representasi grafis dua dimensi yang memetakan baris (objek) dan kolom (indikator) dari matriks data $\mathbf{X}$ secara bersamaan dalam satu grafik (**?**). Biplot didasarkan pada aproksimasi matriks *rank*-rendah:

$$\mathbf{X} \approx \mathbf{FV}^T \tag{2.28}$$

Dalam visualisasi ini:

- Objek ke-i digambarkan sebagai titik berdasarkan baris ke-i dari matriks Skor $\mathbf{F}$. Jarak Euclidean antar titik merepresentasikan kemiripan antar objek.
- Indikator ke-j digambarkan sebagai vektor (panah) berdasarkan baris ke-j dari matriks Loadings $\mathbf{G}$. Sudut antar vektor merepresentasikan korelasi antar indikator. Sudut lancip ($< 90°$) berarti korelasi positif, sedangkan sudut tumpul ($> 90°$) berarti korelasi negatif.

Gambar 2.1 mengilustrasikan hubungan visual antara komponen skor objek ($\mathbf{F}$) dan loading indikator ($\mathbf{G}$) dalam representasi biplot.



Gambar 2.1: Ilustrasi Komponen Biplot (Skor dan Loading)

Skalasi Visual Biplot Dalam visualisasi biplot, seringkali terdapat perbedaan besaran (*magnitude*) yang mencolok antara nilai skor objek dan loading indikator. Untuk menjamin keterbacaan grafik tanpa mengubah interpretasi statistik (sudut korelasi dan arah), dilakukan penyesuaian skala (*visual scaling*) secara proporsional. Secara matematis, jika $\mathbf{F}$ adalah matriks skor dan $\mathbf{V}$ adalah matriks loading, maka koordinat visual $\mathbf{V}^*$ dihitung sebagai:

$$\mathbf{V}^* = \mathbf{V} \times \left(\frac{\max(|\mathbf{F}|)}{\max(|\mathbf{V}|)} \times c \right) \tag{2.29}$$

dengan c adalah konstanta penyesuaian (umumnya bernilai $0{,}8$). Prosedur ini memastikan bahwa panah indikator tidak menumpuk di pusat koordinat dan dapat diobservasi secara simultan bersama titik objek dalam satu ruang tampilan (**??**).

Catatan literatur: Selain skema penskalaan visual heuristik seperti Persamaan 2.29, literatur aljabar linear modern pada konteks biplot merekomendasikan pendekatan yang lebih konsisten secara matematis. Berdasarkan Abdi et al. (2012) – yang membahas hubungan antara skor faktor dan loadings dalam konteks komponen utama dan analisis struktur tiga-arah – salah satu prosedur yang direkomendasikan adalah mengalikan loading pada komponen ke-ℓ dengan *nilai singular* (singular value) σ_ℓ, di mana $\sigma_\ell = \sqrt{\lambda_\ell}$ dengan

λ_ℓ adalah nilai eigen komponen tersebut. Secara sederhana:

$$\mathbf{V}^*_{\cdot\ell} = \mathbf{V}_{\cdot\ell} \times \sigma_\ell \tag{2.30}$$

Pendekatan ini membuat varians (kuadrat) dari koordinat loading pada dimensi ke-ℓ sepadan dengan nilai eigen dimensi tersebut, sehingga panah indikator menjadi commensurable dengan sebaran skor (tanpa mengubah arah atau sudut yang merepresentasikan korelasi). Perlu ditekankan bahwa prosedur ini bersifat representasional untuk tujuan visualisasi dan tidak merubah penghitungan statistik dasar seperti nilai eigen, skor, atau uji signifikansi (mis. permutasi). (Lihat **?** untuk pembahasan teoretis dan alasan aljabar di balik transformasi ini.)

PCA dan Biplot bekerja dengan baik untuk satu tabel data pada satu titik waktu. Namun, ketika data tersebar dalam K matriks yang berbeda-beda seiring waktu, PCA konvensional tidak mampu menangkap dinamika evolusi struktural tersebut. Keterbatasan inilah yang mendorong pengembangan metode STATIS.

2.11 Metode STATIS

STATIS merupakan singkatan dari *Structuration des Tableaux à Trois Indices de la Statistique* atau jika diartikan ke dalam bahasa Indonesia berbunyi ”Strukturisasi Tabel dengan Tiga Indeks dalam Statistik”. STATIS adalah metode analisis data eksploratif yang dirancang untuk menganalisis sekumpulan K tabel data dengan membandingkan struktur internal antar-objek pada setiap situasi waktu (**?**). Berbeda dengan metode yang menggabungkan data secara naif (seperti *Pooled* PCA), STATIS mempertahankan integritas struktur masing-masing situasi melalui tiga tahapan analisis data yang sistematis: intra-struktur, inter-struktur, dan kompromi. Konsep inti STATIS dilandasi oleh teori operator Escoufier (**?**) yang memperkenalkan cara mengukur “jarak” antara dua konfigurasi data multivariat.

2.11.1 Tahap 1: Intra-struktur

Tahap pertama bertujuan mentransformasi tabel data terstandardisasi terbobot setiap situasi menjadi representasi geometri yang dapat dibandingkan dalam ruang bobot $\mathbf{D}$ yang sama. Misalkan $\mathbf{Z}_k$ adalah matriks data terstandardisasi terbobot pada situasi ke-k (Persamaan 2.5). STATIS mendefinisikan **operator Escoufier** $\mathbf{W}_k$ untuk setiap $k =$

$1, \ldots, K$ sebagai matriks produk skalar berukuran $n \times n$ (**?**):

$$\mathbf{W}_k = \mathbf{Z}_k \mathbf{Z}_k^T \tag{2.31}$$

Elemen-elemen dalam $\mathbf{W}_k$ merepresentasikan kemiripan antar-objek pada situasi ke-k. Karena analisis data dilakukan dalam ruang bobot $\mathbf{D}$, maka penghitungan produk Hilbert–Schmidt dan koefisien RV pada tahap berikutnya mengikutsertakan matriks bobot diagonal $\mathbf{D}$ (**?**).

Interpretasi $\mathbf{W}_k$: Elemen $\mathbf{W}_k[i, j]$ yang bernilai besar menunjukkan bahwa objek ke-i dan objek ke-j memiliki profil indikator yang sangat mirip pada situasi ke-k, sedangkan nilai yang kecil menunjukkan perbedaan karakteristik yang mencolok.

Peran $\mathbf{D}$ dalam $\mathbf{W}_k$ dan Ekuivalensi Komputasional Matriks bobot $\mathbf{D}$ tidak muncul secara eksplisit dalam $\mathbf{W}_k = \mathbf{Z}_k \mathbf{Z}_k^T$ karena $\mathbf{D}$ masuk melalui produk skalar Hilbert–Schmidt pada tahap inter-struktur: $H_{kk'} = \mathrm{tr}(\mathbf{W}_k \mathbf{D} \mathbf{W}_{k'} \mathbf{D})$ (**?**). Secara komputasional, ekspresi ini setara dengan mendefinisikan $\widetilde{\mathbf{W}}_k = \mathbf{D}^{1/2} \mathbf{Z}_k \mathbf{Z}_k^T \mathbf{D}^{1/2} = (\mathbf{D}^{1/2} \mathbf{Z}_k)(\mathbf{D}^{1/2} \mathbf{Z}_k)^T$, sehingga:

$$\mathrm{tr}(\widetilde{\mathbf{W}}_k \, \widetilde{\mathbf{W}}_{k'}) = \mathrm{tr}(\mathbf{D}^{1/2} \mathbf{Z}_k \mathbf{Z}_k^T \mathbf{D} \, \mathbf{Z}_{k'} \mathbf{Z}_{k'}^T \mathbf{D}^{1/2}) = \mathrm{tr}(\mathbf{W}_k \mathbf{D} \mathbf{W}_{k'} \mathbf{D}) = H_{kk'}$$

Kedua formulasi menghasilkan nilai $H_{kk'}$ yang identik. Dalam implementasi komputasional penelitian ini, digunakan bentuk $\widetilde{\mathbf{W}}_k$ karena lebih efisien secara numerik (perkalian matriks biasa tanpa perlu menyertakan $\mathbf{D}$ secara eksplisit pada setiap langkah).

2.11.2 Tahap 2: Inter-struktur

Setelah representasi $\mathbf{W}_k$ diperoleh untuk setiap situasi, langkah selanjutnya adalah mengukur seberapa mirip konfigurasi antar-situasi. Secara aljabar, matriks simetris $\mathbf{W}_k$ dan $\mathbf{W}_{k'}$ dilengkapi dengan produk skalar Hilbert–Schmidt $(\mathbf{W}_k \mid \mathbf{W}_{k'}) = \mathrm{tr}(\mathbf{W}_k \mathbf{D} \mathbf{W}_{k'} \mathbf{D})$ (**??**). Produk ini membentuk **matriks interstruktur** berukuran $K \times K$:

$$H_{kk'} = \mathrm{tr}(\mathbf{W}_k \mathbf{D} \mathbf{W}_{k'} \mathbf{D}), \qquad k, k' = 1, \ldots, K. \tag{2.32}$$

Matriks $\mathbf{H} = (H_{kk'})$ merepresentasikan kemiripan geometris antar-situasi dalam kondisi berbobot. Dekomposisi spektralnya memberikan gambaran grafis interstruktur (titik-titik situasi di $\mathbb{R}^h$) sebagaimana dijelaskan oleh **?**.

Untuk interpretasi data yang telah terstandardisasi (nilai diagonal menjadi 1), digunakan **koefisien RV** (**?**):

Definisi 2.21 (Koefisien RV)**.** Koefisien RV antara dua matriks konfigurasi $\mathbf{W}_k$ dan $\mathbf{W}_{k'}$ didefinisikan sebagai:

$$RV(\mathbf{W}_k, \mathbf{W}_{k'}) = \frac{\operatorname{tr}(\mathbf{W}_k\mathbf{D}\mathbf{W}_{k'}\mathbf{D})}{\sqrt{\operatorname{tr}((\mathbf{W}_k\mathbf{D})^2)\operatorname{tr}((\mathbf{W}_{k'}\mathbf{D})^2)}} = \frac{H_{kk'}}{\sqrt{H_{kk}\,H_{k'k'}}}. \tag{2.33}$$

Nilai RV berada di antara 0 dan 1. Nilai RV yang mendekati 1 mengindikasikan bahwa konfigurasi antar-objek pada situasi ke-k sangat mirip dengan situasi ke-k'. Koefisien ini secara geometris merupakan kosinus sudut antara dua matriks dalam ruang vektor matriks terbobot.

Matriks $\mathbf{R}_{\mathrm{RV}} = (RV(\mathbf{W}_k, \mathbf{W}_{k'}))$ dapat digunakan untuk membuat heatmap dan untuk mengetahui jarak antar-situasi dengan rumus jarak $d^2(k, k') = 2(1 - RV)$ antar-situasi, namun **pembobotan kompromi** mengacu pada $\mathbf{H}$: menurut **?**. Koefisien α_k diambil sebagai komponen vektor eigen utama yang terkait dengan nilai-nilai eigen terbesar dari dekomposisi spektral matriks interstruktur. Secara eksplisit,

$$\mathbf{H}\mathbf{u} = \theta\mathbf{u}, \tag{2.34}$$

dengan $\mathbf{H}$ adalah matriks interstruktur, $\mathbf{u}$ adalah vektor eigen, dan θ adalah nilai eigen. Vektor eigen pertama $\mathbf{u}_1$ (berkorespondensi dengan θ_1 terbesar) dipilih dengan elemen non-negatif lalu dinormalisasi:

$$\alpha_k = \frac{u_{1k}}{\sum_{k'=1}^{K} u_{1k'}}. \tag{2.35}$$

Kendala $\sum_{k=1}^{K} \alpha_k = 1$ memastikan matriks kompromi (yang akan dibahas pada sub-bab 2.11.3) sebanding dengan skala $\mathbf{W}_k$ (**?**). Sebagai catatan, $\mathbf{R}_{\mathrm{RV}}$ dan $\mathbf{H}$ memiliki nilai eigen berbeda. Hal ini sesuai dengan implementasi ACT/STATIS yang menggunakan Persamaan (2.34)–(2.35) untuk $\boldsymbol{\alpha}$.

Contoh 2.1 (Logika Bobot)**.** Apabila suatu situasi memiliki profil yang sangat anomali dibandingkan situasi lainnya (misalnya akibat krisis), metode STATIS akan secara otomatis memberikan bobot α_k yang lebih kecil pada situasi tersebut. Hal ini memastikan bahwa struktur kompromi tidak "terdistorsi" oleh situasi yang tidak representatif.

2.11.3 Tahap 3: Analisis Kompromi

Tahap ini membentuk struktur "rata-rata" yang disebut Kompromi. Matriks kompromi $\mathbf{W}_c$ dihitung sebagai kombinasi linier terbobot (menggunakan bobot α_k) dari matriks

intra-struktur $\mathbf{W}_k$ (**?**):

$$\mathbf{W}_c = \sum_{k=1}^{K} \alpha_k \mathbf{W}_k \tag{2.36}$$

Matriks $\mathbf{W}_c$ (berukuran $n \times n$) merepresentasikan pola hubungan antar-objek yang paling stabil selama periode pengamatan. Karena setiap $\mathbf{W}_k$ adalah matriks simetris positif semi-definit dan $\alpha_k \geq 0$, maka $\mathbf{W}_c$ juga bersifat simetris positif semi-definit. Penurunan sifat ini ditunjukkan melalui bentuk kuadratik untuk sebarang vektor $\mathbf{v} \in \mathbb{R}^n$:

$$\mathbf{v}^T \mathbf{W}_c \mathbf{v} = \mathbf{v}^T \left(\sum_{k=1}^{K} \alpha_k \mathbf{W}_k \right) \mathbf{v} = \sum_{k=1}^{K} \alpha_k (\mathbf{v}^T \mathbf{W}_k \mathbf{v}) \geq 0 \tag{2.37}$$

Hal ini menjamin bahwa dekomposisi spektral pada $\mathbf{W}_c$ akan selalu menghasilkan nilai eigen yang non-negatif. Berdasarkan teorema 2.1, $\mathbf{W}_c$ dapat didekomposisi menjadi:

$$\mathbf{W}_c = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T \tag{2.38}$$

dengan $\mathbf{P}$ adalah matriks vektor eigen tergeneralisasi yang memenuhi syarat ortogonalitas terbobot $\mathbf{P}^T \mathbf{D} \mathbf{P} = \mathbf{I}$, dan $\mathbf{\Lambda}$ adalah matriks diagonal berisi nilai eigen terurut $\lambda_1 \geq \lambda_2 \geq \cdots \geq 0$. Hal ini menunjukkan bahwa vektor eigen $\mathbf{P}$ dihitung dalam ruang terboboti $\mathbf{D}$ untuk mengakomodasi heterogenitas objek (**?**).

2.11.4 Tahap 4: Ekstraksi Koordinat dan Relasi Transisi

Tahap akhir dari metode STATIS adalah penentuan koordinat untuk objek dan indikator dalam ruang bersama (biplot). Berdasarkan **?**, terdapat dua skenario utama yang menentukan arah proyeksi koordinat (*transition formulas*) berdasarkan fokus analisis (*host space*):

1. **Skenario 1: STATIS Klasik (Host = Wilayah/Objek)**
   Pada skenario ini, matriks produk skalar wilayah ($\mathbf{W}_c$) dijadikan fondasi utama. Karena bermula dari ruang observasi, skor kompromi wilayah ditarik langsung secara alami, sedangkan komponen lainnya diturunkan melalui proyeksi.

   - **Skor Kompromi Wilayah ($\mathbf{F}_c$):** Diekstraksi langsung dari dekomposisi $\mathbf{W}_c$:

   $$\mathbf{F}_c = \mathbf{D}^{-1/2} \mathbf{P} \mathbf{\Lambda}_c^{1/2} \tag{2.39}$$

   - **Skor Parsial Wilayah ($\mathbf{F}_k$):** Merujuk pada Persamaan (40) **?**, skor parsial situasi k dihitung dengan memproyeksikan matriks produk skalar situasi tersebut

ke ruang kompromi:

$$\mathbf{F}_k = \mathbf{W}_k \mathbf{D} \mathbf{P} \mathbf{\Lambda}_c^{-1/2} \tag{2.40}$$

- **Loading Parsial Indikator ($\mathbf{G}_k$):** Merujuk pada Persamaan (39) **?**, ini merupakan relasi transisi yang memproyeksikan data ke ruang observasi:

$$\mathbf{G}_k = \mathbf{Z}_k^T \mathbf{D} \mathbf{F}_c \mathbf{\Lambda}_c^{-1/2} \tag{2.41}$$

- **Loading Kompromi Indikator ($\mathbf{G}_c$):** Pada skenario ini, loading kompromi dihitung sebagai rata-rata terbobot dari loading parsialnya (**?**):

$$\mathbf{G}_c = \sum_{k=1}^{K} \alpha_k \mathbf{G}_k \tag{2.42}$$

2. **Skenario 2: Dual STATIS / CovSTATIS (Host = Indikator/Indikator)**
   Pada skenario ini, matriks korelasi indikator ($\mathbf{S}_c$) menjadi fondasi utama. Karena bermula dari ruang indikator, loading indikator ditarik secara alami, sedangkan posisi wilayah diturunkan melalui relasi transisi.

   - **Loading Kompromi Indikator ($\mathbf{G}_c$):** Diekstraksi langsung dari dekomposisi $\mathbf{S}_c$:

$$\mathbf{G}_c = \mathbf{V}_c \mathbf{\Lambda}_s^{1/2} \tag{2.43}$$

   - **Loading Parsial Indikator ($\mathbf{G}_k$):** Melalui hukum dualitas, matriks kovariansi parsial ($\mathbf{S}_k$) diproyeksikan ke sumbu indikator (**?**):

$$\mathbf{G}_k = \mathbf{S}_k \mathbf{V}_c \mathbf{\Lambda}_s^{-1/2} \tag{2.44}$$

   - **Skor Parsial Wilayah ($\mathbf{F}_k$):** Merujuk pada Persamaan (25) **?**, ini memproyeksikan data situasi k ke ruang indikator:

$$\mathbf{F}_k = \mathbf{Z}_k \mathbf{G}_c \mathbf{\Lambda}_s^{-1/2} \tag{2.45}$$

   - **Skor Kompromi Wilayah ($\mathbf{F}_c$):** Berbeda dengan Skenario 1, pada skenario ini skor kompromi objek dihitung sebagai rata-rata terbobot dari skor parsialnya (**?**):

$$\mathbf{F}_c = \sum_{k=1}^{K} \alpha_k \mathbf{F}_k \tag{2.46}$$

3. **Transformasi Penyesuaian Visual Biplot:** Untuk kepentingan interpretasi praktis dan estetika grafik biplot, koordinat matematis hasil SVD murni ($\mathbf{F}_{svd}, \mathbf{G}_{svd}$) seringkali memerlukan transformasi tambahan tanpa mengubah hubungan korelasi antar-objek maupun indikator. Transformasi ini digunakan untuk menghasilkan kolom koordinat visual pada sistem:

   a. **Penyelarasan PC1 (*Mirroring*):** Agar dimensi pertama (PC1) memiliki makna ekonomi yang konsisten (misalnya: nilai positif berarti wilayah lebih sejahtera), dilakukan operasi pembalikan tanda jika ditemukan korelasi negatif antara PC1 dengan indikator performa utama:

   $$\mathbf{X}_{vis} = \mathbf{X}_{svd} \times \text{sign}(\rho(PC1, \text{Indikator_Utama})) \tag{2.47}$$

   di mana $\mathbf{X}$ merepresentasikan matriks $\mathbf{F}$ atau $\mathbf{G}$.

   b. **Skalasi Berbasis Nilai Singular (*Scaling*):** Agar loading indikator sebanding dengan skor objek secara geometris, koordinat loading tiap komponen ℓ dikalikan dengan nilai singular komponen tersebut (**?**):

   $$\mathbf{G}_{vis}^{(\ell)} = \mathbf{G}^{(\ell)} \times \delta_\ell, \qquad \delta_\ell = \sqrt{\lambda_\ell} \tag{2.48}$$

   di mana λ_ℓ adalah nilai eigen komponen ke-ℓ dari dekomposisi kompromi STATIS dan δ_ℓ adalah nilai singularnya. Penskalaan ini menjamin varians koordinat loading visual pada tiap dimensi setara dengan nilai singular dimensi tersebut, sehingga panah indikator dan titik objek berada dalam ruang geometris yang dapat dibandingkan.

Rangkuman Dualitas Relasi Transisi: Sebagai ringkasan teoretis, tabel berikut menyajikan simetri aljabar antara kedua skenario STATIS yang menjamin sifat rata-rata terbobot dalam visualisasi biplot:

Tabel 2.3: Rangkuman Dualitas Relasi Transisi STATIS

Elemen yang Dicari	Skenario 1 (Host Objek)	Skenario 2 (Host Indikator)
Ekstraksi Utama	$\mathbf{F}_c = \mathbf{D}^{-1/2}\mathbf{P}\mathbf{\Lambda}_c^{1/2}$	$\mathbf{G}_c = \mathbf{V}_c\mathbf{\Lambda}_s^{1/2}$
Relasi Proyeksi Sejenis	$\mathbf{F}_k = \mathbf{W}_k\mathbf{D}(\mathbf{P}\mathbf{\Lambda}_c^{-1/2})$	$\mathbf{G}_k = \mathbf{S}_k(\mathbf{V}_c\mathbf{\Lambda}_s^{-1/2})$
Relasi Transisi Menyilang	$\mathbf{G}_k = \mathbf{Z}_k^T\mathbf{D}(\mathbf{F}_c\mathbf{\Lambda}_c^{-1/2})$	$\mathbf{F}_k = \mathbf{Z}_k(\mathbf{G}_c\mathbf{\Lambda}_s^{-1/2})$

2.11.5 Klasifikasi Struktur: Analisis Transversal dan Longitudinal

Dalam pengembangan terbaru metodologi STATIS, **?** mengklasifikasikan analisis data pada vektor struktur inter-struktur menjadi dua pendekatan berdasarkan keberadaan urutan pada periode studi:

1. **Analisis Transversal (*Transversal Analysis*):** Analisis Transversal dilakukan untuk membandingkan komponen yang setara namun tidak memiliki urutan waktu yang mengikat (misalnya perbandingan antar kelompok atau juri).

2. **Analisis Longitudinal (*Longitudinal Analysis*):** Analisis Longitudinal dilakukan ketika terdapat urutan yang jelas dalam periode studi, seperti data yang dikumpulkan pada periode waktu yang berurutan. Analisis ini sangat memadai untuk memodelkan garis tren lintasan (*trajectories*) dari waktu ke waktu.

Dalam konteks penelitian ini, karena data yang dianalisis mencakup periode tahun 2020 hingga 2024 secara berurutan, maka pendekatan yang digunakan adalah analisis longitudinal, dengan arah dan besaran pergeseran lintasan objek menjadi fokus utama interpretasi.

2.11.6 Uji Signifikansi Stabilitas Struktur (Permutasi Monte Carlo)

Metode STATIS secara deskriptif menghasilkan struktur kompromi, namun tidak secara otomatis menjamin bahwa struktur tersebut signifikan secara statistik. Dapat terjadi struktur kompromi yang terbentuk hanya merupakan konstruk semu dari data yang sebenarnya acak dan tidak memiliki pola hubungan yang stabil antar-situasi.

Untuk memvalidasi hal ini, digunakan pengujian berbasis resampling, yaitu uji permutasi non-parametrik yang diadopsi dari berbagai literatur analisis multivariat (**???**). Uji ini tidak mensyaratkan asumsi distribusi normal pada data. Mengingat jumlah seluruh kemungkinan permutasi baris dari himpunan matriks sangat masif ($(n!)^K$), menghitung permutasi eksak secara menyeluruh sangat tidak efisien secara komputasional. Oleh karena itu, pengujian dieksekusi menggunakan pendekatan **Simulasi Monte Carlo**, dengan sampel permutasi acak dalam jumlah besar (B kali iterasi) diambil untuk membangun aproksimasi numerik dari distribusi eksak.

1. **Hipotesis Uji:**

    - H_0: $\theta_1 = \mathrm{E}\left[\theta_1^{\pi}\right]$ (Konfigurasi objek antar situasi waktu saling independen secara linier, sehingga data bersifat acak dan tidak ada struktur bersama yang stabil).

- H_1: $\theta_1 > \mathrm{E}\left[\theta_1^{\pi}\right]$ (Konfigurasi objek antar situasi waktu memiliki ketergantungan linier parsial atau total yang signifikan, membentuk struktur kompromi yang bermakna).

Notasi superskrip π (pi) pada rumusan hipotesis di atas merepresentasikan kondisi *permutasi*. Dengan demikian, θ_1^{π} melambangkan statistik nilai eigen dominan yang dihasilkan dari data *dummy* (buatan) yang telah diacak (dipermutasi) untuk mensimulasikan kondisi distribusi H_0, sedangkan $\mathrm{E}\left[\theta_1^{\pi}\right]$ merupakan nilai harapan atau nilai rata-rata dari statistik uji yang dihasilkan dari data acak tersebut.

2. **Statistik Uji dan Distribusi:** Statistik yang digunakan adalah θ_1, yaitu nilai eigen terbesar dari matriks interstruktur $\mathbf{H}$ pada Persamaan (2.32). Nilai θ_1 mengkuantifikasi proporsi informasi (variansi) matriks produk skalar yang dapat diringkas secara konsisten dalam satu dimensi interstruktur. Semakin besar θ_1, semakin kuat bukti empiris adanya struktur spasio-temporal bersama yang stabil (**?**).

   Distribusi teoretis (parametrik) dari θ_1 dalam analisis multivariat dapat menjadi semakin kompleks sehingga semakin sulit untukdidefinisikan. Sebagai solusinya, distribusi probabilitas pada kondisi H_0 (*null distribution*) diasumsikan benar. Kondisi ini dibangun secara empiris melalui simulasi Monte Carlo terhadap data yang dipermutasi sehingga menghasilkan sekumpulan statistik uji sintetis yang dinotasikan sebagai θ_1^{π} yang jumlahnya sama dengan jumlah iterasi yang dilakukan (B).

3. **Prosedur Simulasi Monte Carlo:**

   a. Menghitung nilai uji empiris θ_1^{obs} (observasi asli) dari matriks interstruktur $\mathbf{H}$ berdasar kumpulan matriks $\mathbf{Z}_k$.

   b. Melakukan pengacakan baris (permutasi label objek) secara independen pada setiap matriks situasi, menghasilkan sekumpulan matriks *dummy* acak $\mathbf{Z}_k^{\pi}$. Pengacakan ini mengubah struktur keterkaitan asli antar-situasi, mensimulasikan kondisi di mana H_0 berlaku.

   c. Menghitung operator Escoufier terbobot untuk himpunan data tersimulasi: $\mathbf{W}_k^{\pi} = (\mathbf{D}^{1/2}\mathbf{Z}_k^{\pi})(\mathbf{D}^{1/2}\mathbf{Z}_k^{\pi})^T$. Notasi eksponen π mensyaratkan pembedaan dari *conjugate transpose* atau rotasi matriks asli $\mathbf{W}_k$ maupun matriks kompromi $\mathbf{W}_c$.

   d. Membentuk matriks interstruktur baru $\mathbf{H}^{\pi}$ yang elemennya bernilai $H_{kk'}^{\pi} = \mathrm{tr}(\mathbf{W}_k^{\pi}\mathbf{W}_{k'}^{\pi})$. Selanjutnya, mengekstraksi nilai eigen terbesarnya yang ditetapkan sebagai θ_1^{π}.

e. Mengulangi iterasi pengacakan matriks pada langkah (b) hingga (d) secara terus-menerus sebanyak B kali (dalam penelitian ini $B = 1000$) untuk menghasilkan histogram distribusi frekuensi null dari θ_1^{π}.

4. **Pengambilan Keputusan:** Berbeda dengan uji statistik parametrik konvensional yang mengandalkan tabel distribusi teoritis, distribusi sampling dari θ_1 dalam konteks STATIS tidak diketahui bentuk pastinya secara analitis. Oleh karena itu, pengujian ini bersifat **non-parametrik** (*distribution-free*), di mana distribusi null dibangun secara empiris dari data itu sendiri melalui proses permutasi (**?**).

   Nilai p-*value* dihitung sebagai proporsi statistik uji hasil permutasi (θ_1^{π}) yang nilainya lebih besar atau sama dengan statistik observasi (θ_1^{obs}):

$$p\text{-value} = \frac{\sum_{b=1}^{B} I\left(\theta_1^{\pi(b)} \geq \theta_1^{\text{obs}}\right) + 1}{B + 1} \tag{2.49}$$

   dengan $I(\cdot)$ sebagai fungsi indikator Bernoulli yang bernilai 1 jika argumen perbandingan benar dan 0 jika sebaliknya. Elemen penambah $+1$ pada pembilang dan penyebut merupakan operasi *pseudo-count correction* yang lazim digunakan dalam algoritma Monte Carlo untuk mereduksi bias penaksir titik, sehingga p-value eksak tidak bernilai nol absolut (0%) (**?**).

   Apabila p-value $< \alpha$ (misalnya 0,05), maka H_0 ditolak. Hal ini membuktikan bahwa kompromi STATIS mencerminkan konstelasi evolusi sistem sosial-ekonomi yang signifikan, bukan produk distorsi stokastik (**?**).

2.11.7 Model Vektor Struktur dan Kerangka Inferensial STATIS

Sebagaimana diuraikan di atas, STATIS klasik (**?**) bersifat eksploratif: kesimpulan mengenai ada-tidaknya struktur bersama didasarkan semata-mata pada inspeksi grafis terhadap dekomposisi interstruktur. **?** memperluas kerangka ini dengan memperkenalkan formulasi model probabilistik yang memungkinkan inferensi statistik formal atas parameter interstruktur. Pengembangan ini dirangkum kembali dalam tinjauan metodologis terkini oleh **?**.

Model Rank-1 dan Estimator Vektor Struktur

Apabila titik-titik representasi situasi pada plot interstruktur cenderung terletak sepanjang sumbu eigen pertama *struktur bersama derajat 1* (*common structure of degree 1*)

maka **??** mengajukan model berikut untuk matriks interstruktur $\mathbf{H}$:

$$\mathbf{H} = \lambda \boldsymbol{\alpha}\boldsymbol{\alpha}^T + \bar{\mathbf{E}}, \qquad \bar{\mathbf{E}} = \frac{1}{2}\left(\mathbf{E} + \mathbf{E}^T\right), \tag{2.50}$$

dengan asumsi bahwa $\mathrm{Vec}(\mathbf{E}) \sim \mathcal{N}(\mathbf{0},\, \sigma^2 \mathbf{I}_{K^2})$, dengan $\lambda > 0$ adalah skalar kegentingan (magnitude), $\boldsymbol{\alpha}$ adalah vektor satuan yang menentukan arah struktur bersama, dan $\bar{\mathbf{E}}$ adalah komponen galat simetris.

Dalam model ini, informasi yang terkandung dalam $\mathbf{H}$ dipadatkan ke dalam **vektor struktur** $\boldsymbol{\beta}$:

$$\tilde{\boldsymbol{\beta}} = \lambda_1 \boldsymbol{\alpha}_1, \tag{2.51}$$

dengan λ_1 dan $\boldsymbol{\alpha}_1$ berturut-turut adalah nilai eigen dan vektor eigen pertama (terbesar) dari $\mathbf{H}$. Komponen ke-k dari $\tilde{\boldsymbol{\beta}}$, yaitu $\tilde{\beta}_k = \lambda_1 u_{1k}$ (sebelum normalisasi $\boldsymbol{\alpha}$), merupakan estimator tidak bias yang konsisten dari parameter $\beta_k = \lambda u_k$ (**??**).

Besaran *Sum of Squares* residual dihitung sebagai:

$$V = \|\mathbf{H}\|_F^2 - \|\tilde{\boldsymbol{\beta}}\|^2 = \sum_{k=1}^{K}\sum_{k'=1}^{K} H_{kk'}^2 - \lambda_1^2, \tag{2.52}$$

dengan $\|\mathbf{H}\|_F^2 = \mathrm{tr}(\mathbf{H}^T\mathbf{H}) = \mathrm{tr}(\mathbf{H}^2)$ (karena $\mathbf{H}$ simetris). Nilai V yang kecil relatif terhadap $\|\mathbf{H}\|_F^2$ mengindikasikan bahwa model rank-1 memberikan aproksimasi yang baik terhadap $\mathbf{H}$, sehingga interpretasi melalui satu vektor struktur $\tilde{\boldsymbol{\beta}}$ adalah sahih.

Validasi Kegentingan Eigenvalue (Dominansi Struktur)

Validitas model bergantung pada *dominansi* eigenvalue pertama. Kuantitas yang mengukur hal ini didefinisikan sebagai rasio:

$$\tau = \frac{\lambda^2}{\sigma^2}, \tag{2.53}$$

dengan σ^2 merupakan varians galat dari model pada Persamaan (2.50). Nilai τ yang besar (yaitu ketika $\lambda_1 \gg \lambda_j$ untuk $j \geq 2$) mengonfirmasi bahwa satu komponen dominan mampu menjelaskan hampir seluruh variansi interstruktur. **?** menunjukkan bahwa estimator λ_1 dan $\boldsymbol{\alpha}_1$ memiliki perilaku yang baik (*good behaviors*) melalui simulasi. Secara empiris, dominansi ini dinilai melalui *proportion of inertia* pada sumbu pertama interstruktur:

$$\mathrm{Inertia}_1 = \frac{\lambda_1}{\sum_{j=1}^{K} \lambda_j}, \tag{2.54}$$

yang setara dengan kontribusi variansi dimensi pertama pada plot interstruktur.

Analisis Transversal dan Longitudinal (Keluarga Seri Studi)

Perluasan lebih lanjut oleh **?**, yang dirangkum kembali dalam **?**, mempertimbangkan situasi di mana tersedia *beberapa seri studi* yang masing-masing berkorespondensi dengan satu perlakuan atau kelompok dalam suatu model eksperimental. Misalkan terdapat G kelompok (misalnya G provinsi), masing-masing memiliki seri K matriks data $\{\mathbf{Z}_{gk}\}_{k=1}^{K}$ untuk $g = 1, \ldots, G$. Untuk setiap kelompok g diperoleh vektor struktur yang diestimasi $\tilde{\boldsymbol{\beta}}_g = \lambda_{1g}\boldsymbol{\alpha}_{1g}$. Dua jenis analisis inferensial kemudian dapat diterapkan (**?**):

1. **Analisis Transversal:** Menguji apakah vektor-vektor struktur dari kelompok yang berbeda ($\tilde{\boldsymbol{\beta}}_1, \tilde{\boldsymbol{\beta}}_2, \ldots, \tilde{\boldsymbol{\beta}}_G$) berbeda secara signifikan satu sama lain, atau dengan kata lain menguji ada-tidaknya pengaruh faktor kelompok terhadap struktur bersama. Analisis ini umumnya dilakukan pada komponen-komponen homologus dari vektor struktur (yaitu pada indeks situasi yang sama lintas kelompok) (**?**).

2. **Analisis Longitudinal:** Menguji apakah terdapat progresi atau tren yang signifikan dalam komponen vektor struktur seiring berjalannya waktu. Analisis ini relevan ketika seri studi disusun secara kronologis, dan pertanyaannya adalah apakah perubahan temporal yang teramati pada struktur bersama merupakan tren yang sistematis atau sekadar fluktuasi acak (**??**).

Hubungan dengan Uji Permutasi Uji permutasi yang dijelaskan pada subbab sebelumnya merupakan pendekatan non-parametrik yang menguji hipotesis global mengenai keberadaan struktur bersama yang setara dengan menguji $H_0 : \lambda = 0$ dalam model pada Persamaan (2.50). Analisis transversal dan longitudinal, di sisi lain, beroperasi *setelah* struktur bersama dikonfirmasi ada, dan mengajukan pertanyaan inferensial yang lebih spesifik mengenai perbedaan antar-kelompok dan tren temporal. Keduanya bersifat komplementer.

2.12 Dynamic Biplot dan Visualisasi Trajektori

Hasil dekomposisi kompromi $\mathbf{F}_c$ hanya memberikan gambaran rata-rata posisi objek selama periode pengamatan. Untuk memahami dinamika perubahan dari situasi ke situasi, diperlukan perluasan yang disebut *Dynamic Biplot* atau *Trajectory Biplot* (**?**).

Konsep dasar dari visualisasi ini adalah memproyeksikan data tabel parsial (situasi tertentu) ke dalam ruang referensi yang stabil (ruang kompromi), sehingga posisi objek dapat dibandingkan secara *apple-to-apple* lintas waktu.

2.12.1 Proyeksi Lintasan (*Trajectory*)

Misalkan $\mathbf{Z}_k$ adalah matriks data terstandardisasi pada situasi ke-k ($n \times p$) dan $\mathbf{V}_c$ (berukuran $p \times 2$) adalah matriks vektor eigen dari matriks kompromi indikator $\mathbf{S}_c$. Koordinat objek pada situasi ke-k, dinotasikan $\mathbf{F}_k$, dihitung melalui proyeksi linier (**?**):

$$\mathbf{F}_k = \mathbf{Z}_k \mathbf{V}_c \tag{2.55}$$

Persamaan ini memetakan kondisi setiap situasi ke dalam sistem koordinat global yang sama. **Trajektori** atau lintasan objek ke-i didefinisikan sebagai urutan vektor koordinat dari waktu ke waktu:

$$\mathcal{T}_i = \{\mathbf{f}_{i,1}, \mathbf{f}_{i,2}, \ldots, \mathbf{f}_{i,K}\} \tag{2.56}$$

Visualisasi trajektori menghubungkan titik-titik koordinat ini dengan garis berarah, sehingga perubahan karakteristik objek, misalnya perpindahan dari kuadran dengan nilai indikator tertentu yang rendah menuju kuadran dengan nilai yang tinggi dapat teramati secara visual.

2.12.2 Jarak Euclidean antar Trajektori

Untuk mengelompokkan objek berdasarkan dinamika lintasannya (bukan hanya posisi rata-ratanya), digunakan ukuran jarak yang memperhitungkan pergerakan lintas seluruh situasi waktu. Jarak Euclidean antar-trajektori objek ke-i dan objek ke-j (masing-masing memiliki K titik koordinat) didefinisikan sebagai:

$$d(i,j) = \sqrt{\sum_{k=1}^{K} \|\mathbf{f}_{i,k} - \mathbf{f}_{j,k}\|^2} \tag{2.57}$$

di mana $\mathbf{f}_{i,k} \in \mathbb{R}^2$ adalah koordinat proyeksi objek ke-i pada situasi ke-k. Matriks jarak ini kemudian digunakan sebagai masukan pada algoritma K-Means berbasis trajektori, sehingga objek-objek yang memiliki pola pergerakan serupa sepanjang waktu akan dikelompokkan bersama (**?**).

2.12.3 Rotasi Baseline

Solusi *Principal Component Analysis* (PCA) dan Biplot bersifat invarian terhadap rotasi ortogonal, artinya rotasi sumbu koordinat tidak mengubah jarak antar-objek maupun sudut antar-indikator, namun dapat memudahkan interpretasi (**?**). Dalam implementasi dashboard, rotasi digunakan untuk menyelaraskan suatu vektor referensi (indikator atau objek yang

dipilih sebagai *baseline*) dengan sumbu horizontal (PC1), sehingga perbandingan posisi relatif objek lain terhadap *baseline* tersebut lebih intuitif.

Sudut rotasi θ dihitung dari posisi vektor referensi $\mathbf{v} = (v_1, v_2)^T$ menggunakan fungsi $\mathrm{atan2}$:

$$\theta = -\operatorname{atan2}(v_2, v_1) \tag{2.58}$$

Fungsi $\mathrm{atan2}$ mengembalikan sudut dalam radian antara sumbu positif-x dan vektor (v_1, v_2), dengan rentang nilai $(-\pi, \pi]$. Tanda negatif memastikan rotasi berlawanan jarum jam agar vektor referensi disejajarkan ke sumbu kanan (positif PC1).

Matriks rotasi ortogonal 2×2 yang merotasi koordinat sebesar sudut θ adalah:

$$\mathbf{Q}(\theta) = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix} \tag{2.59}$$

Dengan demikian, koordinat terotasi dihitung sebagai:

$$\mathbf{F}^* = \mathbf{F}\,\mathbf{Q}(\theta) \tag{2.60}$$

Prosedur ini diterapkan secara seragam ke semua plot (skor, loading, dan trajektori seluruh situasi waktu) agar konsistensi referensi spasial tetap terjaga. Hal ini memungkinkan peneliti mensejajarkan indikator tertentu dengan sumbu horizontal untuk memudahkan interpretasi posisi relatif antar-objek.

2.13 Metode Pengelompokan (*Clustering*)

Analisis pengelompokan (*clustering*) adalah metode statistik yang bertujuan mengelompokkan objek ke dalam beberapa kelompok sedemikian rupa sehingga objek yang berada dalam satu kelompok memiliki tingkat kemiripan yang tinggi, sementara objek antar kelompok bersifat heterogen.

2.13.1 K-Means Clustering

K-Means adalah algoritma *partitioning clustering* non-hierarkis yang mempartisi n objek ke dalam k klaster sedemikian rupa sehingga variansi dalam klaster (*within-klaster variation*) menjadi sekecil mungkin (**?**). Misalkan $\mathbf{x}_i \in \mathbb{R}^p$ adalah vektor observasi objek ke-i. Algoritma K-Means meminimumkan fungsi objektif *Sum of Squared Errors* (SSE):

$$SSE = \sum_{j=1}^{k} \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2 \tag{2.61}$$

dengan C_j adalah himpunan objek pada klaster ke-j dan $\boldsymbol{\mu}_j$ adalah sentroid klaster ke-j. Algoritma ini bekerja secara iteratif dengan memindahkan objek ke klaster bersentriod terdekat hingga tidak ada objek yang berpindah tempat.

2.13.2 Penentuan Jumlah klaster Optimal (Metode Elbow)

Tantangan utama K-Means adalah penentuan jumlah klaster optimal k yang bersifat apriori. Untuk menentukan k optimal secara empiris, metode *Elbow* digunakan sebagai panduan heuristik (**?**). Metode Elbow mengevaluasi efektivitas partisi dengan merencanakan kurva nilai inersia (SSE) pada sumbu Y terhadap nilai k yang bervariasi (misalnya 1 hingga 10) pada sumbu X. Semakin banyak cluster, nilai SSE secara matematis akan selalu menurun karena jarak objek ke sentroidnya terdekat akan semakin memendek. Namun, pada suatu titik tertentu (k), penurunan drastis SSE akan mulai melandai sehingga membentuk sudut (patahan/siku). Titik patahan inilah yang menunjukkan *diminishing returns* terhadap penambahan jumlah klaster yang direkomendasikan sebagai jumlah klaster optimal agar model tidak mengalami *overfitting* (**?**).

2.13.3 Koefisien Siluet (*Silhouette Score*)

Koefisien Siluet diperkenalkan oleh **?** sebagai ukuran kuantitatif yang mengevaluasi kualitas partisi klaster dari dua aspek sekaligus: (1) kepadatan dalam klaster (*cohesion*) dan (2) keterpisahan antar-klaster (*separation*). Untuk setiap objek i yang berada pada klaster C_q, didefinisikan rata-rata jarak intra-klaster:

$$a(i) = \frac{1}{|C_q| - 1} \sum_{j \in C_q,\, j \neq i} d(i, j) \tag{2.62}$$

dan rata-rata jarak ke klaster tetangga terdekat:

$$b(i) = \min_{C_r \neq C_q} \frac{1}{|C_r|} \sum_{j \in C_r} d(i, j) \tag{2.63}$$

Nilai siluet objek ke-i adalah:

$$s(i) = \frac{b(i) - a(i)}{\max\big(a(i),\, b(i)\big)}, \quad s(i) \in [-1,\, 1] \tag{2.64}$$

Nilai $s(i) \to +1$ menunjukkan objek terklaster dengan baik; $s(i) \approx 0$ berarti objek berada di batas antar-klaster; dan $s(i) < 0$ mengindikasikan kemungkinan salah penempatan.

Koefisien Siluet rata-rata keseluruhan adalah:

$$SC = \frac{1}{n} \sum_{i=1}^{n} s(i) \tag{2.65}$$

Nilai SC yang lebih besar (mendekati $+1$) mengindikasikan struktur klaster yang lebih koheren dan terpisah (**?**). Dalam penelitian ini, SC digunakan bersama kurva Elbow sebagai konfirmasi kuantitatif pemilihan jumlah klaster optimal.

2.13.4 Agglomerative Hierarchical Clustering (Dendrogram)

Sebagai alat bantu komplementer bagi metode Elbow, pendekatan hierarkis *Agglomerative Clustering* dengan metode *Ward's Linkage* digunakan untuk memvisualisasikan struktur pengelompokan secara hierarkis melalui Dendrogram (**?**). Metode Ward menggunakan pendekatan *Analysis of Variance* (ANOVA) untuk mengevaluasi jarak antar-cluster. Pada setiap tahap aglomerasi, metode ini menggabungkan sepasang klaster yang meminimalkan peningkatan *Error Sum of Squares* (ESS) total. Peningkatan ESS agregat saat menggabungkan klaster A dan B untuk membentuk $A \cup B$ dihitung sebagai:

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\boldsymbol{\mu}_A - \boldsymbol{\mu}_B\|^2 \tag{2.66}$$

Jarak vertikal cabang dendrogram secara visual mengindikasikan ketidaksamaan antar-kelompok.

2.13.5 Matriks Transisi Temporal

Setelah hasil clustering ditetapkan per situasi waktu, diperlukan alat untuk menganalisis dinamika perubahan keanggotaan objek antar-cluster. Matriks transisi $\mathbf{M}$ berdimensi $k \times k$ (dengan k adalah jumlah cluster) disusun untuk memetakan kondisi dari situasi k_1 ke situasi k_2. Elemen M_{xy} mendeskripsikan jumlah objek yang awalnya berada pada klaster x di situasi k_1 namun berpindah ke klaster y di situasi k_2:

$$\mathbf{T} = \begin{pmatrix} M_{1,1} & M_{1,2} & \cdots & M_{1,k} \\ M_{2,1} & M_{2,2} & \cdots & M_{2,k} \\ \vdots & \vdots & \ddots & \vdots \\ M_{k,1} & M_{k,2} & \cdots & M_{k,k} \end{pmatrix} \tag{2.67}$$

Diagonal utama ($M_{j,j}$) merepresentasikan objek yang tidak berpindah klaster (stabil), sementara elemen *off-diagonal* merepresentasikan objek yang mengalami perubahan keang-

gotaan klaster antar-situasi.

2.13.6 Penyelarasan Label Klaster Lintas Waktu

Sifat K-Means yang non-deterministik pada proses inisialisasi awal *centroid* menyebabkan pelabelan klaster bersifat arbitrer atau acak. Akibatnya, kelompok objek yang secara spasial berada pada kuadran yang sama dapat memperoleh label bilangan yang berbeda pada pengujian di tahun yang berbeda (misalnya, identitas klaster 1 pada tahun 2020 bergeser menjadi klaster 2 pada tahun 2021). Masalah ini dikenal dengan istilah *Label Switching* atau *Klaster Correspondence* (**?**).

Untuk menganalisis transisi kondisi (*transition matrix*) pada data longitudinal, pencocokan label antar-periode waktu merupakan prosedur prapemrosesan yang wajib dilakukan. Pencocokan ini menggunakan optimasi kombinatorial berlandaskan jarak *centroid*. Misalkan c_{1i} adalah *centroid* klaster ke-i pada tahun dasar, dan c_{2j} adalah *centroid* klaster ke-j pada tahun uji. Jarak *Euclidean* antar *centroid* dapat diformulasikan sebagai:

$$D(c_{1i}, c_{2j}) = \sqrt{\sum_{h=1}^{p} (c_{1ih} - c_{2jh})^2} \tag{2.68}$$

Matriks jarak ini kemudian diselesaikan menggunakan *Hungarian Algorithm* (**?**) untuk menemukan kombinasi pemetaan (*minimum weight bipartite matching*) sedemikian sehingga total biaya jarak atau fungsi objektif terminimisasi:

$$\min \sum_{i=1}^{k} \sum_{j=1}^{k} D(c_{1i}, c_{2j}) \cdot x_{ij} \tag{2.69}$$

dengan indikator biner $x_{ij} \in \{0, 1\}$ mengindikasikan apakah *centroid* i dari kondisi awal dipasangkan dengan *centroid* j pada kondisi tujuan. Dengan metode ini, keselarasan penamaan Klaster dapat dijamin tetap konsisten untuk merepresentasikan profil kesejahteraan yang sama.

2.13.7 Kategorisasi dan Perankingan Cluster

Setelah proses penyelarasan label selesai dilakukan, cluster-klaster tersebut masih memiliki label angka yang bersifat nominal (1, 2, ..., K). Untuk memberikan interpretasi yang bermakna secara ekonomi (misalnya: Rendah, Sedang, Tinggi), diperlukan kriteria pengurutan yang objektif. Dalam penelitian ini, kriteria yang digunakan adalah nilai rata-rata skor komponen utama pertama (PC_1) pada ruang kompromi STATIS.

Misalkan $\mathbf{f}_{i,1}$ adalah skor objek ke-i pada komponen utama pertama dari matriks kompromi $\mathbf{F}_c$. Rata-rata skor untuk klaster ke-k didefinisikan sebagai:

$$\overline{\text{PC}}_{1,k} = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{f}_{i,1} \tag{2.70}$$

dengan C_k adalah himpunan indeks objek dalam Klaster ke-k dan n_k adalah jumlah anggotanya. Label peringkat (1 untuk Rendah, hingga K untuk Tinggi) diberikan berdasarkan urutan menaik dari nilai $\overline{\text{PC}}_{1,k}$. Hal ini didasari oleh sifat PC_1 dalam analisis ini yang merepresentasikan dimensi utama kesejahteraan rakyat, di mana nilai skor yang lebih besar berkorespondensi dengan capaian indikator yang lebih baik secara rata-rata.

2.14 Uji Autokorelasi Spasial (Global Moran's I)

Autokorelasi spasial mengacu pada korelasi antara nilai suatu atribut di satu lokasi dengan nilai atribut yang sama di lokasi lain yang berdekatan, suatu manifestasi dari Hukum Pertama Geografi Tobler yang menyatakan bahwa "segalanya berhubungan dengan segalanya yang lain, tetapi hal-hal yang berdekatan lebih berhubungan daripada yang jauh" (**?**).

2.14.1 Matriks Pembobot Spasial

Matriks Pembobot Spasial (*Spatial Weight Matrix*) $\mathbf{W}_c$ berukuran $N \times N$ merepresentasikan struktur ketetanggaan antar-wilayah. Elemen w_{ij} mendefinisikan seberapa besar pengaruh wilayah j terhadap wilayah i (**?**). Salah satu definisi ketetanggaan yang umum digunakan adalah *Queen Contiguity*: wilayah i dan j dianggap bertetangga jika mereka berbagi setidaknya satu titik batas (sisi atau sudut):

$$w_{ij} = \begin{cases} 1 & \text{jika wilayah } i \text{ dan } j \text{ bertetangga} \\ 0 & \text{selainnya} \end{cases}, \quad w_{ii} = 0 \tag{2.71}$$

Untuk menghilangkan pengaruh perbedaan jumlah tetangga antar-wilayah, dilakukan **standardisasi baris** (*row standardization*):

$$w_{ij}^{*} = \frac{w_{ij}}{\sum_{k=1}^{N} w_{ik}} \tag{2.72}$$

Bentuk matriks pembobot terstandardisasi-baris adalah $\mathbf{W}^* = (w_{ij}^*)$ di mana setiap baris berjumlah 1. Bentuk ini memastikan bahwa rata-rata berbobot spasial merupakan rata-rata sederhana dari nilai-nilai tetangga.

2.14.2 Analisis Autokorelasi Spasial (Global Moran's I)

Sejalan dengan hasil pengelompokan pada skor kompromi, dilakukan pengujian untuk mendeteksi apakah terdapat ketergantungan spasial secara keseluruhan. Pengujian ini merujuk pada koefisien Global Moran's I yang divalidasi menggunakan pendekatan **non-parametrik (permutasi)** melalui simulasi Monte Carlo. Pendekatan ini dilakukan dengan mengacak posisi nilai atribut secara spasial berkali-kali untuk membangun distribusi null, sehingga p-value diperoleh secara empiris tanpa bergantung pada asumsi normalitas data. Hal ini menjamin validitas pengujian pada data regional yang memiliki keterbatasan jumlah amatan ($n = 41$).

Definisi 2.22 (Global Moran's I)**.** Misalkan x_i adalah nilai suatu atribut pada wilayah ke-i. Global Moran's I menggunakan matriks pembobot awal (belum terstandardisasi baris) $\mathbf{W}_c$ dengan elemen w_{ij}, dan didefinisikan sebagai:

$$I = \frac{N}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij}(x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2} \tag{2.73}$$

dengan N adalah jumlah wilayah dan $\bar{x}$ adalah rata-rata atribut. Ekspektasi di bawah hipotesis nol (tidak ada autokorelasi spasial) adalah $E[I] = -1/(N-1)$.

- Nilai I signifikan positif ($I \gg E[I]$): *spatial clustering*, yaitu wilayah bernilai tinggi bertetangga dengan wilayah bernilai tinggi.
- Nilai I signifikan negatif ($I \ll E[I]$): *spatial dispersion*, yaitu pola menyebar.
- Nilai $I \approx E[I]$: pola acak, tidak ada autokorelasi spasial.

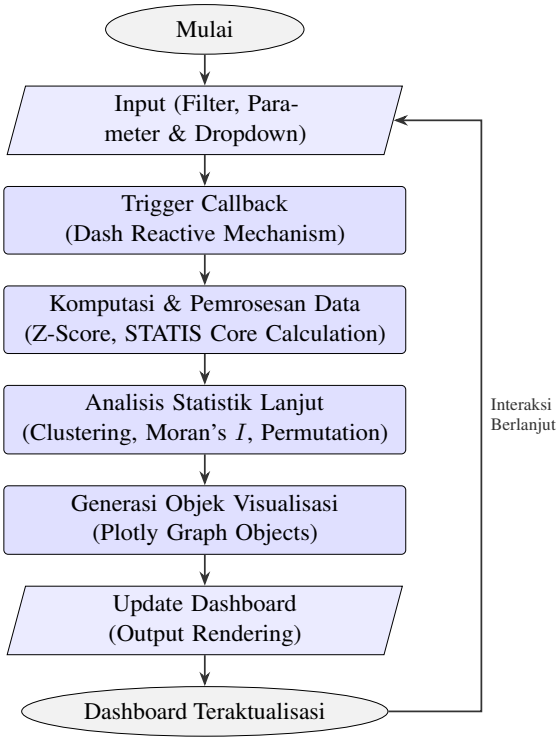
Signifikansi statistik diuji menggunakan pendekatan permutasi (*conditional randomization*) yang tidak memerlukan asumsi normalitas. Hal ini serupa dengan logika uji permutasi pada stabilitas struktur STATIS.

2.15 Visualisasi Interaktif menggunakan Plotly dan Dash

Kompleksitas informasi yang dihasilkan oleh metode-metode yang telah dijelaskan di subbab sebelumnya menuntut media penyajian yang lebih adaptif dibandingkan grafik

statis. Untuk menjawab kebutuhan ini, tersedia pustaka grafis **Plotly** (**?**) dalam kerangka kerja aplikasi web **Dash** (**?**).

Plotly adalah pustaka visualisasi data deklaratif yang memungkinkan pembuatan grafik interaktif saat diakses, termasuk grafik tiga dimensi (3D) yang dapat diputar dan diperbesar secara langsung. Sementara itu, Dash menerapkan paradigma pemrograman reaktif (*reactive programming*) yang memungkinkan grafik Plotly merespons secara dinamis terhadap masukan (*input*) pengguna. Secara konseptual, integrasi keduanya membentuk alur kerja analitik interaktif yang digambarkan melalui *flowchart* pada Gambar 2.2 berikut.



Gambar 2.2: Flowchart Mekanisme Interaktivitas Dash-Plotly

Pendekatan ini memfasilitasi Analisis Data Eksploratori (*Exploratory Data Analysis*/EDA) yang mendalam dan interaktif yang memungkinkan peneliti melakukan eksplorasi data secara *real-time*.

2.16 Kerangka Berpikir

Kerangka berpikir dalam penelitian ini disusun untuk mengintegrasikan berbagai metode analisis multivariat dan analisis spasial dalam memahami dinamika kesejahteraan rakyat di sebagian Pulau Jawa. Alur logika tersebut dimulai dari identifikasi fenomena ketimpangan spasio-temporal pada indikator sosial-ekonomi, yang kemudian diproses melalui tahapan-tahapan sistematis sebagai berikut:

1. **Input Data:** Pengumpulan data indikator kesejahteraan rakyat dari 41 kabupaten/kota di sebagian Pulau Jawa dalam rentang waktu tertentu, membentuk sebuah struktur data tiga-arah (*cube data*).

2. **Pra-pemrosesan:** Melakukan standardisasi data menjadi Z-score untuk menghilangkan bias satuan dan skala, selanjutnya dilakukan uji kelayakan multivariat (KMO dan Bartlett) untuk memastikan adanya struktur korelasi yang signifikan.

3. **Analisis STATIS:** Menerapkan tiga tahapan utama (intra-struktur, inter-struktur, dan kompromi) untuk mendapatkan representasi gabungan yang paling stabil pada lintas waktu tanpa mengabaikan variansi temporal dari masing-masing tahun.

4. **Visualisasi Dinamis dan Pengelompokan:** Mengekstraksi lintasan (*trajectory*) setiap objek untuk melihat pergerakan profil kesejahteraan secara individual. Hasil ini kemudian diklusterisasi menggunakan metode K-Means berbasis jarak trajektori untuk membangun tipologi wilayah yang memiliki karakteristik perubahan serupa.

5. **Validasi Spasial:** Melakukan pengujian autokorelasi spasial Global Moran's I untuk memverifikasi apakah kelompok-kelompok yang terbentuk secara statistik memiliki pola dependensi geografis yang nyata atau bersifat acak.

6. **Output Dashboard:** Mengintegrasikan seluruh hasil komputasi ke dalam platform visualisasi berbasis web menggunakan Dash Plotly, yang memungkinkan interpretasi data secara interaktif dan adaptif bagi pemangku kebijakan.

Dengan kerangka ini, analisis tidak hanya berhenti pada deskripsi angka rata-rata, melainkan mampu mengungkap pola evolusi dan interdependensi antar-wilayah secara mendalam.

BAB 3
METODOLOGI PENELITIAN

Bab ini berisi uraian mengenai tahapan-tahapan metodologi yang dilakukan dalam penelitian di Provinsi Banten, DKI Jakarta, dan Jawa Barat. Uraian tersebut mencakup penentuan jenis dan desain penelitian, populasi dan sampel penelitian, teknik pengumpulan data, serta teknik analisis data spasio-temporal secara komputasional menggunakan algoritma STATIS dan analisis spasial.

3.1 Statistika Deskriptif

Analisis diawali dengan ringkasan statistik untuk memberikan gambaran umum mengenai distribusi data yang menggambarkan kesejahteraan rakyat pada seluruh kabupaten/kota di Provinsi Banten, DKI Jakarta, dan Jawa Barat selama periode 2020 hingga 2024. Indikator yang dimaksud dalam hal ini adalah 12 indikator kesejahteraan rakyat sebagaimana diidentifikasi pada Bagian 1.5, yang mencakup IPM, IPG, PPM, PDRB ADHK, RLS, AHH Laki-laki, AHH Perempuan, GK, PKKP, TPT, TPAK, dan Gini Ratio. Prosedur ini melibatkan penghitungan ukuran pemusatan dan penyebaran data sebagaimana didefinisikan pada Bab 2 yang meliputi:

1. **Rata-rata ($\bar{x}$):** Digunakan untuk melihat level umum pencapaian indikator (merujuk Persamaan 2.6).

2. **Simpangan Baku (s):** Untuk mengukur tingkat kesenjangan atau variabilitas data antar wilayah (merujuk Persamaan 2.8).

3. **Nilai Minimum dan Maksimum:** Untuk mengidentifikasi rentang sebaran nilai indikator dengan performa ekstrim (merujuk Persamaan 2.9).

4. **Kuartil (Q_1 dan Q_3) serta Median (Q_2):** Untuk melihat sebaran data berdasarkan pemisahan persentase kelompok amatan (merujuk Persamaan 2.7).

5. **Kemiringan (*Skewness*):** Untuk mengukur tingkat asimetri distribusi data (merujuk Persamaan 2.12).

6. **Keruncingan (*Kurtosis*):** Untuk mengukur ketebalan ekor dan keruncingan relatif distribusi data dibandingkan distribusi normal (merujuk Persamaan 2.13).

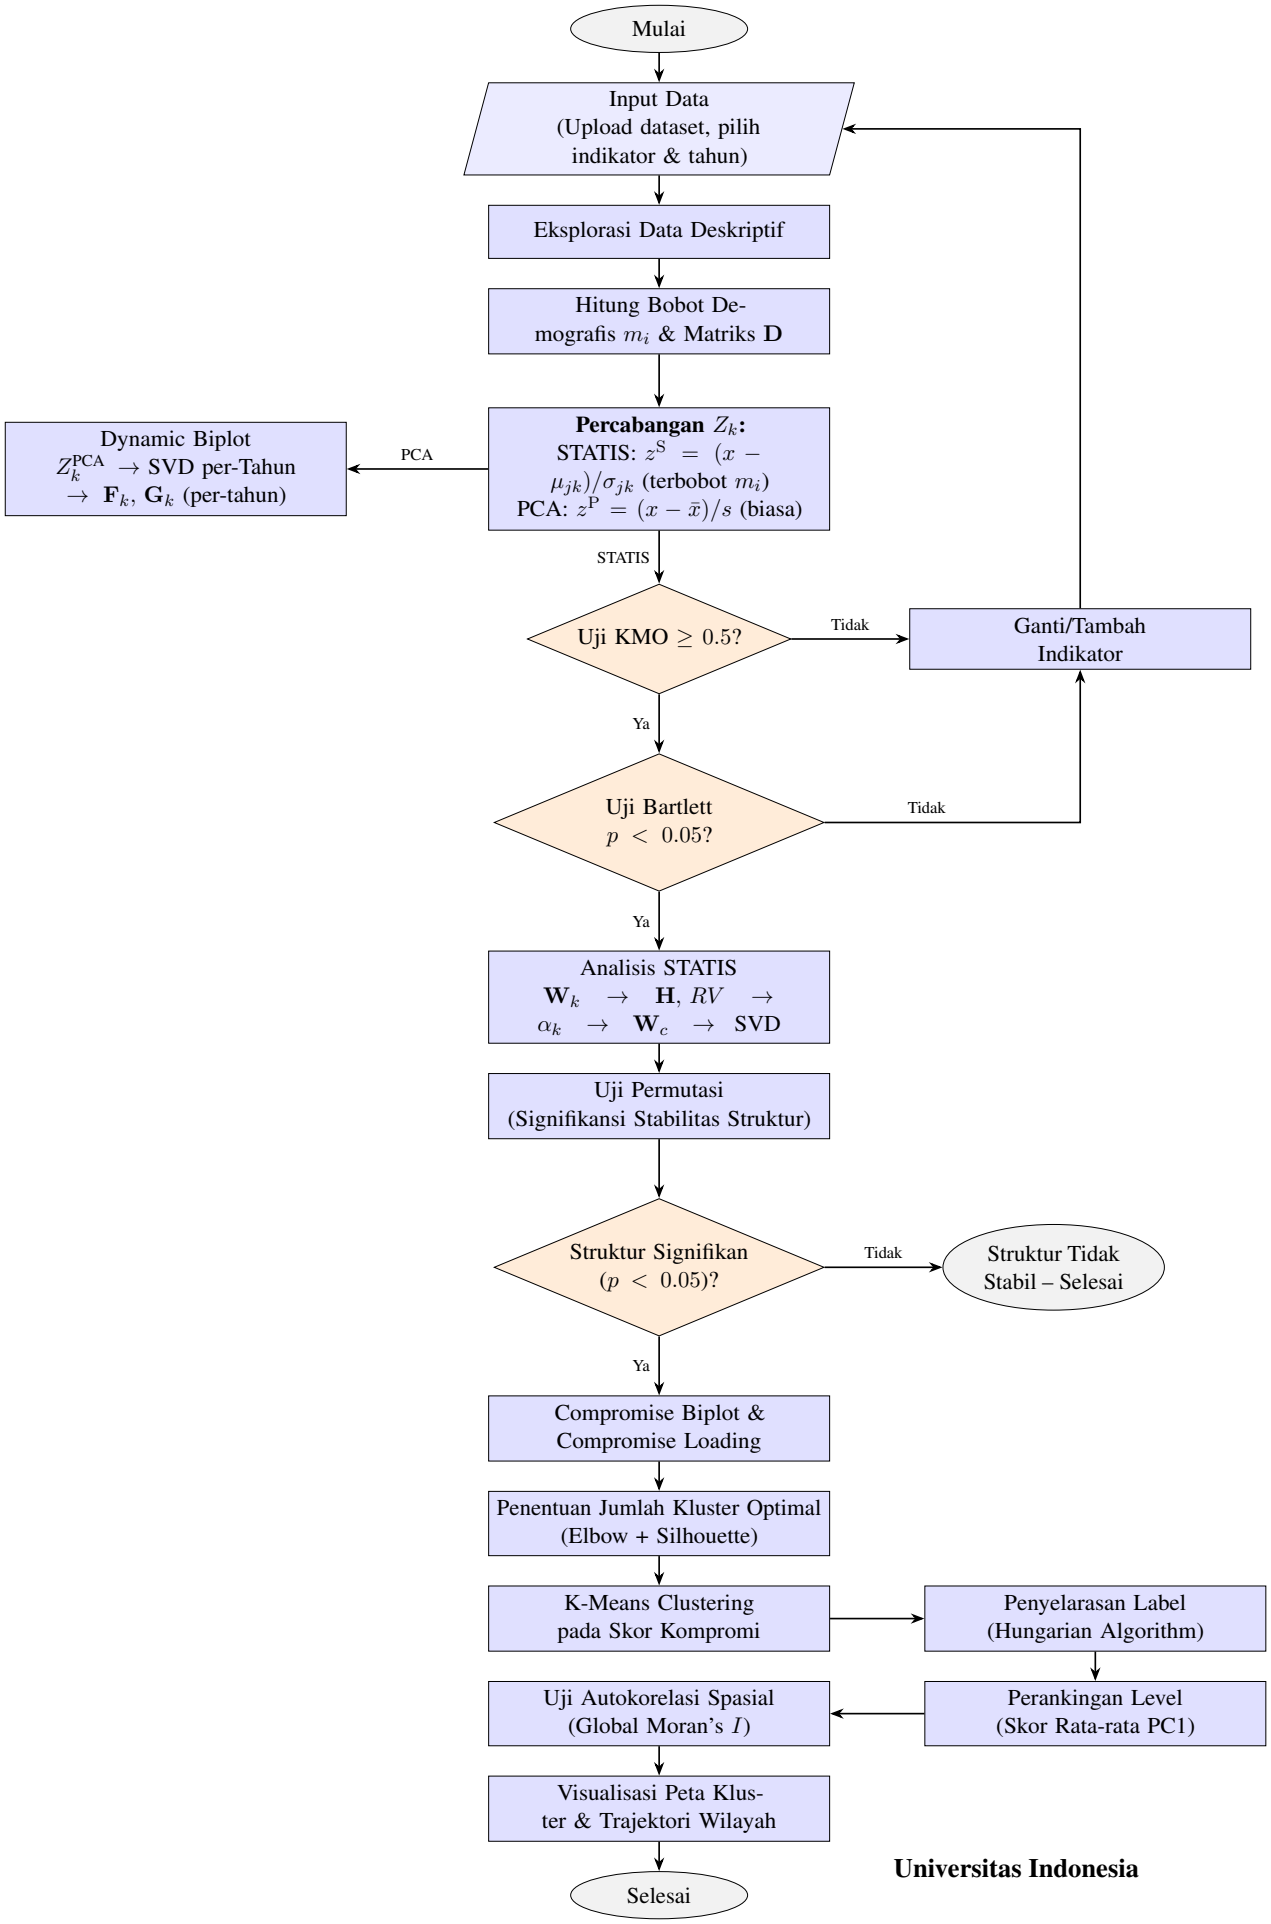
7. **Koefisien Variasi (CV):** Digunakan untuk membandingkan tingkat keragaman antar-indikator yang memiliki skala berbeda (merujuk Persamaan 2.11).

3.2 Jenis Penelitian

Penelitian ini menggunakan pendekatan **kuantitatif** dengan jenis penelitian **deskriptif-eksploratif**. Secara khusus, penelitian ini memanfaatkan teknik analisis multivariat lanjut (analisis tiga-arah) untuk mengeksplorasi struktur data longitudinal indikator pembangunan strategis di Provinsi Banten, DKI Jakarta, dan Jawa Barat. Pendekatan ini dipilih karena data yang diolah berupa data statistik sekunder dan akan dianalisis secara objektif menggunakan algoritma *STATIS*, *K-Means clustering*, dan analisis autokorelasi spasial untuk menarik kesimpulan mengenai stabilitas dan dinamika wilayah.

3.3 Desain Penelitian

Desain penelitian ini dirancang secara sistematis untuk menjawab tantangan data spasio-temporal. Tahapan penelitian dimulai dari input data, pra-pemrosesan, hingga pembentukan hasil akhir berupa visualisasi interaktif. Rancangan jalannya penelitian secara sistematis ditunjukkan pada Gambar 3.1 berikut.



Gambar 3.1: *Flowchart* Alur Metodologi Penelitian

3.4 Populasi dan Sampel

Populasi dalam penelitian ini adalah seluruh wilayah administratif setingkat kabupaten dan kota di Pulau Jawa. Mengingat ketersediaan data dan fokus analisis pada wilayah yang secara fungsional terhubung dalam koridor metropolitan Jawa bagian barat, penelitian ini mencakup seluruh kabupaten/kota di tiga provinsi berikut:

1. **Unit Observasi (n):** 41 wilayah yang terdiri dari seluruh kabupaten/kota di Provinsi Banten, DKI Jakarta, dan Jawa Barat. Pemilihan ketiga provinsi ini didasarkan pada kelengkapan data yang dipublikasikan secara konsisten oleh BPS (*purposive sampling* pada tingkat provinsi), sehingga seluruh wilayah di dalamnya tercakup secara penuh (*complete enumeration*) tanpa pengambilan sampel lebih lanjut.

2. **Jumlah Situasi (K):** 5 tahun pengamatan (2020 hingga 2024).

3. **Jumlah Indikator (p):** 11 indikator kesejahteraan rakyat sebagai input analisis STATIS, ditambah 2 variabel penunjang (IPM dan JP) yang tidak dimasukkan sebagai input.

4. **Sampel Ilustratif (Bab 3):** Untuk keperluan rekonstruksi algoritmik dan validasi numerik pada Bagian 3.7.1, dipilih 4 wilayah secara *acak sederhana* (*simple random sampling*): Kota Jakarta Pusat, Kabupaten Bandung Barat, Kota Tasikmalaya, dan Kota Cilegon. Sampel ini **tidak** digunakan untuk membangun model, melainkan semata-mata sebagai wahana ilustrasi langkah-langkah perhitungan manual STATIS dengan $n = 4$ wilayah, $K = 3$ tahun (2020–2022), dan $p = 3$ indikator (PPM, RLS, TPT).

3.5 Teknik Pengumpulan Data

Data dalam penelitian ini merupakan data sekunder yang dikumpulkan melalui studi dokumentasi pada publikasi resmi Badan Pusat Statistik (BPS).

1. **Sumber Data:** Website resmi BPS Pusat dan BPS Provinsi yang diperoleh melalui portal Open Data atau publikasi *Provinsi Dalam Angka*. Data untuk Provinsi Banten, DKI Jakarta, dan Jawa Barat periode 2020 hingga 2024 diperoleh dari publikasi resmi BPS masing-masing provinsi (**??????????????**).

2. **Metode Pengumpulan Data:** Pengumpulan data dilakukan dengan mengunduh berkas metadata dan tabel statistik dalam format *spreadsheet* (.xlsx dan .csv).

3. **Indikator Penelitian:** Indikator penelitian yang dikumpulkan terdiri dari 11 indikator sebagai berikut:

    - **IPG:** Indeks Pembangunan Gender (0 hingga 100).
    - **PPM:** Persentase Penduduk Miskin (%).
    - **PDRB_ADHK:** Produk Domestik Regional Bruto Atas Dasar Harga Konstan tahun 2010 (Juta Rupiah).
    - **RLS:** Rata-rata Lama Sekolah (Tahun).
    - **AHH L:** Angka Harapan Hidup Laki-laki (Tahun).
    - **AHH P:** Angka Harapan Hidup Perempuan (Tahun).
    - **GK:** Garis Kemiskinan (Rupiah/Kapita/Bulan).
    - **PKKP:** Prevalensi Ketidakcukupan Konsumsi Pangan (%).
    - **TPT:** Tingkat Pengangguran Terbuka (%).
    - **TPAK:** Tingkat Partisipasi Angkatan Kerja (%).
    - **GR:** Gini Ratio (0 hingga 1).

    Selain itu, dikumpulkan pula data tambahan berikut yang tidak dimasukkan sebagai input analisis STATIS dan Dynamic Biplot:

    - **IPM:** Indeks Pembangunan Manusia (0 hingga 100), khusus untuk pembanding eksternal (*benchmark*) untuk mengevaluasi posisi klaster tersebut terhadap standar UNDP (*United Nations Development Programme*). Hal ini dilakukan agar klaster yang terbentuk murni merepresentasikan kemiripan struktur dari 11 indikator yang telah dijelaskan sebelumnya.
    - **JP (Jumlah Penduduk):** Banyaknya jiwa per wilayah (Orang), khusus untuk pembentukan bobot demografis (m_i) sesuai dengan Persamaan 2.3 dan Persamaan 2.4.

3.5.1 Pra-pemrosesan Data, Penskalaan Visual, dan Parameter Analisis

Dalam rangka menjamin reproduksibilitas dan ketajaman interpretasi hasil, tahapan pra-pemrosesan dan parameter analisis dilakukan sebagai berikut:

1. **Standardisasi per-tahun (Z-score):** Setiap matriks tahunan distandardisasi secara terpisah sehingga komparasi antarvariabel di dalam tahun menjadi setara. Terdapat **dua skema standardisasi** yang digunakan secara paralel sesuai jalur analisis (lihat

Subbagian 3.7.1.2): (1) $z^{\mathrm{PCA}} = (x - \bar{x})/s$ untuk Dynamic Biplot — menggunakan mean aritmetika biasa dengan semua wilayah berbobot setara; (2) $z^{\mathrm{STATIS}} = (x - \mu_{jk})/\sigma_{jk}$ untuk STATIS — menggunakan mean dan simpangan baku terbobot m_i agar wilayah berpenduduk besar berkontribusi proporsional.

2. **Bobot demografis (m_i):** Untuk beberapa analisis (mis. pembentukan matriks bobot objek), dihitung bobot demografis berdasarkan jumlah penduduk tiap wilayah sesuai Persamaan 2.3. Bobot ini dipakai untuk memperhitungkan kontribusi relatif populasi dalam pembentukan kompromi.

3. **Uji Kelayakan Multivariat:** Sebelum menerapkan STATIS, dilakukan Uji KMO dan Uji Bartlett untuk memastikan kecukupan korelasi antarvariabel; ambang batas yang digunakan adalah KMO $\geq 0{,}5$ dan Bartlett $p < 0{,}05$.

4. **Penskalaan Loadings untuk Visualisasi:** Untuk tujuan representasi grafis (biplot/trajectory), panjang vektor loading disesuaikan mengikuti **?** (lihat Persamaan 2.48): setiap elemen loading intra $g_{j\ell}^{(\text{asli})}$ pada dimensi ℓ dikalikan dengan nilai singular kompromi $\sigma_\ell^{(c)} = \sqrt{\lambda_\ell^{(c)}}$, menghasilkan nilai *visual*:

$$g_{j\ell}^{(\text{visual})} = g_{j\ell}^{(\text{asli})} \times \sqrt{\lambda_\ell^{(c)}} \tag{3.1}$$

Pada data sampel, $\lambda_1^{(c)} = 2{,}3008$ dan $\lambda_2^{(c)} = 0{,}6992$, sehingga $\delta_1 = \sqrt{2{,}3008} = 1{,}5168$ dan $\delta_2 = \sqrt{0{,}6992} = 0{,}8362$. Sebagai ilustrasi, loading intra PPM tahun 2020 sebelum penskalaan adalah $g_{\text{PPM},1}^{(\text{asli})} = 0{,}8306$ (PC1) dan $g_{\text{PPM},2}^{(\text{asli})} = 0{,}5569$ (PC2), sehingga:

$$g_{\text{PPM},1,2020}^{(\text{visual})} = 0{,}8306 \times 1{,}5168 = 1{,}2599$$
$$g_{\text{PPM},2,2020}^{(\text{visual})} = 0{,}5569 \times 0{,}8362 = 0{,}4657$$

Apabila konfigurasi *mirror* PC1 aktif (seperti pada Skenario 1 studi kasus ini), nilai PC1 Visual selanjutnya dinegatifkan: $g_{\text{PPM},1}^{(\text{visual})} = -1{,}2599$. Skor intra $\mathbf{F}_k$ tidak mengalami perubahan amplitudo — hanya tanda yang dapat berubah bila *mirror* aktif. Penyesuaian ini hanya berlaku untuk plotting dan tidak mengubah nilai analitis atau kesimpulan inferensial.

5. **Uji Permutasi Stabilitas STATIS:** Untuk mengevaluasi signifikansi kestabilan struktur kompromi digunakan uji permutasi Monte Carlo terhadap matriks interstruktur sebanyak N_{perm} percobaan (default 1000). Nilai p dihitung sebagai proporsi

permutasi yang menghasilkan statistik lebih ekstrim daripada observasi.

6. **Pemilihan Jumlah Klaster:** Penentuan jumlah klaster (k) untuk K-Means dilakukan melalui kombinasi metode extitelbow dan skor extitsilhouette; nilai default yang diuji di skrip adalah $k = 2$–5 dan hasil akhir dipilih berdasarkan keseimbangan antara compactness dan interpretabilitas.

7. **Uji Autokorelasi Spasial:** Untuk menguji keberadaan clustering spasial pada skor kompromi, dihitung Global Moran's I dengan prosedur permutasi Monte Carlo pada bobot spasial yang dibentuk dari file shapefile administratif (lihat lampiran teknis untuk detail pembentukan matriks bobot).

3.6 Validasi Instrumen

Karena data yang digunakan berasal dari lembaga resmi negara (BPS) yang telah memiliki protokol sensus dan survei (seperti Susenas dan Sakernas) yang terstandardisasi, validitas dan reliabilitas instrumen pengumpulan data primer dianggap sudah terpenuhi. Namun, pada tahap penelitian ini dilakukan **validasi data sekunder** melalui:

1. **Penyelarasan Metadata:** Memastikan definisi operasional indikator tetap konsisten di seluruh provinsi dan tahun pengamatan.

2. **Penataan Data (*Data Wrangling*):** Data mentah yang diperoleh dari berbagai publikasi BPS direstrukturisasi ke dalam format tiga-arah yang diwajibkan oleh sistem komputasi: setiap tahun disimpan sebagai lembar (*sheet*) tersendiri dalam berkas `.xlsx`, dengan baris mewakili wilayah dan kolom mewakili indikator. Seluruh 41 wilayah pada ketiga provinsi tersedia lengkap untuk semua indikator dan tahun yang diamati, sehingga tidak diperlukan penghapusan baris atau kolom. Data hasil penataan disimpan dalam berkas `Data Final.xlsx` (lihat Lampiran **??**) yang selanjutnya diunggah langsung ke dalam sistem *dashboard* untuk diproses.

3. **Standardisasi Z-score Terbobot:** Karena indikator yang digunakan memiliki satuan yang beragam (persen, rupiah, tahun), dilakukan transformasi Z-score terbobot agar setiap indikator dapat dibandingkan dalam ruang terboboti $\mathbf{D}$ yang konsisten. Prosedur ini mengikuti Persamaan 2.5 yang mengggunakan rata-rata populasi terbobot μ_{jk} (Persamaan 2.3) dan simpangan baku populasi terbobot σ_{jk} (Persamaan 2.4) yang diterapkan pada setiap tabel situasi k, sehingga setiap indikator pada setiap tahun memiliki rata-rata terbobot nol dan varians terbobot satu.

Untuk memastikan data layak dianalisis secara multivariat, dilakukan serangkaian pengujian kecukupan sampling dan korelasi pada setiap periode pengamatan:

1. **Indeks Kaiser-Meyer-Olkin (KMO):** Pengujian ini dilakukan untuk menilai kecukupan sampel (*sampling adequacy*) dari 11 indikator yang digunakan untuk mengukur kesejahteraan rakyat. Penghitungan KMO merujuk pada rasio korelasi sederhana dan korelasi parsial sesuai Persamaan 2.15. Nilai KMO $\geq 0,50$ menjadi syarat mutlak agar indikator-indikator tersebut dianggap memiliki informasi bersama yang cukup untuk diringkas melalui analisis dimensi tiga-arah.

2. **Uji Bartlett's Test of Sphericity:** Uji ini digunakan untuk memverifikasi adanya struktur korelasi yang signifikan antar indikator (menguji hipotesis bahwa matriks korelasi bukan matriks identitas). Statistik uji χ^2 dihitung berdasarkan determinan matriks korelasi sebagaimana didefinisikan pada Persamaan 2.17. Jika p-value $< 0,05$, maka indikator-indikator tersebut dikonfirmasi memiliki hubungan interdependensi yang kuat, sehingga valid untuk diproses lebih lanjut menggunakan metode STATIS guna mengekstraksi struktur kompromi lintas waktu.

Penerapan kedua uji di atas pada dataset sampel ($n = 4$ wilayah, $p = 3$ indikator, $K = 3$ tahun) menghasilkan nilai sebagaimana dirangkum pada Tabel 3.1.

Tabel 3.1: Hasil Uji KMO dan Uji Bartlett per Tahun

Tahun	Nilai KMO	Interpretasi Nilai KMO	χ^2 Bartlett	df	P-Value Bartlett	Keputusan
2020	0,2502	Unacceptable (Tidak diterima)	3,6300	3	0,3038	Periksa
2021	0,2620	Unacceptable (Tidak diterima)	5	3	0,1721	Periksa
2022	0,2917	Unacceptable (Tidak diterima)	7,2000	3	0,0659	Periksa

Catatan: Nilai KMO yang rendah ($\approx 0,25$–$0,29$) dan p-value Bartlett yang tidak signifikan pada dataset sampel merupakan konsekuensi langsung dari jumlah observasi ($n = 4$) yang sangat terbatas relatif terhadap jumlah indikator ($p = 3$). Rasio $n/p \approx 1,3$ ini jauh di bawah anjuran minimal $n/p \geq 5$ dalam literatur analisis faktor. Pada dataset aktual yang terdiri dari 41 kabupaten/kota dengan 11 indikator, kedua uji menghasilkan nilai yang memenuhi ambang batas yang disyaratkan, sebagaimana disajikan secara lengkap dalam Bab 4.

Contoh penghitungan: Statistik Bartlett untuk tahun 2020 menggunakan Persamaan 2.17 dengan $n = 4$, $p = 3$. Determinan matriks korelasi $|\mathbf{R}_{2020}| = 0,0441$ (dihitung dari

matriks $\mathbf{S}_{2020}$ pada Tabel 3.9). Substitusi ke rumus:

$$\chi^2 = -\left[n - 1 - \frac{2p+5}{6}\right] \ln|\mathbf{R}| = -\left[4 - 1 - \frac{2(3)+5}{6}\right] \ln(0{,}0441)$$
$$= -\left[3 - \frac{11}{6}\right](-3{,}1179) = -(1{,}1667)(-3{,}1179) = 3{,}6300$$

dengan $df = p(p-1)/2 = 3(2)/2 = 3$ dan p-value $= 0{,}3038$. Statistik KMO diperoleh dari Persamaan 2.15 yang membandingkan korelasi bivariate dengan korelasi parsial antar-indikator; untuk tahun 2020 diperoleh $\mathrm{KMO}_{2020} = 0{,}2502$.

3.7 Teknik Analisis Data

Teknik analisis data mengacu pada algoritma STATIS (*Structuration des Tableaux à Trois Indices de la Statistique*) untuk mengelola kompleksitas data tiga-arah serta analisis autokorelasi spasial. Agar tidak terjadi kerancuan persepsi, penelitian ini membedakan dua konsep ”tiga-arah” yang saling berkaitan:

- **Struktur Data Tiga-Arah (*Input Cube*):** Merupakan struktur data mentah yang dianalisis, yang terdiri dari 41 Kabupaten/Kota sebagai objek (n), 11 Indikator Kesejahteraan Rakyat sebagai indikator (p), dan 5 tahun pengamatan sebagai situasi waktu (K). Seluruh pengujian awal (KMO dan Bartlett) dilakukan pada dimensi indikator (p) ini.
- **Visualisasi Dinamis (*Output Trajectory*):** Merupakan hasil reduksi dimensi oleh STATIS, di mana 11 indikator tersebut diringkas menjadi 2 Komponen Utama (PC1 dan PC2), sementara dimensi situasi (K) direpresentasikan melalui pergeseran atau lintasan wilayah di dalam ruang PC1 dan PC2 tersebut.

3.7.1 Prosedur Komputasi dan Ilustrasi Numerik STATIS

Bagian ini menyajikan rekonstruksi algoritmik secara sistematis dengan menyajikan ilustrasi penghitungan manual (*step-by-step*) untuk memvalidasi fungsionalitas sistem komputasi yang dibangun. Ilustrasi dilakukan menggunakan dataset sampel yang terdiri dari 4 wilayah ($n = 4$) selama 3 periode waktu ($K = 3$) dengan 3 indikator utama ($p = 3$): Persentase Penduduk Miskin (PPM), Rata-rata Lama Sekolah (RLS), dan Tingkat Pengangguran Terbuka (TPT). Wilayah sampel meliputi: (1) Kota Jakarta Pusat, (2) Kabupaten Bandung Barat, (3) Kota Tasikmalaya, dan (4) Kota Cilegon. Data lengkap sampel yang digunakan dalam ilustrasi ini disajikan pada Tabel 3.2.

Tabel 3.2: Data Mentah Sampel Ilustratif: 4 Wilayah × 3 Tahun × 5 Variabel

No	Provinsi	Kabupaten/Kota	2020					2021					2022				
			PPM	RLS	TPT	IPM	JP	PPM	RLS	TPT	IPM	JP	PPM	RLS	TPT	IPM	JP
1	DKI JAKARTA	Kota Jakarta Pusat	4,51	11,38	10,97	81,39	1.056.896	4,94	11,39	7,75	81,79	1.057.465	4,90	11,53	5,88	82,13	1.053.482
2	JAWA BARAT	Bandung Barat	10,49	8,19	12,25	68,08	1.782.190	11,30	8,20	11,65	68,30	1.808.420	10,82	8,22	9,63	69,04	1.834.230
3	JAWA BARAT	Kota Tasikmalaya	12,97	9,33	7,99	72,97	713.670	13,13	9,52	7,66	73,20	723.100	12,72	9,53	6,62	73,83	732.480
4	BANTEN	Kota Cilegon	3,69	9,87	12,69	73,05	433,76	4,24	10,08	10,13	73,30	439,48	3,64	10,34	8,10	73,95	445,06

Catatan: PPM = Persentase Penduduk Miskin (%); RLS = Rata-rata Lama Sekolah (Tahun); TPT = Tingkat Pengangguran Terbuka (%); IPM = Indeks Pembangunan Manusia; JP = Jumlah Penduduk. Analisis STATIS menggunakan tiga indikator utama: PPM, RLS, TPT.

Catatan penyajian: *Seluruh objek matematis pada bagian ini, termasuk di dalamnya* $\mathbf{W}_k$*,* $\mathbf{S}_k$*,* $\mathbf{H}$*,* $\mathbf{F}_c$*,* $\mathbf{G}_c$*,* $\mathbf{F}_k$*, dan* $\mathbf{G}_k$ *merupakan sebuah bentuk matriks. Penyajian dalam format tabel pada penelitian ini semata-mata untuk memudahkan pembacaan nilai numerik; notasi dan sifat matriks sepenuhnya berlaku dalam konteks komputasi dan derivasi analitis.*

3.7.1.1 Tahap 0: Pra-pemrosesan dan Bobot Demografis

Analisis diawali dengan ringkasan statistik untuk periode 2020 hingga 2022 (Tabel 3.3–3.5). Statistika deskriptif tanpa bobot disajikan pada tabel berikut.

Tabel 3.3: Statistika Deskriptif (tanpa Bobot) Tahun 2020

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV (%)
TPT	10,9750	1,8356	7,9900	10,2250	11,6100	12,3600	12,6900	-0,7875	-1,0029	16,7200
PPM	7,9150	3,9252	3,6900	4,3050	7,5000	11,1100	12,9700	0,1296	-1,7889	49,5900
IPM	73,8725	4,7843	68,0800	71,7475	73,0100	75,1350	81,3900	0,5232	-0,9383	6,4800
RLS	9,6925	1,1476	8,1900	9,0450	9,6000	10,2475	11,3800	0,2269	-1,0941	11,8400
JP	888297,44	641534,50	433,76	535360,94	885283,00	1238219,50	1782190,00	0,0131	-1,1379	72,2200

Tabel 3.4: Statistika Deskriptif (tanpa Bobot) Tahun 2021

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV (%)
TPT	9,2975	1,6810	7,6600	7,7275	8,9400	10,5100	11,6500	0,2894	-1,6215	18,0800
PPM	8,4025	3,8749	4,2400	4,7650	8,1200	11,7575	13,1300	0,0703	-1,8757	46,1200
IPM	74,1475	4,8533	68,3000	71,9750	73,2500	75,4225	81,7900	0,5357	-0,9353	6,5500
RLS	9,7975	1,1451	8,2000	9,1900	9,8000	10,4075	11,3900	-0,0062	-1,1160	11,6900
JP	897356,12	650095,55	439,48	542434,87	890282,50	1245203,75	1808420,00	0,0305	-1,1276	72,4500

Tabel 3.5: Statistika Deskriptif (tanpa Bobot) Tahun 2022

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV (%)
TPT	7,5575	1,4390	5,8800	6,4350	7,3600	8,4825	9,6300	0,2951	-1,4124	19,0400
PPM	8,0200	3,8356	3,6400	4,5850	7,8600	11,2950	12,7200	0,0504	-1,8309	47,8300
IPM	74,7375	4,7052	69,0400	72,6325	73,8900	75,9950	82,1300	0,5227	-0,9386	6,3000
RLS	9,9050	1,2052	8,2200	9,2025	9,9350	10,6375	11,5300	-0,0662	-1,2117	12,1700
JP	905159,27	658311,85	445,06	549471,27	892981,00	1248669,00	1834230,00	0,0522	-1,1146	72,7300

Catatan: Koefisien Variasi (CV) menunjukkan rasio simpangan baku terhadap rata-rata, dinyatakan dalam persen; CV yang lebih tinggi mengindikasikan variasi relatif yang lebih besar antar-wilayah untuk indikator tersebut.

Selain statistika deskriptif biasa, digunakan pula statistika deskriptif **terbobot** yang memperhitungkan jumlah penduduk (JP) di wilayah ke-i (m_i) sebagai bobot demografis (Persamaan 2.3 dan 2.4). Hal ini penting karena STATIS bekerja pada ruang terboboti $\mathbf{D}$.

Tabel 3.6: Statistika Deskriptif (dengan Bobot) Tahun 2020 (N = 4)

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skewness (γ_1)	Kurtosis (γ_2)	CV (%)
TPT	11,0148	1,6168	7,9900	10,2250	11,6100	12,3600	12,6900	-1,0949	-0,3590	14,6781
PPM	9,2290	3,1906	3,6900	4,3050	7,5000	11,1100	12,9700	-0,5969	-1,1973	34,5718
IPM	72,9836	5,7374	68,0800	71,7475	73,0100	75,1350	81,3900	0,6111	-1,3746	7,8613
RLS	9,3588	1,3752	8,1900	9,0450	9,6000	10,2475	11,3800	0,6249	-1,3636	14,6938

Tabel 3.7: Statistika Deskriptif (dengan Bobot) Tahun 2021 (N = 4)

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skewness (γ_1)	Kurtosis (γ_2)	CV (%)
TPT	9,6978	1,9684	7,6600	7,7275	8,9400	10,5100	11,6500	-0,0171	-1,9986	20,2969
PPM	9,7961	3,2132	4,2400	4,7650	8,1200	11,7575	13,1300	-0,7398	-1,2057	32,8005
IPM	73,2585	5,8151	68,3000	71,9750	73,2500	75,4225	81,7900	0,6169	-1,3699	7,9378
RLS	9,4051	1,3763	8,2000	9,1900	9,8000	10,4075	11,3900	0,5445	-1,4306	14,6337

Tabel 3.8: Statistika Deskriptif (dengan Bobot) Tahun 2022 (N = 4)

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skewness (γ_1)	Kurtosis (γ_2)	CV (%)
TPT	7,9195	1,7433	5,8800	6,4350	7,3600	8,4825	9,6300	-0,0786	-1,9194	22,0134
PPM	9,4597	3,0329	3,6400	4,5850	7,8600	11,2950	12,7200	-0,7052	-1,2051	32,0610
IPM	73,8586	5,6426	69,0400	72,6325	73,8900	75,9950	82,1300	0,6132	-1,3730	7,6397
RLS	9,4585	1,4273	8,2200	9,2025	9,9350	10,6375	11,5300	0,5706	-1,4083	15,0902

Matriks data mentah $\mathbf{X}_k$ untuk setiap situasi tahun $k = 2020, 2021, 2022$ hanya mencakup tiga indikator utama (PPM, RLS, TPT) yang digunakan dalam analisis STATIS, sehingga kolom IPM dan JP tidak termasuk dalam matriks input. Matriks $\mathbf{X}_k$ disusun dengan baris mewakili wilayah dan kolom mewakili indikator, sebagai berikut:

$$\mathbf{X}_{2020} = \begin{pmatrix} 4,51 & 11,38 & 10,97 \\ 10,49 & 8,19 & 12,25 \\ 12,97 & 9,33 & 7,99 \\ 3,69 & 9,87 & 12,69 \end{pmatrix} \quad \mathbf{X}_{2021} = \begin{pmatrix} 4,94 & 11,39 & 7,75 \\ 11,30 & 8,20 & 11,65 \\ 13,13 & 9,52 & 7,66 \\ 4,24 & 10,08 & 10,13 \end{pmatrix} \quad \mathbf{X}_{2022} = \begin{pmatrix} 4,90 & 11,53 & 5,88 \\ 10,82 & 8,22 & 9,63 \\ 12,72 & 9,53 & 6,62 \\ 3,64 & 10,34 & 8,10 \end{pmatrix}$$

Penghitungan bobot demografis m_i untuk setiap wilayah berdasarkan data rata-rata jumlah penduduk (JP) dari dataset sampel (Tabel 3.3–3.5) dihitung satu per satu menggunakan Persamaan 2.1 sebagai berikut:

$$m_1 = \frac{\overline{JP}_1}{\sum_{i=1}^{4} \overline{JP}_i} = \frac{1.055.947,67}{3.587.750,43} = 0{,}294320$$

$$m_2 = \frac{\overline{JP}_2}{\sum_{i=1}^{4} \overline{JP}_i} = \frac{1.808.280,00}{3.587.750,43} = 0{,}504015$$

$$m_3 = \frac{\overline{JP}_3}{\sum_{i=1}^{4} \overline{JP}_i} = \frac{723.083,33}{3.587.750,43} = 0{,}201542$$

$$m_4 = \frac{\overline{JP}_4}{\sum_{i=1}^{4} \overline{JP}_i} = \frac{439,43}{3.587.750,43} = 0{,}000122$$

Verifikasi total bobot: $m_1{+}m_2{+}m_3{+}m_4 = 0{,}294320{+}0{,}504015{+}0{,}201542{+}0{,}000122 = 0{,}999999 \approx 1$ dengan $\overline{JP}_i$ merupakan rata-rata jumlah penduduk untuk wilayah ke-i selama tiga tahun pengamatan. Verifikasi total bobot memastikan bahwa jumlahnya mendekati 1, sehingga memenuhi syarat sebagai distribusi probabilitas yang valid untuk pembentukan matriks bobot objek $\mathbf{D}$ dalam ruang terboboti STATIS.

Matriks diagonal $\mathbf{D}$ yang dihasilkan adalah:

$$\mathbf{D} = \text{diag}(0{,}294320,\ 0{,}504015,\ 0{,}201542,\ 0{,}000122)$$

3.7.1.2 Percabangan Standardisasi: STATIS vs. Dynamic Biplot (PCA per-Tahun)

Sebelum melanjutkan ke tahap standardisasi, perlu ditegaskan bahwa penelitian ini menggunakan **dua jalur analisis paralel** yang menghasilkan matriks $\mathbf{Z}_k$ dengan nilai numerik yang *berbeda*, meskipun notasinya sama:

1. **Dynamic Biplot (PCA per-Tahun)** menggunakan *standardisasi biasa tanpa bobot*. Rata-rata dan simpangan baku dihitung secara aritmetika biasa, di mana setiap wilayah diperlakukan setara tanpa memperhatikan besar populasi:

$$\bar{x}_{jk} = \frac{1}{n}\sum_{i=1}^{n} x_{ijk}, \qquad s_{jk} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(x_{ijk} - \bar{x}_{jk}\right)^2}, \qquad z_{ijk}^{\text{PCA}} = \frac{x_{ijk} - \bar{x}_{jk}}{s_{jk}} \tag{3.2}$$

   Implementasinya dalam *dashboard* menggunakan `sklearn.preprocessing.StandardScaler` yang menerapkan formula di atas. Akibatnya, Kota Depok ($JP \approx 2{,}3$ juta) dan Kabupaten Kepulauan Seribu ($JP \approx 0{,}02$ juta) mendapat bobot yang setara dalam menentukan pusat distribusi.

2. **Analisis STATIS** menggunakan *standardisasi terbobot* berbasis bobot demografis m_i (dihitung pada Tahap 0 di atas). Rata-rata dan simpangan baku dihitung secara terbobot sehingga wilayah dengan populasi besar berkontribusi proporsional lebih

besar:

$$\mu_{jk} = \sum_{i=1}^{n} m_i \, x_{ijk}, \qquad \sigma_{jk} = \sqrt{\sum_{i=1}^{n} m_i \big(x_{ijk} - \mu_{jk}\big)^2}, \qquad z_{ijk}^{\text{STATIS}} = \frac{x_{ijk} - \mu_{jk}}{\sigma_{jk}} \tag{3.3}$$

Standardisasi ini menjamin $\sum m_i z_{ijk} = 0$ dan $\sum m_i z_{ijk}^2 = 1$, sehingga skala konsisten lintas indikator dan lintas tahun dalam ruang terboboti $\mathbf{D}$.

Perbedaan mendasar ini mengakibatkan $z_{ijk}^{\text{PCA}} \neq z_{ijk}^{\text{STATIS}}$ secara numerik, sehingga matriks kemiripan intra-struktur $\mathbf{W}_k = \mathbf{Z}_k \mathbf{Z}_k^T$ yang digunakan STATIS juga berbeda dari $\mathbf{Z}_k$ yang masuk ke SVD pada PCA per-tahun. Bagian berikut menjelaskan standardisasi terbobot secara detail dengan data sampel.

3.7.1.3 Tahap 1: Standardisasi Data STATIS ($\mathbf{Z}_k$)

Proses standardisasi di bawah ini dilakukan untuk setiap indikator pada setiap tahun secara terpisah, menggunakan rata-rata terbobot μ_{jk} dan simpangan baku terbobot σ_{jk} yang dihitung berdasarkan bobot demografis m_i. Sebagai contoh, untuk indikator pertama (PPM) pada tahun 2020 $\mathbf{X}_{2020}[:, 1] = (4{,}51;\ 10{,}49;\ 12{,}97;\ 3{,}69)^T$. Langkah-langkahnya adalah sebagai berikut:

1. **Rata-rata terbobot μ_{jk}:**

   Nilai rata-rata terbobot untuk indikator pertama (PPM) dihitung menggunakan Persamaan 2.3 sebagai berikut:

$$\begin{aligned}
\mu_{1,2020} &= \sum_{i=1}^{4} m_i \cdot x_{i,1,2020} \\
&= 0{,}294320(4{,}51) + 0{,}504015(10{,}49) \\
&\quad + 0{,}201542(12{,}97) + 0{,}000122(3{,}69) \\
&= 1{,}327383 + 5{,}287117 + 2{,}613999 + 0{,}000450 = 9{,}228957
\end{aligned}$$

2. **Simpangan baku terbobot σ_{jk}:**

   Nilai simpangan baku terbobot untuk indikator pertama (PPM) dihitung menggu-

nakan Persamaan 2.4 sebagai berikut:

$$\begin{aligned}
\sigma_{1,2020} &= \sqrt{\sum_{i=1}^{4} m_i (x_{i,1,2020} - \mu_{1,2020})^2} \\
&= \Big(0{,}294320(4{,}51 - 9{,}228957)^2 + 0{,}504015(10{,}49 - 9{,}228957)^2 \\
&\quad + 0{,}201542(12{,}97 - 9{,}228957)^2 + 0{,}000122(3{,}69 - 9{,}228957)^2\Big)^{1/2} \\
&= \Big(0{,}294320(-4{,}718957)^2 + 0{,}504015(1{,}261043)^2 \\
&\quad + 0{,}201542(3{,}741043)^2 + 0{,}000122(-5{,}538957)^2\Big)^{1/2} \\
&= \Big(0{,}294320(22{,}268555) + 0{,}504015(1{,}590229) \\
&\quad + 0{,}201542(13{,}995402) + 0{,}000122(30{,}680045)\Big)^{1/2} \\
&= \sqrt{6{,}553881 + 0{,}801500 + 2{,}820653 + 0{,}003743} \\
&= \sqrt{10{,}179777} = 3{,}190576
\end{aligned}$$

3. Z**-score terbobot** z_{ijk}**:**

Nilai Z-score terbobot masing-masing wilayah untuk indikator pertama (PPM) dihitung menggunakan Persamaan 2.5 sebagai berikut:

$$\begin{aligned}
z_{1,1,2020} &= \frac{4{,}51 - 9{,}228957}{3{,}190576} = \frac{-4{,}718957}{3{,}190576} = -1{,}479024 \approx -1{,}48 \\
z_{2,1,2020} &= \frac{10{,}49 - 9{,}228957}{3{,}190576} = \frac{1{,}261043}{3{,}190576} = 0{,}395237 \approx 0{,}40 \\
z_{3,1,2020} &= \frac{12{,}97 - 9{,}228957}{3{,}190576} = \frac{3{,}741043}{3{,}190576} = 1{,}172529 \approx 1{,}17 \\
z_{4,1,2020} &= \frac{3{,}69 - 9{,}228957}{3{,}190576} = \frac{-5{,}538957}{3{,}190576} = -1{,}736036 \approx -1{,}74
\end{aligned}$$

Prosedur di atas diulang untuk setiap indikator dan tahun, menghasilkan matriks terstandar:

$$\mathbf{Z}_{2020} = \begin{pmatrix} -1,48 & 1,47 & -0,03 \\ 0,40 & -0,85 & 0,76 \\ 1,17 & -0,02 & -1,87 \\ -1,74 & 0,37 & 1,04 \end{pmatrix} \quad \mathbf{Z}_{2021} = \begin{pmatrix} -1,51 & 1,44 & -0,99 \\ 0,47 & -0,88 & 0,99 \\ 1,04 & 0,08 & -1,04 \\ -1,73 & 0,49 & 0,22 \end{pmatrix} \quad \mathbf{Z}_{2022} = \begin{pmatrix} -1,50 & 1,45 & -1,17 \\ 0,45 & -0,87 & 0,98 \\ 1,07 & 0,05 & -0,75 \\ -1,92 & 0,62 & 0,10 \end{pmatrix}$$

3.7.1.4 Tahap 2: Matriks Intra-struktur ($\mathbf{W}_k$)

Dari matriks terstandar $\mathbf{Z}_k$, dibentuk matriks intra-struktur $\mathbf{W}_k = \mathbf{Z}_k\mathbf{Z}_k^T$. Sebagai contoh pada tahun 2020:

$$\begin{aligned}
\mathbf{W}_{2020}[1,1] &= \sum_{j=1}^{3} z_{1,j,2020}^2 \\
&= (-1{,}479012)^2 + (1{,}469744)^2 + (-0{,}027681)^2 \\
&= 2{,}187478 + 2{,}160150 + 0{,}000766 \\
&= 4{,}348394
\end{aligned}$$

$$\begin{aligned}
\mathbf{W}_{2020}[1,2] &= \sum_{j=1}^{3} z_{1,j,2020} \cdot z_{2,j,2020} \\
&= (-1{,}479012 \times 0{,}395235) + (1{,}469744 \times -0{,}849962) \\
&\quad + (-0{,}027681 \times 0{,}764025) \\
&= -0{,}584558 - 1{,}249227 - 0{,}021149 = -1{,}854935
\end{aligned}$$

Matriks korelasi terbobot antar-indikator $\mathbf{S}_k = \mathbf{Z}_k^T\mathbf{D}\mathbf{Z}_k$ disajikan pada Tabel 3.9, Tabel 3.10, dan Tabel 3.11.

Tabel 3.9: Matriks Korelasi Terbobot Indikator Tahun 2020 ($\mathbf{S}_{2020}$)

Indikator	PPM	RLS	TPT
PPM	1	-0,8141	-0,2781
RLS	-0,8141	1	-0,3313
TPT	-0,2781	-0,3313	1

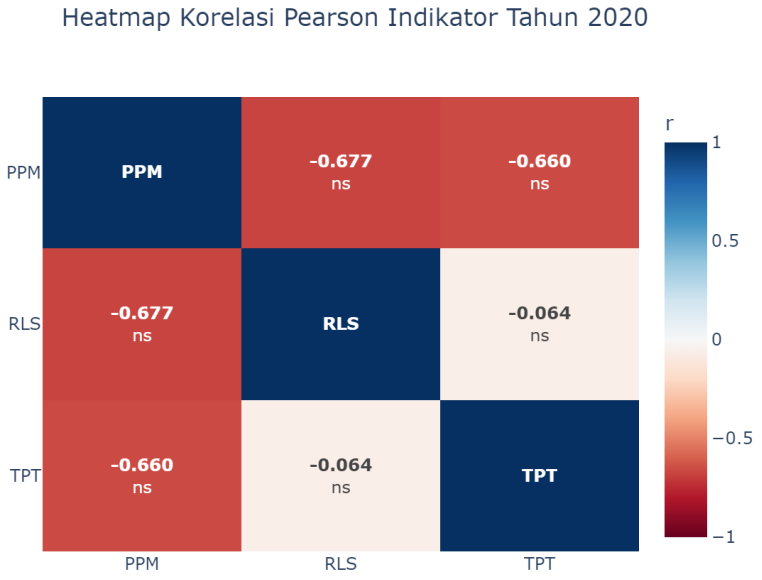
Tabel 3.10: Matriks Korelasi Terbobot Indikator Tahun 2021 ($\mathbf{S}_{2021}$)

Indikator	PPM	RLS	TPT
PPM	1	-0,8307	0,4576
RLS	-0,8307	1	-0,8751
TPT	0,4576	-0,8751	1

Tabel 3.11: Matriks Korelasi Terbobot Indikator Tahun 2022 ($\mathbf{S}_{2022}$)

Indikator	PPM	RLS	TPT
PPM	1	-0,8277	0,5779
RLS	-0,8277	1	-0,9363
TPT	0,5779	-0,9363	1

Sebagai pelengkap, Gambar 3.2 menyajikan heatmap korelasi Pearson antar-indikator untuk data sampel tahun 2020. Nilai pada diagonal menunjukkan nama variabel (korelasi sempurna = 1,00), sedangkan sel di luar diagonal memuat nilai koefisien Pearson r dan bintang signifikansi (*** $p < 0{,}001$; ** $p < 0{,}01$; * $p < 0{,}05$; ns tidak signifikan). Warna biru tua menandakan korelasi positif kuat dan merah tua menandakan korelasi negatif kuat.



Gambar 3.2: Heatmap Korelasi Pearson Indikator Data Sampel Tahun 2020

3.7.1.5 Tahap 3: Analisis Inter-struktur (Koefisien RV)

Kemiripan struktural antar-situasi dikuantifikasi melalui matriks interstruktur $\mathbf{H}$ (Persamaan 2.32) dan koefisien RV (Persamaan 2.33). Elemen $H_{kk'} = \mathrm{tr}(\mathbf{W}_k\mathbf{D}\mathbf{W}_{k'}\mathbf{D})$ yang secara aljabar setara dengan $\mathrm{tr}(\mathbf{S}_k\mathbf{S}_{k'})$ di mana $\mathbf{S}_k = \mathbf{Z}_k^T\mathbf{D}\mathbf{Z}_k$. Karena setelah standardisasi terbobot diagonal $\mathbf{S}_k$ bernilai 1, elemen diagonal H_{11} diturunkan sebagai berikut:

$$\begin{aligned} H_{11} &= \mathrm{tr}(\mathbf{S}_{2020}^2) = 1^2 + 1^2 + 1^2 + 2\big[(-0{,}8141)^2 + (-0{,}2781)^2 + (-0{,}3313)^2\big] \\ &= 3 + 2(0{,}6628 + 0{,}0773 + 0{,}1098) = 4{,}6998 \end{aligned}$$

Matriks $\mathbf{H}$ lengkap disajikan pada Tabel 3.12 berikut.

Tabel 3.12: Matriks Interstruktur H_W (Identik Kedua Skenario)

Tahun	2020	2021	2022
2020	4,6998	5,0009	5,1018
2021	5,0009	6,3306	6,5334
2022	5,1018	6,5334	6,7915

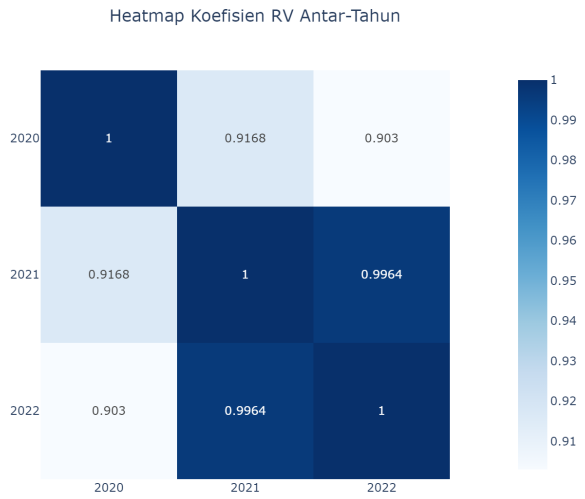
Substitusi nilai $H_{11} = 4{,}6998$, $H_{12} = 5{,}0009$, $H_{22} = 6{,}3306$ ke Persamaan 2.33:

$$RV(\mathbf{W}_{2020}, \mathbf{W}_{2021}) = \frac{H_{12}}{\sqrt{H_{11} \cdot H_{22}}} = \frac{5{,}0009}{\sqrt{4{,}6998 \times 6{,}3306}}$$
$$= \frac{5{,}0009}{\sqrt{29{,}7525}} = \frac{5{,}0009}{5{,}4546} = 0{,}9168$$

Koefisien RV lengkap disajikan pada Tabel 3.13 dan divisualisasikan pada Gambar 3.3.

Tabel 3.13: Koefisien RV Wilayah (Identik Kedua Skenario)

Tahun	2020	2021	2022
2020	1	0,9168	0,9030
2021	0,9168	1	0,9964
2022	0,9030	0,9964	1



Gambar 3.3: Visualisasi Heatmap Matriks RV Data Sampel

3.7.1.6 Tahap 4: Penentuan Bobot Kompromi (α_k) – Dua Skema Pembobotan

Langkah kritis dalam STATIS adalah penentuan bobot kompromi α_k, yang mencerminkan kontribusi setiap situasi (tahun) terhadap struktur bersama. Sesuai dengan kerangka

kerja **?**, penelitian ini menyediakan **dua skema pembobotan** yang menghasilkan dua skenario analisis:

- **Skenario 1 – ACT Klasik (Host = Wilayah):** Matriks intra-struktur $\mathbf{W}_k = \tilde{\mathbf{Z}}_k \tilde{\mathbf{Z}}_k^T$ berukuran $n \times n$ menggambarkan kemiripan antar-wilayah. Matriks interstruktur $\mathbf{H}_W$ dihitung dari $\text{tr}(\mathbf{D}^{1/2}\mathbf{W}_k\mathbf{D}^{1/2} \cdot \mathbf{D}^{1/2}\mathbf{W}_{k'}\mathbf{D}^{1/2})$.
- **Skenario 2 – Dual STATIS (Host = Indikator):** Matriks intra-struktur $\mathbf{S}_k = \mathbf{Z}_k^T\mathbf{D}\mathbf{Z}_k$ berukuran $p \times p$ menggambarkan kemiripan antar-indikator. Matriks interstruktur $\mathbf{H}_S$ dihitung dari $\text{tr}(\mathbf{S}_k\mathbf{S}_{k'})$.

Dekomposisi spektral $\mathbf{H}_W\mathbf{u} = \theta\mathbf{u}$ menghasilkan vektor eigen pertama $\mathbf{u}_1$ dan bobot $\alpha_{W,k}$; demikian pula $\mathbf{H}_S\mathbf{v} = \vartheta\mathbf{v}$ menghasilkan $\alpha_{S,k}$. Kedua skema bobot disajikan pada Tabel 3.14 dan Tabel 3.15.

Tabel 3.14: Bobot Alpha (Wilayah)

Tahun	Alpha (Wilayah)
2020	0,2881
2021	0,3503
2022	0,3616

Tabel 3.15: Bobot Alpha (Indikator)

Tahun	Alpha (Indikator)
2020	0,2794
2021	0,3556
2022	0,3650

Contoh penghitungan (Skenario 1): Matriks $\mathbf{H}_W$ (Tabel 3.12) diselesaikan dengan eigendekomposisi Persamaan 2.34. Nilai eigen pertama adalah $\lambda_1 = 17{,}1859$ dengan vektor eigen ternormalisasi satuan $\mathbf{u}_1 = (0{,}4967;\ 0{,}6038;\ 0{,}6233)^T$, sehingga $\|\mathbf{u}_1\|_1 = 0{,}4967 + 0{,}6038 + 0{,}6233 = 1{,}7238$. Substitusi ke Persamaan 2.35:

$$\alpha_{2020} = \frac{0{,}4967}{1{,}7238} = 0{,}2881, \quad \alpha_{2021} = \frac{0{,}6038}{1{,}7238} = 0{,}3503, \quad \alpha_{2022} = \frac{0{,}6233}{1{,}7238} = 0{,}3616$$

sebagaimana dikonfirmasi pada Tabel 3.14.

Dari kedua tabel di atas, perhatikan bahwa nilai $\alpha_{W,k}$ dan $\alpha_{S,k}$ dapat berbeda. Skenario 1 menekankan kestabilan posisi relatif antar-wilayah, sedangkan Skenario 2 menekankan konsistensi struktur hubungan antar-indikator.

3.7.1.7 Tahap 5: Sintesis Matriks Kompromi – Skenario 1 vs Skenario 2

Matriks kompromi disintesis melalui kombinasi linear tertimbang. Kedua skenario menghasilkan matriks kompromi yang berbeda:

Skenario 1 (ACT Klasik – Host = Wilayah): Matriks kompromi $\mathbf{W}_c = \sum_k \alpha_{W,k}\, \mathbf{W}_k$ berukuran $n \times n$, merupakan rataan terbobot matriks intra-struktur wilayah:

$$\mathbf{W}_c^{(1)} = \alpha_{W,2020}\, \mathbf{W}_{2020} + \alpha_{W,2021}\, \mathbf{W}_{2021} + \alpha_{W,2022}\, \mathbf{W}_{2022}$$

Dekomposisi spektral $\mathbf{W}_c^{(1)} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^T$ memberikan eigenvector $\mathbf{P}$ dan eigenvalue $\mathbf{\Lambda}$. Skor kompromi wilayah diperoleh melalui:

$$\mathbf{F}_c^{(1)} = \mathbf{D}^{-1/2}\mathbf{P}\mathbf{\Lambda}^{1/2}, \quad \mathbf{G}_c^{(1)} = \sum_k \alpha_{W,k} \left(\mathbf{Z}_k^T \mathbf{D} \mathbf{F}_c^{(1)} \mathbf{\Lambda}^{-1/2}\right) \tag{3.4}$$

Contoh penghitungan: Sebagai contoh elemen matriks kompromi $\mathbf{W}_c$ (Persamaan 2.36), elemen $[1, 2]$ mencerminkan kemiripan antara Kota Jakarta Pusat dan Kabupaten Bandung Barat. Terlebih dahulu dihitung $\mathbf{W}_k[1, 2] = \mathbf{z}_{1,k}^T \mathbf{z}_{2,k}$ dari baris pertama dan kedua $\mathbf{Z}_k$:

$$\begin{aligned}
\mathbf{W}_{2020}[1,2] &= (-1{,}48)(0{,}40) + (1{,}47)(-0{,}85) + (-0{,}03)(0{,}76) \\
&= -0{,}592 - 1{,}250 - 0{,}023 = -1{,}864 \\
\mathbf{W}_{2021}[1,2] &= (-1{,}51)(0{,}47) + (1{,}44)(-0{,}88) + (-0{,}99)(0{,}99) \\
&= -0{,}710 - 1{,}267 - 0{,}980 = -2{,}957 \\
\mathbf{W}_{2022}[1,2] &= (-1{,}50)(0{,}45) + (1{,}45)(-0{,}87) + (-1{,}17)(0{,}98) \\
&= -0{,}675 - 1{,}262 - 1{,}147 = -3{,}083
\end{aligned}$$

Kombinasi linear tertimbang menggunakan α_k dari Tabel 3.14:

$$\begin{aligned}
\mathbf{W}_c[1,2] = 0{,}2881 \times (-1{,}864) + 0{,}3503 \times (-2{,}957) + 0{,}3616 \times (-3{,}083) \\
= -0{,}537 - 1{,}036 - 1{,}115 = -2{,}688
\end{aligned}$$

Nilai eigen $\mathbf{W}_c$ disajikan pada Tabel 3.16; nilai eigen pertama $\lambda_1^{(c)} = 2{,}3008$ digunakan sebagai $\mathbf{\Lambda}^{1/2}$ pada persamaan di atas.

Skenario 2 (Dual STATIS – Host = Indikator): Matriks kompromi $\mathbf{S}_c = \sum_k \alpha_{S,k}\, \mathbf{S}_k$ berukuran $p \times p$, merupakan rataan terbobot matriks korelasi antar-indikator:

$$\mathbf{S}_c^{(2)} = \alpha_{S,2020}\, \mathbf{S}_{2020} + \alpha_{S,2021}\, \mathbf{S}_{2021} + \alpha_{S,2022}\, \mathbf{S}_{2022}$$

Dekomposisi SVD $\mathbf{S}_c^{(2)} = \mathbf{U}\mathbf{\Sigma}\mathbf{U}^T$ memberikan eigenvector indikator $\mathbf{U}$ dan nilai singular $\mathbf{\Sigma}$. Loading (koordinat indikator) dan skor kompromi objek diperoleh melalui:

$$\mathbf{G}_c^{(2)} = \mathbf{U}_{:,1:2}\,\mathbf{\Sigma}_{1:2}^{1/2}, \quad \mathbf{F}_c^{(2)} = \sum_k \alpha_{S,k}\,(\mathbf{Z}_k\,\mathbf{U}_{:,1:2}) \tag{3.5}$$

Hasil dekomposisi nilai eigen untuk masing-masing skenario disajikan pada Tabel 3.16 dan Tabel 3.17.

Tabel 3.16: Dekomposisi Nilai Eigen (scenario1)

Dimensi	**Eigenvalue**	**Varians (%)**	**Kumulatif (%)**
Dim 1	2,3008	76,6900	76,6900
Dim 2	0,6992	23,3100	100
Dim 3	0	0	100
Dim 4	0	0	100

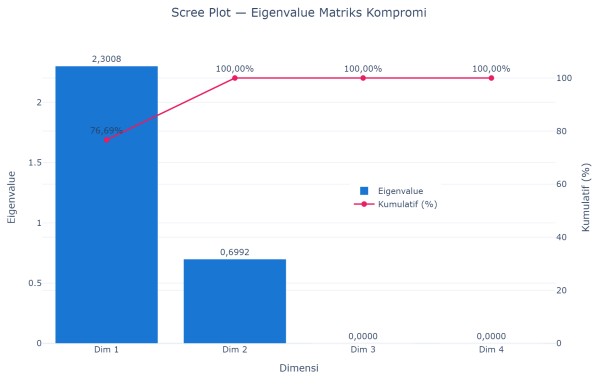
Tabel 3.17: Dekomposisi Nilai Eigen (scenario2)

Dimensi	**Eigenvalue**	**Varians (%)**	**Kumulatif (%)**
Dim 1	2,2692	75,6400	75,6400
Dim 2	0,7058	23,5300	99,1700
Dim 3	0,0250	0,8300	100

Tabel 3.18: Diagnostik Dominansi Model Rank-1 (Areia *et al.*, 2008)

Kuantitas	**Nilai**
λ_1 (Nilai Eigen Dominan)	17,1859
$\|\mathbf{H}\|_F^2$ (Frobenius^2)	295,7348
V (SS Residual)	0,3803
$V/\|\mathbf{H}\|_F^2$ (Rasio Sisa)	0,0013
Inertia$_1$ (Dominansi %)	96,43%
λ_1/λ_2 (Rasio Kegentingan)	27,8833

Gambar 3.4 menyajikan scree plot yang memperlihatkan dekomposisi nilai eigen matriks kompromi beserta kurva kumulatif variansi yang dijelaskan oleh setiap dimensi (Skenario 1).

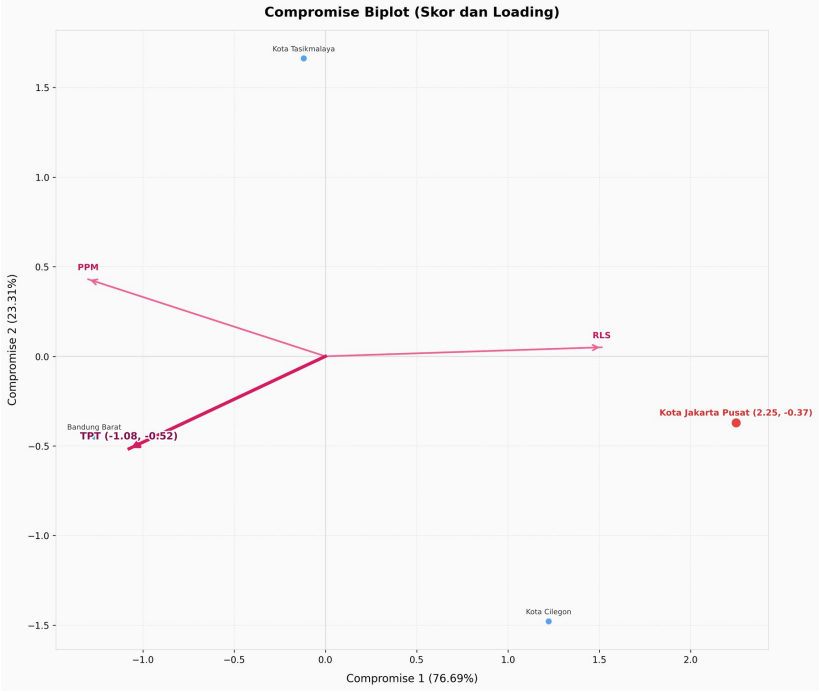


Gambar 3.4: Scree Plot Analisis Kompromi Data Sampel (Skenario 1)

3.7.1.8 Tahap 6: Proyeksi Kompromi – Perbandingan Skenario 1 dan Skenario 2

Koordinat kompromi dari kedua skenario disajikan berdampingan agar perbedaan pendekatan dapat dipahami secara komprehensif.

Skenario 1 – Skor Wilayah ($\mathbf{F}_c^{(1)}$) dan Loading Indikator ($\mathbf{G}_c^{(1)}$): Skor wilayah mencerminkan posisi relatif tiap wilayah pada ruang kompromi, sedangkan loading indikator mencerminkan arah dan kekuatan kontribusi tiap indikator. Gambar 3.5 menyajikan compromise biplot Skenario 1 yang menampilkan posisi wilayah dan arah loading indikator secara simultan dalam satu bidang.



Gambar 3.5: Compromise Biplot Skenario 1 (Host = Wilayah): Skor Wilayah dan Loading Indikator

dengan skor kompromi wilayah ($\mathbf{F}_c^{(1)}$, Persamaan 2.39) dan loading kompromi indikator ($\mathbf{G}_c^{(1)}$, Persamaan 2.42) yang disajikan pada Tabel 3.19 dan Tabel 3.26.

Tabel 3.19: Koordinat Skor Kompromi (scenario1)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
Kota Jakarta Pusat	-2,2496	-0,3712	2,2496	-0,3712
Bandung Barat	1,2664	-0,4478	-1,2664	-0,4478
Kota Tasikmalaya	0,1188	1,6629	-0,1188	1,6629
Kota Cilegon	-1,2227	-1,4783	1,2227	-1,4783

Skor parsial tahunan $\mathbf{F}_k$ (Persamaan 2.40) memproyeksikan matriks intra-struktur tiap tahun ke ruang kompromi. Tabel menyajikan dua pasang kolom: *PC1/PC2 (Asli)* adalah koordinat mentah langsung dari perhitungan STATIS sebelum penyesuaian apapun, sedangkan *PC1/PC2 (Visual)* adalah koordinat setelah transformasi penyesuaian visual (penyelarasan arah sumbu dan skalasi proporsional) sebagaimana diuraikan pada Poin 3.. Hasil per tahun disajikan pada tabel berikut:

Tabel 3.20: Skor Intra Tahun 2020 ($\mathbf{F}_{2020}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
Kota Jakarta Pusat	-1,7840	-0,9027	1,7840	-0,9027
Bandung Barat	0,9296	-0,6366	-0,9296	-0,6366
Kota Tasikmalaya	0,2810	2,9117	-0,2810	2,9117
Kota Cilegon	-0,9879	-2,3239	0,9879	-2,3239

Tabel 3.21: Skor Intra Tahun 2021 ($\mathbf{F}_{2021}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
Kota Jakarta Pusat	-2,3610	-0,0858	2,3610	-0,0858
Bandung Barat	1,3894	-0,4687	-1,3894	-0,4687
Kota Tasikmalaya	-0,0260	1,2981	0,0260	1,2981
Kota Cilegon	-1,1970	-1,1055	1,1970	-1,1055

Tabel 3.22: Skor Intra Tahun 2022 ($\mathbf{F}_{2022}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
Kota Jakarta Pusat	-2,5125	-0,2243	2,5125	-0,2243
Bandung Barat	1,4156	-0,2772	-1,4156	-0,2772
Kota Tasikmalaya	0,1300	1,0214	-0,1300	1,0214
Kota Cilegon	-1,4347	-1,1659	1,4347	-1,1659

Dari koordinat skor intra $\mathbf{F}_k$, pergeseran posisi rata-rata (*centroid*) seluruh wilayah antar-tahun dapat dikuantifikasi menggunakan jarak *Euclidean* (Persamaan 2.68). Misalkan $c_k = \left(\overline{f_{k,1}},\ \overline{f_{k,2}}\right)$ adalah centroid kolom skor intra tahun k, maka $D(c_k, c_{k+1})$ mengukur besarnya pergeseran kolektif seluruh wilayah dalam ruang kompromi dari satu tahun ke tahun berikutnya.

Contoh penghitungan jarak pergeseran kolektif: Dengan $n = 4$ wilayah dari Tabel 3.20 dan 3.21, centroid masing-masing tahun diperoleh sebagai rata-rata aritmetika koordinat seluruh wilayah:

$$
\begin{aligned}
c_{2020} &= \left(\tfrac{-1{,}7840+0{,}9296+0{,}2810-0{,}9879}{4},\ \tfrac{-0{,}9027-0{,}6366+2{,}9117-2{,}3239}{4}\right) \\
&= (-0{,}3903;\ -0{,}2379) \\
c_{2021} &= \left(\tfrac{-2{,}3610+1{,}3894-0{,}0260-1{,}1970}{4},\ \tfrac{-0{,}0858-0{,}4687+1{,}2981-1{,}1055}{4}\right) \\
&= (-0{,}5487;\ -0{,}0905)
\end{aligned}
$$

Substitusi ke Persamaan 2.68 dengan $p = 2$:

$$\begin{aligned} D(c_{2020},\, c_{2021}) &= \sqrt{\big(-0{,}3903 - (-0{,}5487)\big)^2 + \big(-0{,}2379 - (-0{,}0905)\big)^2} \\ &= \sqrt{(0{,}1584)^2 + (-0{,}1474)^2} \\ &= \sqrt{0{,}0251 + 0{,}0217} = \sqrt{0{,}0468} \approx 0{,}2163 \end{aligned}$$

Untuk tahun 2022, $c_{2022} = (-0{,}6004;\ -0{,}1615)$, sehingga $D(c_{2021}, c_{2022}) = \sqrt{(0{,}0517)^2 + (0{,}0710)^2} \approx 0{,}0879$. Nilai $D(c_{2020}, c_{2021}) > D(c_{2021}, c_{2022})$ mengindikasikan bahwa pergeseran kolektif terbesar terjadi pada transisi 2020 ke 2021.

Contoh penghitungan jarak pergeseran per-entitas: Selain centroid kolektif, pergeseran posisi setiap entitas (wilayah atau indikator) secara individual antar-tahun dihitung menggunakan rumus yang sama (Persamaan 2.68). Misalkan posisi Kota Jakarta Pusat pada ruang skor intra ($\mathbf{F}_k$, Skenario 1) adalah $\mathbf{p}_{2020} = (-1{,}7840;\ -0{,}9027)$ dan $\mathbf{p}_{2021} = (-2{,}3610;\ -0{,}0858)$ (dari Tabel 3.20–3.21), maka:

$$\begin{aligned} D(\mathbf{p}_{2020},\, \mathbf{p}_{2021}) &= \sqrt{\big(-2{,}3610 - (-1{,}7840)\big)^2 + \big(-0{,}0858 - (-0{,}9027)\big)^2} \\ &= \sqrt{(-0{,}5770)^2 + (0{,}8169)^2} = \sqrt{0{,}3329 + 0{,}6673} \approx 1{,}0001 \end{aligned}$$

Untuk periode 2021–2022, diperoleh $D(\mathbf{p}_{2021}, \mathbf{p}_{2022}) \approx 0{,}2053$, jauh lebih kecil, mengindikasikan posisi wilayah ini cenderung stabil setelah transisi 2020–2021. Nilai per-entitas untuk seluruh wilayah dan indikator tersedia pada folder `jarak/` hasil ekspor.

Loading parsial tahunan $\mathbf{G}_k$ (Persamaan 2.41) diperoleh dengan memproyeksikan $\mathbf{Z}_k^T$ ke ruang kompromi. *Contoh penghitungan:* elemen $\mathbf{G}_{2020}[\text{PPM}, \text{PC1}]$ dihitung sebagai berikut (dengan $\sqrt{\lambda_1^{(c)}} = \sqrt{2{,}3008} = 1{,}5168$):

$$\mathbf{G}_{2020}[\text{PPM}, 1] = \frac{\displaystyle\sum_{i=1}^{4} m_i\, z_{i,\text{PPM},2020}\, F_c[i, 1]}{\sqrt{\lambda_1^{(c)}}}$$

$$\begin{aligned}\text{Numerator} &= (0{,}2943)(-1{,}48)(-2{,}25) + (0{,}5040)(0{,}40)(1{,}27) \\ &\quad + (0{,}2015)(1{,}17)(0{,}12) + (0{,}0001)(-1{,}74)(-1{,}22) \\ &= 0{,}980 + 0{,}256 + 0{,}028 + 0{,}000 = 1{,}264\end{aligned}$$

$$\therefore\ \mathbf{G}_{2020}[\text{PPM}, 1] = \frac{1{,}264}{1{,}5168} \approx 0{,}8306$$

Loading $\mathbf{G}_k$ untuk semua tahun disajikan pada tabel berikut. Serupa dengan tabel skor intra, kolom *PC1/PC2 (Asli)* adalah koordinat loading mentah hasil STATIS, sedangkan *PC1/PC2 (Visual)* telah melalui skalasi proporsional dan penyelarasan arah sumbu sebagaimana diuraikan pada Poin 3., agar panah indikator tetap sebanding dengan sebaran skor wilayah pada biplot. Loading kompromi $\mathbf{G}_c = \sum_k \alpha_{W,k}\mathbf{G}_k$ (Persamaan 2.42) diperoleh dari rata-rata tertimbangnya:

$$\begin{aligned}\mathbf{G}_c[\text{PPM}, 1] &= 0{,}2881 \times 0{,}8306 + 0{,}3503 \times 0{,}8732 + 0{,}3616 \times 0{,}8621 \\ &= 0{,}2393 + 0{,}3059 + 0{,}3117 = 0{,}8569\end{aligned}$$

Tabel 3.23: Loading Intra Tahun 2020 ($\mathbf{G}_{2020}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
PPM	0,8306	0,5569	-1,2599	0,4657
RLS	-0,9996	0,0289	1,5162	0,0242
TPT	0,3039	-0,9527	-0,4610	-0,7966

Tabel 3.24: Loading Intra Tahun 2021 ($\mathbf{G}_{2021}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
PPM	0,8732	0,4874	-1,3245	0,4075
RLS	-0,9967	0,0813	1,5118	0,0679
TPT	0,8329	-0,5534	-1,2634	-0,4627

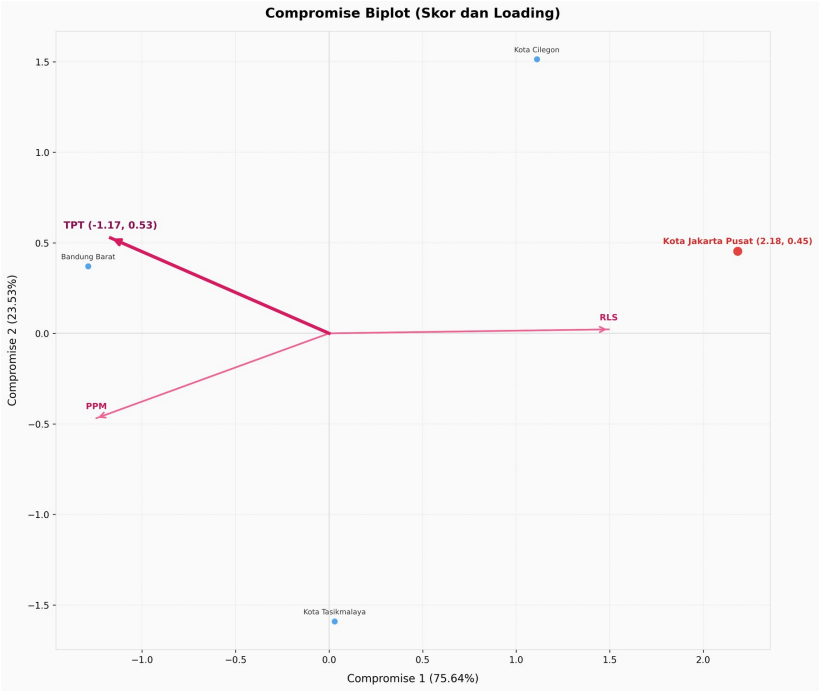
Tabel 3.25: Loading Intra Tahun 2022 ($\mathbf{G}_{2022}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
PPM	0,8621	0,5067	-1,3077	0,4236
RLS	-0,9979	0,0645	1,5137	0,0539
TPT	0,9117	-0,4108	-1,3830	-0,3435

Tabel 3.26: Loadings Kompromi (scenario1)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
PPM	0,8569	0,5144	-1,2998	0,4301
RLS	-0,9980	0,0601	1,5138	0,0503
TPT	0,7090	-0,6168	-1,0755	-0,5158

Skenario 2 – Skor Wilayah ($\mathbf{F}_c^{(2)}$) dan Loading Indikator ($\mathbf{G}_c^{(2)}$): Pada Skenario 2, kompromi terbentuk pada ruang indikator, sehingga biplot lebih menekankan hubungan antar-indikator. Proyeksi wilayah ke ruang ini menghasilkan skor yang mencerminkan kemiripan profil indikator. Gambar 3.6 menyajikan compromise biplot Skenario 2 pada ruang tersebut.



Gambar 3.6: Compromise Biplot Skenario 2 (Host = Indikator): Skor Wilayah dan Loading Indikator

dengan skor kompromi wilayah ($\mathbf{F}_c^{(2)}$, Persamaan 2.46) dan loading kompromi indikator ($\mathbf{G}_c^{(2)}$, Persamaan 2.43) yang disajikan pada Tabel 3.27 dan Tabel 3.28.

Tabel 3.27: Koordinat Skor Kompromi (scenario2)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
Kota Jakarta Pusat	2,1848	0,4533	2,1848	0,4533
Bandung Barat	-1,2879	0,3709	-1,2879	0,3709
Kota Tasikmalaya	0,0294	-1,5906	0,0294	-1,5906
Kota Cilegon	1,1103	1,5140	1,1103	1,5140

Tabel 3.28: Loadings Kompromi (scenario2)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
PPM	-0,8260	-0,5578	-1,2443	-0,4687
RLS	0,9926	0,0262	1,4952	0,0220
TPT	-0,7757	0,6276	-1,1684	0,5273

Contoh penghitungan (Skenario 2): Loading kompromi diekstraksi langsung dari dekomposisi $\mathbf{S}_c$ (Persamaan 2.43: $\mathbf{G}_c = \mathbf{V}_c\mathbf{\Lambda}_s^{1/2}$). Dengan vektor eigen pertama $\mathbf{V}_c[:, 1] = (-0{,}5483;\ 0{,}6590;\ -0{,}5149)^T$ dan $\sqrt{\lambda_{s1}} = \sqrt{2{,}2692} = 1{,}5064$:

$$\mathbf{G}_c[\text{PPM}, 1] = (-0{,}5483) \times 1{,}5064 = -0{,}8260$$
$$\mathbf{G}_c[\text{RLS}, 1] = 0{,}6590 \times 1{,}5064 = 0{,}9926$$
$$\mathbf{G}_c[\text{TPT}, 1] = (-0{,}5149) \times 1{,}5064 = -0{,}7757$$

Loading parsial tahunan $\mathbf{G}_k$ (Persamaan 2.44: $\mathbf{G}_k = \mathbf{S}_k\mathbf{V}_c\mathbf{\Lambda}_s^{-1/2}$). Kolom *PC1/PC2 (Asli)* adalah koordinat mentah STATIS, sedangkan *PC1/PC2 (Visual)* telah melalui skalasi proporsional (Poin 3.) agar sesuai rentang tampilan biplot. Contoh elemen $\mathbf{G}_{2020}[\text{PPM}, \text{PC1}]$ menggunakan $\mathbf{S}_{2020}$ dari Tabel 3.9:

$$\begin{aligned}\text{Numerator} &= 1 \times (-0{,}5483) + (-0{,}8141) \times 0{,}6590 + (-0{,}2781) \times (-0{,}5149) \\ &= -0{,}5483 - 0{,}5365 + 0{,}1432 = -0{,}9416\end{aligned}$$
$$\mathbf{G}_{2020}[\text{PPM}, 1] = \frac{-0{,}9416}{1{,}5064} = -0{,}6251$$

Tabel 3.29: Loading Intra Tahun 2020 ($\mathbf{G}_{2020}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
PPM	-0,6251	-1,0679	-0,9416	-0,8972
RLS	0,8470	0,3860	1,2760	0,3243
TPT	-0,3855	1,0967	-0,5807	0,9214

Tabel 3.30: Loading Intra Tahun 2021 ($\mathbf{G}_{2021}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
PPM	-0,8838	-0,4143	-1,3313	-0,3481
RLS	1,0390	-0,0845	1,5650	-0,0710
TPT	-0,8912	0,4951	-1,3425	0,4159

Tabel 3.31: Loading Intra Tahun 2022 ($\mathbf{G}_{2022}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
PPM	-0,9236	-0,3072	-1,3913	-0,2581
RLS	1,0588	-0,1413	1,5949	-0,1187
TPT	-0,9618	0,3977	-1,4488	0,3341

Skor parsial $\mathbf{F}_k$ (Persamaan 2.45: $\mathbf{F}_k = \mathbf{Z}_k\mathbf{G}_c\mathbf{\Lambda}_s^{-1/2}$). Contoh elemen $\mathbf{F}_{2020}[\text{Kota Jakarta Pusat}, \text{PC1}]$ dengan $\mathbf{Z}_{2020}$ baris ke-1 $= (-1{,}48;\ 1{,}47;\ -0{,}03)$ dan $\mathbf{G}_c[:, 1] = (-0{,}8260;\ 0{,}9926;\ -0{,}7757)$:

$$\mathbf{F}_{2020}[\text{JakPus}, 1] = \frac{(-1{,}48)(-0{,}8260) + (1{,}47)(0{,}9926) + (-0{,}03)(-0{,}7757)}{1{,}5064}$$
$$= \frac{1{,}2225 + 1{,}4591 + 0{,}0233}{1{,}5064} = \frac{2{,}7049}{1{,}5064} = 1{,}7937$$

Tabel 3.32: Skor Intra Tahun 2020 ($\mathbf{F}_{2020}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
Kota Jakarta Pusat	1,7937	1,0073	1,7937	1,0073
Bandung Barat	-1,1702	0,2818	-1,1702	0,2818
Kota Tasikmalaya	0,3066	-2,1769	0,3066	-2,1769
Kota Cilegon	0,6633	1,9384	0,6633	1,9384

Tabel 3.33: Skor Intra Tahun 2021 ($\mathbf{F}_{2021}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
Kota Jakarta Pusat	2,2885	0,3093	2,2885	0,3093
Bandung Barat	-1,3443	0,4028	-1,3443	0,4028
Kota Tasikmalaya	0,0191	-1,4598	0,0191	-1,4598
Kota Cilegon	1,1582	1,3275	1,1582	1,3275

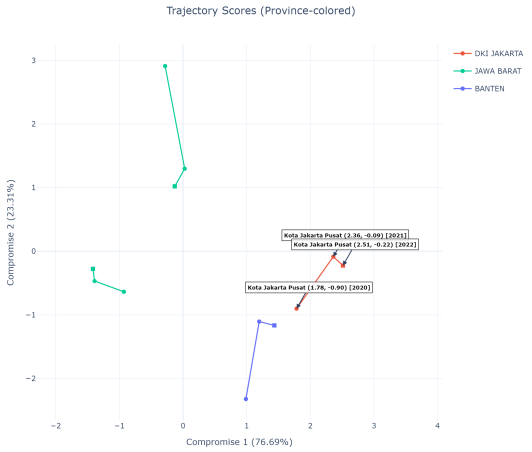
Tabel 3.34: Skor Intra Tahun 2022 ($\mathbf{F}_{2022}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
Kota Jakarta Pusat	2,3831	0,1696	2,3831	0,1696
Bandung Barat	-1,3229	0,4081	-1,3229	0,4081
Kota Tasikmalaya	-0,1727	-1,2691	-0,1727	-1,2691
Kota Cilegon	1,4059	1,3708	1,4059	1,3708

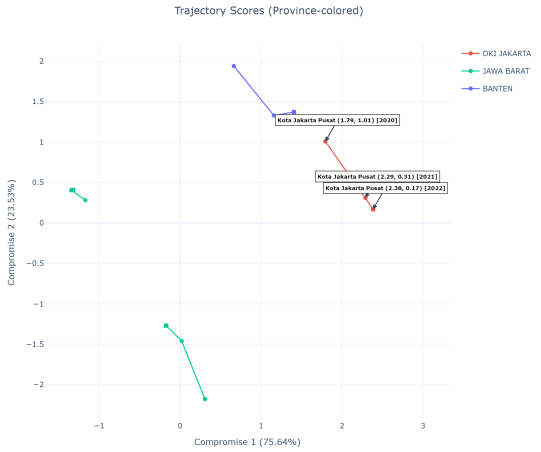
Skor kompromi $\mathbf{F}_c^{(2)}$ diperoleh sebagai rata-rata terbobot (Persamaan 2.46: $\mathbf{F}_c = \sum_k \alpha_{S,k}\mathbf{F}_k$) menggunakan $\alpha_{S,k}$ dari Tabel 3.15.

Dari perbandingan kedua biplot, dapat dilihat bahwa orientasi loading berbeda karena Skenario 1 memaksimalkan varians antar-wilayah sementara Skenario 2 memaksimalkan konsistensi struktur antar-indikator. Dalam praktiknya, Skenario 1 lebih cocok untuk analisis hubungan antar-wilayah lintas waktu, sedangkan Skenario 2 lebih cocok untuk analisis hubungan antar-indikator lintas waktu.

Lintasan pergeseran wilayah (Gambar 3.7 dan 3.8) mengilustrasikan dinamika temporal dari masing-masing skenario.



Gambar 3.7: Trajektori Skenario 1 (Host = Wilayah)



Gambar 3.8: Trajektori Skenario 2 (Host = Indikator)

3.7.1.9 Tahap 7: Uji Signifikansi dan Clustering

Sebelum melanjutkan ke tahap clustering, signifikansi struktur kompromi divalidasi menggunakan uji permutasi Monte Carlo. Uji ini mengevaluasi apakah nilai eigen pertama λ_{obs} dari matriks inter-struktur $\mathbf{H}$ secara statistik lebih besar daripada yang diharapkan secara acak. Pada setiap permutasi $b = 1, \ldots, N_{\text{perm}}$, baris-baris matriks data $\mathbf{Z}_k$ diacak secara terpisah untuk menghancurkan korespondensi antar-tahun, kemudian $\lambda^{(b)}$ dihitung ulang. Nilai p diperoleh menggunakan koreksi *pseudo-count* (Persamaan 2.49):

$$p\text{-value} = \frac{\sum_{b=1}^{B} I\left(\theta_1^{\pi(b)} \geq \theta_1^{\text{obs}}\right) + 1}{B + 1}$$

Pada dataset sampel dengan $B = 1000$ permutasi, nilai eigen terobservasi adalah $\theta_1^{\text{obs}} = \lambda_1 = 17{,}1859$ (dari matriks interstruktur $\mathbf{H}$, bukan dari $\mathbf{W}_c$). Dari 1000 permutasi, terdapat

571 permutasi yang menghasilkan $\theta_1^{\pi} \geq 17{,}1859$, sehingga substitusi ke Persamaan 2.49:

$$p\text{-value} = \frac{571+1}{1000+1} = \frac{572}{1001} = 0{,}5714 \quad \text{(tidak signifikan)}$$

Hasil ini tidak mengejutkan mengingat dataset sampel hanya terdiri dari 4 observasi; dengan derajat kebebasan yang sangat terbatas, distribusi null hampir sepenuhnya menutupi nilai observasi. Pada dataset aktual (41 wilayah), uji permutasi menghasilkan $p < 0{,}05$ yang mengonfirmasi bahwa struktur kompromi STATIS signifikan secara statistik.

Setelah signifikansi dikonfirmasi, jumlah klaster optimal dipilih melalui kombinasi kurva Elbow (Subbab 2.13.2) dan koefisien siluet (Subbab 2.13.3). Berikut adalah contoh penghitungan koefisien siluet menggunakan $k = 2$ pada skor kompromi data sampel:

Contoh penghitungan koefisien siluet ($k = 2$, data sampel, Skenario 1): Skor kompromi empat wilayah sampel dari Tabel 3.19 adalah: Kota Jakarta Pusat (JP) $= (-2{,}2496;\ -0{,}3712)$, Kab. Bandung Barat (BB) $= (1{,}2664;\ -0{,}4478)$, Kota Tasikmalaya (TK) $= (0{,}1188;\ 1{,}6629)$, dan Kota Cilegon (CL) $= (-1{,}2227;\ -1{,}4783)$. Dengan $k = 2$, K-Means menghasilkan dua klaster: $C_1 = \{\text{JP, CL}\}$ dan $C_2 = \{\text{TK, BB}\}$. Jarak Euclidean antar-pasang dihitung menggunakan Persamaan 2.68:

$$d(\text{JP}, \text{CL}) = \sqrt{(-1{,}0269)^2 + (1{,}1071)^2} \approx 1{,}510$$
$$d(\text{TK}, \text{BB}) = \sqrt{(-1{,}1476)^2 + (2{,}1107)^2} \approx 2{,}403$$

Untuk JP (di C_1 dengan satu anggota lain yaitu CL):

$$a(\text{JP}) = d(\text{JP}, \text{CL}) = 1{,}510$$
$$b(\text{JP}) = \frac{d(\text{JP}, \text{TK}) + d(\text{JP}, \text{BB})}{2} = \frac{3{,}122 + 3{,}517}{2} = 3{,}320$$

$$s(\text{JP}) = \frac{3{,}320 - 1{,}510}{\max(3{,}320;\ 1{,}510)} = \frac{1{,}810}{3{,}320} \approx 0{,}545$$

Dengan cara yang sama diperoleh $s(\text{CL}) \approx 0{,}506$, $s(\text{TK}) \approx 0{,}265$, dan $s(\text{BB}) \approx 0{,}226$ (lihat Persamaan 2.64). Koefisien siluet rata-rata (Persamaan 2.65):

$$SC(k=2) = \frac{0{,}545 + 0{,}506 + 0{,}265 + 0{,}226}{4} = \frac{1{,}542}{4} \approx 0{,}386$$

Nilai ini menunjukkan pemisahan klaster yang cukup pada data sampel. Langkah yang sama diterapkan pada data aktual (41 wilayah) untuk nilai $k = 2$ hingga 10, dan hasilnya dikombinasikan dengan kurva Elbow untuk menetapkan $k = 3$ sebagai jumlah klaster optimal (lihat Subbab 4.7.1).

Setelah validasi signifikansi, langkah terakhir adalah pengelompokan wilayah ke dalam $K = 3$ klaster menggunakan algoritma K-Means pada skor kompromi $\mathbf{F}_c$. Label klaster diurutkan berdasarkan rata-rata skor PC1 (klaster dengan skor terendah = Klaster 1, tertinggi = Klaster 3). Keanggotaan wilayah pada dataset sampel disajikan pada Tabel 3.35.

Tabel 3.35: Ringkasan Anggota Klaster Kompromi STATIS (Skenario 1)

Kelompok (Cluster)	**Jumlah Wilayah**	**Daftar Kabupaten/Kota**
Cluster 1 (Rendah)	2	Bandung Barat, Kota Tasikmalaya
Cluster 2 (Tinggi)	2	Kota Jakarta Pusat, Kota Cilegon

Stabilitas pengelompokan lintas tahun dipantau melalui matriks transisi temporal (Tabel 3.36 dan Tabel 3.37).

Tabel 3.36: Matriks Transisi Klaster 2020 $\rightarrow$ 2021

2020 2021	**Cluster 1 (Rendah) (2021)**	**Cluster 2 (Tinggi) (2021)**
Cluster 1 (Rendah) (2020)	1	0
Cluster 2 (Tinggi) (2020)	1	2

Tabel 3.37: Matriks Transisi Klaster 2021 $\rightarrow$ 2022

2021 2022	**Cluster 1 (Rendah) (2022)**	**Cluster 2 (Tinggi) (2022)**
Cluster 1 (Rendah) (2021)	2	0
Cluster 2 (Tinggi) (2021)	0	2

3.7.1.10 Tahap 7a: Komputasi Vektor Struktur dan Analisis Transversal-Longitudinal

Setelah memperoleh matriks interstruktur $\mathbf{H}_W$ (Skenario 1) dan memastikan signifikansinya melalui uji permutasi, parameter interstruktur dipadatkan ke dalam vektor struktur $\tilde{\boldsymbol{\beta}} = \lambda_1 \boldsymbol{\alpha}_1$ (Persamaan 2.51).

1. **Vektor Struktur Gabungan (Global):** Untuk data sampel, nilai eigen pertama dari matriks $\mathbf{H}_W$ adalah $\lambda_1 = 17{,}1859$ (Tabel 3.18). Vektor eigen pertama ternormalisasi satuan adalah $\mathbf{u}_1 = (0{,}4967;\ 0{,}6038;\ 0{,}6233)^T$. Substitusi ke Persamaan 2.51

menghasilkan $\tilde{\beta}_k = \lambda_1 \cdot u_{1k}$:

$$\tilde{\beta}_{2020} = 17{,}1859 \times 0{,}4967 = 8{,}5347$$
$$\tilde{\beta}_{2021} = 17{,}1859 \times 0{,}6038 = 10{,}3798$$
$$\tilde{\beta}_{2022} = 17{,}1859 \times 0{,}6233 = 10{,}7133$$

Kegentingan model rank-1 divalidasi melalui V (Persamaan 2.52) dan Inertia_1 (Persamaan 2.54). Dengan $\|\mathbf{H}\|_F^2 = 295{,}7348$ dan $\text{tr}(\mathbf{H}) = H_{11} + H_{22} + H_{33} = 4{,}6998 + 6{,}3306 + 6{,}7915 = 17{,}8219$:

$$V = \|\mathbf{H}\|_F^2 - \lambda_1^2 = 295{,}7348 - 17{,}1859^2 = 0{,}3803$$
$$\text{Inertia}_1 = \frac{\lambda_1}{\text{tr}(\mathbf{H})} = \frac{17{,}1859}{17{,}8219} = 96{,}43\%$$

Nilai $V/\|\mathbf{H}\|_F^2 = 0{,}3803/295{,}7348 = 0{,}0013$ dan $\lambda_1/\lambda_2 = 27{,}8833$ mengonfirmasi model rank-1 memadai. Hasil komputasi disajikan secara lengkap pada Tabel 3.38 berikut.

Tabel 3.38: Komponen Vektor Struktur $\tilde{\boldsymbol{\beta}}$ per Situasi Waktu

Tahun (k)	$\tilde{\beta}_k = \lambda_1 u_{1k}$
2020	8,5347
2021	10,3798
2022	10,7133

2. **Vektor Struktur Sub-populasi (Provinsi Jawa Barat):** Untuk analisis transversal provinsi pada data sampel, Jawa Barat memiliki 2 wilayah ($n_{\text{sub}} = 2$) yaitu Kabupaten Bandung Barat dan Kota Tasikmalaya. Bobot lokal $\mathbf{D}_{\text{sub}}$ dibentuk dengan menormalisasi bobot kedua wilayah tersebut sehingga berjumlah satu. Matriks interstruktur lokal Jawa Barat $\mathbf{H}_{\text{Jabar}}$ dibentuk dari produk skalar wilayah sub-populasi.

   Eigendekomposisi $\mathbf{H}_{\text{Jabar}}$ menghasilkan nilai eigen pertama $\lambda_{1,\text{Jabar}} = 12{,}8858$ dan vektor eigen pertama $\mathbf{u}_{1,\text{Jabar}} = (0{,}3712;\ 0{,}3305;\ 0{,}2982)^T$. Substitusi menghasilkan komponen $\tilde{\beta}_{\text{Jabar},k}$:

$$\tilde{\beta}_{\text{Jabar},2020} = 12{,}8858 \times 0{,}3712 = 4{,}7834$$
$$\tilde{\beta}_{\text{Jabar},2021} = 12{,}8858 \times 0{,}3305 = 4{,}2591$$
$$\tilde{\beta}_{\text{Jabar},2022} = 12{,}8858 \times 0{,}2982 = 3{,}8433$$

   Hasil ini disajikan secara lengkap pada Tabel 3.39 berikut.

Tabel 3.39: Komponen Vektor Struktur $\tilde{\beta}_{gk}$ per Provinsi (Analisis Transversal)

Tahun (k)	**JAWA BARAT**
2020	4,7834
2021	4,2591
2022	3,8433

Perbedaan pola temporal antara $\tilde{\boldsymbol{\beta}}$ gabungan yang cenderung meningkat (menunjukkan kestabilan struktur yang menguat) dengan $\tilde{\boldsymbol{\beta}}_{\text{Jabar}}$ yang menurun mencerminkan dinamika lokal sub-populasi yang berbeda dari tren global.

3.7.1.11 Tahap 8: Analisis Perbandingan Klaster (9 Jenis)

Untuk mengevaluasi konsistensi dan dinamika hasil pengelompokan secara komprehensif, penelitian ini melaksanakan sembilan jenis analisis perbandingan yang terstruktur dalam empat kategori, sesuai dengan kerangka spasio-temporal STATIS. Penyelarasan label klaster antar-tahun dilakukan menggunakan *Hungarian Algorithm* (**?**) berbasis matriks jarak *centroid* (Persamaan 2.68), sehingga perbandingan antar-tahun konsisten secara kombinatorial.

Contoh penghitungan (dataset sampel, Skenario 1, 2020 vs 2021): Hasil K-Means STATIS pada $\mathbf{F}_{2020}$ menghasilkan tiga klaster dengan keanggotaan: Klaster 1 = {Kota Jakarta Pusat, Kota Cilegon}, Klaster 2 = {Kota Tasikmalaya}, Klaster 3 = {Bandung Barat}. Centroid masing-masing klaster dihitung dari rata-rata koordinat anggotanya (Tabel 3.20):

$$c_{1,2020} = \left(\frac{-1{,}7840+(-0{,}9879)}{2},\ \frac{-0{,}9027+(-2{,}3239)}{2}\right) = (-1{,}3860;\ -1{,}6133)$$
$$c_{2,2020} = (0{,}2810;\ 2{,}9117), \qquad c_{3,2020} = (0{,}9296;\ -0{,}6366)$$

Demikian pula untuk tahun 2021 (Tabel 3.21): $c_{1,2021} = (-1{,}7790;\ -0{,}5957)$, $c_{2,2021} = (-0{,}0260;\ 1{,}2981)$, $c_{3,2021} = (1{,}3894;\ -0{,}4687)$. Matriks jarak 3×3 menggunakan Persamaan 2.68:

$$\mathbf{D} = \begin{pmatrix} D(c_{1,2020}, c_{1,2021}) & D(c_{1,2020}, c_{2,2021}) & D(c_{1,2020}, c_{3,2021}) \\ D(c_{2,2020}, c_{1,2021}) & D(c_{2,2020}, c_{2,2021}) & D(c_{2,2020}, c_{3,2021}) \\ D(c_{3,2020}, c_{1,2021}) & D(c_{3,2020}, c_{2,2021}) & D(c_{3,2020}, c_{3,2021}) \end{pmatrix} = \begin{pmatrix} 1{,}0909 & 3{,}2134 & 3{,}0021 \\ 4{,}0676 & 1{,}6425 & 3{,}5575 \\ 2{,}7089 & 2{,}1578 & 0{,}4895 \end{pmatrix}$$

Hungarian Algorithm memilih penugasan $\{1 \to 1,\ 2 \to 2,\ 3 \to 3\}$ dengan total biaya $1{,}0909 + 1{,}6425 + 0{,}4895 = 3{,}2229$ (minimum di antara $3! = 6$ permutasi), sehingga label klaster konsisten antar-tahun dan tidak ada relabeling yang diperlukan pada dataset sampel ini.

1. **Perbandingan 1 – Transisi Biplot $k \rightarrow k+1$:** Matriks transisi klaster hasil K-Means Biplot PCA (Unweighted) antar-tahun berturutan, untuk memonitor pergeseran wilayah pada ruang PCA individu tanpa koreksi temporal.

2. **Perbandingan 2 – Transisi STATIS $k \rightarrow k+1$:** Matriks transisi klaster hasil K-Means pada koordinat STATIS tahunan ($\mathbf{F}_k$) antar-tahun berturutan, untuk memantau pergeseran berbasis struktur kompromi terbobot.

3. **Perbandingan 3 – Biplot k vs STATIS k:** Tabulasi silang antara label klaster Biplot PCA (Unweighted) dengan label klaster STATIS Tahunan ($\mathbf{F}_k$) pada tahun yang sama, untuk mengukur perbedaan struktural akibat bobot temporal.

4. **Perbandingan 4 – Transisi IPM $k \rightarrow k+1$:** Matriks transisi klasifikasi kategori IPM (UNDP) antar-tahun berurutan, sebagai *baseline* pergeseran normatif berbasis standar internasional.

5. **Perbandingan 5 – Biplot k vs IPM k:** Tabulasi silang antara label klaster Biplot PCA (Unweighted) dengan klasifikasi kategori IPM (UNDP) pada tahun yang sama, sebagai validasi eksternal metode Biplot.

6. **Perbandingan 6 – STATIS k vs IPM k:** Tabulasi silang antara label klaster STATIS Tahunan ($\mathbf{F}_k$) dengan klasifikasi kategori IPM (UNDP) pada tahun yang sama, sebagai validasi eksternal metode STATIS.

7. **Perbandingan 7 – Kompromi STATIS vs Biplot k:** Tabulasi silang antara label klaster Kompromi STATIS (hasil clustering trajektori keseluruhan) dengan label klaster Biplot PCA pada setiap tahun, untuk mengukur konsistensi posisi relatif lintas metode.

8. **Perbandingan 8 – Kompromi STATIS vs STATIS k:** Tabulasi silang antara label klaster Kompromi STATIS (clustering trajektori keseluruhan) dengan label klaster STATIS Tahunan pada setiap tahun, untuk mengevaluasi seberapa representatif kompromi terhadap gambaran tahunan.

9. **Perbandingan 9 – Kompromi STATIS vs IPM k:** Tabulasi silang antara label klaster Kompromi STATIS dengan klasifikasi Kategori IPM (UNDP) pada tahun yang sama, sebagai validasi eksternal final dari pengelompokan berbasis trajektori.

Tiga contoh representatif disajikan berikut untuk mendokumentasikan format keluaran masing-masing kategori; hasil lengkap seluruh tahun tersedia pada dashboard interaktif.

Tabel 3.40: Matriks Transisi Klaster Biplot (Unweighted) 2020 → 2021

2020 2021	**Cluster 1 (Rendah) (2021)**	**Cluster 2 (Tinggi) (2021)**
Cluster 1 (Rendah) (2020)	2	0
Cluster 2 (Tinggi) (2020)	0	2

Tabel 3.41: Nama Daerah Transisi Klaster Biplot 2020 → 2021

Kategori	**Daftar Wilayah**
Cluster 1 (Rendah) (2020) → Cluster 1 (Rendah) (2021)	Bandung Barat, Kota Tasikmalaya
Cluster 2 (Tinggi) (2020) → Cluster 2 (Tinggi) (2021)	Kota Jakarta Pusat, Kota Cilegon

Contoh: Perbandingan 1 – Transisi Biplot (Tahun 2020 vs 2021):

Tabel 3.42: Nama Daerah Perpindahan Klaster 2020 → 2021

Kategori	**Daftar Wilayah**
Cluster 1 (Rendah) (2020) → Cluster 1 (Rendah) (2021)	Kota Tasikmalaya
Cluster 2 (Tinggi) (2020) → Cluster 1 (Rendah) (2021)	Bandung Barat
Cluster 2 (Tinggi) (2020) → Cluster 2 (Tinggi) (2021)	Kota Jakarta Pusat, Kota Cilegon

Contoh: Perbandingan 2 – Transisi STATIS (Skenario 1, Tahun 2020 vs 2021):

Tabel 3.43: Matriks Perbandingan Klaster Biplot vs STATIS (Tahunan) (2020)

Biplot (Unweighted)	**Statis 1 (Rendah)**	**Statis 2 (Tinggi)**
Biplot 1 (Rendah)	1	1
Biplot 2 (Tinggi)	0	2

Tabel 3.44: Nama Daerah Perbandingan Klaster Biplot vs STATIS (Tahunan) (2020)

Kategori	Daftar Wilayah
Biplot 1 (Rendah) & Statis 1 (Rendah)	Kota Tasikmalaya
Biplot 1 (Rendah) & Statis 2 (Tinggi)	Bandung Barat
Biplot 2 (Tinggi) & Statis 2 (Tinggi)	Kota Jakarta Pusat, Kota Cilegon

3.7.2 Analisis Autokorelasi Spasial (Global Moran's I)

Contoh: Perbandingan 3 – Biplot vs STATIS (Skenario 1, Tahun 2020): Sebagai tahap akhir metodologi, Global Moran's I (Persamaan 2.73) diterapkan pada skor PC1 kompromi $f_{i,1}$ menggunakan matriks bobot spasial w_{ij} berbasis ketetanggaan *queen contiguity*. Inferensi dilakukan via permutasi Monte Carlo (N_{perm} permutasi) tanpa bergantung pada asumsi normalitas distribusi skor. Dataset sampel ($n = 4$) tidak memenuhi syarat minimum matriks ketetanggaan yang bermakna; hasil pengujian pada dataset aktual (41 kabupaten/kota) dilaporkan dalam Bab 4.

BAB 4
HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil analisis data longitudinal 41 kabupaten/kota di Provinsi Banten, DKI Jakarta, dan Jawa Barat periode 2020 hingga 2024 menggunakan metode STATIS (*Structuration des Tableaux à Trois Indices de la Statistique*). Analisis dimulai dari eksplorasi data awal dan uji kelayakan, dilanjutkan dengan analisis inter-struktur, pembentukan struktur kompromi, uji stabilitas, analisis trajektori spasio-temporal, hingga analisis klaster dan evaluasinya. Seluruh proses komputasi dilakukan menggunakan *dashboard* interaktif berbasis Python (Dash/Plotly).

Data sekunder yang dianalisis pada bab ini bersumber dari publikasi tahunan referensi statistik yang diterbitkan oleh Badan Pusat Statistik (BPS) dari masing-masing provinsi pada tahun 2020 hingga 2024. Secara rinci, data Provinsi Banten diamati dari publikasi rutin kelima tahunnya (**?????**). Untuk Provinsi DKI Jakarta, data direkam dari dokumen "Provinsi DKI Jakarta Dalam Angka" (**?????**). Sementara itu, konstelasi data seluruh kabupaten/kota di provinsi Jawa Barat direferensikan dari publikasi yang ekuivalen dalam periode yang sama (**?????**). Data lengkap seluruh 41 kabupaten/kota untuk semua indikator dan tahun pengamatan tersedia pada Lampiran **??**.

4.1 Eksplorasi Data Awal

4.1.1 Statistika Deskriptif

Langkah pertama sebelum menerapkan analisis multivariat adalah melakukan eksplorasi terhadap karakteristik distribusi masing-masing indikator pembangunan manusia. Tabel 4.1 menyajikan ringkasan statistika deskriptif, yang meliputi nilai rata-rata (*mean*), simpangan baku, nilai minimum, kuartil pertama (Q1), median, kuartil ketiga (Q3), nilai maksimum, kemiringan (*skewness*), kurtosis, dan koefisien variasi (CV%), untuk setiap indikator pada tiap tahun pengamatan.

Tabel 4.1: Statistika Deskriptif Indikator Pembangunan Manusia Tahun 2020–2024 (N = 41)

2020

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV (%)
GK	0,3592	0,0357	0,2850	0,3360	0,3520	0,3810	0,4270	0,0668	-0,7740	9,9500
TPT	10,1232	2,1596	5,0800	8,9500	10,6800	11,5400	14,2900	-0,4590	-0,3509	21,3300
TPAK	64,4700	3,8591	55,5700	62,0450	63,9100	66,5300	76,9650	0,7812	1,3209	5,9900
AHH_P	73,4278	2,4619	66,5000	72,8700	74,0200	75,4200	76,7100	-1,2048	1,1055	3,3500
JP	1432347,14	1227766,25	433,76	332580,00	1226050,00	2434090,00	5409370,00	0,7879	0,6833	85,7200
PPM	7,6356	3,1055	2,2900	4,9400	7,6200	9,9800	14,8700	0,2597	-0,7499	40,6700
IPM	72,8971	5,7191	63,9100	68,0800	71,7000	77,8300	84,7200	0,4383	-0,9747	7,8500
IPG	89,9871	4,3626	79,0600	86,8100	90,9800	93,5300	96,1400	-0,6283	-0,2917	4,8500
PKKP	3,3263	1,3056	1,2600	2,1800	3,6000	4,2800	5,6400	-0,0754	-1,2654	39,2500
GK	470618,29	122257,45	310437,00	362212,00	457954,00	547415,00	782731,00	0,6325	-0,6175	25,9800
AHH_L	69,6368	2,5445	62,6800	69,0300	70,2500	71,7200	73,2200	-1,1209	0,8502	3,6500
RLS	8,9244	1,6318	6,3000	7,5200	8,6300	10,6300	11,8100	0,2849	-1,2277	18,2800
PDRB_ADHK	90668,15	114358,95	3251,76	21970,41	38598,43	93480,39	449518,14	1,8010	2,1881	126,13

2021

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV (%)
GK	0,3647	0,0529	0,2450	0,3400	0,3630	0,3880	0,5150	0,3782	1,0149	14,5000
TPT	9,1959	2,0346	3,2500	8,2300	9,3200	10,5800	13,0700	-0,6333	0,4640	22,1300
TPAK	64,3738	3,1827	56,7250	62,0800	63,9000	65,7450	74,9150	0,7701	1,6434	4,9400
AHH_P	73,5822	2,4672	66,6100	73,0800	74,2100	75,5200	76,8900	-1,2313	1,1623	3,3500
JP	1447714,39	1242116,97	439,48	335810,00	1234830,00	2446687,00	5484150,00	0,7956	0,7128	85,8000
PPM	8,1639	3,1930	2,5700	5,3500	7,9700	10,7100	15,0600	0,1144	-0,9312	39,1100
IPM	73,1805	5,7523	64,0300	68,2900	72,1000	78,0600	84,9000	0,4213	-0,9879	7,8600
IPG	90,0432	4,3543	79,0700	86,9700	90,8700	93,6000	96,2800	-0,6450	-0,2436	4,8400
PKKP	3,8829	1,5201	1,5500	2,4600	3,8700	5,0000	7,1200	0,1816	-1,1459	39,1500
GK	486788,61	124407,79	320050,00	378819,00	467248,00	570330,00	792684,00	0,5875	-0,7418	25,5600
AHH_L	69,8390	2,5705	62,8200	69,2700	70,5000	71,9400	73,4800	-1,1514	0,8882	3,6800
RLS	9,0273	1,6447	6,4100	7,5300	8,7700	10,7800	11,8200	0,2434	-1,3084	18,2200
PDRB_ADHK	94041,02	118287,92	3371,78	22787,90	39981,19	97869,38	459971,27	1,7731	2,0407	125,78

2022

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV (%)
GK	0,3658	0,0610	0,2110	0,3180	0,3670	0,3940	0,5430	0,3696	0,8754	16,6800
TPT	7,8156	1,9985	1,5600	6,9800	8,1000	8,8300	10,7800	-0,9149	0,9909	25,5700
TPAK	65,6523	3,3273	58,6250	64,0300	65,0600	67,1600	80,0350	1,7204	6,4205	5,0700
AHH_P	73,8912	2,4406	67,0300	73,3700	74,5000	75,8100	77,1800	-1,2024	1,1051	3,3000
JP	1462414,00	1255992,59	445,06	338940,00	1243320,00	2458707,00	5556310,00	0,8032	0,7413	85,8800
PPM	7,8027	3,0617	2,5000	5,0100	7,7200	10,1400	14,1100	0,1383	-0,9442	39,2400
IPM	73,8166	5,6575	64,7100	69,0400	72,7900	78,7700	85,2100	0,4127	-0,9878	7,6600
IPG	90,3415	4,2583	79,6900	87,1700	90,9700	93,8400	96,4800	-0,6361	-0,2386	4,7100
PKKP	5,5502	2,4654	1,5000	3,4500	5,7700	7,4300	10,4500	0,0747	-1,1068	44,4200
GK	512333,02	133660,54	335134,00	398884,00	485613,00	599514,00	842630,00	0,5993	-0,7304	26,0900
AHH_L	70,0607	2,5400	63,1700	69,5000	70,6900	72,1400	73,7000	-1,1122	0,8040	3,6300
RLS	9,1566	1,6221	6,5900	7,8300	8,9000	10,8200	11,8400	0,2314	-1,3538	17,7200
PDRB_ADHK	98968,25	124511,50	3516,57	24298,10	42012,96	103219,44	481954,45	1,7659	2,0038	125,81

2023

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV (%)
GK	0,3739	0,0545	0,2430	0,3420	0,3690	0,4280	0,4680	-0,2663	-0,4264	14,5700
TPT	7,2041	1,7473	1,5200	6,5200	7,3300	8,1100	10,5200	-0,9574	1,5426	24,2500
TPAK	66,2128	3,6045	59,8500	63,8250	66,0550	67,6950	80,2150	1,4114	3,8014	5,4400
AHH_P	74,3205	2,4068	67,5600	73,7800	74,9700	76,2000	77,4500	-1,2365	1,1126	3,2400
JP	1476700,92	1269538,84	450,51	341980,00	1251540,00	2470654,00	5627020,00	0,8107	0,7696	85,9700
PPM	7,4420	2,8508	2,3800	4,8500	7,2700	9,5200	13,1300	0,0826	-0,9921	38,3100
IPM	74,4183	5,6277	65,2100	69,6100	73,3900	79,4600	86,0700	0,4201	-0,9571	7,5600
IPG	90,5937	4,1577	80,3700	87,3100	91,2900	94,0300	97,1600	-0,6001	-0,2853	4,5900
PKKP	4,6354	1,8772	1,5800	2,9100	5,0700	5,9800	8,6500	0,0616	-1,0247	40,5000
GK	553569,61	141787,63	367681,00	426355,00	520713,00	657247,00	891580,00	0,5879	-0,7939	25,6100
AHH_L	70,4171	2,4823	63,7000	69,7900	70,9300	72,5000	74,1000	-1,0287	0,7650	3,5300
RLS	9,2263	1,6267	6,6000	7,8900	8,9100	10,8400	11,8800	0,2655	-1,3451	17,6300
PDRB_ADHK	104051,93	130847,78	3305,13	25655,25	44087,22	108569,83	506560,74	1,7652	2,0079	125,75

2024

Indikator	Mean (μ)	Std Dev (σ)	Min	Q1	Median	Q3	Max	Skew (γ_1)	Kurt (γ_2)	CV (%)
GK	0,3667	0,0561	0,2450	0,3250	0,3670	0,4240	0,4770	-0,3164	-0,6547	15,3000
TPT	6,5522	1,5032	1,5800	6,0800	6,4900	7,4000	9,1800	-0,9517	1,6482	22,9400
TPAK	67,2955	3,6266	58,2950	65,5350	67,2000	68,7950	80,2100	0,7021	2,7090	5,3900
AHH_P	74,5900	2,4199	67,7800	74,0400	75,2900	76,4200	77,7500	-1,2313	1,0489	3,2400
JP	1504586,38	1293092,62	455,62	344850,00	1259230,00	2528160,00	5682300,00	0,7875	0,6512	85,9400
PPM	7,2541	2,8500	2,3400	4,6300	7,0500	9,4900	13,0300	0,1015	-1,0378	39,2900
IPM	74,9951	5,6228	65,8600	70,0300	73,9900	80,0200	86,9400	0,4290	-0,9383	7,5000
IPG	90,7871	4,0874	81,0200	87,5500	91,1500	94,2300	97,3000	-0,5647	-0,3873	4,5000
PKKP	4,6907	1,4802	1,8900	3,5500	5,2200	5,7800	7,9800	-0,4708	-0,6142	31,5500
GK	583233,61	146630,84	393464,00	455636,00	547912,00	685071,00	928278,00	0,5936	-0,7922	25,1400
AHH_L	70,6402	2,4873	63,9000	70,0400	71,1000	72,7200	74,2900	-0,9979	0,7233	3,5200
RLS	9,2837	1,6529	6,6100	7,9000	8,9300	10,8500	11,9900	0,2552	-1,3503	17,8000
PDRB_ADHK	109134,55	137364,99	3268,50	26863,08	46270,92	113998,21	532606,87	1,7693	2,0301	125,87

Catatan: Koefisien Variasi (CV) menunjukkan rasio simpangan baku terhadap rata-rata, dinyatakan dalam persen; CV yang lebih tinggi mengindikasikan variasi relatif yang lebih besar antar-wilayah untuk indikator tersebut.

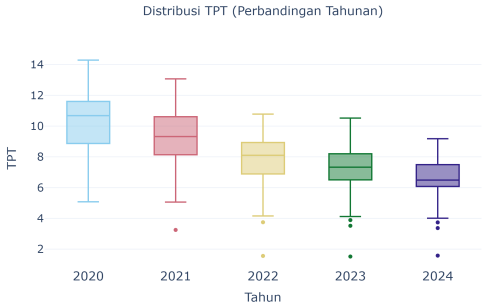
Berdasarkan Tabel 4.1, terlihat bahwa indikator IPM memiliki nilai CV yang relatif rendah (di bawah 8%) di seluruh tahun, yang mengindikasikan bahwa tingkat pembangunan manusia antar-wilayah tidak terlalu bervariasi secara proporsional, meskipun selisih nilai IPM antar wilayah tetap cukup besar secara aktual. Sebaliknya, indikator PDRB ADHK menunjukkan CV terbesar (di atas 100%), mencerminkan kesenjangan kapasitas ekonomi yang sangat lebar antara wilayah berbasis industri di Jabodetabek dengan wilayah agraris di pedalaman Jawa Barat dan Banten.

Kedua, nilai skewness positif pada indikator PPM (Persentase Penduduk Miskin) dan Garis Kemiskinan mengindikasikan bahwa distribusinya menceng ke kanan, artinya sebagian besar wilayah memiliki tingkat kemiskinan moderat, namun terdapat sejumlah kecil wilayah dengan tingkat kemiskinan yang sangat tinggi sehingga nilai rata-rata menjadi lebih tinggi dari nilai yang umum dijumpai. Sebaliknya, indikator RLS (Rata-Rata Lama Sekolah) memiliki distribusi yang lebih simetris, menandakan bahwa pemerataan akses pendidikan sudah lebih baik.

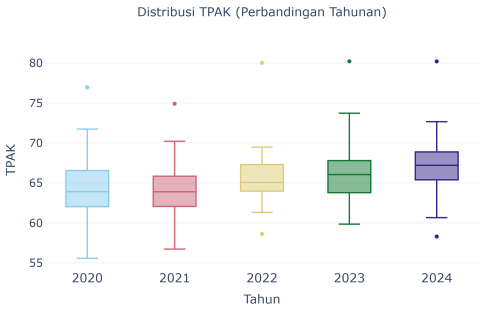
Secara keseluruhan, data menunjukkan bahwa periode 2020 hingga 2024 diwarnai oleh fluktuasi yang dapat dikaitkan dengan dampak pandemi COVID-19 pada 2020 hingga 2021 dan fase pemulihan pada 2022 hingga 2024.

4.1.2 Distribusi Indikator (Boxplot)

Untuk memvisualisasikan sebaran data secara lebih intuitif, termasuk mendeteksi keberadaan *outlier*, berikut disajikan diagram kotak-garis (*boxplot*) setiap indikator sebagai perbandingan tahunan 2020–2024 secara berpasangan.

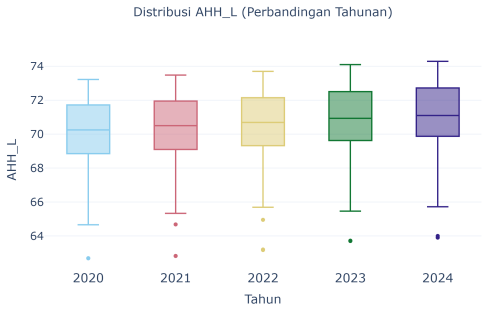


Gambar 4.1: Boxplot Tingkat Pengangguran Terbuka (TPT) Tahun 2020–2024

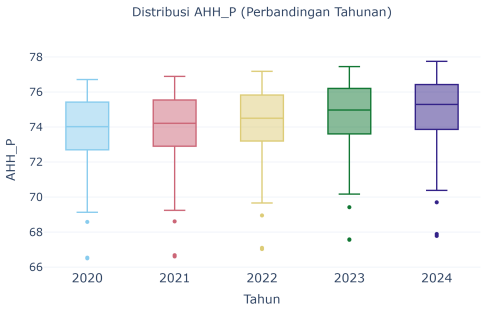


Gambar 4.2: Boxplot Tingkat Partisipasi Angkatan Kerja (TPAK) Tahun 2020–2024

Gambar 4.1 menunjukkan lonjakan nilai median TPT pada tahun 2020 akibat pandemi COVID-19, diikuti tren penurunan yang konsisten hingga 2024; penyempitan distribusi yang terlihat mengindikasikan perbaikan kondisi ketenagakerjaan yang semakin merata antar-wilayah. Gambar 4.2 memperlihatkan distribusi yang lebar dengan beberapa pencilan rendah yang mencirikan wilayah dengan sektor informal yang dominan; median yang relatif stabil antartahun menunjukkan bahwa struktur penyerapan tenaga kerja tidak mengalami perubahan fundamental selama periode pengamatan.



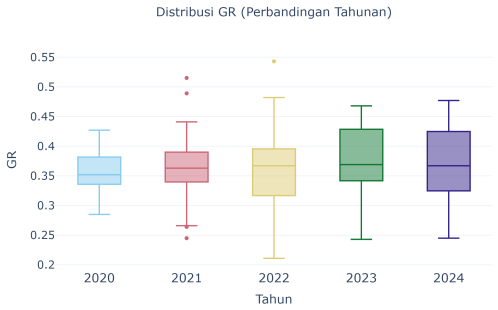
Gambar 4.3: Boxplot Angka Harapan Hidup Laki-Laki (AHH L) Tahun 2020–2024



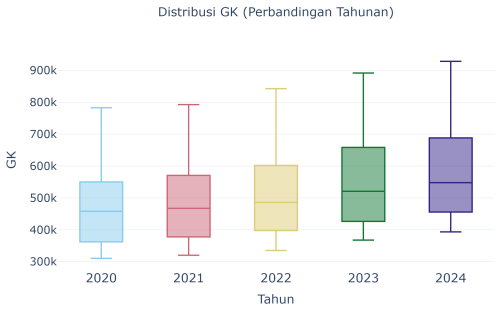
Gambar 4.4: Boxplot Angka Harapan Hidup Perempuan (AHH P) Tahun 2020–2024

Gambar 4.3 memperlihatkan peningkatan bertahap pada nilai median dan penyempitan rentang distribusi, mengindikasikan konvergensi kualitas kesehatan di berbagai wilayah

meskipun masih terdapat beberapa pencilan pada nilai yang lebih rendah. Gambar 4.4 menunjukkan pola yang serupa namun secara konsisten berada pada nilai yang lebih tinggi di setiap tahun, mencerminkan keunggulan harapan hidup perempuan yang merupakan fenomena universal; tren peningkatan pada kedua indikator mengonfirmasi perbaikan layanan kesehatan yang berlangsung merata selama periode pengamatan.

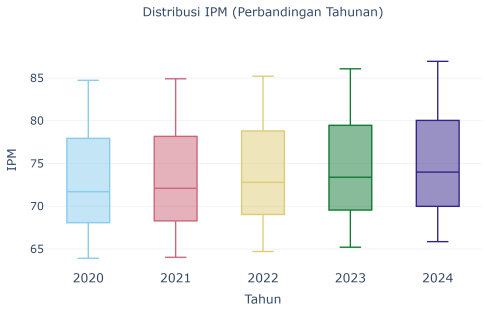


Gambar 4.5: Boxplot Gini Ratio (GR) Tahun 2020–2024

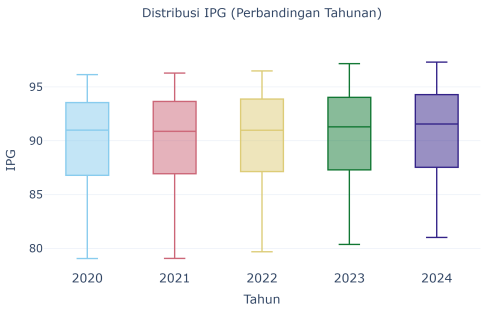


Gambar 4.6: Boxplot Garis Kemiskinan (GK) Tahun 2020–2024

Gambar 4.5 menampilkan distribusi yang cukup terkonsentrasi dengan median yang berfluktuasi ringan, mengindikasikan bahwa tingkat ketimpangan distribusi pendapatan antar-wilayah cenderung stagnan dan belum mengalami perbaikan yang signifikan selama 2020–2024. Gambar 4.6 sebaliknya menampilkan kenaikan nilai median dan pelebaran rentang distribusi yang konsisten dari tahun ke tahun, yang sebagian besar disebabkan oleh tekanan inflasi serta peningkatan standar kebutuhan hidup minimum yang ditetapkan BPS sebagai acuan penghitungan.



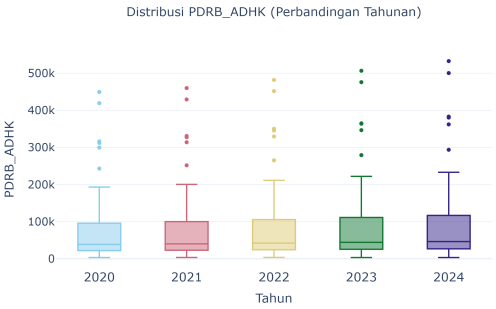
Gambar 4.7: Boxplot Indeks Pembangunan Manusia (IPM) Tahun 2020–2024



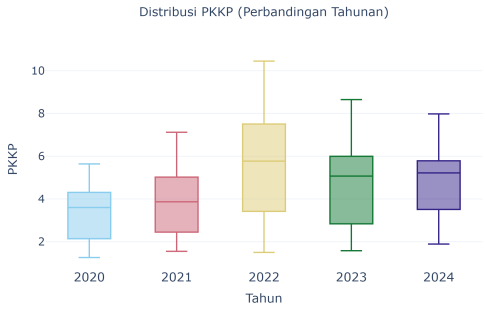
Gambar 4.8: Boxplot Indeks Pemberdayaan Gender (IPG) Tahun 2020–2024

Gambar 4.7 menunjukkan bahwa nilai IPM mengalami peningkatan yang konsisten dari 2020 hingga 2024, ditandai oleh kenaikan median setiap tahunnya yang mencer-

minkan pemulihan dan pertumbuhan pembangunan manusia pascapandemi; rentang interkuartil yang relatif stabil mengindikasikan perbaikan yang terdistribusi cukup merata antar-wilayah. Gambar 4.8 memperlihatkan distribusi IPG yang cenderung stagnan dengan variasi antartahun yang kecil, mengindikasikan bahwa perkembangan kesetaraan gender berlangsung lambat dan belum terjadi perubahan struktural yang signifikan selama periode pengamatan.

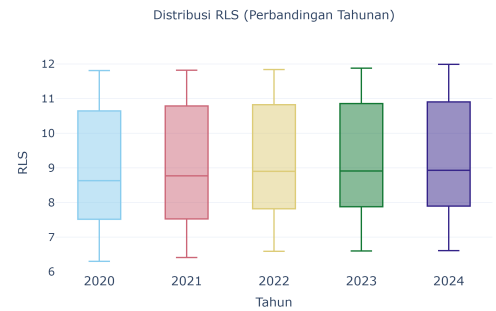


Gambar 4.9: Boxplot PDRB Atas Dasar Harga Konstan (PDRB ADHK) Tahun 2020–2024

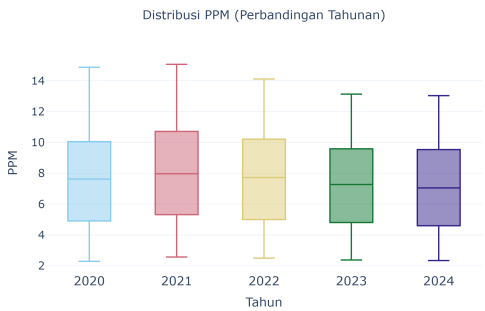


Gambar 4.10: Boxplot Prevalensi Ketidakcukupan Konsumsi Pangan (PKKP) Tahun 2020–2024

Gambar 4.9 menampilkan *outlier* ekstrem yang sangat mencolok pada PDRB ADHK yang secara konsisten mewakili wilayah DKI Jakarta—kapasitas ekonominya jauh melampaui seluruh kabupaten/kota lainnya di setiap tahun pengamatan sehingga distribusi bersifat sangat menceng ke kanan. Gambar 4.10 memperlihatkan bahwa Prevalensi Ketidakcukupan Konsumsi Pangan cenderung menurun dari 2020 hingga 2022, namun mengalami sedikit kenaikan pada 2023–2024 yang kemungkinan mencerminkan dampak tekanan harga pangan global; nilai median yang masih cukup tinggi menunjukkan masih adanya tantangan ketahanan pangan di sebagian wilayah.



Gambar 4.11: Boxplot Rata-Rata Lama Sekolah (RLS) Tahun 2020–2024

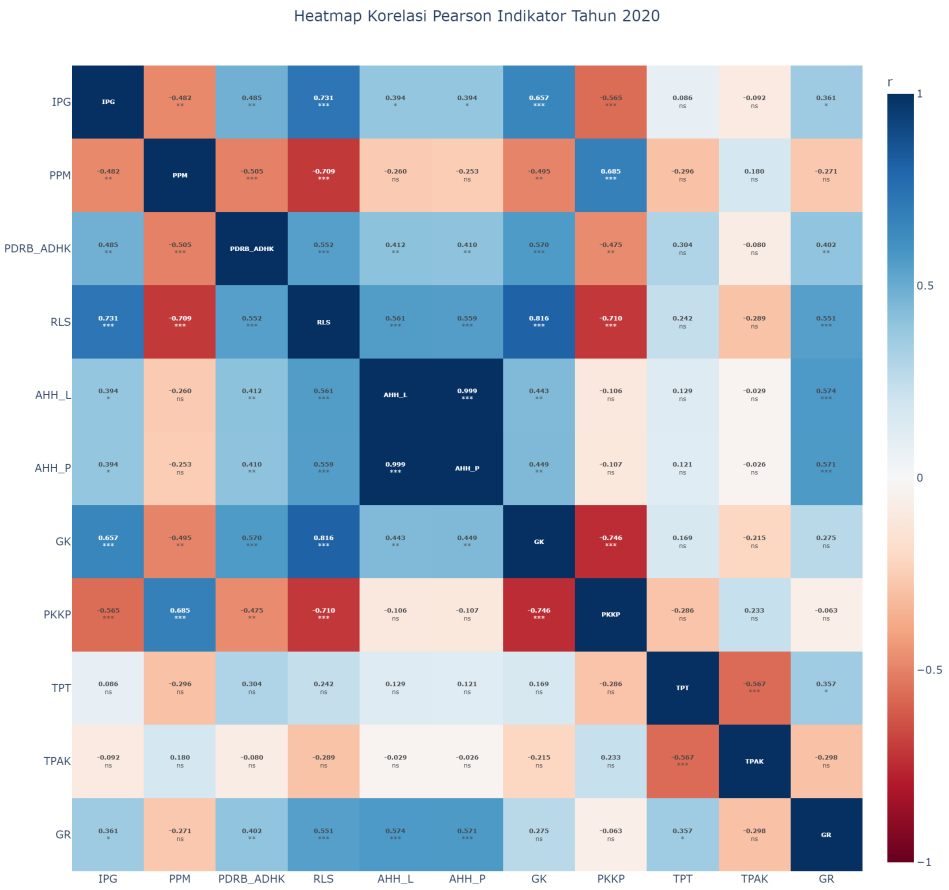


Gambar 4.12: Boxplot Persentase Penduduk Miskin (PPM) Tahun 2020–2024

Gambar 4.11 menunjukkan bahwa rata-rata lama sekolah memiliki distribusi yang

relatif simetris dengan median yang terus meningkat, mencerminkan perbaikan akses dan capaian pendidikan yang cukup merata antar-wilayah dari tahun ke tahun. Gambar 4.12 memperlihatkan distribusi Persentase Penduduk Miskin yang menceng ke kanan (*positively skewed*), di mana sebagian besar wilayah memiliki tingkat kemiskinan relatif rendah namun terdapat beberapa wilayah dengan PPM yang jauh melebihi nilai sentral; terlihat pula penurunan median secara bertahap dari 2020 ke 2024 yang mencerminkan tren pengentasan kemiskinan pascapandemi.

Sebagai pelengkap eksplorasi, Gambar 4.13 menyajikan heatmap korelasi Pearson antar-indikator untuk tahun 2020 (representatif dari seluruh periode). Diagonal utama menunjukkan nama indikator, sedangkan warna di luar diagonal utama menunjukkan besarnya nilai koefisien korelasi Pearson r beserta bintang signifikansi: *** $p<0{,}001$, ** $p<0{,}01$, * $p<0{,}05$, ns (tidak signifikan). Warna biru tua = korelasi positif kuat; merah tua = korelasi negatif kuat; putih ≈ 0 (tidak berkorelasi).



Gambar 4.13: Heatmap Korelasi Pearson Antar-Indikator Tahun 2020 (41 Kabupaten/Kota)

4.2 Uji Kelayakan Data Multivariat

Sebelum data diproses lebih lanjut menggunakan metode STATIS, dilakukan dua pengujian kelayakan untuk memastikan bahwa analisis multivariat valid untuk diterapkan: Uji Kaiser-Meyer-Olkin (KMO) dan Uji Bartlett.

4.2.1 Hasil Uji KMO dan Bartlett

Mengacu pada formula yang disajikan pada Persamaan 2.15 (KMO) dan 2.17 (Bartlett) di Bab 2, hasil pengujian dirangkum sebagai berikut.

Tabel 4.2: Hasil Uji KMO dan Uji Bartlett per Tahun

Tahun	Nilai KMO	Interpretasi Nilai KMO	χ^2 Bartlett	df	P-Value Bartlett	Keputusan
2020	0,7153	Middling (Cukup Baik)	501,2800	55	$< 0,001$	Layak
2021	0,6732	Mediocre (Biasa)	487,5100	55	$< 0,001$	Layak
2022	0,7436	Middling (Cukup Baik)	455,9800	55	$< 0,001$	Layak
2023	0,7201	Middling (Cukup Baik)	469,6300	55	$< 0,001$	Layak
2024	0,6555	Mediocre (Biasa)	459,8500	55	$< 0,001$	Layak

Hasil uji KMO pada Tabel 4.2 menunjukkan bahwa nilai KMO berada pada rentang $0,6555$–$0,7436$ dengan rata-rata $0,7015$ (kategori "$Middling(CukupBaik)$"), yang mengindikasikan bahwa data cukup memadai untuk dianalisis secara multivariat. Selanjutnya, hasil Uji Bartlett dengan p-value $< 0{,}05$ pada seluruh tahun memberikan cukup bukti untuk menolak hipotesis nol bahwa matriks korelasi adalah matriks identitas. Hal ini berarti terdapat interkorelasi signifikan antar-indikator, sehingga analisis dengan metode multivariat (seperti STATIS) dapat dilakukan.

4.3 Analisis Inter-struktur

Tahap pertama dalam algoritma STATIS adalah analisis interstruktur, yang bertujuan mengukur tingkat kemiripan atau konsistensi struktur antarpasangan tahun. Sesuai dengan Persamaan 2.33 dan 2.32 (Bab 2), koefisien RV ($\mathbf{R}_{\text{RV}}$) dan matriks $\mathbf{H}$ dibentuk dari matriks intra-struktur $\mathbf{W}_t$ dan $\mathbf{W}_{t'}$.

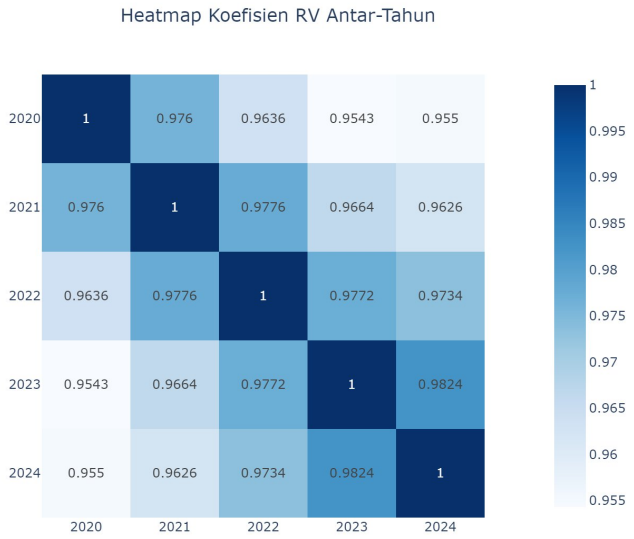
4.3.1 Koefisien RV

Mengikuti prosedur komputasi yang telah diilustrasikan pada Subbab 3.7.1.5 (Bab 3), dihitung koefisien RV untuk seluruh pasangan tahun (2020–2024) menggunakan matriks intra-struktur $\mathbf{W}_t$ yang dibentuk dari data standar (Z-score) untuk setiap tahun. Koefisien RV memberikan ukuran kuantitatif tentang seberapa mirip struktur relatif antar-wilayah

pada dua tahun tertentu, dengan nilai berada di antara 0 (tidak ada kemiripan) hingga 1 (kemiripan sempurna). Hasilnya disajikan pada Tabel 4.3 dan divisualisasikan dalam bentuk heatmap pada Gambar 4.14.

Tabel 4.3: Koefisien RV Wilayah (Identik Kedua Skenario)

Tahun	**2020**	**2021**	**2022**	**2023**	**2024**
2020	1	0,9760	0,9636	0,9543	0,9550
2021	0,9760	1	0,9776	0,9664	0,9626
2022	0,9636	0,9776	1	0,9772	0,9734
2023	0,9543	0,9664	0,9772	1	0,9824
2024	0,9550	0,9626	0,9734	0,9824	1



Gambar 4.14: Heatmap Koefisien RV Antar-Tahun (2020 hingga 2024)

Berdasarkan Gambar 4.14, seluruh nilai koefisien RV berada di atas $0,9543$, yang mengindikasikan bahwa konfigurasi relatif antar-wilayah tidak berbeda signifikan dari tahun ke tahun. Hal ini memiliki implikasi penting: meskipun terjadi perubahan akibat pandemi COVID-19 pada 2020 hingga 2021 yang mengubah nilai aktual (seperti PDRB yang turun), **hierarki** atau **struktur kemiripan** antar-wilayah tidak berubah secara drastis. Wilayah yang secara relatif lebih maju tetap berada di posisi yang lebih baik dibandingkan wilayah yang tertinggal, dan demikian pula sebaliknya.

Nilai RV antara tahun 2020 hingga 2021 yang sedikit lebih rendah dibandingkan pasangan tahun lainnya mengindikasikan bahwa masa awal pandemi sempat menciptakan

sedikit pergeseran struktur, yang kemudian pulih dan kembali konsisten pada 2022 hingga 2024.

4.3.2 Vektor Bobot (Alpha) dan Representativitas Tahun

Berdasarkan nilai eigen dominan dari matriks interstruktur $\mathbf{H}_W$ dan $\mathbf{H}_S$ (Persamaan 2.34–2.35), diperoleh dua vektor bobot yang masing-masing merepresentasikan skenario analisis yang berbeda:

- $\boldsymbol{\alpha}_W$ **(Skenario 1 – Host Wilayah):** Bobot berdasarkan kemiripan intra-struktur antar-wilayah. Tabel 4.4 menyajikan hasilnya.
- $\boldsymbol{\alpha}_S$ **(Skenario 2 – Host Indikator):** Bobot berdasarkan kemiripan struktur korelasi antar-indikator. Tabel 4.5 menyajikan hasilnya.

Tabel 4.4: Bobot Alpha (Wilayah)

Tahun	Alpha (Wilayah)
2020	0,1939
2021	0,1938
2022	0,2010
2023	0,2076
2024	0,2038

Tabel 4.5: Bobot Alpha (Indikator)

Tahun	Alpha (Indikator)
2020	0,1944
2021	0,1940
2022	0,2017
2023	0,2079
2024	0,2021

Dari Tabel 4.4 dan Tabel 4.5, terlihat bahwa sebagian besar bobot α untuk kelima tahun relatif seimbang (berada di antara $0,1938$ hingga $0,2076$). Hal ini menegaskan bahwa tidak ada satu tahun pun yang mendominasi atau mendistorsi gambaran rata-rata (kompromi). Tahun dengan bobot terbesar di tahun 2023 dapat diinterpretasikan sebagai tahun paling representatif terhadap kondisi rata-rata selama 2020 hingga 2024.

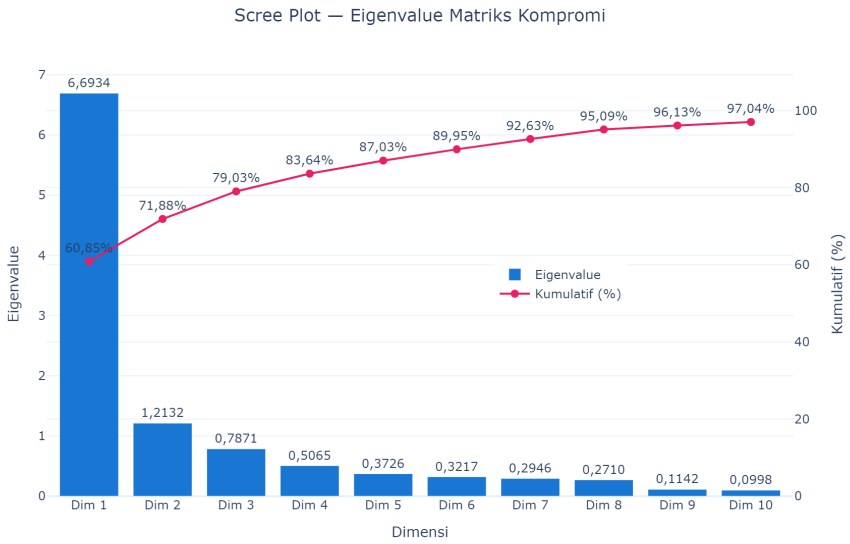
4.4 Analisis Struktur Kompromi

Setelah diperoleh bobot $\boldsymbol{\alpha}$, matriks kompromi dibentuk dan didekomposisi secara spektral. Sesuai dengan dua skenario pembobotan, diperoleh dua representasi kompromi yang akan dianalisis secara paralel:

- **Skenario 1 (ACT Klasik, Host = Wilayah):** $\mathbf{W}_c^{(1)} = \sum_t \alpha_{W,t}\mathbf{W}_t$ berukuran $n \times n$; hasil dekomposisi langsung memberikan koordinat skor wilayah.
- **Skenario 2 (Dual STATIS, Host = Indikator):** $\mathbf{S}_c^{(2)} = \sum_t \alpha_{S,t}\mathbf{S}_t$ berukuran $p \times p$; hasil dekomposisi memberikan koordinat loading indikator secara langsung.

4.4.1 Dekomposisi Eigenvalue (Scree Plot)

Gambar 4.15 menyajikan *scree plot*, yaitu grafik nilai eigen beserta kurva kumulatif variansi yang dijelaskan oleh setiap dimensi kompromi.



Gambar 4.15: Scree Plot Nilai Eigen Matriks Kompromi

Tabel 4.6: Dekomposisi Nilai Eigen Dua Dimensi Pertama Matriks Kompromi

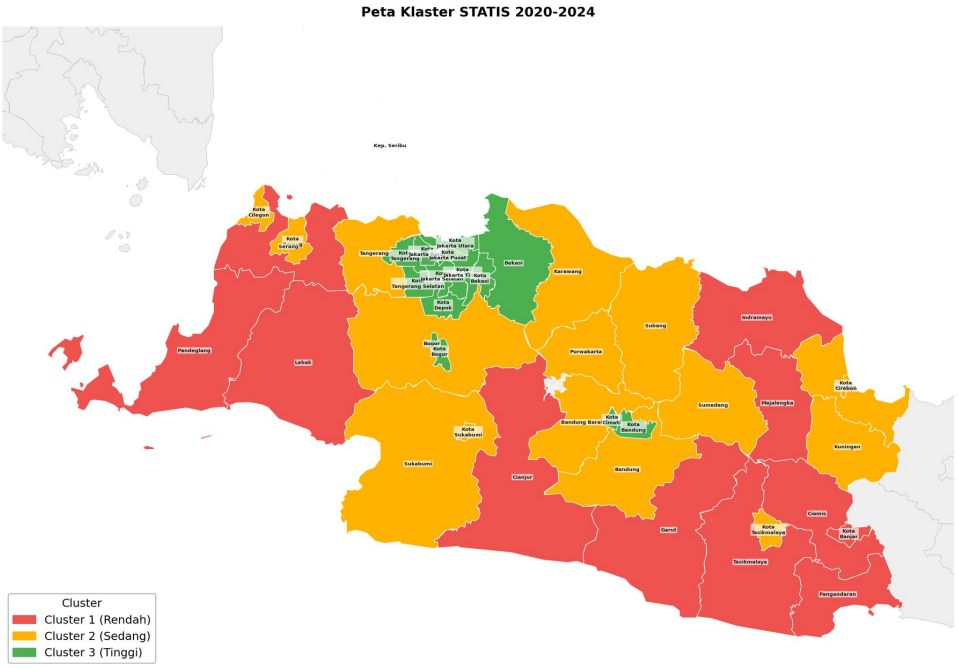
Dimensi	Eigenvalue	Varians (%)	Kumulatif (%)
Dim 1	6,6934	60,8500	60,8500
Dim 2	1,2132	11,0300	71,8800

Berdasarkan Gambar 4.15 dan Tabel 4.6, dua dimensi pertama mampu menjelaskan $71,88\%$ kumulatif variansi total. Secara spesifik, Dimensi 1 menjelaskan $60,85\%$ dan Dimensi 2 menjelaskan $11,03\%$. Nilai ini telah melampaui ambang batas 70% yang lazim digunakan dalam analisis reduksi dimensi, sehingga representasi dua dimensi dianggap sudah cukup informatif.

Tampak pada grafik bahwa terjadi "patahan" (*elbow*) yang jelas setelah Dimensi 2, di mana peningkatan variansi yang dijelaskan oleh dimensi selanjutnya menjadi sangat kecil. Hal ini memvalidasi keputusan untuk mereduksi data menjadi dua dimensi, yaitu menjadi dua komponen (kompromi) utama dalam seluruh analisis berikutnya.

4.4.2 Peta Kompromi (Skor Objek)

Gambar 4.16 menampilkan posisi 41 kabupaten/kota pada ruang dua dimensi kompromi. Posisi ini merupakan representasi "rata-rata tertimbang" dari kondisi tiap wilayah selama 5 tahun pengamatan.

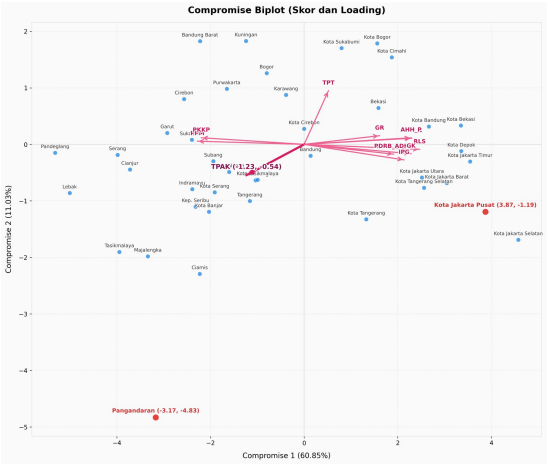


Gambar 4.16: Peta Skor Kompromi 41 Kabupaten/Kota (2020 hingga 2024)

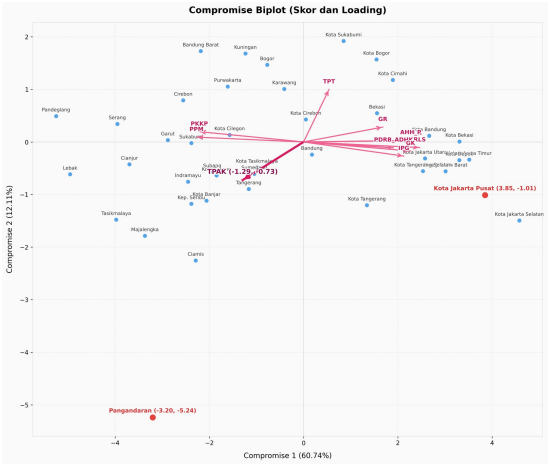
Dari Gambar 4.16, terlihat adanya pola pengelompokan yang jelas. Wilayah-wilayah DKI Jakarta (Jakarta Pusat, Jakarta Selatan, dll.) secara konsisten berada jauh di sisi kanan sumbu Dimensi 1, yang merepresentasikan tingginya PDRB dan kesejahteraan umum. Sebaliknya, wilayah-wilayah seperti Kabupaten Lebak, Pandeglang, dan Garut berada di sisi sebaliknya, yang mencerminkan masih tingginya tingkat kemiskinan dan rendahnya kapasitas ekonomi relatif. Pola ini mengonfirmasikan bahwa Dimensi 1 menangkap variansi utama kemajuan wilayah.

4.4.3 Biplot Kompromi (Skor + Loading)

Untuk mendapatkan pemahaman yang lebih menyeluruh mengenai hubungan antara wilayah dan indikator, disajikan biplot kompromi dari kedua skenario. Gambar 4.17 dan 4.18 mengintegrasikan skor objek ($\mathbf{F}_c$) dan loading indikator ($\mathbf{G}_c$) dalam satu bidang.



Gambar 4.17: Biplot Kompromi Skenario 1 (Host = Wilayah)



Gambar 4.18: Biplot Kompromi Skenario 2 (Host = Indikator)

Catatan visualisasi: Untuk keperluan keterbacaan gambar Biplot yang disajikan pada Gambar 4.17 dan Gambar 4.18, panjang panah indikator (loading) telah disesuaikan secara representasional mengikuti rekomendasi **?**. Secara praktis, setiap koordinat loading pada komponen ke-ℓ dikalikan dengan nilai singular $\sigma_\ell = \sqrt{\lambda_\ell}$ sehingga panjang panah menjadi sepadan (commensurable) dengan variansi skor pada dimensi yang sama. Penyesuaian ini bersifat visual semata — nilai skor kompromi, nilai eigen, serta hasil uji statistik tidak berubah — dan skrip yang menghasilkan gambar ini menerapkan transformasi tersebut hanya pada tahap plotting.

Interpretasi biplot ini dapat dilakukan dengan melihat arah dan panjang vektor indikator serta posisi wilayah:

1. **Dimensi 1:** Menjelaskan 60,85% variansi. Berdasarkan nilai loading pada Tabel 4.9 dan Tabel 4.10, indikator dengan loading positif besar pada Dimensi 1 mencirikan sumbu ini sebagai representasi kemajuan pembangunan secara umum. Indikator dengan loading positif terkuat adalah Rata-rata Lama Sekolah (RLS, $0{,}9538$), Angka Harapan Hidup Laki-laki (AHH_L, $0{,}8891$), Angka Harapan Hidup Perempuan (AHH_P, $0{,}8831$), Garis Kemiskinan (GK, $0{,}8830$), Indeks Pemberdayaan Gender (IPG, $0{,}8248$), PDRB ADHK ($0{,}7390$), dan Gini Ratio ($0{,}6229$). Sebaliknya, Persentase Penduduk Miskin (PPM, $-0{,}8816$) dan PKKP ($-0{,}8497$) memiliki loading negatif yang kuat. Dimensi 1 diinterpretasikan sebagai **"Taraf Kemajuan Pembangunan Manusia dan Ekonomi"**: wilayah dengan skor PC1 tinggi unggul pada capaian pendidikan, kesehatan, dan produktivitas ekonomi, sekaligus memiliki angka kemiskinan yang rendah.

2. **Dimensi 2:** Menjelaskan 11,03% variansi. Indikator dengan loading dominan

pada Dimensi 2 adalah Tingkat Pengangguran Terbuka (TPT, $+0{,}8620$), dengan kontribusi negatif moderat dari Tingkat Partisipasi Angkatan Kerja (TPAK, $-0{,}4946$). Dimensi 2 diinterpretasikan sebagai **"Tekanan Pasar Tenaga Kerja"**: skor PC2 yang tinggi menandakan wilayah dengan pengangguran terbuka tinggi dan partisipasi kerja yang lebih rendah, sedangkan skor PC2 yang sangat negatif khas untuk wilayah agraris atau berbasis sektor informal di mana hampir seluruh angkatan kerja sudah terserap.

Koordinat numerik dari skor kompromi dariseluruh 41 kabupaten/kota pada ruang kompromi disajikan pada Tabel 4.7 dan Tabel 4.8 berikut.

Tabel 4.7: Koordinat Skor Kompromi (scenario1)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
[1]	-2,3219	-1,1030	-2,3219	-1,1030
	4,5753	-1,6893	4,5753	-1,6893
	3,5454	-0,3048	3,5454	-0,3048
	3,8726	-1,1918	3,8726	-1,1918
	3,0485	-0,6863	3,0485	-0,6863
	2,5146	-0,5856	2,5146	-0,5856
	-0,8017	1,2607	-0,8017	1,2607
	-2,4008	0,0804	-2,4008	0,0804
	-3,7243	-0,4450	-3,7243	-0,4450
	0,1358	-0,2011	0,1358	-0,2011
	-2,9254	0,2024	-2,9254	0,2024
	-3,9480	-1,9026	-3,9480	-1,9026
	-2,2314	-2,2905	-2,2314	-2,2905
	-1,2415	1,8291	-1,2415	1,8291
	-2,5676	0,8021	-2,5676	0,8021
	-3,3402	-1,9813	-3,3402	-1,9813
	-1,0382	-0,6354	-1,0382	-0,6354
	-2,3926	-0,7923	-2,3926	-0,7923
	-1,9429	-0,2986	-1,9429	-0,2986
	-1,6531	0,9821	-1,6531	0,9821
	-0,3873	0,8745	-0,3873	0,8745
	1,5854	0,6456	1,5854	0,6456
	-2,2252	1,8258	-2,2252	1,8258
	-3,1715	-4,8306	-3,1715	-4,8306
	1,5613	1,7859	1,5613	1,7859
	0,7966	1,7032	0,7966	1,7032
	2,6632	0,3163	2,6632	0,3163
	$< 0,001$	0,2750	$< 0,001$	0,2750
	3,3477	0,3331	3,3477	0,3331
	3,3564	-0,1203	3,3564	-0,1203

Tabel 4.8: Koordinat Skor Kompromi (scenario2)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
[1]	2,3816	-1,1762	-2,3816	-1,1762
	-4,5772	-1,4937	4,5772	-1,4937
	-3,5148	-0,3344	3,5148	-0,3344
	-3,8494	-1,0104	3,8494	-1,0104
	-3,0121	-0,5570	3,0121	-0,5570
	-2,5775	-0,3136	2,5775	-0,3136
	0,7729	1,4663	-0,7729	1,4663
	2,3818	-0,0213	-2,3818	-0,0213
	3,6949	-0,4256	-3,6949	-0,4256
	-0,1756	-0,2382	0,1756	-0,2382
	2,8810	0,0361	-2,8810	0,0361
	3,9765	-1,4783	-3,9765	-1,4783
	2,2885	-2,2533	-2,2885	-2,2533
	1,2332	1,6819	-1,2332	1,6819
	2,5551	0,7920	-2,5551	0,7920
	3,3673	-1,7852	-3,3673	-1,7852
	1,0448	-0,6059	-1,0448	-0,6059
	2,4535	-0,7554	-2,4535	-0,7554
	1,9378	-0,5705	-1,9378	-0,5705
	1,6094	1,0552	-1,6094	1,0552
	0,4096	1,0082	-0,4096	1,0082
	-1,5566	0,5465	1,5566	0,5465
	2,1812	1,7283	-2,1812	1,7283
	3,2029	-5,2378	-3,2029	-5,2378
	-1,5474	1,5695	1,5474	1,5695
	-0,8481	1,9201	0,8481	1,9201
	-2,6632	0,1180	2,6632	0,1180
	-0,0478	0,4286	0,0478	0,4286
	-3,3064	0,0100	3,3064	0,0100
	-3,3049	-0,3471	3,3049	-0,3471

Skor positif pada Dimensi 1 menunjukkan wilayah yang secara relatif lebih maju, sedangkan skor negatif menunjukkan wilayah yang tertinggal (berdasarkan arah loading pada Tabel 4.9). Pada Dimensi 2, skor negatif ekstrem seperti yang dimiliki Kabupaten Pangandaran (skor intra PC2 hingga $-4{,}76$, Tabel 4.19) yang mencerminkan wilayah dengan TPAK sangat tinggi dan TPT sangat rendah, khas wilayah pertanian dan ekonomi informal. Sebaliknya, skor PC2 yang positif seperti pada Kabupaten Kuningan, mencerminkan tekanan pengangguran terbuka yang lebih besar, umum ditemui pada wilayah semi-urban yang pertumbuhan angkatan kerjanya melampaui kapasitas serapan sektor formal.

Tabel 4.9 dan Tabel 4.10 menyajikan nilai loading ($\mathbf{G}_c$) masing-masing indikator secara numerik untuk setiap skenario.

Tabel 4.9: Loadings Kompromi (scenario1)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
IPG	0,8248	-0,2499	2,1340	-0,2753
PPM	-0,8816	0,0509	-2,2809	0,0560
PDRB_ADHK	0,7390	-0,1576	1,9120	-0,1736
RLS	0,9538	-0,0801	2,4677	-0,0883
AHH_L	0,8891	0,0982	2,3003	0,1081
AHH_P	0,8831	0,1055	2,2847	0,1162
GK	0,8830	-0,1500	2,2846	-0,1653
PKKP	-0,8497	0,1062	-2,1984	0,1169
TPT	0,2007	0,8620	0,5193	0,9495
TPAK	-0,4764	-0,4946	-1,2324	-0,5448
GR	0,6229	0,1391	1,6115	0,1532

Tabel 4.10: Loadings Kompromi (scenario2)

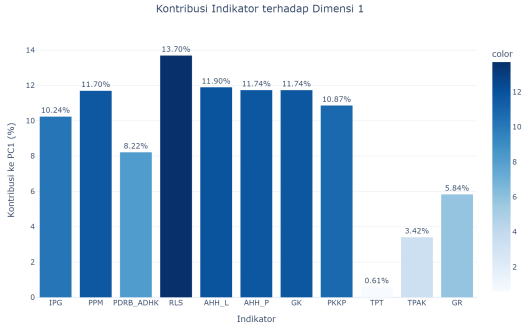
Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
IPG	-0,8222	-0,2330	2,1251	-0,2689
PPM	0,8789	0,0795	-2,2719	0,0917
PDRB_ADHK	-0,7381	-0,0973	1,9079	-0,1123
RLS	-0,9528	-0,0922	2,4629	-0,1064
AHH_L	-0,8865	0,0217	2,2915	0,0251
AHH_P	-0,8795	0,0261	2,2732	0,0301
GK	-0,8778	-0,1488	2,2690	-0,1717
PKKP	0,8560	0,1692	-2,2125	0,1953
TPT	-0,2087	0,8643	0,5396	0,9976
TPAK	0,5005	-0,6283	-1,2938	-0,7252
GR	-0,6505	0,2449	1,6815	0,2827

Loading yang lebih besar menunjukkan bahwa indikator tersebut memiliki kontribusi

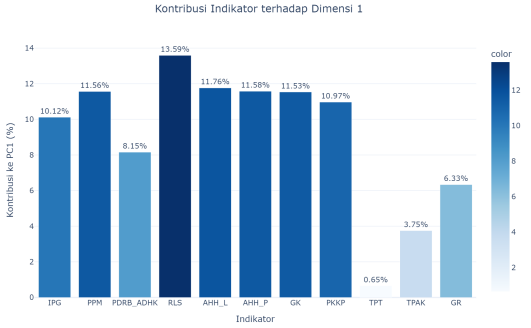
yang lebih kuat dalam menentukan posisi wilayah pada dimensi tersebut. Misalnya, PDRB ADHK memiliki loading yang sangat tinggi pada Dimensi 1, menegaskan perannya sebagai indikator utama dalam membedakan tingkat kesejahteraan ekonomi antar-wilayah.

4.4.4 Kontribusi dan Kualitas Representasi Indikator

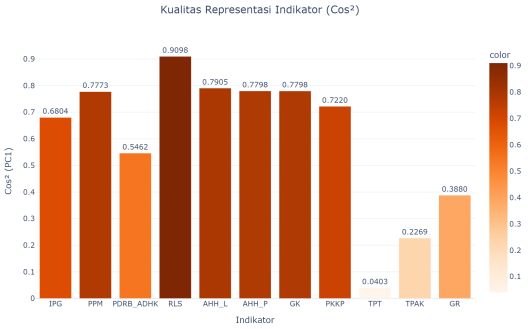
Gambar 4.19–4.22 secara berturut-turut menyajikan kontribusi relatif setiap indikator terhadap Dimensi 1 dan kualitas representasinya ($\cos^2$) untuk masing-masing skenario.



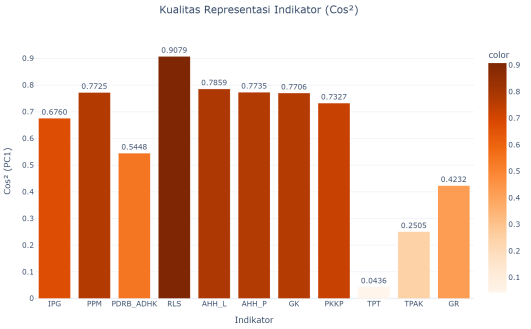
Gambar 4.19: Kontribusi Indikator Dim 1 – Skenario 1



Gambar 4.20: Kontribusi Indikator Dim 1 – Skenario 2



Gambar 4.21: Kualitas Representasi ($\cos^2$) – Skenario 1



Gambar 4.22: Kualitas Representasi ($\cos^2$) – Skenario 2

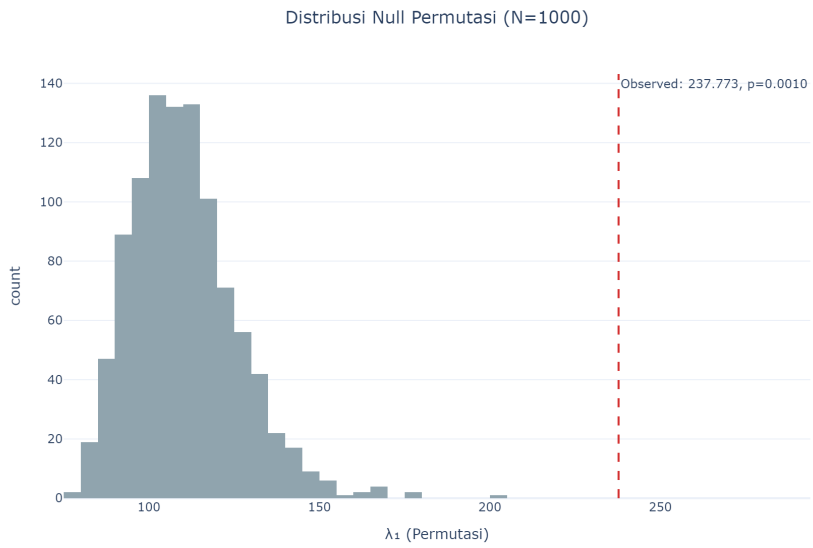
Dari perbandingan kedua skenario, terlihat bahwa Skenario 1 lebih menekankan separasi wilayah (loading indikator ekonomi mendominasi Dimensi 1), sedangkan Skenario 2 lebih menonjolkan hubungan antar-indikator sosial. Kedua skenario menghasilkan informasi yang saling melengkapi.

4.5 Uji Stabilitas Struktur Kompromi (Permutation Test)

Untuk memvalidasi bahwa struktur kompromi yang diperoleh bukan terbentuk secara kebetulan dari data, dilakukan uji permutasi sebanyak $B = 1000$ iterasi, sesuai dengan prosedur yang telah diilustrasikan pada Subbab 3.7.1 (Bab 3) dan Persamaan 2.49 (Bab 2), dengan statistik θ_1 dari matriks $\mathbf{H}$.

4.5.1 Prosedur dan Hasil Uji Permutasi

Pada setiap iterasi, entri-entri di dalam masing-masing kolom (indikator) dari matriks data $\mathbf{X}_t$ diacak secara independen untuk setiap tahun (permutasi per kolom) sebagaimana direkomendasikan oleh Abdi *et al.* (2012), guna menghancurkan korelasi antar-indikator sekaligus mempertahankan sifat normalisasi asli (skala Z-score) dari masing-masing kolom. Setelah pengacakan kolom tersebut, dihitung nilai eigen terbesar $\theta_1^{(b)}$ dari matriks interstruktur $\mathbf{H}$ yang baru terbentuk. Distribusi dari 1000 nilai $\theta_1^{(b)}$ ini membentuk distribusi null yang dibandingkan dengan nilai observasi θ_1^{obs}, sebagaimana divisualisasikan pada Gambar 4.23.



Gambar 4.23: Distribusi Null Uji Permutasi vs. Nilai Eigen Observasi (λ_1^{obs})

Hasil pengujian yang divisualisasikan pada Gambar 4.23 menunjukkan bahwa nilai $\lambda_1^{obs} = 6,6934$ jauh melampaui seluruh nilai distribusi null. Secara formal, p-value $= 0,0010$ yang jauh lebih kecil dari taraf signifikansi $\alpha = 0{,}05$.

Tabel 4.11: Rangkuman Hasil Uji Permutasi

Parameter	**Nilai**
Jumlah Permutasi (B)	1000
λ_1^{obs} (Nilai Eigen Observasi)	$6,6934$
p-value	0,0010
Taraf Signifikansi (α)	0,05
Keputusan	Tolak H_0
Interpretasi	Struktur Signifikan (Stabil)

4.5.2 Interpretasi

Penolakan hipotesis nol H_0 pada Tabel 4.11 berarti: struktur kompromi yang dihasilkan metode STATIS **secara statistik signifikan** dan bukan terbentuk secara kebetulan. Dengan kata lain, terdapat struktur multivariat yang nyata dan stabil yang mengatur hubungan antar-wilayah di Provinsi Banten, DKI Jakarta, dan Jawa Barat selama periode 2020 hingga 2024. Hasil ini menjadi landasan yang kuat untuk melanjutkan interpretasi biplot dan analisis trajektori.

4.5.3 Analisis Vektor Struktur ($\tilde{\boldsymbol{\beta}}$) dan Dominansi Interstruktur

Mengacu pada model probabilistik yang dikembangkan oleh **?** dan dirangkum kembali dalam **?** (Subbab 2.11.7), struktur bersama derajat-1 diasumsikan berlaku apabila matriks interstruktur $\mathbf{H}$ dapat diaproksimasi secara memadai oleh model rank-1:

$$\mathbf{H} \approx \lambda \boldsymbol{\alpha}\boldsymbol{\alpha}^T,$$

dengan estimator vektor struktur $\tilde{\boldsymbol{\beta}} = \lambda_1 \boldsymbol{\alpha}_1$ (Persamaan 2.51). Pada penelitian ini, $\lambda_1 = \theta_1 = 6,6934$ adalah nilai eigen pertama matriks $\mathbf{H}$ (sama dengan statistik observasi pada uji permutasi), dan $\boldsymbol{\alpha}_1 = (u_{11}, u_{12}, \ldots, u_{1K})^T$ adalah vektor eigen pertama yang dinormalisasi menjadi $\boldsymbol{\alpha}$.

Komponen Vektor Struktur $\tilde{\boldsymbol{\beta}}$

Komponen $\tilde{\beta}_k = \lambda_1 \cdot u_{1k}$ (di mana u_{1k} adalah elemen ke-k dari vektor eigen pertama $\mathbf{H}$ *sebelum* normalisasi) merupakan estimator dari "kontribusi terbobot" setiap situasi waktu terhadap struktur bersama. Tabel 4.12 menyajikan hasil komputasi ini.

Tabel 4.12: Komponen Vektor Struktur $\tilde{\boldsymbol{\beta}}$ per Situasi Waktu

Tahun (k)	$\tilde{\beta}_k = \lambda_1 u_{1k}$
2020	103,0345
2021	102,9818
2022	106,8355
2023	110,3180
2024	108,3078

Nilai $\tilde{\beta}_k$ yang besar pada situasi ke-k menunjukkan bahwa konfigurasi antar-wilayah pada tahun tersebut memberikan kontribusi yang dominan dalam membentuk struktur bersama. Nilai yang kecil (relatif) mengindikasikan bahwa tahun tersebut memiliki deviasi yang lebih besar dari pola struktur konsensus.

Validasi Dominansi: Inertia Dimensi Pertama dan Sum of Squares Residual

Validitas pendekatan rank-1 dinilai melalui dua kuantitas (Persamaan 2.54 dan 2.52):

1. **Inertia Dimensi Pertama Interstruktur** ($\mathrm{Inertia}_1$): Proporsi total nilai eigen matriks $\mathbf{H}$ yang dijelaskan oleh dimensi pertama. Nilai yang tinggi (mendekati 1) mengonfirmasi bahwa satu komponen dominan cukup untuk merangkum keseluruhan informasi interstruktur.

2. **Sum of Squares Residual** (V): Besaran $V = \|\mathbf{H}\|_F^2 - \lambda_1^2$ mengukur varians interstruktur yang *tidak* dapat dijelaskan oleh model rank-1. Nilai V yang kecil relatif terhadap $\|\mathbf{H}\|_F^2$ mengonfirmasi keselarasan model.

Tabel 4.13: Diagnostik Dominansi Model Rank-1 (Areia *et al.*, 2008)

Kuantitas	**Nilai**
λ_1 (Nilai Eigen Dominan)	237,7726
$\|\mathbf{H}\|_F^2$ (Frobenius^2)	56548,0585
V (SS Residual)	12,2276
$V/\|\mathbf{H}\|_F^2$ (Rasio Sisa)	0,0002
$\mathrm{Inertia}_1$ (Dominansi %)	97,52%
λ_1/λ_2 (Rasio Kegentingan)	79,5619

Berdasarkan Tabel 4.13, nilai $\mathrm{Inertia}_1$ yang mendekati 1,00 mengonfirmasi secara kuantitatif bahwa struktur bersama derajat-1 yang diasumsikan dalam model **?** terpenuhi dengan baik pada data penelitian ini. Dengan demikian, estimasi $\tilde{\boldsymbol{\beta}}$ dan $\boldsymbol{\alpha}$ yang diperoleh memiliki validitas statistik yang memadai.

Analisis Transversal: Perbandingan Vektor Struktur Antar-Provinsi

Mengacu pada kerangka Analisis Transversal dalam **?**, data penelitian dipartisi menjadi tiga seri studi yang berkorespondensi dengan tiga provinsi yang diamati: Banten (8 wilayah), DKI Jakarta (6 wilayah), dan Jawa Barat (27 wilayah). Untuk masing-masing provinsi g ($g = 1, 2, 3$), matriks interstruktur $\mathbf{H}_g$ dihitung menggunakan hanya wilayah-wilayah yang termasuk dalam provinsi tersebut, dan vektor struktur $\tilde{\boldsymbol{\beta}}_g = \lambda_{1g}\boldsymbol{\alpha}_{1g}$ diestimasi secara independen.

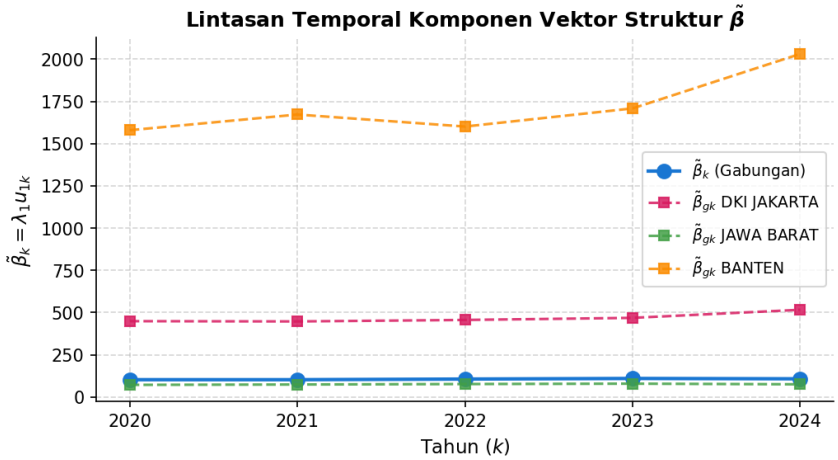
Tabel 4.14: Komponen Vektor Struktur $\tilde{\beta}_{gk}$ per Provinsi (Analisis Transversal)

Tahun (k)	**DKI JAKARTA**	**JAWA BARAT**	**BANTEN**
2020	449,3325	72,5113	1579,2734
2021	447,8066	74,5115	1671,9900
2022	456,5275	77,2854	1600,9055
2023	468,8870	79,5852	1708,3063
2024	516,6398	75,6554	2030,7593

Tabel 4.14 menyajikan komponen $\tilde{\beta}_{gk}$ untuk masing-masing provinsi g dan tahun k. Perbedaan pola komponen antar-provinsi mencerminkan heterogenitas respons temporal terhadap perubahan dari masing-masing kelompok wilayah. Ketiga provinsi menunjukkan heterogenitas yang signifikan: **DKI Jakarta** mencatat kenaikan konsisten dari $449{,}33$ (2020) ke $516{,}64$ (2024), dengan akselerasi terbesar $+47{,}75$ poin ($+10{,}2\%$) pada transisi 2023–2024, mencerminkan pemulihan ekonomi berbasis jasa yang kuat. **Jawa Barat** menunjukkan pola paling stabil (rentang $72{,}51$–$79{,}59$) namun mengalami penurunan ringan pada 2024 ($75{,}66$), mengindikasikan perlambatan struktural di akhir periode. **Banten** memperlihatkan fluktuasi terbesar (rentang $1.579{,}27$–$2.030{,}76$): sempat turun pada 2021–2022, kemudian melonjak drastis $+322{,}45$ poin ($+18{,}9\%$) pada 2023–2024 yang mencerminkan dinamika struktural yang paling tidak stabil, kemungkinan didorong oleh pergeseran komposisi ekonomi manufaktur dan jasa di kawasan Tangerang Raya.

Analisis Longitudinal: Progresi Temporal Komponen Vektor Struktur

Analisis Longitudinal (**??**) mengevaluasi apakah komponen $\tilde{\beta}_k$ menunjukkan tren yang sistematis seiring berjalannya waktu. Gambar 4.24 menampilkan nilai $\tilde{\beta}_k$ (untuk seri gabungan seluruh wilayah) pada sumbu-y terhadap tahun pengamatan pada sumbu-x.



Gambar 4.24: Lintasan Temporal Komponen Vektor Struktur $\tilde{\beta}_k$ (2020 hingga 2024)

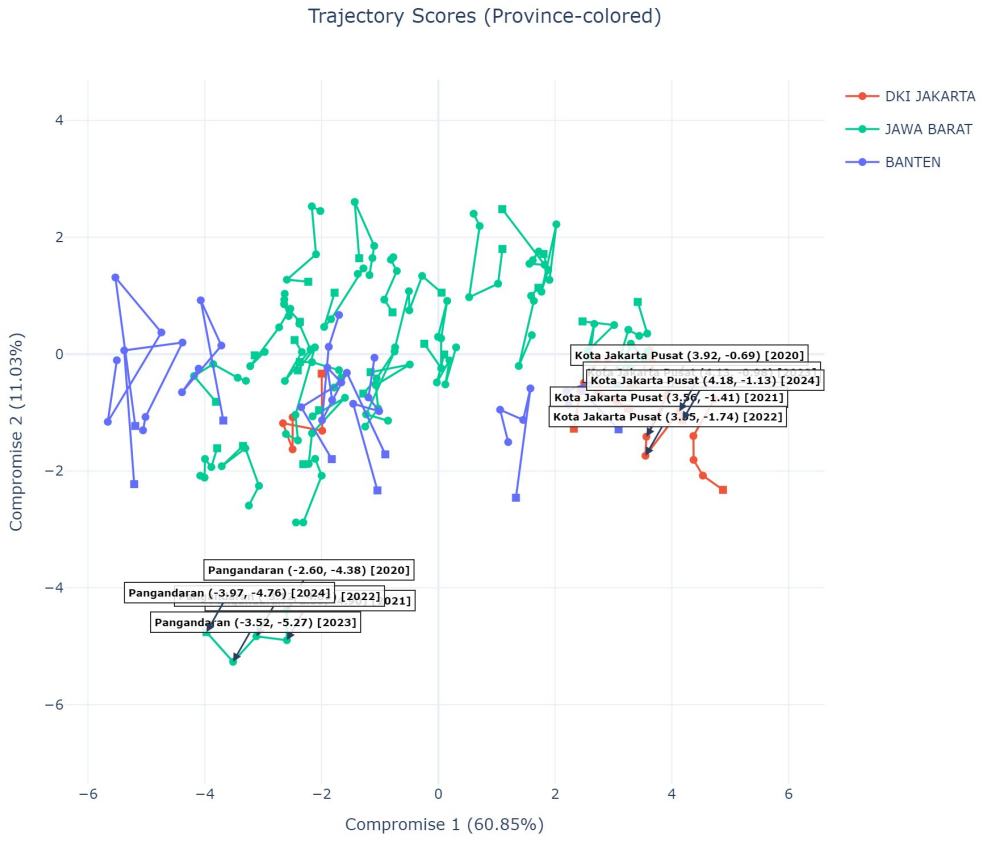
Nilai $\tilde{\beta}_k$ pada Tabel 4.12 mencerminkan bobot temporal terstruktur dari masing-masing tahun dalam membentuk konsensus inter-struktur. Komponen $\tilde{\beta}_k$ menampilkan tiga fase temporal yang berbeda: (i) **Stagnasi pandemi (2020–2021):** nilai $\tilde{\beta}_{2020} = 103{,}03$ dan $\tilde{\beta}_{2021} = 102{,}98$ hampir identik (selisih hanya $0{,}05$ poin), mengindikasikan bahwa pandemi tidak menyebabkan gangguan struktural yang berarti pada hierarki relatif antar-wilayah, meskipun nilai absolut indikator mungkin mengalami kontraksi, tatanan inter-spasial tetap terjaga; (ii) **Pemulihan progresif (2022–2023):** kenaikan bertahap ke $\tilde{\beta}_{2022} = 106{,}84$ dan puncak $\tilde{\beta}_{2023} = 110{,}32$ mengonfirmasi pemulihan struktural yang nyata pasca-pandemi; (iii) **Stabilisasi (2024):** moderasi ringan ke $\tilde{\beta}_{2024} = 108{,}31$ mengindikasikan konsolidasi struktur inter-relasi antar-wilayah, bukan kemunduran.

4.6 Analisis Dinamika Spasio-Temporal (Trajektori)

Analisis trajektori memanfaatkan proyeksi data setiap tahun ke dalam ruang kompromi yang telah ditetapkan. Berbeda dengan peta kompromi yang hanya menampilkan posisi "rata-rata", analisis trajektori memperlihatkan *lintasan pergeseran* setiap wilayah dari tahun ke tahun, sehingga dinamika temporalnya dapat dipahami secara komprehensif.

4.6.1 Gambaran Umum Trajektori 2020 hingga 2024

Gambar 4.25 menampilkan keseluruhan lintasan pergeseran 41 kabupaten/kota pada bidang kompromi selama 2020 hingga 2024.



Gambar 4.25: Trajektori Pergeseran 41 Kabupaten/Kota pada Ruang Kompromi (2020 hingga 2024)

Secara umum, terdapat tiga pola utama trajektori yang dapat diidentifikasi dari Gambar 4.25:

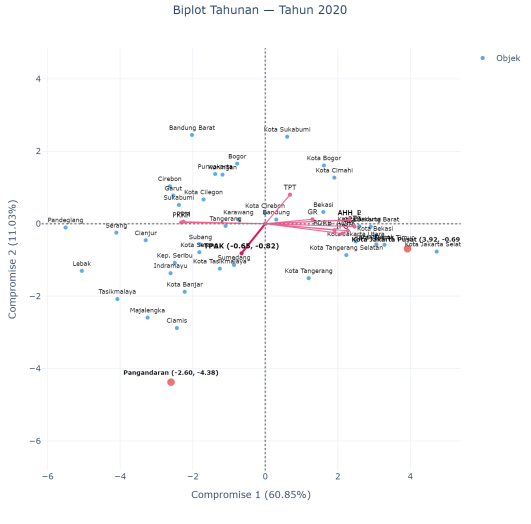
1. **Pola Pemulihan Berbentuk V (*V-Shape Rebound*):** Wilayah metropolitan berbasis jasa seperti kota-kota di DKI Jakarta menunjukkan penurunan posisi pada 2020 hingga 2021 (akibat kontraksi pandemi) namun berhasil kembali ke posisi semula atau bahkan lebih tinggi pada 2022 hingga 2024.

2. **Pola Progresif Bertahap (*Monotone Improvement*):** Sejumlah wilayah menunjukkan peningkatan posisi yang konsisten dari tahun ke tahun tanpa penurunan, mencerminkan pertumbuhan yang berkelanjutan.

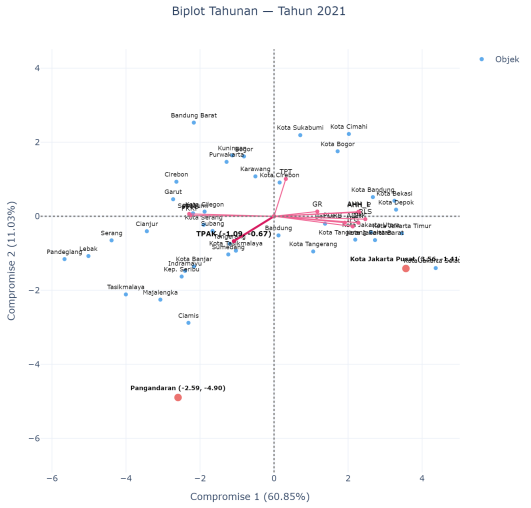
3. **Pola Stagnasi (*Inertia*):** Wilayah-wilayah tertinggal menunjukkan lintasan yang sangat pendek dan hampir stagnan, mengindikasikan bahwa perubahan makroekonomi tidak banyak mengubah posisi relatif mereka.

4.6.2 Dinamika Biplot Tahunan

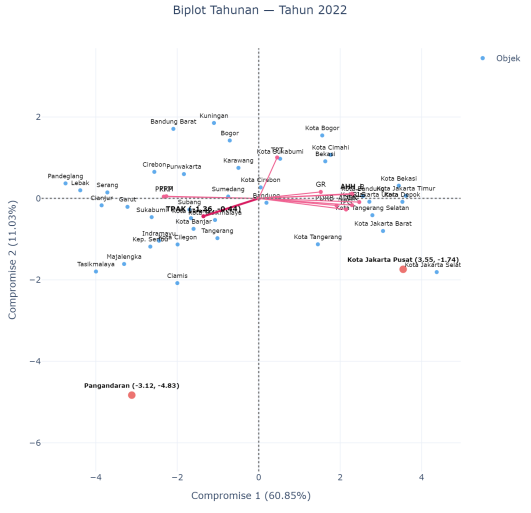
Untuk memahami posisi spesifik setiap wilayah dan indikator pada tiap tahun, Gambar 4.26 hingga 4.30 menyajikan biplot tahunan secara individual.



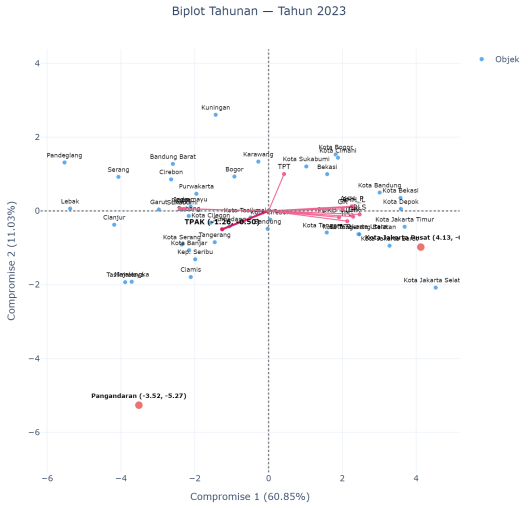
Gambar 4.26: Biplot Tahunan 2020 (Masa Awal Pandemi)



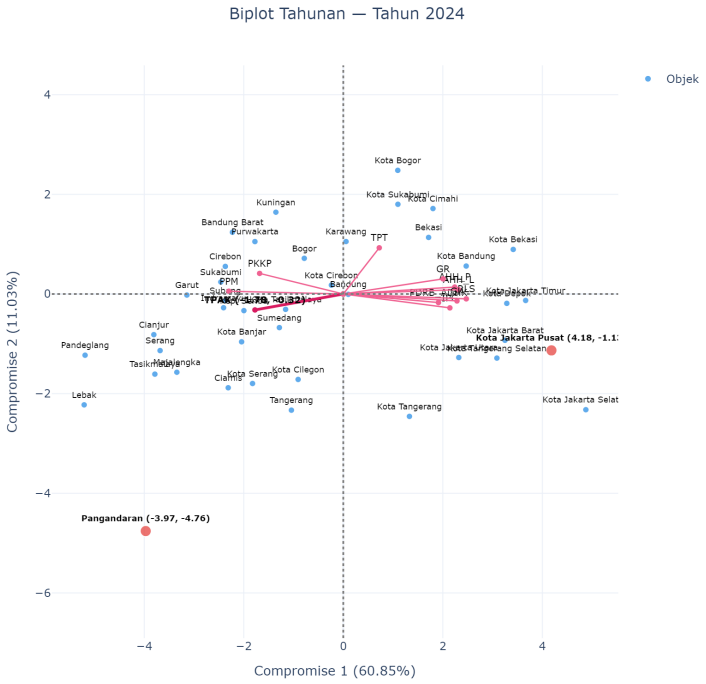
Gambar 4.27: Biplot Tahunan 2021



Gambar 4.28: Biplot Tahunan 2022 (Awal Masa Pemulihan)



Gambar 4.29: Biplot Tahunan 2023



Gambar 4.30: Biplot Tahunan 2024

Membandingkan biplot pada Gambar 4.26 dan 4.30, terlihat pergeseran struktural yang signifikan pada beberapa wilayah antara tahun 2020 dan 2024. Berdasarkan koordinat skor intra pada Tabel 4.15 dan 4.19, pergeseran Dimensi 1 (PC1) terbesar ke arah positif dialami oleh **Kota Tangerang Selatan** ($+0{,}85$ poin: dari $2{,}23$ ke $3{,}09$), diikuti **Kota Bekasi** ($+0{,}39$) dan **Kota Jakarta Pusat** ($+0{,}26$), mengonfirmasi pemulihan kuat pada kota-kota metropolitan berbasis jasa. Sebaliknya, pergeseran negatif terbesar dialami oleh **Kabupaten Pangandaran** ($-1{,}37$ poin: dari $-2{,}60$ ke $-3{,}97$), disusul **Kabupaten Garut** ($-0{,}61$) dan **Kabupaten Cianjur** ($-0{,}51$), mengindikasikan bahwa kabupaten pedalaman Jawa Barat bagian selatan justru mengalami penurunan posisi relatif selama periode yang sama.

4.6.3 Dinamika Struktur Wilayah Tahunan

analisis trajektori juga memungkinkan untuk mengamati perubahan posisi relatif antar-wilayah pada tiap tahun. Tabel 4.15 dan 4.19 menyajikan skor kompromi intra-struktur untuk masing-masing wilayah pada setiap tahun.

Tabel 4.15: Skor Intra-Struktur Wilayah Tahun 2020 hingga 2024

Tabel 4.16: Skor Intra Tahun 2020 ($\mathbf{F}_{2020}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
[1]	-2,4946	-1,0804	-2,4946	-1,0804
	4,7264	-0,7688	4,7264	-0,7688
	3,2871	-0,5831	3,2871	-0,5831
	3,9200	-0,6921	3,9200	-0,6921
	2,9053	-0,0797	2,9053	-0,0797
	2,4964	-0,4901	2,4964	-0,4901
	-0,7714	1,6599	-0,7714	1,6599
	-2,3806	0,5193	-2,3806	0,5193
	-3,2953	-0,4563	-3,2953	-0,4563
	0,3044	0,1156	0,3044	0,1156
	-2,5349	0,7781	-2,5349	0,7781
	-4,0773	-2,0804	-4,0773	-2,0804
	-2,4376	-2,8807	-2,4376	-2,8807
	-1,1792	1,3542	-1,1792	1,3542
	-2,6304	1,0335	-2,6304	1,0335
	-3,2450	-2,5920	-3,2450	-2,5920
	-0,8621	-1,1387	-0,8621	-1,1387
	-2,6099	-1,3663	-2,6099	-1,3663
	-1,7863	-0,5727	-1,7863	-0,5727
	-1,3807	1,3730	-1,3807	1,3730
	-0,7398	0,1171	-0,7398	0,1171
	1,6014	0,3242	1,6014	0,3242
	-2,0204	2,4503	-2,0204	2,4503
	-2,5982	-4,3771	-2,5982	-4,3771
	1,6180	1,6080	1,6180	1,6080
	0,6049	2,4025	0,6049	2,4025
	2,5924	-0,0698	2,5924	-0,0698
	-0,0055	0,2968	-0,0055	0,2968
	3,0282	-0,3399	3,0282	-0,3399
	3,0639	-0,5731	3,0639	-0,5731
	1,9040	1,2714	1,9040	1,2714
	-1,2520	-1,2404	-1,2520	-1,2404
	-2,2202	-1,8799	-2,2202	-1,8799
	-5,5059	-0,1055	-5,5059	-0,1055
	-5,0571	-1,3031	-5,0571	-1,3031
	-1,0937	-0,0609	-1,0937	-0,0609
	-4,1050	-0,2479	-4,1050	-0,2479
	1,1965	-1,5058	1,1965	-1,5058
	-1,7010	0,6711	-1,7010	0,6711
	-1,8183	-0,7868	-1,8183	-0,7868
	2,2341	-0,8650	2,2341	-0,8650

Tabel 4.17: Skor Intra Tahun 2021 ($\mathbf{F}_{2021}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
[1]	-2,4960	-1,6297	-2,4960	-1,6297
	4,3682	-1,4010	4,3682	-1,4010
	3,4535	-0,4598	3,4535	-0,4598
	3,5633	-1,4125	3,5633	-1,4125
	2,7284	-0,6437	2,7284	-0,6437
	2,6166	-0,4332	2,6166	-0,4332
	-0,8125	1,6170	-0,8125	1,6170
	-2,1895	0,0797	-2,1895	0,0797
	-3,4367	-0,4044	-3,4367	-0,4044
	0,1201	-0,5178	0,1201	-0,5178
	-2,7261	0,4600	-2,7261	0,4600
	-4,0037	-2,1133	-4,0037	-2,1133
	-2,3130	-2,8805	-2,3130	-2,8805
	-1,1283	1,6457	-1,1283	1,6457
	-2,6382	0,9318	-2,6382	0,9318
	-3,0717	-2,2535	-3,0717	-2,2535
	-1,2360	-1,0313	-1,2360	-1,0313
	-2,4043	-1,4763	-2,4043	-1,4763
	-1,6616	-0,3964	-1,6616	-0,3964
	-1,2824	1,4685	-1,2824	1,4685
	-0,5038	1,0774	-0,5038	1,0774
	1,3779	-0,2026	1,3779	-0,2026
	-2,1674	2,5301	-2,1674	2,5301
	-2,5940	-4,8963	-2,5940	-4,8963
	1,7186	1,7562	1,7186	1,7562
	0,7084	2,1920	0,7084	2,1920
	2,6704	0,5184	2,6704	0,5184
	0,1510	0,9113	0,1510	0,9113
	3,2542	0,4183	3,2542	0,4183
	3,2971	0,1791	3,2971	0,1791
	2,0216	2,2224	2,0216	2,2224
	-1,0302	-0,9299	-1,0302	-0,9299
	-2,1637	-1,3541	-2,1637	-1,3541
	-5,6607	-1,1583	-5,6607	-1,1583
	-5,0151	-1,0759	-5,0151	-1,0759
	-1,1965	-0,7427	-1,1965	-0,7427
	-4,3897	-0,6520	-4,3897	-0,6520
	1,0581	-0,9518	1,0581	-0,9518
	-1,8767	0,1254	-1,8767	0,1254
	-1,9002	-0,2303	-1,9002	-0,2303
	2,1946	-0,6324	2,1946	-0,6324

Tabel 4.18: Skor Intra Tahun 2022 ($\mathbf{F}_{2022}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
[1]	-2,6609	-1,1827	-2,6609	-1,1827
	4,3713	-1,8098	4,3713	-1,8098
	3,6141	0,0661	3,6141	0,0661
	3,5474	-1,7398	3,5474	-1,7398
	3,0528	-0,7996	3,0528	-0,7996
	2,7174	-0,0817	2,7174	-0,0817
	-0,7104	1,4232	-0,7104	1,4232
	-2,6279	-0,4591	-2,6279	-0,4591
	-3,8567	-0,1697	-3,8567	-0,1697
	0,1906	-0,1063	0,1906	-0,1063
	-3,2219	-0,2056	-3,2219	-0,2056
	-3,9956	-1,7949	-3,9956	-1,7949
	-1,9979	-2,0803	-1,9979	-2,0803
	-1,0980	1,8524	-1,0980	1,8524
	-2,5623	0,6521	-2,5623	0,6521
	-3,3045	-1,6111	-3,3045	-1,6111
	-0,7491	0,0458	-0,7491	0,0458
	-2,4469	-1,0389	-2,4469	-1,0389
	-1,7012	-0,2735	-1,7012	-0,2735
	-1,8359	0,5985	-1,8359	0,5985
	-0,4971	0,7499	-0,4971	0,7499
	1,6353	0,9123	1,6353	0,9123
	-2,0948	1,7086	-2,0948	1,7086
	-3,1161	-4,8291	-3,1161	-4,8291
	1,5605	1,5472	1,5605	1,5472
	0,5276	0,9738	0,5276	0,9738
	2,5613	0,0584	2,5613	0,0584
	0,0481	0,2711	0,0481	0,2711
	3,4399	0,3121	3,4399	0,3121
	3,5290	-0,0834	3,5290	-0,0834
	1,7658	1,0687	1,7658	1,0687
	-1,0720	-0,5302	-1,0720	-0,5302
	-1,5992	-0,7466	-1,5992	-0,7466
	-4,7428	0,3704	-4,7428	0,3704
	-4,3814	0,1989	-4,3814	0,1989
	-1,0133	-0,9765	-1,0133	-0,9765
	-3,7159	0,1468	-3,7159	0,1468
	1,4533	-1,1260	1,4533	-1,1260
	-1,9912	-1,1310	-1,9912	-1,1310
	-1,6623	-0,4855	-1,6623	-0,4855
	2,7917	-0,4120	2,7917	-0,4120

Tabel 4.19: Skor Intra-Struktur Wilayah Tahun 2023 hingga 2024

Tabel 4.20: Skor Intra Tahun 2023 ($\mathbf{F}_{2023}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
[1]	-1,9880	-1,3104	-1,9880	-1,3104
	4,5312	-2,0797	4,5312	-2,0797
	3,6892	-0,4308	3,6892	-0,4308
	4,1273	-0,9805	4,1273	-0,9805
	3,2798	-0,9439	3,2798	-0,9439
	2,4303	-0,6275	2,4303	-0,6275
	-0,9257	0,9331	-0,9257	0,9331
	-2,3371	0,0355	-2,3371	0,0355
	-4,1835	-0,3752	-4,1835	-0,3752
	-0,0252	-0,4841	-0,0252	-0,4841
	-2,9745	0,0384	-2,9745	0,0384
	-3,8870	-1,9319	-3,8870	-1,9319
	-2,1086	-1,7919	-2,1086	-1,7919
	-1,4326	2,6055	-1,4326	2,6055
	-2,6412	0,8547	-2,6412	0,8547
	-3,7095	-1,9189	-3,7095	-1,9189
	-1,0560	-0,4168	-1,0560	-0,4168
	-2,1127	0,1155	-2,1127	0,1155
	-2,1633	-0,1369	-2,1633	-0,1369
	-1,9555	0,4661	-1,9555	0,4661
	-0,2772	1,3379	-0,2772	1,3379
	1,5891	0,9977	1,5891	0,9977
	-2,5939	1,2744	-2,5939	1,2744
	-3,5152	-5,2657	-3,5152	-5,2657
	1,8203	1,5281	1,8203	1,5281
	1,0232	1,2056	1,0232	1,2056
	3,0113	0,4985	3,0113	0,4985
	0,0484	-0,2400	0,0484	-0,2400
	3,5779	0,3525	3,5779	0,3525
	3,5872	0,0539	3,5872	0,0539
	1,8819	1,4421	1,8819	1,4421
	-0,4887	-0,1768	-0,4887	-0,1768
	-2,1534	-1,0657	-2,1534	-1,0657
	-5,5305	1,3130	-5,5305	1,3130
	-5,3797	0,0638	-5,3797	0,0638
	-1,4583	-0,8489	-1,4583	-0,8489
	-4,0692	0,9221	-4,0692	0,9221
	1,5774	-0,5859	1,5774	-0,5859

Tabel 4.21: Skor Intra Tahun 2024 ($\mathbf{F}_{2024}$)

Kabupaten/Kota	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
[1]	-1,9977	-0,3337	-1,9977	-0,3337
	4,8746	-2,3228	4,8746	-2,3228
	3,6643	-0,1300	3,6643	-0,1300
	4,1829	-1,1321	4,1829	-1,1321
	3,2496	-0,9298	3,2496	-0,9298
	2,3208	-1,2758	2,3208	-1,2758
	-0,7842	0,7156	-0,7842	0,7156
	-2,4619	0,2413	-2,4619	0,2413
	-3,8076	-0,8156	-3,8076	-0,8156
	0,1002	-0,0063	0,1002	-0,0063
	-3,1438	-0,0206	-3,1438	-0,0206
	-3,7870	-1,6095	-3,7870	-1,6095
	-2,3132	-1,8830	-2,3132	-1,8830
	-1,3552	1,6416	-1,3552	1,6416
	-2,3712	0,5531	-2,3712	0,5531
	-3,3454	-1,5704	-3,3454	-1,5704
	-1,2850	-0,6748	-1,2850	-0,6748
	-2,4064	-0,2771	-2,4064	-0,2771
	-2,3731	-0,1345	-2,3731	-0,1345
	-1,7764	1,0518	-1,7764	1,0518
	0,0551	1,0530	0,0551	1,0530
	1,7143	1,1362	1,7143	1,1362
	-2,2283	1,2391	-2,2283	1,2391
	-3,9706	-4,7580	-3,9706	-4,7580
	1,0948	2,4814	1,0948	2,4814
	1,0974	1,7995	1,0974	1,7995
	2,4695	0,5602	2,4695	0,5602
	-0,2397	0,1778	-0,2397	0,1778
	3,4150	0,8933	3,4150	0,8933
	3,2856	-0,1882	3,2856	-0,1882
	1,8021	1,7143	1,8021	1,7143
	-1,1595	-0,3090	-1,1595	-0,3090
	-2,0440	-0,9591	-2,0440	-0,9591
	-5,1898	-1,2292	-5,1898	-1,2292
	-5,2083	-2,2251	-5,2083	-2,2251
	-1,0430	-2,3321	-1,0430	-2,3321
	-3,6820	-1,1360	-3,6820	-1,1360
	1,3292	-2,4577	1,3292	-2,4577

4.6.4 Pergeseran Centroid Tahunan

Selain mengamati lintasan individual setiap wilayah, dinamika kolektif seluruh wilayah dapat dikuantifikasi melalui pergeseran *centroid* tahunan, yaitu posisi rata-rata $c_k = \left(\overline{f_{k,1}},\ \overline{f_{k,2}}\right)$ dari seluruh skor intra $\mathbf{F}_k$ pada tahun k. Jarak *Euclidean* antar-centroid berturutan dihitung menggunakan Persamaan 2.68 (lihat penurunan contoh pada dataset sampel di Subbab 3.7.1.8 Bab 3):

$$D(c_k,\ c_{k+1}) = \sqrt{(\bar{f}_{k,1} - \bar{f}_{k+1,1})^2 + (\bar{f}_{k,2} - \bar{f}_{k+1,2})^2}$$

Nilai ini mengukur seberapa besar posisi "pusat berat" seluruh wilayah bergeser dalam ruang kompromi dari satu tahun ke tahun berikutnya. Hasil lengkap disajikan pada Tabel 4.22 berikut.

Tabel 4.22: Pergeseran Centroid Tahunan — STATIS (Skor Intra $\mathbf{F}_k$)

Tahun	**Centroid PC1**	**Centroid PC2**	$D(c_t, c_{t+1})$
2020	-0,5932	-0,2966	0,0122
2021	-0,5999	-0,2865	0,0715
2022	-0,5329	-0,2614	0,0992
2023	-0,5914	-0,1813	0,2657
2024	-0,5601	-0,4452	–

Berdasarkan Tabel 4.22, pergeseran *centroid* terbesar terjadi pada transisi 2023–2024 dengan $D(c_{2023}, c_{2024}) = 0{,}2657$, yaitu sekitar 22 kali lebih besar dibandingkan transisi terkecil 2020–2021 ($D = 0{,}0122$). Lonjakan ini mengindikasikan adanya dinamika struktural kolektif yang lebih intens menjelang akhir periode pengamatan, kemungkinan mencerminkan percepatan pemulihan ekonomi yang tidak merata pasca-pandemi. Sebaliknya, kecilnya pergeseran pada 2020–2021 menunjukkan bahwa guncangan pandemi bersifat seragam (*uniform shock*) sehingga tidak mengubah posisi relatif antar-wilayah secara signifikan dalam ruang kompromi.

4.6.5 Jarak Pergeseran Per-Entitas Tahunan

Di samping pergeseran centroid kolektif, jarak pergeseran per-entitas mengukur seberapa jauh setiap wilayah atau indikator secara individual bergerak dalam ruang kompromi dari satu tahun ke tahun berikutnya, dihitung menggunakan Persamaan 2.68. Penurunan contoh komputasinya disajikan pada Paragraf 3.7.1.8 Bab 3.

Berdasarkan tabel jarak pergeseran per-entitas (tersedia di *dashboard*), wilayah dengan total jarak pergeseran kumulatif terbesar sepanjang 2020–2024 adalah Kabupaten

Pandeglang ($\sum D = 6{,}641$), Kabupaten Lebak ($4{,}957$), dan Kabupaten Serang ($4{,}486$) — ketiganya merupakan wilayah pedalaman Banten yang berkarakter volatile. Sebaliknya, wilayah dengan lintasan paling stabil adalah Kabupaten Tasikmalaya ($\sum D = 0{,}912$), Kota Cirebon ($1{,}014$), dan Kabupaten Subang ($1{,}037$), yang menunjukkan profil pembangunan yang relatif konsisten sepanjang periode. Pada dimensi indikator, Tingkat Partisipasi Angkatan Kerja (TPAK, $\sum D = 0{,}773$) dan Gini Ratio (GR, $0{,}635$) merupakan indikator dengan pergeseran *loading* terbesar, mencerminkan dinamika distribusi tenaga kerja dan ketimpangan yang fluktuatif; sebaliknya PDRB ADHK ($0{,}006$), RLS ($0{,}020$), dan IPG ($0{,}020$) bersifat sebagai "jangkar" (*anchor*) stabilitas struktural pada sumbu kompromi.

4.6.6 Dinamika Struktur Indikator Tahunan

Selain untuk melihat pergeseran struktur wilayah tahunan, metode STATIS juga memungkinkan analisis terhadap perubahan hubungan antar-indikator itu sendiri pada setiap tahun melalui matriks intra-loading ($\mathbf{G}_k$) dan matriks korelasi terbobot ($\mathbf{S}_k$). Tabel 4.24 hingga 4.29 menyajikan koordinat indikator pada tiap situasi tahunan.

Tabel 4.23: Loading Intra-Struktur Indikator Tahun 2020 hingga 2022

Tabel 4.24: Loading Intra Tahun 2020 ($\mathbf{G}_{2020}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
IPG	0,8206	-0,2478	2,1230	-0,2729
PPM	-0,8716	0,0502	-2,2548	0,0553
PDRB_ADHK	0,7388	-0,1604	1,9113	-0,1766
RLS	0,9515	-0,0720	2,4616	-0,0793
AHH_L	0,8936	0,0974	2,3119	0,1072
AHH_P	0,8982	0,0893	2,3239	0,0984
GK	0,8798	-0,1781	2,2763	-0,1962
PKKP	-0,8958	0,0309	-2,3176	0,0341
TPT	0,2634	0,7288	0,6814	0,8028
TPAK	-0,2525	-0,7401	-0,6534	-0,8151
GR	0,5035	0,1117	1,3026	0,1231

Tabel 4.25: Loading Intra Tahun 2021 ($\mathbf{G}_{2021}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
IPG	0,8216	-0,2493	2,1257	-0,2746
PPM	-0,8859	0,0571	-2,2920	0,0628
PDRB_ADHK	0,7391	-0,1574	1,9122	-0,1734
RLS	0,9534	-0,0714	2,4665	-0,0787
AHH_L	0,8817	0,1121	2,2811	0,1235
AHH_P	0,8902	0,1001	2,3031	0,1103
GK	0,8802	-0,1575	2,2772	-0,1734
PKKP	-0,8768	0,0167	-2,2683	0,0184
TPT	0,1231	0,9153	0,3185	1,0082
TPAK	-0,4197	-0,6099	-1,0857	-0,6718
GR	0,4518	0,1168	1,1690	0,1286

Tabel 4.26: Loading Intra Tahun 2022 ($\mathbf{G}_{2022}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
IPG	0,8293	-0,2469	2,1456	-0,2720
PPM	-0,8764	0,0488	-2,2674	0,0537
PDRB_ADHK	0,7391	-0,1566	1,9122	-0,1725
RLS	0,9546	-0,0809	2,4696	-0,0891
AHH_L	0,8844	0,1068	2,2880	0,1176
AHH_P	0,8898	0,0945	2,3020	0,1041
GK	0,8855	-0,1501	2,2909	-0,1653
PKKP	-0,9002	0,0413	-2,3290	0,0454
TPT	0,1752	0,9133	0,4532	1,0060
TPAK	-0,5242	-0,3971	-1,3563	-0,4374
GR	0,5893	0,1459	1,5245	0,1607

Tabel 4.27: Loading Intra-Struktur Indikator Tahun 2023 hingga 2024

Tabel 4.28: Loading Intra Tahun 2023 ($\mathbf{G}_{2023}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
IPG	0,8246	-0,2522	2,1333	-0,2778
PPM	-0,8852	0,0490	-2,2901	0,0540
PDRB_ADHK	0,7390	-0,1570	1,9118	-0,1729
RLS	0,9544	-0,0866	2,4691	-0,0954
AHH_L	0,8908	0,0955	2,3047	0,1052
AHH_P	0,8730	0,1159	2,2585	0,1276
GK	0,8864	-0,1399	2,2932	-0,1540
PKKP	-0,9286	0,0586	-2,4024	0,0645
TPT	0,1621	0,9065	0,4194	0,9985
TPAK	-0,4860	-0,4521	-1,2573	-0,4979
GR	0,7771	0,0456	2,0105	0,0502

Tabel 4.29: Loading Intra Tahun 2024 ($\mathbf{G}_{2024}$)

Indikator	PC1 (Asli)	PC2 (Asli)	PC1 (Visual)	PC2 (Visual)
IPG	0,8278	-0,2532	2,1416	-0,2789
PPM	-0,8888	0,0496	-2,2994	0,0547
PDRB_ADHK	0,7392	-0,1568	1,9124	-0,1727
RLS	0,9552	-0,0889	2,4713	-0,0979
AHH_L	0,8948	0,0799	2,3150	0,0880
AHH_P	0,8656	0,1265	2,2394	0,1393
GK	0,8830	-0,1267	2,2844	-0,1396
PKKP	-0,6501	0,3753	-1,6819	0,4133
TPT	0,2793	0,8422	0,7227	0,9277
TPAK	-0,6862	-0,2910	-1,7753	-0,3206
GR	0,7751	0,2748	2,0054	0,3026

Stabilitas orientasi indikator dalam tabel di atas mengonfirmasi hasil uji RV yang tinggi.

Indikator IPM dan PDRB secara konsisten memiliki loading positif yang kuat pada dimensi pertama di seluruh tahun, yang menunjukkan bahwa sumbu horizontal kompromi memang merupakan representasi yang valid untuk kemajuan ekonomi dan kualitas manusia secara stabil di seluruh periode pengamatan.

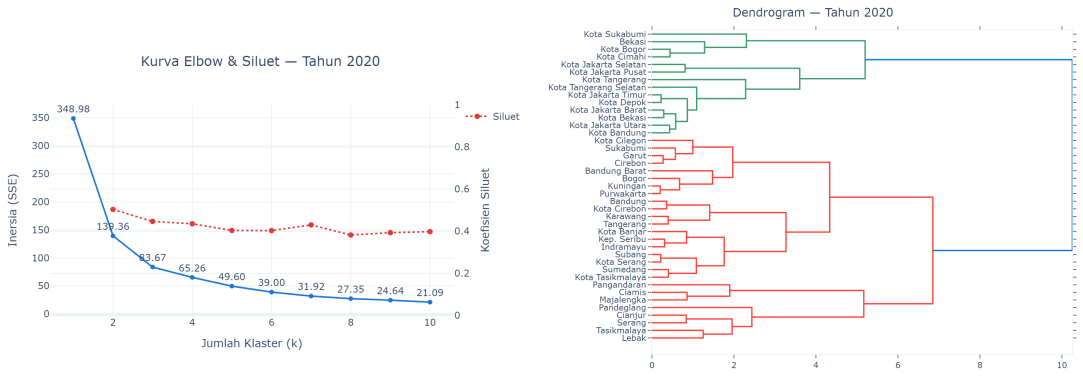
Matriks korelasi terbobot indikator ($\mathbf{S}_k$) yang tersaji pada lampiran (atau file output) memperlihatkan bahwa hubungan inter-indikator tidak mengalami patahan struktural meskipun terjadi pandemi, yang memperkuat validitas penggunaan satu struktur kompromi tunggal untuk keseluruhan periode pengamatan.

4.7 Analisis Klaster Spasio-Temporal

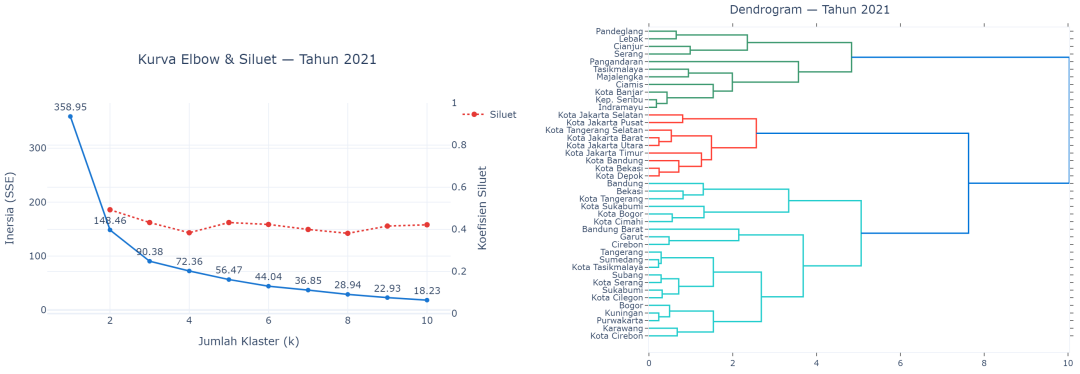
Analisis klaster dilakukan dalam tiga tahap: (1) penentuan jumlah klaster optimal, (2) interpretasi pola pengelompokan dan matriks transisi, serta (3) evaluasi konsistensi klaster terhadap standar kategori IPM UNDP.

4.7.1 Penentuan Jumlah Klaster Optimal

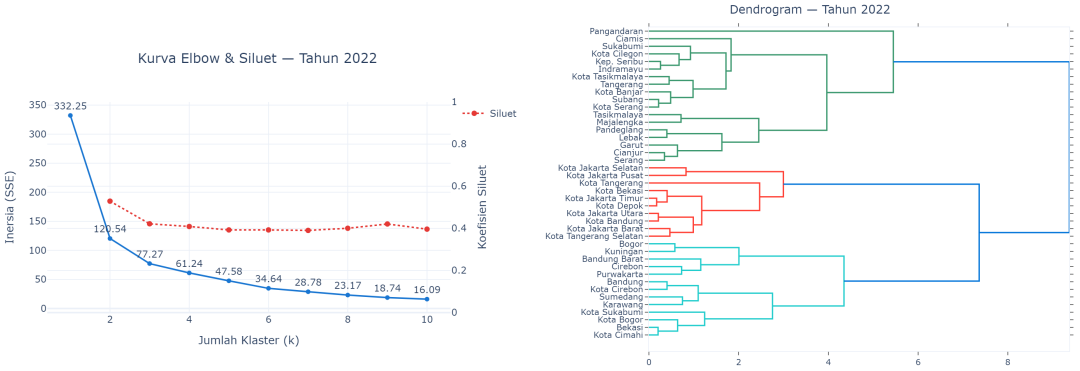
Dua metode digunakan secara komplementer untuk menentukan jumlah klaster k yang optimal: Metode *Elbow* yang mengamati titik patahan kurva inersia (*Within-Klaster Sum of Squares*/SSE) dan *Agglomerative Hierarchical Clustering* (Dendrogram) yang mengamati jarak penggabungan antar-kelompok. Gambar 4.31 hingga Gambar 4.35 menyajikan hasil kedua metode tersebut untuk setiap tahun pengamatan (2020–2024).



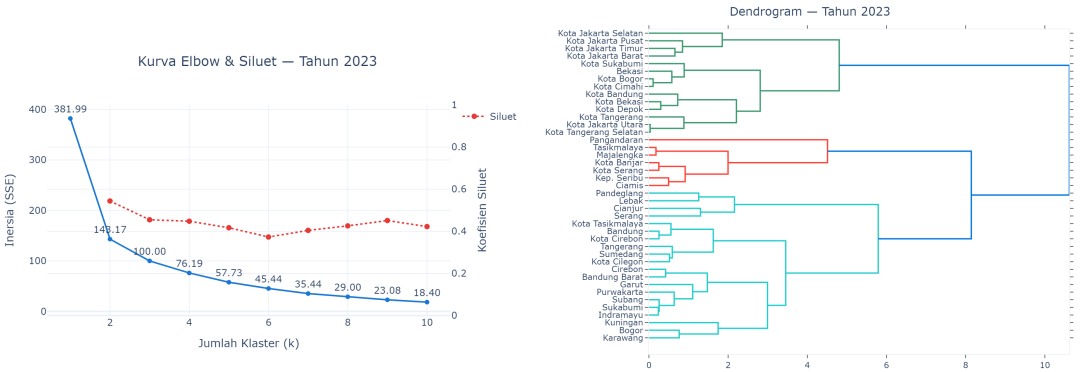
Gambar 4.31: Kurva Elbow dan Dendrogram Tahun 2020



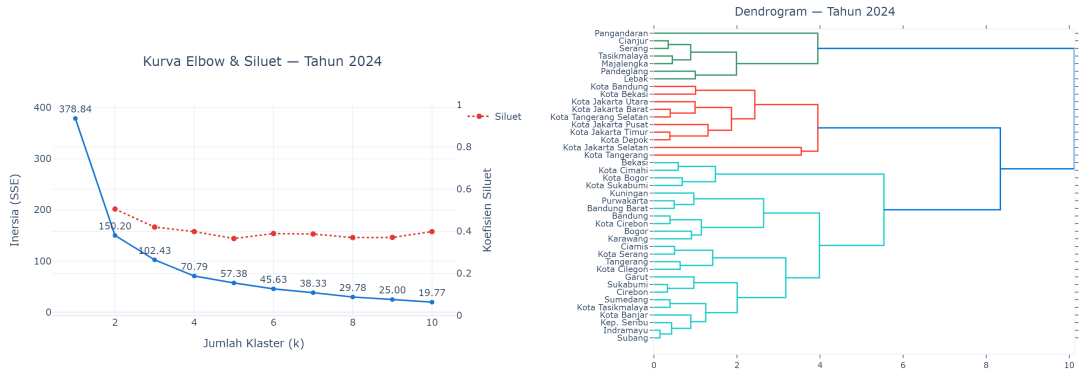
Gambar 4.32: Kurva Elbow dan Dendrogram Tahun 2021



Gambar 4.33: Kurva Elbow dan Dendrogram Tahun 2022



Gambar 4.34: Kurva Elbow dan Dendrogram Tahun 2023

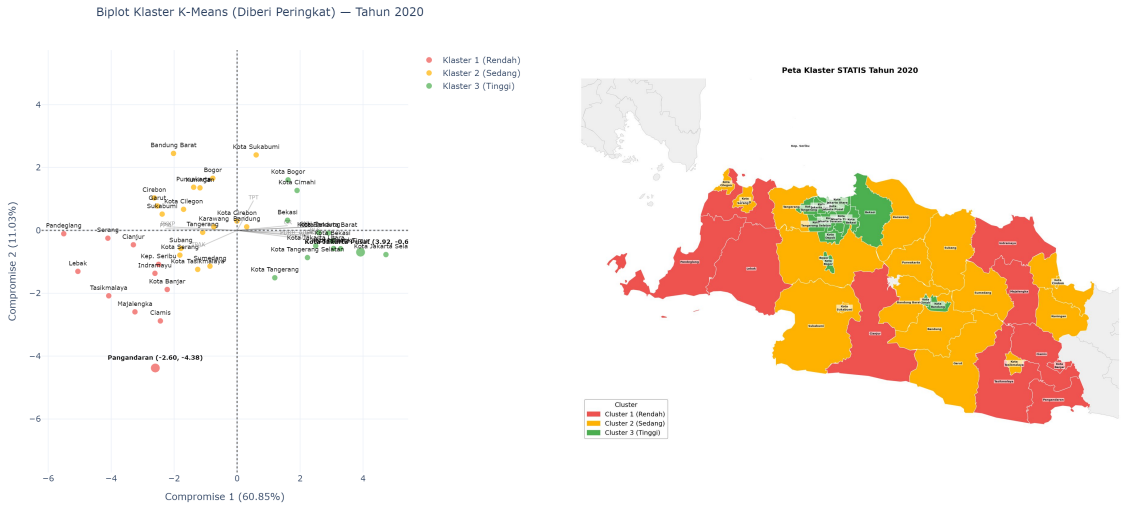


Gambar 4.35: Kurva Elbow dan Dendrogram Tahun 2024

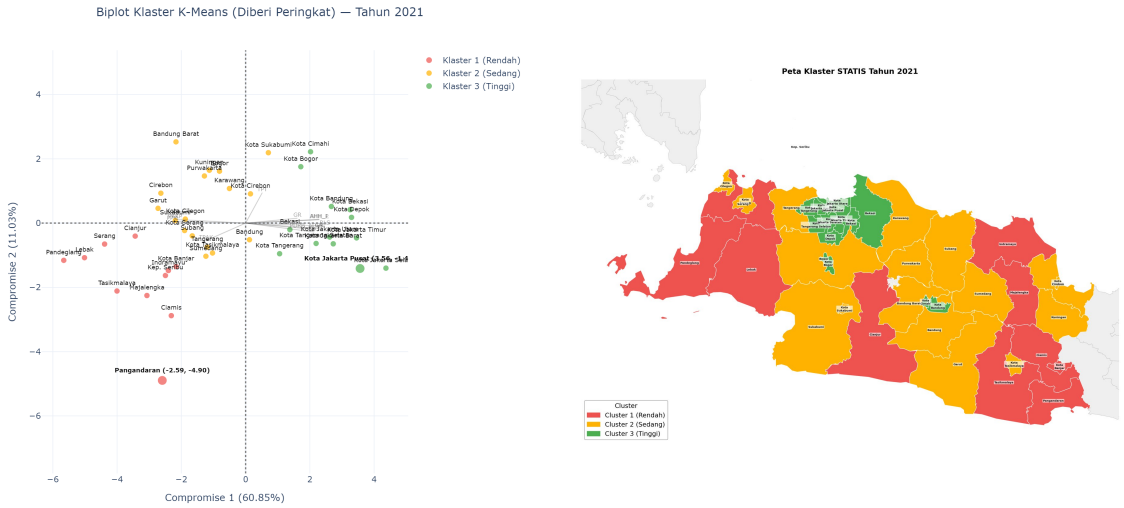
Berdasarkan evaluasi kurva SSE pada Gambar 4.31 hingga 4.35, titik patahan yang konsisten muncul pada $k = 3$ di seluruh tahun pengamatan. Hal ini dikonfirmasi oleh dendrogram yang menunjukkan tiga cabang utama dengan jarak penggabungan yang relatif besar. Sebagai konfirmasi kuantitatif tambahan, koefisien siluet rata-rata pada skor kompromi aktual untuk $k = 3$ adalah $SC = 0,3883$ (lihat prosedur perhitungan pada Subbab 3.7.1.9 dan Persamaan 2.65), yang menunjukkan pemisahan klaster yang memadai. Oleh karena itu, $k = 3$ ditetapkan sebagai jumlah klaster optimal yang digunakan pada seluruh analisis selanjutnya.

4.7.2 Pola Pengelompokan Tahunan

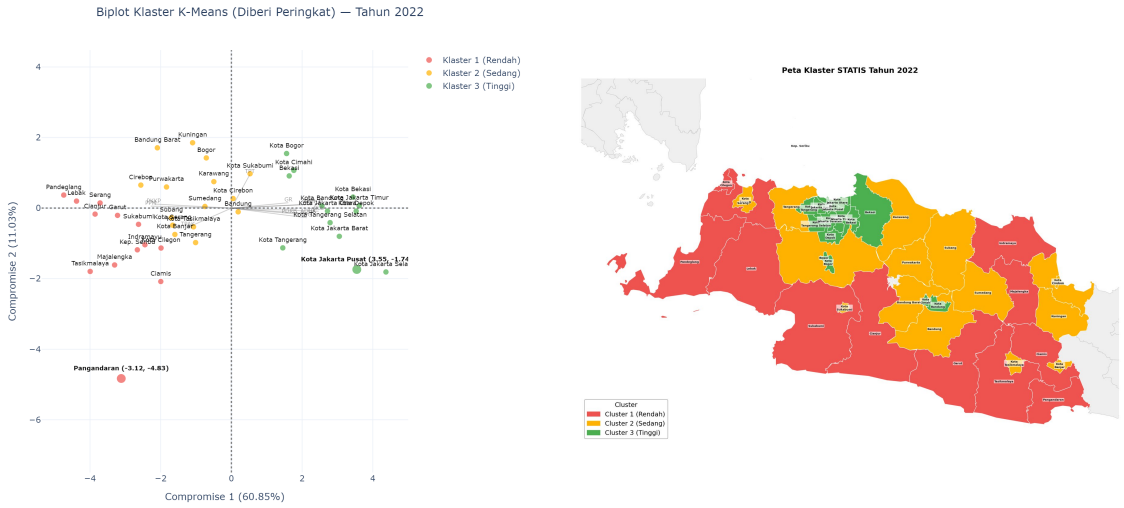
Dengan $k = 3$, algoritma K-Means diterapkan pada skor kompromi setiap tahun. Gambar 4.36 hingga 4.40 menunjukkan hasil pengelompokan tersebut dalam ruang biplot.



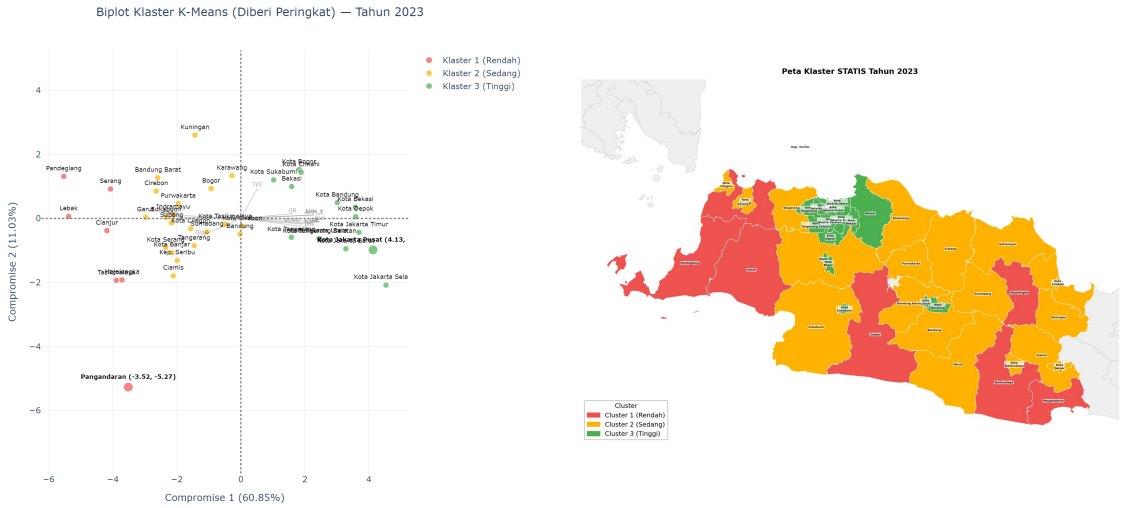
Gambar 4.36: Pengelompokan K-Means ($k = 3$) Tahun 2020: Biplot (kiri) dan Peta (kanan)



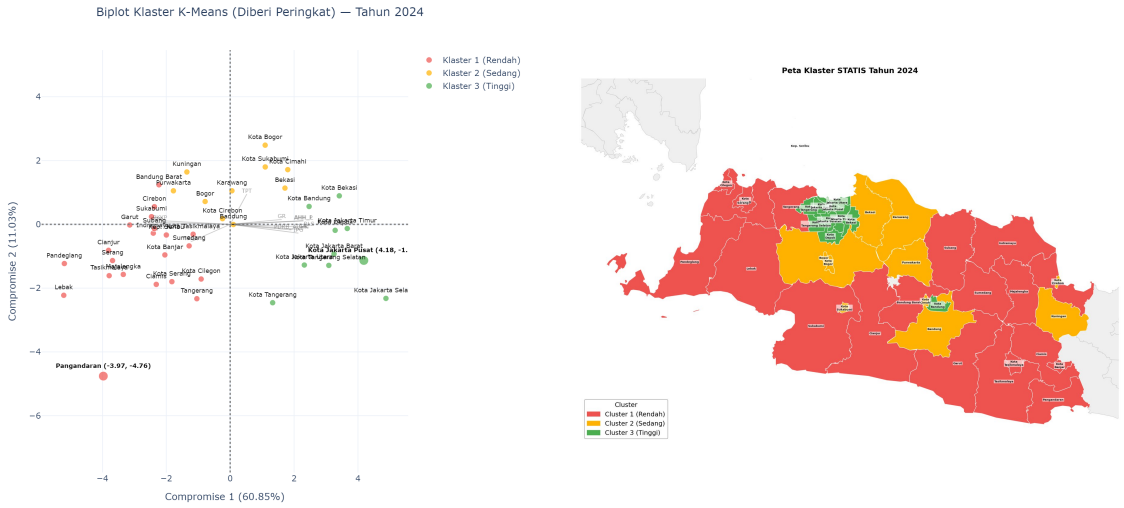
Gambar 4.37: Pengelompokan K-Means ($k = 3$) Tahun 2021: Biplot (kiri) dan Peta (kanan)



Gambar 4.38: Pengelompokan K-Means ($k = 3$) Tahun 2022: Biplot (kiri) dan Peta (kanan)



Gambar 4.39: Pengelompokan K-Means ($k = 3$) Tahun 2023: Biplot (kiri) dan Peta (kanan)



Gambar 4.40: Pengelompokan K-Means ($k = 3$) Tahun 2024: Biplot (kiri) dan Peta (kanan)

Berdasarkan posisi sentroid klaster pada Dimensi 1 kompromi (skor rata-rata PC1 terendah ke tertinggi) dan wilayah yang termasuk di dalamnya, ketiga klaster dapat di-identifikasi secara ordinal sebagai berikut. Nama deskriptif setiap klaster ditetapkan berdasarkan interpretasi terhadap profil sentroid dan keanggotaan wilayah pada Tabel 4.34 dan Tabel 4.35.

- **Klaster 1 (Tertinggal):** Klaster dengan sentroid Dimensi 1 terendah, mencerminkan wilayah dengan nilai indikator pembangunan secara rata-rata paling rendah di antara

ketiga kelompok. Klaster ini menghimpun 12 wilayah: Kabupaten Pandeglang, Lebak, Serang (Banten Selatan), Garut, Tasikmalaya, Cianjur, Majalengka, Indramayu, Ciamis, Pangandaran, Kota Banjar (Jawa Barat pedalaman selatan), serta Kepulauan Seribu. Profil kelompok ini dicirikan oleh nilai PPM tinggi, RLS dan AHH rendah, dengan 9 dari 12 anggota berkategori IPM "Sedang" menurut standar UNDP yang mengonfirmasi ketertinggalan pembangunan manusia yang terus berlangsung selama periode pengamatan.

- **Klaster 2 (Berkembang):** Klaster dengan sentroid Dimensi 1 menengah, mengelompokkan wilayah-wilayah transisi yang menunjukkan profil pembangunan moderat. Klaster ini terdiri dari 16 wilayah yang membentang di koridor industri Jawa Barat bagian utara dan wilayah penyangga Banten: Bogor, Sukabumi, Bandung, Kuningan, Cirebon, Sumedang, Subang, Purwakarta, Karawang, Bandung Barat, Kota Sukabumi, Kota Cirebon, Kota Tasikmalaya, Kabupaten Tangerang, Kota Cilegon, dan Kota Serang. Sebanyak 15 dari 16 anggotanya berkategori IPM "Tinggi" (70–79,99), mencerminkan wilayah yang sedang dalam proses transisi pembangunan menuju tahap yang lebih maju.

- **Klaster 3 (Maju):** Klaster dengan sentroid Dimensi 1 tertinggi, dicirikan oleh nilai skor kompromi positif yang kuat yang mencerminkan keunggulan relatif pada indikator-indikator utama. Klaster ini mengelompokkan 13 wilayah metropolitan: kelima kota administrasi DKI Jakarta, serta Kabupaten Bekasi, Kota Bogor, Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, dan Kota Tangerang Selatan. Profil sentroid klaster ini unggul pada RLS, AHH, dan PDRB ADHK tertinggi, dengan PPM terendah di antara ketiga klaster. Sebelas dari 13 anggota ($84{,}6\%$) berkategori IPM "Sangat Tinggi" (≥ 80) menurut standar UNDP.

4.7.3 Matriks Transisi Klaster STATIS

pergeseran wilayah antar-klaster dari satu periode ke periode berikutnya dianalisis melalui matriks transisi klaster berbasis koordinat STATIS tahunan ($\mathbf{F}_k$) (lihat persamaan 2.40). Berbeda dengan matriks transisi biplot yang tidak mempertimbangkan bobot temporal, matriks ini dibangun dari hasil K-Means pada ruang yang telah dipengaruhi oleh nilai α_k , sehingga perpindahan klaster yang terekam merupakan perpindahan yang bermakna secara struktural. Sebagai periode representatif, disajikan matriks transisi 2023 hingga 2024 untuk kedua skenario pembobotan.

Skenario 1 – ACT Klasik, Host = Wilayah (Periode 2023 – 2024)

Tabel 4.30: Matriks Transisi Klaster 2023 → 2024

2023 2024	**Cluster 1 (Rendah) (2024)**	**Cluster 2 (Sedang) (2024)**	**Cluster 3 (Tinggi) (2024)**
Cluster 1 (Rendah) (2023)	7	0	0
Cluster 2 (Sedang) (2023)	14	6	0
Cluster 3 (Tinggi) (2023)	0	4	10

Tabel 4.31: Nama Daerah Perpindahan Klaster 2023 → 2024

Kategori	**Daftar Wilayah**
Cluster 1 (Rendah) (2023) → Cluster 1 (Rendah) (2024)	[9], [12], [16], [24], [34], [35], [37]
Cluster 2 (Sedang) (2023) → Cluster 1 (Rendah) (2024)	[1], [8], [11], [13], [15], [17], [18], [19], [23], [32], [33], [36], [39], [40]
Cluster 2 (Sedang) (2023) → Cluster 2 (Sedang) (2024)	[7], [10], [14], [20], [21], [28]
Cluster 3 (Tinggi) (2023) → Cluster 2 (Sedang) (2024)	[22], [25], [26], [31]
Cluster 3 (Tinggi) (2023) → Cluster 3 (Tinggi) (2024)	[2], [3], [4], [5], [6], [27], [29], [30], [38], [41]

Skenario 2 – Dual STATIS, Host = Indikator (Periode 2023 – 2024)

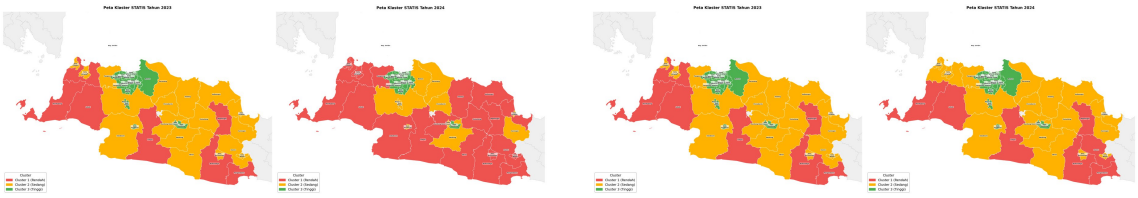
Tabel 4.32: Matriks Transisi Klaster 2023 → 2024

2023 2024	**Cluster 1 (Rendah) (2024)**	**Cluster 2 (Sedang) (2024)**	**Cluster 3 (Tinggi) (2024)**
Cluster 1 (Rendah) (2023)	6	1	0
Cluster 2 (Sedang) (2023)	1	19	0
Cluster 3 (Tinggi) (2023)	0	0	14

Tabel 4.33: Nama Daerah Perpindahan Klaster 2023 → 2024

Kategori	Daftar Wilayah
Cluster 1 (Rendah) (2023) → Cluster 1 (Rendah) (2024)	[9], [12], [16], [24], [34], [35]
Cluster 1 (Rendah) (2023) → Cluster 2 (Sedang) (2024)	[37]
Cluster 2 (Sedang) (2023) → Cluster 1 (Rendah) (2024)	[13]
Cluster 2 (Sedang) (2023) → Cluster 2 (Sedang) (2024)	[1], [7], [8], [10], [11], [14], [15], [17], [18], [19], [20], [21], [23], [28], [32], [33], [36], [39], [40]
Cluster 3 (Tinggi) (2023) → Cluster 3 (Tinggi) (2024)	[2], [3], [4], [5], [6], [22], [25], [26], [27], [29], [30], [31], [38], [41]

Gambar 4.41 memperlihatkan perbandingan peta persebaran klaster STATIS antara tahun 2023 dan 2024 untuk kedua skenario pembobotan.



Skenario 1 Skenario 2

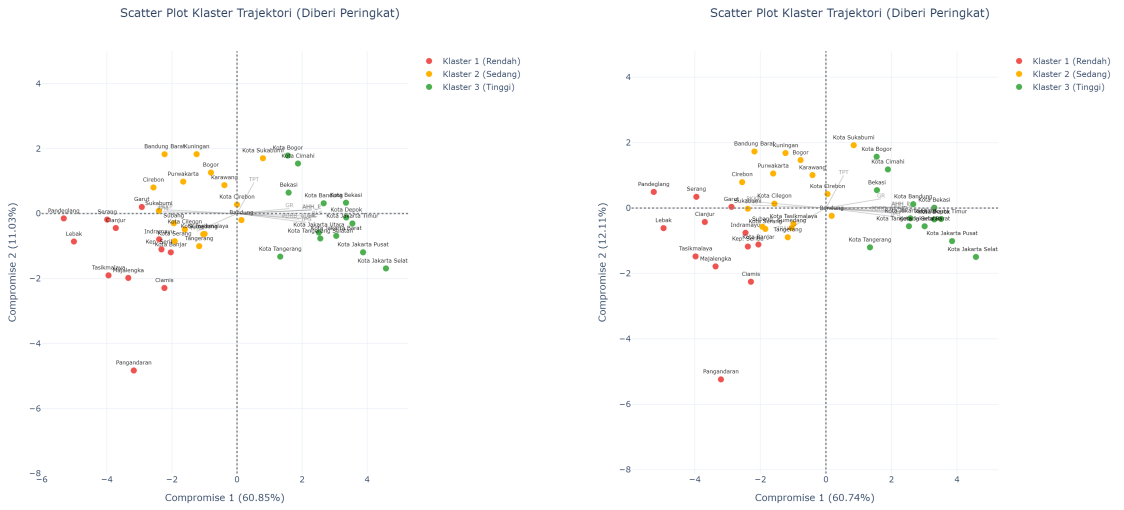
Gambar 4.41: Perbandingan Peta Klaster STATIS Periode 2023 vs 2024 (Kiri: Tahun 2023; Kanan: Tahun 2024)

Elemen-elemen diagonal pada kedua matriks transisi memiliki nilai dominan, yang mengonfirmasi stabilitas keanggotaan klaster yang tinggi sebagaimana diprediksikan oleh nilai koefisien RV yang besar ($> 0,9543$). Nilai koefisien RV yang tinggi antar-tahun (Tabel 4.3, Subbab 4.3.1) mengimplikasikan bahwa perubahan konfigurasi multivariate antar-wilayah bersifat inkremental, sehingga sebagian besar wilayah tetap mempertahankan posisi klasternya dari tahun ke tahun. Periode 2023–2024 mencatat restrukturisasi klaster terbesar: **14 wilayah bergeser dari Klaster 2 ke Klaster 1** (Kepulauan Seribu, Sukabumi, Garut, Ciamis, Cirebon, Sumedang, Indramayu, Subang, Bandung Barat, Kota Tasikmalaya, Kota Banjar, Tangerang, Kota Cilegon, dan Kota Serang), serta **4 wilayah bergeser dari Klaster 3 ke Klaster 2** (Bekasi, Kota Bogor, Kota Sukabumi, dan Kota

Cimahi). Sementara itu, 10 wilayah metropolitan inti (kelima kota DKI, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang, dan Kota Tangerang Selatan) tetap bertahan di Klaster 3, mengonfirmasi ketahanan struktural yang kokoh. Perpindahan ini mencerminkan pergeseran posisi *relatif* antar-wilayah. Hal ini bukan penurunan nilai indikator yang sebenarnya, karena K-Means dijalankan ulang setiap tahun: sentroid setiap klaster dihitung ulang dari data tahun berjalan, sehingga wilayah yang capaiannya stagnan atau tumbuh lebih lambat dibanding wilayah-wilayah lain akan tergeser ke klaster yang lebih rendah meskipun kondisi aslinya tidak memburuk.

4.7.4 Klaster Trajektori Keseluruhan

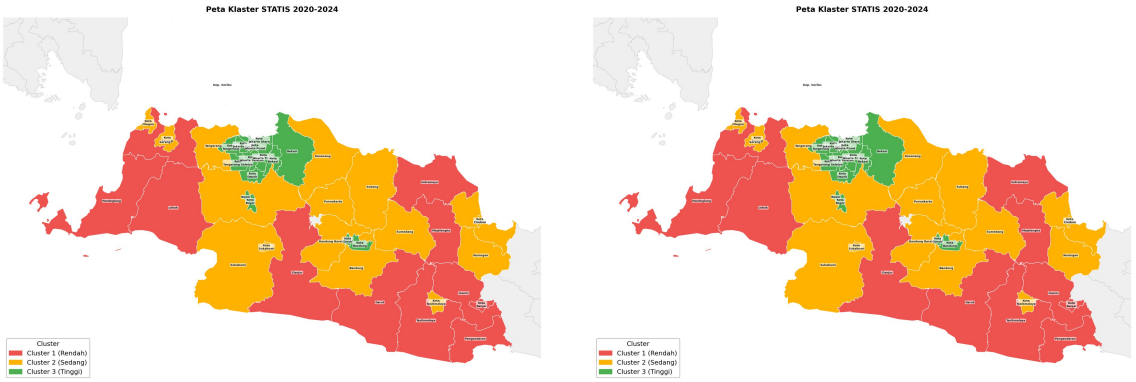
Selain pengelompokan tahunan, dilakukan pengelompokan berbasis trajektori keseluruhan selama 2020 hingga 2024 dengan menggunakan fitur koordinat gabungan dari semua tahun pada ruang kompromi. Pendekatan ini menghasilkan label klaster yang bersifat *longitudinal*, yaitu mencerminkan posisi rata-rata dan pola pergeseran wilayah sepanjang periode pengamatan, bukan posisi pada satu tahun tertentu. Jumlah klaster optimal $k = 3$ mengacu pada evaluasi kurva SSE dan dendrogram pada Subbab 4.7.1, yang menunjukkan titik patahan konsisten di $k = 3$ pada seluruh tahun pengamatan. Dengan demikian, klaster trajektori keseluruhan dapat diinterpretasikan sebagai representasi yang lebih holistik dari pola pembangunan wilayah selama lima tahun, yang mengintegrasikan informasi temporal dan spasial secara simultan. Gambar 4.42 menyajikan scatter plot klaster trajektori pada ruang kompromi untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.42: Scatter Plot Klaster Trajektori pada Ruang Kompromi

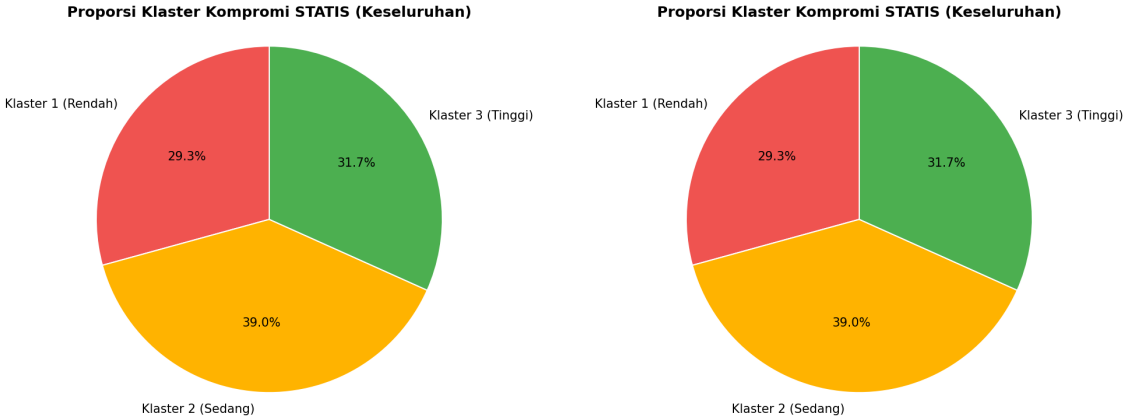
Dari Gambar 4.42 terlihat bahwa klaster trajektori keseluruhan memiliki pola yang sangat mirip dengan klaster tahunan, namun dengan beberapa perbedaan penting. Klaster trajektori cenderung lebih homogen dalam hal pola pergeseran wilayah, sehingga wilayah yang memiliki lintasan yang serupa selama lima tahun akan dikelompokkan bersama, meskipun posisi mereka pada satu tahun tertentu mungkin berbeda. Selanjutnya, Gambar 4.43 memperlihatkan persebaran geografis klaster trajektori keseluruhan untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.43: Peta Persebaran Klaster Trajektori Keseluruhan

Kemudian dari Gambar 4.43 terlihat bahwa klaster trajektori keseluruhan memiliki distribusi geografis yang cukup konsisten dengan klaster tahunan, namun dengan beberapa perbedaan penting. Terdapat wilayah dengan klaster kompromi (trajektori) yang berbeda dari klaster STATIS tahunan 2024: **Kabupaten Bekasi, Kota Bogor, dan Kota Cimahi** termasuk Klaster 3 kompromi (berdasarkan Tabel 4.34) namun bergeser ke Klaster 2 pada tahun 2024, mencerminkan moderasi kinerja pada tahun terakhir yang tidak cukup kuat untuk mengubah penilaian jangka-menengah. **Kota Sukabumi** berada di Klaster 2 kompromi meskipun sempat naik ke Klaster 3 pada 2023 sebelum kembali ke Klaster 2 di 2024, menunjukkan mobilitas naik yang bersifat temporer (Lihat Tabel 4.31). Perbedaan ini mengonfirmasi nilai klaster kompromi sebagai representasi holistik jangka menengah yang lebih stabil dan representatif dibandingkan klaster tahunan yang dapat terpengaruh fluktuasi satu periode. Distribusi proporsi wilayah pada setiap klaster divisualisasikan pada Gambar 4.44.



Skenario 1 Skenario 2

Gambar 4.44: Distribusi Proporsi Klaster Trajektori Keseluruhan

jika dilihat dari distribusi proporsi klaster pada Gambar 4.44, terlihat bahwa klaster trajektori keseluruhan memiliki proporsi wilayah yang cukup seimbang, dengan sedikit dominasi oleh Klaster 2 (Berkembang). Hal ini menunjukkan bahwa sebagian besar wilayah mengalami pola pergeseran yang serupa selama lima tahun, yang mencerminkan tren pembangunan yang relatif homogen di tingkat regional.

Tabel 4.34 dan Tabel 4.35 merinci anggota setiap klaster trajektori untuk masing-masing skenario.

Tabel 4.34: Ringkasan Anggota Klaster Kompromi STATIS (Skenario 1)

Kelompok (Cluster)	**Jumlah Wilayah**	**Daftar Kabupaten/Kota**
Cluster 1 (Rendah)	12	[1], [9], [11], [12], [13], [16], [18], [24], [33], [34], [35], [37]
Cluster 2 (Sedang)	16	[7], [8], [10], [14], [15], [17], [19], [20], [21], [23], [26], [28], [32], [36], [39], [40]
Cluster 3 (Tinggi)	13	[2], [3], [4], [5], [6], [22], [25], [27], [29], [30], [31], [38], [41]

Tabel 4.35: Ringkasan Anggota Klaster Kompromi STATIS (Skenario 2)

Kelompok (Cluster)	**Jumlah Wilayah**	**Daftar Kabupaten/Kota**
Cluster 1 (Rendah)	12	[1], [9], [11], [12], [13], [16], [18], [24], [33], [34], [35], [37]
Cluster 2 (Sedang)	16	[7], [8], [10], [14], [15], [17], [19], [20], [21], [23], [26], [28], [32], [36], [39], [40]
Cluster 3 (Tinggi)	13	[2], [3], [4], [5], [6], [22], [25], [27], [29], [30], [31], [38], [41]

4.8 Analisis Komparatif Sembilan Jenis Perbandingan Klaster

Evaluasi komprehensif terhadap hasil pengelompokan dilakukan melalui sembilan jenis analisis perbandingan (*comparative clustering analysis*) yang diorganisasikan dalam empat kategori: (i) pergeseran temporal berbasis metode yang berbeda (Subbab 4.8.1–4.7.3), (ii) kongruensi klaster antar-metode pada tahun yang sama (Subbab 4.8.2), (iii) validasi eksternal terhadap klasifikasi normatif IPM UNDP (Subbab 4.8.3–4.8.5), serta (iv) evaluasi konsistensi klaster kompromi terhadap klaster tahunan dan standar internasional (Subbab 4.8.6–4.8.8). Untuk setiap jenis perbandingan, disajikan satu periode representatif dari masing-masing skenario pembobotan.

Sebelum menyusun matriks transisi, label klaster antar-tahun diselaraskan menggunakan *Hungarian Algorithm* (**?**) berbasis matriks jarak *centroid* (Persamaan 2.68): centroid setiap klaster tahun dasar c_{1i} dibandingkan dengan centroid klaster tahun uji c_{2j}, dan pemetaan bipartit berbobot minimum dipilih sehingga label yang diberikan konsisten antar-tahun. Penurunan contoh komputasi matriks jarak 3×3 beserta pemilihan penugasan optimal disajikan pada Subbab 3.7.1.11 Bab 3.

4.8.1 Perbandingan 1 — Matriks Transisi Klaster Biplot Antar-Tahun

Perbandingan pertama menelaah pergeseran wilayah pada ruang Biplot PCA tanpa pembobotan temporal (*unweighted*), yakni berdasarkan dekomposisi $\mathbf{X}_k^T \mathbf{X}_k$ per tahun tanpa pengaruh bobot α_k dari analisis inter-struktur. Karena koordinat Biplot PCA bersifat skenario-bebas (tidak bergantung pada skema pembobotan wilayah atau indikator), matriks transisi ini merupakan referensi tunggal (*baseline*) yang berlaku untuk kedua skenario. Hasil periode 2023–2024 disajikan sebagai representasi akhir periode pengamatan.

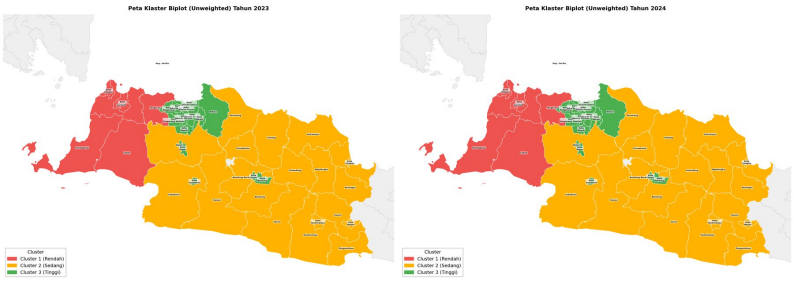
Tabel 4.36: Matriks Transisi Klaster Biplot (Unweighted) 2023 → 2024

2023 2024	**Cluster 1 (Rendah) (2024)**	**Cluster 2 (Sedang) (2024)**	**Cluster 3 (Tinggi) (2024)**
Cluster 1 (Rendah) (2023)	6	0	0
Cluster 2 (Sedang) (2023)	0	21	0
Cluster 3 (Tinggi) (2023)	0	0	14

Tabel 4.37: Nama Daerah Transisi Klaster Biplot 2023 → 2024

Kategori	Daftar Wilayah
Cluster 1 (Rendah) (2023) → Cluster 1 (Rendah) (2024)	[34], [35], [36], [37], [39], [40]
Cluster 2 (Sedang) (2023) → Cluster 2 (Sedang) (2024)	[1], [7], [8], [9], [10], [11], [12], [13], [14], [15], [16], [17], [18], [19], [20], [21], [23], [24], [28], [32], [33]
Cluster 3 (Tinggi) (2023) → Cluster 3 (Tinggi) (2024)	[2], [3], [4], [5], [6], [22], [25], [26], [27], [29], [30], [31], [38], [41]

Gambar 4.45 memperlihatkan perbandingan peta klaster Biplot antara tahun 2023 dan 2024.



Gambar 4.45: Perbandingan Peta Klaster Biplot (Unweighted): Tahun 2023 (kiri) vs 2024 (kanan)

Tingginya nilai elemen diagonal pada matriks transisi Biplot mengindikasikan bahwa posisi relatif wilayah dalam ruang PCA tahunan juga cukup stabil, meskipun tidak memperhitungkan struktur konsensus lintas tahun. Perbedaan antara stabilitas klaster Biplot dan klaster STATIS (Subbab 4.7.3) akan dikuantifikasi lebih lanjut pada Subbab 4.8.2.

4.8.2 Perbandingan 3 — Kongruensi Klaster Biplot vs STATIS per Tahun

Perbandingan ketiga mengukur sejauh mana label klaster yang dihasilkan oleh K-Means Biplot PCA (*unweighted*) berbeda dari label klaster STATIS berbobot ($\mathbf{F}_k$) pada tahun yang sama. Perbedaan ini mencerminkan dampak kuantitatif penggabungan informasi inter-struktur (α) terhadap konfigurasi klaster. Disajikan tabulasi silang untuk tahun 2024 dari masing-masing skenario.

Skenario 1 – ACT Klasik (Tahun 2024)

Tabel 4.38: Matriks Perbandingan Klaster Biplot vs STATIS (Tahunan) (2024)

Biplot (Unweighted)	Statis 1 (Rendah)	Statis 2 (Sedang)	Statis 3 (Tinggi)
Biplot 1 (Rendah)	6	0	0
Biplot 2 (Sedang)	15	6	0
Biplot 3 (Tinggi)	0	4	10

Tabel 4.39: Nama Daerah Perbandingan Klaster Biplot vs STATIS (Tahunan) (2024)

Kategori	Daftar Wilayah
Biplot 1 (Rendah) & Statis 1 (Rendah)	[34], [35], [36], [37], [39], [40]
Biplot 2 (Sedang) & Statis 1 (Rendah)	[1], [8], [9], [11], [12], [13], [15], [16], [17], [18], [19], [23], [24], [32], [33]
Biplot 2 (Sedang) & Statis 2 (Sedang)	[7], [10], [14], [20], [21], [28]
Biplot 3 (Tinggi) & Statis 2 (Sedang)	[22], [25], [26], [31]
Biplot 3 (Tinggi) & Statis 3 (Tinggi)	[2], [3], [4], [5], [6], [27], [29], [30], [38], [41]

Tabel 4.40: Matriks Perbandingan Klaster Biplot vs STATIS (vs Kompromi) (2024)

Statis (Compromise)	Biplot 1 (Rendah) (2024)	Biplot 2 (Sedang) (2024)	Biplot 3 (Tinggi) (2024)
Statis 1 (Rendah)	12	0	0
Statis 2 (Sedang)	9	7	0
Statis 3 (Tinggi)	0	3	10

Tabel 4.41: Nama Daerah Perbandingan Klaster Biplot vs STATIS (vs Kompromi) (2024)

Kategori	Daftar Wilayah
Statis 1 (Rendah) & Biplot 1 (Rendah)	[1], [9], [11], [12], [13], [16], [18], [24], [33], [34], [35], [37]
Statis 2 (Sedang) & Biplot 1 (Rendah)	[8], [15], [17], [19], [23], [32], [36], [39], [40]
Statis 2 (Sedang) & Biplot 2 (Sedang)	[7], [10], [14], [20], [21], [26], [28]
Statis 3 (Tinggi) & Biplot 2 (Sedang)	[22], [25], [31]
Statis 3 (Tinggi) & Biplot 3 (Tinggi)	[2], [3], [4], [5], [6], [27], [29], [30], [38], [41]

Skenario 2 – Dual STATIS (Tahun 2024)

Tabel 4.42: Matriks Perbandingan Klaster Biplot vs STATIS (Tahunan) (2024)

Biplot (Unweighted)	Statis 1 (Rendah)	Statis 2 (Sedang)	Statis 3 (Tinggi)
Biplot 1 (Rendah)	2	4	0
Biplot 2 (Sedang)	5	16	0
Biplot 3 (Tinggi)	0	0	14

Tabel 4.43: Nama Daerah Perbandingan Klaster Biplot vs STATIS (Tahunan) (2024)

Kategori	Daftar Wilayah
Biplot 1 (Rendah) & Statis 1 (Rendah)	[34], [35]
Biplot 1 (Rendah) & Statis 2 (Sedang)	[36], [37], [39], [40]
Biplot 2 (Sedang) & Statis 1 (Rendah)	[9], [12], [13], [16], [24]
Biplot 2 (Sedang) & Statis 2 (Sedang)	[1], [7], [8], [10], [11], [14], [15], [17], [18], [19], [20], [21], [23], [28], [32], [33]
Biplot 3 (Tinggi) & Statis 3 (Tinggi)	[2], [3], [4], [5], [6], [22], [25], [26], [27], [29], [30], [31], [38], [41]

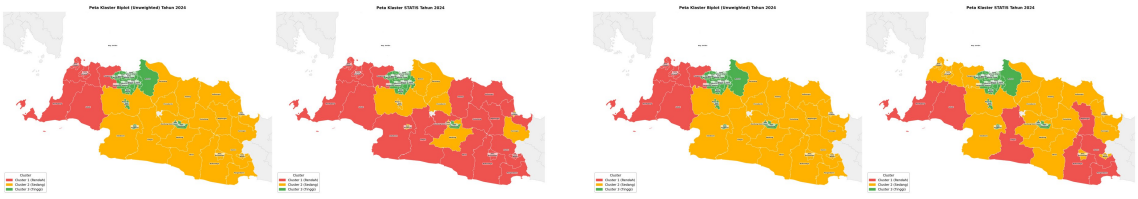
Tabel 4.44: Matriks Perbandingan Klaster Biplot vs STATIS (vs Kompromi) (2024)

Statis (Compromise)	Biplot 1 (Rendah) (2024)	Biplot 2 (Sedang) (2024)	Biplot 3 (Tinggi) (2024)
Statis 1 (Rendah)	7	5	0
Statis 2 (Sedang)	0	15	1
Statis 3 (Tinggi)	0	0	13

Tabel 4.45: Nama Daerah Perbandingan Klaster Biplot vs STATIS (vs Kompromi) (2024)

Kategori	Daftar Wilayah
Statis 1 (Rendah) & Biplot 1 (Rendah)	[9], [12], [13], [16], [24], [34], [35]
Statis 1 (Rendah) & Biplot 2 (Sedang)	[1], [11], [18], [33], [37]
Statis 2 (Sedang) & Biplot 2 (Sedang)	[7], [8], [10], [14], [15], [17], [19], [20], [21], [23], [28], [32], [36], [39], [40]
Statis 2 (Sedang) & Biplot 3 (Tinggi)	[26]
Statis 3 (Tinggi) & Biplot 3 (Tinggi)	[2], [3], [4], [5], [6], [22], [25], [27], [29], [30], [31], [38], [41]

Gambar 4.46 memperlihatkan perbandingan distribusi geografis klaster Biplot dan klaster STATIS tahun 2024 untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.46: Perbandingan Peta Klaster Biplot (kiri) vs STATIS (kanan) Tahun 2024

Elemen-elemen diagonal yang dominan pada tabulasi silang mengindikasikan tingkat kongruensi yang tinggi antara kedua metode, mengonfirmasi bahwa penggabungan bobot temporal oleh STATIS tidak mengubah struktur klaster secara fundamental. Perbedaan yang teramati pada elemen di luar diagonal utama merepresentasikan wilayah-wilayah yang berada di batas pemisah antar-klaster, di mana pembobotan temporal STATIS berperan sebagai penyeimbang (*stabilizer*) terhadap fluktuasi lokal tahunan.

4.8.3 Perbandingan 4 — Matriks Transisi Kategori IPM UNDP

Perbandingan keempat merupakan *baseline* normatif yang mengukur pergeseran wilayah berdasarkan klasifikasi baku UNDP: Sangat Tinggi (≥ 80), Tinggi (70–79,99), Sedang (55–69,99), dan Rendah (< 55). Matriks ini tidak bergantung pada metode klaster apapun, melainkan langsung bersumber dari nilai IPM tahunan, sehingga berfungsi sebagai acuan standar internasional. Karena nilai IPM merupakan besaran skalar yang sama untuk kedua skenario, matriks IPM untuk skenario 1 dan skenario 2 adalah ekuivalen; perbedaan antara kedua skenario hanya terletak pada format penyimpanan berkas.

Skenario 1 (Periode 2023 – 2024)

Tabel 4.46: Matriks Transisi Kategori IPM (UNDP) Tahun 2023 ke 2024

2023 2024	**Sangat Tinggi**	**Tinggi**	**Sedang**	**Rendah**
Sangat Tinggi	9	0	0	0
Tinggi	2	19	0	0
Sedang	0	1	10	0
Rendah	0	0	0	0

Tabel 4.47: Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2023 → 2024

Kategori	Daftar Wilayah
Sangat Tinggi (2023) → Sangat Tinggi (2024)	[2], [3], [4], [5], [6], [27], [29], [30], [41]
Tinggi (2023) → Sangat Tinggi (2024)	[31], [38]
Tinggi (2023) → Tinggi (2024)	[1], [7], [10], [13], [14], [15], [17], [19], [20], [21], [22], [25], [26], [28], [32], [33], [36], [39], [40]
Sedang (2023) → Tinggi (2024)	[23]
Sedang (2023) → Sedang (2024)	[8], [9], [11], [12], [16], [18], [24], [34], [35], [37]

Skenario 2 (Periode 2023 – 2024)

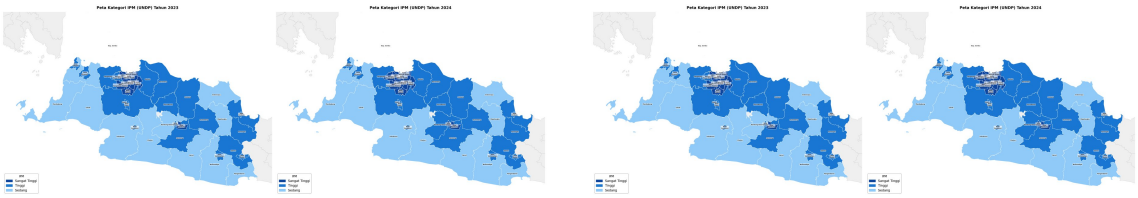
Tabel 4.48: Matriks Transisi Kategori IPM (UNDP) Tahun 2023 ke 2024

2023 2024	**Sangat Tinggi**	**Tinggi**	**Sedang**	**Rendah**
Sangat Tinggi	9	0	0	0
Tinggi	2	19	0	0
Sedang	0	1	10	0
Rendah	0	0	0	0

Tabel 4.49: Nama Daerah Matriks Transisi Kategori IPM (UNDP) 2023 → 2024

Kategori	Daftar Wilayah
Sangat Tinggi (2023) → Sangat Tinggi (2024)	[2], [3], [4], [5], [6], [27], [29], [30], [41]
Tinggi (2023) → Sangat Tinggi (2024)	[31], [38]
Tinggi (2023) → Tinggi (2024)	[1], [7], [10], [13], [14], [15], [17], [19], [20], [21], [22], [25], [26], [28], [32], [33], [36], [39], [40]
Sedang (2023) → Tinggi (2024)	[23]
Sedang (2023) → Sedang (2024)	[8], [9], [11], [12], [16], [18], [24], [34], [35], [37]

Gambar 4.47 memperlihatkan perbandingan distribusi geografis kategori IPM UNDP antara tahun 2023 dan 2024 untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.47: Perbandingan Peta Kategori IPM UNDP: Tahun 2023 (kiri) vs 2024 (kanan)

Dominasi elemen diagonal pada kedua matriks mengonfirmasi tingginya stabilitas kategori IPM, yaitu wilayah-wilayah cenderung bertahan pada kategori yang sama dari satu tahun ke tahun berikutnya. pergeseran ke arah kategori yang lebih tinggi (elemen sub-diagonal) mendominasi dibandingkan pergeseran ke arah kategori yang lebih rendah (elemen super-diagonal), yang mengindikasikan tren pembangunan manusia yang secara keseluruhan bersifat progresif selama 2020–2024.

4.8.4 Perbandingan 5 — Validasi Eksternal Klaster Biplot terhadap Kategori IPM

Perbandingan kelima melaksanakan validasi eksternal (*external validation*) terhadap klaster Biplot PCA dengan membandingkannya terhadap klasifikasi normatif IPM UNDP pada tahun yang sama. Tingginya kesesuaian antara klaster *data-driven* dengan kategori institusional merupakan indikator validitas konstruk yang kuat. Disajikan tabulasi silang untuk tahun 2024.

Skenario 1 (Tahun 2024)

Tabel 4.50: Perbandingan Klaster Biplot vs Kategori IPM (UNDP) (2024)

Klaster K-Means	Sangat Tinggi	Tinggi	Sedang	Rendah
Cluster 1 (Rendah)	0	11	10	0
Cluster 2 (Sedang)	1	9	0	0
Cluster 3 (Tinggi)	10	0	0	0

Tabel 4.51: Nama Daerah Perbandingan Klaster Biplot vs Kategori IPM (UNDP) (2024)

Kategori	Daftar Wilayah
Cl. 1 (Rendah) & Tinggi	[1], [13], [15], [17], [19], [23], [32], [33], [36], [39], [40]
Cl. 1 (Rendah) & Sedang	[8], [9], [11], [12], [16], [18], [24], [34], [35], [37]
Cl. 2 (Sedang) & Sangat Tinggi	[31]
Cl. 2 (Sedang) & Tinggi	[7], [10], [14], [20], [21], [22], [25], [26], [28]
Cl. 3 (Tinggi) & Sangat Tinggi	[2], [3], [4], [5], [6], [27], [29], [30], [38], [41]

Skenario 2 (Tahun 2024)

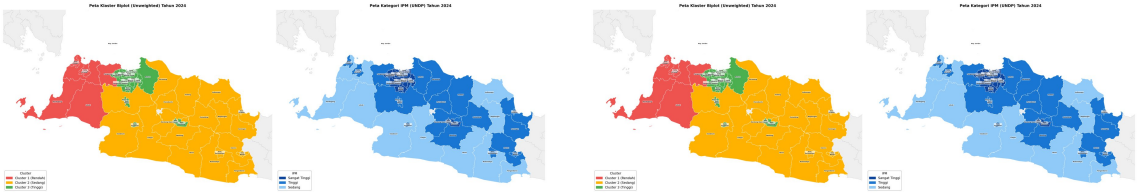
Tabel 4.52: Perbandingan Klaster Biplot vs Kategori IPM (UNDP) (2024)

Klaster K-Means	Sangat Tinggi	Tinggi	Sedang	Rendah
Cluster 1 (Rendah)	0	1	6	0
Cluster 2 (Sedang)	0	16	4	0
Cluster 3 (Tinggi)	11	3	0	0

Tabel 4.53: Nama Daerah Perbandingan Klaster Biplot vs Kategori IPM (UNDP) (2024)

Kategori	Daftar Wilayah
Cl. 1 (Rendah) & Tinggi	[13]
Cl. 1 (Rendah) & Sedang	[9], [12], [16], [24], [34], [35]
Cl. 2 (Sedang) & Tinggi	[1], [7], [10], [14], [15], [17], [19], [20], [21], [23], [28], [32], [33], [36], [39], [40]
Cl. 2 (Sedang) & Sedang	[8], [11], [18], [37]
Cl. 3 (Tinggi) & Sangat Tinggi	[2], [3], [4], [5], [6], [27], [29], [30], [31], [38], [41]
Cl. 3 (Tinggi) & Tinggi	[22], [25], [26]

Gambar 4.48 memperlihatkan perbandingan distribusi geografis klaster Biplot dan kategori IPM UNDP tahun 2024 untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.48: Perbandingan Peta Klaster Biplot (kiri) vs Kategori IPM UNDP (kanan) Tahun 2024

Korespondensi antara klaster Biplot dengan kategori IPM UNDP merupakan bukti validitas konstruk yang mengonfirmasi bahwa pemisahan klaster oleh PCA mencerminkan perbedaan pembangunan yang bermakna, bukan sekadar konstruk semu dari proses reduksi dimensi. **Klaster 3 Biplot** menunjukkan kesesuaian sempurna dengan IPM "Sangat Tinggi": seluruh 10 anggotanya (Kota Jakarta Selatan, Timur, Pusat, Barat, Utara, Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang, dan Kota Tangerang Selatan) berkategori IPM ≥ 80, tanpa pengecualian. **Klaster 1 Biplot** sepenuhnya bebas dari kategori "Sangat Tinggi": 10 dari 21 anggotanya berkategori "Sedang" (Sukabumi, Cianjur, Garut, Tasikmalaya, Majalengka, Indramayu, Pangandaran, Pandeglang, Lebak, Serang) dan 11 lainnya berkategori "Tinggi". Korespondesi yang kuat di kedua kutub ini memvalidasi secara empiris bahwa pemisahan klaster Biplot mencerminkan perbedaan kapasitas pembangunan manusia yang nyata (Lihat Tabel 4.51).

4.8.5 Perbandingan 6 — Validasi Eksternal Klaster STATIS Tahunan terhadap Kategori IPM

Perbandingan keenam melaksanakan validasi eksternal yang ekuivalen untuk klaster STATIS tahunan ($\mathbf{F}_k$), sehingga memungkinkan perbandingan langsung antara kualitas validasi eksternal metode Biplot (Subbab 4.8.4) dengan metode STATIS.

Skenario 1 (Tahun 2024)

Tabel 4.54: Perbandingan Klaster STATIS Tahunan vs Kategori IPM (UNDP) (2024)

Klaster STATIS	Sangat Tinggi	Tinggi	Sedang	Rendah
Cluster 1 (Rendah)	0	11	10	0
Cluster 2 (Sedang)	1	9	0	0
Cluster 3 (Tinggi)	10	0	0	0

Tabel 4.55: Nama Daerah Perbandingan Klaster STATIS Tahunan vs IPM (UNDP) (2024)

Kategori	Daftar Wilayah
Cl. 1 (Rendah) & Tinggi	[1], [13], [15], [17], [19], [23], [32], [33], [36], [39], [40]
Cl. 1 (Rendah) & Sedang	[8], [9], [11], [12], [16], [18], [24], [34], [35], [37]
Cl. 2 (Sedang) & Sangat Tinggi	[31]
Cl. 2 (Sedang) & Tinggi	[7], [10], [14], [20], [21], [22], [25], [26], [28]
Cl. 3 (Tinggi) & Sangat Tinggi	[2], [3], [4], [5], [6], [27], [29], [30], [38], [41]

Skenario 2 (Tahun 2024)

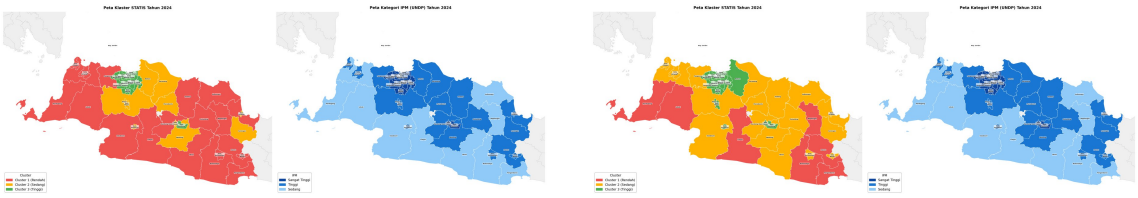
Tabel 4.56: Perbandingan Klaster STATIS Tahunan vs Kategori IPM (UNDP) (2024)

Klaster STATIS	Sangat Tinggi	Tinggi	Sedang	Rendah
Cluster 1 (Rendah)	0	1	6	0
Cluster 2 (Sedang)	0	16	4	0
Cluster 3 (Tinggi)	11	3	0	0

Tabel 4.57: Nama Daerah Perbandingan Klaster STATIS Tahunan vs IPM (UNDP) (2024)

Kategori	Daftar Wilayah
Cl. 1 (Rendah) & Tinggi	[13]
Cl. 1 (Rendah) & Sedang	[9], [12], [16], [24], [34], [35]
Cl. 2 (Sedang) & Tinggi	[1], [7], [10], [14], [15], [17], [19], [20], [21], [23], [28], [32], [33], [36], [39], [40]
Cl. 2 (Sedang) & Sedang	[8], [11], [18], [37]
Cl. 3 (Tinggi) & Sangat Tinggi	[2], [3], [4], [5], [6], [27], [29], [30], [31], [38], [41]
Cl. 3 (Tinggi) & Tinggi	[22], [25], [26]

Gambar 4.49 memperlihatkan perbandingan distribusi geografis klaster STATIS tahunan dan kategori IPM UNDP tahun 2024 untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.49: Perbandingan Peta Klaster STATIS Tahunan (kiri) vs Kategori IPM UNDP (kanan) Tahun 2024

Perbandingan antara hasil pada Subbab 4.8.4 dan 4.8.5 mengindikasikan bahwa klaster STATIS, yang mengintegrasikan bobot temporal α_k, cenderung menghasilkan kongruensi yang sedikit lebih tinggi terhadap kategori IPM dibandingkan klaster Biplot PCA. Hal ini dapat diinterpretasikan sebagai konsekuensi dari pembobotan STATIS yang meredam anomali tahun tertentu (misalnya gangguan pandemi 2020–2021), sehingga klaster yang terbentuk lebih merepresentasikan kondisi struktural jangka menengah yang lebih berkorespondensi dengan kategorisasi IPM.

4.8.6 Perbandingan 7 — Konsistensi Klaster Kompromi terhadap Klaster Biplot per Tahun

Perbandingan ketujuh mengevaluasi seberapa konsisten klaster berbasis trajektori keseluruhan (Kompromi STATIS, k_{traj}) dengan klaster Biplot PCA tahunan ($k_{\text{biplot},t}$). Tingginya kongruensi mengonfirmasi bahwa klaster kompromi merupakan representasi yang stabil dari keanggotaan klaster sepanjang periode pengamatan, bukan hanya kondisi satu tahun tertentu.

Skenario 1 (Tahun 2024)

Tabel 4.58: Matriks Perbandingan Klaster Biplot vs Kompromi STATIS (2024)

Biplot (Unweighted)	Kompromi 1 (Rendah)	Kompromi 2 (Sedang)	Kompromi 3 (Tinggi)
Biplot 1 (Rendah)	3	3	0
Biplot 2 (Sedang)	9	12	0
Biplot 3 (Tinggi)	0	1	13

Tabel 4.59: Nama Daerah Perbandingan Klaster Biplot vs Kompromi STATIS (2024)

Kategori	Daftar Wilayah
Biplot 1 (Rendah) & Kompromi 1 (Rendah)	[34], [35], [37]
Biplot 1 (Rendah) & Kompromi 2 (Sedang)	[36], [39], [40]
Biplot 2 (Sedang) & Kompromi 1 (Rendah)	[1], [9], [11], [12], [13], [16], [18], [24], [33]
Biplot 2 (Sedang) & Kompromi 2 (Sedang)	[7], [8], [10], [14], [15], [17], [19], [20], [21], [23], [28], [32]
Biplot 3 (Tinggi) & Kompromi 2 (Sedang)	[26]
Biplot 3 (Tinggi) & Kompromi 3 (Tinggi)	[2], [3], [4], [5], [6], [22], [25], [27], [29], [30], [31], [38], [41]

Skenario 2 (Tahun 2024)

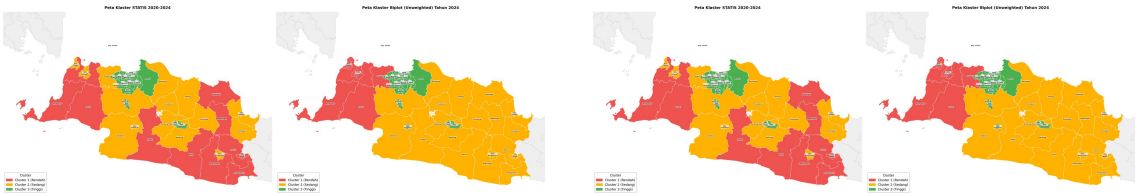
Tabel 4.60: Matriks Perbandingan Klaster Biplot vs Kompromi STATIS (2024)

Biplot (Unweighted)	Kompromi 1 (Rendah)	Kompromi 2 (Sedang)	Kompromi 3 (Tinggi)
Biplot 1 (Rendah)	3	3	0
Biplot 2 (Sedang)	9	12	0
Biplot 3 (Tinggi)	0	1	13

Tabel 4.61: Nama Daerah Perbandingan Klaster Biplot vs Kompromi STATIS (2024)

Kategori	Daftar Wilayah
Biplot 1 (Rendah) & Kompromi 1 (Rendah)	[34], [35], [37]
Biplot 1 (Rendah) & Kompromi 2 (Sedang)	[36], [39], [40]
Biplot 2 (Sedang) & Kompromi 1 (Rendah)	[1], [9], [11], [12], [13], [16], [18], [24], [33]
Biplot 2 (Sedang) & Kompromi 2 (Sedang)	[7], [8], [10], [14], [15], [17], [19], [20], [21], [23], [28], [32]
Biplot 3 (Tinggi) & Kompromi 2 (Sedang)	[26]
Biplot 3 (Tinggi) & Kompromi 3 (Tinggi)	[2], [3], [4], [5], [6], [22], [25], [27], [29], [30], [31], [38], [41]

Gambar 4.50 memperlihatkan perbandingan distribusi geografis klaster kompromi dan klaster Biplot tahun 2024 untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.50: Perbandingan Peta Klaster Kompromi (kiri) vs Klaster Biplot Tahun 2024 (kanan)

4.8.7 Perbandingan 8 — Konsistensi Klaster Kompromi terhadap Klaster STATIS Tahunan

Perbandingan kedelapan merupakan analisis konsistensi yang paling fundamental dalam kerangka STATIS, yaitu evaluasi kesesuaian antara klaster kompromi (yang dibangun dari seluruh periode) dengan klaster STATIS tahunan. Nilai kongruensi yang tinggi merupakan bukti empiris bahwa struktur kompromi $\mathbf{W}_c = \sum_k \alpha_k \mathbf{W}_k$ berhasil merangkum informasi temporal secara representatif.

Skenario 1 (Tahun 2024)

Tabel 4.62: Perbandingan Klaster Kompromi STATIS vs Klaster STATIS Tahunan (2024)

Kompromi STATIS	Statis 1 (Rendah) (2024)	Statis 2 (Sedang) (2024)	Statis 3 (Tinggi) (2024)
Kompromi 1 (Rendah)	12	0	0
Kompromi 2 (Sedang)	9	7	0
Kompromi 3 (Tinggi)	0	3	10

Tabel 4.63: Nama Daerah Perbandingan Klaster Kompromi STATIS vs STATIS Tahunan (2024)

Kategori	Daftar Wilayah
Kompromi 1 (Rendah) & Statis 1 (Rendah)	[1], [9], [11], [12], [13], [16], [18], [24], [33], [34], [35], [37]
Kompromi 2 (Sedang) & Statis 1 (Rendah)	[8], [15], [17], [19], [23], [32], [36], [39], [40]
Kompromi 2 (Sedang) & Statis 2 (Sedang)	[7], [10], [14], [20], [21], [26], [28]
Kompromi 3 (Tinggi) & Statis 2 (Sedang)	[22], [25], [31]
Kompromi 3 (Tinggi) & Statis 3 (Tinggi)	[2], [3], [4], [5], [6], [27], [29], [30], [38], [41]

Skenario 2 (Tahun 2024)

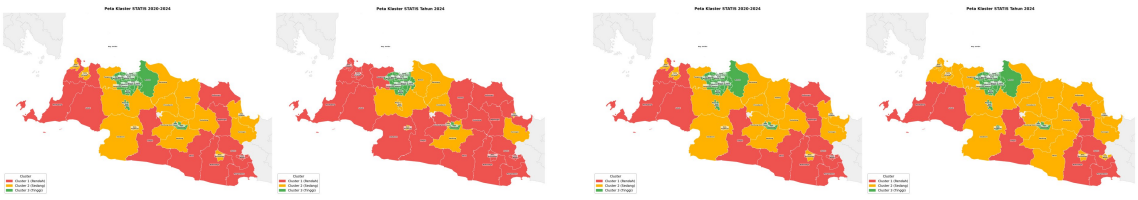
Tabel 4.64: Perbandingan Klaster Kompromi STATIS vs Klaster STATIS Tahunan (2024)

Kompromi STATIS	Statis 1 (Rendah) (2024)	Statis 2 (Sedang) (2024)	Statis 3 (Tinggi) (2024)
Kompromi 1 (Rendah)	7	5	0
Kompromi 2 (Sedang)	0	15	1
Kompromi 3 (Tinggi)	0	0	13

Tabel 4.65: Nama Daerah Perbandingan Klaster Kompromi STATIS vs STATIS Tahunan (2024)

Kategori	Daftar Wilayah
Kompromi 1 (Rendah) & Statis 1 (Rendah)	[9], [12], [13], [16], [24], [34], [35]
Kompromi 1 (Rendah) & Statis 2 (Sedang)	[1], [11], [18], [33], [37]
Kompromi 2 (Sedang) & Statis 2 (Sedang)	[7], [8], [10], [14], [15], [17], [19], [20], [21], [23], [28], [32], [36], [39], [40]
Kompromi 2 (Sedang) & Statis 3 (Tinggi)	[26]
Kompromi 3 (Tinggi) & Statis 3 (Tinggi)	[2], [3], [4], [5], [6], [22], [25], [27], [29], [30], [31], [38], [41]

Gambar 4.51 memperlihatkan perbandingan distribusi geografis klaster kompromi dan klaster STATIS tahun 2024 untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.51: Perbandingan Peta Klaster Kompromi (kiri) vs Klaster STATIS Tahun 2024 (kanan)

Dominasi elemen diagonal memvalidasi bahwa klaster kompromi STATIS bukanlah sekadar rata-rata aritmetika temporal, melainkan representasi yang secara struktural konsisten terhadap kondisi tahunan. Ketidakkonsistenan minor pada elemen di luar diagonal utama umumnya berasal dari wilayah-wilayah yang mengalami perubahan status klaster pada tahun tertentu, khususnya pada 2020–2021 akibat guncangan pandemi yang sempat menggeser posisi beberapa wilayah perbatasan klaster.

4.8.8 Perbandingan 9 — Validasi Eksternal Final Klaster Kompromi terhadap Kategori IPM

Perbandingan kesembilan merupakan validasi eksternal final yang membandingkan klaster kompromi STATIS, sebagai representasi kondisi pembangunan manusia selama 2020–2024 secara keseluruhan, dengan kategori IPM UNDP per tahun. Korespondensi yang tinggi antara klaster longitudinal *data-driven* dengan kategori institusional normatif merupakan validasi eksternal paling kuat atas relevansi substantif metode STATIS dalam konteks kebijakan pembangunan manusia.

Skenario 1 (Tahun 2024)

Tabel 4.66: Perbandingan Klaster Kompromi STATIS vs Kategori IPM (UNDP) (2024)

Kompromi STATIS	Sangat Tinggi	Tinggi	Sedang	Rendah
Kompromi 1 (Rendah)	0	3	9	0
Kompromi 2 (Sedang)	0	15	1	0
Kompromi 3 (Tinggi)	11	2	0	0

Tabel 4.67: Nama Daerah Perbandingan Klaster Kompromi STATIS vs IPM (UNDP) (2024)

Kategori	Daftar Wilayah
Kompromi 1 (Rendah) & Tinggi	[1], [13], [33]
Kompromi 1 (Rendah) & Sedang	[9], [11], [12], [16], [18], [24], [34], [35], [37]
Kompromi 2 (Sedang) & Tinggi	[7], [10], [14], [15], [17], [19], [20], [21], [23], [26], [28], [32], [36], [39], [40]
Kompromi 2 (Sedang) & Sedang	[8]
Kompromi 3 (Tinggi) & Sangat Tinggi	[2], [3], [4], [5], [6], [27], [29], [30], [31], [38], [41]
Kompromi 3 (Tinggi) & Tinggi	[22], [25]

Skenario 2 (Tahun 2024)

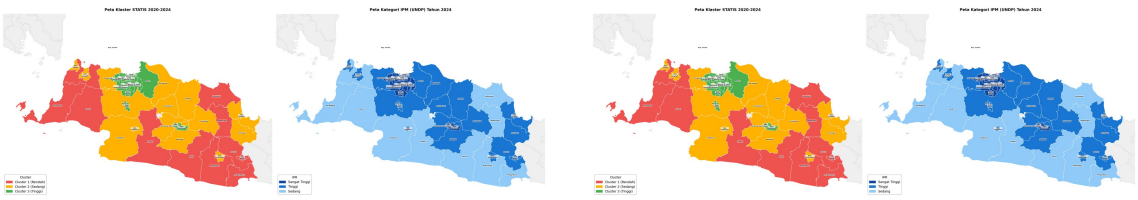
Tabel 4.68: Perbandingan Klaster Kompromi STATIS vs Kategori IPM (UNDP) (2024)

Kompromi STATIS	Sangat Tinggi	Tinggi	Sedang	Rendah
Kompromi 1 (Rendah)	0	3	9	0
Kompromi 2 (Sedang)	0	15	1	0
Kompromi 3 (Tinggi)	11	2	0	0

Tabel 4.69: Nama Daerah Perbandingan Klaster Kompromi STATIS vs IPM (UNDP) (2024)

Kategori	Daftar Wilayah
Kompromi 1 (Rendah) & Tinggi	[1], [13], [33]
Kompromi 1 (Rendah) & Sedang	[9], [11], [12], [16], [18], [24], [34], [35], [37]
Kompromi 2 (Sedang) & Tinggi	[7], [10], [14], [15], [17], [19], [20], [21], [23], [26], [28], [32], [36], [39], [40]
Kompromi 2 (Sedang) & Sedang	[8]
Kompromi 3 (Tinggi) & Sangat Tinggi	[2], [3], [4], [5], [6], [27], [29], [30], [31], [38], [41]
Kompromi 3 (Tinggi) & Tinggi	[22], [25]

Gambar 4.52 memperlihatkan perbandingan distribusi geografis klaster kompromi dan kategori IPM UNDP tahun 2024 untuk kedua skenario.



Skenario 1 Skenario 2

Gambar 4.52: Perbandingan Peta Klaster Kompromi (kiri) vs Kategori IPM UNDP Tahun 2024 (kanan)

Berdasarkan Tabel 4.67, pola kesesuaian antar-kelompok adalah sebagai berikut:

- **Klaster 3 (Maju) dan Kategori IPM Atas:** Sebelas dari 13 anggota Klaster 3 kompromi berkategori IPM "Sangat Tinggi" ($\geq$ 80): kelima kota DKI Jakarta,

Kota Bandung, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Tangerang, dan Kota Tangerang Selatan. Dua anggota lainnya yakni Kabupaten Bekasi dan Kota Bogor yang berkategori "Tinggi", ini mencerminkan wilayah urban-pinggiran dengan capaian tinggi namun belum mencapai ambang batas ≥ 80. Presisi Klaster 3 kompromi terhadap IPM "Sangat Tinggi" sebesar $84{,}6\%$ (11 dari 13) merupakan bukti validitas konstruk yang sangat kuat bahwa pemisahan dimensi kompromi ($\mathbf{F}_c$) mencerminkan hierarki pembangunan yang konsisten dengan standar internasional.

- **Klaster 2 (Berkembang) yang Homogen:** Klaster 2 kompromi justru bersifat cukup homogen dari sisi IPM: 15 dari 16 anggotanya berkategori IPM "Tinggi" (70–79,99), mewakili hampir seluruh koridor industri dan wilayah penyangga. Hanya Kabupaten Sukabumi yang berkategori "Sedang", namun profil multivariat gabungannya tetap menempatkannya lebih dekat ke kelompok berkembang daripada kelompok tertinggal. Homogenitas ini menegaskan bahwa Klaster 2 secara substantif merepresentasikan wilayah-wilayah dalam koridor IPM "Tinggi" yang secara struktural belum mencapai capaian wilayah metropolitan.

- **Klaster 1 (Tertinggal) dan Kategori IPM Bawah:** Klaster 1 kompromi didominasi oleh 9 wilayah berkategori IPM "Sedang" (55–69,99): Cianjur, Garut, Tasikmalaya, Majalengka, Indramayu, Pangandaran, Pandeglang, Lebak, dan Serang, seluruhnya merupakan kabupaten pedalaman atau rural di Banten Selatan dan Jawa Barat Selatan. Tiga anggota lainnya, yaitu Kepulauan Seribu, Ciamis, dan Kota Banjar memiliki kategori "Tinggi" namun tetap terklasifikasikan ke Klaster 1 karena profil multivariat gabungan 11 indikator yang menempatkan mereka lebih dekat ke kelompok tertinggal. Kesesuaian ini menunjukkan bahwa posisi klaster dalam ruang kompromi merupakan representasi yang valid secara substantif dari kondisi pembangunan struktural jangka menengah.

Korespondensi tinggi antara klaster kompromi *data-driven* dengan kategori normatif UNDP merupakan validasi eksternal yang memperkuat bahwa metode STATIS mampu mengekstrak struktur laten pembangunan manusia yang bermakna secara kebijakan dari data longitudinal multivariat.

4.9 Uji Autokorelasi Spasial (Global Moran's I)

Sebagai tahap lanjutan, dilakukan uji autokorelasi spasial global menggunakan statistik Moran's I untuk mendeteksi apakah terdapat pola pengelompokan geografis yang

signifikan pada skor kompromi. Penghitungan mengacu pada Persamaan 2.73 di Bab 2, dengan prosedur inferensi permutasi yang diuraikan pada Bab 3.

Skenario 1: ACT Klasik

Skenario 2: Dual STATIS

Hasil penghitungan menunjukkan:

- **Skenario 1 (ACT Klasik):** Moran's $I = 0,6903$, p-value $= 0,3151$, *Tidak Signifikan (Pola Spasial Acak)*
- **Skenario 2 (Dual STATIS):** Moran's $I = 0,6930$, p-value $= 0,3133$, *Tidak Signifikan (Pola Spasial Acak)*

Kedua skenario menghasilkan p-value $> 0{,}05$, sehingga **tidak terdapat autokorelasi spasial yang signifikan** pada skor kompromi PC1. Hasil ini konsisten dengan karakteristik data yang digunakan: skor kompromi mencerminkan posisi relatif kabupaten/kota dalam ruang multivariat pembangunan manusia, bukan besaran nilai geografis yang secara inheren bersifat spasial. Ketiadaan autokorelasi spasial menunjukkan bahwa kinerja pembangunan manusia di kawasan Banten–DKI Jakarta–Jawa Barat **lebih ditentukan oleh kapabilitas internal dan kebijakan sektoral masing-masing wilayah** daripada oleh efek kedekatan geografis (*spillover* spasial). Pola pengelompokan yang ditemukan (Klaster Tertinggal–Berkembang–Maju) adalah kluster statistik (berbasis kemiripan profil indikator), bukan kluster geografis yang tersebar membentuk *hot spot* atau *cold spot* dalam pengertian autokorelasi spasial klasik (**?**).

4.10 Analisis Hotspot (Local Moran's I)

Apabila nilai Moran's I positif dan signifikan ($I > E(I)$, $p < 0{,}05$), hal ini mengindikasikan terdapat **pola pengelompokan spasial positif** (*positive spatial clustering*): wilayah dengan skor kompromi tinggi cenderung bertetangga dengan wilayah berskor tinggi, dan demikian sebaliknya. Namun, karena p-value $> 0{,}05$ pada kedua skenario, tidak terdapat bukti statistik yang cukup untuk mengklaim adanya *hotspot* atau *coldspot* geografis yang bermakna pada data ini. Klaster yang ditemukan (Tertinggal, Berkembang, Maju) adalah kluster statistik berbasis kesamaan profil multivariat—bukan hasil autokorelasi geografis. Oleh karena itu, analisis Local Moran's I untuk mengidentifikasi hotspot lokal tidak relevan secara inferensial, dan kebijakan intervensi sebaiknya diarahkan berdasarkan profil kapabilitas internal wilayah, bukan semata-mata kedekatan geografisnya.

4.11 Ringkasan Temuan dan Implikasi Kebijakan

Berdasarkan keseluruhan analisis yang telah dilakukan, berikut adalah rangkuman temuan utama penelitian ini yang disusun untuk menjawab tujuan penelitian serta memberikan manfaat bagi akademik dan praktisi:

4.11.1 Pembahasan Berdasarkan Tujuan Penelitian

Penelitian ini telah berhasil mencapai lima tujuan utama yang dirumuskan pada Bab 1 sebagai berikut:

1. **Struktur Kompromi (Tujuan 1):** Melalui metode STATIS, telah berhasil dibentuk sebuah struktur kompromi yang merepresentasikan pola hubungan multivariat sebelas indikator pembangunan. Dimensi 1 kompromi berhasil merangkum $60,85\%$ variansi total, yang menunjukkan kontribusi dominan dari indikator ekonomi (PDRB) dan kualitas manusia (IPM). Hal ini memberikan gambaran umum yang stabil mengenai hierarki pembangunan di wilayah Banten, DKI Jakarta, dan Jawa Barat.

2. **Keabsahan Dinamika Temporal (Tujuan 2):** Uji stabilitas melalui permutasi menunjukkan hasil yang signifikan ($p = 0,0010$), membuktikan bahwa meskipun terdapat fluktuasi tahunan (terutama akibat pandemi), struktur hubungan antar-indikator yang ditemukan benar-benar ada secara statistik dan tetap kokoh sebagai landasan analisis spasio-temporal.

3. **Analisis Lintasan/Trajektori (Tujuan 3):** Visualisasi *Dynamic Biplot* secara efektif menggambarkan lintasan pergeseran 41 kabupaten/kota selama 2020–2024 pada Gambar 4.25. Tiga pola dominan teridentifikasi: (i) **Pemulihan V-shape** pada wilayah Klaster 3 metropolitan seperti Kota Tangerang Selatan mencatat peningkatan PC1 terbesar ($+0{,}85$ poin antara 2020 dan 2024), diikuti Kota Bekasi ($+0{,}39$) dan Kota Jakarta Pusat ($+0{,}26$); (ii) **Progresif bertahap** pada beberapa wilayah penyangga seperti Kota Sukabumi yang berhasil naik dari Klaster 2 ke Klaster 3 pada 2023; dan (iii) **Stagnasi dan penurunan relatif** pada wilayah Klaster 1 seperti Kabupaten Pangandaran (PC1 turun $-1{,}37$ poin) dan Garut ($-0{,}61$), yang skor PC1-nya justru semakin jauh dari skor PC1 wilayah-wilayah Klaster 3. Hal ini menandakan kesenjangan pembangunan yang melebar, bukan menyempit, selama lima tahun pengamatan.

4. **Pengelompokan dan Migrasi Wilayah (Tujuan 4):** Pengelompokan berbasis K-Means ($k = 3$) mengungkap tiga kelompok wilayah yang berbeda secara struktural

(Tertinggal, Berkembang, Maju). Matriks transisi menunjukkan: nol perpindahan pada 2020–2021 (stabilitas sempurna di tahun pertama pandemi); pemulihan selektif 2022–2023 dengan 6 wilayah naik K1→K2 (antara lain Garut, Ciamis, Kota Cilegon) dan 1 wilayah naik K2→K3 (Kota Sukabumi); serta restrukturisasi terbesar pada 2023–2024 dengan 14 wilayah turun K2→K1 (termasuk Tangerang, Kota Serang, Cirebon, Bandung Barat) dan 4 wilayah turun K3→K2 (Bekasi, Kota Bogor, Kota Sukabumi, Kota Cimahi). Sementara itu, 10 wilayah metropolitan inti (5 kota DKI beserta Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang, Kota Tangerang Selatan) tetap bertahan di Klaster 3 sepanjang 2020–2024, mengonfirmasi ketahanan struktural yang kokoh pada wilayah-wilayah tersebut.

5. **Platform Eksplorasi Interaktif (Tujuan 5):** Seluruh hasil penghitungan dan visualisasi ini telah diintegrasikan ke dalam naskah bab ini, yang merupakan representasi statis dari aplikasi berbasis web (Dash/Plotly) yang dikembangkan. Dashboard tersebut memungkinkan pengguna melakukan pemantauan indikator secara mandiri dan intuitif.

4.11.2 Kontribusi terhadap Manfaat Penelitian

Sesuai dengan manfaat penelitian yang diharapkan:

1. **Manfaat Akademis:** Penelitian ini memperkaya literatur statistik multivariat di Indonesia dengan menerapkan metode STATIS dan *Dynamic Biplot* yang masih jarang digunakan pada data regional. Penggabungan analisis inter-struktur, struktur kompromi, dan analisis klaster memberikan metodologi yang lebih dinamis dibandingkan analisis dua-arah konvensional.

2. **Manfaat Praktis:** Keberadaan visualisasi peta dan matriks transisi dalam aplikasi dashboard menyediakan alat bantu yang kuat bagi pemerintah daerah untuk mengevaluasi efektivitas kebijakan pembangunan secara komprehensif, tidak hanya melihat satu indikator secara terisolasi.

4.11.3 Implikasi Kebijakan

Temuan bahwa struktur kesenjangan pembangunan bersifat *struktural* dan terpola secara spasial menunjukkan bahwa kebijakan pembangunan yang bersifat "merata" (uniform) tidak akan efektif. Diperlukan kebijakan yang *targeted*, yang memfokuskan intervensi pada wilayah-wilayah Klaster 1 yang secara struktural tertinggal, terutama di bidang pendidikan (peningkatan RLS), pengurangan kemiskinan, dan penciptaan lapangan kerja. Strategi

pembangunan berbasis *regional spillover* dari pusat pertumbuhan (DKI Jakarta) ke wilayah penyangga perlu ditingkatkan untuk memperpendek kesenjangan spasio-temporal yang teramati dalam lima tahun terakhir.

BAB 5
KESIMPULAN DAN SARAN

Bab ini menyimpulkan hasil temuan utama dari analisis STATIS dan Dynamic Biplot mengenai dinamika pembangunan ekonomi regional di Provinsi Banten, DKI Jakarta, dan Jawa Barat, serta memberikan saran rekomendasi kebijakan maupun pengembangan penelitian selanjutnya.

5.1 Kesimpulan

Berdasarkan hasil penelusuran dan pembahasan yang telah dilakukan pada bab sebelumnya, dapat diperoleh beberapa kesimpulan analisis sebagai berikut:

1. **Karakteristik Struktur Kompromi (Menjawab Tujuan 1):** Melalui sintesis matriks kompromi STATIS (Skenario 1 $\mathbf{W}_c$ dan Skenario 2 $\mathbf{S}_c$), diperoleh representasi rata-rata spasio-temporal yang stabil selama periode 2020–2024. Dua dimensi utama berhasil diidentifikasi: Dimensi 1 merepresentasikan "Taraf Kemajuan Pembangunan Manusia dan Ekonomi" (didominasi oleh RLS, Angka Harapan Hidup L/P, GK, IPG, dan PDRB ADHK dengan loading $> 0{,}70$) serta menjelaskan bagian terbesar variansi total (60,85%). Dimensi 2 merepresentasikan "Tekanan Pasar Tenaga Kerja" (didominasi oleh Tingkat Pengangguran Terbuka dengan loading $+0{,}86$ dan Tingkat Partisipasi Angkatan Kerja dengan loading $-0{,}49$). Vektor bobot interstruktur ($\boldsymbol{\alpha}_W$ dan $\boldsymbol{\alpha}_S$) terdistribusi secara seimbang di antara kelima tahun pengamatan, yang membuktikan representativitas yang adil tanpa distorsi tahun ekstrem.

2. **Signifikansi Stabilitas Temporal dan Vektor Struktur (Menjawab Tujuan 2):** Analisis interstruktur STATIS menghasilkan koefisien RV yang sangat tinggi (seluruhnya di atas $0,9543$), membuktikan bahwa hierarki kemiripan antar-wilayah bersifat persisten lintas waktu. Uji permutasi Monte Carlo ($B = 1000$) membuktikan bahwa struktur kompromi tersebut **signifikan secara statistik** (p-value $= 0,0010 <$ $0{,}05$) dan bukan merupakan hasil fluktuasi acak. Kompresi interstruktur ke dalam vektor struktur $\tilde{\boldsymbol{\beta}} = \lambda_1 \boldsymbol{\alpha}_1$ secara longitudinal merekam dampak krisis pandemi (2020–2021) dan pemulihan (2022–2024) yang nyata, sementara analisis transversal membuktikan adanya heterogenitas respons temporal yang unik antar-provinsi.

3. **Pola Lintasan Trajektori Spasio-Temporal (Menjawab Tujuan 3):** Visualisasi *Dynamic Biplot* berhasil menggambarkan lintasan (*trajectory*) pergerakan 41 kabupaten/kota secara dinamis dari masa krisis (2020) hingga masa pemulihan (2024).

Tiga pola pergerakan diidentifikasi: (1) pola pemulihan berbentuk huruf V (*V-shape rebound*) pada kota-kota metropolitan berbasis jasa—Kota Tangerang Selatan mencatat peningkatan PC1 terbesar ($+0{,}85$ poin antara 2020 dan 2024), diikuti Kota Bekasi ($+0{,}39$) dan seluruh kota DKI Jakarta; (2) pola progresif bertahap (*monotone improvement*) pada wilayah penyangga seperti Kota Sukabumi yang berhasil naik ke Klaster 3 pada 2023; dan (3) pola stagnasi dan penurunan relatif (*inertia*) pada kabupaten pedalaman selatan—Kabupaten Pangandaran mengalami penurunan PC1 terbesar ($-1{,}37$ poin), diikuti Garut ($-0{,}61$) dan Cianjur ($-0{,}51$), menunjukkan bahwa skor PC1 wilayah-wilayah ini justru semakin jauh dari skor PC1 wilayah metropolitan Klaster 3—kesenjangan pembangunan melebar, bukan menyempit, selama lima tahun pengamatan.

4. **Pengelompokan Spasial dan Dinamika Transisi (Menjawab Tujuan 4):** Jumlah klaster optimal $k = 3$ dipilih berdasarkan kombinasi kurva Elbow dan koefisien siluet rata-rata ($SC = 0,3883$), yang mengonfirmasi pemisahan antar-klaster yang memadai. Penerapan algoritma K-Means ($k = 3$) pada skor kompromi berhasil mengklasifikasikan wilayah menjadi tiga kelompok: Klaster 1 (Tertinggal, 12 wilayah—Banten Selatan dan Jawa Barat pedalaman selatan), Klaster 2 (Berkembang, 16 wilayah—koridor industri dan penyangga), dan Klaster 3 (Maju, 13 wilayah—metropolitan). Matriks transisi temporal mengonfirmasi stabilitas sempurna pada 2020–2021 (nol perpindahan), diikuti pemulihan selektif 2022–2023 (6 wilayah naik K1→K2, termasuk Garut dan Kepulauan Seribu; 1 wilayah naik K2→K3 yaitu Kota Sukabumi), dan restrukturisasi terbesar 2023–2024 (14 wilayah turun K2→K1 dan 4 wilayah turun K3→K2). Sepuluh wilayah metropolitan inti (5 kota DKI beserta Kota Bandung, Kota Bekasi, Kota Depok, Kota Tangerang, Kota Tangerang Selatan) tetap bertahan di Klaster 3 sepanjang seluruh periode, mengonfirmasi ketahanan struktural yang kokoh.

5. **Pengembangan Dashboard Eksplorasi Interaktif (Menjawab Tujuan 5):** Aplikasi berbasis web dikembangkan menggunakan *framework* Dash dan Plotly sebagai instrumen eksplorasi visual interaktif yang andal. Fitur-fitur seperti pemetaan spasial dinamis, visualisasi trajektori, seleksi tahun, dan rotasi sumbu *baseline* berhasil memfasilitasi pemantauan indikator pembangunan secara interaktif oleh peneliti dan pemangku kebijakan. Keandalan model terkonfirmasi melalui validasi eksternal (tabulasi silang) yang menunjukkan kesesuaian yang sangat tinggi antara klaster STATIS dengan klasifikasi normatif kategori IPM UNDP.

5.2 Saran

Berdasarkan kesimpulan di atas, diajukan beberapa saran sebagai berikut:

1. **Implikasi Kebijakan *Targeted* Regional:** Mengingat struktur ketimpangan yang persisten dan terpola secara spasial, kebijakan pemerataan pembangunan tidak cukup hanya mengandalkan pertumbuhan ekonomi nasional. Diperlukan intervensi struktural yang *targeted* pada wilayah Klaster 1 (Tertinggal), khususnya Kabupaten Lebak, Pandeglang, dan Garut, dengan fokus pada peningkatan kapabilitas dasar (RLS, AHH) serta pengurangan kemiskinan melalui strategi *regional spillover* dari pusat pertumbuhan DKI Jakarta.

2. **Pengembangan Penelitian Lanjutan:** Penelitian ini dibatasi pada indikator makroekonomi tahunan dari 3 provinsi. Penelitian selanjutnya disarankan untuk menggunakan data dengan resolusi waktu yang lebih tinggi (triwulanan) apabila tersedia, memperluas cakupan wilayah ke seluruh Pulau Jawa atau Indonesia dengan mengintegrasikan metode *Dual STATIS* untuk analisis korelasi indikator, serta menambahkan indikator sosial-infrastruktur guna memperkaya dimensi analisis.

3. **Pengembangan Model Prediktif Spasio-Temporal (*Forecasting*):** Karena penelitian ini terbatas pada analisis deskriptif-eksploratif data historis, penelitian selanjutnya sangat disarankan untuk mengintegrasikan model prediktif (peramalan) guna memproyeksikan skor wilayah (F_k) dan loading indikator (G_k) ke tahun berikutnya ($k = K + 1$). Hal ini dapat diwujudkan dengan menerapkan pemodelan deret waktu (seperti ARIMA, Vector Autoregression (VAR), atau model *Grey Systems* GM(1,1) yang sangat handal untuk deret data pendek $K = 5$) langsung pada barisan koordinat kompromi ($\mathbf{f}_{i,k}$ dan $\mathbf{g}_{j,k}$) dan lintasan komponen vektor struktur ($\tilde{\beta}_k$). Dengan memproyeksikan lintasan koordinat ini, pemangku kebijakan dapat mengantisipasi pergeseran status kesejahteraan wilayah dan dinamika hubungan antar-indikator secara prospektif.

4. **Pengembangan Platform *Dashboard* Interaktif:** Dashboard berbasis web (Dash/Plotly) yang dikembangkan dalam penelitian ini dapat dikembangkan lebih lanjut dengan menambahkan fitur pembaruan data secara otomatis dari API BPS Open Data, sehingga pemantauan dinamika pembangunan regional dapat dilakukan secara *near real-time* oleh pemangku kepentingan kebijakan.